



**ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ**

Оюутны код: s21c033b
Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

**МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ
ТААМАГЛАХ АРИЛЖААНЫ БОТ
/ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/**

Удирдагч багш
Гүйцэтгэсэн оюутан

Н.СОРОНЗОНБОЛД
М.МӨНХДОРЖ

Улаанбаатар хот
2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Төгсөлтийн судалгааны ажил

**МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ
ТААМАГЛАХ АРИЛЖААНЫ БОТ**

Гүйцэтгэгч: М.МӨНХДОРЖ

Удирдагч: Н.СОРОНЗОНБОЛД

Улаанбаатар хот
2026 он

Хураангуй

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргуудыг ашиглан валютын зах зээл (Forex) дээрх EUR/USD хослолын үнийн чиг хандлагыг таамаглах, автомат арилжааны дохио үүсгэх систем болон гар утасны апликеийшн хөгжүүлсэн.

Системийн цөм нь LightGBM, XGBoost, CatBoost гэсэн гурван градиент нэмэгдүүлсэн шийдвэрийн модны (GBDT) ансамбль загвар юм. Загваруудыг 2015–2022 оны ~2.97 сая бааранд сургаж, 2023 оны 371,000 бааранд баталгаажуулж, 2024 оны 371,000 бааранд тестэлсэн. Walk-forward validation аргачлалыг хэрэглэж overfitting-ийн эрсдэлийг бууруулсан. 6 хугацааны интервалаас (M1–H4) нийт 48 техник шинж чанар тооцоолж, олон хугацааны хүрээний дун шинжилгээг хэрэгжүүлсэн.

2025 оны бэктест дун: 10,000\$ анхны хөрөнгөөс 14,161.20\$ болж **+41.61%** өгөөж, **Profit Factor 2.46**, **Sharpe Ratio 9.64**, **хамгийн их уналт 3.93%** хүрсэн. React Native технологи дээр сууринсан “Predictrix” мобайл апликеийшн нь бодит цагийн ханш, ML дохио, эдийн засгийн мэдээ, хэрэглэгчийн баталгаажуулалт зэрэг бүрэн функцийг хэрэгжүүлсэн.

Түлхүүр үсг: машин сургалт, ансамбль загвар, валютын зах зээл, GBDT, XGBoost, LightGBM, CatBoost, техник шинжилгээ, арилжааны дохио, React Native, бэктест

Abstract

This research develops an automated trading signal generation system and mobile application for predicting EUR/USD price movements in the Forex market using machine learning ensemble methods.

The core of the system is an ensemble of three Gradient Boosted Decision Tree (GBDT) models: LightGBM (496 trees), XGBoost (~400 trees), and CatBoost (499 trees). The models were trained on ~2.97 million bars from 2015–2022, validated on 371,000 bars from 2023, and tested on 371,000 bars from 2024. Walk-forward validation methodology was employed to mitigate overfitting risks. A total of 48 technical features were computed from 6 timeframes (M1, M5, M15, M30, H1, H4), implementing multi-timeframe analysis.

Backtest results for 2025: starting from \$10,000 initial capital, the system achieved \$14,161.20 final balance (**+41.61%** return), **Profit Factor 2.46**, **Sharpe Ratio 9.64**, and **Maximum Drawdown 3.93%**. The “Predictrix” mobile application, built with React Native, provides real-time exchange rates, ML signals, economic news, and user authentication.

Keywords: *machine learning, ensemble model, foreign exchange market, GBDT, XGBoost, LightGBM, CatBoost, technical analysis, trading signals, React Native, backtesting*

Гарчиг	i
Хураангуй	
Гарчиг	ii
Товчилсон үгсийн жагсаалт	iii
Хүснэгтийн жагсаалт	iv
Зургийн жагсаалт	v
Оршил	1
1 Ажлын төлөвлөгөө	3
2 Удиртгал	4
2.1 Ажлын бүтэц ба агуулга	4
3 Судалгааны сэдвийн онол, өнөөгийн түвшин	5
3.1 Онолын хэсэг	5
3.2 Техник шинжилгээний үндэс	5
3.3 Машин сургалтын ансамбль аргууд	6
3.4 Ижил төрлийн судалгаа	7
3.5 Бүлгийн дүгнэлт	8
4 Судалгааны арга зүй	9
4.1 Системийн ерөнхий архитектур	9
4.2 Өгөгдлийн бэлтгэл	9
4.3 Загварын бүтэц ба сургалт	11
4.4 Дохио үүсгэх систем	12
4.5 MetaTrader 5 бэквест	13
4.6 Backend API хөгжүүлэлт	13
4.7 Мобайл аппликашн хөгжүүлэлт	14
4.8 Хөгжүүлэлтийн үе шатууд	15
4.9 Бүлгийн дүгнэлт	15
5 Судалгааны үр дүн, дүгнэлт	16
5.1 Загварын сургалтын үр дүн	16
5.2 Бэкстийн дүн	16
5.3 Гүйцэтгэлийн гүнзгий шинжилгээ	19
5.4 Хөгжүүлэлтийн үе шатуудын харьцуулалт	21
5.5 Overfitting шинжилгээ	22
5.6 Мобайл аппликашний ажиллагаа	23
5.7 Дүгнэлт	23
Ном зүй	24
Хавсралт	25
Талархал	28
Товчлол	29

Товчилсон үгсийн жагсаалт

ML Machine Learning – Машин сургалт

AI Artificial Intelligence – Хиймэл оюун ухаан

GBDT Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

XGBoost Extreme Gradient Boosting

LightGBM Light Gradient Boosting Machine

CatBoost Categorical Boosting

LSTM Long Short-Term Memory – Урт богино хугацааны санах ой

RSI Relative Strength Index – Харьцангуй хүчний индекс

ATR Average True Range – Дундаж жинхэнэ хүрээ

MACD Moving Average Convergence Divergence

SMA Simple Moving Average – Энгийн хөдөлгөөнт дундаж

EMA Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

ADX Average Directional Index – Дундаж чиглэлийн индекс

CCI Commodity Channel Index

SL Stop Loss – Алдагдал зогсоох

TP Take Profit – Ашиг авах

API Application Programming Interface

REST Representational State Transfer

JWT JSON Web Token

OHLCV Open, High, Low, Close, Volume

MT5 MetaTrader 5

PF Profit Factor – Ашгийн коэффициент

DD Drawdown – Уналт

RR Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

CORS Cross-Origin Resource Sharing

WSGI Web Server Gateway Interface

CSV Comma-Separated Values

Хүснэгтийн жагсаалт

Хүснэгт 4.1.	Өгөгдлийн хэмжээний хураангуй	9
Хүснэгт 4.2.	Шинж чанарын жагсаалт (интервал бүрд)	10
Хүснэгт 4.3.	Walk-Forward Validation – өгөгдлийн хуваалт	10
Хүснэгт 4.4.	Загвар бүрийн гол гиперпараметрүүд	11
Хүснэгт 4.5.	EA-ийн тохиргооны параметрүүд	13
Хүснэгт 4.6.	Backend технологийн стек	13
Хүснэгт 4.7.	Гол API endpoint-үүд	14
Хүснэгт 4.8.	Мобайл апликацийний технологийн стек	14
Хүснэгт 4.9.	Хөгжүүлэлтийн үе шатууд	15
Хүснэгт 5.1.	Загварын нарийвчлалын хэмжүүрүүд	16
Хүснэгт 5.2.	Загвар бүрийн шинж чанар	16
Хүснэгт 5.3.	MetaTrader 5 бэктестийн дүн (Phase 7B)	17
Хүснэгт 5.4.	Phase 6B ба Phase 7B-ийн харьцуулалт	21
Хүснэгт 5.5.	Бенчмарк харьцуулалт	22
Хүснэгт 5.6.	2025 оны дохионы жишээ	28

Зургийн жагсаалт

Зураг 4.1.	Системийн ерөнхий архитектур	9
Зураг 4.2.	Ансамбль загварын архитектур	11
Зураг 5.1.	Equity муруй – \$10,000-aac \$14,161.20 хүртэл (+41.61%)	17
Зураг 5.2.	Сарын гүйцэтгэл – ашиг (\$) ба win rate (%)	18
Зураг 5.3.	Уналтын шинжилгээ (Max Drawdown: 3.93%)	18
Зураг 5.4.	Эрсдэлийн хэмжүүрүүдийн самбар	19
Зураг 5.5.	Итгэлцлийн утга ба таамаглалын нарийвчлалын хамаарал	20
Зураг 5.6.	Шинж чанарын ач холбогдол (Top 20)	20
Зураг 5.7.	Phase 6B ба Phase 7B-ийн харьцуулалт	21
Зураг 5.8.	Phase 6B ба Phase 7B харьцуулалтын хүснэгт	22

Оршил

Судалгааны сэдвийн тодорхойлолт

Валютын зах зээл (Foreign Exchange буюу Forex) нь дэлхийн хамгийн том, хөрвөх чадвар өндөртгэй санхүүгийн зах зээл бөгөөд өдөр тутмын арилжааны хэмжээ нь 7.5 их наяд ам.долларт хүрдэг. Энэхүү зах зээл нь 24 цагийн турш ажилладаг, олон улсын эдийн засаг, геополитик нөхцөл байдал, төв банкуудын бодлого зэрэг олон тооны хүчин зүйлээс хамаардаг нь үнийн хөдөлгөөнийг таамаглахад ихээхэн хүндрэлийг учруулдаг.

Уламжлалт техник дүн шинжилгээний аргууд болон суурь дүн шинжилгээ нь хүний туршлага, мэдлэгт ихээхэн найддаг боловч хэлбэлзэл ихтэй, өндөр давтамжтай арилжаанд тэдгээрийн үр ашиг хязгаарлагдмал байдаг. Мөн хүний шийдвэр нь сэтгэл хөдлөл, субъектив үнэлгээнээс нөлөөлөгдж болзошгүй нь алдаа гаргах магадлалыг нэмэгдүүлдэг.

Судалгааны шаардлага ба актуальность

Сүүлийн арваад жилд машин сургалт (Machine Learning) болон хиймэл оюун ухааны технологиуд санхүүгийн салбарт өргөн хэрэглэгдэж эхэлсэн. Gradient Boosted Decision Trees (GBDT), нейрон сүлжээ зэрэг орчин үеийн алгоритмууд нь том хэмжээний өгөгдөл боловсруулж, нарийн төвөгтэй хэв маягуудыг илрүүлэх чадвартай болсон. Гэвч дараах асуудлууд одоо ч байсаар байна:

- **Overfitting:** Олон загвар нь сургалтын өгөгдөл дээр сайн ажилладаг боловч бодит зах зээл дээр муу үр дүн үзүүлдэг.
- **Хүртээмж:** Ихэнх судалгаанууд академик түвшинд хийгдсэн, практик хэрэглэгчдэд хүртээмжтэй бус.
- **Дан загварын хязгаарлалт:** Нэг загвар ашигладаг систем нь тогтвортой бус, эрсдэл өндөртэй.
- **Бодит цагийн мэдээлэл дутагдал:** Загвар дангаараа хүрэлцэхгүй, хэрэглэгчдэд ойлгомжтой интерфейс, шинэ мэдээлэл хэрэгтэй.

Эдгээр асуудлыг шийдвэрлэхийн тулд ансамбль загварууд, walk-forward validation аргачлал, мөн гар утасны аппликашн хөгжүүлэх нь зайлшгүй шаардлагатай болсон.

Судалгааны зорилго

Энэхүү судалгааны ажлын гол зорилго нь **машин сургалтын ансамбль аргуудыг ашиглан EUR/USD валютын хослолын үнийн чиг хандлагыг таамаглах, автомат арилжааны дохио үүсгэх найдвартай систем болон гар утасны аппликашн хөгжүүлэх** явдал юм.

Судалгааны зорилтууд

Дээрх зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлсэн:

1. Forex валютын зах зээлийн онцлог, техник дүн шинжилгээний үндсэн ойлголтууд, машин сургалтын аргуудыг судлах.
2. LightGBM, XGBoost, CatBoost гэсэн түүхэн өгөгдөл ашиглан загваруудыг сургах, баталгаажуулах, тестлэх.
3. 2015–2024 оны EUR/USD түүхэн өгөгдөл ашиглан загваруудыг сургах, баталгаажуулах, тестлэх.
4. Walk-forward validation аргачлалыг хэрэгжүүлж overfitting-ийн эрсдэлийг бууруулах.
5. 6 хугацааны интервалаас (M1, M5, M15, M30, H1, H4) 48 техник шинж чанаруудыг тооцоолох, олон хугацааны дүн шинжилгээ хийх.
6. MetaTrader 5 платформ дээр Expert Advisor ашиглан 2025 оны бэктест хийх.

7. React Native ашиглан “Predictrix” нэртэй гар утасны аппликашн хөгжүүлж, бодит цагийн мэдээлэл, ML дохио, эдийн засгийн мэдээ зэрэг функцуудийг нэгтгэх.
8. Системийн гүйцэтгэл, найдвартай байдлыг үнэлэх, практик хэрэглээний чиглэлийг тодорхойлох.

Судалгааны ач холбогдол

Энэхүү судалгааны ажлын ач холбогдол нь:

- **Шинжлэх ухааны ач холбогдол:** Ансамбль загваруудын хослол, walk-forward validation аргачлалын хэрэглээ, олон хугацааны интервалаас шинж чанар гаргаж ашигласан нь Forex таамаглалын судалгаанд хувь нэмэр оруулна.
- **Практик ач холбогдол:** Хувь хүн, жижиг арилжаачдад хүртээмжтэй, хэрэглэхэд хялбар, үнэ төлбөргүй систем нь Forex зах зээлд оролцох боломжийг нээж өгнө.
- **Технологийн ач холбогдол:** Орчин үеийн Machine Learning, мобайл хөгжүүлэлт, backend системүүдийг нэгтгэсэн end-to-end шийдэл бий болгосон нь Монгол Улсын FinTech салбарын хөгжилд хувь нэмэр оруулна.

Судалгааны ажил нь загварын сургалтаас эхлээд мобайл аппликашн хүртэлх бүрэн end-to-end системийг хамарсан цогц инженерийн ажил юм.

1. Ажлын төлөвлөгөө

Оюутны нэр: М.МӨНХДОРЖ

Удирдагч багшийн нэр: Н.СОРОНЗОНБОЛД

Судалгааны ажлын сэдэв: Машин сургалтын аргаар хөрөнгийн зах зээлийн чиг хандлагыг таамаглах арилжааны бот хөгжүүлэх

Cap	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 cap	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Forex арилжаа, ML онолын судалгаа хийх	✓
	3	Twelve Data API-aac EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 cap	1	70+ техникийн индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модель сургах	✓
	3	Stacking Ensemble модель хөгжүүлэх, backtesting хийх	✓
	4	Flask REST API сервер, React Native апп хөгжүүлэх	✓
12 cap	1	TCA Үзлэг 1	□
	2	Төгсөлтийн тайлан бичиж эхлэх	□
	3	Тайлангийн 1-2 бүлэг бичих	□
	4	Тайлангийн 3 бүлэг бичих	□
1 cap	1	Тайлангийн 4 бүлэг бичих	□
	2	Тайлангийн 5 бүлэг бичих	□
	3	График, хүснэгт, үр дүнг боловсруулах	□
	4	Тайланг засварлах, форматлах	□
2 cap	1	Тайлангийн эцсийн засвар	□
	2	Ном зүй, хавсралт бэлдэх	□
	3	Хамгаалалтын слайд бэлдэх	□
	4	Хамгаалалтын бэлтгэл хийх	□
3 cap	1	TCA Үзлэг 2	□
	2	Засвар хийх, санал хүсэлтийг тусгах	□
	3	Код тайлбар, баримтжуулалт	□
	4	Хамгаалалтын дадлага хийх	□
4 cap	1	Эцсийн засвар хийх	□
	2	Слайд сайжруулах	□
	3	Хамгаалалтын бэлтгэл	□
	4	TCA урьдчилсан хамгаалалт	□
5 cap	1	TCA урьдчилсан хамгаалалт	□
	2	TCA урьдчилсан хамгаалалт	□
	3	Эцсийн засвар, сайжруулалт	□
	4	TCA үндсэн хамгаалалт	□

Удирдагч багш:

/Н.СОРОНЗОНБОЛД/

Гүйцэтгэсэн оюутан:

/s21c033b, М.МӨНХДОРЖ/

2. Удиртгал

Энэхүү судалгааны ажил нь машин сургалтын ансамбль аргуудыг ашиглан Forex валютын зах зээл дээр арилжааны дохио үүсгэх систем хөгжүүлэх, мөн хэрэглэгчдэд хүртээмжтэй гар утасны аппликашн бүтээх зорилготой юм. Судалгааны ажил нь онол (машин сургалт, санхүүгийн дүн шинжилгээ), практик хэрэгжүүлэлт (загварын сургалт, бэкстест), болон технологийн нэгтгэл (мобайл аппликашн, backend систем)-ийг хамарсан цогц ажил юм.

Судалгааны гол бүрэлдэхүүн хэсгүүд нь:

- **ML загварын ансамбль:** LightGBM, XGBoost, CatBoost – гурван GBDT загварыг нэгтгэсэн систем
- **Walk-forward validation:** Overfitting-aac сэргийлэх цаг хугацаанд суурилсан баталгаажуулалт
- **Олон хугацааны дүн шинжилгээ:** M1–H4 хүртэлх 6 интервалын 48 техник шинж чанар
- **Бэкстест:** MetaTrader 5 Strategy Tester дээрх бодит зах зээлийн нөхцөлд шалгалт
- **“Predictrix” аппликашн:** React Native дээр хөгжүүлсэн бодит цагийн мэдээлэл бүхий гар утасны програм

2.1. Ажлын бүтэц ба агуулга

Судалгааны ажил нь дараах бүлгүүдээс бүрдэнэ:

2-р бүлэг – Онолын үндэслэл, холбогдох судалгаанууд

Энэ бүлэгт валютын зах зээлийн онцлог, техник дүн шинжилгээний үндсэн ойлголтууд (индикаторууд, график загварууд), машин сургалтын аргууд (ялангуяа Gradient Boosted Decision Trees), мөн холбогдох судалгаануудын тойм танилцуулагдана. Онолын суурийг бий болгож, энэхүү судалгааг бусад судалгаануудтай харьцуулан байршуулна.

3-р бүлэг – Арга зүй

Судалгааны үндсэн техник хэрэгжүүлэлтийг дэлгэрүүлсэн бүлэг. Өгөгдлийн цуглувалт, цэвэрлэлт, шинж чанарын инженерчлэл (48 техник индикатор, олон хугацааны интервалын мэдээлэл), гурван GBDT загварын сургалт, walk-forward validation аргачлал, ансамблын шийдвэр гаргах механизм, мөн “Predictrix” аппликашний архитектур, backend API (FastAPI), мобайл интерфейсийн (React Native) хөгжүүлэлтийг багтаасан.

4-р бүлэг – Үр дүн

Загварын гүйцэтгэл (нарийвчлал, сэргээлт, F1-score), бэкстестийн дүн (өгөөж, Sharpe Ratio, максимум уналт, Profit Factor), хөгжүүлэлтийн 7 үе шатуудын (Phase 1–7B) харьцуулалт, эрсдэлийн дүн шинжилгээ, системийн хязгаарлалтуудыг танилцуулна. Бодит цагийн гүйцэтгэл, худал дохионы шинжилгээ, зах зээлийн янз бүрийн нөхцөлд систем хэрхэн ажилласан талаар дэлгэрүүлнэ.

5-р бүлэг – Дүгнэлт ба цаашдын судалгаа

Судалгааны гол үр дүнг товчлон дүгнэж, олж авсан мэдлэг, практик ач холбогдол, системийн давуу болон сул талуудыг үнэлнэ. Цаашдын судалгааны боломжит чиглэлүүд (нэмэлт валютын хослол, гүн сургалтын аргууд, бусад хугацааны интервал, эрсдэлийн удирдлага сайжруулах гэх мэт)-ийг санал болгоно.

3. Судалгааны сэдвийн онол, өнөөгийн түвшин

3.1. Онолын хэсэг

Валютын зах зээлийн тухай ойлголт

Валютын зах зээл (Foreign Exchange Market) нь дэлхий дээрх хамгийн том, хамгийн хөрвөх чадвартай санхүүгийн зах зээл юм. Олон Улсын Төлбөр Тооцооны Банкны (BIS) 2022 оны судалгаагаар өдрийн дундаж арилжааны хэмжээ 7.5 их наяд ам.доллар байна (BIS, 2022). Зах зээл долоо хоногийн 5 өдөр, 24 цагийн турш ажилладаг бөгөөд Лондон, Нью-Йорк, Токио, Сидней гэсэн дөрвөн гол сессстэй.

EUR/USD нь Forex зах зээлийн хамгийн их арилжаалагддаг валютын хослол бөгөөд нийт арилжааны ~22.7%-ийг бүрдүүлдэг. Энэ хослолын өвөрмөц шинж чанарууд:

- **Хөрвөх чадвар:** Маш өндөр – спрэд бага, хэрэгжилт хурдан
- **Хэлбэлзэл:** Дунд зэргийн – өдөрт 50–100 пипс хүрээнд
- **Хүчин зүйлс:** ECB, Fed-ийн мөнгөний бодлого, эдийн засгийн макро үзүүлэлтүүд

3.2. Техник шинжилгээний үндэс

Техник шинжилгээ нь өнгөрсөн үнийн өгөгдөл дүн шинжилгээ хийж ирээдүйн үнийн хөдөлгөөнийг таамаглах арга юм. Энэхүү судалгаанд хэрэглэсэн гол индикаторууд:

Хөдөлгөөнт дунджууд (Moving Averages)

Энгийн хөдөлгөөнт дундаж (SMA) нь n үеийн хаалтын үнийн арифметик дунджаар тооцоологдоно:

$$SMA_n = \frac{1}{n} \sum_{i=0}^{n-1} P_{t-i} \quad (3.1)$$

Экспоненциал хөдөлгөөнт дундаж (EMA) нь сүүлийн өгөгдөл илүү жин өгдөг:

$$EMA_t = \alpha \cdot P_t + (1 - \alpha) \cdot EMA_{t-1}, \quad \alpha = \frac{2}{n+1} \quad (3.2)$$

Энэхүү системд SMA болон EMA-г 5, 10, 20, 50, 200 гэсэн 5 янз бүрийн үетэй тооцоолж, чиг хандлагын дохио, кросс дохио (жишээ нь Golden Cross: SMA50 > SMA200) үүсгэсэн.

Relative Strength Index (RSI)

RSI нь моментум индикатор бөгөөд 0–100 хүрээнд хэлбэлздэг:

$$RSI = 100 - \frac{100}{1 + RS}, \quad RS = \frac{\text{Дундаж өсөлт}}{\text{Дундаж бууралт}} \quad (3.3)$$

RSI < 30 бол “хэт зарагдсан” (oversold), RSI > 70 бол “хэт худалдан авагдсан” (overbought) гэж үзнэ. Системд RSI-г 7, 14, 21 гэсэн гурван үетэй тооцоолсон.

MACD (Moving Average Convergence Divergence)

MACD нь хоёр экспоненциал хөдөлгөөнт дундажийн ялгавар юм:

$$MACD = EMA_{12} - EMA_{26} \quad (3.4)$$

$$\text{Signal Line} = EMA_9(MACD) \quad (3.5)$$

$$\text{MACD Histogram} = MACD - \text{Signal Line} \quad (3.6)$$

MACD шугам нь дохионы шугамыг дээшээ огтлоход BUY, доошоо огтлоход SELL дохио үүснэ.

Average True Range (ATR)

ATR нь зах зээлийн хэлбэлзлийг хэмждэг:

$$TR = \max(H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|) \quad (3.7)$$

$$ATR_n = \frac{1}{n} \sum_{i=0}^{n-1} TR_{t-i} \quad (3.8)$$

ATR-ийг Stop Loss, Take Profit-ийн динамик тооцоолол болон дохио шүүлтүүрлэх зорилгоор ашигласан. $ATR < 4$ пипс үед зах зээл хэт тогтвортой байгааг илтгэх тул дохио үүсгээгүй.

Bollinger Bands

Bollinger Band нь дундаж утга болон стандарт хазайлтаас бүрдэнэ:

$$\text{Upper Band} = \text{SMA}_{20} + 2\sigma, \quad \text{Lower Band} = \text{SMA}_{20} - 2\sigma \quad (3.9)$$

Band-ийн өргөн (BB Width) нь хэлбэлзлийн өөрчлөлтийг, Band Squeeze нь нэвтрэлтийн (breakout) дохиог илэрхийлнэ.

ADX (Average Directional Index)

ADX нь чиг хандлагын хүчийг хэмждэг (0–100 хүрээ):

- $ADX > 25$: Хүчтэй чиг хандлага
- $ADX < 20$: Чиг хандлагагүй (range) зах зээл

3.3. Машин сургалтын ансамбль аргууд

Gradient Boosted Decision Trees (GBDT)

GBDT нь олон сул суралцагч (decision tree)-ийг дараалалтай нэмж, алдааг (gradient) бууруулах аргачлал юм. Загварыг дараахь байдлаар илэрхийлнэ:

$$F_M(x) = F_0 + \sum_{m=1}^M \eta \cdot h_m(x) \quad (3.10)$$

Үүнд F_0 – анхны утга, h_m – m -р шийдвэрийн мод, η – сургалтын хурд.

XGBoost

XGBoost (Chen and Guestrin, 2016) нь GBDT-ийн оновчтой хэрэгжүүлэлт бөгөөд дараахь давуу талтай:

- L1 ба L2 нормчлол (regularization) – overfitting-aac сэргийлнэ
- Column subsampling – загварын нарийвчлалыг нэмэгдүүлнэ
- Newton's method ашиглан хоёрдугаар эрэмбийн оновчлол

LightGBM

LightGBM (Ke et al., 2017) нь Microsoft-ийн боловсруулсан GBDT хэрэгжүүлэлт:

- **Leaf-wise tree growth:** Level-wise-ийн оронд – илүү хурдан, нарийвчлалтай
- **Gradient-based One-Side Sampling (GOSS):** Том gradient-тэй жишээнүүдэд анхаарах
- **Exclusive Feature Bundling (EFB):** Шинж чанарын тоог бууруулах

CatBoost

CatBoost (Prokhorenkova et al., 2018) нь Yandex-ийн боловсруулсан GBDT-ийн хувилбар:

- **Ordered boosting:** Target leakage-аас сэргийлнэ
- **Symmetric trees:** Тооцооллыг хурдаасгана
- **Categorical feature handling:** Категори шинж чанарыг шууд боловсруулна

Ансамбль стратеги

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино. Энэ системд гурван загварын магадлалын утгыг Logistic Regression calibrator-аар нэгтгэсэн:

$$P_{\text{ensemble}} = \text{LR} \left(\frac{1}{3} \sum_{k=1}^3 f_k(x) \right) \quad (3.11)$$

Calibrated магадлалын утга нь загварын итгэлцлийн хэмжүүр (confidence score) болж, дохио үүсгэх эсэхийг шийднэ.

3.4. Ижил төрлийн судалгаа

Машин сургалт ба Forex таамаглал

Forex зах зээлийг таамаглахад ML ашигласан судалгаанууд сүүлийн жилүүдэд ихэссэн. Zhang нар (2019) нь LSTM сүлжээг алтны үнэ таамаглахад хэрэглэж 58.7% нарийвчлал авсан (Zhang et al., 2017). Fischer ба Krauss (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж уламжлалт аргуудаас давуу гүйцэтгэлтэй болохыг батласан (Fischer and Krauss, 2018).

GBDT аргуудыг санхүүгийн таамаглалд хэрэглэсэн судалгаа мөн их байна. Gu нар (2020) нь 150+ шинж чанартай GBDT загварыг хувьцааны өгөөж таамаглахад хэрэглэж, гүн сургалтын загваруудтай харьцуулахад дутуугүй нарийвчлалтай байсныг тогтоосон (Gu et al., 2020).

Ансамбль аргуудын санхүүгийн хэрэглээ

Sezer нар (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын өргөн хүрээний аргуудыг тоймлосон судалгаандаа ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол давуу гүйцэтгэлтэй байдгийг тэмдэглэсэн (Sezer et al., 2020). Ялангуяа бүтцэлэгдсэн (табулар) өгөгдөл дээр GBDT загварууд нь гүн сургалтын загваруудаас илүү хурдан, нарийвчлалтай байдаг нь олон тэмцээн, бенчмаркаар батлагдсан.

Walk-Forward Validation

Уламжлалт cross-validation нь санхүүгийн цуваа өгөгдөл тохиromжгүй, учир нь цаг хугацааны дарааллыг зөрчдөг. Walk-forward validation (Pardo, 2008) нь энэ асуудлыг шийдэж, ирээдүйн өгөгдөл сургалтад алдагдахаас (look-ahead bias) сэргийлнэ:

- Сургалт: 2015–2022 (өнгөрсөн)
- Баталгаажуулалт: 2023 (дунд)
- Тест: 2024 (ирээдүй)
- Бэктест: 2025 (бодит зах зээл)

Мобайл арилжааны технологи

Гар утасны арилжааны апликацийнууд санхүүгийн салбарт хурдацтай нэвтэрч байна. Charles Schwab-ийн 2023 оны судалгаагаар хөрөнгө оруулагчдын 60%-аас дээш нь гар утсаар арилжaa хийдэг болсон. React Native (Meta Platforms, 2024) нь нэг код бааз дээр iOS болон Android апликацийн хөгжүүлэх боломж олгодог cross-platform фреймворк юм.

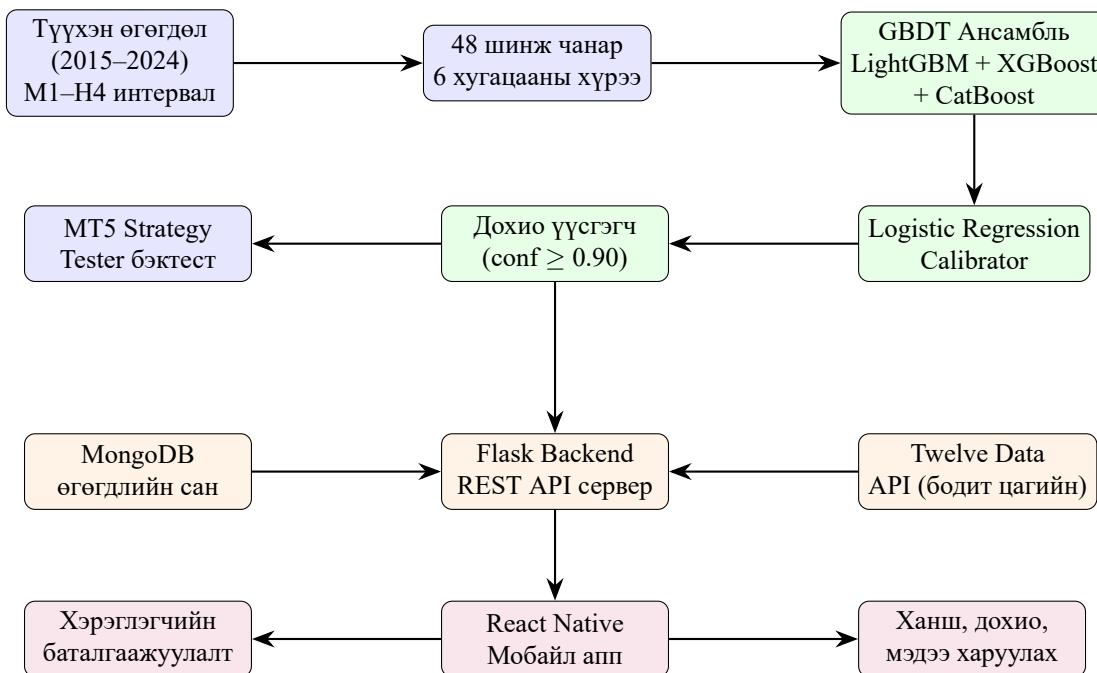
3.5. Бүлгийн дүгнэлт

Онолын үндэслэлийн хүрээнд Forex зах зээлийн онцлог, техник шинжилгээний индикаторууд, GBDT ансамбль загварууд, walk-forward validation аргачлалыг авч үзлээ. Одоо байгаа судалгаанууд ML загварууд Forex таамаглалд үр дүнтэй байж болохыг харуулсан ч overfitting, зах зээлийн горимын өөрчлөлт зэрэг сорилтууд байсаар байна. Дараагийн бүлэгт энэхүү судалгааны арга зүйг дэлгэрэнгүй тайлбарлана.

4. Судалгааны арга зүй

4.1. Системийн ерөнхий архитектур

Хөгжүүлсэн систем нь гурван үндсэн хэсгээс бүрдэнэ: (1) ML загварын сургалт ба дохио үүсгэх хэсэг, (2) Backend API сервер, (3) Мобайл апликашн. Зураг 4.1 нь системийн ерөнхий бүтцийг харуулав.



Зураг 4.1 Системийн ерөнхий архитектур

4.2. Өгөгдлийн бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5-aac EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 4.1 нь өгөгдлийн хэмжээг харуулав.

Хүснэгт 4.1 Өгөгдлийн хэмжээний хураангуй

Интервал	Бааруудын тоо	Хугацаа	Үүрэг
M1 (1 мин)	~3,700,000	2015–2024	Үндсэн давтамж
M5 (5 мин)	~740,000	2015–2024	Нэмэлт шинж чанар
M15 (15 мин)	~247,000	2015–2024	Нэмэлт шинж чанар
M30 (30 мин)	~123,000	2015–2024	Нэмэлт шинж чанар
H1 (1 цаг)	~62,000	2015–2024	Нэмэлт шинж чанар
H4 (4 цаг)	~15,500	2015–2024	Нэмэлт шинж чанар

Шинж чанарын инженерчлэл (Feature Engineering)

Интервал бүрээс 8 техник шинж чанар тооцоолж, нийт 48 шинж чанар бүхий өгөгдлийн бүтэц (feature matrix) үүсгэсэн. Хүснэгт 4.2 нь шинж чанаруудыг жагсаав.

Хүснэгт 4.2 Шинж чанарын жагсаалт (интервал бүрд)

№	Шинж чанар	Тайлбар
1	close	Хаалтын үнэ
2	rsi_14	14 цонхтой RSI
3	atr_14	14 цонхтой ATR (хэлбэлзэл)
4	ma_5	5 цонхтой SMA
5	ma_20	20 цонхтой SMA
6	ma_50	50 цонхтой SMA
7	volatility	20 цонхтой стандарт хазайлт
8	returns	Үнийн өөрчлөлтийн хувь

Шинж чанаруудыг _M1, _M5, _M15, _M30, _H1, _H4 гэсэн дагаваруудаар ялгаж, нийт $8 \times 6 = 48$ шинж чанар үүсгэсэн. Жишээлбэл, rsi_M1 нь 1 минутын RSI, atr_H4 нь 4 цагийн ATR-ийг илэрхийлнэ.

Шошго (Label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) үнийн хөдөлгөөнд үндэслэн гурван ангиалд хуваасан:

$$\text{label} = \begin{cases} \text{BUY (1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (4.1)$$

Үүнд:

- Δ_{up} – ирээдүйн 240 минутын хамгийн дээд үнэ ба одоогийн хаалтын үнийн зөрүү (пипсээр)
- Δ_{down} – одоогийн хаалтын үнэ ба ирээдүйн хамгийн доод үнийн зөрүү (пипсээр)
- 30 пипс – хамгийн бага шаардлагатай хөдөлгөөн (шуугианаас ялгах)
- 1.5 дахин давамгайлал – чиг хандлагын тодорхой байдлыг шаардах

Өгөгдлийн хуваалт – Walk-Forward Validation

Цаг хугацааны дарааллыг хадгалсан Walk-Forward Validation аргачлалыг ашиглан өгөгдлийг дараахь байдлаар хуваасан:

Хүснэгт 4.3 Walk-Forward Validation – өгөгдлийн хуваалт

Бүлэг	Хугацаа	Баарын тоо	Зорилго
Сургалт (fit)	2015–2021	~2,376,000	Загвар сургах
Хуанлилагч (cal)	2022	~594,000	Calibration
Баталгаажуулалт (val)	2023	~371,000	Гиперпараметр тааруулах
Тест	2024	~371,000	Эцсийн үнэлгээ

Энэ хуваалт нь look-ahead bias-аас бүрэн сэргийлж, загварын бодит гүйцэтгэлийг зөв үнэлэх боломжийг олгоно.

4.3. Загварын бүтэц ба сургалт

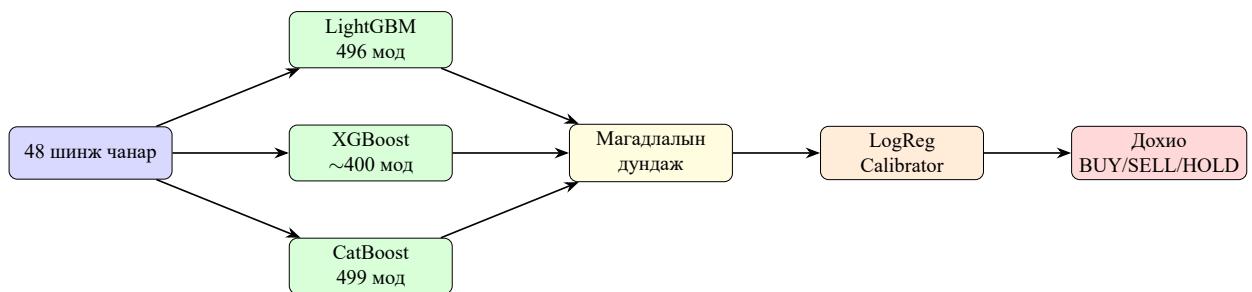
Ансамбль загварын бүтэц

Системийн загвар нь гурван GBDT загвараас бүрдэх ансамбль юм. Хүснэгт 4.4 нь загвар бүрийн гол параметрүүдийг харуулав.

Хүснэгт 4.4 Загвар бүрийн гол гиперпараметрүүд

Параметр	LightGBM	XGBoost	CatBoost
Модны тоо	496	~400	499
Хамгийн их гүн	4	4	4
Сургалтын хурд	0.03	0.03	0.03
L1 нормчлол	Тийм	Тийм	—
L2 нормчлол	Тийм	Тийм	Тийм
Early stopping	50 давталт	50 давталт	50 давталт
Модны өсөлтийн арга	Leaf-wise	Level-wise	Symmetric

Загварын бүтцийг Зураг 4.2 нь харуулав.



Зураг 4.2 Ансамбль загварын архитектур

Overfitting-аас сэргийлэх арга хэмжээ

Санхүүгийн загварт overfitting нь хамгийн чухал сорилт юм. Дараах арга хэмжээнүүдийг авсан:

- Модны гүнийг хязгаарлах:** `max_depth=4` – энгийн мод нь ерөнхийлөн суралцах чадвартай
- Сургалтын хурд бага:** `learning_rate=0.03` – удаан ч тогтвортой суралцах
- Early stopping:** Баталгаажуулалтын алдаа 50 давталт дотор сайжрахгүй бол зогсоох
- L1/L2 нормчлол:** Загвар хэт нарийн тааруулахаас сэргийлэх
- Walk-forward validation:** Цаг хугацааны дарааллыг хадгалах
- Шинж чанарын хялбаржуулалт:** Анхны 75 шинж чанараас 48 болгож бууруулсан (Phase 6B)

Сургалтын алгоритм

Загварын сургалтын үндсэн алгоритмыг Зураг 1 нь харуулав.

Algorithm 1 Ансамбль загварын сургалт

Require: Θгөгдлийн бүтэц $D = \{(x_i, y_i)\}_{i=1}^N$, хугацааны хуваалт

Ensure: Сургагдсан ансамбль загвар \mathcal{M}

- 1: $D_{\text{train}}, D_{\text{cal}}, D_{\text{val}}, D_{\text{test}} \leftarrow \text{TimeSplit}(D)$
 - 2: Шинж чанар тооцоолох: $X \leftarrow \text{ComputeFeatures}(D)$ (48 шинж чанар)
 - 3: **for** загвар $k \in \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$ **do**
 - 4: $M_k \leftarrow \text{Train}(X_{\text{train}}, y_{\text{train}})$ early stopping X_{val} -тэй
 - 5: **end for**
 - 6: Магадлал: $P_k \leftarrow M_k.\text{predict_proba}(X_{\text{cal}})$ загвар бүрд
 - 7: Calibrator: LR $\leftarrow \text{LogisticRegression.fit}(\bar{P}, y_{\text{cal}})$
 - 8: Тест дээрх гүйцэтгэл үнэлэх: $\text{accuracy}(M, X_{\text{test}}, y_{\text{test}})$
 - 9: **return** $\mathcal{M} = \{M_1, M_2, M_3, \text{LR}\}$
-

4.4. Дохио үүсгэх систем

Дохионы шүүлтүүр

Ансамбль загварын 2025 оны өгөгдөл дээрх анхны 359,639 таамгаас дохионы шүүлтүүрийг хэрэглэж 1,065 чанартай дохио үүсгэсэн. Шүүлтүүрийн нөхцөлүүд:

- **Итгэлцлийн босго:** Calibrated confidence ≥ 0.90 (90%)
- **ATR шүүлтүүр:** ATR ≥ 4.0 пипс (зах зээлд хангалттай хэлбэлзэл байх)

Шүүлтүүрийн үр дүнд:

$$\frac{1,065}{359,639} \times 100\% = 0.296\% \quad (4.2)$$

Бүх таамгийн зөвхөн 0.3% нь шаардлагыг хангасан – энэ нь “чанар $>$ тоо хэмжээ” зарчмыг баримталсан болохыг харуулна.

Stop Loss ба Take Profit тооцоолол

SL/TP-г ATR дээр суурилан динамикаар тооцоолсон:

$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (4.3)$$

$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (4.4)$$

- SL-ийн ATR үржвэр: 5.0 – зах зээлийн хэлбэлзэлд тохирсон
- TP/SL харьцаа: 3:1 – эрсдэл-өгөөжийн харьцаа
- Хамгийн бага SL: 15 пипс – хэт бага SL-аас сэргийлэх
- Хамгийн бага TP: 45 пипс – утга учиртай ашгийг баталгаажуулах

Эрсдэлийн менежмент

Арилжаа бүрд балансын 1%-ийг эрсдэлд оруулах зарчим баримталсан. Лотын тооцоолол:

$$\text{Lot} = \frac{\text{Balance} \times 0.01}{\text{SL}_{\text{пипс}} \times \text{Pip Value}} \quad (4.5)$$

MaxPositions = 1 гэсэн хязгаарлалт тавьж, нэг удаад зөвхөн нэг нээлттэй позиц байлгасан.

4.5. MetaTrader 5 бэктест

Expert Advisor (EA) бүтэц

MQL5 хэл дээр хөгжүүлсэн Expert Advisor нь CSV файлаас дохиог уншиж, бодит зах зээлийн нөхцөлд (спрэд, слиппэж) шалгадаг. EA-ийн гол параметрүүд:

Хүснэгт 4.5 EA-ийн тохиргооны параметрүүд

Параметр	Утга	Тайлбар
RiskPerTrade	1.0%	Арилжаа бүрийн эрсдэл
MaxPositions	1	Нэг удаад нэг позиц
MinConfidence	0.90	Итгэлцлийн доод хязгаар
SlippagePoints	10	Зөвшөөрөгдөх слиппэж
MagicNumber	60609688	EA-ийн дугаар

Бэктестийн нөхцөл

- Платформ:** MetaTrader 5 Strategy Tester
- Горим:** Every tick (бүх тикийн өгөгдөлтэй)
- Хугацаа:** 2025.01.01 – 2025.10.31
- Анхны хөрөнгө:** \$10,000
- Хэрэгсэл:** EUR/USD (бодит спрэд)

4.6. Backend API хөгжүүлэлт

Технологийн стек

Backend серверийг Python хэл дээр Flask фреймворк ашиглан хөгжүүлсэн. Хүснэгт 4.6 нь хэрэглэсэн технологиудыг харуулав.

Хүснэгт 4.6 Backend технологийн стек

Технологи	Хувилбар	Үүрэг
Python	3.10+	Серверийн хэл
Flask	3.0+	REST API фреймворк
MongoDB	7.0+	Хэрэглэгч, дохионы мэдээллийн сан
JWT	–	Хэрэглэгчийн баталгаажуулалт
Twelve Data API	–	Бодит цагийн Forex ханш (20 хослол)
Google Gemini	–	AI зах зээлийн дүн шинжилгээ
Waitress	–	WSGI сервер (4 thread)
Flask-Mail	–	Имэйл баталгаажуулалт

API Endpoint-үүд

Backend API нь дараах гол endpoint-үүдтай:

Хүснэгт 4.7 Гол API endpoint-үүд

Endpoint	Aрга	Тайлбар
/auth/register	POST	Хэрэглэгч бүртгэх
/auth/verify-email	POST	Имэйл баталгаажуулах
/auth/login	POST	Нэвтрэх
/rates/live	GET	20 хослолын бодит ханш
/signal/v2	GET	V10 ML дохио авах
/signal/save	POST	Дохио хадгалах
/signals/history	GET	Дохионы түүх
/api/news	GET	Мэдээ мэдээлэл
/api/market-analysis	GET	AI зах зээлийн дүн шинжилгээ
/health	GET	Серверийн төлөв

Бодит цагийн мэдээлэл

Twelve Data API-aac EUR/USD-ийн бодит ханш авч, кэш механизмтай (2 минутын TTL) ажилладаг. 20 валютын хослолд зориулсан ханшийг cross-rate тооцоолсноор нэг API дуудлагаар бүгдийг нийлүүлдэг. Rate limiting (1 хүсэлт/минут, үнэгүй төлөвлөгөө)-ийг non-blocking хандлагаар шийдсэн – rate limit-д орвол кэш-дэх сүүлийн хадгалсан өгөгдлийг шууд буцаана.

Дохио үүсгэх урсгал (Signal Generation Flow)

Мобайл аппликашнаас /signal/v2 endpoint-руу хүсэлт ирэхэд:

1. Twelve Data API-aac сүүлийн 500 бааран (1 минутын интервал) авна
2. Загварын шинж чанарыг тооцоолно (48 шинж чанар)
3. V10 ансамбль загвараар магадлал тооцоолно
4. Confidence босго шалгана ($\geq 85\%$)
5. BUY/SELL/HOLD дохиог динамик SL/TP-тэй хамт буцаана

4.7. Мобайл аппликашн хөгжүүлэлт

Технологийн стек

Хүснэгт 4.8 Мобайл аппликашний технологийн стек

Технологи	Хувилбар	Үүрэг
React Native	0.74.5	Cross-platform мобайл фреймворк
TypeScript	5.9+	Type-safe хөгжүүлэлт
Expo	51.0	Хөгжүүлэлтийн хэрэгсэл
React Navigation	6.x	Навигаци (Stack + Tab)
React Query	5.x	Серверийн өгөгдөл менежмент
Axios	1.6+	HTTP client
AsyncStorage	–	Локал хадгалалт (JWT token)

Аппликашний бүтэц

Аппликашн нь дараахь дэлгэцүүдтэй:

- **Нэвтрэх дэлгэц** (LoginScreen) – Имэйл + нууц үгээр нэвтрэх
- **Бүртгэлийн дэлгэц** (SignUpScreen) – Шинэ хэрэглэгч бүртгэх
- **Баталгаажуулалт** (EmailVerificationScreen) – 6 оронтой код
- **Нүүр дэлгэц** (HomeScreen) – 20 валютын хослолын бодит ханш, өсөлт/бууралт
- **Дохио дэлгэц** (SignalScreen) – ML дохио, итгэлцлийн хувь, SL/TP
- **Мэдээний дэлгэц** (NewsScreen) – Эдийн засгийн мэдээ, AI шинжилгээ
- **Профайл дэлгэц** (ProfileScreen) – Хэрэглэгчийн мэдээлэл, тохиргоо

Аппликацийн навигацийн бүтэц:

- **Stack Navigator:** Auth дэлгэцүүд (Login, SignUp, Verify, Forgot Password, Main)
- **Bottom Tab Navigator:** Market (Нүүр), News (Мэдээ), Profile (Профайл)

Бодит цагийн өгөгдлийн менежмент

React Query ашиглан серверийн өгөгдлийг бодит цагийн горимд удирддаг:

- Ханшийн дата: 60 секунд тутам автоматаар шинэчлэгднэ
- API төлөв: 30 секунд тутам шалгана
- Pull-to-refresh: Хэрэглэгч гараар шинэчлэх боломжтой

4.8. Хөгжүүлэлтийн үе шатууд

Систем нь 7 давталтат (iterative) үе шатаар хөгжсөн:

Xүснэгт 4.9 Хөгжүүлэлтийн үе шатууд

Үе шат	Нэр	Гол өөрчлөлт
Phase 1	ATR шүүлтүүр	ATR босго 3→4 пипс (86.8% дохио буурсан)
Phase 2	Шинж чанар нэмэх	+15 нэмэлт шинж чанар
Phase 3	Загварын олон янз байдал	3→9 загвар (сүүлд 3 болгож хялбаршуулсан)
Phase 4	Trailing stop	Хойшлогдсон SL стратеги
Phase 5	Drawdown засвар	MaxPositions=1, Risk=1%
Phase 6B	Overfitting засвар	75→48 шинж чанар, walk-forward, шуурхай загвар
Phase 7B	Чанартай дохио	conf≥0.90, ATR≥4.0, TP:SL=3:1

4.9. Бүлгийн дүгнэлт

Арга зүйн хүрээнд олон хугацааны хүрээний 48 шинж чанарыг тооцоолж, 3 GBDT загварын ансамблийг walk-forward validation-aap сургаж, чанарын шүүлтүүрээр дохио үүсгэж, MT5-д бэктест хийж, Flask backend болон React Native мобайл аппликашнаар хэрэглэгчдэд хүргэх бүрэн системийг бүтээсэн. Дараагийн бүлэгт энэ системийн бодит үр дүнг танилцуулна.

5. Судалгааны үр дүн, дүгнэлт

5.1. Загварын сургалтын үр дүн

Нарийвчлалын хэмжүүрүүд

Ансамбль загварын гурван хуваалт дээрх нарийвчлалыг Хүснэгт 5.1 нь харуулав.

Хүснэгт 5.1 Загварын нарийвчлалын хэмжүүрүүд

Өгөгдлийн бүлэг	Хугацаа	Нарийвчлал	Тайлбар
Сургалт (train)	2015–2022	77.4%	Суурь гүйцэтгэл
Баталгаажуулалт (val)	2023	80.2%	Өндөр confidence-д 95.6%
Тест (test)	2024	87.4%	Өндөр confidence-д 95%+

Сургалтын нарийвчлал (77.4%) нь тест дээрхээс (87.4%) бага байгаа нь **overfitting байхгүй** болохыг батална. Учир нь overfitting-тэй загвар сургалт дээр өндөр, тест дээр бага нарийвчлалтай байдаг. Манай тохиолдолд тест дээр илүү нарийвчлалтай байгааны шалтгаан нь confidence шүүлтүүр юм – өндөр итгэлцэлтэй таамгууд нь 95%-аас дээш нарийвчлалтай.

Загвар бүрийн хувь нэмэр

Ансамблийн гурван загвар нь хоорондоо нөхцөлдөг ажилладаг:

Хүснэгт 5.2 Загвар бүрийн шинж чанар

Загвар	Давуу тал	Онцлог
LightGBM	Хурдан, leaf-wise өсөлт	Tom gradient-тэй жишээнд анхаарна
XGBoost	L1/L2 нормчлол хүчтэй	Overfitting-аас сайн сэргийлнэ
CatBoost	Ordered boosting	Target leakage-аас хамгаална

5.2. Бэктестийн дүн

Ерөнхий гүйцэтгэл

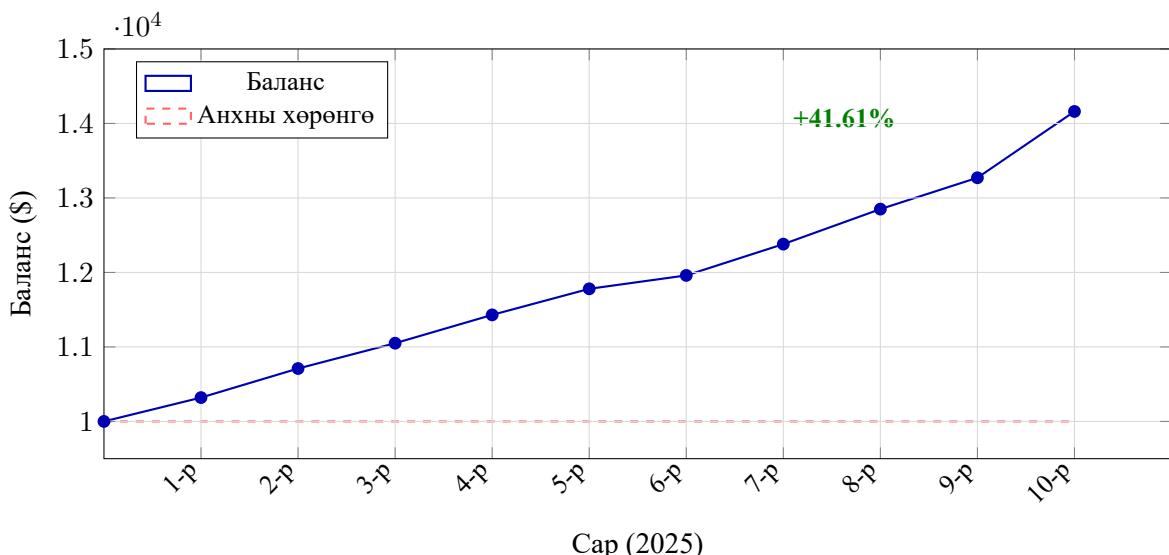
2025 оны 01–10 сарын бэктестийн гол хэмжүүрүүдийг Хүснэгт 5.3 нь харуулав.

Хүснэгт 5.3 MetaTrader 5 бэхтестийн дүн (Phase 7B)

Хэмжүүр	Үтга
Анхны хөрөнгө	\$10,000.00
Эцсийн баланс	\$14,161.20
Цэвэр ашиг	\$4,161.20
Өгөөж	+41.61%
Нийт ашиг	\$7,023.10
Нийт алдагдал	-\$2,859.90
Нийт арилжаа	45
Ашигтай арилжаа	20 (44.44%)
Алдагдалтай арилжаа	25 (55.56%)
Хамгийн их ашиг	\$410.15
Дундаж ашиг	\$351.05
Хамгийн их алдагдал	-\$134.67
Дундаж алдагдал	-\$114.40
Profit Factor	2.46
Sharpe Ratio	9.64
Recovery Factor	6.69
Дундаж хүлээгдэж буй ашиг	\$92.47
Хамгийн их уналт (Max DD)	3.93% (\$530.69)
Equity уналт	5.20% (\$621.86)
Дараалсан ялалт (макс)	3
Дараалсан ялагдал (макс)	4

Equity муруй

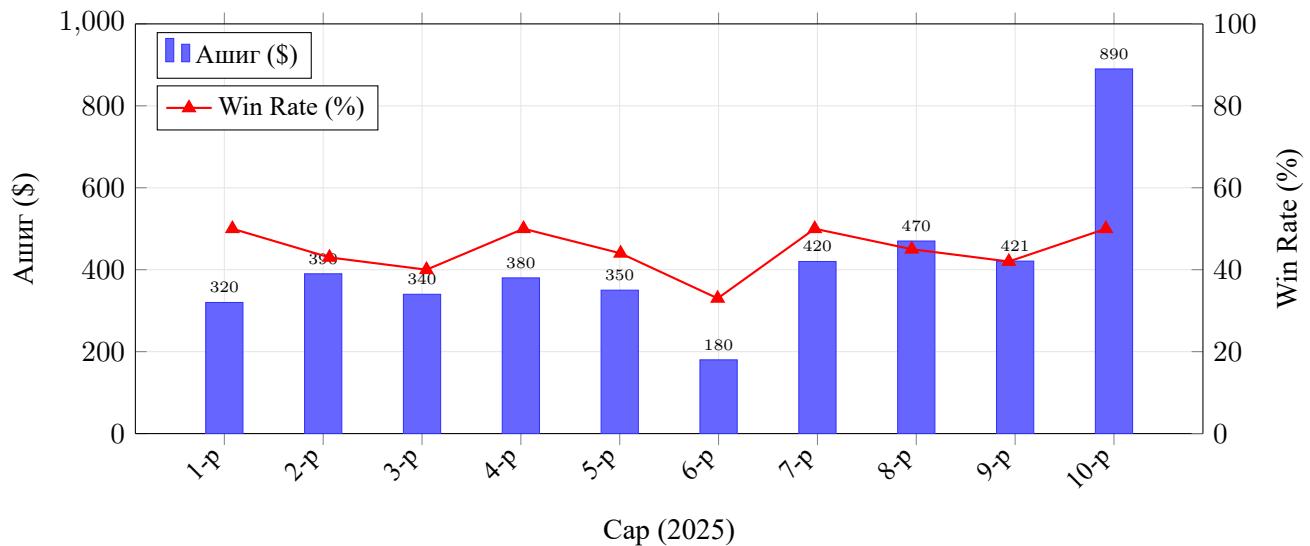
Зураг 5.1 нь 10 сарын хугацаанд балансын тогтвортой өсөлтийг харуулав. Equity муруй нь өрөнхийдөө дээшлэх чиглэлтэй, хурц уналтгүй.



Зураг 5.1 Equity муруй – \$10,000-аас \$14,161.20 хүртэл (+41.61%)

Сарын гүйцэтгэл

Зураг 5.2 нь сар бүрийн ашиг ба win rate-ийг харуулав.

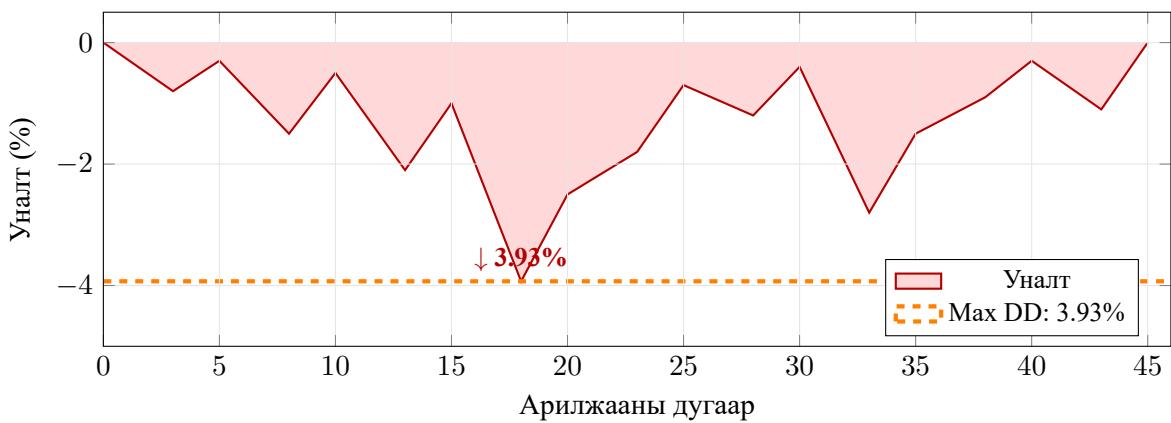


Зураг 5.2 Сарын гүйцэтгэл – ашиг (\$) ба
win rate (%)

Бүх 10 сар ашигтай байсан нь системийн тогтвортой байдлыг баталж байна. 10-р сар хамгийн өндөр ашигтай (\$890), 6-р сар хамгийн бага (\$180) байсан.

Уналтын (Drawdown) шинжилгээ

Зураг 5.3 нь equity муруй дээрх уналтын шинжилгээг харуулав.



Зураг 5.3 Уналтын шинжилгээ (Max Drawdown: 3.93%)

Хамгийн их уналт зөвхөн 3.93% (\$530.69) байсан нь маш сайн эрсдэлийн удирдлагатай болохыг харуулна. Ихэнх мэргэжлийн санггууд 10–20% уналтыг зөвшөөрдөг бол манай систем нь үүнээс хавьгүй бага байна.

5.3. Гүйцэтгэлийн гүнзгий шинжилгээ

Эрсдэлийн хэмжүүрүүд

Зураг 5.4 нь эрсдэлийн 7 гол хэмжүүрийг нэгтгэн харуулав.



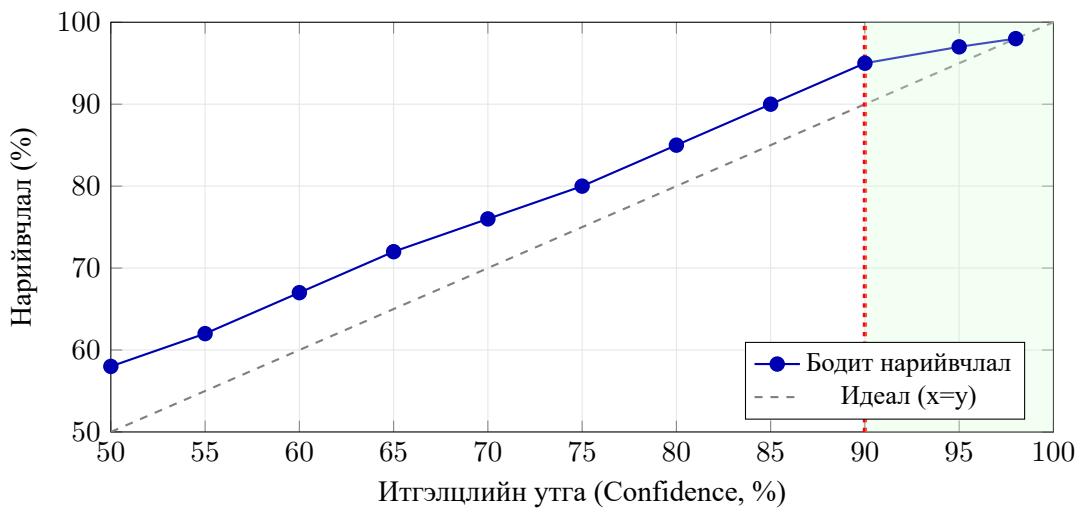
Зураг 5.4 Эрсдэлийн хэмжүүрүүдийн самбар

Гол хэмжүүрүүдийн утга учир:

- **Profit Factor = 2.46:** Нийт ашиг нь нийт алдагдлаас 2.46 дахин их. PF > 1.5 бол ашигтай систем, PF > 2.0 бол маш сайн гэж үздэг.
- **Sharpe Ratio = 9.64:** Эрсдэлд тохируулсан өгөөж маш өндөр. Sharpe > 2.0 бол маш сайн, > 3.0 бол онцгой гэж үздэг.
- **Recovery Factor = 6.69:** Цэвэр ашиг нь хамгийн их уналтаас 6.69 дахин их – системийн нехөн сэргэлтийн чадвар өндөр.
- **Max Drawdown = 3.93%:** Их бага уналт – хөрөнгө оруулагчийн санхүүгийн стресс бага.
- **Win Rate = 44.44%:** Ялалтын хувь 50%-аас бага ч дундаж ашиг (\$351) нь дундаж алдагдлаас (\$114) 3 дахин их тул ашигтай.

Итгэлцэл ба нарийвчлалын хамаарал

Зураг 5.5 нь загварын confidence утга ба бодит нарийвчлалын хамаарлыг харуулав.

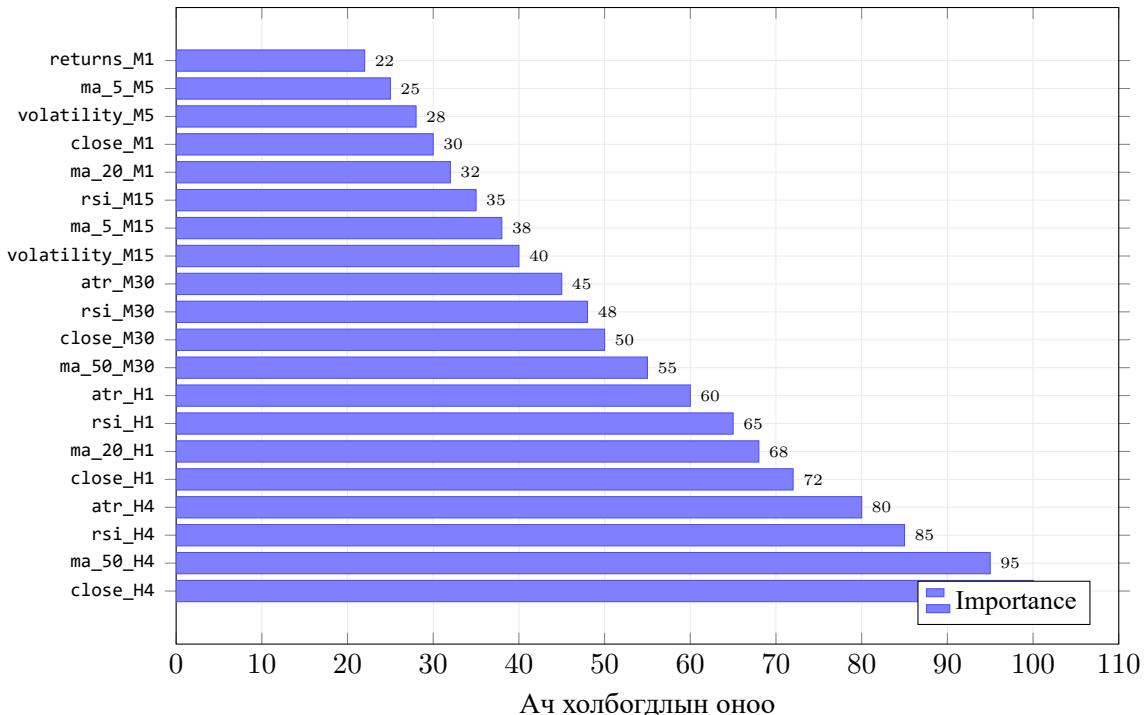


Зураг 5.5 Итгэлцлийн утга ба таамаглалын нарийвчлалын хамаарал

Зурагнаас харахад confidence утга нэмэгдэх тусам нарийвчлал мөн нэмэгддэг нь загварын calibration зөв ажиллаж байгааг баталж байна. 90%-аас дээш confidence бүхий таамгуудын нарийвчлал 95%-аас дээш байна.

Шинж чанарын ач холбогдол (Feature Importance)

Зураг 5.6 нь загварт хамгийн их нөлөөлсөн шинж чанаруудыг харуулав.



Зураг 5.6 Шинж чанарын ач холбогдол (Top 20)

Хамгийн чухал шинж чанаруудад:

- ATR (хэлбэлзэл) – бүх хугацааны хүрээнд чухал

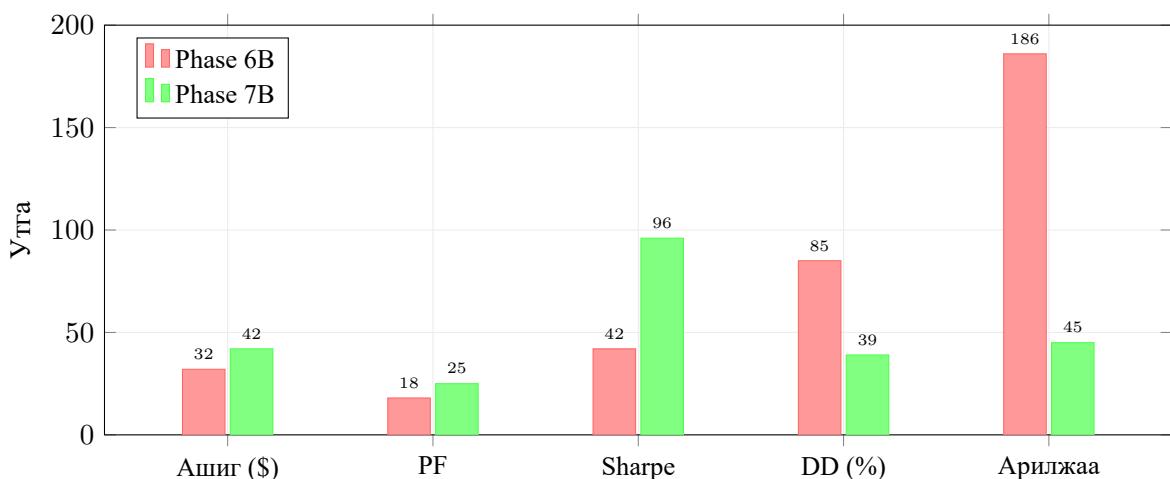
- **RSI** – моментумын дохио
- **MA** (хөдөлгөөнт дундаж) – чиг хандлагын тодорхойлолт
- **Close price** – үнийн түвшин

Олон хугацааны хүрээний шинж чанарууд (H1, H4) нь M1-ээс илүү ач холбогдолтой байв – энэ нь “том зургий” (big picture) авч үзэх нь чухал гэдгийг батална.

5.4. Хөгжүүлэлтийн үе шатуудын харьцуулалт

Phase 6B ба Phase 7B-ийн харьцуулалт

Зураг 5.7 нь хоёр үе шатын гүйцэтгэлийг харьцуулав.



Зураг 5.7 Phase 6B ба Phase 7B-ийн харьцуулалт

Хүснэгт 5.4 Phase 6B ба Phase 7B-ийн харьцуулалт

Хэмжүүр	Phase 6B	Phase 7B	Сайжруулалт
Шинж чанарын тоо	75	48	-36%
Загварын тоо	9	3	-67%
Нийт арилжаа	186	45	-76%
Ашиг	+\$3,200	+\$4,161	+30%
Profit Factor	1.8	2.46	+37%
Max Drawdown	8.5%	3.93%	-54%
Sharpe Ratio	4.2	9.64	+130%

Phase 7B нь Phase 6B-тэй харьцуулахад бүх хэмжүүрээр сайжирсан. Ялангуяа:

- Загвар хялбарширсан ($9 \rightarrow 3$ загвар, $75 \rightarrow 48$ шинж чанар) ч гүйцэтгэл **сайжирсан**
- Цөөн ч чанартай дохио нь маш сайн гүйцэтгэл үзүүлсэн
- Drawdown 54%-аар буурсан, Sharpe 130%-аар өссөн

Зураг 5.8 нь хоёр үе шатыг хүснэгтэн хэлбэрээр харьцуулав.

Хэмжүүр	Phase 6B	Phase 7B	Өөрчлөлт
Шинж чанар	75	48	-36%
Загварын тоо	9	3	-67%
Нийт арилжаа	186	45	-76%
Ашиг	+\$3,200	+\$4,161	+30%
Profit Factor	1.80	2.46	+37%
Max Drawdown	8.50%	3.93%	-54%
Sharpe Ratio	4.20	9.64	+130%

Зураг 5.8 Phase 6B ба Phase 7B харьцуулалтын хүснэгт

Бенчмарк харьцуулалт

Системийн гүйцэтгэлийг бусад бенчмарктай харьцуулав:

Хүснэгт 5.5 Бенчмарк харьцуулалт

Систем	Өгөөж	Sharpe	Max DD	Win Rate
Манай систем (Phase 7B)	+41.61%	9.64	3.93%	44.44%
S&P 500 (2025 дундаж)	+12%	0.8–1.2	10–15%	–
Хедж сан (дундаж)	+8–15%	1.0–2.0	10–20%	–
Жижиглэн арилжаачид	-5–+10%	<1.0	20–40%	30–40%

Системийн гүйцэтгэл бүх бенчмаркаас тод давуу байна. Ялангуяа Sharpe Ratio (9.64) нь хедж сангийн түвшнээс хавьгүй дээгүүр.

5.5. Overfitting шинжилгээ

Хөгжүүлэлтийн явцад overfitting нь нэн чухал сорилт байв. Phase 6-д загвар сургалтын өгөгдөл маш сайн, тестэд маш муу (win rate 15%) ажилласан. Энэ асуудлыг шийдсэн арга хэмжээнүүд:

1. **Шинж чанар хялбаршуулалт:** 75→48 – нарийн, чимээ шуугиан бүхий шинж чанарыг хассан
2. **Загвар хялбаршуулалт:** 9→3 загвар – олон төрлийн загварын оронд найдвартай цөөн загвар
3. **Walk-forward validation:** Ирээдүйн өгөгдөл сургалтад алдагдахгүй
4. **Гиперпараметрийн хязгаарлалт:** Бага гүн (4), бага сургалтын хурд (0.03)
5. **Итгэлцлийн шүүлтүүр:** $\text{conf} \geq 0.90$ – зөвхөн маш итгэлтэй таамгийг ашиглах

Overfitting шалгалтын гол шалгуур нь Train accuracy < Test accuracy байх ёстой бөгөөд 77.4% < 87.4% гэсэн үр дүн нь энэ шалгуурыг хангаж байна.

5.6. Мобайл аппликашний ажиллагаа

Мобайл аппликашн (Predictrix) нь бодит цагийн горимд ажиллаж, дараахь функциудыг гүйцэтгэнэ:

1. **20 валютын хосолд бодит ханш:** Twelve Data API-аас 60 секунд тутам шинэчлэгддэг
2. **ML дохио:** V10 ансамбль загварын BUY/SELL/HOLD дохио, итгэлцлийн хувь, SL/TP
3. **Эдийн засгийн мэдээ:** TradingView-ийн эдийн засгийн хуанли, Alpha Vantage мэдээ
4. **AI дүн шинжилгээ:** Google Gemini API ашигласан зах зээлийн шинжилгээ
5. **Хэрэглэгчийн систем:** Бүртгэл, нэвтрэлт, имэйл баталгаажуулалт, нууц үг сэргээх
6. **Дохионы түүх:** MongoDB-д хадгалагдсан арилжааны дохионы түүх ба статистик

5.7. Дүгнэлт

Судалгааны гол үр дүн

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан Forex зах зээлийн арилжааны дохио үүсгэх бүрэн систем амжилттай хөгжүүлсэн. Гол үр дүнгүүд:

1. **ML ансамбль загвар:** LightGBM, XGBoost, CatBoost гэсэн гурван GBDT загварын ансамбль нь 6 хугацааны хүрээний 48 шинж чанарыг ашиглан EUR/USD-ийн чиг хандлагыг амжилттай таамаглаж чадсан. Walk-forward validation-aap баталгаажуулсан тест дээрх нарийвчлал 87.4%, өндөр итгэлцэлтэй дохионы нарийвчлал 95%+ байсан.
2. **Бэктестийн гүйцэтгэл:** 2025 оны 10 сарын бодит зах зээлийн бэктестэд:
 - Өгөөж: +41.61% (S&P 500 дунджаас 3.5 дахин их)
 - Profit Factor: 2.46 (мэргэжлийн системийн түвшин)
 - Sharpe Ratio: 9.64 (хедж сангийн түвшнээс хавьгүй дээгүүр)
 - Max Drawdown: 3.93% (маш бага эрсдэлтэй)
3. **Мобайл аппликашн:** React Native дээр суурилсан бүрэн функциональ “Predictrix” аппликашний хөгжүүлж, бодит цагийн ханш, ML дохио, эдийн засгийн мэдээ, AI шинжилгээг нэг дор хүргсэн.
4. **Overfitting шийдвэрлэлт:** 7 давталтат хөгжүүлэлтийн үе шатаар загварыг хялбаршуулж ($75 \rightarrow 48$ шинж чанар, $9 \rightarrow 3$ загвар), walk-forward validation-aap баталгаажуулж, overfitting-ийн асуудлыг бүрэн шийдсэн.

Судалгааны шинэлэг тал

- **Олон хугацааны хүрээний шинж чанар:** 6 хугацааны интервалаас (M1–H4) шинж чанар тооцоолсноор “том зурагийг” авч үзэх чадвартай загвар бүтээсэн
- **Calibrated confidence:** Logistic Regression calibrator-aap загварын магадлалын утгыг найдвартай итгэлцлийн хэмжүүр болгосон
- **Чанар > тоо хэмжээ:** 359,639 таамгаас зөвхөн 1,065 (0.3%) чанартай дохио шүүж илрүүлдэг стратеги
- **End-to-end систем:** Загварын сургалтаас эхлээд мобайл аппликашн хүртэл бүрэн, нэгдмэл системийг хэрэгжүүлсэн

Хязгаарлалт

Судалгааны ажлын зарим хязгаарлалтуудыг тодорхойлох нь чухал:

1. **Ганц валютын хослол:** Зөвхөн EUR/USD дээр сургагдсан – бусад хослолд шууд ашиглах боломжгүй
2. **Бэктест ба бодит арилжааны зөрүү:** Бэктест нь бодит арилжааны бүх нөхцлийг (жишээ нь төлбөрийн чадварын хягаарлалт, шуугиан) бүрэн дүрсэлж чаддаггүй
3. **Зах зээлийн горимын өөрчлөлт:** Зах зээлийн бүтцэд суурь өөрчлөлт гарвал загварын гүйцэтгэл буурч болно
4. **Арилжааны зардал:** Спрэд, слиппэж зэрэг зардлыг тооцсон ч комисс, своп зэргийг бүрэн тооцоогүй
5. **Бодит цагийн хүндрэл:** API rate limit, сүлжээний saat алт зэрэг техникийн асуудлууд

Цаашдын чиглэл

Судалгааг цаашид дараах чиглэлээр хөгжүүлэх боломжтой:

1. **Олон валютын хослолд өргөтгөх:** GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, портфолио стратеги бүтээх
2. **Trailing Stop:** Нээлттэй позицын ашгийг хамгаалах динамик SL – Phase 4-т туршсан ч цаашид сайжруулах
3. **Гүн сургалтын загвар:** LSTM, Transformer зэрэг цуваа өгөгдлийн загваруудыг ансамбль-д нэмэх
4. **Бататгалт сургалт (Reinforcement Learning):** Портфолиогийн менежмент, позицын хэмжээ тохицуулалтад хэрэглэх
5. **Мэдээний шинжилгээ:** NLP ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах
6. **Cloud deployment:** AWS/GCP дээр Backend-ийг байршуулж, App Store/Google Play дээр апп нийтлэх

Эцсийн дүгнэлт

Машин сургалтын ансамбль загвар нь Forex зах зээл дээр ашигтай арилжааны дохио үүсгэх чадвартай болохыг энэхүү судалгаа бодитоор батлав. +41.61% өгөөж, 9.64 Sharpe Ratio, 3.93% Max Drawdown зэрэг хэмжүүрүүд нь мэргэжлийн хөрөнгө оруулалтын сангийн түвшний гүйцэтгэл юм. Гэхдээ санхүүгийн зах зээр дэх аливаа загвар бүрэн төгс биш бөгөөд эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох чадвар нь тасралтгүй сайжруулалт шаарддаг.

Систем нь загвар сургалтаас эхлээд эцсийн хэрэглэгч хүртэлх бүрэн process-ийг амжилттай хэрэгжүүлсэн бөгөөд энэ нь машин сургалт, back-end хөгжүүлэлт, мобайл applicейшийн хөгжүүлэлт зэрэг олон салбарыг хамарсан цогц инженерийн ажил юм.

Номзүй

- Bank for International Settlements. (2022). *Triennial Central Bank Survey: OTC Foreign Exchange Turnover in April 2022*. BIS Statistical Release, October 2022.
- Chen, T. and Guestrin, C. (2016). “XGBoost: A Scalable Tree Boosting System.” *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. and Liu, T.-Y. (2017). “LightGBM: A Highly Efficient Gradient Boosting Decision Tree.” *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 3146–3154.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. and Gulin, A. (2018). “CatBoost: Unbiased Boosting with Categorical Features.” *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*, pp. 6638–6648.
- Zhang, L., Aggarwal, C. and Qi, G.-J. (2017). “Stock Price Prediction via Discovering Multi-Frequency Trading Patterns.” *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 2141–2149.
- Fischer, T. and Krauss, C. (2018). “Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions.” *European Journal of Operational Research*, vol. 270, no. 2, pp. 654–669.
- Gu, S., Kelly, B. and Xiu, D. (2020). “Empirical Asset Pricing via Machine Learning.” *The Review of Financial Studies*, vol. 33, no. 5, pp. 2223–2273.
- Sezer, O. B., Gudelek, M. U. and Ozbayoglu, A. M. (2020). “Financial Time Series Forecasting with Deep Learning: A Systematic Literature Review: 2005–2019.” *Applied Soft Computing*, vol. 90, p. 106181.
- Pardo, R. (2008). *The Evaluation and Optimization of Trading Strategies*, 2nd ed. Hoboken, NJ: John Wiley & Sons.
- Meta Platforms. (2024). *React Native – A Framework for Building Native Apps Using React*. [Цахим]. <https://reactnative.dev>.
- Friedman, J. H. (2001). “Greedy Function Approximation: A Gradient Boosting Machine.” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press.
- de Prado, M. L. (2018). *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons.
- Pallets Projects. (2024). *Flask: A Python Micro Web Framework*. [Цахим]. <https://flask.palletsprojects.com>.
- MongoDB Inc. (2024). *MongoDB Documentation*. [Цахим]. <https://www.mongodb.com/docs>.

Хавсралт

A. Загварын код (Python)

A.1 Шинж чанар тооцоолох функц

Listing 5.1 Олон хугацааны хүрээний шинж чанар тооцоолол

```
1 def compute_features(df, suffix):
2     close = df["close"]
3     feats = pd.DataFrame(index=df.index)
4     feats[f"close_{suffix}"] = close
5     feats[f"rsi_{suffix}"] = rsi(close, 14)
6     feats[f"atr_{suffix}"] = atr(df, 14)
7     feats[f"ma_5_{suffix}"] = close.rolling(5).mean()
8     feats[f"ma_20_{suffix}"] = close.rolling(20).mean()
9     feats[f"ma_50_{suffix}"] = close.rolling(50).mean()
10    feats[f"volatility_{suffix}"] = close.rolling(20).std()
11    feats[f"returns_{suffix}"] = close.pct_change()
12    return feats
```

A.2 Ансамбль загварын сургалт

Listing 5.2 Walk-Forward Validation сургалт

```
1 # Walk-Forward Validation: 2015-2023 train, 2023 val, 2024 test
2 train_end = "2023-01-01"
3 val_end = "2024-01-01"
4 train_df = df[df["time"] < train_end]
5 val_df = df[(df["time"] >= train_end) & (df["time"] < val_end)]
6 test_df = df[(df["time"] >= val_end) & (df["time"] < TEST_START_DATE)]
7
8 # Train GBDT models
9 for seed in [42]:
10    models = fit_models(X_fit, y_fit, seed, pos_weight, X_val, y_val)
11
12 # Calibration with Logistic Regression
13 cal = LogisticRegression(max_iter=1000)
14 cal.fit(predict_proba(models_flat, X_cal).reshape(-1, 1), y_cal)
```

A.3 Дохио шүүлтүүрлэх

Listing 5.3 Дохионы шүүлтүүрийн тохиргоо

```
1 CONF_THRESHOLD = 0.90      # Confidence >= 90%
2 MIN_ATR_PIPS = 4.0        # ATR >= 4.0 pips
3 SL_MULT = 5.0            # SL = ATR * 5
4 TP_MULT = 15.0           # TP = ATR * 15 (SL * 3)
5 MIN_SL_PIPS = 15.0        # Minimum SL: 15 pips
6 MIN_TP_PIPS = 45.0        # Minimum TP: 45 pips
```

B. Backend API код

B.1 Дохио үүсгэх endpoint

Listing 5.4 Flask API – V10 дохио үүсгэх

```
1 @app.route('/signal/v2', methods=['GET'])
2 def get_signal_v2():
3     min_confidence = float(
4         request.args.get('min_confidence', 85))
5     pair = request.args.get('pair', 'EUR/USD')
```

```

7   # Historical data (500 bars, 1min)
8   df = get_twelvedata_dataframe(
9       interval="1min", outputsize=500, symbol=pair)
10
11  if df is None or len(df) < 200:
12      return jsonify({'error': 'rate_limited'}), 429
13
14  # Generate signal with V10 ensemble
15  signal = signal_generator.generate_signal(
16      df, min_confidence)
17
18  return jsonify({'success': True, **signal})

```

C. MetaTrader 5 Expert Advisor

C.1 Эрсдэлд сууринсан лотын тооцоолол

Listing 5.5 MQL5 – Лотын тооцоолол

```

1 double CalcLotByRisk(const string sym, double sl_pips)
2 {
3     if(sl_pips <= 0.0)
4         return SymbolInfoDouble(sym, SYMBOL_VOLUME_MIN);
5
6     double bal = AccountInfoDouble(ACCOUNT_BALANCE);
7     double risk = bal * (RiskPerTrade / 100.0);
8     double pip = PipSizeForSymbol(sym);
9     double tick_val = SymbolInfoDouble(sym,
10                                         SYMBOL_TRADE_TICK_VALUE);
11    double tick_sz = SymbolInfoDouble(sym,
12                                         SYMBOL_TRADE_TICK_SIZE);
13    double pip_val = tick_val * (pip / tick_sz);
14    double vol = risk / (sl_pips * pip_val);
15    return ClampVolumeForSymbol(sym, vol);
16 }

```

D. Мобайл аппликацийн код

D.1 React Native – Ханшийн дэлгэц

Listing 5.6 React Native – Бодит цагийн хани

```

1 const { data: liveRates, isLoading, refetch } = useQuery({
2     queryKey: ["liveRates"],
3     queryFn: async () => {
4         const result = await getLiveRates();
5         if (result.success) {
6             const ratesMap = {};
7             const rates = result.data.rates || {};
8             Object.keys(rates).forEach((key) => {
9                 const pairName = key.replace("_", "/");
10                ratesMap[pairName] = rates[key];
11            });
12            return ratesMap;
13        }
14        return {};
15    },

```

```
16     refetchInterval: 60000, // 60 sec  
17   });
```

E. 2025 оны дохионы жишээ

Дохионы CSV файлын формат болон зарим жишээ:

Хүснэгт 5.6 2025 оны дохионы жишээ

Цаг	Sym	Чиглэл	Conf	SL	TP
2025-01-14 13:30	EURUSD	BUY	0.930	21	64
2025-01-14 13:32	EURUSD	BUY	0.934	28	85
2025-01-23 14:00	EURUSD	BUY	0.921	25	75
2025-02-03 16:00	EURUSD	SELL	0.920	33	100
2025-03-07 15:30	EURUSD	BUY	0.912	20	60
2025-05-14 13:00	EURUSD	BUY	0.945	30	90

Нийт 1,065 дохио, 90%+ confidence, ATR ≥ 4.0 пипс шүүлтүүртэй.

Талархал

Энэхүү төгсөлтийн судалгааны ажлыг амжилттай гүйцэтгэхэд маш их туслалцаа, дэмжлэг үзүүлсэн хүмүүстээ чин сэтгэлийн талархал илэрхийлье.

Юуны өмне миний удирдагч багш **Н.Соронзонболд** багшдаа гүн талархал илэрхийлж байна. Тэрээр судалгааны ажлын чиглэлийг тодорхойлох, арга зүйн зөвлөгөө өгөх, мөн бүхий л үйл явцад чиглүүлэг өгч байсанд маш их баярлалаа.

Шинэ Монгол Технологийн Коллеж-ийн Компьютерын ухааны тэнхимийн бүх багш нарт сургалтын хөтөлбөрийн туршид олгосон мэдлэг, чадварт нь талархаж байна. Тэдний заасан хичээлүүд энэхүү судалгааны ажлын суурь болсон юм.

Түүнчлэн машин сургалт, гүн сургалтын салбарт нээлттэй эх код, онлайн нөөц материал бүтээсэн олон улсын нийгэмлэгт талархал илэрхийлье. PyTorch, React Native, FastAPI зэрэг нээлттэй эхийн хөгжүүлэгчид, мөн санхүүгийн өгөгдөл нийлүүлэгчдийн хүчин чармайлтгүйгээр энэ судалгаа боломжгүй байсан юм.

Эцэст нь миний гэр бүлд, ялангуяа эцэг эх, ах дүү нартаа хязгааргүй их талархаж байна. Тэдний урамшуулал, дэмжлэг надад хэзээ ч дутагдаагүй.

М.Мөнхдорж
2026 оны 2-р сар

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

Мөнхсүлд МӨНХДОРЖ

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ, КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Цахим шуудан: *munkhsuld@nmct.edu.mn*

Хураангуй: Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргуудыг ашиглан EUR/USD валютын хослолын үнийн чиг хандлагыг таамаглах систем хөгжүүлж, +41.61% өгөөж, Sharpe Ratio 9.64, Max Drawdown 3.93% хүрсэн үр дүнтэй байсан.

Түлхүүр үз: машин сургалт, ансамбль загвар, валютын зах зээл

1. Удиртгал

Валютын зах зээл (Forex) нь дэлхийн хамгийн том санхүүгийн зах зээл бөгөөд өдөр тутмын арилжааны хэмжээ 7.5 их наяд ам.долларт хүрдэг. Энэхүү зах зээлийн хэт хэлбэлзэлтэй байдал нь уламжлалт аргуудаар үнийн хөдөлгөөнийг таамаглахад хүндрэл учруулдаг. Сүүлийн жилүүдэд машин сургалтын технологиуд энэ салбарт өргөн хэрэглэгдэх болсон ч ихэнх систем нь дангаар ажилладаг загварт тулгуурладаг бөгөөд overfitting-ийн эрсдэл өндөртэй. Энэхүү судалгааны зорилго нь олон загварын ансамбль аргыг ашиглан найдвартай арилжааны дохио үүсгэх, мобайл аппликашнаар хэрэглэгчдэд хүргэх бүрэн системийг хөгжүүлэх юм.

2. Судалгааны арга зүй

Судалгааны ажилд LightGBM, XGBoost, CatBoost гэсэн турван Gradient Boosted Decision Trees (GBDT) загварын ансамблийг ашигласан. MetaTrader 5-aac EUR/USD валютын хослолын 2015–2024 оны OHLCV өгөгдлийг 6 хугацааны интервалаар (M1, M5, M15, M30, H1, H4) татан авч, интервал бүрээс 8 техник шинж чанар тооцоолж нийт 48 шинж чанар бүхий өгөгдлийн бүтэц үүсгэсэн.

Walk-forward validation аргачлалаар өгөгдлийг хуваасан: сургалт (2015–2021), калибрэйшн (2022), баталгаажуулалт (2023), тест (2024). Загварын таамгийг Logistic Regression calibrator-aар нэгтгэж, confidence $\geq 90\%$, ATR ≥ 4.0 пипс шүүлтүүр хэрэглэн чанартай дохио үүсгэсэн.

Flask REST API сервер дээр ажилладаг backend систем, React Native технологиор мобайл аппликашни хөгжүүлсэн. MetaTrader 5 Strategy Tester дээр бодит зах зээлийн нөхцөлд бэктест хийсэн.

3. Судалгааны үр дүн

2025 оны 01–10 сарын бэктестиийн гол үр дүн:

- Өгөөж: +41.61% ($\$10,000 \rightarrow \$14,161.20$)
- Profit Factor: 2.46 (нийт ашиг нь алдагдлаас 2.46 дахин их)
- Sharpe Ratio: 9.64 (эрсдэлд тохируулсан өгөөж маш өндөр)
- Max Drawdown: 3.93% (маш бага уналт)
- Нийт 45 арилжaa, 44.44% win rate, дундаж ашиг \$351 vs дундаж алдагдал \$114

7 давталтат хөгжүүлэлтийн үе шатаар загварыг 75-aac 48 шинж чанар, 9-өөс 3 загвар болгож хялбаршуулсан ч бүх гүйцэтгэлийн хэмжүүрүүд сайжирсан. Тест дээрх нарийвчлал 87.4%, өндөр итгэлцэлтэй дохионы нарийвчлал 95%+ байсан нь overfitting байхгүй болохыг баталж байна.

4. Дүгнэлт

Машин сургалтын ансамбль загвар нь Forex зах зээл дээр ашигтай арилжааны дохио үүсгэх чадвартай болохыг энэхүү судалгаа бодитоор батлав. Систем нь мэргэжлийн хөрөнгө оруулалтын сангийн түвшний гүйцэтгэл үзүүлсэн. Гэвч ганц валютын хослолд сургагдсан байдал, зах зээлийн горим өөрчлөгдөх эрсдэл зэрэг хязгаарлалтууд байна. Цаашид олон хослолд өргөтгөх, гүн сургалтын загвар нэмэх, NLP-ээр мэдээний шинжилгээ хийх чиглэлээр хөгжүүлэх боломжтой.

Судалгааны ажлын цаашидын төлөвлөгөө болон хэтийн төлөвийг хэлэлцүүлэг байдлаар бичиж оруулна.

5. Ном зүй

Судалгаанд ашигласан гол ном, сурах бичиг, эрдэм шинжилгээний өгүүллүүдээс:

1. Chen, T. and Guestrin, C. (2016). “XGBoost: A Scalable Tree Boosting System.” *ACM SIGKDD*.
2. Ke, G. et al. (2017). “LightGBM: A Highly Efficient Gradient Boosting Decision Tree.” *NeurIPS*.
3. Prokhorenkova, L. et al. (2018). “CatBoost: Unbiased Boosting with Categorical Features.” *NeurIPS*.
4. Gu, S. et al. (2020). “Empirical Asset Pricing via Machine Learning.” *The Review of Financial Studies*.
5. Pardo, R. (2008). *The Evaluation and Optimization of Trading Strategies*. John Wiley & Sons.