



ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутны код: s21c033b

Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

/ДЭД БАКАЛАВРЫН ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот

2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Дэд бакалаврын төгсөлтийн судалгааны ажил (061301)

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН
ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот
2026 он

Хураангуй

Энэхүү судалгааны зорилго нь валютын зах зээл (Forex)-ийн шуугиан ихтэй, горим хувьсамтгай өгөгдлөөс арилжааны дохио үүсгэх машин сургалтын системийг хөгжүүлж үнэлэхэд оршино. Загварын ангиллын чанарыг дангаар нь биш, дохио бодит гүйцэтгэлд хэрхэн хөрвөж байгааг түүхэн өгөгдөл дээрх системийн туршилтын үр дүнтэй хамтатган шинжилсэн.

EUR/USD-ийн 2015–2024 оны өгөгдлийг зургаан хугацааны интервалаар нэгтгэн 48 шинж чанар (feature) үүсгэж, LightGBM, XGBoost, CatBoost загваруудыг зөөлөн саналын ансамблиар нэгтгэсэн. Үнэлгээний хүрээ нь урагш гүйлгэн баталгаажуулалт (WFV) бөгөөд Fold 5 огтлолд (2015–2022 сургалт, 2023 баталгаажуулалт, 2024 тест) KPI тайлан төвлөрүүлсэн. Магадлалын тохируулгыг (calibration) баталгаажуулалтын огтлол дээр туршилтын ажиглалтаар шалгасан бөгөөд ажиллах үеийн дүнг тохируулга хэрэглээгүй шууд магадлалаар тайлагнасан.

Түүхэн өгөгдөл дээрх системийн туршилтыг 2025.01.01–2026.01.01 цонхонд хийж, ажиллах үеийн итгэлцлийн босгыг 0.90 дээр тогтмол байлгасан нөхцөлд 0.90–0.99 мужийн сценариудыг харьцуулсан. 359,639 анхны таамгаас 3,567 дохио (1.0%) шүүгдэж үлдсэн. 0.91 босгон дээр \$61,770.46 (+517.70%), 0.90 дээр \$58,262.39 (+482.62%), 0.99 дээр \$17,428.89 (+74.29%) гарсан. EUR/USD buy-and-hold жишгээр \$10,000 хөрөнгө \$11,346.87 (+13.47%) болсон. Win rate 44.78%–65.71%, Expectancy (R) 0.79–1.63, Max drawdown 1.98%–9.53%, хамгийн урт дараалсан алдагдал 2–10 байв. Спред ба гулсалтыг тусгасан ч шимтгэл, свопыг бүрэн хамраагүй тул өгөөжийн дүнг сценарийн харьцуулалтын хүрээнд тайлбарласан.

Машин сургалт, серверийн хэсэг (backend), харагдах хэсэг (frontend)-ийг API-гаар нэгтгэснээр дохионы үр дүнг хэрэглэгчид хүргэх инженерчлэлийн боломжийг харуулсан.

Түлхүүр үгс: машин сургалт, ансамбль загвар, GBDT, урагш гүйлгэн баталгаажуулалт, түүхэн өгөгдөл дээрх системийн туршилт, дохио-арилжааны хөрвүүлэлт, Wilson итгэлцлийн интервал, хүлээгдэж буй өгөөж (R), Max drawdown, сценарийн хэлбэлзэл (CV), серверийн хэсэг (backend), харагдах хэсэг (frontend)

Гарчиг	
Хураангуй	i
Гарчиг	ii
Товчилсон үгсийн жагсаалт	iii
Нэр томъёоны тайлбар толь	iv
Хүснэгтийн жагсаалт	vi
Зургийн жагсаалт	vii
1 Ажлын төлөвлөгөө	1
2 Удиртгал	2
2.1 Үндэслэл, ач холбогдол	2
2.2 Зорилго, зорилт	2
2.3 Судалгааны асуулт ба хэмжигдэх шалгуур	3
3 Судалгааны сэдвийн онол, өнөөгийн түвшин	4
3.1 Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд	4
3.2 Шинж чанаруудын судалгаа	5
3.3 Урагш гүйлгэн баталгаажуулалт (walk-forward validation) ба санхүүгийн цаг хугацааны цуваа	6
3.4 Форекс арилжааны аппликейшн ба технологийн хэрэгжүүлэлт	7
3.5 Төсөөтэй системүүд ба харьцуулалт	7
3.6 Судалгааны арга барил	9
3.7 Системийн ерөнхий бүтэц	9
3.8 Өгөгдлийн урсгал	10
3.9 Өгөгдлийн бэлтгэл	11
3.10 AI загварын бүтэц ба сургалт	15
3.11 Дохио үүсгэх систем	18
3.12 MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт (backtesting)	21
3.13 Серверийн хэсгийн хэрэгжүүлэлт	24
3.14 Мобайл давхаргын архитектурын хураангуй	26
3.15 Загварын давталтат сайжруулалт	26
4 Судалгааны үр дүн, дүгнэлт	28
4.1 Үр дүнгийн өгөгдлийн эх сурвалж	28
4.2 Босгын мужийн нэгтгэсэн үр дүн	28
4.3 Үр дүнгийн тайлбар	32
4.4 Дахин хэрэгжүүлэх боломж ба орчны нөхцөл	34
4.5 Практик шийдвэр гаргалтын хүрээ	35
4.6 Дүгнэлт	35
Ном зүй	37
Товчлол	40

Товчилсон үгсийн жагсаалт

ML	Machine Learning – Машин сургалт
AI	Artificial Intelligence – Хиймэл оюун ухаан
GBDT	Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод
XGBoost	Extreme Gradient Boosting
LightGBM	Light Gradient Boosting Machine
CatBoost	Categorical Boosting
LSTM	Long Short-Term Memory – Урт богино хугацааны санах ой
RSI	Relative Strength Index – Харьцангуй хүчний индекс
ATR	Average True Range – Дундаж жинхэнэ хүрээ
MACD	Moving Average Convergence Divergence
SMA	Simple Moving Average – Энгийн хөдөлгөөнт дундаж
EMA	Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж
ADX	Average Directional Index – Дундаж чиглэлийн индекс
CCI	Commodity Channel Index
SL	Stop Loss – Алдагдал зогсоох
TP	Take Profit – Ашиг авах
API	Application Programming Interface
REST	Representational State Transfer
JWT	JSON Web Token
OHLCV	Open, High, Low, Close, Volume
MT5	MetaTrader 5
PF	Profit Factor – Ашгийн коэффициент
DD	Drawdown – Уналт
RR	Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа
CORS	Cross-Origin Resource Sharing
WSGI	Web Server Gateway Interface
CSV	Comma-Separated Values

Тайлбар: MACD, ADX, CCI зэрэг товчилсон нэршил нь судалгааны тойм болон боломжит индикаторын хэлэлцүүлэгт хэрэглэгдсэн; энэ хувилбарын эцсийн 48 шинж чанарын матрицад заавал орсон гэсэн утга биш.

Нэр томъёоны тайлбар толь

Хатуу мөрдөх зарчим:

- Нэг ойлголтод зөвхөн хүснэгтэд өгсөн нэг л Монгол нэршлийг хэрэглэнэ.
- Өөр хувилбар, ижил утгатай өөр орчуулга, эсвэл Монгол нэршилгүй дан гадаад үг хэрэглэхгүй.
- Орчуулгыг үгчлэн махчилж буулгахгүй; компьютерийн ухааны хэрэглээний утгаар нь Монгол хэлэнд буулгана.
- Бичлэгийн үндсэн хэлбэр нь **Монгол нэр (original term)** байна.

Канон Монгол нэршил	Original term
хиймэл оюун ухаан	artificial intelligence
машин сургалт	machine learning
ангилал	classification
хоёртын ангилал	binary classification
шинж чанар	feature
шинж чанарын инженерчлэл	feature engineering
шинж чанарын нөлөөлөл	feature importance
шошго	label
ансамбль загвар	ensemble model
зөөлөн санал хураалт	soft voting
гиперпараметр	hyperparameter
эрт зогсоох	early stopping
тогтмолжуулалт	regularization
хэт нийцэл	overfitting
урагш гүйлгэн баталгаажуулалт	walk-forward validation
ирээдүйн мэдээлэл ашиглах хэвийдэл	look-ahead bias
зорилтот хувьсагчийн нэвчилт	target leakage
түүхэн өгөгдөл дээрх системийн туршилт	backtesting
уналт	drawdown
ханшийн хэлбэлзэл	volatility
хугацааны интервал	timeframe
итгэлцэл	confidence
итгэлцлийн босго	confidence threshold
магадлалын тохируулга	probability calibration
сүлжээнээс гадуурх үнэлгээ	offline evaluation
хэрэгжилтийн шалгалт	verification
бодит ажиллах орчин	production runtime

Канон Монгол нэршил	Original term
серверийн хэсэг	backend
харагдах хэсэг	frontend
өгөгдөл боловсруулах урсгал	data pipeline
программ хангамжийн интерфейс (interface)	API
цогц систем	end-to-end system
цогц шийдэл	end-to-end solution
цогц боловсруулах урсгал	end-to-end pipeline
түүвэр доторх	in-sample
түүврийн гадуурх	out-of-sample
байрлал	position
пипс	pip
спрэд	spread
гулсалт	slippage
эрсдэл-өгөөжийн харьцаа	risk-reward ratio
загварын шилжилт	model drift
push мэдэгдэл	push notification

Хүснэгтийн жагсаалт

Хүснэгт 2.1.	Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)	3
Хүснэгт 3.1.	Түүхэн өгөгдлийн хэмжээний хураангуй	11
Хүснэгт 3.2.	Шинж чанар (feature)ын жагсаалт (интервал бүрд)	12
Хүснэгт 3.3.	Leakage audit-ын цагийн нийцлийн дүрэм	13
Хүснэгт 3.4.	Урагш гүйлгэн баталгаажуулалтын хүрээнд ашигласан үндсэн огтлолын өгөгд- лийн хуваалт	14
Хүснэгт 3.5.	Загвар бүрийн гол гиперпараметрууд	17
Хүснэгт 3.6.	Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо	21
Хүснэгт 3.7.	Арилжааны зардлын хамралтын матриц	22
Хүснэгт 3.8.	Системийн үнэлгээний шалгуур үзүүлэлтүүд	23
Хүснэгт 3.9.	Серверийн хэсгийн үндсэн бүрэлдэхүүн	24
Хүснэгт 3.10.	Deployment топологийн хураангуй	25
Хүснэгт 3.11.	Серверийн хэсгийн функцийн бүлгүүд	25
Хүснэгт 4.1.	Босго тус бүрийн нотолгооны индексжүүлсэн холболт	28
Хүснэгт 4.2.	0.90–0.99 босгын мужийн харьцуулсан шинжилгээний баталгаажсан дүн	29
Хүснэгт 4.3.	EUR/USD buy-and-hold benchmark-ийн хураангуй	29
Хүснэгт 4.4.	Босго тус бүрийн дохио-арилжааны хөрвүүлэлт ба win rate (95% CI)	30
Хүснэгт 4.5.	Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ	30
Хүснэгт 4.6.	Арга зүйн эрсдэлийн нэгдсэн хүснэгт (энэ хувилбар)	34

Зургийн жагсаалт

Зураг 3.1.	Давталтат хөгжүүлэлтийн мөчлөгийн хураангуй (7 давталт)	9
Зураг 3.2.	Системийн үндсэн ойлголт – өгөгдлөөс трейдер хүртэлх урсгал	9
Зураг 3.3.	Системийн гурван давхаргат бүтэц	10
Зураг 3.4.	Өгөгдлийн урсгалын диаграмм (data flow diagram)	11
Зураг 3.5.	Урагш гүйлгэн баталгаажуулалт (WFV): энэ судалгааны үнэлгээнд ашигласан нэг огтлолын (Fold 5) өгөгдлийн хуваалт	14
Зураг 3.6.	Урагш гүйлгэн баталгаажуулалтын (WFV) олон огтлолын концепцын схем	15
Зураг 3.7.	GBDT ансамбль загварын архитектур	16
Зураг 3.8.	Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио	19
Зураг 3.9.	Дохио үүсгэх дарааллын диаграмм (sequence diagram)	20
Зураг 3.10.	Загварын давталтат сайжруулалтын үе шатууд ба гол өөрчлөлтүүд	27
Зураг 4.1.	Босгын мужийн шинжилгээ: Execution rate-ийн өөрчлөлт	31
Зураг 4.2.	Босгын мужийн шинжилгээ: Win rate ба 95% итгэлцлийн интервал	31
Зураг 4.3.	Босгын мужийн шинжилгээ: Expectancy (R)-ийн өөрчлөлт	32

1. Ажлын төлөвлөгөө

Оюутны нэр: М.Мөнхдорж

Удирдагч багшийн нэр: Н.Соронзонболд

Судалгааны ажлын сэдэв: Машин сургалтын аргаар хөрөнгийн зах зээлийн чиг хандлагыг таамаглах арилжааны бот хөгжүүлэх

Сар	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 сар	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Форекс арилжаа, машин сургалт (machine learning) онолын судалгаа хийх	✓
	3	Yahoo Finance API-аас EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 сар	1	70+ техник индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модел сургах	✓
	3	Stacking Ensemble модел хөгжүүлэх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх	✓
	4	Серверийн хэсэг болон мобайл апп хөгжүүлэх	✓
12 сар	1	ТСА Үзлэг 1	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 сар	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 сар	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	✓
	4	Хамгаалалтын бэлтгэл хийх	✓
3 сар	1	ТСА Үзлэг 2	□
	2	Засвар хийх, санал хүсэлтийг тусгах	□
	3	Код тайлбар, баримтжуулалт	□
	4	Хамгаалалтын дадлага хийх	□
4 сар	1	Эцсийн засвар хийх	□
	2	Слайд сайжруулах	□
	3	Хамгаалалтын бэлтгэл	□
	4	ТСА урьдчилсан хамгаалалт	□
5 сар	1	ТСА урьдчилсан хамгаалалт	□
	2	ТСА урьдчилсан хамгаалалт	□
	3	Эцсийн засвар, сайжруулалт	□
	4	ТСА үндсэн хамгаалалт	□

Удирдагч багш

Гүйцэтгэсэн оюутан

/Н.Соронзонболд, магистр/

/s21c033b, М.Мөнхдорж/

2. Удиртгал

2.1. Үндэслэл, ач холбогдол

Өгөгдлийн шинжлэх ухаан болон мэдээллийн технологийн салбарт олон хэмжээст, шуугиан ихтэй цаг хугацааны цувааны өгөгдөлд дүн шинжилгээ хийх нь томоохон сорилт хэвээр байна. Түүний тод жишээ нь гадаад валютын зах зээл буюу форекс юм. Энэ зах зээл нь олон улсын эдийн засгийн төлөв байдал, төв банкуудын бодлого зэрэг макро түвшний хүчин зүйлсээс хамааран тасралтгүй, өндөр хэлбэлзэлтэйгээр өөрчлөгддөг [1]. Ийм шугаман бус өгөгдлөөс зүй тогтлыг илрүүлэх нь уламжлалт статистикийн шинжилгээний хувьд хүндрэлтэй.

Уламжлалт аргууд нь ихэвчлэн хүний шууд оролцоо, субъектив дүгнэлтэд тулгуурладаг. Иймээс их хэмжээний өгөгдлийг богино хугацаанд боловсруулж үнэн зөв таамаглахад тооцооллын хүчин чадал болон математик загварчлалын нарийвчлалын хувьд хязгаарлагдмал.

Сүүлийн жилүүдэд машин сургалт болон хиймэл оюун ухааны алгоритмууд программ хангамжийн салбарт эрчимтэй нэвтэрч байна. Тухайлбал, GBDT болон нейрон сүлжээ зэрэг орчин үеийн алгоритмууд нь их хэмжээний өгөгдөл дэх нарийн төвөгтэй зүй тогтлыг илрүүлэх өндөр чадамжтайг харуулсан [2][3]. Гэсэн хэдий ч загвар сургалтын өгөгдөлдөө хэт нийцэх, нэг алгоритмд түшиглэсэн архитектураас үүдэн системийн доголдол гарах зэрэг инженерчлэлийн асуудал практик орчинд тулгарсаар байна.

Иймд энэ чиглэлийн судалгаанд зөвхөн загварын нарийвчлалыг сайжруулах нь хангалтгүй. Серверийн хэсэг (backend)-ийн бодит цагийн өгөгдөл боловсруулах урсгал, гүйцэтгэлийн тогтвортой байдал, мөн харагдах хэсэг (frontend)-д үр дүнг хүргэх инженерчлэлийн уялдааг хамтад нь авч үзэх шаардлагатай. Тиймээс энэхүү судалгаа нь алгоритмын нарийвчлалыг серверийн хэсэг (backend) болон харагдах хэсэг (frontend)-ийн бодит хэрэгжилттэй уялдуулсан систем хөгжүүлснээрээ онцлог.

Энэхүү ажилд санал хураалтад суурилсан ансамбль загвар, урагш гүйлгэн баталгаажуулалт, олон хугацааны интервалын шинж чанарын инженерчлэлийг ашиглан илүү найдвартай архитектурыг судалж хөгжүүлсэн. Түүнчлэн тооцооллын үр дүнг API-аар дамжуулан хэрэглэгчдэд ойлгомжтой хэлбэрээр хүргэх мобайл интерфэйс бүтээснээр финтек болон мэдээллийн технологийн салбарт практик үнэ цэн бий болгох боломжийг харуулна.

2.2. Зорилго, зорилт

Судалгааны зорилго

Энэхүү судалгааны ажлын үндсэн зорилго нь **EUR/USD валютын хослолын арилжааны өгөгдөл дээр машин сургалтын ансамбль загвар боловсруулж, зах зээлийн шуугианыг шүүх замаар ангиллын чанарыг сайжруулан, үүссэн дохионы гүйцэтгэлийг түүхэн өгөгдөл дээрх системийн туршилтаар үнэлэх** явдал юм.

Судалгааны зорилтууд

Энэхүү зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлэв:

1. EUR/USD хослолын түүхэн өгөгдлийг цуглуулах, цэвэрлэх, түүнчлэн зах зээлийн суурь шинж чанаруудыг тодорхойлох шинж чанарын инженерчлэл (feature engineering) гүйцэтгэх.
2. Алгоритмын хэт нийцлээс (overfitting) сэргийлэх урагш гүйлгэн баталгаажуулалтын (walk-forward validation) аргад суурилсан, олон алгоритмын холимог буюу ансамбль санал хураалтын (voting mechanism) туршилтын орчныг хөгжүүлэх.

3. Системийн ангиллын чанар (accuracy), эрсдэлийн алдагдал (drawdown), болон найдвартай байдлыг цогцоор нь үнэлэх системийн туршилт (system testing) хийх.
4. Хэрэглэгчид ойлгомжтой интерфэйс бүхий харагдах хэсгийн (frontend) аппликейшн бүтээж, серверийн бодит цагийн арилжааны дохиог дамжуулах системийн интеграци хэрэгжүүлэх.

2.3. Судалгааны асуулт ба хэмжигдэх шалгуур

Судалгааны ажлын зорилтуудыг хэмжихүйц шалгууруудтай холбохын тулд дараах судалгааны асуултуудыг тодорхойлов. Асуулт бүрийн хариуг баруун баганад буй тодорхой хэмжүүрээр (KPI) үнэлнэ.

Хүснэгт 2.1 Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)

RQ	Судалгааны асуулт	Хэмжих шалгуур үзүүлэлт
RQ1	Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр тогтвортой, найдвартай ажиллах уу?	Ерөнхий ангиллын чанар (accuracy/F1), мөн өндөр итгэлцэлтэй дохионы дэд багц дахь чанар
RQ2	Шүүгдсэн дохио бодит гүйцэтгэл дээр үнэхээр арилжаа болж хэрэгжих үү?	Дохио-арилжааны хөрвүүлэлт (execution rate), амжилттай арилжааны хувь (win rate), win rate-ийн Wilson 95% итгэлцлийн интервал
RQ3	Тогтмол эрсдэлийн дүрэмтэй үед систем урт хугацаанд ашигтай, тогтвортой байх уу?	Эцсийн үлдэгдэл ба нийт өгөөж, нэг арилжааны хүлээгдэж буй өгөөж (Expectancy, R), сценарийн хэлбэлзэл (балансын CV)

3. Судалгааны сэдвийн онол, өнөөгийн түвшин

3.1. Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

Уламжлалт машин сургалтын аргууд

Санхүүгийн зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн өмнөх үеийн судалгаанууд нь голчлон нейрон сүлжээ (neural networks) болон тулгуур векторын машин (support vector machines, SVM)-д төвлөрч байсан. Kamruzzaman, Sarker нар (2003) нь нейрон сүлжээг ашиглан валютын ханш таамаглахад 81%-ийн нарийвчлал хүрсэн [4]. Гэвч судалгааны дараах сул талууд байна:

- Зөвхөн нэг валютын хослолд хязгаарлагдсан
- Хэт нийцэл (overfitting)-ийн асуудлыг тодорхой авч үзээгүй
- Түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийгээгүй

Kumar, Thenmozhi нар (2006) нь SVM болон Random Forest-ийг хөрөнгийн индексийн чиглэлийн таамаглалд харьцуулсан бөгөөд зах зээлийн нөхцөл өөрчлөгдөхөд загварын тогтвортой байдал буурах эрсдэлийг онцолсон [5].

Санамсаргүй ой (random forest) болон градиент нэмэгдүүлэлт (gradient boosting) аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings тэргүүтэй судлаачид (2015) нь хувьцааны ханшийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц гарсан болохыг тогтоосон** [6]. Гэсэн хэдий ч, санхүүгийн зах зээлд эдгээр аргуудыг бүрэн туршиж үзээгүй нь судалгааны ажлуудын дутагдалтай тал хэвээр байна.

Гүн сургалтын аргууд

Сүүлийн жилүүдэд урт-богино хугацааны санах ой (long short-term memory, LSTM) болон гүн нейрон сүлжээ (deep neural network, DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer, Krauss нар (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang тэргүүтэй судлаачид (2019) нь санхүүгийн цаг хугацааны цуваанд гүн сургалтын хэрэглээг системтэй тоймлон нэгтгэсэн [8].

2022 оноос хойш цаг хугацааны цуваанд Transformer суурьтай шинэ архитектурууд (жишээ нь PatchTST, TimesNet) хүчтэй хөгжсөн. PatchTST нь цувааг хэсэгчлэн токенчлох аргаар урт хамаарлыг үр ашигтай барих, TimesNet нь 1D цувааг олон хугацааны 2D хувиргалтаар дүрслэх санааг дэвшүүлсэн [9] [10]. Гэвч эдгээр ажлуудын үндсэн зорилт нь ихэвчлэн ерөнхий forecasting benchmark дээр төвлөрдөг бөгөөд форексын дохио шүүлтүүр, гүйцэтгэлийн хөрвүүлэлт, түүхэн өгөгдөл дээрх системийн туршилтын ажиллах орчны нөхцөлийг иж бүрэн хамарсан судалгаа ховор хэвээр байна.

Гэсэн хэдий ч, **гүн сургалтын аргуудын дараах сул талууд** илэрхий байна [11]:

- **Тайлбарлах боломжгүй байдал (black-box):** Санхүүгийн шийдвэр гаргалтанд шаардлагатай тайлбарлах чадвар дутмаг
- **Маш олон параметр, удаан сургалт:** 100,000+ параметртэй, өгөгдөл их шаарддаг
- **Хэт нийцэл (overfitting)-д эмзэг:** Түүхэн өгөгдөлд хэт тохирч, шинэ зах зээлийн нөхцөлд муу ажилладаг
- **Тогтворгүй:** Анхны параметрээс их хамаардаг

Krauss болон түүний багийнхан (2017) нь гүн нейрон сүлжээ болон градиент нэмэгдүүлсэн шийдвэрийн мод (gradient-boosted trees) загваруудыг S&P 500 дээр харьцуулж, **GBDT загварууд илүү тогтвортой үр дүн үзүүлсэн** гэж дүгнэсэн [11]. Энэ нь судалгаанд GBDT ансамбль загваруудыг ашиглах үндэслэл болж байна.

Градиент нэмэгдүүлсэн шийдвэрийн мод (gradient boosted decision trees) санхүүгийн салбарт

GBDT нь Friedman (2001)-ийн боловсруулсан аргачлал бөгөөд олон шийдвэрийн мод (decision tree)-ийг дараалан нэмж, алхам бүрд өмнөх загварын үлдэгдэл алдааг (gradient) бууруулж сургадаг [12]. Gu, Kelly, болон Xiu (2020) нь 150+ оролтын хувьсагчтай GBDT загварыг хувьцааны өгөөж таамаглахад хэрэглэж, **гүн сургалтын загваруудтай харьцуулахад илүү нарийвчлалтай** байсныг тогтоосон [13]. Тэд мөн GBDT загваруудын дараах давуу талуудыг дурдсан:

- Хүснэгтэн (tabular) өгөгдөлд тохирсон шинж чанаруудын харилцан үйлчлэл (feature interaction)-ийг олж илрүүлдэг
- Цөөн параметртэй – хурдан сургаж болно
- Шинж чанарын чухал байдал (feature importance)-ыг хялбар тооцоолох – тайлбарлах боломжтой
- Гажиг утга (outlier)-д мэдрэмтгий бус

XGBoost [2], LightGBM [3], CatBoost [14] нь GBDT-ийн орчин үеийн хувилбар бөгөөд өөр өөр онцлогтой. XGBoost нь L1/L2 тогтмолжуулалт (regularization) давуу талтай, LightGBM нь хурдтай боловч хэт нийцэл (overfitting)-д илүү эмзэг, CatBoost нь эрэмбэлэгдсэн нэмэгдүүлэлт (ordered boosting) ашиглан зорилтот хувьсагчийн нэвчилт (target leakage)-ийн эрсдэлийг бууруулдаг. Гэсэн хэдий ч, эдгээр загваруудыг **форекс зах зээлд ансамбль хэлбэрээр хэрэглэж, харьцуулсан судалгаа маш хомс** байна.

Ансамбль аргуудын хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [15]. Breiman (2001) санамсаргүй ой (random forest) аргаар олон модыг параллель сургаж, дундажлах (average) замаар хэлбэлзэл (variance)-ийг бууруулсан [16]. Sezer тэргүүтэй судлаачид (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол өндөр гүйцэтгэлтэй байдгийг** дурдсан [17].

3.2. Шинж чанаруудын судалгаа

Шинж чанаруудын үр дүнтэй байдлын харьцуулалт

Уламжлалт санхүүгийн онол буюу Fama (1970)-ийн гаргасан “Үр ашигт зах зээлийн таамаглал” (efficient market hypothesis – ЕМН)-аар техникийн дүн шинжилгээ нь ямар ч ашиггүй хэмээн үздэг байв [18]. Хожим нь Murphy (1999) техник шинжилгээний талаарх маш системтэй танилцуулгыг бичсэн ч, түүнийгээ бодит өгөгдөл дээр хангалттай сайн баталгаажуулж чадаагүй юм [19]. Харин Lo болон бусад судлаачид (2000) илүү нарийвчилсан статистик тестүүд хийж үзээд, **техник аргууд нь зах зээл дээр статистикийн хувьд ач холбогдолтой үр дүн өгч чаддаг** болохыг нотолсон байдаг [20].

Энэхүү нээлт нь зах зээл хэзээд, бүрэн үр ашигтай байдаг гэсэн ЕМН-ийн онолыг тодорхой хэмжээнд няцаасан юм.

Түүнчлэн, Olson (2004) нь ханшийн хэлбэлзэл болон эрчмийг хэмждэг RSI, MACD, Stochastic зэрэг түгээмэл шинж чанаруудыг форекс зах зээлд судалж үзээд, **ганц шинж чанар дангаараа тогтвортой ашиг өгөх боломжгүй** гэж дүгнэжээ [21]. Тэрээр хугацааны интервал өөрчлөгдөхөд индикаторын үр дүн дагаад өөрчлөгддөг бөгөөд зах зээлийн тухайн үеийн нөхцөлөөс ихээхэн хамаардаг болохыг онцолсон. Иймээс **олон шинж чанарыг хослуулах, мөн олон хугацааны хүрээг зэрэг ашиглах** шаардлага гардаг. Энэхүү шаардлага нь энэ судалгааны ажлын суурь болж, M1-ээс H4 хүртэлх 6 ялгаатай хугацааны интервалаас нийт 48 шинж чанар тооцоолж загварт оруулах үндэслэл болсон.

Brock тэргүүтэй судлаачид (1992) нь хөдөлгөөний дунджийн огтлолцол (moving average crossover буюу ханшийн дундаж утгуудын муруй огтлолцох цэг дээр суурилсан дохио) бүхий стратегиудыг судалж, тодорхой нөхцөлд ашигтай байж болохыг харуулсан боловч **арилжааны зардал (transaction cost)-ыг тооцох үед ашиг ихээхэн багасах** эрсдэлийг онцолсон [22]. Энэ нь MetaTrader 5 (бодит өгөгдлийн платформ (data platform)) дээрх түүхэн өгөгдөл дээрх системийн туршилт (backtesting)-д спред (spread буюу авах, зарах ханшийн зөрүү), ханшийн зөрүү (slippage буюу захиалга биелэх үеийн ханшийн зөрүү), болон своп (swap буюу хоног шилжих үеийн хүүгийн зардал) зэрэг бодит зах зээлийн шимтгэлүүдийг заавал авч үзэх шаардлагатайг харуулж байна. Marshall болон түүний багийнхан (2008) нь commodity futures зах зээл дээрх тоон хугацааны стратегийн үр дүн нь хэрэглэсэн дүрэм болон зардлын таамаглалаас хүчтэй хамаарахыг харуулсан [23].

Шинж чанарын хослуулалт ба шинж чанарын инженерчлэл

Park, Irwin нар (2007) нь 95 судалгааг тоймлон, техник аргууд 1995 он хүртэл үр дүнтэй байсан боловч сүүлийн жилүүдэд үр дүн буурч байгааг тогтоосон. Үүнийг **зах зээлийн дасан зохицох чадвар**-ын илрэл гэж тайлбарласан [24]. Энэ нь шинж чанарыг дангаар нь ашиглахаас илүү машин сургалтын загварт хослуулан хэрэглэх нь үр дүнтэй байж болохыг илтгэнэ.

Шинж чанарууд нь GBDT загварт оролтын хувьсагч болж ашиглагдахад үр дүнтэй. Гэвч өмнөх судалгааны ихэнх нь зөвхөн нэг хугацааны интервалын өгөгдөл ашигласан. Энэ нь чухал мэдээллийг алдах эрсдэлтэй: жишээлбэл, 1 минутын график дээр богино хугацааны эргэлт харагддаг бол 4 цагийн график дээр урт хугацааны чиг хандлага илүү тод ажиглагдана. Эдгээрийг хамтад нь ашигласнаар загвар зах зээлийн дүр зургийг олон өнцгөөс харж чаддаг. Энэхүү судалгаанд M1, M5, M15, M30, H1, H4 гэсэн 6 хугацааны интервалаас 48 индикатор тооцоолж загварт оруулсан нь өмнөх судалгаанаас ялгарах гол онцлог.

3.3. Урагш гүйлгэн баталгаажуулалт (walk-forward validation) ба санхүүгийн цаг хугацааны цуваа

Уламжлалт k-нугалааст солбицсон баталгаажуулалт (k-fold cross-validation) нь санхүүгийн цуваа өгөгдөлд тохиромжгүй, учир нь цаг хугацааны дарааллыг зөрчиж, ирээдүйн мэдээлэл ашиглах хэвийдэл (look-ahead bias) үүсгэдэг. Pardo (2008) нь урагш гүйлгэн баталгаажуулалт (walk-forward validation, WFW) аргачлалыг танилцуулж, энэхүү аргачлал нь цаг хугацааны дарааллыг хадгалж, загварыг ирээдүйн өгөгдөл дээр шалгахад илүү бодит болохыг харуулсан [25].

Урагш гүйлгэн баталгаажуулалт (walk-forward validation) аргачлалын давуу талууд:

- **Ирээдүйн өгөгдөл сургалтад нэвтрэхээс сэргийлдэг:** Загварыг сургах үед зөвхөн тухайн цэгийн өмнөх өгөгдлийг ашигладаг тул ирээдүйн мэдээлэл алдагдахгүй
- **Зах зээлийн нөхцөл өөрчлөгдөхийг илрүүлдэг:** Цаг хугацааны явцад зах зээлийн зан төлөв өөрчлөгдөж байдаг бөгөөд WFV нь загварын гүйцэтгэлийн хэлбэлзлээр энэ өөрчлөлтийг илрүүлж чаддаг
- **Бодит арилжааны нөхцөлийг дуурайдаг:** Загвар нь таамаглал хийх үед зөвхөн өнгөрсөн өгөгдлийг хардаг – яг бодит арилжаан дахь шийдвэр гаргалттай адил

Bailey болон түүний багийнхан (2014) нь санхүүгийн загваруудын хэт нийцэл (overfitting)-ийн эрсдэлийг задлан, **олон параметрийн тохируулга (parameter tuning) хийх нь түүвэр доторх (in-sample) үр дүнг сайжруулна гэхдээ түүврийн гадуурх (out-of-sample) дээр муудна** гэж анхааруулсан [26]. Энэ нь WFV ашиглах чухал шалтгаан – энэхүү судалгаанд 2015–2022 (сургалт), 2023 (баталгаажуулалт), 2024 (тест), 2025 (түүхэн өгөгдөл дээрх системийн туршилт (backtesting)) гэж тусгаарлаж, хэт нийцэл (overfitting)-аас сэргийлсэн.

3.4. Форекс арилжааны аппликейшн ба технологийн хэрэгжүүлэлт

Мобайл арилжааны технологи

React Native [27] нь JavaScript дээр суурилсан гар утасны хөгжүүлэлтийн орчин бөгөөд нэг кодын сууриар Android аппликейшн хурдан хөгжүүлэхэд тохиромжтой. Eisenman (2018) нь React Native-ийн давуу тал нь хурдан хөгжүүлэлт, код дахин ашиглалт болохыг дурдсан боловч гүйцэтгэл нь цэвэр native аппликейшнаас бага зэрэг буурч болохыг тэмдэглэсэн [28].

Серверийн хэсгийн ерөнхий архитектурын хандлага

Серверийн хэсгийн архитектурын зорилго нь бодит цагийн өгөгдлийг тогтвортой боловсруулах, машин сургалтын загварын үр дүнг API дамжуулалт хэлбэрээр хүргэх, мөн мобайл аппликейшн-тэй найдвартай холболт үүсгэх явдал юм. Судалгааны ажлуудад хөнгөн, уян хатан вэб фреймворк (framework) ашиглах нь хурдан туршилт болон тасралтгүй шинэчлэл хийх давуу талтай гэж үздэг [29].

Системийн найдвартай байдал ба аюулгүй байдлын судалгааны цоорхой

Арилжааны системийн олон судалгаа загварын нарийвчлал (accuracy), өгөөж (return) зэрэг үзүүлэлтүүдэд төвлөрдөг боловч бодит хэрэглээний орчинд системийн найдвартай ажиллагаа, серверийн тасралтгүй бэлэн байдал (availability), мэдээлэл хүргэлтийн чанарыг хангалттай авч үздэггүй.

Энэ цоорхой нь бодит хэрэглээнд шилжих үед өндөр эрсдэл үүсгэдэг. Учир нь загварын математик гүйцэтгэл сайн байсан ч үйл ажиллагааны хүчин зүйлс сул байвал системийн нийт үр нөлөө буурдаг. Иймд энэхүү судалгаанд машин сургалт (machine learning)-ын үнэлгээг системийн найдвартай ажиллагааны үнэлгээтэй уялдуулсан нэгдмэл хандлагыг хэрэглэсэн.

3.5. Төсөөтэй системүүд ба харьцуулалт

Бидний санал болгож буй “Predictrix” системтэй төстэй, зах зээлд байгаа зарим мобайл аппликейшн болон open source системүүдийг харьцуулан судлав.

Зах зээлд байгаа төсөөтэй аппликейшнууд

1. AlgoTrade 3

Kin Fung Wong-ийн хөгжүүлсэн “AlgoTrade 3” нь алгоритмын арилжааны стратегиудыг симуляци хийх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх зориулалттай мобайл аппликейшн юм. Энэ нь өдөр тутмын (daily) хувыцааны өгөгдөл дээр үндэслэн стратегиудыг турших боломжийг олгодог.

- *Ялгаа:* Энэхүү апп нь бодит цагийн фореक्स дохио өгдөггүй, зөвхөн түүхэн өгөгдөл дээрх симуляцид төвлөрсөн. Мөн зөвхөн өдрийн хугацааны интервал (Daily timeframe) ашигладаг тул өдрийн (intraday) бодит арилжаанд тохиромжгүй. Харин “Predictrix” нь M1–H4 олон хугацааны интервал ашиглан бодит цагийн дохио үүсгэдэг.

2. Tradlgo: Algo Trade & Screener (Android)

ZSCALE TECH-ийн хөгжүүлсэн “Tradlgo” нь хиймэл оюун ухаан ашиглан хэрэглэгчийн бичсэн энгийн текстээс (natural language) алгоритмын арилжааны стратеги үүсгэх, код бичихгүйгээр (no-code) автоматжуулах боломжийг олгодог платформ юм.

- *Ялгаа:* Tradlgo нь хэрэглэгчийг өөрөө стратегиа бүтээхэд туслах хэрэгсэл (tool) юм. Харин “Predictrix” нь урьдчилан сургагдсан GBDT ансамблийн гаралтад суурилсан дохиог аппликейшнаар хүргэх судалгааны прототип байдлаар хэрэгжсэн.

Харьцуулсан судалгаа ба open source системүүд

1. GBDT загваруудын хэрэглээний суурь:

XGBoost, LightGBM, CatBoost загваруудын алгоритмын онцлог, давуу талуудыг эх бүтээлүүдэд дэлгэрэнгүй тайлбарласан [2][3][14]. Гэсэн хэдий ч эдгээр загварыг форекс өгөгдөл дээр нэгтгэсэн ансамбль хэлбэрээр системийн түвшинд туршсан эмпирик нотолгоо хязгаарлагдмал хэвээр байна.

2. Open source арилжааны системүүд (QuantConnect, Freqtrade):

QuantConnect (lean engine) болон Freqtrade зэрэг open source төслүүд нь алгоритмын арилжааны дэд бүтцийн жишээ болдог. Ялангуяа Freqtrade нь “FreqAI” модулиар дамжуулан машин сургалтын загваруудыг ашиглах боломжийг олгодог. Гэвч эдгээр системүүд нь: (1) ихэвчлэн автомат арилжаанд (bot) зориулагдсан, (2) жирийн хэрэглэгчдэд ээлтэй мобайл интерфэйсгүй байдаг. “Predictrix” нь шийдвэр гаргалтыг дэмжих (decision support system) зорилготой мобайл аппликейшний судалгааны прототип хэлбэрээр хэрэгжсэн.

apterСудалгааны арга зүй


Энэ бүлэгт судалгааны ажлын арга зүйг дэлгэрэнгүй тайлбарлана. Эхлээд судалгааны ерөнхий арга барилыг тодорхойлж, дараа нь системийн бүтэц, өгөгдлийн бэлтгэл, AI загварын архитектур, дохио үүсгэх механизм, MetaTrader 5 дээрх түүхэн өгөгдөл дээрх системийн туршилт (backtesting), серверийн болон мобайл аппликейшний хөгжүүлэлт, мөн үнэлгээний шалгуур үзүүлэлтүүдийг харна.

3.6. Судалгааны арга барил

Энэхүү судалгаа нь **дизайн шинжлэх ухаан** (design science research – DSR) [30] арга зүйд суурилсан. DSR нь бодит асуудлыг шийдвэрлэхэд чиглэсэн цоо шинэ артефакт (систем, загвар, бүтээгдэхүүн) бүтээж, түүний ашиг тусыг туршилтаар баталгаажуулдаг [31]. Энэ судалгааны хувьд DSR-ийн дараахь гурван үндсэн зарчмыг баримтлав:

1. **Артефакт бүтээх:** Санхүүгийн зах зээлийн таамаглалын үр дүн үүсгэж, мобайл аппликейшнаар дамжуулан хэрэглэгчид хүргэх систем хөгжүүлэх
2. **Асуудалд чиглэсэн:** Жижиг арилжаачдын мэдээлэл дутмаг, мэргэжлийн дүн шинжилгээний хүртээмж бага байдлыг шийдвэрлэх
3. **Туршилтаар баталгаажуулах:** MetaTrader 5 Strategy Tester-ийн бодит зах зээлийн нөхцөлд (спрэд буюу spread, гулсалт буюу slippage) түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийж, системийн ашигт ажиллагааг шинжлэх ухааны аргаар үнэлэх

Судалгааны процесс нь **давталтат хөгжүүлэлт** (iterative development) загвараар явагдсан. Үе шат бүрд загварын гүйцэтгэлийг хэмжиж, сул талыг тодорхойлон, дараагийн хувилбарт засварлах мөчлөгийг 7 удаа давтсан. Энэхүү давталтат арга барил нь нэг удаагийн шугаман хөгжүүлэлтээс ялгаатай нь системийн чанарыг алхам алхмаар сайжруулах боломжийг олгосон. Зураг 3.1 нь мөчлөгийн ерөнхий логикийг, Зураг 3.10 нь 7 үе шатны дэлгэрэнгүй өөрчлөлтийг тус тус харуулна.



Зураг 3.1 Давталтат хөгжүүлэлтийн мөчлөгийн хураангуй (7 давталт)


3.7. Системийн ерөнхий бүтэц

Зураг 3.2 нь системийн үндсэн санааг товч харуулав: санхүүгийн зах зээлийн өгөгдлийг автоматаар дүн шинжилгээ хийж, AI загвараар таамаглалын үр дүн үүсгэн, хэрэглэгчийн утасны аппликейшнд хүргэнэ.



Зураг 3.2 Системийн үндсэн ойлголт – өгөгдлөөс трейдер хүртэлх урсгал

Хөгжүүлсэн систем нь гурван үндсэн хэсгээс бүрдэнэ: (1) машин сургалтын хэсэг, (2) серверийн хэсэг (backend), (3) харагдах хэсэг (frontend). Зураг 3.3 нь энэ бүтцийг харуулав.




Зураг 3.3 Системийн гурван давхаргат бүтэц

Системийн ажиллах зарчим дараах байдалтай:

1. **Машин сургалт (machine learning)-ын давхарга:** MetaTrader 5-аас татсан 10 жилийн түүхэн өгөгдлөөр 3 GBDT загварыг сургаж, зөөлөн санал хураалт (soft voting) ансамблиар нэгтгэн итгэлцлийн (confidence) утга тооцно. Магадлалын тохируулгыг (calibration) сүлжээнээс гадуурх (offline) туршилтын ажиглалтаар шалгасан бөгөөд энэ тайлангийн ажиллах үеийн үнэлгээнд ансамблийн шууд магадлалыг ашиглана
2. **Серверийн хэсэг (backend):** Бодит цагийн мэдээллийг нэгтгэн боловсруулж, загварын дүгнэлт дээр суурилсан дохиог хадгалж, API-гаар хэрэглэгчдэд түгээнэ
3. **Харагдах хэсэг (frontend):** Серверийн хэсэг (backend)-тэй холбогдож ханш, дохио, мэдээг хэрэглэгчдэд ойлгомжтой байдлаар харуулна

3.8. Өгөгдлийн урсгал

Системд өгөгдөл хэрхэн урсаж, боловсруулагддагийг Зураг 3.4 харуулав. Гадаад эх сурвалжаас (MetaTrader 5, Yahoo Finance, TradingView, AlphaVantage) өгөгдөл орж ирэн, серверийн хэсэг (backend) дээр боловсруулагдаж, эцэст нь харагдах хэсэг (frontend)-ээр дамжин хэрэглэгчдэд хүрнэ.



Зураг 3.4 Өгөгдлийн урсгалын диаграмм (data flow diagram)

Өгөгдлийн урсгалын гол шатуудыг тайлбарлавал:

- **Өгөгдөл цуглуулах:** MetaTrader 5-аас 10 жилийн OHLCV (Нээлтийн ханш, Дээд ханш, Доод ханш, Хаалтын ханш, Эзлэхүүн), Yahoo Finance-аас бодит цагийн ханш, AlphaVantage (мэдээний уур амьсгал буюу сентимент (sentiment)) болон TradingView (эдийн засгийн хуанли (economic calendar))-аас эдийн засгийн мэдээ татна
- **Шинж чанар (feature) тооцоолох:** 6 хугацааны интервалаас (M1, M5, M15, M30, H1, H4) тус бүр 8 шинж чанар (feature) тооцоолж, нийт 48 шинж чанар (feature) үүсгэнэ
- **Таамаглал хийх:** LightGBM, XGBoost, CatBoost гурван загварын ансамбль магадлалаар дохио үүсгэнэ
- **Шүүж хадгалах:** Итгэлцэл (confidence) $\geq 90\%$, бодит дундаж хэлбэлзэл (ATR буюу Average True Range) ≥ 4.0 пипс шалгуурыг хангасан дохиог өгөгдлийн сан (MongoDB)-д хадгалж, хэрэглэгчдэд push мэдэгдэл илгээнэ
- **Хэрэглэгчид хүргэх:** Мобайл аппликейшн нь серверийн хэсэг (backend)-тэй холбогдон бүх мэдээллийг бодит цагт хүлээн авна

3.9. Өгөгдлийн бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5 платформуос EUR/USD валютын хослолын 2015–2024 оны OHLCV (open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 3.1 нь интервал бүрийн өгөгдлийн хэмжээг харуулав.

Хүснэгт 3.1 Түүхэн өгөгдлийн хэмжээний хураангуй

Интервал (timeframe)	Мөрийн тоо	Хугацаа
M1 (1 минут)	~3,700,000	2015–2024
M5 (5 минут)	~740,000	2015–2024
M15 (15 минут)	~247,000	2015–2024
M30 (30 минут)	~123,000	2015–2024
H1 (1 цаг)	~62,000	2015–2024
H4 (4 цаг)	~15,500	2015–2024

Олон цагийн интервал бүхий өгөгдлийг хослуулах замаар загвар нь зах зээлийн богино хугацааны хэлбэлзэл (M1, M5), дунд хугацааны чиг хандлага (M15, M30), мөн урт хугацааны бүтэц (H1, H4)-ыг нэгэн зэрэг харах боломжтой болсон. Энэ олон хугацааны интервалын арга нь [19] шинж чанарын инженерчлэл (feature engineering) буюу “олон хугацааны хүрээ” (multiple timeframe analysis) зарчимд нийцнэ.

Шинж чанар (feature)-ын инженерчлэл (feature engineering)

Интервал бүрээс 8 шинж чанар (feature) тооцоолж, нийт 48 шинж чанар (feature) бүхий матриц үүсгэсэн. Хүснэгт 3.2 нь шинж чанарууд (features)-ыг жагсаав.

Хүснэгт 3.2 Шинж чанар (feature)-ын жагсаалт (интервал бүрд)

№	Шинж чанар (feature)	Тайлбар
1	close	Тухайн candle-ийн хаалтын ханш
2	rsi	RSI (14 candle) — хэт худалдсан/хэт худалдан авсан байдлыг 0–100 хуваарьт хэмждэг импульс шинж чанар (feature)
3	atr	ATR (14 candle) — сүүлийн 14 candle-ийн дундаж жинхэнэ хэлбэлзэл; зах зээлийн эрсдэлийн хэмжүүр
4	ma_5	Сүүлийн 5 candle-ийн хаалтын ханшийн хөдөлгөөний дундаж (SMA) — богино хугацааны чиглэл
5	ma_20	Сүүлийн 20 candle-ийн SMA — дунд хугацааны чиглэл
6	ma_50	Сүүлийн 50 candle-ийн SMA — урт хугацааны чиглэл
7	volatility	Сүүлийн 20 candle-ийн хаалтын ханшийн стандарт хазайлт; зах зээлийн тайван эсвэл хэлбэлзэлтэй байдлын үзүүлэлт
8	returns	Өмнөх candle-тэй харьцуулсан ханшийн өөрчлөлтийн хувь (pct_change)

Энэ ажлын эхний шатанд 75 орчим боломжит шинж чанарыг туршсан боловч эцсийн загварт 48 шинж чанарын матрицыг тогтмол болгосон. Тиймээс MACD, ADX, CCI зэрэг индикаторын нэр томьёо нь судалгааны тойм болон туршилтын боломжит багцад дурдагдсан ч энэ хувилбарын эцсийн оролтын матрицад ороогүй.

Шинж чанаруудыг _1min, _5min, _15min, _30min, _1H, _4H гэсэн дагавраар ялгана. Жишээлбэл, rsi_1min нь 1 минутын RSI, atr_4H нь 4 цагийн ATR-ийг илэрхийлнэ. 1 минутын суурь өгөгдлөөс бусад интервалын шинж чанаруудыг merge_asof (backward) аргаар нэгтгэсэн.

Шошго (label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) ханшийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

$$\text{label} = \begin{cases} \text{BUY (1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (3.1)$$

Үүнд:

- Δ_{up} – ирээдүйн 240 минутын хамгийн дээд ханш ба одоогийн хаалтын ханшийн зөрүү (пипсээр)
- Δ_{down} – одоогийн хаалтын ханш ба ирээдүйн хамгийн доод ханшийн зөрүү (пипсээр)
- 30 пипс – хамгийн бага шаардлагатай хөдөлгөөн (шуугианаас ялгах)
- 1.5 дахин давамгайлал – чиг хандлагын тодорхой байдлыг шаардах

Шошго ба шинж чанарын цагийн нийцлийн аудит (leakage audit)

Шошго үүсгэх ба олон интервалын шинж чанар (feature) нэгтгэх үеийн гол шаардлага нь шийдвэрийн агшин (t_0)-д зөвхөн тухайн мөчөөс өмнө мэдэгдэх боломжтой мэдээлэл ашиглах явдал юм. Энэ нөхцөлийг дараах байдлаар тодорхойлов:

$$t_{\text{feature}} \leq t_0, \quad \text{label window} = (t_0, t_0 + 240 \text{ минут}] \quad (3.2)$$

Өөрөөр хэлбэл ирээдүйн 240 минутын мэдээлэл зөвхөн зорилтот хувьсагч (label)-т хэрэглэгдэж, шинж чанар (feature) үүсгэхэд эргэж орох ёсгүй. Хүснэгт 3.3 нь энэ ажлын leakage audit-ын шалгуур дүрмийг нэгтгэн харуулав.

Хүснэгт 3.3 *Leakage audit-ын цагийн нийцлийн дүрэм*

Компонент	Ашиглах хугацаа	Label цонхтой давхцах эсэх	Хяналтын дүрэм
M1 суурь мөр	t_0	Үгүй (зорилтот)	Тухайн мөрийн шийдвэрийн агшныг суурь болгож шошго тооцох
M5–H4 нэгтгэл	$\leq t_0$	Үгүй (зорилтот)	<code>merge_asof(backward)</code> -оор зөвхөн хамгийн ойрын өнгөрсөн мөрийг холбох
Label тооцоолол	$(t_0, t_0 + 240\text{m}]$	–	Ирээдүйн цонхыг зөвхөн зорилтот хувьсагчийн түвшинд ашиглах
Сургалт/ баталгаажуулалт/ тест зааг	зааг орчмын тусгаарлалт	Үгүй (зорилтот)	Хуваалтын зааг дээр хугацааны тусгаарлалт (embargo)-ын дүрэм мөрдөх

Тайлбар: `merge_asof(backward)` болон хугацааны тусгаарлалтын дүрэм нь leakage эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй. Иймээс үр дүнг тайлбарлахдаа энэ эрсдэлийг хязгаарлалтын хүрээнд хамтад нь авч үзсэн.


WFV-ийн олон огтлолтын алхамт логик (концепц)

Энэ судалгаанд урагш гүйлгэн баталгаажуулалт (walk-forward validation, WFV)-ыг цаг хугацааны дараалал хадгалсан **олон огтлолт, өргөтгөх сургалтын цонх** (expanding window) протоколоор хэрэгжүүлсэн. Өөрөөр хэлбэл Fold 1–Fold 5 огтлол бүрт сургалт→баталгаажуулалт→тестийн алхмыг урагшлуулан давтаж, ирээдүйн мэдээлэл сургалтад нэвтрэх эрсдэлийг хязгаарласан. Энэ бүлгийн KPI-ийн дэлгэрэнгүй тайлан нь энэхүү протоколын **Fold 5** огтлол (2015–2022 / 2023 / 2024)-д суурилсан бөгөөд Хүснэгт 3.4 тухайн огтлолын хуваалтыг нэгтгэн харуулна.

Хүснэгт 3.4 Урагш гүйлгэн баталгаажуулалтын хүрээнд ашигласан үндсэн огтлолын өгөгдлийн хуваалт

Бүлэг	Хугацаа	Candle-ын тоо	Зорилго
Сургалт	2015–2022	~2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	~371,000	Early stopping, calibration туршилтын ажиглалт (10%)
Тест	2024	~371,000	Эцсийн үнэлгээ (10%)

Зураг 3.5 нь энэхүү хуваалтыг цаг хугацааны тэнхлэг дээр дүрслэн харуулав. Сургалтын өгөгдөл (80%) баталгаажуулалтын өгөгдөл (10%) тестийн өгөгдөл (10%)-өөс цаг хугацааны дарааллаар ялгагдана.



Зураг 3.5 Урагш гүйлгэн баталгаажуулалт (WFV): энэ судалгааны үнэлгээнд ашигласан нэг огтлолын (Fold 5) өгөгдлийн хуваалт

Зураг 3.5 нь дээрх олон огтлолт протоколын хүрээнд KPI үнэлгээнд ашигласан Fold 5-ийн бодит хуваалтыг цаг хугацааны тэнхлэг дээр харуулна. Иймд Зураг 3.6-ийн олон огтлолтын концепц ба Зураг 3.5-ийн нэг огтлолын дэлгэрэнгүй тайлан нь хоорондоо зөрчилгүй, харин нэг арга зүйн хүрээний **ерөнхий логик** ба **үнэлгээний фокус** гэсэн хоёр түвшний дүрслэл болно.

WFV-ийн олон огтлолтын ерөнхий алхамт логик нь:

1. Эхний хугацааны огтлолд өмнөх жилүүдээр загвар сургана
2. Дараагийн хугацааны огтлолд баталгаажуулалт/шалгалт (early stopping, calibration) хийнэ
3. Дараагийн огтлол руу шилжихдээ сургалтын цонхыг урагшлуулж дахин сургана
4. Эцсийн үнэлгээнд сүүлийн огтлолын түүврийн гадуурх (out-of-sample) гүйцэтгэлийг ашиглана



Зураг 3.6 Урагш гүйлгэн баталгаажуулалтын (WFV) олон огтлолтын концепцын схем

Тайлбар: Зураг 3.6 нь Fold 1–Fold 5 протоколыг **нэг зурагт** жилээр нь харуулсан: бүх Fold-ийн сургалт 2015-аас эхэлж, Fold өсөх тусам сургалтын цонх өргөжин, баталгаажуулалт ба тестийн цонх урагш шилжинэ. Харин Зураг 3.5 нь энэ протоколоос үнэлгээнд сонгосон Fold 5 огтлолын бодит хуваалтыг дэлгэрэнгүй харуулна.


3.10. AI загварын бүтэц ба сургалт

Ансамбль загварын архитектур

Системийн загвар нь гурван GBDT (gradient boosted decision trees) загвараас бүрдэх soft-voting ансамбль юм. GBDT нь олон модны нэгтгэсэн загвар бөгөөд санхүүгийн хүснэгтэн өгөгдөлтэй сайн нийцдэг [2]. Загвар бүр ижил 48 шинж чанарыг хүлээн авч BUY, SELL, HOLD гурван ангиллын магадлалыг тус тус тооцоолно. Эдгээр магадлалыг дундажилж эцсийн итгэлцлийг үүсгэнэ. Logistic Regression-д суурилсан магадлалын тохируулгыг сургалтын үеийн баталгаажуулалтын огтлол дээр туршилтын ажиглалтаар шалгахад зарим нөхцөлд магадлалын тархалт хэт төвлөрөх шинж ажиглагдсан. Иймээс энэ тайлангийн ажиллах үеийн дүнг тохируулга хэрэглээгүй ансамблийн шууд магадлалаар тайлагнав. Calibration-ийн үр дүнг production хэрэглээ гэж бус, туршилтын ажиглалт гэж тайлбарлав. Зураг 3.7 нь энэхүү бүтцийг харуулав.

Ансамблийн жинг $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ гэж тэгш авсан шалтгаан нь хоёр талтай. Нэгдүгээрт, LightGBM/XGBoost/CatBoost нь суралцах хандлагын хувьд ялгаатай тул нэг загварт жинг хэт төвлөрүүлэхээс сэргийлсэн. Хоёрдугаарт, нэг баталгаажуулалтын огтлолын дүн дээр жинг тусад нь оновчлох нь data-snooping эрсдэл нэмэгдүүлэх тул энэ хувилбарт тогтвортой, дахин хэрэгжүүлэхэд энгийн тэгш жингийн бодлогыг баримталсан.

Энд нэг чухал ялгаа бий: **загварын ангиллын гаралт** нь BUY/SELL/HOLD (3 ангилал), харин **гүйцэтгэлийн түвшний хэрэгжих үйлдэл** нь BUY эсвэл SELL (2 үйлдэл) юм. HOLD ангилал сонгогдсон үед систем шинэ байрлал нээхгүй, өөрөөр хэлбэл “үйлдэлгүй төлөв” (no-trade state) гэж үзнэ.



Зураг 3.7 GBDT ансамбль загварын архитектур

Гурван загварыг ансамбль хэлбэрээр хослуулсан шалтгаан нь тус бүр нь өөр өөр давуу талтай:

- **LightGBM:** Leaf-wise (навч чиглэлтэй) модны өсөлт ашигладаг тул сургалтын хурд маш өндөр. Их хэмжээний өгөгдөлд тохиромжтой
- **XGBoost:** Level-wise (түвшин чиглэлтэй) модны өсөлт болон L1/L2 нормчлолоор тогтвортой гүйцэтгэл үзүүлдэг. Тохируулах параметрийн уян хатан байдал өндөр
- **CatBoost:** Symmetric (тэгш хэмт) модны бүтэц, ordered boosting ашиглан хэт нийцэл (overfitting)-аас хамгийн сайн хамгаалагддаг

Гиперпараметр сонголтын протокол

Гиперпараметрийг “хамгийн өндөр ганц үзүүлэлт” дагуу хайх бус, тогтвортой байдлын протоколоор сонгосон. Үндсэн алхмууд нь: (1) өндөр багтаамжтай суурь тохиргооноос эхлэх, (2) модны гүн ба навчийн тоог бууруулах, (3) subsample/colsample болон L1/L2 тогтмолжуулалт нэмэх, (4) 2023 оны баталгаажуулалтын огтлол дээр early stopping-оор хэт сургалтыг зогсоох. Сонголтын шалгуур нь train-val зөрүүг хянах, өндөр итгэлцлийн дэд мужийн чанарыг хадгалах, мөн ажиллах үеийн итгэлцлийн тархалтыг тогтвортой байлгах явдал байсан.

Энэ хувилбарт ансамбль сургалтыг нэг эхлүүлэх утга (single-seed protocol)-тай явуулсан нь туршилтын хэмжээсийг хэт томруулахгүйгээр давтан хэрэгжих чадварыг сайжруулах зорилготой. Олон seed-ийн дундажтай тайланг дараагийн шатны баталгаажуулалтын ажилд үлдээсэн.

Хүснэгт 3.5 нь загвар бүрийн гол гиперпараметрүүдийг харуулав.

Хүснэгт 3.5 Загвар бүрийн гол гиперпараметрууд

Параметр	LightGBM	XGBoost	CatBoost
Модны тоо (n_estimators)	496	~400	499
Хамгийн их гүн (max_depth)	6	5	5
Сургалтын хурд (learning_rate)	0.03	0.03	0.03
L1 нормчлол (reg_alpha)	Тийм	Тийм	—
L2 нормчлол (reg_lambda)	Тийм	Тийм	Тийм
Early stopping (patience)	50 давталт	50 давталт	50 давталт
Модны өсөлтийн арга	Leaf-wise	Level-wise	Symmetric

Хэт нийцэл (overfitting)-аас сэргийлэх арга хэмжээ

Санхүүгийн загварт хэт нийцэл (overfitting) нь хамгийн чухал сорилт юм. Сургалтын өгөгдлийг хэт сайн цээжлэх нь шинэ өгөгдөл дээр гүйцэтгэл буурахад хүргэдэг. Үүнээс сэргийлэх дараахь арга хэмжээнүүдийг авсан:

1. **Модны гүнийг хязгаарлах** (max_depth=5 - -6): Гүн бага мод нь ерөнхийлөн суралцах чадвартай тул шинэ өгөгдөл дээр илүү тогтвортой ажилладаг
2. **Сургалтын хурдыг бага тогтоох** (learning_rate=0.03): Загварыг удаан боловч илүү нарийвчлалтай сургах. Алхам бүрд бага зэргийн өөрчлөлт хийдэг
3. **Early stopping**: Баталгаажуулалтын алдаа 50 давталт дотор сайжрахгүй бол сургалтыг зогсоох
4. **L1/L2 нормчлол**: Загварын жингүүдийг хэт их болгохоос сэргийлж, ерөнхийлөн суралцах чадварыг нэмэгдүүлэх
5. **Урагш гүйлгэн баталгаажуулалт (walk-forward validation)**: Цаг хугацааны дарааллыг хадгалж, ирээдүйн өгөгдөл сургалтад нэвтрэхээс сэргийлэх
6. **Шинж чанар (feature) хялбаржуулалт**: Анхны 75 шинж чанар (feature)-аас 48 болгож бууруулсан. Хэт олон шинж чанар (feature) нь загварыг шуугианд суралцуулах эрсдэлтэй

Сургалтын алгоритм

Энэ судалгаанд ансамбль загварын сургалтыг хугацааны дараалал хадгалсан тогтмол протоколоор хэрэгжүүлсэн. Протоколын зорилго нь өгөгдөл хуваах ба шинж чанар бэлтгэх алхмыг тогтмолжуулах, суурь загваруудыг ижил нөхцөлд сургах, магадлалуудыг тэгш жингээр нэгтгэх, мөн тохируулга ба тестийн үнэлгээг нэг мөрөөр тодорхойлох явдал юм.

Тэмдэглэгээ: D нь цагийн дараалалтай өгөгдөл, $\mathcal{B} = \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$ нь суурь загварын багц, $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ нь ансамблийн жин, $p = 50$ нь early stopping-ийн patience параметр болно.

Ансамбль загварын сургалтын протокол

Оролт: Цагийн дараалалтай өгөгдөл D , суурь загварын багц $\mathcal{B}$, жин w , эрт зогсоолтын параметр p

Гаралт: Ансамбль $\mathcal{M} = \{M_1, M_2, M_3\}$, тохируулгын загвар C , тестийн үнэлгээ acc_{test}
 $\mathcal{B} \leftarrow \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$
 $w \leftarrow (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$

I. Цаг хугацааны хуваалт ба шинж чанар бэлтгэх

$(D_{\text{train}}, D_{\text{val}}, D_{\text{test}}) \leftarrow \text{TimeSplit}(D)$
 $(X_{\text{train}}, X_{\text{val}}, X_{\text{test}}) \leftarrow \text{BuildFeatures}(D_{\text{train}}, D_{\text{val}}, D_{\text{test}})$
 $(y_{\text{train}}, y_{\text{val}}, y_{\text{test}}) \leftarrow \text{ExtractLabels}(D_{\text{train}}, D_{\text{val}}, D_{\text{test}})$

II. Суурь загвар сургах

for суурь загвар $b_k \in \mathcal{B}$ **do**
 $M_k \leftarrow \text{Train}(b_k, X_{\text{train}}, y_{\text{train}}, X_{\text{val}}, y_{\text{val}}, p)$
end for

III. Ансамбль магадлал нэгтгэх

for $k = 1, 2, 3$ **do**
 $P_{\text{val}}^{(k)} \leftarrow M_k.\text{predict_proba}(X_{\text{val}})$
 $P_{\text{test}}^{(k)} \leftarrow M_k.\text{predict_proba}(X_{\text{test}})$
end for
 $\bar{P}_{\text{val}} \leftarrow \sum_{k=1}^3 w_k P_{\text{val}}^{(k)}$
 $\bar{P}_{\text{test}} \leftarrow \sum_{k=1}^3 w_k P_{\text{test}}^{(k)}$

IV. Тохируулга ба үнэлгээ

$C \leftarrow \text{FitCalibrator}(\bar{P}_{\text{val}}, y_{\text{val}})$
 $(\text{score}_{\text{raw}}, \text{score}_{\text{cal}}) \leftarrow \text{CompareCalibration}(\bar{P}_{\text{val}}, C(\bar{P}_{\text{val}}), y_{\text{val}})$
 $\text{acc}_{\text{test}} \leftarrow \text{accuracy}(\bar{P}_{\text{test}}, y_{\text{test}})$
 Ажиллах үеийн шийдвэрт ансамблийн шууд магадлал $\hat{P}$ -оос $c = \max(\hat{P})$ итгэлцлийг тооцно
return $\mathcal{M}, w, C, \text{score}_{\text{raw}}, \text{score}_{\text{cal}}, \text{acc}_{\text{test}}$

Тайлбар: Энэ хувилбарт тохируулгын загвар (C)-ыг сүлжээнээс гадуурх үнэлгээнд ашиглаж, ажиллах орчинд ансамблийн шууд магадлалыг хэрэглэсэн.


3.11. Дохио үүсгэх систем

Дохионы шүүлтүүр

Загварын таамгаас чанартай дохиог ялгахын тулд хоёр шүүлтүүр ашигласан. HOLD ангилал нь энэ шатанд BUY/SELL мэт “дохио” биш, харин арилжаанд орохгүй гэсэн төлөв тул хэрэгжих захиалгын урсгалд орохгүй:

- **Итгэлцлийн босго:** Ансамблийн итгэлцэл (confidence) ≥ 0.90 . Загвар 90%-аас дээш итгэлтэй тохиолдолд л дохио үүсгэнэ
- **ATR шүүлтүүр:** $\text{ATR} \geq 4.0$ пипс. Зах зээлд хангалттай хэлбэлзэл байх үед л дохио өгнө (бага хэлбэлзэлтэй үед арилжаа хийх нь ашиггүй)

2025 оны өгөгдөл дээрх анхны 359,639 таамгаас итгэлцэл (confidence) $\geq 90\%$ босгонд 3,567 нь (1.0%) эдгээр шалгуурыг хангасан. Зураг 3.8 нь энэхүү шүүлтүүрийн процессыг юүлүүр диаграммаар харуулав.



Зураг 3.8 Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио

Stop Loss ба Take Profit тооцоолол

SL/TP-г ATR (average true range) дээр суурилан динамикаар тооцоолсон:

$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (3.3)$$


$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (3.4)$$

Энэ аргын давуу тал нь зах зээлийн хэлбэлзэлд тохируулан SL/TP-г динамикаар тогтоодог. Хэлбэлзэл их байхад SL/TP өргөн, бага байхад нарийн болно. Гол параметрууд:

- SL-ийн ATR үржвэр: 5.0 – зах зээлийн шуугиан, спрэдийг тооцоолсон
- TP/SL харьцаа: 3:1 – 33% нарийвчлалтай ч ашигтай байх боломжтой эрсдэл-өгөөжийн харьцаа
- Хамгийн бага SL: 15 пипс – хэт бага SL нь шуугиан дээр зогсох эрсдэлтэй
- Хамгийн бага TP: 45 пипс – утга бүхий ашгийг баталгаажуулах

Дохио үүсгэх дарааллын диаграмм

Зураг 3.9 нь серверийн хэсэг автоматаар дохио үүсгэх бүрэн дарааллыг харуулав.



Зураг 3.9 Дохио үүсгэх дарааллын диаграмм (sequence diagram)

Дарааллын диаграммаас харахад, дохио үүсгэх процесс дараах дарааллаар явагдана:

1. Scheduler минут бүр автоматаар серверийн тооцооллын мөчлөгийг ажиллуулна
2. Сервер нь гадаад эх сурвалжаас 6 интервалын (M1, M5, M15, M30, H1, H4) OHLCV өгөгдлийг татна
3. Татсан өгөгдлөөс 6 интервалын 48 шинж чанарыг тооцоолно
4. GBDT ансамбль загвараар BUY/SELL/HOLD гурван ангиллын магадлалыг тооцоолно
5. HOLD ангилал гарвал шинэ байрлал нээхгүй; BUY/SELL ангилалд итгэлцэл ($\geq 90\%$) болон ATR (≥ 4 пипс) шүүлтүүрийг давсан тохиолдолд л хэрэгжих дохио үүснэ
6. Динамик SL/TP-г ATR дээр суурилан тооцоолно
7. Дохиог өгөгдлийн санд хадгалж, мобайл апп руу мэдэгдэл илгээнэ
8. Мобайл апп хүсэлтээр дохионы мэдээллийг авч хэрэглэгчид харуулна

Дохионы эх үүсвэрийн бүрэн бүтэн байдал ба leakage-ээс сэргийлэлт

Энэ судалгаанд leakage (өгөгдөл/шийдвэрийн нэвчилт) гэдгийг ирээдүйн мэдээлэл сургалт, үнэлгээ рүү санамсаргүй орох эсвэл гадаад гараар оруулсан дохио автомат урсгалтай холилдох эрсдэл

гэж тодорхойлов. Иймээс үнэлгээний багцад зөвхөн автомат pipeline-аар үүссэн дохиог хамруулж, гараар үүсгэсэн болон хувийн туршилтын дохиог үнэлгээний өгөгдлөөс тусгаарласан.

Мөн дохио бүрт эх үүсвэрийн мөр (provenance trace) хадгалж, ямар загварын хувилбар, ямар хугацааны огноо-цагийн цонхоос үүссэнийг индексжүүлэн шалгах боломжтой болгосон. Ингэснээр үр дүнг дахин тооцоход адил гаралт авах нөхцөл хангагдаж, аудитын үед дохионы гарал үүслийг буцаан шалгах боломж бүрдсэн.

Энэ бичвэрт хэрэгжилтийг арга зүйн түвшинд абстракцлан, шалгуур логик болон нэгтгэсэн үзүүлэлтүүдийг системтэй нэгтгэн тайлбарласан.

3.12. MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт (backtesting)

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн логик

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлд эрсдэлийн удирдлагатай гүйцэтгэгч модуль ашиглаж, дохио бүр дээр байрлалын хэмжээ, итгэлцлийн босго, гулсалтын хязгаар зэрэг дүрмийг тогтмол мөрдсөн. Хүснэгт 3.6 нь энэ хэсгийн үндсэн тохиргоог харуулав.

Хүснэгт 3.6 Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо

Параметр	Утга	Тайлбар
Арилжаа бүрийн эрсдэл	1.0%	Нэг дохион дээр авах эрсдэлийн хувь
Нэг удаагийн байрлалын дээд тоо	1	Давхар байрлал нээхээс сэргийлсэн
Итгэлцлийн доод босго	0.90	Чанарын шүүлтүүрийн үндсэн босго
Зөвшөөрөгдөх гулсалтын хязгаар	10 point	Гүйцэтгэлийн бодит нөхцөлийг тусгасан

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) нөхцөл

- **Платформ:** MetaTrader 5 Strategy Tester
- **Горим:** Every tick (бүх тикийн өгөгдөл – бодит нөхцөлд ойролцоо гүйцэтгэлийн горим)
- **ЕА тестийн цонх:** 2025.01.01 – 2026.01.01
- **Анхны хөрөнгө:** \$10,000
- **Хэрэгсэл:** EUR/USD (бодит спрэд)
- **Суурь дохионы багц:** 0.90 итгэлцлийн шүүлтүүртэй суурь багц (3,567 дохио)
- **Нэмэлт босгын багцууд:** 0.91–0.99 мужийн урьдчилан шүүсэн дохионы багцууд; ЕА талын ажиллах үеийн итгэлцлийн босго 0.90 дээр тогтмол байсан бөгөөд ялгаа нь оролтын шүүлтүүрээс үүссэн
- **Дохио/өдөр үзүүлэлт:** backtest цонхны Даваа–Баасан арилжааны өдрийн тоо (261 өдөр)-д суурилан тооцсон

Арилжааны зардлын хамралтын матриц

Энэ судалгаанд зардлын загварчлалын хамрах хүрээг Хүснэгт 3.7-д нэгтгэв. CS чиглэлийн уншигчдад ойлгомжтойгоор тайлбарлавал spread нь худалдан авах ба зарах үнийн зөрүү, slippage нь төлөвлөсөн үнэ ба бодит биелсэн үнийн зөрүү, swap нь байрлал шөнө хадгалах санхүүжилтийн зардал юм.

Хүснэгт 3.7 Арилжааны зардлын хамралтын матриц

Зардлын бүрэлдэхүүн	Статус	Энэ ажлын хэрэгжүүлэлт	Тайлбарын нөлөө
Spread	Тийм	MT5-ийн бодит spread орчинд тооцсон	Бодит нөхцөлд ойртуулна
Slippage	Тийм	10 point дээд хязгаар ашигласан	Гүйцэтгэлийн тодорхой бус байдлыг хэсэгчлэн тусгана
Commission	Үгүй	Брокер тус бүрийн шимтгэлийг sweep тайланд тусгаагүй	Өгөөжийг хэт өөдрөг харагдуулах эрсдэлтэй
Swap	Үгүй	Шөнийн санхүүжилтийн зардлыг тусгаагүй	Удаан хадгалсан байрлалын цэвэр үр дүнг зөрүүлэх эрсдэлтэй

Иймд энэ бүлэгт нэгтгэн харуулсан өгөөжийн дүнг бүх зардал бүрэн шингэсэн эцсийн ашиг гэж бус, сценарийн түвшний харьцуулалтын үр дүн гэж тайлбарлав.

Босго сонголтын протокол ба data-snooping эрсдэлийн хяналт

Босгын мужийн хүснэгт нь **сценарийн харьцуулалт** бөгөөд ажиллах үеийн динамик босго тааруулалт биш юм. Өөрөөр хэлбэл энэ ажилд EA талын босго 0.90 дээр тогтмол байсан ба шинжилгээ нь урьдчилан шүүсэн дохионы багцуудын үр дүнг харьцуулсан тайлангийн алхам болно.

Data-snooping эрсдэлийг бууруулахын тулд босго сонголтыг дараах зарчмаар тайлбарлав:

1. **Selection phase:** ижил журамтай сонголтын цонх дээр кандидат босгуудын харьцуулалт хийх
2. **Freeze:** сонгосон бодлогын мужийг (жишээ нь 0.90–0.92) тогтмолжуулах
3. **Confirmation:** дараагийн хугацааны цонхонд өөрчлөлтгүй баталгаажуулах

Иймд 0.91 босго нь энэ шинжилгээний хүрээнд ажиглагдсан локал дээд цэг гэж тайлбарлагдах бөгөөд бүх нөхцөлд универсал оновчтой утга гэж дүгнэхгүй. Мөн энэ хувилбарт confirmation шатны тусдаа хугацааны цонхны дүнг бүрэн тусгаагүй тул босгоны дүгнэлтийг нөхцөлт хүрээнд авч үзсэн.

Үнэлгээний шалгуур үзүүлэлтүүд

Загварын болон системийн гүйцэтгэлийг дараах шалгуур үзүүлэлтүүдээр үнэлсэн. Хүснэгт 3.8 нь тэдгээрийн тодорхойлолт болон чиглэлийг харуулав.

Хүснэгт 3.8 Системийн үнэлгээний шалгуур үзүүлэлтүүд

Үзүүлэлт	Тодорхойлолт	Үнэлгээний чиглэл
<i>Загварын ангиллын чанарын үзүүлэлтүүд (энэ ажлын үнэлгээний хүрээнд)</i>		
Тестийн нарийвчлал (accuracy)	2024 оны тест хуваалтын зөв ангиллын хувь	Өндөр байх тусам сайн
Өндөр итгэлцэлтэй дохионы нарийвчлал	Итгэлцэл өндөр муж дахь зөв ангиллын хувь	Өндөр байх тусам сайн
<i>Босгын мужийн сценарийн системийн үзүүлэлтүүд (Chapter 4-т нэгтгэн харуулсан)</i>		
Эцсийн баланс (\$)	Сценари бүрийн туршилтын эцсийн хөрөнгө	Өндөр байх тусам сайн
Цэвэр ашиг (\$)	Эцсийн баланс – анхны хөрөнгө (\$10,000)	Өндөр байх тусам сайн
Өгөөж (%)	$\frac{\text{Final Balance} - 10,000}{10,000} \times 100$	Өндөр байх тусам сайн
Дохио/өдөр	Нийт дохиог backtest цонхны Даваа–Баасан арилжааны өдрийн тоонд (261) харьцуулсан давтамж	Хэрэглээний ачааллаас хамаарна
Дохио тутмын ашиг (\$)	Нэг дохионд ногдох дундаж ашиг	Өндөр байх тусам сайн
Гүйцэтгэлийн хувь (execution rate)	Шүүгдсэн дохионоос бодитоор нээгдэж хаагдсан арилжааны хувь	Контекстээс хамаарна
Ялалтын хувь (win rate)	Хаагдсан арилжаан дахь TP эзлэх хувь	Өндөр байх тусам сайн
Ялалтын хувь 95% CI	Wilson аргаар тооцсон итгэлцлийн интервал	Нарийн байх тусам тодорхой
Expectancy (R)	TP/SL=3:1 нөхцөлд нэг арилжаанд хүлээгдэх нормчилсон өгөөж	0-ээс их байх тусам сайн
Сценарийн хэлбэлзэл (balance CV)	Босгуудад харгалзах эцсийн балансын тархалтын хэлбэлзэл (std/mean)	Бага байх тусам тогтвортой
Max drawdown (MaxDD)	Оргил балансаас хамгийн их уналтын хувь	Бага байх тусам сайн
Sharpe	Өдөр тутмын өгөөжийн эрсдэлд нормчилсон өгөөж	Өндөр байх тусам сайн
Sortino	Зөвхөн сөрөг хэлбэлзлээр нормчилсон өгөөж	Өндөр байх тусам сайн
Calmar	Жилийн дүнгээр тооцсон өгөөжийг MaxDD-д харьцуулсан үзүүлэлт	Өндөр байх тусам сайн
Max losing streak	Хамгийн урт дараалсан алдагдлын үзүүлэлт	Бага байх тусам тэсвэртэй

Энэ судалгаанд ангиллын чанарыг тестийн нарийвчлал болон өндөр итгэлцэлтэй дохионы нарийвчлалаар, системийн үр ашгийг босгын мужийн балансын нэгтгэсэн үзүүлэлтүүдээр үнэлсэн. Нэмэлтээр дохио-арилжааны хөрвүүлэлтийн чанарыг хэрэгжилтийн хувь, ялалтын хувь, ялалтын хувийн 95% интервал, Expectancy (R), сценарийн түвшний balance CV, мөн

MaxDD/Sharpe/Sortino/Calmar/хамгийн урт алдагдлын дарааллын эрсдэлийн шинжилгээтэй хамтатган нэгтгэн харуулав. Санхүүгийн туршилтад дохио/өдөр зэрэг давтамжийн үзүүлэлт нь backtest цонхны Даваа–Баасан арилжааны өдрийн тооноос (261) хамаарах тул түүний тооцооллын суурийг Хүснэгт 4.2-ийн доор ил тод тайлбарласан.

TP/SL=3:1 нөхцөлд Expectancy-г дараах байдлаар тодорхойлно:

$$E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}}) \quad (3.5)$$

энд p_{win} нь ялалтын хувь юм. $E[R] > 0$ бол нормчилсон эрсдэл-өгөөжийн хувьд статистикийн давуу талтай, $E[R] \leq 0$ бол тухайн босгоны бодлого хангалтгүйг илэрхийлнэ.

3.13. Серверийн хэсгийн хэрэгжүүлэлт

Архитектурын үндсэн бүрэлдэхүүн

Серверийн хэсэг нь бодит цагийн мэдээлэл боловсруулах, дохио үүсгэх, хэрэглэгчийн хүсэлтийг боловсруулах, болон мобайл аппликейшнтэй өгөгдөл солилцох үүргийг гүйцэтгэнэ. Хүснэгт 3.9 хүснэгтэд энэ давхаргын үндсэн бүрэлдэхүүнийг нэгтгэв.

Хүснэгт 3.9 Серверийн хэсгийн үндсэн бүрэлдэхүүн

Бүрэлдэхүүн	Үүрэг
API давхарга	Харагдах хэсэг (frontend)-ээс ирсэн хүсэлтийг хүлээн авч, өгөгдлийг API хариу хэлбэрээр дамжуулах
Өгөгдөл хадгалалтын давхарга	Дохио, хэрэглэгчийн мэдээлэл, статистикийг найдвартай хадгалах
Нэвтрэлт ба эрхийн удирдлага	Хэрэглэгчийн нэвтрэлтийн аюулгүй байдал, хандалтын эрхийн хяналтыг хангах
Мэдэгдэл түгээлтийн систем	Дохио болон чухал үйл явдлын мэдээллийг хэрэглэгчид шуурхай хүргэх

Deployment архитектур ба ажиллуулах орчин

Судалгааны прототипийг контейнерт суурилсан орчноор ажиллуулах боломжтойгоор зохион байгуулсан. Архитектурын түвшинд API үйлчилгээ болон арын ажлыг тусад нь process болгон салгаж, нэг орчинд (PaaS) бие даан скейл хийх боломж үлдээсэн. Ингэснээр хэрэглэгчийн хүсэлтийн урсгал (API) ба хугацаат тооцооллын урсгал (worker)-ыг ачааллаар нь тусгаарлан тогтвортой байдлыг нэмэгдүүлдэг.

Хүснэгт 3.10 *Deployment топологийн хураангуй*

Давхарга	Хэрэгжүүлэлт	Үүрэг
Контейнер орчин	Docker-д суурилсан ажиллах орчин	API ба worker процессийг ижил суурь image дээр тогтвортой ажиллуулах
API процесс	HTTP үйлчилгээ	Нэвтрэлт, дохио, ханш, тайлангийн endpoint-уудыг харагдах хэсэг (frontend)-д хүргэх
Worker процесс	Арын төлөвлөгч/worker	Төлөвлөгөөт шинэчлэлт, дохио тооцоолол, мэдэгдлийн урсгалыг тасралтгүй ажиллуулах
Cloud орчин	PaaS байршуулалт	Орчны хувьсагч, process scaling, health-check дээр суурилсан ажиллагаа

Системийн модулийн бүлгүүд

Серверийн хэсгийн бүтцийг судалгааны зорилготой уялдуулан дараах үндсэн бүлгүүдэд зохион байгуулсан.

Хүснэгт 3.11 *Серверийн хэсгийн функцийн бүлгүүд*

Бүлэг	Тайлбар
Нэвтрэлт ба хэрэглэгч	Бүртгэл, нэвтрэлт, профайл шинэчлэлт, нууц үгийн удирдлага
Ханшийн мэдээлэл	Бодит цагийн ханш болон сонгосон хослолын мэдээлэл авах
Дохионы мэдээлэл	Одоогийн болон түүхэн дохио, гүйцэтгэлийн статистик боловсруулах
Мэдээ, шинжилгээ	Эдийн засгийн мэдээ болон тайлбар шинжилгээ хүргэх
Мэдэгдэл	Push болон апп доторх мэдэгдлийн тохиргоо, төлөвийн удирдлага

Нэвтрэлтийн аюулгүй байдал ба тогтвортой ажиллагаа

Системийн нэвтрэлтийн хэсэгт богино наст токен ба сессийн баталгаажуулалт ашигласнаар буруу орчноос хандалт хийх, хугацаа хэтэрсэн сесс дахин ашиглагдах эрсдэлийг бууруулсан. Мөн серверийн тасралтгүй ажиллагааг хангахын тулд арын ажлуудын (background jobs) давхардлыг хянах, алдаа гарсан үед сэргээн оролдох бодлого хэрэгжүүлсэн.

Серверийн арын ажлууд

Серверийн хэсэг нь хэрэглэгчийн хүсэлт боловсруулахаас гадна төлөвлөгөөт арын ажлаар дараах үндсэн ажлуудыг тогтмол гүйцэтгэнэ:

1. Эдийн засгийн мэдээ болон үйл явдлын мэдээллийг шинэчлэх
2. Өндөр нөлөөтэй үйл явдлын талаар хэрэглэгчдэд мэдэгдэл хүргэх
3. Бодит ханш дээр суурилан автомат дохио үүсгэх
4. Серверийн эхлэлд шаардлагатай өгөгдлийг урьдчилан ачаалж гүйцэтгэлийг тогтворжуулах

Бодит цагийн ханшийн мэдээлэл

Систем нь гол валютын хослолуудын бодит ханшийг тогтмол шинэчилж, кэшийн механизмаар давтамжтай хүсэлтийн ачааллыг бууруулан ажилладаг. Энэ нь мобайл талд мэдээлэл тасалдахгүй хүрэх нөхцөлийг бүрдүүлдэг.


3.14. Мобайл давхаргын архитектурын хураангуй

Харагдах хэсэг (frontend)-ийн зорилго нь серверийн хэсгээс ирэх ханш, дохио, мэдээ, мэдэгдлийг нэгтгэн хэрэглэгчид тасралтгүй хүргэхэд оршино. Энэ судалгаанд мобайл давхаргыг гурван түвшний архитектураар тайлбарлав: (i) нэвтрэлт ба сессийн удирдлага, (ii) өгөгдөл харуулах үндсэн модуль (ханш/дохио/мэдээ), (iii) сервертэй синхрончлол ба алдааны сэргээн оролт.

Ийм зохион байгуулалт нь мобайл хэсгийг технологийн хувилбарын жагсаалтаас илүү системийн интеграцийн үр нөлөөгөөр үнэлэх боломж олгов. Технологийн нарийвчилсан тохиргоо, дэлгэцийн микро-урсгал, диаграммын дэлгэрэнгүйг хавсралтад авч үзнэ.

3.15. Загварын давталтат сайжруулалт

DSR арга зүйн дагуу загварын хөгжүүлэлтийг 7 давталтат (iterative) үе шатаар явуулсан. Үе шат бүрт “бүтээх → үнэлэх → сайжруулах” мөчлөгийг давтаж, өмнөх хувилбарын түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үр дүнд тулгуурлан сул талыг зассан. Зураг 3.10 нь энэ давталтат урсгал болон үе шат бүрийн гол өөрчлөлтийг нэгтгэн харуулав.



Зураг 3.10 Загварын давталтат сайжруулалтын үе шатууд ба гол өөрчлөлтүүд

4. Судалгааны үр дүн, дүгнэлт

4.1. Үр дүнгийн өгөгдлийн эх сурвалж

Энэ бүлгийн бүх тоон дүнг түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) логоудаас гаргав.

- MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) 10 гүйлтийн лог (0.90–0.99 босго)
- Логийн Loaded signals, final balance, Trades/Trade мөрүүдээс шууд тооцсон агрегат үзүүлэлтүүд

Лог файлууд нь хуримтлагдсан (append) бүтэцтэй тул өмнөх гүйлтийн мөрүүд дараагийн файлд давтагддаг. Иймээс босго бүрийн run-ыг Loaded signals мөрөөр таньж, тухайн run-т харгалзах final balance болон TP/SL мөрүүдтэй тогтмол дүрмээр хослуулан нэгтгэл хийв. Энэ дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах нөхцөлийг хангана.

Max drawdown, Sharpe, Sortino, Calmar, хамгийн урт дараалсан алдагдлын тоо зэрэг эрсдэлийн үзүүлэлтүүдийг мөн ижил логийн Trade/Trades мөрөөс, ижил нэгтгэлийн дүрмээр тооцсон.

Эх сурвалжийн индексжүүлсэн баталгаа

Хүснэгт 4.1 Босго тус бүрийн нотолгооны индексжүүлсэн холболт

Босго	Дохио индекс	Баланс индекс	Дохионы тоо	Эцсийн баланс (\$)
0.90	SIG-090	BAL-090	3,567	58,262.39
0.91	SIG-091	BAL-091	3,274	61,770.46
0.92	SIG-092	BAL-092	2,958	56,512.20
0.93	SIG-093	BAL-093	2,643	46,807.24
0.94	SIG-094	BAL-094	2,287	38,050.13
0.95	SIG-095	BAL-095	1,914	32,844.40
0.96	SIG-096	BAL-096	1,588	33,040.14
0.97	SIG-097	BAL-097	1,195	29,019.19
0.98	SIG-098	BAL-098	673	25,447.43
0.99	SIG-099	BAL-099	147	17,428.89

Тайлбар: Индексжүүлэлт нь нэгтгэлийн мөр-эх сурвалжийн холболтыг тогтвортой хадгалах зорилготой.

Бүх туршилтанд ЕА-ийн итгэлцлийн босго 0.90 дээр тогтмол байсан. 0.90–0.99 мужийн шинжилгээ нь урьдчилан шүүсэн дохионы багцуудын сценарийн харьцуулалт юм. Харагдах хэсэг (frontend)-д хэрэглэгч босгыг 0.90–0.99 мужид сонгох боломжтой.

4.2. Босгын мужийн нэгтгэсэн үр дүн

Өгөөжийг дараах томъёогоор тооцсон:

$$\text{Return(\%)} = \frac{\text{Final Balance} - 10,000}{10,000} \times 100 \quad (4.1)$$

Хүснэгт 4.2 хүснэгтэд босго өсөхөд дохионы тоо, эцсийн баланс хэрхэн өөрчлөгдсөнийг харуулав.

Хүснэгт 4.2 0.90–0.99 босгын мужийн харьцуулсан шинжилгээний баталгаажсан дүн

Босго	Нийт дохио	Дохио/өдөр	Эцсийн баланс (\$)	Цэвэр ашиг (\$)	Өгөөж (%)	Нэг дохионы ашиг (\$)
0.90	3,567	13.67	58,262.39	48,262.39	482.62	13.53
0.91	3,274	12.54	61,770.46	51,770.46	517.70	15.81
0.92	2,958	11.33	56,512.20	46,512.20	465.12	15.72
0.93	2,643	10.13	46,807.24	36,807.24	368.07	13.93
0.94	2,287	8.76	38,050.13	28,050.13	280.50	12.27
0.95	1,914	7.33	32,844.40	22,844.40	228.44	11.94
0.96	1,588	6.08	33,040.14	23,040.14	230.40	14.51
0.97	1,195	4.58	29,019.19	19,019.19	190.19	15.92
0.98	673	2.58	25,447.43	15,447.43	154.47	22.95
0.99	147	0.56	17,428.89	7,428.89	74.29	50.54

Тайлбар: Дохио/өдөр үзүүлэлтийг Нийт дохио/261 томъёогоор тооцсон (261 нь backtest-ын арилжааны өдрийн тоо). Спред ба гулсалтыг тусгасан боловч шимтгэл, свопыг хамруулаагүй тул өгөөжийн дүнг сценариудын харьцуулалтын үр дүн гэж үзнэ.

Суурь benchmark: EUR/USD buy-and-hold

Сценарийн дүнг зах зээлийн ерөнхий хөдөлгөөнтэй харьцуулахын тулд EUR/USD-ийн close-to-close buy-and-hold жишгийг тооцоов.

Хүснэгт 4.3 EUR/USD buy-and-hold benchmark-ийн хураангуй

Үзүүлэлт	Утга
Эхлэл хаалт (2025)	1.03514
Төгсгөл хаалт (2025)	1.17456
Buy-and-hold өгөөж (%)	13.47
\$10,000 хөрөнгийн эцсийн баланс (\$)	11,346.87

Тайлбар: Энэ benchmark нь close-to-close энгийн жишиг тул стратегийн өгөөжтэй шууд тэнцэхгүй; харин сценарийн дүнг харьцуулахад ашиглав.

Дохио-арилжааны хөрвүүлэлт ба гүйцэтгэлийн чанар

Түүхэн өгөгдөл дээрх системийн туршилтын логийг босго тус бүрт anchor дүрмээр задлахад шүүгдсэн дохионы тоо болон бодитоор нээгдэж хаагдсан арилжааны тоо хооронд тогтвортой зөрүү ажиглагдсан. Энэ зөрүү нь дараах гүйцэтгэлийн механизмтай холбоотой:

- Нэг агшинд зөвхөн нэг байрлал нээх дүрэм (MaxPositions=1)
- Нээлттэй байрлал хаагдахаас өмнөх давхцсан дохионуудыг алгасах
- Зөвхөн тухайн хэрэгсэл дээрх дохиог гүйцэтгэх хязгаарлалт

Иймээс энэ бүлэгт хөрвүүлэлтийн хувь $E_{\text{хес.}}(\%) = \frac{\text{Арилжаа}}{\text{Loaded}} \times 100$ томъёогоор тооцсон. Break-even ялалтын хувь 25% байна. Босго өсөх тусам арилжааны тоо буурч, итгэлцлийн интервал өргөсдөг.

Хүснэгт 4.4 Босго тус бүрийн дохио-арилжааны хөрвүүлэлт ба win rate (95% CI)

Босго	Loaded	Арилжаа	Хөрвөөгүй	Ехес. (%)	TP/SL	Win (%)	95% CI (Win)	E[R]
0.90	3,567	230	3,337	6.45	103/127	44.78	[38.49, 51.24]	0.79
0.91	3,274	212	3,062	6.48	100/112	47.17	[40.56, 53.88]	0.89
0.92	2,958	201	2,757	6.80	95/106	47.26	[40.48, 54.15]	0.89
0.93	2,643	188	2,455	7.11	87/101	46.28	[39.30, 53.41]	0.85
0.94	2,287	154	2,133	6.73	73/81	47.40	[39.68, 55.26]	0.90
0.95	1,914	137	1,777	7.16	65/72	47.45	[39.27, 55.76]	0.90
0.96	1,588	113	1,475	7.12	59/54	52.21	[43.08, 61.20]	1.09
0.97	1,195	106	1,089	8.87	54/52	50.94	[41.56, 60.26]	1.04
0.98	673	76	597	11.29	43/33	56.58	[45.39, 67.14]	1.26
0.99	147	35	112	23.81	23/12	65.71	[49.15, 79.17]	1.63

Тайлбар: Win rate-ийн 95% итгэлцлийн интервалыг Wilson аргаар тооцсон. TP/SL=3:1 тогтмол бодлогын дор Expectancy-г $E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}})$ томъёогоор тооцсон.

Статистикийн тодорхойгүй байдлын нэмэлт нэгтгэл

Босгуудын эцсийн балансын тархалтыг нэгтгэн үзвэл дундаж нь \$39,918.25, стандарт хазайлт нь \$15,171.78, харьцангуй хэлбэлзэл (CV) нь 38.01% байна. Энэ нь шинжилгээний үр дүн босго сонголтод мэдрэмтгий болохыг илэрхийлнэ.

Хүснэгт 4.5 Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжсийн шинжилгээ


Босго	MaxDD (%)	Sharpe	Sortino	Calmar	Хамгийн урт дараалсан алдагдал
0.90	3.93	9.11	24.82	122.96	7
0.91	2.97	9.75	25.99	174.20	7
0.92	2.99	9.90	29.78	155.79	7
0.93	9.53	9.21	25.92	38.63	10
0.94	6.80	8.87	24.66	41.23	8
0.95	3.94	8.57	23.97	57.97	6
0.96	4.88	9.84	30.15	47.18	5
0.97	2.96	9.02	24.90	64.19	4
0.98	7.66	10.63	28.84	20.16	8
0.99	1.98	12.83	44.76	37.53	2

Тайлбар: Sharpe/Sortino/Calmar нь хэлцлийн логийн өдөр тутмын балансын мөрөөс тооцсон агрегат үзүүлэлт тул MT5-ийн стандарт statement metric-тэй 1:1 шууд тэнцүүлэхгүй; харин босгуудын хоорондын харьцуулалтын суурь болгон ашиглав.

Энэ графикаас харахад 0.93 (9.53%) болон 0.98 (7.66%) босгон дээр уналтын эрсдэл харьцангуй өндөр байна. Харин 0.99 дээр MaxDD хамгийн бага (1.98%) боловч нийт өгөөж болон дохионы тоо мэдэгдэхүйц буурсан. Иймээс босго сонгохдоо зөвхөн өгөөж бус, уналтын эрсдэлийг хамтад нь авч үзэх шаардлагатай.

Босго ба Execution rate-ийн хамаарал

Зураг 4.1 зурагт Loaded дохионоос бодитоор арилжаанд орсон хувь (Execution rate)-ын өөрчлөлтийг харуулав.




Зураг 4.1 Босгын мужийн шинжилгээ: Execution rate-ийн өөрчлөлт

0.90–0.97 мужид execution rate харьцангуй ойролцоо, харин 0.98–0.99 дээр өссөн нь өндөр босгонд шүүгдсэн дохионы тоо цөөрөх үед гүйцэтгэгдэх хувийн жин нэмэгдэж байгааг илтгэнэ.

Босго ба Win rate (95% CI)-ийн хамаарал

Зураг 4.2 зурагт win rate-ийг 95% Wilson итгэлцлийн интервалтай хамт error bar хэлбэрээр үзүүлэв.




Зураг 4.2 Босгын мужийн шинжилгээ: Win rate ба 95% итгэлцлийн интервал

Босго өсөхөд win rate дундаж өсөх хандлагатай ч интервал мөн өргөсөж байна. Энэ нь өндөр босго дээр арилжааны тоо багассанаас статистикийн тодорхойгүй байдал нэмэгдэж байгааг илтгэнэ.

Босго ба Expectancy (R)-ийн хамаарал

Зураг 4.3 зурагт нэг арилжааны хүлээгдэж буй дундаж үр ашиг болох Expectancy (R)-ийн өөрчлөлтийг харуулав.



Зураг 4.3 Босгын мужийн шинжилгээ: Expectancy (R)-ийн өөрчлөлт

Expectancy (R) бүх босгон дээр 0-ээс дээш байгаа нь хэрэгжсэн арилжааны түвшинд эерэг хүлээлттэй байгааг харуулна. Гэвч үүнийг execution rate, MaxDD, нийт өгөөжтэй хамт уншиж байж практик шийдвэрт ашиглах нь зүйтэй.

4.3. Үр дүнгийн тайлбар

Энэ хэсгийн тайлбар нь дээрх 10 backtest логийн нэгтгэл дээр тулгуурласан бөгөөд босгын мужийн дүнг нэг цонхонд харьцуулсан **нөхцөлт** дүгнэлт болохыг анхаарна.

Сценарийн хүрээнд ажиглагдсан дээд цэг

Энэ цонхны сценарийн харьцуулалтад хамгийн өндөр эцсийн баланс босго 0.91 дээр \$61,770.46 (+517.70%) гарсан. Үүнийг универсал оновчтой босго гэж бус, тухайн өгөгдөл ба гүйцэтгэлийн дүрмийн хүрээнд ажиглагдсан локал дүн гэж тайлбарлав.

Уг дүн нь “3,274 loaded дохио → 212 хэрэгжсэн арилжаа” гэсэн шүүлтүүртэй нөхцөлд гарсан. Иймээс бүх дохионд ижил түвшний хэрэгжилт автоматаар гарна гэж тайлбарлахгүй. MaxDD=2.97%, Sharpe=9.75, Sortino=25.99, Calmar=174.20 (Хүснэгт 4.5) зэрэг үзүүлэлтүүдийг сценари хоорондын харьцуулалтын суурь гэж авч үзэв.

Чанар-тоо хэмжээний зөрчил

Босго 0.90-ээс 0.99 хүртэл өсөхөд:

- Нийт дохио 3,567-оос 147 болж 95.88%-аар буурсан
- Нийт өгөөж +482.62%-аас +74.29% хүртэл буурсан

- Харин дохио тутмын дундаж ашиг \$13.53-аас \$50.54 хүртэл өссөн

Энэ нь **чанартай (өндөр итгэлцэлтэй) дохио** цөөрөх тусам нэг дохионы үр ашиг өсч болох ч, нийт оролтын давтамж хэт багассанаар хуримтлагдсан ашиг буурч болдгийг илэрхийлнэ. Энд “итгэлцэл” нь загвар тухайн BUY/SELL ангиллыг зөв гэж үзэж буй магадлалын түвшин юм. Санхүүгийн туршилтад ийм дээжийн хэмжээний (sample size) нөлөөг хамтад нь авч үзэх шаардлагатайг [25, 26] онцолдог.

Босго сонголтын зарчим (data-snooping эрсдэлийн хяналт)

0.91 босго нь энэ шинжилгээний хүрээнд ажиглагдсан локал дээд цэг бөгөөд бүх нөхцөлд универсал оновчтой утга гэж тайлбарлахгүй. Иймээс босгоны дүгнэлтийг зөвхөн сценарийн харьцуулалтын түвшинд авч үзэж, дараагийн хугацааны цонхонд ижил дүрмээр дахин шалгасны дараа л ажиллах бодлогод хэрэглэх нь зүйтэй.

Өөрөөр хэлбэл энэ бүлгийн зорилго нь “ажиллах үед босгыг динамикаар тааруулж оновчлох” биш, харин урьдчилан тогтоосон босгуудын оролт-үр ашгийн тэнцвэрийг нэг ижил гүйцэтгэлийн нөхцөлд харьцуулах юм.

Орон нутгийн хэлбэлзэл

0.95 ба 0.96 дээр жижиг зөрүү ажиглагдсан (\$32,844.40 → \$33,040.14). Энэ нь босгоос гадна тухайн хугацаанд таарсан хэлбэлзэл, байрлал хаагдах дараалал зэрэг гүйцэтгэлийн түвшний хүчин зүйлс үр дүнд нөлөөлдгийг харуулна.

Арга зүйн эрсдэлийн нэгдсэн тайлбар

Хүснэгт 4.6 Арга зүйн эрсдэлийн нэгдсэн хүснэгт (энэ хувилбар)

Эрсдэл	Нөлөө	Энэ тайлан дахь хяналт	Үлдэгдэл эрсдэл
Label leakage	Өндөр	Цагийн дарааллын дүрэм, backward нэгтгэл, split тусгаарлалт	Бүрэн үгүйсгээгүй
WFFV нэг огтлолын нэгтгэл	Дунд-өндөр	WFFV хүрээ хэрэглэсэн, нэг огтлолд төвлөснийг ил тод заасан	Олон огтлолтын дундаж дутуу
Execution selection bias	Өндөр	Loaded vs Executed ялгааг хүснэгтээр нэгтгэн харуулсан	Нөхцөлт тайлбар шаардлагатай
Зардлын модел дутуу	Дунд	Spread/slippage тусгасан, хамралтын матриц нэмсэн	Commission/ swap дутуу
Calibration туршилтын ажиглалт (train/serve skew)	Дунд	Calibration-ийг баталгаажуулалтын огтлол дээр туршилтын ажиглалтаар шалгасан, ажиллах үеийн дүнг raw probability-гаар тайлагнасан	Ажиллах орчны баталгаажуулалт дутуу
Эрсдэлийн шинжилгээний лог-суурь тооцоолол	Дунд	MaxDD/Sharpe/Sortino/Calmar/losing streak-ийг босго бүрт нэгтгэн харуулсан	MT5 statement-level official metric-тэй бүрэн кросс-валидаци дутуу
Threshold data-snooping	Дунд	Selection-freeze-confirmation протокол тайлбарласан	Confirmation шат бүрэн тусгаагүй

4.4. Дахин хэрэгжүүлэх боломж ба орчны нөхцөл

Энэ бүлгийн үр дүнг дахин хэрэгжүүлэхэд дараах нөхцөлийг тогтмол хадгалах шаардлагатай.

- Эх сурвалжийн лог багц: босгын мужийн 0.90–0.99 бүх гүйлтийн MT5 логиог өөрчлөхгүй хадгалах
- Нэгтгэлийн дүрэм: босго бүрт Loaded signals anchor мөрөөс хойших эхний final balance мөрийг холбох
- Арилжааны үзүүлэлтүүд: Trades/Trade мөрөөс TP/SL болон хаагдсан арилжааны дарааллыг нэг ижил дүрмээр тооцох
- Гүйцэтгэлийн нөхцөл: ижил MT5 тестийн хугацааны цонх, ижил EA ажиллах үеийн дүрмүүд (нэг агшинд нэг байрлал, ижил дохио ачаалах журам)

Эдгээр нөхцөл зөрвөл тайланд буй тоон үр дүнтэй 1:1 давхцахгүй байж болох тул дахин хэрэгжүүлэлтийн үед параметрийн өөрчлөлт бүрийг тусдаа протоколын хүснэгтээр бүртгэх нь зүйтэй.

4.5. Практик шийдвэр гаргалтын хүрээ

Энэ судалгааны шинжилгээний хүрээнд дараах байдлаар практик тайлбар хийж болно.

- **Эрсдэл-өмнөх шалгуур:** CV харьцангуй бага, MaxDD хэт өсөөгүй, хамгийн урт дараалсан алдагдал богино, win rate-ийн 95% CI хэт өргөн биш, мөн Expectancy (R) тогтвортой эерэг мужийг давуу үзэх
- **Нийт өгөөжийг** түлхүү зоривол: энэ шинжилгээний хүрээнд босго 0.90–0.92 муж практик сонголт болж ажиглагдсан
- **Дохионы тоог** багасгаж, зөвхөн өндөр итгэлцэлтэй оролт хүсвэл: энэ шинжилгээний хүрээнд босго 0.97+ мужийг нөхцөлтөөр авч үзэж болно
- **Тэнцвэрт сонголт:** 0.90–0.92 муж нь энэ датасетийн шинжилгээнд нийт өгөөж ба давтамжийн харьцаагаар нөхцөлт практик муж болж ажиглагдсан

Энд “хамгийн сайн босго” нь универсал тогтмол утга биш; өгөгдлийн хугацаа, зах зээлийн горим, зардлын нөхцөл өөрчлөгдвөл дагаад өөрчлөгдөх боломжтой.

4.6. Дүгнэлт

Судалгааны гол үр дүн

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан форекс зах зээлийн арилжааны дохионы системийг хөгжүүлсэн. Үр дүнг гурван түвшинд дүгнэв.

1. **Машин сургалт (machine learning) ансамбль загвар:** LightGBM, XGBoost, CatBoost гурван GBDT загварын ансамбль нь 6 хугацааны хүрээний 48 шинж чанар (feature)-ыг ашиглан EUR/USD-ийн чиг хандлагыг BUY/SELL/HOLD гурван ангилалд таамагласан.
2. **Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэл:** 0.90–0.99 мужийн сценарийн харьцуулалтад бүх босго эерэг өгөөжтэй гарсан. Дохио-арилжааны хөрвүүлэлтийн хувь, win rate-ийн 95% Wilson CI, Expectancy (R)-г хэрэгжсэн арилжааны хүрээнд тайлбарласан. MaxDD, Sharpe, Sortino, Calmar зэрэг эрсдэлийн үзүүлэлтүүдийг босго бүрээр харьцуулсан.
3. **Инженерчлэлийн хэрэгжүүлэлт:** Серверийн хэсэг (backend)-ээс харагдах хэсэг (frontend)-д хүрэх архитектурын уялдааг судалгааны прототипийн түвшинд хэрэгжүүлсэн.
4. **Хэт нийцэл (overfitting) эрсдэлийн бууралт:** 7 давталтат хөгжүүлэлтийн үе шатаар загварыг хялбаршуулж (75→48 шинж чанар, 9→3 загвар), тогтвортой байдлыг сайжруулсан.

Судалгааны практик хувь нэмэр

- **Системийн түвшний нэгтгэл:** Загварын сургалт, дохио үүсгэх урсгал, түүхэн өгөгдөл дээрх системийн туршилт (backtesting), серверийн хэсэг (backend), харагдах хэсэг (frontend)-ийг нэг судалгааны хүрээнд уялдуулсан
- **Ил тод үнэлгээний хүрээ:** RQ/KPI уялдаа, тодорхойгүй байдлын интервал, сценарийн харьцуулалт, threats-to-validity матрицыг ашигласан

- **Монгол хэл дээрх техникийн баримтжуулалт:** Санхүүгийн нэр томъёог компьютерийн шинжлэх ухааны уншигчдад ойлгомжтой тайлбарлаж баримтжуулсан

Хязгаарлалт

1. **External validity:** EUR/USD хэрэгсэл, сонгосон хугацааны цонхонд батлагдсан тул өөр валютын хослол, брокерт шууд ерөнхийшүүлэхгүй
2. **Label leakage-ийн үлдэгдэл эрсдэл:** Олон интервалын нэгтгэхэд хугацааны дүрэм мөрдсөн ч бүрэн үгүйсгээгүй
3. **Дохио-арилжааны хөрвүүлэлтийн хэлбийлт:** Execution rate 100% биш үед win rate, Expectancy нь хэрэгжсэн арилжаанд нөхцөлт
4. **Арилжааны зардлын хамралт:** Спред, гулсалт тусгасан боловч шимтгэл, свопыг бүрэн хамруулаагүй
5. **Calibration ба train/serve зөрүү:** Offline calibration-ийг туршилтын ажиглалтаар шалгасан; ажиллах үеийн raw probability-тэй ялгаанаас үлдэгдэл эрсдэл үүсч болно
6. **Бодит цагийн хүндрэл:** Гадаад системийн (3rd-party API) хязгаарлалт, сүлжээний саатал зэрэг техникийн асуудлууд

Цаашдын чиглэл

1. **Олон валютын хослолд өргөтгөх:** GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, багц (portfolio) стратеги бүтээх
2. **Дагах зогсоол (trailing stop):** Ашгийг хамгаалах динамик SL-ийн аргачлалыг сайжруулах
3. **Гүн сургалтын загвар:** LSTM, Transformer зэрэг цуваа өгөгдлийн загваруудыг ансамбль-д нэмэх
4. **Бататгалтат сургалт (reinforcement learning):** Багцын менежмент, байрлалын хэмжээ тохируулалтад хэрэглэх
5. **Мэдээний шинжилгээ:** NLP ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах
6. **Түгээлт ба MLOps:** Google Play түгээлтийн сувгийг нэвтрүүлж, загварын шилжилт (model drift) мониторинг, хувилбар гаргалтын автоматжуулалтыг өргөтгөх

Эцсийн дүгнэлт

Энэхүү сценарийн цонхонд машин сургалтын ансамбль загвар эерэг гүйцэтгэлийн шинж үзүүлсэн. Бүх босгын сценари эерэг өгөөжтэй гарч, дохио-арилжааны хөрвүүлэлт, win rate-ийн интервал, Expectancy (R), MaxDD зэргийг хамтатган үнэлсэн. Гэсэн ч тухайн хэрэгсэл, хугацааны цонх, зардлын загварын хүрээнд хүчинтэй тул ерөнхийшүүлэхгүй. Практикт эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох чадварыг заавал авч үзнэ.

Нийт дүнгээр, систем нь загвар сургалтаас эхлээд хэрэглэгчид хүргэх хүртэлх урсгалыг прототипийн түвшинд хэрэгжүүлсэн. Энэ нь машин сургалт, серверийн хэсэг (backend), мобайл аппликейшний хөгжүүлэлтийг нэг инженерчлэлийн хүрээнд уялдуулсан үр дүн юм.

- [1] Bank for International Settlements. Triennial central bank survey: Foreign exchange turnover in april 2022, 2022.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.
- [3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.
- [4] Joarder Kamruzzaman and Ruhul A. Sarker. Forecasting of currency exchange rates using ANN: A case study. *Journal of Financial Forecasting and Analysis*, 1(1):1–15, 2003.
- [5] M. Kumar and M. Thenmozhi. Forecasting stock index movement: A comparison of SVM and random forest. *Indian Institute of Capital Markets Working Paper*, 1(1):1–22, 2006.
- [6] Michel Ballings, Dirk Van den Poel, Niels Hespeels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.
- [7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.
- [8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review. *Applied Soft Computing*, 97, 2019.
- [9] Yuqi Nie, Nam Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. A time series is worth 64 words: Long-term forecasting with transformers. *International Conference on Learning Representations*, 2023.
- [10] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis. *International Conference on Learning Representations*, 2023.
- [11] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2):689–702, 2017.
- [12] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [13] Shihao Gu, Bryan T. Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [14] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [15] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.
- [16] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

- [17] Omer Berat Sezer, Mehmet U. Gudelek, and A. Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [18] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.
- [19] John J. Murphy. *Technical Analysis of the Financial Markets*. New York Institute of Finance, 1999.
- [20] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis. *The Journal of Finance*, 55(4):1705–1765, 2000.
- [21] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.
- [22] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.
- [23] Ben R. Marshall, Ros Cahan, and Jean M. Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.
- [24] Cheol-Ho Park and Scott H. Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.
- [25] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.
- [26] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.
- [27] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023.
- [28] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O’Reilly Media, 2nd edition, 2018.
- [29] Miguel Grinberg. *Flask Web Development: Developing Web Applications with Python*. O’Reilly Media, 2nd edition, 2018.
- [30] Alan R Hevner, Salvatore T March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.
- [31] Ken Peffers, Tuure Tuunanen, Marcus A Rothenberger, and Samir Chatterjee. A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77, 2007.

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутан: s21c033b, М.Мөнхдорж

Удирдагч багш: Н.Соронзонболд

1. Удиртгал

Энэхүү судалгаа нь валютын зах зээл (Forex)-д машин сургалтын загвараар дохио үүсгэж, серверийн хэсэг (backend) болон харагдах хэсэг (frontend)-тэй нэгдсэн систем хэлбэрээр хэрэгжүүлсэн. Санхүүгийн өгөгдөл нь шуугиан ихтэй, горимын өөрчлөлтөд мэдрэмтгий учраас өндөр нарийвчлалыг дангаар хөөхөөс илүү арга зүй-гүйцэтгэл-эрсдэлийн гурван түвшний баталгаажуулалтыг хэрэгжүүлсэн.

Судалгааны зорилт нь: (1) EUR/USD дээр тогтвортой ансамбль загвар бүтээх, (2) дохионы чанарыг бодит нөхцөлд үнэлэх, (3) прототип системийг хэрэглэгчид хүрэх түвшинд холбох, (4) өгөөж ба эрсдэлийг статистик аргаар тайлбарлах.

2. Онолын суурь

GBDT бүлгийн LightGBM, XGBoost, CatBoost алгоритмуудыг зөөлөн саналын (soft voting) ансамблиар нэгтгэхэд тулгуурласан. Хүснэгтэн өгөгдөлд гүн сургалтаас илүү тогтвортой ажиллах давуу талтай. Урагш гүйлгэн баталгаажуулалт (WFV) аргаар цаг хугацааны дарааллыг хадгалж, ирээдүйн мэдээлэл ашиглах хэвийдэл (look-ahead bias)-ийн эрсдэлийг бууруулсан.

3. Арга зүй

Дизайн шинжлэх ухааны “бүтээх-үнэлэх-сайжруулах” мөчлөгөөр 7 давталтаар хэрэгжүүлсэн. EUR/USD-ийн 2015–2024 оны OHLCV өгөгдлийг M1–H4 зургаан интервалаар ашиглаж, интервал бүрээс 8 шинж чанар (feature) гаргаж нийт 48 шинж чанарын матриц

байгуулсан. Шошго (BUY/SELL/HOLD) нь ирээдүйн 240 минутын ханшийн хөдөлгөөнд суурилсан. Дохионы шүүлтүүрт итгэлцлийн босго (≥ 0.90) болон ATR (≥ 4.0 пипс)-ыг ашигласан. WFV-ийн Fold 5 огтлолд (2015–2022 / 2023 / 2024) KPI тайлан төвлөрүүлсэн.

Түүхэн өгөгдөл дээрх системийн туршилтыг 2025.01.01–2026.01.01 цонхонд, \$10,000 анхны хөрөнгөтэй, бодит спред нөхцөлд хийсэн. EA-ийн босго 0.90 дээр тогтмол байсан бөгөөд 0.90–0.99 мужийн ялгаа нь урьдчилан шүүсэн дохионы багцуудын сценарийн харьцуулалтаас үүдсэн.

4. Үр дүн ба дүгнэлт

359,639 таамгаас шүүлтүүрийн дараа 3,567 дохио (1.0%) үлдсэн. Бүх босгын сценари эерэг өгөөжтэй гарсан: хамгийн өндөр нь 0.91 босгон дээр +517.70% (\$61,770.46), 0.90 дээр +482.62% (\$58,262.39). EUR/USD buy-and-hold жишгээр \$10,000 хөрөнгө +13.47% буюу \$11,346.87 болсон.

Win rate 44.78%–65.71%, Expectancy (R) 0.79–1.63 хооронд эерэг гарсан (TP/SL=3:1 нөхцөлд break-even 25%). Max drawdown 1.98%–9.53%, хамгийн урт дараалсан алдагдал 2–10. Execution rate 6.45%–23.81% мужид хэлбэлзсэн. Спред, гулсалтыг тусгасан боловч шимтгэл, свопыг бүрэн хамруулаагүй.

Инженерчлэлийн хувьд загвар сургалтаас эхлээд серверийн хэсэг (backend)-ээс харагдах хэсэг (frontend)-д хүргэх нэгдсэн урсгалыг прототипийн түвшинд хэрэгжүүлсэн.

5. Ном зүй

Товчлолын гол эх сурвалжууд:

1. Hevner, A. R., et al. (2004). Design Science in IS Research.
2. Peffers, K., et al. (2007). A DSR Methodology.
3. Chen, T., & Guestrin, C. (2016). XGBoost.
4. Ke, G., et al. (2017). LightGBM.
5. Pardo, R. (2008). Trading Strategies.
6. Bailey, D. H., et al. (2014). Backtest Overfitting.