



ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутны код: s21c033b

Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

/ДЭД БАКАЛАВРЫН ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот

2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Дэд бакалаврын төгсөлтийн судалгааны ажил (061301)

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ
СИСТЕМ

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот
2026 он

Хураангуй

Энэхүү судалгаа нь санхүүгийн цаг хугацааны цуваан дээр (EUR/USD) машин сургалтын ансамбль ашиглан гурван ангиллын (BUY / HOLD / SELL) дохиог автоматаар гаргах системийг боловсруулсан. Гадаад валютын зах зээлийн (Форекс) шуугиан ихтэй, тогтворгүй (non-stationary) шинж чанар нь ангиллын хүндрэлтэй сорилт болдог. Загварын ангиллын гүйцэтгэлийг цаг хугацааны дарааллыг хадгалсан баталгаажуулалт болон бодит нөхцөлийг дуурайсан симуляцаар цогцоор үнэлэв.

LightGBM, XGBoost, CatBoost гурван GBDT загварыг зөөлөн санал хураалтаар (soft voting) нэгтгэсэн ансамблийг EUR/USD-ийн 2015–2024 оны өгөгдөл дээр сургасан. Урагш гүйлгэн баталгаажуулалтын (Walk-Forward Validation, WFW) Fold 5 огтлолын 2024 оны тестийн ерөнхий нарийвчлал 89.25% (F1-macro=59.45%, F1-weighted=87.23%) бөгөөд HOLD ангийн давамгайлсан тэнцвэргүй өгөгдөлд нарийвчлалыг ганц хэмжүүр болгох хангалтгүй гэдгийг F1-macro харуулна. Баталгаажуулалтын өгөгдөл дээр итгэлцэл ≥ 0.90 дохионы нарийвчлал 96.96% гарсан нь босгон шүүлтүүрийн үндэслэлийг харуулна. MetaTrader 5 дээр 2025 оны бүтэн жилд бүх 10 итгэлцлийн сценари эерэг өгөөж үзүүлсэн; 0.91 босгон дээр +517.70% (\$61,770) хүрч, суурь жишгийн (EUR/USD-г эхнээс эцэс хүртэл барих стратеги) +13.47%-г мэдэгдэхүйц давсан. Энэ дүн нь 1% эрсдэлийн тогтмол хэмжээлэлт ба нийлмэл хуримтлагдах өсөлтийн үр нөлөөнөөс үүдэлтэй учир босго бүрийн сценарийг харьцуулах хэмжүүр болгон тайлбарлах нь зүйтэй. Брокерын шимтгэл болон шөнийн хадгалалтын зардлыг тусгаагүй зэрэг хязгаарлалтыг \$4.6.3-аас үзнэ үү.

Системийн инженерчлэлийн талд офлайн загвар сургалт, REST API сервер (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Expo Push) гэсэн дөрвөн давхаргыг нэгтгэсэн ML serving дамжлагыг ажиллах прототип хэлбэрээр бэлдсэн.

Түлхүүр үгс: машин сургалт, GBDT ансамбль загвар, урагш гүйлгэн баталгаажуулалт, олон хугацааны интервалын шинж чанар, түүхэн өгөгдөл дээрх системийн туршилт, дохио-арилжааны хөрвүүлэлт, хүлээгдэж буй өгөөж (R), эрсдэл-өгөөжийн үнэлгээ

Гарчиг	
Хураангуй	i
Гарчиг	ii
Товчилсон үгсийн жагсаалт	iii
Нэр томъёоны тайлбар толь	iv
Хүснэгтийн жагсаалт	vi
Зургийн жагсаалт	vii
Ажлын төлөвлөгөө	1
1 Удиртгал	2
1.1 Үндэслэл, ач холбогдол	2
1.2 Зорилго, зорилт	2
1.3 Судалгааны асуулт ба хэмжигдэх шалгуур	3
2 Судалгааны сэдвийн онол, өнөөгийн түвшин	4
2.1 Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд	4
2.2 Шинж чанаруудын судалгаа	5
2.3 Урагш гүйлгэн баталгаажуулалт	5
2.4 ML serving дамжлага ба мобайл аппын архитектур	6
2.5 Төсөөтэй системүүд ба судалгааны цоорхой	6
2.6 Үндсэн судалгаануудтай харьцуулсан тойм	6
2.7 Судалгааны ажлын шинэлэг тал	7
3 Судалгааны арга зүй	8
3.1 Судалгааны арга барил	8
3.2 Системийн ерөнхий бүтэц	8
3.3 Өгөгдлийн урсгал	9
3.4 Өгөгдөл бэлтгэл	10
3.5 AI загварын бүтэц ба сургалт	14
3.6 Дохио үүсгэх систем	17
3.7 MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт	19
3.8 Серверийн хэсгийн хэрэгжүүлэлт	21
3.9 Харагдах хэсгийн архитектур	23
3.10 Загварын давталтын сайжруулалт	25
4 Судалгааны үр дүн	26
4.1 Үр дүнгийн өгөгдлийн эх сурвалж	26
4.2 Загварын ангиллын гүйцэтгэл	26
4.3 Босгын мужийн нэгтгэсэн үр дүн	27
4.4 Үр дүнгийн тайлбар	33
4.5 Архитектурын KPI-ийн баталгаажуулалтын үр дүн	33
4.6 Дүгнэлт	34
Ном зүй	36
Хавсралт	38
Товчлол	1

Товчилсон үгсийн жагсаалт

Нэр томъёоны тайлбар толь

Энэхүү тайлбар тольд ажлын туршид ижил утгаар хэрэглэсэн гол нэр томъёонуудыг нэг мөр болгож жагсаав. Монгол нэршлийг үндсэн хэлбэр болгон авч, шаардлагатай тохиолдолд эх нэршлийг хаалтанд хавсаргав.

Монгол нэршил	Original term
шинж чанар	feature
шинж чанарын инженерчлэл	feature engineering
шинж чанарын нөлөөлөл	feature importance
шошго	label
ансамбль загвар	ensemble model
зөөлөн санал хураалт	soft voting
гиперпараметр	hyperparameter
эрт зогсоох	early stopping
тогтмолжуулалт	regularization
хэт нийцэл	overfitting
урагш гүйлгэн баталгаажуулалт	walk-forward validation
ирээдүйн мэдээлэл ашиглах хэвийдэл	look-ahead bias
зорилтот хувьсагчийн нэвчилт	target leakage
түүхэн өгөгдөл дээрх системийн туршилт	backtesting
уналт	drawdown
ханшийн хэлбэлзэл	volatility
хугацааны интервал	timeframe
итгэлцэл	confidence
итгэлцлийн босго	confidence threshold
магадлалын тохируулга	probability calibration
системийн туршилт	system testing
серверийн хэсэг	backend
харагдах хэсэг	frontend
өгөгдөл боловсруулах урсгал	data pipeline
цогц систем	end-to-end system
түүвэр доторх	in-sample
түүврийн гадуурх	out-of-sample
байрлал	position
пипс	pip
спрэд	spread
гулсалт	slippage
эрсдэл-өгөөжийн харьцаа	risk-reward ratio
загварын шилжилт	model drift
push мэдэгдэл	push notification

ML Machine Learning – Машин сургалт

AI Artificial Intelligence – Хиймэл оюун ухаан

GBDT Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

XGBoost Extreme Gradient Boosting

LightGBM Light Gradient Boosting Machine

CatBoost Categorical Boosting

LSTM Long Short-Term Memory – Урт богино хугацааны санах ой

RSI Relative Strength Index – Харьцангуй хүчний индекс

ATR Average True Range – Дундаж жинхэнэ хүрээ

SMA Simple Moving Average – Энгийн хөдөлгөөнт дундаж

EMA Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

SL Stop Loss – Алдагдал зогсоох

TP Take Profit – Ашиг авах

API Application Programming Interface

REST Representational State Transfer

JWT JSON Web Token

OHLCV Open, High, Low, Close, Volume

MT5 MetaTrader 5

DD Drawdown – Уналт

RR Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

WSGI Web Server Gateway Interface

Expo Expo Push API (exp.host) – React Native апп руу push мэдэгдэл хүргэх үйлчилгээ

APNs Apple Push Notification service – Apple-н push мэдэгдэл хүргэх үйлчилгээ

UI User Interface – Хэрэглэгчийн интерфэйс

UX User Experience – Хэрэглэгчийн туршлага

WFFV Walk-Forward Validation – Урагш гүйлгэн баталгаажуулалт

Хүснэгтийн жагсаалт

Хүснэгт 1.1.	Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)	3
Хүснэгт 2.1.	Холбогдох судалгаатай харьцуулсан үндсэн ялгаа	6
Хүснэгт 3.1.	Түүхэн өгөгдлийн хэмжээний хураангуй	11
Хүснэгт 3.2.	Шинж чанарын жагсаалт (интервал бүрд)	11
Хүснэгт 3.3.	Урагш гүйлгэн баталгаажуулалтын өгөгдлийн хуваалт	13
Хүснэгт 3.4.	Түүхэн өгөгдөл дээрх системийн туршилтын үндсэн тохиргоо	20
Хүснэгт 3.5.	Системийн үнэлгээний шалгуур үзүүлэлтүүд	21
Хүснэгт 3.6.	API endpoint-ийн хандалтын хурдны хязгаарлалт	23
Хүснэгт 3.7.	Харагдах хэсгийн модулиуд, харилцааны загвар ба API endpoint бүлэг	24
Хүснэгт 3.8.	Загварын давталтын 7 үе шат — гол өөрчлөлт ба үндэслэл	25
Хүснэгт 4.1.	GBDT ансамблийн нарийвчлал ба F1 оноо — хуваарь тус бүрээр	26
Хүснэгт 4.2.	Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт (BUY / HOLD / SELL)	27
Хүснэгт 4.3.	Итгэлцлийн бүрийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)	27
Хүснэгт 4.4.	0.90–0.99 мужийн босгын харьцуулалт	28
Хүснэгт 4.5.	EUR/USD худалдан аваад барих жишгийн хураангуй	28
Хүснэгт 4.6.	Босго тус бүрийн дохио-арилжааны гүйцэтгэл ба ялалтын хувь (95% CI)	29
Хүснэгт 4.7.	Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ	30
Хүснэгт А.1.	Нэвчилтийн аудитын цагийн нийцлийн дүрмүүд	39
Хүснэгт В.1.	Архитектурын баталгаажуулалтын KPI протокол	41
Хүснэгт Д.1.	MongoDB Atlas-д байршсан 12 цуглуулгын схем — гол талбарууд, индекс ба TTL тохиргоо	43
Хүснэгт Д.2.	Цуглуулга хоорондын гадаад түлхүүрийн харилцаа	43
Хүснэгт Е.1.	Гурван GBDT загварын гиперпараметрууд	45

Зургийн жагсаалт

Зураг 3.1.	7 давталтын явцад шинж чанар ба загварын тоог цөөлсөн байдал	8
Зураг 3.2.	Системийн архитектур	8
Зураг 3.3.	Өгөгдлийн урсгал	10
Зураг 3.4.	Урагш гүйлгэн баталгаажуулалт (offline сургалтын үе шат) — Fold 5-ын өгөгдлийн хуваалт	14
Зураг 3.5.	GBDT ансамбль загварын архитектур	16
Зураг 3.6.	Дохионы шүүлтүүрийн юүлүүр: 359,639 таамгаас 230 хэлцэл хүртэл (0.90 босго) . .	17
Зураг 3.7.	Дохионы амьдралын мөчлөгийн төлөвт автомат	18
Зураг 3.8.	Дохио үүсгэх дарааллын диаграмм (UML 2.5 sequence diagram)	19
Зураг 3.9.	Системийн байршуулалтын диаграмм — Docker, Azure App Service, role-based scaling	22
Зураг 3.10.	Харагдах хэсэг ба серверийн сервисүүдийн REST polling холболтын архитектур . . .	25
Зураг 4.1.	Босгын мужийн шинжилгээ: гүйцэтгэлийн хувийн өөрчлөлт	31
Зураг 4.2.	Босгын мужийн шинжилгээ: ялалтын хувь ба 95% итгэлцлийн интервал	31
Зураг 4.3.	Босгын мужийн шинжилгээ: хүлээгдэж буй өгөөжийн өөрчлөлт	32
Зураг 4.4.	Хамгийн өндөр өгөөжтэй 3 босгын хөрөнгийн өөрчлөлтийн муруй	32
Зураг Б.1.	WFV олон огтлолын ерөнхий концепцын схем (Fold 1–Fold 5 expanding window protocol)	40

Ажлын төлөвлөгөө**Оюутны нэр:** М.Мөнхдорж**Удирдагч багшийн нэр:** Н.Соронзонболд**Судалгааны ажлын сэдэв:** Машин сургалтын аргаар Форекс зах зээлийн арилжааны дохионы систем хөгжүүлж үнэлэх

Сар	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 сар	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Форекс арилжаа, машин сургалт (machine learning) онолын судалгаа хийх	✓
	3	Yahoo Finance ба MetaTrader 5-аас EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 сар	1	70+ техник индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модел сургах	✓
	3	Stacking Ensemble модел хөгжүүлэх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх	✓
	4	Серверийн хэсэг болон мобайл апп хөгжүүлэх	✓
12 сар	1	ТСА Үзлэг 1	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 сар	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 сар	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	✓
	4	Хамгаалалтын бэлтгэл хийх	✓
3 сар	1	ТСА Үзлэг 2	✓
	2	Засвар хийх, санал хүсэлтийг тусгах	✓
	3	Код тайлбар, баримтжуулалт	✓
	4	Хамгаалалтын дадлага хийх	✓
4 сар	1	Эцсийн засвар хийх	✓
	2	Слайд сайжруулах	✓
	3	Хамгаалалтын бэлтгэл	✓
	4	ТСА урьдчилсан хамгаалалт	✓
5 сар	1	ТСА урьдчилсан хамгаалалт	✓
	2	ТСА урьдчилсан хамгаалалт	✓
	3	Эцсийн засвар, сайжруулалт	✓
	4	ТСА үндсэн хамгаалалт	□

Удирдагч багш
Гүйцэтгэсэн оюутан/Н.Соронзонболд, магистр/
/s21c033b, М.Мөнхдорж/

1. Удиртгал

1.1. Үндэслэл, ач холбогдол

Өгөгдлийн шинжлэх ухаан болон мэдээллийн технологийн салбарт олон хэмжээст, шуугиан ихтэй цаг хугацааны цуваан өгөгдөлд дүн шинжилгээ хийх нь томоохон сорилт хэвээр байна. Үүний тод жишээ нь гадаад валютын зах зээл буюу Форекс юм. Энэ зах зээл нь олон улсын эдийн засгийн төлөв байдал, төв банкуудын бодлого зэрэг макро түвшний хүчин зүйлсээс хамааран тасралтгүй, өндөр хэлбэлзэлтэйгээр өөрчлөгддөг [1]. Ийм өндөр хэлбэлзэлтэй, шугаман бус хандлагатай зах зээлийн өгөгдлөөс зүй тогтлыг илрүүлэх нь уламжлалт статистик аргуудын хувьд нарийн асуудал хэвээр байна.

Уламжлалт аргууд нь ихэвчлэн хүний шууд оролцоо, субъектив дүгнэлтэд тулгуурладаг тул их хэмжээний өгөгдлийг богино хугацаанд автоматаар боловсруулж таамаглахад тохиромжгүй. Иймд буруу дүгнэлт гарах эрсдэл өндөр байдаг.

Сүүлийн жилүүдэд машин сургалт болон хиймэл оюун ухааны алгоритмууд санхүүгийн салбарт эрчимтэй нэвтэрсэн. Тухайлбал, GBDT болон нейрон сүлжээ зэрэг орчин үеийн алгоритмууд их хэмжээний өгөгдлөөс нарийн зүй тогтлыг илрүүлэх чадвартайг олон судалгаа нотолсон [2, 3]. Хэдий тийм ч загвар сургалтын өгөгдөлдөө хэт нийцэх (overfitting), нэг алгоритмд түшиглэсэн архитектураас үүдэн системийн доголдол гарах зэрэг инженерчлэлийн асуудал практик орчинд тулгарсаар байгаа.

Энэ чиглэлийн судалгаанд загварын нарийвчлалыг дангаараа сайжруулах нь хангалтгүй. Серверийн хэсгийн бодит цагийн өгөгдөл боловсруулах урсгал, гүйцэтгэлийн тогтвортой байдал, харагдах хэсэгт үр дүнг хүргэх уялдааг хамтад нь авч үзэх шаардлагатай. Тус судалгаа нь загварын нарийвчлал, серверийн хэсгийн архитектур, мобайл интерфэйс гэсэн гурван давхаргыг нэг туршилтын хүрээнд нэгтгэж, тэдгээрийн хамтарсан гүйцэтгэлийг үнэлснээрээ ялгарна.

Тус ажилд зөөлөн санал хураалтад суурилсан GBDT ансамбль загвар, цаг хугацааны дарааллыг хадгалсан урагш гүйлгэн баталгаажуулалт (Walk-Forward Validation, WFFV), олон хугацааны интервалын шинж чанарын инженерчлэл (multi-timeframe feature engineering) гэсэн гурвыг нэгтгэн найдвартай ангиллын системийг хөгжүүлсэн. Загварын гаралтыг REST API болон мобайл аппаар дамжуулан хэрэглэгчдэд хүргэх ML serving дамжлагыг бүтээснээр загвар, серверийн хэсэг, харагдах хэсгийн уялдааг ажиллах прототип хэлбэрээр бэлдсэн.

1.2. Зорилго, зорилт

Судалгааны зорилго

Судалгааны үндсэн зорилго нь шуугиан ихтэй санхүүгийн цаг хугацааны цуваанд (EUR/USD өгөгдөл дээр) GBDT ансамбль загвар ашиглан гурван ангиллын (BUY / HOLD / SELL) систем боловсруулж, ангиллын чанарыг итгэлцлийн шүүлтүүрээр сайжруулах, мөн үүссэн дохионы гүйцэтгэлийг түүхэн өгөгдөл дээрх системийн туршилтаар үнэлэхэд оршино.

Судалгааны зорилтууд

Энэ зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлэв:

1. Олон хугацааны интервалын (M1–H4, 6 интервал) санхүүгийн цаг хугацааны цуваанаас шинж чанарын матриц (48 feature) бүрдүүлж, гурван ангиллын (BUY / HOLD / SELL) сургалтын шошго үүсгэх; мэдээллийн нэвчилтийн (label leakage) эрсдэлийг аудитаар хянах.

2. Цаг хугацааны дарааллыг алдагдуулахгүй урагш гүйлгэн баталгаажуулалтад суурилсан GBDT ансамбль (LightGBM + XGBoost + CatBoost, зөөлөн санал хураалт)-ийн туршилтын орчныг хөгжүүлж, хэт нийцлийн эрсдэлийг хянах.
3. Ангиллын нарийвчлал, итгэлцлийн шүүлтийн нөлөө, дохио-гүйцэтгэлийн хөрвүүлэлт (signal-to-execution conversion rate), болон эрсдэл-өгөөжийн үзүүлэлтүүдийг нэгдсэн үнэлгээний хүрээнд хэмжих.
4. Бодит цагийн ML таамаглал гаргах серверийн REST API (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Expo Push)-ийг нэгтгэн, загвар сургалтаас хэрэглэгч хүртэлх ML serving дамжлагыг бүтээх.

1.3. Судалгааны асуулт ба хэмжигдэх шалгуур

Судалгааны ажлын зорилтуудыг хэмжихүйц шалгууруудтай холбохын тулд дараах судалгааны асуултуудыг тодорхойлов.

Хүснэгт 1.1 Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)

RQ	Судалгааны асуулт	Хэмжих шалгуур үзүүлэлт
RQ1	Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр найдвартай ажиллах уу?	Ерөнхий ангиллын чанар (accuracy/F1), мөн өндөр итгэлцэлтэй дохионы дэд багц дахь чанар
RQ2	Шүүгдсэн дохио бодит гүйцэтгэл дээр үнэхээр арилжаа болж хэрэгжих үү?	Дохионы гүйцэтгэлийн хувь (execution rate), амжилттай арилжааны хувь (win rate), win rate-ийн Wilson 95% итгэлцлийн интервал
RQ3	Тогтмол эрсдэлийн дүрэмтэй үед систем 1 жилийн тестийн цонхонд эерэг хүлээгдэж буй өгөөж болон тогтвортой балансын өсөлттэй ажиллах уу?	Эцсийн үлдэгдэл ба нийт өгөөж, нэг арилжааны хүлээгдэж буй өгөөж (Expectancy, R), сценарийн хэлбэлзэл (балансын CV)

2. Судалгааны сэдвийн онол, өнөөгийн түвшин

2.1. Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

Уламжлалт машин сургалтын аргууд

Санхүүгийн зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн өмнөх судалгаанууд нь голчлон нейрон сүлжээ болон тулгуур векторын машин (SVM) зэрэг аргад төвлөрч байсан. Kamruzzaman, Sarker нар (2003) нь нейрон сүлжээгээр валютын ханш таамаглахад 81% (in-sample) нарийвчлалд хүрсэн боловч нэг валютын хослолд хязгаарлагдаж, хэт нийцлийн асуудал болон бодит орчны туршилтын үнэлгээ хангалтгүй байсан [4]. Kumar, Thenmozhi нар (2006) нь SVM болон Random Forest-ийн харьцуулалтад зах зээлийн нөхцөл өөрчлөгдөхөд загварын тогтвортой байдал буурах эрсдэлийг онцолсон [5].

Санамсаргүй ой (random forest) болон градиент нэмэгдүүлэлт (gradient boosting) аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings тэргүүтэй судлаачид (2015) нь хувьцааны ханшийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц гарсан** болохыг тогтоосон [6]. Харин Форекс зах зээлд ансамбль аргыг хэрэглэсэн эмпирик харьцуулалтын судалгаа хангалттай хуримтлагдаагүй байна.

Гүн сургалтын аргууд

Сүүлийн жилүүдэд урт-богино хугацааны санах ой (long short-term memory, LSTM) болон гүн нейрон сүлжээ (deep neural network, DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer, Krauss нар (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang тэргүүтэй судлаачид (2019) нь санхүүгийн цаг хугацааны цуваанд гүн сургалтын хэрэглээг системтэй тоймлон нэгтгэсэн [8].

Форекс зах зээлд тусгайлан чиглэсэн судалгааны хувьд Yildirim тэргүүтэй судлаачид (2021) гадаад валютын өдрийн өгөгдөл дээр LSTM загварыг техник болон макро эдийн засгийн үзүүлэлттэй хослуулан ханшийн чиглэлийн хөдөлгөөнийг таамаглах аргыг туршсан [9]. Ozbayoglu тэргүүтэй судлаачид (2020) санхүүгийн салбар дахь гүн сургалтын хэрэглээг үнийн таамаглал, портфелийн удирдлага, эрсдэлийн үнэлгээ зэрэг чиглэлээр өргөн хүрээнд тоймлон нэгтгэсэн [10]. Сүүлийн жилүүдэд PatchTST [11] болон TimesNet [12] зэрэг трансформерт суурилсан орчин үеийн архитектурууд урт хугацааны цаг хугацааны цуваа таамаглалд дэвшил гаргасан боловч эдгээр нь ерөнхий зориулалттай бөгөөд санхүүгийн олон интервалын хүснэгтэн шинж чанарын онцлогт тусгайлан тохируулагдаагүй.

Тэдгээрийн нэг сул тал нь гүн сургалтын загварууд тайлбарлах боломж сул, олон параметртэй, хэт нийцэлд эмзэг, анхны параметрээс их хамааралтай байдагт оршдог [13]. Krauss нар (2017) S&P 500 дээр LSTM болон GBDT-ийг харьцуулж, **GBDT загварууд тогтвортой үр дүн үзүүлсэн** гэж дүгнэсэн бөгөөд энэ нь судалгаанд GBDT ансамблийг сонгох гол үндэслэл болсон.

Градиент нэмэгдүүлсэн шийдвэрийн мод санхүүгийн салбарт

GBDT нь Friedman (2001)-ийн боловсруулсан аргачлал бөгөөд олон шийдвэрийн мод (decision tree)-ийг дараалан нэмж, алхам бүрд өмнөх загварын үлдэгдэл алдааг (gradient) бууруулж сургадаг [14]. Gu, Kelly, болон Xiu (2020) нь 150+ хувьсагчтай GBDT загвар хувьцааны өгөөжийг гүн сургалтаас илүү нарийвчлалтай таамагласныг тогтоосон [15]. GBDT нь хүснэгтэн өгөгдөлд тохирсон шинж чанарын харилцан үйлчлэлийг барьж авдаг, тайлбарлах боломжтой, гажиг утгад тэсвэртэй гэсэн давуу талтай. XGBoost [2], LightGBM [3], CatBoost [16] нь тус бүрийн онцлог (L1/L2 тогтмолжуулалт,

хурд, нэвчилтийн эрсдэл бууруулалт) бүхий орчин үеийн хэрэгжүүлэлтүүд боловч гурвыг нэгтгэн WFV болон нэвчилтийн хяналттай Форекс зах зээлд туршсан эмпирик нотолгоо хомс байна.

Ансамбль аргуудын хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [17]. Breiman (2001) санамсаргүй ой аргаар олон модыг параллель сургаж, дундажлах (average) замаар хэлбэлзэл (variance)-ийг бууруулсан [18]. Sezer тэргүүтэй судлаачид (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол өндөр гүйцэтгэлтэй байдгийг** дурдсан [19].

Өмнөх судалгаануудын хүрэн дэх нээлттэй асуудлууд

Дээр дурдсан ажлуудаас энэ судалгааны хувьд хамааралтай гурван нээлттэй асуудлыг тодорхойлов:

- **Форекс зах зээлийн онцлог тусгагдаагүй:** Судалгааны ихэнх нь хувьцааны зах зээлд төвлөрсөн тул 24/5 үргэлжлэх Форекс зах зээлийн өгөгдлийн онцлог, олон хугацааны интервалын нэгдсэн нөлөөг үнэлсэн ажил хомс байна.
- **GBDT ансамблийн харьцуулалт дутуу:** XGBoost, LightGBM, CatBoost-ийг нэг орчинд ансамбль хэлбэрээр харьцуулан, WFV болон нэвчилтийн хяналттай нэгтгэсэн эмпирик нотолгоо хязгаарлагдмал.
- **Практик хэрэгжүүлэлт хамрагдаагүй:** Загварын нарийвчлалаас эхлэн мобайл аппликейшн хүртэлх бүрэн цогц системийн үнэлгээг нэг судалгааны хүрээнд хийсэн ажил ховор.

2.2. Шинж чанаруудын судалгаа

Lo болон бусад (2000) нарийвчилсан статистик тестүүдээр **техник аргууд ач холбогдолтой үр дүн өгч чаддаг** болохыг нотолж Fama (1970)-ийн EMH онолыг тодорхой хэмжээнд эргэлзэлд оруулсан [20, 21]. Olson (2004) нь **ганц шинж чанар тогтвортой ашиг өгөх боломжгүй** гэж дүгнэж, хугацааны интервал өөрчлөгдөхөд индикаторын үр дүн мөн өөрчлөгддөг тул олон шинж чанарыг хослуулан, олон хугацааны хүрээг зэрэг ашиглах шаардлагыг онцолсон [22]. Brock нар (1992), Marshall нар (2008) бодит орчны туршилтад спрэд, гулсалт зэрэг зардлуудыг тусгах зайлшгүй шаардлагыг нотолсон [23, 24].

Park, Irwin нар (2007) 95 судалгааг тоймлон техник аргуудын үр дүн буурч байгааг зах зээлийн дасан зохицох чадварын илрэл гэж тайлбарласан [25] — энэ нь шинж чанарыг ML загварт хослуулан хэрэглэх үндэслэлийг бэхжүүлнэ. Энэхүү судалгаанд олон хугацааны интервалын шинж чанарыг хослуулан ашигласан нь өмнөх нэг интервалд хязгаарлагдсан ажлуудаас ялгарах онцлогтой; шинж чанарын инженерчлэлийн нарийвчилсан аргачлалыг §3.4.2-т үзүүлэв.

2.3. Урагш гүйлгэн баталгаажуулалт

Уламжлалт k-fold cross-validation нь санхүүгийн цуваа өгөгдөлд цаг хугацааны дарааллыг зөрчиж, ирээдүйн мэдээлэл (look-ahead bias) ашиглах эрсдэлтэй. Pardo (2008) нь урагш гүйлгэн баталгаажуулалт (WFV) нь ирээдүйн өгөгдлийг сургалтаас тусгаарлаж, бодит арилжааны нөхцөлийг

дуурайдаараа давуу болохыг нотолсон [26]. Bailey нар (2014) **олон параметрийн тохируулга нь түүврийн гадуурх үр дүнг муутгадаг** гэж анхааруулсан [27]. Энэ дүгнэлтэд тулгуурлан судалгаанд цаг хугацааны дарааллыг хадгалсан сургалт/баталгаажуулалт/тестийн хуваалтыг ашигласан; нарийвчилсан хуваарийг §3-т үзүүлэв.

2.4. ML serving дамжлага ба мобайл аппын архитектур

React Native [28] нь нэг кодын сууриар Android аппликейшн хурдан хөгжүүлэхэд тохиромжтой [29]. Flask нь хөнгөн WSGI фреймворк бөгөөд ML загварыг REST API-аар туршихад тохиромжтой [30]. ML системийн судалгааны ихэнх нь offline метрикүүдэд төвлөрдөг бол энэ судалгаанд загварын үнэлгээг API latency, мэдээлэл хүргэлтийн чанар зэрэг системийн ажиллагааны үнэлгээтэй нэгтгэн хэмжсэн.

2.5. Төсөөтэй системүүд ба судалгааны цоорхой

Зах зээлд AlgoTrade 3 (Daily timeframe-д суурилсан симуляци) болон Tradlgo (no-code AI стратеги) зэрэг апп байдаг ч эдгээр нь бодит цагийн олон интервалын ML дохиог мобайл хэрэглэгчид хүргэх зорилготой биш. Freqtrade (FreqAI модул) болон QuantConnect зэрэг нээлттэй эхийн системүүд ML арилжааны дэд бүтцийн жишээ болдог боловч автомат арилжааны бот зориулалттай, хэрэглэгчдэд ээлтэй мобайл интерфэйсгүй. “Predictrix” нь шийдвэр гаргалтыг дэмжих зорилготой мобайл аппликейшний судалгааны прототип болохоороо ялгарна.

2.6. Үндсэн судалгаануудтай харьцуулсан тойм

Хүснэгт 2.1 нь хамгийн ойр төстэй дөрвөн ажилтай харьцуулсан үндсэн ялгануудыг нэгтгэв. Тус судалгаа нь Krauss нарын (2017) GBDT-ийн санхүүгийн давуу талын дүгнэлтийг Форекс домэйнд өргөтгөж, гурван загварыг (XGBoost, LightGBM, CatBoost) ансамбль хэлбэрээр нэг орчинд харьцуулсан анхны эмпирик ажлуудын нэг болж байна. Fischer, Krauss (2018) нь LSTM-ийг S&P 500 дээр туршсан бол энэ ажил GBDT-г Форекс зах зээлийн олон интервалын онцлогт тохируулсан. Yildirim нарын (2021) нэг хугацааны интервал ашигласан хязгаарлалтыг M1–H4 6 интервалын нэгтгэлээр давсан. Ozbayoglu нарын (2020) гүн сургалтад чиглэсэн тоймоос ялгарч хүснэгтэн өгөгдөлд тохирсон GBDT-г сонгосны үндэслэлийг тайлбарласан мөн загвар сургалтаас мобайл аппликейшн хүрэх end-to-end ML serving дамжлагыг ажиллах прототип хэлбэрт бүтээсэн.

Хүснэгт 2.1 Холбогдох судалгаатай харьцуулсан үндсэн ялгаа

Судалгаа	Загвар	Зах зээл / интервал	Энэ ажлын ялгаа
Krauss нар (2017)	GBDT vs LSTM	S&P 500, өдрийн	3 GBDT ансамбль, Форекс, M1–H4
Fischer, Krauss (2018)	Ганц LSTM	S&P 500, өдрийн	GBDT ансамбль + WFV + олон интервал
Yildirim нар (2021)	LSTM + макро	EUR/USD, өдрийн	GBDT ансамбль + 6 интервал + мобайл систем
Ozbayoglu нар (2020)	Гүн сургалтын тойм	—	GBDT-ийн хүснэгтэн давуу тал, end-to-end систем

2.7. Судалгааны ажлын шинэлэг тал

Дээрх нээлттэй асуудлууд болон харьцуулсан тоймд тулгуурлан энэ судалгаа дараах хувь нэмрийг оруулна: (1) XGBoost, LightGBM, CatBoost гэсэн гурван загварыг ансамбль хэлбэрээр нэг орчинд туршсан; (2) M1–H4 6 хугацааны интервалын 48 шинж чанар ашигласан; (3) WFV болон нэвчилтийн хяналт бүхий цаг хугацааны тусгаарлалтыг бодит MT5 өгөгдөл дээр хэрэгжүүлсэн; (4) загвар сургалтаас мобайл аппликейшн хүртэлх end-to-end ML serving дамжлагыг ажиллах прототип хэлбэрт баримтжуулсан.

3. Судалгааны арга зүй

3.1. Судалгааны арга барил


Энэхүү судалгаа нь **Зохиомжлох шинжлэх ухааны** (design science research – DSR) [31] арга зүйд суурилсан бөгөөд ML ансамбль загвар бүхий дохионы системийг артефакт болгон бүтээж, MetaTrader 5-ийн бодит нөхцөлд (спрэд, гулсалт) туршилтаар баталгаажуулсан [32]. Судалгааны процесс 7 давталтын хөгжүүлэлтийн мөчлөгөөр явагдсан бөгөөд үе шат бүрийн гол өөрчлөлтийг Зураг 3.1-т харуулав.



Зураг 3.1 7 давталтын явцад шинж чанар ба загварын тоог цөөлсөн байдал

3.2. Системийн ерөнхий бүтэц

Систем нь санхүүгийн өгөгдлийг хиймэл оюуны ансамбль загвараар боловсруулан дохио үүсгэж, мобайл аппаар дамжуулан арилжаачдад хүргэдэг. Системийн **ерөнхий архитектур**-ыг Зураг 3.2-т харуулав. Гүйцэтгэлийн орчны нарийвчилсан UML байршуулалтын диаграмм (deployment diagram)-ыг §3.8-т (Зураг 3.9) тусад нь харуулсан.



Зураг 3.2 Системийн архитектур

Зураг 3.2-т харуулсан архитектур нь дөрвөн үндсэн бүсээс бүрдэнэ.

Хэрэглэгчийн хэсэг (дээд тал): хэрэглэгчид React Native мобайл апп (Android · iOS)-ын тусламжтайгаар системд хандана. Хүсэлт DNS-ээр дамжин шууд сервер рүү чиглэгдэнэ.

Сервер (төв хэсэг): нэг виртуал машинд Flask + Gunicorn (API сервер) болон *фон процесс* (background worker) гэсэн хоёр процесс зэрэгцэн ажиллана. API сервер нь `@app.route` декораторт бүртгэсэн 30 HTTP интерфэйсийг (endpoint) гаргадаг. Фон процесс нь thread-д суурилсан хуваарилагчаар (scheduler) дохио үүсгэх (60 сек), мэдээ шинэчлэх (30 мин), мэдэгдэл илгээх, хослолын шинжилгээ хийх даалгавруудыг гүйцэтгэдэг. Мөн GBDT (LightGBM + XGBoost + CatBoost) ансамблийн таамаглалыг (inference) тус процесс хариуцна. Хоёр процессыг APP_PROCESS_ROLE орчны хувьсагчаар (api / worker / all) тохируулна.

Серверийн доод хэсэгт өгөгдлийн давхарга байрладаг. *Кэш сан* нь сонголтот Redis (хүсэлтийн хязгаарлалтад (rate limiting) хэрэглэгддэг ба байхгүй үед санах ойн нөөц шийдэлд (fallback) шилждэг). *MongoDB* нь үндсэн агуулах болж бүх төлөвийг (users, signals, refresh_tokens, push_tokens, news_analysis, ai_insights, analysis_jobs, job_locks гэх мэт цуглуулга) хадгална.


Дотоод сервис (зүүн тал, улаан): системийн дотоодоос ашиглах туслах сервисүүд — *И-мэйл* нь Flask-Mail SMTP (Gmail) ашиглан баталгаажуулах болон нууц үг сэргээх кодыг илгээдэг; *Даалгаврын дараалал* нь analysis_jobs цуглуулга дахь LLM зах зээлийн шинжилгээний даалгаврын дараалал ба job_locks (TTL индекстэй) хуваарилагдсан түгжээгээс бүрдэнэ; *Хяналт* нь /health интерфэйс болон Fly.io лог-ыг хамардаг.

Гуравдагч талын API (баруун тал, ногоон): дөрвөн гадны API нь нэгдсэн нэг сувгаар фон процесс руу өгөгдөл нийлүүлдэг — *Yahoo Finance* (yfinance-аар OHLCV ханш), *AlphaVantage* (мэдээний сэтгэлгээний шинжилгээ), *TradingView* (эдийн засгийн хуанли), *Gemini API* (21 түлхүүрийн ротацтай LLM шинжилгээ). *Expo Push* нь зүүн-дээд буланд тусдаа байрласан бөгөөд сервер→мобайл чиглэлийн түлхэлтийн мэдэгдэл (push notification) хүргэх суваг (тасархай ягаан сум).

Офлайн сургалт (доод хэсэг, ашиглалтын орчноос тусдаа): түүхэн OHLCV (2015–2024) өгөгдөл дээр GBDT ансамблийг сургаж model.pkl артефакт үүсгэнэ. Энэ артефакт нь фон процесс руу «байршуул» сумаар хуулагдаж ашиглалтын таамаглалд хэрэглэгдэнэ. Гүйцэтгэлийн орчны нарийвчилсан UML байршуулалтын диаграммыг §3.8 (Зураг 3.9)-аас үзнэ үү.

3.3. Өгөгдлийн урсгал

Системд өгөгдөл хэрхэн урсаж, боловсруулагддагийг Зураг 3.3-т Gane–Sarson нотацын дагуу үзүүлэв. Гадаад эх сурвалжаас (Yahoo Finance, AlphaVantage, TradingView) өгөгдөл орж ирээд, серверийн процессуудаар боловсруулагдан MongoDB цуглуулгад хадгалагдсаны дараа REST API-аар дамжин хэрэглэгчдэд хүрнэ. Сервер дээр дохио үүсгэх логик 60 секундын, мэдээ боловсруулах логик 30 минутын давтамжтай ажилладаг (цаг хугацааны хяналт нь DFD-ийн илэрхийллийн хүрээнээс гадуур тул диаграммд тусгаагүй). Олон instance ажиллах үед эдгээр процессын зөв нэгдмэл байдлыг MongoDB job_locks цуглуулга дахь хуваарилагдсан түгжээгээр хангадаг.



Зураг 3.3 Өгөгдлийн урсгал

Системийн өгөгдлийн урсгалд Gemini API-д суурилсан LLM бүрэлдэхүүнийг нэгтгэсэн бөгөөд энэ нь GBDT-ийн таамгийн тайлбар хураангуйг мобайл аппын харагдах хэсэгт MongoDB-д тусдаа талбараар хадгалдаг. LLM нь BUY/HOLD/SELL шийдвэрт нөлөөлөхгүй; тоон үнэлгээг цаашдын судалгаанд үлдээсэн.

3.4. Өгөгдөл бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5 платформуос EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 3.1 нь интервал бүрийн өгөгдлийн хэмжээг харуулав.

Хүснэгт 3.1 Түүхэн өгөгдлийн хэмжээний хураангуй

Хугацааны интервал	Мөрийн тоо	Хугацаа
M1 (1 минут)	~3,700,000	2015–2024
M5 (5 минут)	~740,000	2015–2024
M15 (15 минут)	~247,000	2015–2024
M30 (30 минут)	~123,000	2015–2024
H1 (1 цаг)	~62,000	2015–2024
H4 (4 цаг)	~15,500	2015–2024

Олон цагийн интервал бүхий өгөгдлийг хослуулах замаар загвар нь зах зээлийн богино хугацааны хэлбэлзэл (M1, M5), дунд хугацааны чиг хандлага (M15, M30), мөн урт хугацааны бүтэц (H1, H4)-ыг нэгэн зэрэг харах боломжтой болсон. Энэ олон хугацааны интервалын арга нь шинж чанарын инженерчлэлийн “олон хугацааны хүрээ” (multiple timeframe analysis) зарчимд нийцдэг [33].

Шинж чанарын инженерчлэл

Интервал бүрээс 8 шинж чанар тооцоолж, нийт 48 шинж чанар бүхий матриц үүсгэсэн. Хүснэгт 3.2 нь шинж чанаруудыг жагсаав.

Домэйны нэр томьёо: Candle (мөн OHLCV бар гэнэ) нь тодорхой хугацааны интервалын нээлт (open), дээд (high), доод (low), хаалт (close) ханш болон эргэлт (volume)-ийн таван утгыг хамарсан нэгдмэл өгөгдлийн цэг. Жишээлбэл, M1 интервалын нэг candle нь 1 минутын хугацааны дүн юм. RSI нь Relative Strength Index (харьцангуй хүч индекс), ATR нь Average True Range (дундаж жинхэнэ хэлбэлзэл), SMA нь Simple Moving Average (энгийн хөдөлгөөний дундаж)-ийн товчлол.

Хүснэгт 3.2 Шинж чанарын жагсаалт (интервал бүрд)

№	Шинж чанар	Тайлбар
1	close	Тухайн candle-ийн хаалтын ханш
2	rsi	RSI (14 candle) — хэт худалдсан/хэт худалдан авсан байдлыг 0–100 хуваарьт хэмждэг импульс шинж чанар
3	atr	ATR (14 candle) — сүүлийн 14 candle-ийн дундаж жинхэнэ хэлбэлзэл; зах зээлийн эрсдэлийн хэмжүүр
4	ma_5	Сүүлийн 5 candle-ийн хаалтын ханшийн хөдөлгөөний дундаж (SMA) — богино хугацааны чиглэл
5	ma_20	Сүүлийн 20 candle-ийн SMA — дунд хугацааны чиглэл
6	ma_50	Сүүлийн 50 candle-ийн SMA — урт хугацааны чиглэл
7	volatility	Сүүлийн 20 candle-ийн хаалтын ханшийн стандарт хазайлт; зах зээлийн тайван эсвэл хэлбэлзэлтэй байдлын үзүүлэлт
8	returns	Өмнөх candle-тэй харьцуулсан ханшийн өөрчлөлтийн хувь (pct_change)

Эхний шатанд 75 боломжит шинж чанарыг туршсаны дараа эцсийн матрицад 8 шинж чанарыг тогтмол болгосон: чиг хандлага (close, MA-5/20/50), импульс (RSI), хэлбэлзэл ба эрсдэл (ATR, volatility, returns). MACD зэрэг MA-аас гарвалтай нэмэлт индикаторуудыг давхардал үүсгэх тул

хасав. Шинж чанаруудыг `_1min_4h` дагавраар ялгаж, нэгдмэл 1 минутын суурь цувааг 6 интервалд `pandas.resample()` хийгээд интервал бүрд 8 индикатор тооцон `merge_asof(backward)` аргаар нэгтгэснээр $8 \times 6 = 48$ хэмжээт шинж чанарын вектор $\mathbf{x} \in \mathbb{R}^{48}$ үүсгэдэг.

Шошго (label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) ханшийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

Домэйны нэр томьёо: Пипс (pip, percentage in point) нь Форекс зах зээлд ханшийн хамгийн бага өөрчлөлтийн нэгж; EUR/USD-д 1 пипс = 0.0001. Зах зээлийн хэлбэлзлийг тоолоход хэрэглэгддэг.

$$\text{label} = \begin{cases} \text{BUY (+1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (3.1)$$

Үүнд Δ_{up} нь ирээдүйн 240 минутын дээд ханш ба одоогийн хаалтын зөрүү, Δ_{down} нь доод ханшийн зөрүү (пипсээр); 30 пипсийн босго нь EUR/USD-ийн дундаж өдрийн ATR(14) (≈ 80 пипс)-ийн 37%; 1.5 давамгайлалыг [1.2, 2.0] мужийг туршиж шошгын тэнцвэрийг харгалзан сонгосон.

Томьёоны бодит хэрэгжилтийг Алгоритм 1-д псевдокод хэлбэрээр харуулав.

Algorithm 1 Шошго үүсгэх алгоритм

Оролт: OHLC цуваа $\{(t_i, o_i, h_i, l_i, c_i)\}_{i=1}^N$, ирээдүйн цонх $W = 240$ мин, босго $\theta = 30$ пип, давамгайлал $\rho = 1.5$

Гаралт: Шошгын вектор $\mathbf{y} \in \{-1, 0, +1\}^N$

```

1: pip_size  $\leftarrow 0.0001$  // зөвхөн EUR/USD-д
2: for  $i = 1, \dots, N - W$  do
3:    $H_{\max} \leftarrow \max_{j \in [i+1, i+W]} h_j$ 
4:    $L_{\min} \leftarrow \min_{j \in [i+1, i+W]} l_j$ 
5:    $\Delta_{\text{up}} \leftarrow (H_{\max} - c_i) / \text{pip\_size}$ 
6:    $\Delta_{\text{down}} \leftarrow (c_i - L_{\min}) / \text{pip\_size}$ 
7:   if  $\Delta_{\text{up}} \geq \theta$  and  $\Delta_{\text{up}} > \rho \cdot \Delta_{\text{down}}$  then  $y_i \leftarrow +1$  // BUY
8:   else if  $\Delta_{\text{down}} \geq \theta$  and  $\Delta_{\text{down}} > \rho \cdot \Delta_{\text{up}}$  then  $y_i \leftarrow -1$  // SELL
9:   else  $y_i \leftarrow 0$  // HOLD
10: end for
11:  $y_{N-W+1}, \dots, y_N \leftarrow \text{NaN}$  // сүүлийн  $W$  candle-д шошго байхгүй
12: буцаах:  $\mathbf{y}$ 
```

Нэвчилтийн хяналт. Шинж чанарын цонх $[i - K + 1, i]$ ба шошгын цонх $[i + 1, i + W]$ давхцахгүй тул мэдээллийн нэвчилт алгоритмын түвшинд хязгаарлагдсан.

2015–2022 оны M1 сургалтын өгөгдөл (3,726,046 цэг) дээрх ангиллын хуваарилалт нь HOLD 75.5% (2,812,515 цэг), BUY 12.2% (454,999 цэг), SELL 12.3% (458,532 цэг) хэлбэртэй гарсан. Энэхүү тэнцвэргүй байдлыг зохицуулахын тулд LightGBM ба XGBoost загваруудад `scale_pos_weight =`

neg/pos параметрийг тохируулсан. Ангилал тус бүрийн загвар дээрх нөлөө болон BUY/SELL ангийн recall-ийн дүн шинжилгээг §4.2-т нэгтгэв.

Шошго ба шинж чанарын цагийн нийцлийн аудит (leakage audit)

Мэдээллийн нэвчилт гэдэг нь загварын сургалтад ирээдүйн мэдээлэл санамсаргүй нэвтрэх үзэгдэл бөгөөд энэ нь тестийн нарийвчлалыг хиймлээр өндөр харуулдаг. Шошго үүсгэх ба олон интервалын шинж чанар нэгтгэх үеийн гол шаардлага нь шийдвэрийн агшин (t_0)-д зөвхөн тухайн мөчөөс өмнө мэдэгдэх боломжтой мэдээлэл ашиглах явдал. Энэ нөхцөлийг хатуу хэлбэрээр томъёолбол:

$$t_{\text{feature}} \leq t_0, \quad \text{label window} = (t_0, t_0 + 240 \text{ минут}] \tag{3.2}$$

Шинж чанар үүсгэх ба шошго тооцох үе шатанд систем цагийн нийцлийн дүрмийг тогтвортой мөрддөг (томъёо 3.2). Бүх компонентын нарийвчилсан хяналтын дүрмийг Хавсралт А-д тайлбарласан. `merge_asof(backward)` болон хугацааны тусгаарлалтын дүрэм нь нэвчилтийн эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй.

WFV-ийн олон огтлолын алхамт логик

Судалгаанд урагш гүйлгэн баталгаажуулалтыг цаг хугацааны дараалал хадгалсан **олон огтлол, өргөтгөх сургалтын цонх** (expanding window) протоколоор хэрэгжүүлсэн. KPI-ийн дэлгэрэнгүй үнэлгээ **Fold 5** огтлол (2015–2022 / 2023 / 2024)-д суурилсан бөгөөд Хүснэгт 3.3 тухайн огтлолын хуваалтыг нэгтгэн харуулна. Олон огтлолын ерөнхий концепцын схемийг Хавсралт Б-аас үзнэ үү.

Хүснэгт 3.3 Урагш гүйлгэн баталгаажуулалтын өгөгдлийн хуваалт

Бүлэг	Хугацаа	Candle-ын тоо	Зорилго
Сургалт	2015–2022	~2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	~371,000	Эрт зогсоох (early stopping), calibration туршилтын ажиглалт (10%)
Тест	2024	~371,000	Эцсийн үнэлгээ (10%)

Зураг 3.4 нь энэхүү хуваалтыг цаг хугацааны тэнхлэг дээр дүрслэн харуулав. Сургалтын өгөгдөл (80%), баталгаажуулалтын өгөгдөл (10%), тестийн өгөгдөл (10%) нь цаг хугацааны дарааллаар ялгагдана. **Чухал:** WFV нь зөвхөн *офлайн сургалтын үе шатанд* (хөгжүүлэгчийн компьютер дээр) хэрэгждэг; production-д ажиллаж буй Flask серверт WFV логик байхгүй бөгөөд эцсийн сонгогдсон загвар (`model.pkl`) л байршуулагдсан.



Зураг 3.4 Урагш гүйлгэн баталгаажуулалт (offline сургалтын үе шат) — Fold 5-ын өгөгдлийн хуваалт

Тайлбар: KPI үнэлгээнд ашигласан Fold 5-ийн бодит хуваалтыг Зураг 3.4-т харуулсан. WFV-ийн олон огтлолын ерөнхий концепцын схем болон алхамт логикийг Хавсралт Б-аас (Зураг Б.1) үзнэ үү.

3.5. AI загварын бүтэц ба сургалт

Ансамбль загварын архитектур

Системийн загвар нь гурван GBDT (gradient boosted decision trees) загвараас бүрдсэн ансамбль бөгөөд олон модны нэгтгэсэн архитектураар санхүүгийн хүснэгтэн өгөгдөлтэй сайн нийцдэг [2]. Загвар бүр ижил 48 шинж чанарыг хүлээн авч BUY, SELL, HOLD гурван ангиллын магадлалыг тус тус тооцоолно.

Загварын математик тодорхойлолт

Сургалтын өгөгдөл $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, $\mathbf{x}_i \in \mathbb{R}^{48}$, $y_i \in \{0, 1, 2\}$ (HOLD=0, BUY=1, SELL=2). Суурь загвар $k \in \{\text{LGB, XGB, CAT}\}$ нь давталтын *gradient boosting* аргачлалаар T шийдвэрийн модны нийлбэрийг сурдаг:

$$F_k^{(T)}(\mathbf{x}) = \sum_{t=1}^T \eta \cdot f_t(\mathbf{x}), \quad f_t \in \mathcal{F} \quad (3.3)$$

Үүнд $\mathcal{F}$ нь шийдвэрийн модны функцын орон зай, $\eta = 0.03$ нь learning rate, f_t нь t -р алхамын үед өмнөх ансамблийн *градиентыг бууруулахаар* сурсан мод юм:

$$f_t = \arg \min_{f \in \mathcal{F}} \sum_{i=1}^N \ell(y_i, F_k^{(t-1)}(\mathbf{x}_i) + f(\mathbf{x}_i)) + \Omega(f) \quad (3.4)$$

энд $\Omega(f)$ нь модны нарийн төвөгшилт хариуцсан тогтмолжуулалт. Гурван анги тул логит $\mathbf{z} \in \mathbb{R}^3$ -ыг softmax-аар магадлал болгон хувиргана:

$$P_k(y = c \mid \mathbf{x}) = \frac{\exp(z_c)}{\sum_{c'=0}^2 \exp(z_{c'})}, \quad \mathbf{z} = F_k(\mathbf{x}) \quad (3.5)$$

Алдагдлын функц (loss function)

Гурван загвар бүгд **multi-class cross-entropy** (мөн *softmax loss*, *log-loss* гэж нэрлэдэг) алдагдлын функцыг минимумжуулдаг:

$$\mathcal{L}(\mathcal{D}; \theta_k) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=0}^2 \mathbb{I}[y_i = c] \cdot \log P_k(y_i = c \mid \mathbf{x}_i; \theta_k) + \lambda_1 \|\theta_k\|_1 + \lambda_2 \|\theta_k\|_2^2 \quad (3.6)$$

Үүнд θ_k нь k -р загварын бүх параметрийн вектор, $\mathbb{I}[\cdot]$ нь индикатор функц (зөв ангилалд 1, бусдад 0), λ_1, λ_2 нь L1 ба L2 тогтмолжуулалтын хүчний коэффициент (Хүснэгт E.1-аас LightGBM ба XGBoost-д $\lambda_1 = 0.10, \lambda_2 = 1.0$; CatBoost-д L2 коэффициент (12_leaf_reg) 3.0). HOLD ангиллын давамгайллаас үүсэх тэнцвэргүй байдлыг зохицуулахын тулд LightGBM ба XGBoost загваруудад scale_pos_weight параметрийг сөрөг ба эерэг ангийн харьцаагаар (neg/pos) тохируулсан.

Ансамблийн нэгтгэх дүрэм

Гурван загварын магадлалыг **зөөлөн санал хураалтаар** тэгш жингээр дундажилж эцсийн магадлалыг гаргана:


$$P_{\text{ensemble}}(c \mid \mathbf{x}) = \sum_{k=1}^3 w_k \cdot P_k(c \mid \mathbf{x}), \quad w_k = \frac{1}{3} \quad (3.7)$$

Ангилалын шийдвэр болон итгэлцлийг доорх томъёогоор тодорхойлно:

$$\hat{c} = \arg \max_c P_{\text{ensemble}}(c \mid \mathbf{x}), \quad \text{conf} = \max_c P_{\text{ensemble}}(c \mid \mathbf{x}) \quad (3.8)$$

Үүнд $\hat{c}$ нь сонгосон ангилал, $\text{conf} \in [\frac{1}{3}, 1]$ нь ансамблийн итгэлцэл болно. Зураг 3.5 нь энэхүү бүтцийг харуулав.

Ансамблийн жинг $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ тэгш авсан шалтгаан нь нэг огтлолд жинг оновчлох замаар үүсэх data-snooping эрсдэлээс зайлсхийх зорилготой. HOLD ангилал сонгогдсон үед систем шинэ байрлал нээхгүй (no-trade state).



Зураг 3.5 GBDT ансамбль загварын архитектур

Гурван загварыг ансамбль хэлбэрээр хослуулсан шалтгаан нь тус бүр өсөлтийн стратеги, хурд, хэт нийцлийн эрсдэлийн хувьд бие биенээ нөхдөгт оршино: LightGBM (leaf-wise, маш өндөр хурд), XGBoost (level-wise, L1/L2 нормчлол), CatBoost (symmetric, хамгийн бага нэвчилтийн эрсдэл). Зөөлөн санал хураалтын дараа ангилал ($\arg \max_c \bar{p}_c$) болон итгэлцэл ($\max_c \bar{p}_c$) хоёр зэрэгцэн авагдана. Өөрөөр хэлбэл итгэлцлийн утга нь ансамблийн дундаж магадлалын хамгийн их утга болно.

Probability calibration (Platt scaling)-ийг туршилтын үе шатанд офлайн туршиж үзсэн боловч ансамбль өөрөө аль хэдийн зохистой тохируулагдсан магадлал гаргаж байв. Иймд калибровкыг production-д идэвхгүй болгож, түүхий $\max_c \bar{p}_c$ -г итгэлцлийн босготой шууд харьцуулдаг.

Гиперпараметр сонголтын протокол


Гиперпараметрийг grid search-ийн оронд тогтвортой байдлын протоколоор сонгосон: train-val зөрүү $< 5\%$, conf ≥ 0.90 дэд мужийн нарийвчлал $> 90\%$, шинж чанарын top-10 жагсаалтын Jaccard коэффициент > 0.7 гэсэн гурван шалгуурыг зэрэг хангах утгуудыг хайсан. Ансамбль сургалтыг random_state=42 нэг seed-ийн протоколоор явуулсан. Гол сонголтууд: $n_{\text{estimators}} = 500$, $\eta = 0.03$, $\text{max_depth} \in \{5, 6\}$, $\text{reg_lambda} \in \{1.0, 3.0\}$, $\text{early_stopping_rounds} = 50$. Хэт нийцлээс сэргийлэх зургаан арга хэмжээ (модны гүнийг хязгаарлах, бага learning rate, эрт зогсоолт, L1/L2 нормчлол, WFV, шинж чанарын цөөрөлт) бүгд хослуулан хэрэгжүүлсэн. Гурван загварын бүх гиперпараметрийн нарийвчилсан утгуудыг ялгаа болон үүргийн тайлбартай нь **Хавсралт Е-д** (Хүснэгт Е.1) нэгтгэв.

3.6. Дохио үүсгэх систем

Дохионы шүүлтүүр ба тоон үр дүн

Процесс P2 (Зураг 3.3) дохиог хоёр нөхцлөөр шүүгээд D1 (signals) агуулахад хадгална: (1) ансамблийн таамагласан анги BUY эсвэл SELL байх (HOLD биш) ба (2) $M1 ATR \geq 4$ пипс. Автоматаар үүсгэх мөчлөг нь итгэлцлийн босгыг энэ шатанд хэрэглэдэггүй; дээрх хоёр нөхцлийг хангасан дохио бүрийг insert үйлдлээр MongoDB-д хадгална. Итгэлцлийн босго (анхдагчаар 0.90) нь дараа нь Expo Push мэдэгдлийг хэрэглэгчид илгээх шатанд, хэрэглэгч бүрийн хувийн тохиргооны дагуу хэрэглэгдэнэ. ATR шүүлтүүр нь зах зээлийн идэвхгүй хугацаанд (шөнийн хаагдалт, долоо хоногийн эцэс) буурсан хэлбэлзлийн үед үүсэх сул дохиог хасдаг. Аль нэг нөхцөл хангагдаагүй, эсвэл өмнө нь ижил минутын дохио бүртгэгдсэн бол тухайн мөчийн боловсруулалт алгасагдана.

2025 оны бодит өгөгдөл дээрх тоон үр дүн (стратегийн гүйцэтгэлийн дэлгэрэнгүй үнэлгээг §4-аас үзнэ үү): нийт 359,639 таамгаас итгэлцэл ≥ 0.90 ба $ATR \geq 4$ пипсийн нөхцөлд 3,567 (1.0%) дохио тэнцсэн. Хоёр шүүлтүүрийн хооронд корреляц өндөр байна: загвар итгэлцэл өндөр таамаглал гаргахдаа зах зээлийн хэлбэлзэл өндөр үеийг ихэвчлэн сонгодог тул ATR шүүлтүүр зөвхөн ≈ 33 нэмэлт дохиог хасдаг. Гүйцэтгэлийн талд MT5 EA-ийн MaxPositions=1 дүрэм (нэг агшинд зөвхөн нэг нээлттэй байрлалтай байх) 3,567 дохиог 230 хэлцэл хүртэл багасгадаг бөгөөд энэ нь загварын дотоод бус, гүйцэтгэлийн талын шүүлтүүрт хамаарна. Зураг 3.6 нь энэ дөрвөн алхамт юүлүүрийн процессыг харуулна.



Зураг 3.6 Дохионы шүүлтүүрийн юүлүүр: 359,639 таамгаас 230 хэлцэл хүртэл (0.90 босго)

Stop Loss ба Take Profit тооцоолол

Арилжааны эрсдэлийг хязгаарлах Stop Loss (SL) болон ашгийг хамгаалах Take Profit (TP) утгуудыг ATR-д суурилан динамикаар тооцоолсон:


$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (3.9)$$

$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (3.10)$$

ATR үржвэр 5.0 нь 7 давталтын туршилтаар 3.0–7.0 мужаас тогтвортой гүйцэтгэл өгсөн утга; TP/SL=3:1 нь ердөө 33%-ийн ялалтын хувьд ч санхүүгийн хувьд ашигтай байх математик нөхцөл; 15/45 пипсийн доод хязгаар нь санамсаргүй хөдөлгөөн болон зардлаас хамгаалдаг.

Дохионы амьдралын мөчлөгийн төлөвт автомат

Дохио нь ансамбль таамаглал гарсан мөчөөс эхлэн MT5 платформ дээр позиц хаагдах хүртэлх амьдралын мөчлөгт долоон үндсэн төлвөөр дамждаг. Энэ дарааллыг Зураг 3.7-т UML 2.5-ийн төлөвт автомат (state machine) хэлбэрээр харуулсан: үндсэн босоо тэнхлэгээр амжилттай дохионы зам, баруун талаар шүүлтүүрт татгалзсан салбар, доод хэсэгт MT5 дэх гүйцэтгэлийн нийлмэл (composite) төлөв зэрэгцэн оршино.




Зураг 3.7 Дохионы амьдралын мөчлөгийн төлөвт автомат

Дохио нь итгэлцэл ($\geq 0,90$) ба ATR (≥ 4 пип) гэсэн хоёр шүүлтүүрийг дараалан давсны дараа SL/TP-г тооцоолон MongoDB-д хадгалагдана. Дараа нь Expo Push-аар хэрэглэгчийн утсанд мэдэгдэл хүрнэ.

Хэрэглэгч MT5-д позиц нээх үед нийлмэл «Гүйцэтгэж буй» төлөвт ордог. Тус нийлмэл төлөвт TP-хяналт, SL-хяналт болон 4 цагийн таймер гэсэн гурван зэрэгцээ муж нэгэн зэрэг идэвхждэг. Аль нэгийг нь нөхцөл түрүүлж биелэх үед тухайн төлвөөр эцсийн төлөв (TP-д хүрсэн / SL-д хүрсэн / хугацаа дууссан) тодорхойлогдоно. Тоон үр дүн нь Хүснэгт 4.6-ийн баганатай шууд харгалзана.

Дохио үүсгэх дарааллын диаграмм

Дохио үүсгэх процессыг таамаглах, шүүх, хэрэглэгчид хүргэх гэсэн нэгдмэл дарааллыг Зураг 3.8-т UML 2.5 sequence diagram хэлбэрээр харуулав.



Зураг 3.8 Дохио үүсгэх дарааллын диаграмм (UML 2.5 sequence diagram)

(1) APScheduler 60 секунд тутамд SignalService-г сэрээдэг. (2)–(6) SignalService нь 6 timeframe-ийн OHLCV-г татаж, 48 шинж чанарыг тооцоолоод GBDT ансамблийн зөөлөн санал хураалтаар (class, conf) гаргана. (7)–(10) Итгэлцэл ≥ 0.90 ба $ATR \geq 4$ пип нөхцлийг хангавал SL/TP-г тооцоолж MongoDB-д хадгалаад, тухайн босгод тохирох хэрэглэгчдийн push_token-ыг түүж авна. (11)–(15) par fragment нь Expo Push (async) болон мобайл аппын REST polling гэсэн хоёр зэрэгцээ хүргэлтийн сувгийг харуулна.

3.7. MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт

MetaTrader 5-ийн Strategy Tester нь Expert Advisor (EA) алгоритмыг түүхэн OHLCV өгөгдөл дээр симуляцаар тоглуулж хэлцлийн лог (timestamp, SL, TP, ашиг/алдагдал) бичдэг бөгөөд энэ судалгаанд GBDT ансамблийн гаралтыг бодит нөхцөлтэй холбосон баталгаажуулалтын орчин болгон ашигласан.

Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэлийн логик

Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэлд эрсдэлийн удирдлагатай гүйцэтгэгч модуль ашиглаж, дохио бүр дээр байрлалын хэмжээ, итгэлцлийн босго, гулсалтын хязгаар зэрэг дүрмийг тогтмол мөрдсөн. Хүснэгт 3.4 нь энэ хэсгийн үндсэн тохиргоог харуулав.

Хүснэгт 3.4 Түүхэн өгөгдөл дээрх системийн туршилтын үндсэн тохиргоо

Параметр	Утга	Тайлбар
Арилжаа бүрийн эрсдэл	1.0%	Нэг дохион дээр авах эрсдэлийн хувь
Нэг удаагийн байрлалын дээд тоо	1	Давхар байрлал нээхээс сэргийлсэн
Итгэлцлийн доод босго	0.90	Чанарын шүүлтүүрийн үндсэн босго
Зөвшөөрөгдөх гулсалтын хязгаар	10 point	Гүйцэтгэлийн бодит нөхцөлийг тусгасан

Түүхэн өгөгдөл дээрх системийн туршилтын нөхцөл

MetaTrader 5 Strategy Tester дээр Every-tick горимд, EUR/USD хэрэгслийн бодит спрэдтэй, 2025.01.01–2026.01.01 цонхонд, \$10,000 анхны хөрөнгөөр туршилт хийсэн. 0.90 суурь шүүлтүүрийн 3,567 дохионоос гадна 0.91–0.99 мужийн урьдчилан шүүсэн багцуудыг харьцуулан ажиглав; дохио/өдөр үзүүлэлтийг 261 ажлын өдрөөр тооцсон.

Арилжааны зардлын хамралт

Туршилтын орчинд spread ба гулсалт (10 point дээд хязгаар) тусгагдсан; commission болон swap зардал тусгагдаагүй. Энэ нөхцөлийн нөлөө болон үлдэгдэл хязгаарлалтын дэлгэрэнгүй хэлэлцүүлгийг §4.6.3-т нэгтгэв.

Босго сонголтын протокол

Шалгагдсан 0.90–0.99 мужийн доод хязгаар нь баталгаажуулалтын итгэлцлийн нарийвчлалын шинжилгээнд (Хүснэгт 4.3) тулгуурласан; дээд хязгаар нь дохионы давтамж хэт цөөрөхийн урьдчилан сэргийлэлт. Босгын мужийн хүснэгт нь ажиллах үеийн динамик тааруулалт бус, **сценарийн харьцуулалт** бөгөөд 0.91 нь энэ шинжилгээний хүрээнд ажиглагдсан локал дээд цэг тул бүх нөхцөлд универсал оновчтой утга гэж дүгнэхгүй.

Үнэлгээний шалгуур үзүүлэлтүүд

Загварын болон системийн гүйцэтгэлийг дараах шалгуур үзүүлэлтүүдээр үнэлсэн. Хүснэгт 3.5 нь тэдгээрийн тодорхойлолт болон чиглэлийг харуулав.

Хүснэгт 3.5 Системийн үнэлгээний шалгуур үзүүлэлтүүд

Үзүүлэлт	Тодорхойлолт	Чиглэл
<i>Загварын ангиллын чанар</i>		
Тестийн нарийвчлал	2024 тест хуваалтын зөв ангиллын хувь	Өндөр = сайн
Өндөр итгэлцэлтэй нарийвчлал	Итгэлцэл өндөр мужийн зөв ангиллын хувь	Өндөр = сайн
<i>Сценарийн системийн үзүүлэлтүүд (Chapter 4)</i>		
Өгөөж (%)	$(B_{\text{final}} - 10,000) / 10,000 \times 100$	Өндөр = сайн
Дохио/өдөр	Нийт дохио / 261 арилжааны өдөр	Контекстээс хамаарна
Дохио тутмын ашиг	Нэг дохионд ногдох дундаж ашиг (\$)	Өндөр = сайн
Гүйцэтгэлийн хувь	Шүүгдсэн дохионоос хаагдсан арилжааны хувь	Контекстээс хамаарна
Ялалтын хувь; 95% CI	Хаагдсан арилжаан дахь TP хувь; Wilson CI	Өндөр = сайн
Expectancy (R)	TP/SL=3:1-д нэг арилжаанд хүлээгдэх өгөөж	0-ээс их = сайн
Balance CV	std/mean — эцсийн балансын хэлбэлзэл	Бага = тогтвортой
MaxDD	Оргил балансаас хамгийн их бууралт	Бага = сайн
Sharpe / Sortino / Calmar	Эрсдэлд нормчилсан өгөөжийн үзүүлэлт	Өндөр = сайн
Max losing streak	Хамгийн урт дараалсан алдагдал	Бага = тэсвэртэй

TP/SL=3:1 нөхцөлд $E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}})$ томъёогоор Expectancy тооцно; $E[R] > 0$ бол статистикийн давуу талтай.


Эрсдэлийн үзүүлэлтүүдийн тодорхойлолт: MaxDD (Maximum Drawdown) нь балансын оргил цэгээс хамгийн гүн уналтын зай. Sharpe нь илүүдэл өгөөжийг нийт хэлбэлзлээр хуваасан харьцаа; Sortino нь зөвхөн доошлох хэлбэлзлийг (downside volatility) тооцдог Sharpe-ын хувилбар; Calmar нь жилийн өгөөжийг MaxDD-д хуваасан харьцаа. Win rate-ийн 95% итгэлцлийн интервалыг Wilson аргаар (хоёртын хувь хэмжигдэхүүнд тохирсон, жижиг түүвэрт нарийвчлалтай тооцоолол) тооцов.

3.8. Серверийн хэсгийн хэрэгжүүлэлт

Архитектурын үндсэн бүрэлдэхүүн

Серверийн хэсэг нь Flask REST API, MongoDB, GBDT inference модуль, JWT нэвтрэлт гэсэн дөрвөн давхаргаас бүрдэнэ. API ба worker процессуудыг Docker контейнераар Microsoft Azure App Service дээр байршуулсан бөгөөд нэвтрэлт, ханш, дохио, мэдээ, мэдэгдэл гэсэн 5 функциональ урсгал тэдгээрт хуваарилагдана. Зураг 3.9 нь системийн **физик байршуулалтыг** (UML 2.5 deployment

diagram) зангилаа (node), артефакт (artifact), гадаад үйлчилгээний түвшинд харуулсан бөгөөд §3.2-ийн логик архитектурыг гүйцэтгэлийн орчинд хэрхэн зурвасласныг дүрсэлдэг.



Зураг 3.9 Системийн байршуулалтын диаграмм — Docker, Azure App Service, role-based scaling

Зураг 3.9-т гурван байршуулалтын зангилаа болон гадаад үйлчилгээнүүдтэй холболтыг харуулсан. Зангилаа бүр нь хөгжүүлэгчийн компьютер (офлайн сургалт), Microsoft Azure App Service-д Docker контейнероор байршуулсан Flask сервер, мөн Android утас гэсэн гурван физик орчныг төлөөлдөг.

Серверийн дотор API ба фон процессийн (worker) үүрэг нь APP_PROCESS_ROLE орчны хувьсагчаар (api / worker / all) тусдаа container instance-аар хэвтээ хуваагдан ажиллана. Олон instance-ын зэрэгцээ ажиллагааг MongoDB Atlas-ийн job_locks цуглуулга (TTL индексстэй) дахь хуваарилагдсан түгжээгээр зохицуулдаг — энэ нь scheduler-үүдийн давхар ажиллахаас сэргийлдэг.

Систем нь гурван үе шатаар ажиллана: (1) оффлайн сургалтаар 3 GBDT загвар бэлдэж model.pkl артефактыг серверт байршуулна («deploy»); (2) worker үүрэгтэй instance нь Yahoo Finance-с ханш, AlphaVantage болон TradingView-с мэдээллийн хуанли татаж дохио үүсгэн MongoDB-д хадгалана; (3) Expo Push API-гаар дамжуулан мэдэгдэл хүргэж, React Native апп REST API-аар дохио, ханш, мэдээг хэрэглэгчдэд үзүүлнэ.

Нэвтрэлтийн аюулгүй байдал ба тогтвортой ажиллагаа

Системийн нэвтрэлтийн хэсэгт богино наст токен ба сессийн баталгаажуулалт ашигласнаар буруу орчноос хандалт хийх, хугацаа хэтэрсэн сесс дахин ашиглагдах эрсдэлийг бууруулсан. Мөн

серверийн тасралтгүй ажиллагааг хангахын тулд фон процессийн (background jobs) давхардлыг хянах, алдаа гарсан үед сэргээн оролдох бодлого хэрэгжүүлсэн.

Хандалтын хурдны хязгаарлалт (Rate limiting)

Олон нийтийн API endpoint-д Redis-д суурилсан хурдны хязгаарлалтыг хэрэгжүүлсэн; Redis ашиглах боломжгүй үед дотоод санах ойд (in-memory fallback) шилжинэ. Endpoint тус бүрийн хязгаарыг Хүснэгт 3.6-д харуулав.

Хүснэгт 3.6 API endpoint-ийн хандалтын хурдны хязгаарлалт

Endpoint бүлэг	Хязгаар (хүсэлт)	Цонх (секунд)
/signals/latest	30	60
/rates/live	60	60
/auth/* (нэвтрэлт)	20	60

MongoDB болон Expo Push-ийн тасрал, нэг Flask сервер зэрэг нэг цэгийн эмзэглэлийг job lock, max_retries=3, TTL кэш зэргээр хэсэгчлэн бууруулсан; бүрэн шийдэл үйлдвэрлэлийн орчинд replica set шаардана.

Архитектурын хэмжигдэх KPI ба баталгаажуулалтын протокол

Архитектурын шийдлүүдийг хэмжигдэх шалгуураар үнэлэхэд API, worker, push урсгалын KPI-г дараах хүрээнд тогтоосон: p95 latency $\leq 350\text{ms}$, 5xx алдааны хувь < 1.0

3.9. Харагдах хэсгийн архитектур

Харагдах хэсгийн зорилго нь серверийн хэсгээс ирэх ханш, дохио, мэдээ, мэдэгдлийг нэгтгэн хэрэглэгчид тасралтгүй хүргэхэд оршино; мобайл давхаргыг нэвтрэлт, өгөгдөл харуулах, сервертэй синхрончлол гэсэн гурван түвшний модулиар хэрэгжүүлсэн.

Харагдах хэсгийн модулийн бүтэц ба API харилцаа

Харагдах хэсэг нь дөрвөн бие даасан модулиас бүрдэх бөгөөд тус бүрийн үүрэг, харилцааны загвар, API endpoint-ийг Хүснэгт 3.7-д харуулав.


Хүснэгт 3.7 Харагдах хэсгийн модулиуд, харилцааны загвар ба API endpoint бүлэг

Модуль	Үндсэн үүрэг	Харилцааны загвар	Холбогдох API endpoint
Нэвтрэлтийн модуль	Бүртгэл, нэвтрэлт, токен шинэчлэлт, профайл	REST POST/PUT	/auth/register, /auth/login, /auth/refresh
Ханшийн модуль	Бодит цагийн ханш, 24 цагийн өөрчлөлт, хослол сонгох	REST GET (polling)	/rates/live, /rates/{pair}/history
Дохионы модуль	Дохио жагсаалт, итгэлцэл, SL/TP дэлгэрэнгүй, гүйцэтгэлийн статистик	REST GET + Push	/signals/latest, /signals/{id}, /signals/stats
Мэдээний модуль	Эдийн засгийн мэдээ, үйл явдлын хуанли, AI шинжилгээ	REST GET	/news/feed, /news/calendar

Нэгдмэл архитектурын зураглал

Систем нь REST polling ба Expo Push гэсэн хоёр харилцааны загварыг хослуулан ашигладаг. Polling урсгалыг Зураг 3.10-т харуулсан бөгөөд харагдах хэсгийн 4 модуль REST API-ийн дөрвөн endpoint бүлгээр серверийн харгалзах сервистэй холбогдоно. Үүний зэрэгцээ серверийн дохио ба мэдээний сервисүүд тэрс чигт (server-initiated) Expo Push сувгаар хэрэглэгчийн утсанд мэдэгдэл илгээдэг — энэ хоёр загварын нарийвчилсан дараалал Зураг ??-т харагдана.

REST polling урсгал — харагдах хэсгийн 4 модуль → REST API → серверийн 4 сервис:



Зураг 3.10 Харагдах хэсэг ба серверийн сервисүүдийн REST polling холболтын архитектур

3.10. Загварын давталтын сайжруулалт

DSR арга зүйн дагуу загварын хөгжүүлэлтийг 7 давталтын (iterative) үе шатаар явуулсан. Үе шат бүрт “бүтээх → үнэлэх → сайжруулах” мөчлөгийг давтаж, өмнөх хувилбарын түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үр дүнд тулгуурлан сул талыг зассан. Хэт ерөнхий явц (шинж чанарын тоо 75→48, загварын тоо 9→3)-ыг §3.1 Зураг 3.1-т аль хэдийн харуулсан тул энд үе шат бүрийн гол өөрчлөлтийг Хүснэгт 3.8-д нэгтгэн харуулав.

Хүснэгт 3.8 Загварын давталтын 7 үе шат — гол өөрчлөлт ба үндэслэл

Үе шат	Гол өөрчлөлт	Үндэслэл ба үр дүн
1	ATR шүүлтүүр	ATR-ийн доод босгыг 3 → 4 пипс болгож, бага хэлбэлзэлтэй 86.8% дохиог шүүн хасав
2	Шинж чанар нэмэх	Анхны багцад 15 нэмэлт техникийн шинж чанар нэмж нийт 63 болгов
3	Загварын олон янз байдал	Туршсан 9 загвараас гүйцэтгэлийн хувьд хамгийн сайн 3-ыг сонгов (LightGBM, XGBoost, CatBoost)
4	Trailing stop	Ашгийн явцад SL-ийг дагуулан шилжүүлэх стратеги нэмж, ашигтай арилжааг урт хугацаанд барьдаг болгов
5	Уналтын засвар	Байрлалын хяналт ба эрсдэлийн хязгаарыг чангатгаснаар Max Drawdown бууруулав
6	Хэт нийцлийн засвар	Шинж чанар 75 → 48 болгож, урагш гүйлгэн баталгаажуулалт (WFFV) хийв
7	Чанартай дохио	Итгэлцлийн босго ≥ 0.90 , $ATR \geq 4$ пип, $TP:SL=3:1$ параметруудийг тогтоож дохионы чанарыг тогтворжуулав

4. Судалгааны үр дүн

4.1. Үр дүнгийн өгөгдлийн эх сурвалж

Энэ бүлгийн бүх тоон үр дүнг MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилтын логуудаас гаргав. Логийн нэгтгэлийн дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах боломжийг хангана. Хязгаарлалтыг §4.6.3-т, эх сурвалжийн нэгтгэлийн нөхцөлийг Хавсралт Г-аас үзнэ үү.

4.2. Загварын ангиллын гүйцэтгэл

Судалгааны асуулт 1 (RQ1): “Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр найдвартай ажиллах уу?” гэсэн асуултад хариулахын тулд GBDT ансамблийн ангиллын нарийвчлалыг Walk-Forward Validation (WV) схемийн дагуу тусдаа өгөгдлийн хуваарь дээр хэмжив. Хэмжилтийн аргачлал (зөөлөн санал хураалт ба *argmax* ангиллын шийдвэр)-ийг §3.4-т тайлбарласан; нарийвчлал ба F1 оноог `sklearn.metrics`-ээр тооцов. Хуваалт: сургалт 2015–2022, баталгаажуулалт 2023, тест 2024 (харагдаагүй өгөгдөл).

Хүснэгт 4.1 GBDT ансамблийн нарийвчлал ба F1 оноо — хуваарь тус бүрээр

Хуваарь	Хугацааны цонх	Нарийвчлал (%)	F1-macro (%)	F1-weighted (%)
Сургалт	2015.01–2022.12	82.71	67.74	80.94
Баталгаажуулалт	2023 бүтэн жил	84.48	62.67	82.29
Тест (out-of-sample)	2024 бүтэн жил	89.25	59.45	87.23

Сургалт ба баталгаажуулалтын нарийвчлалын зөрүү +1.77% (баталгаажуулалт нь сургалтаас өндөр) байгаа нь загварт хэт нийцлийн ноцтой шинж тэмдэг ажиглагдаагүйг илтгэнэ. Тест нарийвчлал 89.25% нь 2024 оны харагдаагүй өгөгдөл дээр ч тогтвортой гүйцэтгэл хадгалагдаж буйг харуулсан.

Зөрүүгийн тайлбар: Баталгаажуулалтын нарийвчлал сургалтаас өндөр гарах нь онолын хувьд ердийн биш. Энэхүү судалгаанд гол хоёр шалтгаан байна. Нэгдүгээрт, 2023 оны баталгаажуулалтын өгөгдөл (371K цэг) дотор HOLD ангийн эзлэх хувь сургалтын дундаж 75.5%-аас өндөр (76.9%) байсан тул HOLD ангийн өндөр precision (90%+) нь нарийвчлалыг дээш нь түрсэн. Хоёрдугаарт, LightGBM ба XGBoost-ийн `early_stopping_rounds=50` нь баталгаажуулалтын алдагдлыг шууд минимумжуулдаг тул баталгаажуулалтын тархалттай уялдаа сайтай байгаа нь хүлээгдэж болох үзэгдэл. Тестийн нарийвчлал баталгаажуулалттай ойролцоо хадгалагдсан (87–89%) нь зөрүү нь өгөгдөл-тусгай хазайлт бөгөөд хэт нийцлийн илрэл биш гэдгийг батлана.

F1-macro vs. F1-weighted тайлбар: F1-macro нь гурван ангийг тэнцүү жинтэйгээр нэгтгэдэг тул 59–68% байна; F1-weighted нь ангийн дээжийн тоогоор жинлэдэг учир 80–87% болж өсдөг. Тестийн (2024) F1-macro нь сургалт болон баталгаажуулалтаас бага байгаа нь BUY/SELL ангийн recall харьцангуй доогуур болохыг илтгэх бөгөөд HOLD давамгайлсан өгөгдөлд нарийвчлал ганцаараа хангалттай хэмжүүр биш юм. HOLD ангийн давамгайлалын шалтгаан ба ангиллын тусдаа дүнг §4.2.1-т харуулав.

Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт (2024)

Хүснэгт 4.2 Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт (BUY / HOLD / SELL)

Анги	Precision (%)	Recall (%)	F1 (%)	Дээжийн тоо
BUY	68.24	29.97	41.65	22,405
HOLD	90.24	98.33	94.11	322,186
SELL	75.80	29.60	42.58	26,791

BUY ба SELL ангийн дуудалтын хувь (recall) харьцангуй бага (30%) байгаа нь хоёр шалтгаантай. Нэгдүгээрт, сургалтын өгөгдлийн 75.6% нь HOLD ангид хамаарах тул загвар HOLD ангийг давтан сонгох хандлагатай болдог. Хоёрдугаарт, итгэлцлийн босго 0.90-өөс дээш шаардах нь нийт чиглэлтэй дохионы 70% гаруйг шүүж хасдаг. Практикт энэ нь аппликейшны хэрэглэгч өдөрт дунджаар 13.67 дохио хүлээн авах боловч нарийвчлал (precision) өндөр (BUY: 68.24%, SELL: 75.80%) гэсэн үр дүнтэй. Нийт чиглэлтэй боломжийн гуравны нэгийг л барьдаг тул давтамж өндөртэй стратегид тохиромжгүй ч, цөөн боловч чанартай дохио хүлээдэг хэрэглэгчид илүү тохиромжтой.

Итгэлцлийн бүрийн нарийвчлал

Хүснэгт 4.3 Итгэлцлийн бүрийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)

Итгэлцлийн бүр	Нарийвчлал (%)
0.85–0.90	≈72
0.90–0.92	≈84
0.92–0.95	≈91
0.95+	≈97
≥0.90 (нийт)	96.96

Итгэлцлийн босго 0.92 дээш дохионд 91%, 0.95 давсан тохиолдолд 97% нарийвчлалд хүрдэг. Баталгаажуулалтын өгөгдөлд 0.90-өөс дээш дохионы нарийвчлал 96.96% байгаа нь ийм босгын шүүлтүүрийн үндэслэлийг тодорхой харуулна. Шүүлтийн босго нэмэгдэх тусам нарийвчлал дагаад өсөх хандлага ажиглагдсан нь RQ1-ийн хүрээнд загварын тогтвортой байдлыг дэмжиж байна.

4.3. Босгын мужийн нэгтгэсэн үр дүн

Өгөөжийг дараах томъёогоор тооцсон:

$$\text{Return}(\%) = \frac{\text{Final Balance} - 10,000}{10,000} \times 100 \quad (4.1)$$

Хүснэгт 4.4 хүснэгтэд босго өсөхөд дохионы тоо, эцсийн баланс хэрхэн өөрчлөгдсөнийг харуулав.

Хүснэгт 4.4 0.90–0.99 мужийн босгын харьцуулалт

Босго	Нийт дохио	Дохио/өдөр	Эцсийн баланс (\$)	Цэвэр ашиг (\$)	Өгөөж (%)	Нэг дохионы ашиг (\$)
0.90	3,567	13.67	58,262.39	48,262.39	482.62	13.53
0.91	3,274	12.54	61,770.46	51,770.46	517.70	15.81
0.92	2,958	11.33	56,512.20	46,512.20	465.12	15.72
0.93	2,643	10.13	46,807.24	36,807.24	368.07	13.93
0.94	2,287	8.76	38,050.13	28,050.13	280.50	12.27
0.95	1,914	7.33	32,844.40	22,844.40	228.44	11.94
0.96	1,588	6.08	33,040.14	23,040.14	230.40	14.51
0.97	1,195	4.58	29,019.19	19,019.19	190.19	15.92
0.98	673	2.58	25,447.43	15,447.43	154.47	22.95
0.99	147	0.56	17,428.89	7,428.89	74.29	50.54

Тайлбар: Дохио/өдөр үзүүлэлтийг Нийт дохио/261 томъёогоор тооцсон. 261 нь Форекс 24/5 зах зээлийн нөхцөлд 2025 оны ажлын өдрийн (Даваа–Баасан) тоо. Зардлын хамралтыг §4.6.3-т дэлгэрэнгүй авч үзсэн.

Суурь жишиг: EUR/USD худалдан аваад барих стратеги

Сценарийн дүнг зах зээлийн ерөнхий хөдөлгөөнтэй харьцуулахын тулд EUR/USD-ийн close-to-close худалдан аваад барих жишгийг тооцоов.

Хүснэгт 4.5 EUR/USD худалдан аваад барих жишгийн хураангуй

Үзүүлэлт	Утга
Эхлэл хаалт (2025)	1.03514
Төгсгөл хаалт (2025)	1.17456
Худалдан аваад барих өгөөж (%)	13.47
\$10,000 хөрөнгийн эцсийн баланс (\$)	11,346.87

Тайлбар: Энэ жишиг нь close-to-close энгийн загвар тул стратегийн өгөөжтэй шууд тэнцэхгүй; харин сценарийн дүнг харьцуулахад ашиглав.

Дохионы гүйцэтгэлийн чанар

Түүхэн өгөгдөл дээрх системийн туршилтын логийг босго тус бүрээр задлахад **шүүгдсэн дохионы тоо** болон **бодитоор нээгдэж хаагдсан арилжааны тоо** хооронд тогтвортой зөрүү ажиглагдсан. Энэ зөрүү нь дараах гүйцэтгэлийн механизмтай холбоотой:

- Нэг агшинд зөвхөн нэг байрлал нээх дүрэм (MaxPositions=1)
- Нээлттэй байрлал хаагдахаас өмнөх давхцсан дохионуудыг алгасгах

- Зөвхөн тухайн хэрэгсэл дээрх дохиог гүйцэтгэх хязгаарлалт

Иймд гүйцэтгэлийн хувийг $\text{Гүйц.}(\%) = \frac{\text{Арилжаа}}{\text{Ачаалагдсан дохио}} \times 100$ томъёогоор тооцсон (хүснэгтэд “Ачаал.” гэж богиносгов). 6.45–23.81%-ийн гүйцэтгэлийн хувь нь системийн алдаа бус, **зориудын чанарын шүүлтүүрийн үр дүн** юм. Загвар минут бүр таамаглал гаргадаг ч итгэлцлийн босго болон $\text{MaxPositions}=1$ дүрмийг (§3.6.1) давсан дохио л арилжаа болдог. $\text{TP/SL}=3:1$ нөхцөлд алдагдалгүй (break-even) байх ялалтын хувь 25% байна. Босго өсөх тусам арилжааны тоо буурч, итгэлцлийн интервал өргөсдөг.

Хүснэгт 4.6 Босго тус бүрийн дохио-арилжааны гүйцэтгэл ба ялалтын хувь (95% CI)

Босго	Ачаал.	Арилжаа	Хөрвөөгүй	Гүйц. (%)	TP/SL	Ялалт (%)	95% CI	E[R]
0.90	3,567	230	3,337	6.45	103/127	44.78	[38.49, 51.24]	0.79
0.91	3,274	212	3,062	6.48	100/112	47.17	[40.56, 53.88]	0.89
0.92	2,958	201	2,757	6.80	95/106	47.26	[40.48, 54.15]	0.89
0.93	2,643	188	2,455	7.11	87/101	46.28	[39.30, 53.41]	0.85
0.94	2,287	154	2,133	6.73	73/81	47.40	[39.68, 55.26]	0.90
0.95	1,914	137	1,777	7.16	65/72	47.45	[39.27, 55.76]	0.90
0.96	1,588	113	1,475	7.12	59/54	52.21	[43.08, 61.20]	1.09
0.97	1,195	106	1,089	8.87	54/52	50.94	[41.56, 60.26]	1.04
0.98	673	76	597	11.29	43/33	56.58	[45.39, 67.14]	1.26
0.99	147	35	112	23.81	23/12	65.71	[49.15, 79.17]	1.63

Тайлбар: Win rate-ийн 95% Wilson итгэлцлийн интервал болон Expectancy ($E[R]$, $\text{TP/SL}=3:1$ нөхцөлд)-ийн тооцооллын аргачлал, тодорхойлолтыг Арга зүйн бүлгийн §3.6-аас үзнэ үү.

Бином тестээр шалгасан статистикийн ач холбогдол

$\text{TP/SL}=3:1$ нөхцөлд алдагдалгүй (break-even) байх ялалтын хувь нь $p_0 = 0.25$. Бином тестээр шалгахад бүх 10 сценарийн win rate энэхүү тэглэлээс мэдэгдэхүйц өндөр гарсан: 0.91 босгод $\hat{p} = 0.4717$ ($n = 212$), $z = (\hat{p} - p_0) / \sqrt{p_0(1 - p_0)/n} = 7.45$, $p < 0.0001$; 0.90 босгод $z = 6.93$; хамгийн бага түүвэртэй 0.99 босгод ($n = 35$) ч $z = 5.56$, $p < 0.0001$. Иймд систем санамсаргүй сонголтоос ($p_0 = 0.25$) статистикийн хувьд ач холбогдлоор давсан гэж дүгнэж болно. Хязгаарлалт: энэ нь нэг ансамбль загварын дотоод үнэлгээ бөгөөд өөр загвартай харьцуулах McNemar тест хийгдээгүй (§4.6.3-т тэмдэглэв).

Балансын хэлбэлзлийн нэгтгэл

10 босгын эцсийн балансын дундаж \$39,918.25, стандарт хазайлт \$15,171.78, харьцангуй хэлбэлзэл (CV) 38.01% байна. Энэ нь шинжилгээний үр дүн босго сонголтод мэдрэмтгий болохыг харуулна.

Хүснэгт 4.7 Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ

Босго	MaxDD (%)	Sharpe	Sortino	Calmar	Хамгийн урт дараалсан алдагдал
0.90	3.93	9.11	24.82	122.96	7
0.91	2.97	9.75	25.99	174.20	7
0.92	2.99	9.90	29.78	155.79	7
0.93	9.53	9.21	25.92	38.63	10
0.94	6.80	8.87	24.66	41.23	8
0.95	3.94	8.57	23.97	57.97	6
0.96	4.88	9.84	30.15	47.18	5
0.97	2.96	9.02	24.90	64.19	4
0.98	7.66	10.63	28.84	20.16	8
0.99	1.98	12.83	44.76	37.53	2


Тайлбар: Хүснэгтийн эрсдэлийн үзүүлэлтүүд (MaxDD, Sharpe, Sortino, Calmar)-ийн тодорхойлолтыг Арга зүйн бүлгийн §3.6 (Хүснэгт 3.5 ба түүний дараах тайлбар)-аас үзнэ үү.

Чухал анхааруулга: Sharpe (9–13), Sortino (24–45), Calmar (20–174) утгууд нь арилжаа цөөн (35–230 хэлцэл), хугацааны цонх богино (1 жил) ба зардлын бүрэн тусгаагүйгээс *зохиомлоор томруулагдсан* тул санхүүгийн стандарт утгуудтай шууд харьцуулах боломжгүй. Эдгээрийг зөвхөн **босгуудын харьцангуй харьцуулалтын суурь** болгон авч үзнэ; хөрөнгө оруулалтын шийдвэрийн үндэс болгохгүй.

Энэ графикаас харахад 0.93 (9.53%) болон 0.98 (7.66%) босгон дээр уналтын эрсдэл харьцангуй өндөр байна. Харин 0.99 дээр MaxDD хамгийн бага (1.98%) боловч нийт өгөөж болон дохионы тоо мэдэгдэхүйц буурсан. Иймээс босго сонгохдоо зөвхөн өгөөж бус, уналтын эрсдэлийг хамтад нь авч үзэх шаардлагатай.

Босго ба гүйцэтгэлийн хувийн хамаарал

Зураг 4.1 зурагт Loaded дохионоос бодитоор арилжаанд орсон хувь буюу гүйцэтгэлийн хувийн өөрчлөлтийг харуулав.




Зураг 4.1 Босгын мужийн шинжилгээ: гүйцэтгэлийн хувийн өөрчлөлт

0.90–0.97 мужид гүйцэтгэлийн хувь 6–9% ойролцоо тогтвортой, 0.98–0.99 дээр шүүгдсэн дохионы тоо цөөрөхөд 11–24% болж өснө.

Босго ба ялалтын хувийн хамаарал

Зураг 4.2 зурагт ялалтын хувийг 95% Wilson итгэлцлийн интервалтай хамт error bar хэлбэрээр үзүүлэв.




Зураг 4.2 Босгын мужийн шинжилгээ: ялалтын хувь ба 95% итгэлцлийн интервал

Босго өсөхөд ялалтын хувь дундаж өсөх хандлагатай ч арилжааны тоо буурснаас итгэлцлийн интервал өргөсч, статистикийн тодорхойгүй байдал нэмэгдэнэ.

Босго ба хүлээгдэж буй өгөөжийн хамаарал

Зураг 4.3 зурагт нэг арилжааны хүлээгдэж буй дундаж үр ашиг буюу хүлээгдэж буй өгөөжийн өөрчлөлтийг харуулав.




Зураг 4.3 Босгын мужийн шинжилгээ: хүлээгдэж буй өгөөжийн өөрчлөлт

Хүлээгдэж буй өгөөж бүх босгон дээр > 0 байна; практик шийдвэрт MaxDD, win rate CI-тэй хамтад нь авч үзэх шаардлагатай.

Хамгийн өндөр өгөөжтэй 3 босгын хөрөнгийн өөрчлөлтийн муруй

Хөрөнгийн өөрчлөлтийн муруй (equity curve) нь хэлцэл бүр хаагдсаны дараах балансын хуримтлагдсан хөдөлгөөнийг харуулна: тасралтгүй өсөх хэсэг нь дохионы эерэг гүйцэтгэлийг, уналтын хэсэг нь дараалсан алдагдлыг илэрхийлнэ.

Зураг 4.4 зурагт өгөөжийн хувьд хамгийн өндөр гурван босго (0.91, 0.90, 0.92)-ын equity curve-ийг нэг графикт давхарлан харуулав. Гурван муруй нь ижил эхлэх баланс (\$10,000) болон ижил 1% тогтмол эрсдэлийн бодлогын дор хуримтлагдсан балансын хөдөлгөөнийг илэрхийлнэ. Координатуудыг MetaTrader 5 Strategy Tester-ийн бодит хэлцлийн логоос тооцоолон гаргасан.



Зураг 4.4 Хамгийн өндөр өгөөжтэй 3 босгын хөрөнгийн өөрчлөлтийн муруй

130–170 дахь арилжааны орчмоос 0.91 босго илт тасарч урагшилсан; 0.92 нь 0.90-тэй ойролцоо эцсийн баланстай боловч арилжааны тоо цөөн (201 vs 230) тул equity муруй жигд байна.

4.4. Үр дүнгийн тайлбар

Энэ хэсэг нь дээрх 10 сценарийн туршилтын нэгтгэсэн үр дүнд суурилсан нөхцөлт дүгнэлтийг агуулна.

Үр дүнг ерөнхийлөн дүгнэх боломжийн хүрээ

Энэ бүлгийн тоон үр дүн нь EUR/USD хэрэгсэл, 2025.01.01–2026.01.01 туршилтын цонх, нэг агшинд нэг байрлалын EA дүрмийн нөхцөлд хүчинтэй. 0.90–0.99 босгын мужийн сценарийн харьцуулалт энэхүү хүрээнд батлагдсан боловч 0.91 босгыг универсал оновчтой гэж үзэх, олон хэрэгсэлд (EUR/USD-ээс гадуур) шууд өргөтгөх, бүрэн зардлын хамралт зэрэг нь батлагдаагүй. Ерөнхийлөх хязгаарлалтыг §4.6.3-т нэгтгэсэн.

Сценарийн хүрээнд ажиглагдсан дээд цэг

Тухайн цонхны харьцуулалтад хамгийн өндөр эцсийн баланс 0.91 босгон дээр \$61,770.46 (+517.70%) гарсан. Энэ нь универсал оновчтой босго биш; тухайн өгөгдөл ба дүрмийн хүрээнд ажиглагдсан локал дүн болно.

Ийм өндөр өгөөжийн дүн нь голчлон нийлмэл өсөлтийн механизмаас үүдэлтэй: нэг арилжаанд хөрөнгийн 1% эрсдэлийг тогтмол хэмжээлж, 200 гаруй арилжааны турш эерэг хүлээгдэж буй өгөөжийг нийлмэлжүүлэхэд эцсийн баланс экспоненциалаар өсдөг. Иймд +517.70% нь хөшүүрэггүй буй-энд-холд жишигтэй шууд адилтгах тоо бус, тогтмол эрсдэлийн бодлогын дор босго хооронд харьцуулах хэмжүүр гэж тайлбарлавал зохистой.

Уг дүн “3,274 loaded дохио → 212 хэрэгжсэн арилжаа” нөхцөлд гарсан; бүх дохионд ижил хэрэгжилт гарна гэж үзэхгүй. MaxDD=2.97%, Sharpe=9.75, Sortino=25.99, Calmar=174.20 үзүүлэлтүүдийг (Хүснэгт 4.7) сценари хооронд харьцуулах суурь болгож ашиглав.

Үр дүнгийн нэгтгэсэн тайлбар

Босго 0.90→0.99 өсөхөд нийт дохио 95.88%-аар буурч нийт өгөөж буурдаг ч нэг дохионы дундаж ашиг \$13.53→\$50.54 болж өснө. Давтамж ба нэг дохионы үр ашгийн энэ зөрчлийг дээжийн хэмжээний нөлөөтэй хамт авч үзэх шаардлагатай [26, 27]. Тухайн нөхцөлд 0.90–0.92 муж нийт өгөөж болон давтамжийн тэнцвэрийн хувьд оновчтой ажиглагдсан. Үр дүнг тайлбарлахдаа арга зүйн үлдэгдэл эрсдэлүүдийг §4.6.3-аас үзнэ үү.

4.5. Архитектурын KPI-ийн баталгаажуулалтын үр дүн

API давхаргын p95 latency 471–536 ms байсан нь зорилтот 350 ms-г хэтэрсэн; нийт 90 хүсэлтийн аль нэг нь ч 5xx кодтой хариу өгөөгүй (5xx алдааны хувь 0.0%). Latency зорилт биелээгүйн гол шалтгаан нь хэмжилтийн байршил (Улаанбаатар) ба сервер (Токио) хоорондын RTT (≈ 150 – 180 ms) болон Flask+MongoDB боловсруулалтын нийлбэр (≈ 300 ms) юм. Шийдвэрлэх чиглэлүүд болон дэлгэрэнгүй хүснэгтийг Хавсралт В-аас үзнэ үү.

4.6. Дүгнэлт

Судалгааны гол үр дүн

Судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан Форекс зах зээлийн арилжааны дохионы системийг хөгжүүлсэн. Гол үр дүнг гурван багц болгон нэгтгэн дүгнэв.

1. **Машин сургалтын ансамбль загвар:** LightGBM, XGBoost, CatBoost гурван GBDT загварыг нэгтгэж, 6 хугацааны интервалын 48 шинж чанараар EUR/USD-ийн чиг хандлагыг BUY/SELL/HOLD гурван ангилалд таамагласан. 7 давталтын хөгжүүлэлтийн мөчлөгөөр 75→48 шинж чанар, 9→3 загвар болгон хялбарчилж хэт нийцлийн эрсдэлийг бууруулсан. Нарийвчилсан үнэлгээний үзүүлэлтийг Хүснэгт 4.1 ба Хүснэгт 4.3-т тайлагнасан (RQ1).
2. **Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэл:** 0.90–0.99 мужийн сценарийн харьцуулалтад бүх босго эерэг өгөөжтэй гарсан. Дохио-арилжааны гүйцэтгэл, ялалтын хувь, хүлээгдэж буй өгөөж, болон уналтын хэмжээг хэрэгжсэн арилжааны хүрээнд тайлбарласан. MaxDD, Sharpe, Sortino, Calmar зэрэг эрсдэлийн үзүүлэлтүүдийг босго бүрээр харьцуулсан.
3. **Инженерчлэлийн хэрэгжүүлэлт:** §3.2-т тайлбарласан загвар сургалт → дохио үүсгэх → мобайл апп гэсэн ML serving дамжлагыг ажиллах прототип хэлбэрт хүргэв.

Судалгааны практик хувь нэмэр

- **Нэгдмэл үнэлгээний хүрээ:** Ангиллын нарийвчлал, Wilson итгэлцлийн интервал, эрсдэлийн матриц, ерөнхийлөх боломжийн хязгаарыг нэг дор тайлбарласан нь финтек судалгааны ил тод байдлын стандартад нийцдэг.
- **Олон давхаргын нэгтгэл:** Загварын математик гүйцэтгэл, серверийн хэсгийн ажиллагаа, мобайл аппликейшны харагдах хэсгийг нэг туршилтын хүрээнд үнэлсэн нь академик хүрээнээс давсан системийн инженерчлэлийн жишиг болно.
- **Монгол хэл дээрх техникийн баримтжуулалт:** Машин сургалт, санхүүгийн нэр томъёоны Монгол тайлбар бүхий судалгааны бичвэр нь энэ чиглэлийн дотоодын судалгааны суурь болж чадна.

Хязгаарлалт

1. **Хамрах хүрээ:** EUR/USD хэрэгсэл болон сонгосон хугацааны цонхонд л үр дүн батлагдсан тул өөр валютын хослол, брокерт шууд ерөнхийлөх боломжгүй
2. **Шошгын нэвчилтийн үлдэгдэл эрсдэл:** Олон интервалын нэгтгэхэд хугацааны дүрэм мөрдсөн ч эрсдэлийг бүрэн үгүйсгээгүй
3. **Гүйцэтгэлийн хөрвүүлэлтийн хэлбийлт:** Гүйцэтгэлийн хувь 100% биш үед ялалтын хувь, хүлээгдэж буй өгөөж нь хэрэгжсэн арилжааны хувьд л хүчинтэй
4. **Статистикийн харьцуулсан тест дутуу:** Win rate-ийн break-even ($p_0 = 0.25$)-тэй харьцуулсан бином тест §4.3-д хийгдсэн ($z > 5$, $p < 0.0001$). Харин загвар хоорондын McNemar's тест

явуулаагүй; арилжааны тоо цөөн (35–230 хэлцэл) нь сценарийн хоорондох ялгааны хүчтэй дүгнэлт гаргахад хязгаарлалт үүсгэнэ

5. **Арилжааны зардлын хамралт:** MetaTrader 5-ийн бодит спрэд болон 10 point-ийн гулсалтын хязгаар тусгасан. Харин брокер тус бүрийн шимтгэл (commission) болон шөнийн байрлал хадгалалтын зардал (swap) энэ хувилбарт тусгаагүй. Шимтгэл нь брокерын нөхцөлөөс ихээхэн хамаарах тул тодорхой тоон утгаар загварчлахын оронд хязгаарлалт болгон тэмдэглэн, өгөөжийн дүнг сценарийн харьцуулалтын хүрээнд тайлбарлав. Бодит орчинд хэрэглэхийн өмнө тухайн брокерын шимтгэл болон свопыг нэмж тооцох нь зайлшгүй.
6. **Тохируулга ба сургалт-үйлчилгээний зөрүү:** Офлайн тохируулгыг туршилтын ажиглалтаар шалгасан; ажиллах үед магадлалын тооцоо өөрчлөгдөх боломжоос үлдэгдэл эрсдэл үүсч болно
7. **Бодит цагийн хүндрэл:** Гадаад системийн API хязгаарлалт, сүлжээний саатал зэрэг техникийн асуудлууд

Цаашдын чиглэл

1. **Олон валютын хослолд өргөтгөх:** GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, багц стратеги бүтээх
2. **Дагах зогсоол:** Ашгийг хамгаалах динамик SL-ийн аргачлалыг сайжруулах
3. **Гүн сургалтын загвар:** Цаашдын ажилд LSTM, Transformer загваруудыг GBDT ансамбльд нэмж, цагийн цуваа дотрох хамаарлыг илрүүлэх чадамжийн хувьд GBDT-тэй харьцуулан үнэлэх боломжтой
4. **Бататгах сургалт:** Багцын менежмент, байрлалын хэмжээ тохируулалтад хэрэглэх
5. **Мэдээний шинжилгээ:** Хэлний боловсруулалт ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах
6. **Түгээлт ба MLOps:** Google Play түгээлтийн сувгийг нэвтрүүлж, загварын шилжилтийн мониторинг, хувилбар гаргалтын автоматжуулалтыг өргөтгөх
7. **Загварын хувилбарын удирдлага ба буцаах протокол:** Дохио бүрт model_version ба run_id талбар хадгалж ул мөрдөх боломж бүрдсэн боловч formal Model Registry, approve/promote workflow, автоматаар rollback хийх протокол бүрэн хэрэгжээгүй хэвээр байна. Иймд энэ хэсэг нь дараагийн инженерчлэлийн ажлын гол шаардлага хэвээр үлдэнэ.

Эцсийн дүгнэлт

Судалгааны гурван асуултад товч хариулт өгвөл:

RQ1 (загварын тогтвортой байдал): **Тийм.** Загвар нь 2024 оны харагдаагүй өгөгдөл дээр 89.25% нарийвчлал, итгэлцэл ≥ 0.90 дохионд 96.96% нарийвчлалд хүрсэн (баталгаажуулалт). Сургалт-баталгаажуулалтын зөрүү +1.77% нь хэт нийцлийн шинж тэмдэгтгүй (Хүснэгт 4.1, Хүснэгт 4.3).

RQ2 (дохио хэрэгжих чадвар): **Тийм.** 0.90 босгод 3,567 шүүгдсэн дохио MT5-д 230 хэлцэл болж хэрэгжсэн (Exec rate 6.45–23.81%). Win rate 44.78–65.71% (Wilson 95% CI) бөгөөд бүх 10 сценарид TP/SL=3:1 break-even ($p_0 = 0.25$)-тэй харьцуулахад бином тестээр $z > 5$, $p < 0.0001$ ач холбогдолтой давсан (Хүснэгт 4.6).

RQ3 (1 жилийн тестийн цонхны ашигт ажиллагаа): **Тийм.** 1% тогтмол эрсдэлийн доор бүх 10 сценари эерэг нийт өгөөж (+74.29% to +517.70%) ба эерэг хүлээгдэж буй өгөөж ($E[R] = 0.79\text{--}1.63R$) үзүүлсэн. MaxDD 1.98–9.53% хүрээнд хадгалагдсан (Хүснэгт 4.4, Хүснэгт 4.7). Сценари хоорондын балансын хэлбэлзэл (CV=38.01%) нь үр дүн босго сонголтод мэдрэмтгий болохыг харуулдаг тул босгыг тогтоохдоо MaxDD-тэй хамтад нь авч үзэх шаардлагатай.

Дүгнэлт нь EUR/USD хэрэгсэл, 2025 оны туршилтын цонх, зардлын бүрэн тусгаагдаагүй нөхцөлд хүчинтэй тул бусад зах зээлд шууд ерөнхийлөх боломжгүй. Практикт эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох протокол шаардлагатай.

Нэгтгэн дүгнэвэл, энэ судалгаа гурван чиглэлд хувь нэмэр оруулсан. Нэгдүгээрт, загвар сургалтаас сервер, мобайл апп хүртэлх end-to-end дамжлагыг нэгэн инженерчлэлийн хүрээнд практик прототип хэлбэрт бүтээсэн. Хоёрдугаарт, GBDT ансамблийн ангиллын нарийвчлал, итгэлцлийн шүүлтийн нөлөө, эрсдэл-өгөөжийн үзүүлэлтийг нэгдсэн хүрээнд үнэлж, тоон дүн болон хязгаарлалтыг ил тайлагнасан нь финтек судалгааны ил тод байдлын стандартад нийцэж байна. Гуравдугаарт, ML-ийн академик үнэлгээг системийн гүйцэтгэлийн шинжилгээтэй нэгтгэсэн арга зүй нь цаашдын олон давхаргат ML системийн судалгааны загвар болж чадна.

- [1] Bank for International Settlements. Triennial central bank survey: Foreign exchange turnover in april 2022, 2022.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.
- [3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.
- [4] Joarder Kamruzzaman and Ruhul A. Sarker. Forecasting of currency exchange rates using ANN: A case study. *Journal of Financial Forecasting and Analysis*, 1(1):1–15, 2003.
- [5] M. Kumar and M. Thenmozhi. Forecasting stock index movement: A comparison of SVM and random forest. *Indian Institute of Capital Markets Working Paper*, 1(1):1–22, 2006.
- [6] Michel Ballings, Dirk Van den Poel, Niels Hespeels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.
- [7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.
- [8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review. *Applied Soft Computing*, 97, 2019.
- [9] Deniz Can Yildirim, Ismail Hakki Toroslu, and Ugo Fiore. Forecasting directional movement of Forex data using LSTM with technical and macroeconomic indicators. *Financial Innovation*, 7(1), 2021.
- [10] Ahmet Murat Ozbayoglu, Mehmet Ugur Gudelek, and Omer Berat Sezer. Deep learning for financial applications: A survey. *Applied Soft Computing*, 93:106384, 2020.
- [11] Yuqi Nie, Nam Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. A time series is worth 64 words: Long-term forecasting with transformers. *International Conference on Learning Representations*, 2023.
- [12] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis. *International Conference on Learning Representations*, 2023.
- [13] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2):689–702, 2017.
- [14] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [15] Shihao Gu, Bryan T. Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

- [17] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.
- [18] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [19] Omer Berat Sezer, Mehmet U. Gudelek, and A. Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [20] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis. *The Journal of Finance*, 55(4):1705–1765, 2000.
- [21] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.
- [22] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.
- [23] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.
- [24] Ben R. Marshall, Ros Cahan, and Jean M. Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.
- [25] Cheol-Ho Park and Scott H. Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.
- [26] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.
- [27] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.
- [28] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023.
- [29] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O’Reilly Media, 2nd edition, 2018.
- [30] Miguel Grinberg. *Flask Web Development: Developing Web Applications with Python*. O’Reilly Media, 2nd edition, 2018.
- [31] Alan R Hevner, Salvatore T March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.
- [32] Ken Peppers, Tuure Tuunanen, Marcus A Rothenberger, and Samir Chatterjee. A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77, 2007.
- [33] John J. Murphy. *Technical Analysis of the Financial Markets*. New York Institute of Finance, 1999.

Хавсралт

Хавсралт А: Нэвчилтийн аудитын нарийвчилсан дүрэм

Цагийн нийцлийн дүрэм

Мэдээллийн нэвчилтээс сэргийлэх цагийн нийцлийн үндсэн томьёо (томьёо 3.2) болон ерөнхий тайлбарыг Арга зүйн бүлгийн §3.3-т (“Шошго ба шинж чанарын цагийн нийцлийн аудит” дэд хэсэг) үзнэ үү. Доор компонент бүрийн нарийвчилсан аудитын дүрмийн хүснэгтийг харуулав.

Нэвчилтийн аудит дүрмүүдийн нарийвчилсан тайлан

Хүснэгт А.1 Нэвчилтийн аудитын цагийн нийцлийн дүрмүүд


Компонент	Үйлдэл	Цагийн нөхцөл	Нэвчилтийн эрсдэл
OHLCV өгөгдөл	t_0 -д хаалтын ханш ба үзүүлэлтүүдийг ашиглах	$t_{\text{candle}} < t_0$	Бага (хаалтын ханш шийдвэрийн агшинд мэдэгдсэн байдаг)
MA (хөдөлгөөнт дундаж)	t_0 -г оруулаад өмнөх 50 лааны (candle) дундаж	$t_{\text{MA window}} < t_0$	Бага (түүхэн мэдээлэл)
RSI, ATR	t_0 -г оруулаад өмнөх өгөгдлөөс тооцох	$t_{\text{period}} \leq t_0$	Бага
240 минутын label	t_0 -ээс дараах 240 минутын хамгийн дээд/доод	$t_{\text{label}} > t_0$	ӨНДӨР (future data)
Олон интервалын синхрончлол	merge_asof, direction=backward	$t_{\text{small}} \leq t_{\text{large}}$	Дунд (boundary алдаа)

Тайлбар: merge_asof(backward) болон хугацааны тусгаарлалтын дүрэм нь нэвчилтийн эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй. Иймээс үр дүнг тайлбарлахдаа энэ эрсдэлийг хязгаарлалтын хүрээнд хамтад нь авч үзсэн.

Хавсралт Б: Урагш гүйлгэн баталгаажуулалтын олон огтлолын схем

WFV олон огтлолын концепцын схем

Үндсэн бичвэрийн §3.4.5-т тайлбарласан **олон огтлол, өргөтгөх сургалтын цонх** (expanding window) протоколын Fold 1–Fold 5-ийн хуваарийг нэг зурагт төвлөрүүлэн харуулав.



Зураг Б.1 *WFV олон огтлолын ерөнхий концепцын схем (Fold 1–Fold 5 expanding window protocol)*

Тайлбар: Бүх Fold-ийн сургалт 2015-аас эхэлж, Fold өсөх тусам сургалтын цонх жил жилээр өргөжин (4 → 5 → 6 → 7 → 8 жил), баталгаажуулалт ба тестийн цонх урагш шилждэг *expanding window* протокол. Сургалтын блокын урт нь бодит хугацааны хэмжээтэй пропорциональ зурагдсан тул дээд folds бага, доод folds (Fold 5) хамгийн урт болж харагдана. Энэ судалгааны KPI үнэлгээнд Fold 5-ын хуваалт ашиглагдсан (үндсэн бичвэрийн Зураг 3.4-ийг үзнэ үү).

Хавсралт В: Архитектурын KPI-ийн хэмжилтийн нөхцөл

Архитектурын хэмжигдэх KPI ба баталгаажуулалтын протокол

Архитектурын шийдлүүдийг зөвхөн бүтэц дүрслэлээр бус хэмжигдэх шалгуураар үнэлэх зорилгоор дараах баталгаажуулалтын протокол нэгтгэсэн. Энэ протокол нь API, worker, push урсгалын ажиллах чанарыг ижил нөхцөлд давтан шалгах үндсэн хүрээг тогтооно.

Хүснэгт В.1 Архитектурын баталгаажуулалтын KPI протокол

Компонент	KPI	Зорилтот босго	Баталгаажуулах арга
API давхарга	p95 latency	$\leq 350\text{ms}$	Ижил endpoint дээр 15 минутын тогтмол ачааллын туршилт, median/p95-г нэгтгэн тайлагнах
API давхарга	5xx алдааны хувь	$< 1.0\%$	Ачааллын туршилтын хугацаанд нийт хүсэлтэд харьцуулж тооцох
Worker урсгал	Job completion rate	$\geq 99\%$	Төлөвлөгөөт ажлын log мөрөөр амжилт/алдааны харьцааг өдөр тутамд тооцох
Worker урсгал	Retry recovery rate	$\geq 95\%$	Алдаатай job-ийн дахин оролдлогоос амжилттай сэргэсний хувийг хэмжих
Push урсгал	Notification delivery rate	$\geq 98\%$	Push сервисийн нийлбэр илгээлт ба хүрсэн мэдэгдлийн тоог харьцуулах

Хэмжилтийн нөхцөл

API давхаргын p95 latency хэмжилтийг дараах нөхцөлд явуулсан:

- **Хэмжилтийн байршил:** Улаанбаатар (Монгол улс)
- **Серверийн байршил:** Токио (Japan East, Azure App Service)
- **Сүлжээний RTT:** дунджаа 150–180ms
- **Хүсэлтийн тоо:** Эндпойнт тутамд $n=30$ хүсэлт
- **Ачааллын загвар:** Дараалсан (sequential) ачаалал, өөр өөр 3 endpoint-т
- **Хэмжилтийн хугацаа:** 15 минут (900 сек), тасралтгүй

Worker ба Push урсгалын KPI:

- **Worker job completion:** Өдөрт 50–100 ажил процесс хийгдэж, лог дээр бичигдэнэ
- **Worker scheduling:** Python threading (time.sleep мөчлөгт суурилсан) ашиглан минут бүр дохио үүсгэх мөчлөгийг гүйцэтгэдэг
- **Push delivery:** Expo Push API (exp.host) платформ, хүргэлтийн статистик Expo dashboard-аар тайлагнана

p95 latency зорилтот босгоос хэтрэлтийн дүн шинжилгээ

API давхаргын p95 latency 471–536ms байсан нь зорилтот 350ms-ийг хэтэрсэн. Үндсэн шалтгааны дүн шинжилгээ:

1. **Сүлжээний RTT нөлөө:** Улаанбаатараас Токиогийн сервер хүртэлх RTT дунджаар 150–180ms байдаг тул энэ сүлжээний саатлыг латентын зорилтот хүлээлтэд тооцох шаардлагатай
2. **MongoDB query latency:** /signals/latest endpoint-т MongoDB дээр дохиог авах query хэрэгтэй бөгөөд үндсэн database-д индексийн оновчлол хийгдээгүй үлдсэн
3. **Сериалчлалын ачаалал:** JSON сериалчлал нь томоохон объектын цуглуулгыг боловсруулахад нэмэлт ачаалал үүсгэдэг
4. **Кэшлэлтийн хомсдол:** /rates/live-ийн үр дүнг Redis кэшэд тогтмол хадгалдаггүй тул кэшлэлтийг сайжруулбал латент буурах боломжтой

Практик сайжруулах сонголтууд:

- MongoDB дохионы хадгалалтад (timestamp, symbol, timeframe) compound unique index + upsert бодлого хэрэгжүүлэх (idempotency)
- Серверийн бүсчлэлийг хэрэглэгчийн байршилд ойртуулах, эсвэл CDN/edge cache ашиглах
- Redis multi-tier кэшлэл (L1 in-memory, L2 Redis)
- Олон query-г багцлан (batch request) илгээх

Хавсралт Г: Эх сурвалжийн нэгтгэлийн дүрэм

Үр дүнгийн өгөгдлийн эх сурвалж ба reproducibility

Энэ бүлгийн бүх тоон дүнг түүхэн өгөгдөл дээрх системийн туршилтын логоудаас гаргав. Лог файлууд нь хуримтлагдсан (append) бүтэцтэй тул өмнөх гүйлтийн мөрүүд дараагийн файлд давтагддаг. Иймээс босго бүрийн run-ыг Loaded signals мөрөөр таньж, тухайн run-т харгалзах final balance болон TP/SL мөрүүдтэй тогтмол дүрмээр хослуулан нэгтгэл хийв. Энэ дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах нөхцөлийг хангана.

Хавсралт Д: MongoDB цуглуулгын схемийн хүснэгт

Системийн өгөгдлийн тогтвортой давхарга нь MongoDB Atlas үүлэн дээр байршуулсан 12 цуглуулгаас бүрдэх ба тэдгээрийг гүйцэтгэх үүргээр нь Хэрэглэгчийн, Дохио-Мэдэгдлийн, Мэдээний болон Системийн гэсэн 4 бүлэгт ангилав. Цуглуулга бүрийн гол талбарууд, индекс ба TTL (Time-To-Live) тохиргоог Хүснэгт Д.1-т нэгтгэв.

Хүснэгт Д.1 *MongoDB Atlas-д байршсан 12 цуглуулгын схем — гол талбарууд, индекс ба TTL тохиргоо*

Цуглуулга	Гол талбарууд	Индекс	TTL
<i>1. Хэрэглэгчийн бүлэг</i>			
users	_id, email, password_hash, name, created_at	unique(email)	—
push_tokens	user_id, push_token, platform, notifications_enabled, signal_threshold	unique(user_id)	—
refresh_tokens	user_id, token_hash, expires_at, created_at	—	expires_at
verification_codes	email, code (OTP), expires_at (+10мин), created_at	—	expires_at
reset_codes	email, code, expires_at, used	—	expires_at
<i>2. Дохио / Мэдэгдлийн бүлэг</i>			
signals	pair, symbol, timeframe, signal {BUY,SELL,HOLD}, confidence, entry_price, SL, TP, run_id, source, timestamp	unique(source, ts, sym, tf); (pair, created_at)	—
in_app_notifications	type {signal, news, security}, title, body, data, created_at, expires_at, read_by: [user_id]	—	expires_at
<i>3. Мэдээний бүлэг</i>			
ai_insights	pair, timestamp, analysis, type, expires_at	—	expires_at
news_analysis	event, impact, analysis, sentiment, timestamp, created_at	—	—
notified_events	event_id, notified_at	—	—
<i>4. Системийн бүлэг</i>			
job_locks	job_name, owner_id, expires_at (хуваарилагдсан түгжээ)	—	expires_at
analysis_jobs	job_id, status {pending,...,done}, result, created_at	—	—

Цуглуулга хоорондын гадаад түлхүүрийн (foreign key) харьцааг Хүснэгт Д.2-т харуулав.

Хүснэгт Д.2 *Цуглуулга хоорондын гадаад түлхүүрийн харилцаа*

Эх цуглуулга	Харьцаа	Зорилтот цуглуулга	Холбогдох талбар
users._id	1:1	push_tokens	user_id
users._id	1:N	refresh_tokens	user_id
signals._id	1:N	in_app_notifications	data.signal_id

Дизайны зарчмууд: (1) TTL индексүүд нь түр зуурын баримтуудыг (verification_codes, reset_codes, job_locks, refresh_tokens, in_app_notifications, ai_insights) автоматаар цэвэрлэж хадгалалтын зайг хэмнэдэг. (2) signals цуглуулгын (source, timestamp, symbol, timeframe) unique compound индекс нь олон instance-ын зэрэгцээ ажиллагаанд давхардсан дохио үүсэхээс сэргийлдэг (idempotent upsert). (3) job_locks цуглуулга нь олон Azure App Service instance-ийн зэрэгцээ ажиллах үед нэг scheduler-ийг зөвхөн нэг instance гүйцэтгэхийг хангадаг.

Хавсралт E: GBDT гиперпараметруудийн нарийвчилсан жагсаалт

§3.4-т (Гиперпараметр сонголтын протокол) дурдсан тогтвортой байдлын протоколын дагуу сонгогдсон LightGBM, XGBoost ба CatBoost загваруудын бүх гиперпараметрийг Хүснэгт E.1 хүснэгтэд нэгтгэв. Хүснэгт нь reproducibility-ийн зорилгод зориулагдсан бөгөөд параметр тус бүрийн утга ба үүргийг загвар бүрд харьцуулан харуулав.

Хүснэгт Е.1 Гурван GBDT загварын гиперпараметрууд

Параметр	LightGBM	XGBoost	CatBoost	Үүрэг
<i>Загварын ерөнхий бүтэц</i>				
n_estimators	500	500	500	Модны дээд тоо (эрт зогсоолтоор тасалдаг)
learning_rate	0.03	0.03	0.03	Алхамын хэмжээ; бага утга → удаан, гэхдээ тогтвортой
max_depth	6	5	5	Модны хамгийн их гүн
num_leaves	31	—	—	Leaf-wise өсөлтийн (LGBM) бутархай хязгаар
<i>Тогтмолжуулалт</i>				
min_child_samples	20	—	—	Leaf-д байх хамгийн бага дээж (LightGBM)
min_child_weight	—	5	—	Leaf-д шаардлагатай хамгийн бага жин (XGBoost)
reg_alpha (L1)	0.10	0.10	—	L1 норм нэмэх жин
reg_lambda (L2)	1.0	1.0	3.0	L2 норм нэмэх жин (CatBoost-д l2_leaf_reg)
gamma	—	0.1	—	Хуваалт хийх хамгийн бага алдагдлын бууралт (XGBoost)
subsample	0.7	0.7	—	Мөр түүвэрлэх хувь (bagging)
colsample_bytree	0.7	0.7	—	Шинж чанар түүвэрлэх хувь
<i>Сургалтын протокол</i>				
early_stopping_rounds	50	50	50	Val loss сайжрахгүй 50 давталт → зогсооно
eval_metric	multi_logloss	mlogloss	MultiClass	Multi-class cross-entropy
scale_pos_weight	neg/pos	neg/pos	—	Ангийн тэнцвэргүй байдлыг зохицуулах
random_state	42	42	42	Reproducibility-н seed
<i>Алгоритмын онцлог параметр</i>				
boosting_type	gbdt	gbtree	Plain	Үндсэн boosting аргачлал
grow_policy	leaf-wise	depth-wise	symmetric	Модны өсөлтийн стратеги
bootstrap_type	—	—	Bayesian	CatBoost-ийн bagging схем (bagging_temperature=1.0)

Тэмдэглэл: “—” нь тухайн параметр уг загварт байхгүйг харуулна. Хэт нийцлээс сэргийлэх зургаан арга хэмжээ (модны гүнийг хязгаарлах, бага learning rate, эрт зогсоолт, L1/L2 нормчлол, WFV, шинж чанарын цөөрөлт) бүгд энэ хүснэгтэд тусгагдсан.

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутан: s21c033b, М.Мөнхдорж

Удирдагч багш: Н.Соронзонболд

1. Удиртгал

Гадаад валютын зах зээл (Форекс) нь олон улсын макро эдийн засгийн хүчин зүйл, зах зээлийн сэтгэл санааны нөлөөгөөр тасралтгүй өөрчлөгддөг олон хэмжээст, өндөр хэлбэлзэлтэй өгөгдлийн эх сурвалж болдог. Ийм тогтворгүй (non-stationary) цаг хугацааны цуваанаас BUY/HOLD/SELL ангиллын дохио (classification signal) найдвартай гаргах нь машин сургалтын тулгамдсан сорилтын нэг. Энэ судалгаанд EUR/USD валютын хослолыг туршилтын домэйн болгон сонгов. Уламжлалт дүн шинжилгээ нь хүний субъектив шийдвэрт тулгуурладаг тул автоматжуулсан ML системийн хэрэгцээ тодорхой байна.

Харин зөвхөн загварын нарийвчлалыг өндөр байлгах нь хангалтгүй. Бодит цагийн дохионы урсгал, гүйцэтгэлийн чанарыг хэмжих аргачлал, хэрэглэгчид үр дүнг хүргэх мобайл интерфэйс — эдгээрийг хамтад нь шийдэх шаардлагатай. Иймд энэ судалгааны зорилго нь EUR/USD дээр машин сургалтын ансамбль загвар боловсруулж, дохионы чанарыг бодит нөхцөлд шалгаад, үр дүнг хэрэглэгчид хүргэх нэгдсэн системийг ажиллах прототип хэлбэрээр бүтээхэд оршино.

Гурван судалгааны асуулт тавьсан:

- **RQ1:** Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр найдвартай ажиллах уу?
- **RQ2:** Шүүгдсэн дохио бодит гүйцэтгэл дээр үнэхээр арилжаа болж хэрэгжих үү?
- **RQ3:** Тогтмол эрсдэлийн дүрэмтэй үед систем 1 жилийн тестийн цонхонд эерэг

хүлээгдэж буй өгөөж болон тогтвортой балансын өсөлттэй ажиллах уу?

2. Онолын суурь

Санхүүгийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд нейрон сүлжээ, тулгуур векторын машин (SVM)-аас эхэлж, LSTM, Transformer зэрэг гүн сургалтын архитектурт хүрсэн. Хэдий тийм ч дунд хэмжээний хүснэгтэн өгөгдөлд гүн сургалт нь тайлбарлах чадвар сул, параметр олон, хэт нийцэлд эмзэг зэрэг практик бэрхшээлтэй.

Krauss нар (2017) S&P 500 дээр градиент нэмэгдүүлсэн шийдвэрийн мод (GBDT) загварууд нь гүн нейрон сүлжээнээс **илүү тогтвортой гүйцэтгэл** үзүүлснийг тогтоосон. Ballings нар (2015) ансамбль аргууд дангаар ажилладаг загвараас **3–7% нарийвчлалын давуу** талтайг харуулсан.

Хэдий ийм нотолгоо бий ч дараах асуудлууд нээлттэй хэвээр:

- Форекс зах зээлийн олон интервалын онцлогийг тусгасан судалгаа цөөн
- XGBoost, LightGBM, CatBoost гурвыг ансамблаар Форекст харьцуулсан ажил дутмаг
- Дохио шүүлтүүр, гүйцэтгэлийн хөрвүүлэлт, мобайл интерфэйсийг нэгтгэсэн судалгаа хийгдээгүй

3. Судалгааны арга зүй

Арга барил: Зохиомжлох шинжлэх ухааны судалгаа (DSR) буюу “бүтээх–үнэлэх–сайжруулах” мөчлөгийг 7 давталтаар

хэрэгжүүлсэн. Давталт бүрд өмнөх хувилбарын алдааг шинжилж загвар болон шинж чанарыг боловсронгуй болгосон. Эцэстээ шинж чанарын тоог 75-аас 48-д, загварын тоог 9-өөс 3-т хүртэл цөөлж хэт нийцлийн эрсдэлийг бууруулсан.

Өгөгдөл: EUR/USD-ийн 2015–2024 оны OHLCV өгөгдлийг зургаан интервалаар (M1, M5, M15, M30, H1, H4) ашигласан. Интервал бүрээс 8 шинж чанар (хаалтын ханш, RSI, ATR, MA(5), MA(20), MA(50), хэлбэлзэл, өгөөж) тооцоолж нийт **48 шинж чанарын матриц** бүрдүүлсэн. Шошгыг ирээдүйн 240 минутын дээд/доод ханшийн хөдөлгөөнд (30 пипс, 1.5 дахин давамгайлал) үндэслэн BUY/SELL/HOLD гэж тодорхойлсон. Нэвчилтийн эрсдэлийг тусгай аудитаар шалгасан.

Загвар: LightGBM, XGBoost, CatBoost гурвыг зөөлөн санал хураалтаар нэгтгэсэн. Урагш гүйлгэн баталгаажуулалтын Fold 5 (2015–2022 сургалт, 2023 баталгаажуулалт, 2024 тест) дээр гол шинжилгээг хийсэн. Гиперпараметрийг тогтвортой байдлын протоколоор сонгосон: модны гүнийг хязгаарлаж (max_depth=5–6), L1/L2 тогтмолжуулалт нэмж, эрт зогсоолтоор (patience=50) хяналт тогтоосон.

Дохионы шүүлтүүр: Ансамблийн гаралтад итгэлцлийн босго (≥ 0.90) болон ATR (≥ 4.0 пипс) гэсэн хоёр шатлалт шүүлтүүр хэрэглэхэд 2025 оны 359,639 таамгийн дөнгөж **1.0% (3,567 дохио)** тэнцсэн. SL/TP-ийг ATR-д суурилан автоматаар тооцсон бөгөөд TP/SL=3:1 харьцаа тогтмол хадгалагдсан.

Туршилт: MetaTrader 5 дээр 2025.01.01–2026.01.01 хугацаанд, \$10,000 анхны хөрөнгөтэй, нэг агшинд нэг байрлал, бодит спрэд нөхцөлд туршсан. Итгэлцлийн босгыг 0.90-оос 0.99 хүртэл 10 утга бүхий сценарид харьцуулсан.

Архитектур: Систем гурван давхаргатай ML serving дамжлага хэлбэрт хэрэгжсэн: (1) офлайн сургалтын давхарга (GBDT загвар); (2) серверийн хэсэг (Python/Flask REST API, Python threading, MongoDB, Expo Push мэдэг-

дэл); (3) мобайл апп (React Native, 4 дэлгэц). Загвар нь REST API polling болон push notification хоёр дамжуулалтыг хослуулан хэрэгжүүлсэн. Дохио үүсгэх дамжлагыг (өгөгдөл татах, таамаглах, шүүх, SL/TP тооцоолох, мэдэгдэл илгээх) бүхэлд нь автоматжуулсан. Эцсийн шийдвэр (арилжаа нээх, хаах) нь хэрэглэгчийн мэдэлд үлдэнэ.

4. Судалгааны үр дүн

Өгөөж: Бүх 10 сценари эерэг өгөөжтэй гарсан. Buy-and-hold жишиг нь \$10,000-ийг +13.47% буюу \$11,347 болгосон. Хамгийн өндөр өгөөж 0.91 босгонд +517.70% (\$61,770) бол 0.90 дээр +482.62% гарсан. Босго өсөхөд дохио цөөрч өгөөж буурна: 0.93 дээр +368%, 0.96 дээр +230%, 0.99 дээр +74% (зөвхөн 147 дохио). Дэлгэрэнгүй томьёолол ба нийлмэлжүүлэлтийн контекстийг Ch4 §4.5.2-аас үзнэ үү.

Дохионы гүйцэтгэл: Ачаалагдсан дохиотой харьцуулахад бодитоор арилжаа болсон хувь 6.45–23.81% байсан. Энэ нь системийн алдаа бус, зориудын чанарын шүүлтүүрийн үр дүн юм: загвар минут бүр таамаглал гаргадаг ч нэг агшинд нэг байрлалын дүрэм болон итгэлцлийн босгыг хангаагүй дохиог алгасдаг. Босго өсөхөд дохио цөөрч, гүйцэтгэлийн хувь нэмэгдэх хандлага ажиглагдсан.

Ялалтын хувь: Ялалтын хувь 44.78–65.71% мужид байсан. TP/SL=3:1 нөхцөлд алдагдалгүй байх доод хязгаар 25% тул бүх сценари түүнээс дээш гарсан. Нэг арилжааны дундаж хүлээгдэж буй өгөөж (Expectancy) 0.79–1.63R мужид эерэг. Босго өсөхөд ялалтын хувь өсөх боловч арилжааны тоо цөөрснөөс итгэлцлийн интервал (95% Wilson CI) мөн өргөсдөг.

Эрсдэл: Sharpe 8.57–12.83, Sortino 23.97–44.76, Calmar 20.16–174.20. Эдгээр утга нь арилжаа цөөн (35–230 хэлцэл), туршилтын цонх богино (1 жил) ба зардлын бүрэн тусгаагүйгээс өндөр харагдаж буй тул сценарийн харьцангуй харьцуулалтын суурь болгож тайлбарлав (дэлгэрэнгүйг Ch4 §4.5-аас үзнэ үү). Хамгийн

их уналт (MaxDD) 1.98% (0.99)–9.53% (0.93), хамгийн урт дараалсан алдагдал 2–10 арилжаа. Балансын харьцангуй хэлбэлзэл (CV) 38.01% байгаа нь босго сонголт гүйцэтгэлд ихээхэн нөлөөтэй болохыг харуулна. 0.91 босго хамгийн өндөр өгөөж (+517.70%) ба бага уналт (MaxDD 2.97%)-ийг хослуулсан тэнцвэртэй сценари.

5. Судалгааны нэгтгэл

Судалгааны асуултуудад товчоор хариулвал:

- **RQ1:** WFV Fold 5-ийн тест өгөгдөл (2024) дээр нарийвчлал 89.25%, баталгаажуулалтын өгөгдөл дээрх итгэлцэл ≥ 0.90 дохионы нарийвчлал 96.96% гарсан нь загвар харагдаагүй өгөгдөл дээр тогтвортой ажиллаж буйг харуулсан.
- **RQ2:** Гүйцэтгэлийн хувь 6.45–23.81% байсан тул дохио бодит арилжаа болж хэрэгжсэн, гэхдээ нэг агшинд нэг байрлалын дүрмээс нэлээд хэсэг алгасагдсан.
- **RQ3:** Бүх сценарид buy-and-hold жишгийг давсан эерэг Expectancy (0.79–1.63R), MaxDD 1.98–9.53% гарсан.

Инженерчлэлийн талд загвар сургалтаас мобайл апп хүртэлх ML serving дамжлагыг ажиллах прототип хэлбэрээр бэлдсэн.

Хязгаарлалт (товч): (i) EUR/USD, нэг хугацааны цонхонд батлагдсан тул бусад хэрэгсэлд шууд нэвтрүүлэх боломжгүй; (ii) Спрэд, гулсалт тусгасан боловч шимтгэл, своп хамруулаагүй; (iii) Гүйцэтгэлийн хувь 100% биш тул ялалтын хувь хэрэгжсэн арилжааны багцад хүчинтэй. Бусад хязгаарлалт (нэвчилтийн үлдэгдэл, офлайн/онлайн зөрүү гэх мэт) §4.6.3-т нэгтгэгдсэн.

Цаашдын чиглэл: (1) GBP/USD, USD/JPY зэрэг хэрэгсэлд өргөтгөх, (2) LSTM/Transformer загвар ансамбльд нэмэх, (3) байрлалын хэмжээнд бататгах сургалт (RL) хэрэглэх, (4) NLP-ээр макро мэдээ шинжлэх,

(5) MLOps мониторинг ба Google Play түгээлт хэрэгжүүлэх.