



ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутны код: s21c033b

Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

/ДЭД БАКАЛАВРЫН ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот

2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Дэд бакалаврын төгсөлтийн судалгааны ажил (061301)

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ
СИСТЕМ

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот
2026 он

Хураангуй

Энэ судалгаагаар EUR/USD валютын хослол дээр машин сургалтын ансамблиар BUY/HOLD/SELL гурван ангиллын дохиог автоматаар гаргах системийг бүтээв. Гадаад валютын зах зээлийн (Форекс) шуугиан ихтэй, тогтворгүй (non-stationary) шинж чанар нь ангиллын хувьд хүнд сорилт болдог. Загварын ангиллын гүйцэтгэлийг цаг хугацааны дарааллыг хадгалсан баталгаажуулалт болон бодит нөхцөлийг дуурайсан симуляцаар цогцоор үнэлэв.

LightGBM, XGBoost, CatBoost гурван GBDT загварыг зөөлөн санал хураалтаар (soft voting) хослуулсан ансамблийг EUR/USD-ийн 2015–2024 оны өгөгдөл дээр урагш гүйлгэн баталгаажуулалт (Walk-Forward Validation, WFV) аргаар сургасан. 2024 оны тестийн ерөнхий нарийвчлал 89.25% ($F1\text{-macro}=59.45\%$, $F1\text{-weighted}=87.23\%$) бөгөөд HOLD ангийн давамгайлсан тэнцвэргүй өгөгдөлд нарийвчлал дангаараа хангалтгүй хэмжүүр болохыг $F1\text{-macro}$ харуулсан. Баталгаажуулалтын өгөгдөл дээр итгэлцэл ≥ 0.90 дохионы нарийвчлал 96.96% гарсан нь босгын шүүлтүүрийн үндэслэлийг харуулна. MetaTrader 5 дээр 2025 оны бүтэн жилд бүх 10 итгэлцлийн сценари эерэг өгөөж үзүүлсэн; 0.91 босгод +517.70% (\$61,770) хүрч, суурь жишгийн (EUR/USD-г худалдан аваад барих стратеги) +13.47%-г мэдэгдэхүйц давсан. Энэ дүн нь 1% эрсдэлийн тогтмол хэмжээ ба нийлмэл өсөлтийн үр нөлөөнөөс үүдэлтэй учир босго бүрийн сценарийг харьцуулах хэмжүүр болгон тайлбарлах нь зүйтэй. Брокерын шимтгэл болон шөнийн своп зардлыг энэ тооцоонд тусгаагүй.

Системийн инженерчлэлийн талд офлайн загвар сургалт, REST API сервер (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Expo Push) гэсэн дөрвөн давхаргаас бүрдсэн ML serving дамжлагыг прототип хэлбэрээр бэлдсэн.

Түлхүүр үгс: машин сургалт, GBDT ансамбль загвар, урагш гүйлгэн баталгаажуулалт, түүхэн өгөгдөл дээрх системийн туршилт, эрсдэл-өгөөжийн үнэлгээ

Гарчиг	
Хураангуй	i
Гарчиг	ii
Товчилсон үгсийн жагсаалт	iii
Хүснэгтийн жагсаалт	iv
Зургийн жагсаалт	v
Ажлын төлөвлөгөө	1
1 Удиртгал	2
1.1 Үндэслэл, ач холбогдол	2
1.2 Зорилго, зорилт	2
1.3 Судалгааны асуулт ба хэмжигдэх шалгуур	3
2 Судалгааны сэдвийн онол, өнөөгийн түвшин	4
2.1 Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд	4
2.2 Шинж чанаруудын судалгаа	5
2.3 Урагш гүйлгэн баталгаажуулалт	6
2.4 ML serving дамжлага ба мобайл аппын архитектур	6
2.5 Төсөөтэй системүүдийн харьцуулалт	6
2.6 Үндсэн судалгаануудтай харьцуулсан тойм	6
2.7 Судалгааны ажлын шинэлэг тал	7
3 Судалгааны арга зүй	8
3.1 Судалгааны арга барил	8
3.2 Системийн ерөнхий бүтэц	8
3.3 Өгөгдлийн урсгал	9
3.4 Өгөгдөл бэлтгэл	10
3.5 AI загварын бүтэц ба сургалт	14
3.6 Дохио үүсгэх систем	17
3.7 Стратегийн backtesting (түүхэн өгөгдөл дээрх системийн туршилт)	19
3.8 Серверийн хэсгийн хэрэгжүүлэлт	21
3.9 Харагдах хэсгийн архитектур	23
3.10 Загварын давталтын сайжруулалт	23
4 Судалгааны үр дүн	25
4.1 Үр дүнгийн өгөгдлийн эх сурвалж	25
4.2 Загварын ангиллын гүйцэтгэл	25
4.3 Босгын мужийн нэгдсэн үр дүн	26
4.4 Үр дүнгийн тайлбар	32
4.5 Архитектурын KPI-ийн баталгаажуулалтын үр дүн	32
4.6 Дүгнэлт	33
Ном зүй	35
Талархал	37
Хавсралт	38

Товчилсон үгсийн жагсаалт

ML Machine Learning – Машин сургалт

AI Artificial Intelligence – Хиймэл оюун ухаан

GBDT Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

XGBoost Extreme Gradient Boosting

LightGBM Light Gradient Boosting Machine

CatBoost Categorical Boosting

LSTM Long Short-Term Memory – Урт богино хугацааны санах ой

RSI Relative Strength Index – Харьцангуй хүчний индекс

ATR Average True Range – Дундаж жинхэнэ хүрээ

SMA Simple Moving Average – Энгийн хөдөлгөөнт дундаж

EMA Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

SL Stop Loss – Алдагдал зогсоох

TP Take Profit – Ашиг авах

API Application Programming Interface

REST Representational State Transfer

JWT JSON Web Token

OHLCV Open, High, Low, Close, Volume

MT5 MetaTrader 5

DD Drawdown – Уналт

RR Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

WSGI Web Server Gateway Interface

Expo Expo Push API (`exp.host`) – React Native апп руу push мэдэгдэл хүргэх үйлчилгээ

APNs Apple Push Notification service – Apple-н push мэдэгдэл хүргэх үйлчилгээ

UI User Interface – Хэрэглэгчийн интерфэйс

UX User Experience – Хэрэглэгчийн туршлага

WFV Walk-Forward Validation – Урагш гүйлгэн баталгаажуулалт

Хүснэгтийн жагсаалт

Хүснэгт 1.1.	Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)	3
Хүснэгт 2.1.	Холбогдох судалгаатай харьцуулсан үндсэн ялгаа	7
Хүснэгт 3.1.	Түүхэн өгөгдлийн хэмжээний хураангуй	11
Хүснэгт 3.2.	Шинж чанарын жагсаалт (интервал бүрд)	11
Хүснэгт 3.3.	Урагш гүйлгэн баталгаажуулалтын өгөгдлийн хуваалт	13
Хүснэгт 3.4.	Backtesting-ийн ЕА-ийн үндсэн тохиргоо	20
Хүснэгт 3.5.	Системийн үнэлгээний шалгуур үзүүлэлтүүд	21
Хүснэгт 3.6.	Загварын давталтын 7 үе шат	24
Хүснэгт 4.1.	GBDT ансамблийн нарийвчлал ба F1 оноо —хуваарь тус бүрээр	25
Хүснэгт 4.2.	Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт.....	25
Хүснэгт 4.3.	Итгэлцлийн мужийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)	26
Хүснэгт 4.4.	Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын товч үзүүлэлт (§4.3.6).....	33

Зургийн жагсаалт

Зураг 3.1.	Загварын 7 давталтын тойм	8
Зураг 3.2.	Системийн архитектур	8
Зураг 3.3.	Өгөгдлийн урсгал	10
Зураг 3.4.	Урагш гүйлгэн баталгаажуулалтын Fold 5-ын өгөгдлийн хуваалт	14
Зураг 3.5.	GBDT ансамбль загварын архитектур	16
Зураг 3.6.	Дохионы шүүлтүүрийн юүлүүр (0.90 босго)	17
Зураг 3.7.	Дохионы амьдралын мөчлөгийн төлөвт автомат	18
Зураг 3.8.	Дохио үүсгэх дараалал	19
Зураг 3.9.	Системийн байршуулалтын диаграмм	22
Зураг 3.10.	REST polling холболтын архитектур	23
Зураг 4.1.	Босго бүрийн эцсийн баланс	27
Зураг 4.2.	Босго тус бүрийн гүйцэтгэлийн хувь	27
Зураг 4.3.	Ялалтын хувь 95% Wilson итгэлцлийн интервалтай	28
Зураг 4.4.	Нэг арилжааны хүлээгдэж буй өгөөж $E[R]$	28
Зураг 4.5.	Эрсдэлийн үзүүлэлтүүд босго тус бүрээр	29
Зураг 4.6.	Босгуудын нэгдсэн (composite) ранкинг	30
Зураг 4.7.	Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын 8 үзүүлэлтийн радар профайл	30
Зураг 4.8.	Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын equity curve (2025 он)	31
Зураг 4.9.	Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын цэвэр ашиг/алдагдал (2025, сараар)	32

Ажлын төлөвлөгөө**Оюутны нэр:** М.Мөнхдорж**Удирдагч багшийн нэр:** Н.Соронзонболд

Судалгааны ажлын сэдэв: Машин сургалтын аргаар Форекс зах зээлийн арилжааны дохионы систем хөгжүүлж үнэлэх

Сар	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 сар	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Форекс арилжаа, машин сургалт (machine learning) онолын судалгаа хийх	✓
	3	Yahoo Finance ба MetaTrader 5-аас EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 сар	1	70+ техник индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest загвар сургах	✓
	3	Stacking Ensemble загвар хөгжүүлэх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх	✓
	4	Серверийн хэсэг болон мобайл апп хөгжүүлэх	✓
12 сар	1	ТСА Үзлэг 1	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 сар	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 сар	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	✓
	4	Хамгаалалтын бэлтгэл хийх	✓
3 сар	1	ТСА Үзлэг 2	✓
	2	Засвар хийх, санал хүсэлтийг тусгах	✓
	3	Код тайлбар, баримтжуулалт	✓
	4	Хамгаалалтын дадлага хийх	✓
4 сар	1	Эцсийн засвар хийх	✓
	2	Слайд сайжруулах	✓
	3	Хамгаалалтын бэлтгэл	✓
	4	ТСА урьдчилсан хамгаалалт	✓
5 сар	1	Эцсийн засвар, сайжруулалт	✓
	2	Эцсийн засвар, сайжруулалт	✓
	3	Эцсийн засвар, сайжруулалт	✓
	4	ТСА үндсэн хамгаалалт	✓

Удирдагч багш
Гүйцэтгэсэн оюутан

/Н.Соронзонболд, магистр/
/s21c033b, М.Мөнхдорж/

1. Удиртгал

1.1. Үндэслэл, ач холбогдол

Олон хэмжээст, шуугиан ихтэй цаг хугацааны цуваан өгөгдлийн дүн шинжилгээ нь өнөөгийн мэдээллийн технологийн томоохон сорилт юм. Үүний тод жишээ нь гадаад валютын зах зээл буюу Форекс юм. Энэ зах зээл нь олон улсын эдийн засгийн төлөв байдал, төв банкуудын бодлого зэрэг макро түвшний хүчин зүйлсээс хамааран тасралтгүй, өндөр хэлбэлзэлтэйгээр өөрчлөгддөг [1]. Ийм шугаман бус хандлагатай зах зээлийн өгөгдлөөс зүй тогтлыг илрүүлэх нь уламжлалт статистик аргуудын хувьд ноцтой бэрхшээл хэвээр байна.

Уламжлалт аргууд нь ихэвчлэн хүний шууд оролцоо, субъектив дүгнэлтэд тулгуурладаг тул их хэмжээний өгөгдлийг богино хугацаанд автоматаар боловсруулж таамаглахад тохиромжгүй. Иймд буруу дүгнэлт гарах эрсдэл өндөр байдаг.

Сүүлийн жилүүдэд машин сургалт болон хиймэл оюун ухааны алгоритмууд санхүүгийн салбарт эрчимтэй нэвтэрсэн. Тухайлбал, GBDT болон нейрон сүлжээ зэрэг орчин үеийн алгоритмууд их хэмжээний өгөгдлөөс нарийн зүй тогтлыг илрүүлэх чадвартайг олон судалгаа нотолсон [2, 3]. Хэдий тийм ч загвар сургалтын өгөгдөлдөө хэт нийцэх (overfitting), нэг алгоритмд түшиглэсэн архитектураас үүдэн системийн доголдол гарах зэрэг инженерчлэлийн асуудал практик орчинд тулгарсаар байна.

Энэ чиглэлийн судалгаанд загварын нарийвчлалыг дангаараа сайжруулах нь хангалтгүй. Серверийн хэсгийн бодит цагийн өгөгдөл боловсруулах урсгал, гүйцэтгэлийн жигд байдал, харагдах хэсэгт үр дүнг хүргэх уялдааг хамтад нь авч үзэх шаардлагатай. Энэ судалгаа нь загварын нарийвчлал, серверийн хэсгийн архитектур, мобайл интерфэйс гэсэн гурван давхаргыг нэг туршилтын хүрээнд нэгтгэж, тэдгээрийн хамтарсан гүйцэтгэлийг үнэлснээрээ ялгарна.

Энэ ажилд зөөлөн санал хураалтад суурилсан GBDT ансамбль загвар, цаг хугацааны дарааллыг хадгалсан урагш гүйлгэн баталгаажуулалт (Walk-Forward Validation, WFV), олон хугацааны интервалын шинж чанарын инженерчлэл (multi-timeframe feature engineering) гэсэн гурвыг нэгтгэн найдвартай ангиллын системийг хөгжүүлсэн. Загварын гаралтыг REST API болон мобайл аппаар дамжуулан хэрэглэгчдэд хүргэх ML serving дамжлагыг бүтээсэн. Ингэснээр загвар, серверийн хэсэг, харагдах хэсгийн уялдааг практикт ажиллах прототип хэлбэрээр хэрэгжүүлсэн.

1.2. Зорилго, зорилт

Судалгааны зорилго

Энэ судалгааны зорилго нь EUR/USD-ийн шуугиан ихтэй цаг хугацааны цуваан өгөгдөл дээр **GBDT ансамбль загвар ашиглан BUY/HOLD/SELL гурван ангиллын систем боловсруулахад** оршино. Ангиллын чанарыг итгэлцлийн шүүлтүүрээр сайжруулж, үүссэн дохионы гүйцэтгэлийг түүхэн өгөгдөл дээрх системийн туршилтаар үнэлнэ.

Судалгааны зорилтууд

Энэ зорилгод хүрэхийн тулд дөрвөн зорилтыг дэвшүүлэв:

1. Олон хугацааны интервалын (M1–H4, 6 интервал) санхүүгийн цаг хугацааны цуваанаас шинж чанарын матриц (48 feature) бүрдүүлж, гурван ангиллын (BUY / HOLD / SELL) сургалтын шошго үүсгэх; мэдээллийн нэвчилтийн (data leakage) эрсдэлийг аудитаар хянах.

2. Цаг хугацааны дарааллыг алдагдуулахгүй урагш гүйлгэн баталгаажуулалтад суурилсан GBDT ансамбль (LightGBM + XGBoost + CatBoost, зөөлөн санал хураалт)-ийн туршилтын орчныг хөгжүүлж, хэт нийцлийн эрсдэлийг хянах.
3. Ангиллын нарийвчлал, итгэлцлийн шүүлтийн нөлөө, дохио-гүйцэтгэлийн хөрвүүлэлт (signal-to-execution conversion rate) болон эрсдэл-өгөөжийн үзүүлэлтүүдийг нэгдсэн үнэлгээний хүрээнд хэмжих.
4. Бодит цагийн ML таамаглал гаргах серверийн REST API (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Expo Push)-ийг нэгтгэн, загвар сургалтаас хэрэглэгч хүртэлх ML serving дамжлагыг бүтээх.

1.3. Судалгааны асуулт ба хэмжигдэх шалгуур

Судалгааны ажлын зорилтуудыг хэмжихүйц шалгууруудтай холбохын тулд гурван судалгааны асуултыг доор тодорхойлов.

Хүснэгт 1.1 Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)

RQ	Судалгааны асуулт	Хэмжих шалгуур үзүүлэлт
RQ1	Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр найдвартай ажиллах уу?	Ерөнхий ангиллын чанар (accuracy/F1), мөн өндөр итгэлцэлтэй дохионы дэд багц дахь чанар
RQ2	Шүүгдсэн дохио бодит гүйцэтгэл дээр үнэхээр арилжаа болж хэрэгжих үү?	Дохионы гүйцэтгэлийн хувь (execution rate), амжилттай арилжааны хувь (win rate), win rate-ийн Wilson 95% итгэлцлийн интервал
RQ3	Тогтмол эрсдэлийн дүрэмтэй үед систем 1 жилийн тестийн цонхонд эерэг хүлээгдэж буй өгөөж болон тогтвортой балансын өсөлттэй ажиллах уу?	Эцсийн үлдэгдэл ба нийт өгөөж, нэг арилжааны хүлээгдэж буй өгөөж (Expectancy, R), сценарийн хэлбэлзэл (балансын CV)

2. Судалгааны сэдвийн онол, өнөөгийн түвшин

2.1. Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

Уламжлалт машин сургалтын аргууд

Санхүүгийн зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн өмнөх судалгаанууд нь голчлон нейрон сүлжээ болон тулгуур векторын машин (SVM) зэрэг аргад төвлөрч байсан. Kamruzzaman, Sarker нар (2003) нь нейрон сүлжээгээр валютын ханш таамаглахад 81% (in-sample) нарийвчлалд хүрсэн. Гэвч судалгаа нь нэг валютын хослолд хязгаарлагдаж, хэт нийцлийн асуудалтай, бодит орчны туршилтын үнэлгээ хангалтгүй байсан [4]. Kumar, Thenmozhi нар (2006) нь SVM болон Random Forest-ийн харьцуулалтад зах зээлийн нөхцөл өөрчлөгдөхөд загварын тогтвортой байдал буурах эрсдэлийг онцолсон [5].

Санамсаргүй ой (random forest) болон градиент нэмэгдүүлэлт (gradient boosting) аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings тэргүүтэй судлаачид (2015) нь хувьцааны ханшийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц гарсан** болохыг тогтоосон [6]. Харин Форекс зах зээлд ансамбль аргыг хэрэглэсэн эмпирик харьцуулалтын судалгаа хангалттай хуримтлагдаагүй байна.

Гүн сургалтын аргууд

Сүүлийн жилүүдэд урт богино хугацааны санах ой (long short-term memory, LSTM) болон гүн нейрон сүлжээ (deep neural network, DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer, Krauss нар (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang тэргүүтэй судлаачид (2019) нь санхүүгийн цаг хугацааны цуваанд гүн сургалтын хэрэглээг системтэй тоймлоосон [8].

Форекс зах зээлд тусгайлан чиглэсэн судалгааны хувьд Yildirim тэргүүтэй судлаачид (2021) гадаад валютын өдрийн өгөгдөл дээр LSTM загварыг техник болон макро эдийн засгийн үзүүлэлттэй хослуулан ханшийн чиглэлийн хөдөлгөөнийг таамаглах аргыг туршсан [9]. Ozbayoglu тэргүүтэй судлаачид (2020) санхүүгийн салбар дахь гүн сургалтын хэрэглээг үнийн таамаглал, портфелийн удирдлага, эрсдэлийн үнэлгээ зэрэг чиглэлээр өргөн хүрээнд тоймлоосон [10]. Сүүлийн жилүүдэд PatchTST [11] болон TimesNet [12] зэрэг трансформерт суурилсан орчин үеийн архитектурууд урт хугацааны цаг хугацааны цуваа таамаглалд дэвшил гаргасан боловч эдгээр нь ерөнхий зориулалттай бөгөөд санхүүгийн олон интервалын хүснэгтэн шинж чанарын онцлогт тусгайлан тохируулагдаагүй.

Эдгээр загваруудын гол сул тал нь дараах байдлаар илэрнэ: тайлбарлах боломж сул, параметр олон, хэт нийцэлд эмзэг, анхны параметрээс их хамааралтай [13]. Krauss нар (2017) S&P 500 дээр LSTM болон GBDT-ийг харьцуулж, **GBDT загварууд илүү найдвартай үр дүн үзүүлсэн** гэж дүгнэсэн нь энэ судалгаанд GBDT ансамблийг сонгох гол үндэслэл болсон.

Градиент нэмэгдүүлсэн шийдвэрийн мод санхүүгийн салбарт

GBDT нь Friedman (2001)-ийн боловсруулсан аргачлал бөгөөд олон шийдвэрийн мод (decision tree)-ийг дараалан нэмж, алхам бүрд өмнөх загварын үлдэгдэл алдааг (gradient) бууруулж сургадаг [14]. Gu, Kelly болон Xiu (2020) нь 150+ хувьсагчтай GBDT загвар хувьцааны өгөөжийг гүн сургалтаас илүү нарийвчлалтай таамагласныг тогтоосон [15]. GBDT нь хүснэгтэн өгөгдөлд тохирсон шинж чанарын харилцан үйлчлэлийг барьж авдаг, тайлбарлах боломжтой, гажиг утгад тэсвэртэй гэсэн давуу талтай. XGBoost [2], LightGBM [3], CatBoost [16] нь тус бүрийн онцлог (L1/L2 тогтмолжуулалт,

хурд, нэвчилтийн эрсдэл бууруулалт) бүхий орчин үеийн хэрэгжүүлэлтүүд боловч гурвыг нэгтгэн WFV болон нэвчилтийн хяналттай Форекс зах зээлд туршсан эмпирик нотолгоо хомс байна.

Ансамбль аргуудын хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [17]. Breiman (2001) санамсаргүй ой аргаар олон модыг параллель сургаж, дундажлах (average) замаар хэлбэлзэл (variance)-ийг бууруулсан [18]. Sezer тэргүүтэй судлаачид (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол өндөр гүйцэтгэлтэй байдгийг** дурдсан [19].

Өмнөх судалгаануудын хүрэн дэх нээлттэй асуудлууд

Дээр дурдсан ажлуудаас энэ судалгааны хувьд хамааралтай гурван нээлттэй асуудлыг тодорхойлов:

- **Форекс зах зээлийн онцлог тусгагдаагүй:** Судалгааны ихэнх нь хувьцааны зах зээлд төвлөрсөн тул 24/5 үргэлжлэх Форекс зах зээлийн өгөгдлийн онцлог, олон хугацааны интервалын нэгдсэн нөлөөг үнэлсэн ажил хомс байна.
- **GBDT ансамблийн харьцуулалт дутуу:** XGBoost, LightGBM, CatBoost-ийг нэг орчинд ансамбль хэлбэрээр харьцуулан, WFV болон нэвчилтийн хяналттай нэгдсэн эмпирик нотолгоо хязгаарлагдмал.
- **Практик хэрэгжүүлэлт хамрагдаагүй:** Загварын нарийвчлалаас эхлэн мобайл аппликейшн хүртэлх бүрэн цогц системийн үнэлгээг нэг судалгааны хүрээнд хийсэн ажил ховор.

2.2. Шинж чанаруудын судалгаа

Энэ судалгаагаар олон хугацааны интервалын шинж чанарыг хослуулан ашигласан үндэслэлийг өмнөх ажлуудтай уялдуулж тогтоов. Доор уг сонголтыг гурван чиглэлийн уран зохиолоор баталгаажуулсан.

Зах зээлийн үр ашгийн таамаглалын эргэлзэл

Fama (1970)-ийн зах зээлийн үр ашгийн таамаглал (Efficient Market Hypothesis, EMH) нь үнийн түүхээс ирээдүйг таамаглах боломжгүй гэж дүгнэсэн [20]. Гэвч Lo болон бусад (2000) нарийвчилсан статистик тестүүдээр **техник аргууд ач холбогдолтой үр дүн өгч чаддаг** болохыг нотолж энэхүү онолыг тодорхой хэмжээнд эргэлзэлд оруулсан [21]. Park, Irwin нар (2007) 95 судалгааг тоймлон **техник аргуудын үр дүн цаг хугацааны явцад буурч байгаа** болохыг харуулж, үүнийг зах зээлийн дасан зохицох чадварын (adaptive market) илрэл гэж тайлбарласан [22]. Эдгээр ажлууд нь EMH-ийн хатуу хэлбэрийг үгүйсгээгүй боловч техник шинж чанарыг машин сургалттай хослуулах эмпирик үндэслэлийг хангадаг. Зах зээл дасан зохицдог тул нэг загвар тогтмол ашигтай хэвээр байх боломжгүй; иймд олон шинж чанартай, давтан сурдаг ансамбль систем шаардагдана.

Олон шинж чанар, олон хугацааны интервалын хэрэгцээ

Olson (2004) нь **ганц шинж чанар тогтмол ашиг өгөх боломжгүй** гэж дүгнэж, хугацааны интервал өөрчлөгдөхөд индикаторын үр дүн мөн өөрчлөгддөг тул олон шинж чанарыг хослуулах,

олон хугацааны хүрээг зэрэг ашиглах шаардлагыг онцолсон [23]. Энэ дүгнэлт нь Lo-Park-Irwin-ийн ажилтай нийцдэг: дангаар нэг арга өөрөө хангалттай биш бөгөөд олон эх сурвалжийн мэдээллийг нэгтгэх замаар тогтвортой давуу талыг олох боломжтой. Энэ судалгаанд M1–H4 6 интервалын 48 шинж чанарыг сонгосон нь Olson-ийн дүгнэлтийн шууд хэрэглээ юм; нарийвчилсан шинж чанарын инженерчлэлийн аргачлалыг §3.4.2-т үзүүлэв.

Бодит зардлын тусгал

Brock нар (1992) болон Marshall нар (2008) бодит орчны туршилтад **спрэд, гулсалт зэрэг зардлуудыг тусгах зайлшгүй шаардлагыг** нотолсон [24, 25]. Тэдгээрийн нийтлэг дүгнэлт нь техник стратеги зөвхөн зардалгүй (frictionless) орчинд ашигтай харагдах ч бодит брокерын нөхцөл (spread, slippage, commission)-ийг тусгахад статистикийн ач холбогдол ноцтой буурдаг. Энэ судалгаанд MetaTrader 5 Strategy Tester-ийн бодит спрэд болон 10 point-ийн гулсалтын хязгаар тусгасан нь Brock-Marshall-ийн шаардлагыг хангадаг; гэхдээ брокерын шимтгэл болон шөнийн своп тусгаагүй үлдэгдэл хязгаарлалтыг §4.6.3-т ил тэмдэглэв.

2.3. Урагш гүйлгэн баталгаажуулалт

Уламжлалт k-fold cross-validation нь санхүүгийн цуваа өгөгдөлд цаг хугацааны дарааллыг зөрчиж, ирээдүйн мэдээлэл (look-ahead bias) ашиглах эрсдэлтэй. Pardo (2008) нь урагш гүйлгэн баталгаажуулалт (WFV) нь ирээдүйн өгөгдлийг сургалтаас тусгаарлаж, бодит арилжааны нөхцөлийг дуурайдгаараа давуу болохыг нотолсон [26]. Bailey нар (2014) **олон параметрийн тохируулга нь түүврийн гадуурх үр дүнг муутгадаг** гэж анхааруулсан [27]. Энэ дүгнэлтэд тулгуурлан судалгаанд цаг хугацааны дарааллыг хадгалсан сургалт/баталгаажуулалт/тестийн хуваалтыг ашигласан; нарийвчилсан хуваарийг §3-т үзүүлэв.

2.4. ML serving дамжлага ба мобайл аппын архитектур

React Native [28] нь нэг кодын сууриар Android аппликейшн хурдан хөгжүүлэхэд тохиромжтой [29]. Flask нь хөнгөн WSGI фреймворк бөгөөд ML загварыг REST API-аар туршихад тохиромжтой [30]. ML системийн судалгааны ихэнх нь офлайн метрикүүдэд төвлөрдөг бол энэ судалгаанд загварын үнэлгээг API latency, мэдээлэл хүргэлтийн чанар зэрэг системийн ажиллагааны үнэлгээтэй нэгтгэн хэмжсэн.

2.5. Төсөөтэй системүүдийн харьцуулалт

Зах зээлд AlgoTrade 3 (Daily timeframe-д суурилсан симуляци) болон Tradlgo (no-code AI стратеги) зэрэг апп байдаг ч эдгээр нь бодит цагийн олон интервалын ML дохиог мобайл хэрэглэгчид хүргэх зорилготой биш. Freqtrade (FreqAI модуль) болон QuantConnect зэрэг нээлттэй эхийн системүүд ML арилжааны дэд бүтцийн жишээ болдог боловч автомат арилжааны бот зориулалттай, хэрэглэгчдэд ээлтэй мобайл интерфэйсээр хангагдаагүй. “Predictrix” нь шийдвэр гаргалтыг дэмжих зорилготой мобайл аппликейшны судалгааны прототип болсноороо ялгарна.

2.6. Үндсэн судалгаануудтай харьцуулсан тойм

Хүснэгт 2.1 нь хамгийн ойр төстэй дөрвөн ажилтай харьцуулсан үндсэн ялгаануудыг нэгтгэв. Энэ судалгаа нь Krauss нарын (2017) GBDT-ийн санхүүгийн давуу талын дүгнэлтийг Форекс домэйнд өргөтгөж, гурван загварыг (XGBoost, LightGBM, CatBoost) ансамбль хэлбэрээр нэг орчинд харьцуулсан анхны эмпирик ажлуудын нэг болж байна. Fischer, Krauss (2018) нь LSTM-ийг S&P 500 дээр

туршсан бол энэ ажил GBDT-ийг Форекс зах зээлийн олон интервалын онцлогт тохируулсан. Yildirim нарын (2021) нэг хугацааны интервал ашигласан хязгаарлалтыг M1–H4 6 интервалын нэгтгэлээр давсан. Ozbayoglu нарын (2020) гүн сургалтад чиглэсэн тоймоос ялгарч хүснэгтэн өгөгдөлд тохирсон GBDT-ийг сонгож, түүний үндэслэлийг §2.1.3-д тайлбарлав.

Хүснэгт 2.1 *Холбогдох судалгаатай харьцуулсан үндсэн ялгаа*

Судалгаа	Загвар	Зах зээл / интервал	Энэ ажлын ялгаа
Krauss нар (2017)	GBDT vs LSTM	S&P 500, өдрийн	3 GBDT ансамбль, Форекс, M1–H4
Fischer, Krauss (2018)	Ганц LSTM	S&P 500, өдрийн	GBDT ансамбль + WFV + олон интервал
Yildirim нар (2021)	LSTM + макро	EUR/USD, өдрийн	GBDT ансамбль + 6 интервал + мобайл систем
Ozbayoglu нар (2020)	Гүн сургалтын тойм	—	GBDT-ийн хүснэгтэн давуу тал, нэгдсэн систем


2.7. Судалгааны ажлын шинэлэг тал

Дээрх нээлттэй асуудлууд болон харьцуулсан тоймд тулгуурлан энэ судалгаа дөрвөн хувь нэмрийг оруулна: (1) XGBoost, LightGBM, CatBoost гэсэн гурван загварыг ансамбль хэлбэрээр нэг орчинд туршсан; (2) M1–H4 6 хугацааны интервалын 48 шинж чанар ашигласан; (3) WFV болон нэвчилтийн хяналт бүхий цаг хугацааны тусгаарлалтыг бодит MT5 өгөгдөл дээр хэрэгжүүлсэн; (4) загвар сургалтаас мобайл апп хүртэлх ML serving дамжлагыг иж бүрэн хэрэгжүүлсэн.

3. Судалгааны арга зүй

3.1. Судалгааны арга барил


Энэ судалгаа нь **дизайн судалгаа** (design science research, DSR) [31] арга зүйд суурилсан. ML ансамбль загвар бүхий дохионы системийг артефакт болгон бүтээж, MetaTrader 5-ийн бодит нөхцөлд (спрэд, гулсалт) туршилтаар баталгаажуулсан [32]. Судалгааны процессыг 7 давталтын хөгжүүлэлтийн мөчлөгөөр явуулсан; үе шат бүрийн гол өөрчлөлтийг Зураг 3.1-т нэгтгэв.



Зураг 3.1 Загварын 7 давталтын тойм

3.2. Системийн ерөнхий бүтэц

Систем нь санхүүгийн өгөгдлийг хиймэл оюуны ансамбль загвараар боловсруулан дохио үүсгэж, мобайл аппаар дамжуулан арилжаачдад хүргэдэг. Системийн **ерөнхий архитектур**-ыг Зураг 3.2-т харуулав. Гүйцэтгэлийн орчны нарийвчилсан UML байршуулалтын диаграмм (deployment diagram)-ыг §3.8-т (Зураг 3.9) тусад нь харуулсан.



Зураг 3.2 Системийн архитектур

Зураг 3.2-т харуулсан архитектур нь дөрвөн үндсэн бүс болон тусдаа офлайн сургалтын хэсгээс бүрдэнэ.

Хэрэглэгчийн хэсэг (дээд тал): хэрэглэгчид React Native мобайл апп (Android ·iOS)-ын тусламжтайгаар системд хандана. Хүсэлт DNS-ээр дамжин шууд сервер рүү чиглэгдэнэ.

Сервер (төв хэсэг): нэг Docker контейнер дотор Flask + Gunicorn (API сервер) болон *фон процесс* (background worker) гэсэн хоёр процесс зэрэгцэн ажиллана. API сервер нь @app.route декораторт бүртгэсэн ~30 HTTP интерфэйсийг (endpoint) гаргадаг. Фон процесс нь утсан (thread) дээр суурилсан хуваарилагчаар (scheduler) дохио үүсгэх (60 сек), мэдээ шинэчлэх (30 мин), мэдэгдэл илгээх, хослолын шинжилгээ хийх даалгавруудыг гүйцэтгэдэг. Мөн GBDT (LightGBM + XGBoost + CatBoost) ансамблийн таамаглалыг (inference) тус процесс хариуцна. Хоёр процессыг APP_PROCESS_ROLE орчны хувьсагчаар (api /worker / all) тохируулна.

Серверийн доод хэсэгт өгөгдлийн давхарга байрладаг. *Кэш сан* нь сонголтот Redis (хүсэлтийн хязгаарлалтад (rate limiting) хэрэглэгддэг ба байхгүй үед санах ойн нөөц шийдэлд (fallback) шилждэг). *MongoDB* нь үндсэн агуулах болж системийн бүх төлөвийг (хэрэглэгчийн профайл, дохио, нэвтрэлтийн токен, push мэдэгдэл, мэдээний шинжилгээ, даалгаврын дараалал г.м.) цуглуулгуудад хадгална; цуглуулга бүрийн схемийг Хавсралт Д-ээс үзнэ үү.


Дотоод сервис (зүүн тал, улаан): системийн дотоодоос ашиглах туслах сервисүүд —*И-мэйл* нь Flask-Mail SMTP (Gmail) ашиглан баталгаажуулах болон нууц үг сэргээх кодыг илгээдэг; *Даалгаврын дараалал* нь analysis_jobs цуглуулга дахь LLM зах зээлийн шинжилгээний даалгаврын дараалал ба job_locks (TTL индекстэй) хуваарилагдсан түгжээгээс бүрдэнэ; *Хяналт* нь /health интерфэйс болон Azure App Service лог-ыг хамардаг.

Гуравдагч талын API (баруун тал, ногоон): дөрвөн гадны API нь нэгдсэн нэг сувгаар фон процесс руу өгөгдөл нийлүүлдэг —*Yahoo Finance* (yfinance-аар OHLCV ханш), *AlphaVantage* (мэдээний сэтгэгдлийн шинжилгээ), *TradingView* (эдийн засгийн хуанли), *Gemini API* (LLM-д суурилсан зах зээлийн шинжилгээ). *Expo Push* нь зүүн-дээд буланд тусдаа байрласан бөгөөд сервер→мобайл чиглэлийн түлхэлтийн мэдэгдэл (push notification) хүргэх суваг юм (тасархай ягаан сум).

Офлайн сургалт (доод хэсэг, ашиглалтын орчноос тусдаа): түүхэн OHLCV (2015–2024) өгөгдөл дээр GBDT ансамблийг сургаж model.pkl артефакт үүсгэнэ. Энэ артефакт нь фон процесс руу «байршуул» сумаар хуулагдаж ашиглалтын таамаглалд хэрэглэгдэнэ. Гүйцэтгэлийн орчны нарийвчилсан UML байршуулалтын диаграммыг §3.8 (Зураг 3.9)-аас үзнэ үү.

3.3. Өгөгдлийн урсгал

Системд өгөгдөл хэрхэн урсаж, боловсруулагддагийг Зураг 3.3-т Gane–Sarson нотацын дагуу үзүүлэв. Гадаад эх сурвалжаас (Yahoo Finance, AlphaVantage, TradingView) өгөгдөл орж ирээд, серверийн процессуудаар боловсруулагдан MongoDB цуглуулгад хадгалагдсаны дараа REST API-аар дамжин хэрэглэгчдэд хүрнэ. Сервер дээр дохио үүсгэх логик 60 секундын, мэдээ боловсруулах логик 30 минутын давтамжтай ажилладаг (цаг хугацааны хяналт нь DFD-ийн илэрхийллийн хүрээнээс гадуур тул диаграммд тусгаагүй). Олон instance ажиллах үед эдгээр процессын зөв нэгдсэн байдлыг MongoDB job_locks цуглуулга дахь хуваарилагдсан түгжээгээр хангадаг.



Зураг 3.3 Өгөгдлийн урсгал

Системийн өгөгдлийн урсгалд Gemini API-д суурилсан LLM бүрэлдэхүүнийг багтаасан. Энэ нь GBDT-ийн таамгийн тайлбар хураангуйг MongoDB-д тусдаа талбараар хадгалж, мобайл аппын харагдах хэсэгт үзүүлдэг. LLM нь BUY/HOLD/SELL шийдвэрт нөлөөлөхгүй; тоон үнэлгээг цаашдын судалгаанд үлдээсэн.

3.4. Өгөгдөл бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5 платформуос EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 3.1 нь интервал бүрийн өгөгдлийн хэмжээг нэгтгэв.

Хүснэгт 3.1 Түүхэн өгөгдлийн хэмжээний хураангуй

Хугацааны интервал	Мөрийн тоо	Хугацаа
M1 (1 минут)	~3,700,000	2015–2024
M5 (5 минут)	~740,000	2015–2024
M15 (15 минут)	~247,000	2015–2024
M30 (30 минут)	~123,000	2015–2024
H1 (1 цаг)	~62,000	2015–2024
H4 (4 цаг)	~15,500	2015–2024

Олон цагийн интервал бүхий өгөгдлийг хослуулах замаар загвар нь зах зээлийн богино хугацааны хэлбэлзэл (M1, M5), дунд хугацааны чиг хандлага (M15, M30), мөн урт хугацааны бүтэц (H1, H4)-ыг нэгэн зэрэг харах боломжтой болсон. Энэ олон хугацааны интервалын арга нь шинж чанарын инженерчлэлийн “олон хугацааны хүрээ” (multiple timeframe analysis) зарчимд нийцдэг [33].

Шинж чанарын инженерчлэл

Интервал бүрээс 8 шинж чанар тооцоолж, нийт 48 шинж чанар бүхий матриц үүсгэсэн. Хүснэгт 3.2 нь шинж чанаруудыг жагсаав.

Домэйны нэр томьёо: Лаа (candle, мөн OHLCV бар гэнэ) нь тодорхой хугацааны интервалын нээлт (open), дээд (high), доод (low), хаалт (close) ханш болон эргэлт (volume)-ийн таван утгыг хамарсан нэгдсэн өгөгдлийн цэг. Жишээлбэл, M1 интервалын нэг лаа нь 1 минутын хугацааны OHLCV утгуудыг илэрхийлдэг. RSI нь Relative Strength Index (харьцангуй хүчний индекс), ATR нь Average True Range (дундаж жинхэнэ хүрээ), SMA нь Simple Moving Average (энгийн хөдөлгөөнт дундаж)-ийн товчлол.

Хүснэгт 3.2 Шинж чанарын жагсаалт (интервал бүрд)

№	Шинж чанар	Тайлбар
1	close	Тухайн candle-ийн хаалтын ханш
2	rsi	RSI (14 candle) — хэт худалдсан/хэт худалдан авсан байдлыг 0–100 хуваарьт хэмждэг импульс шинж чанар
3	atr	ATR (14 candle) — сүүлийн 14 candle-ийн дундаж жинхэнэ хүрээ; зах зээлийн эрсдэлийн хэмжүүр
4	ma_5	Сүүлийн 5 candle-ийн хаалтын ханшийн хөдөлгөөнт дундаж (SMA) — богино хугацааны чиглэл
5	ma_20	Сүүлийн 20 candle-ийн SMA — дунд хугацааны чиглэл
6	ma_50	Сүүлийн 50 candle-ийн SMA — урт хугацааны чиглэл
7	volatility	Сүүлийн 20 candle-ийн хаалтын ханшийн стандарт хазайлт; зах зээлийн тайван эсвэл хэлбэлзэлтэй байдлын үзүүлэлт
8	returns	Өмнөх candle-тэй харьцуулсан ханшийн өөрчлөлтийн хувь (pct_change)

Эхний шатанд 75 боломжит шинж чанарыг туршсаны дараа эцсийн матрицад 8 шинж чанарыг тогтмол болгосон: чиг хандлага (close, MA-5/20/50), импульс (RSI), хэлбэлзэл ба эрсдэл (ATR, volatility, returns). Сонголтыг **домэйны зарчмаар** хийсэн: шинж чанаруудыг гурван ангилалд (чиг

хандлага, импульс, хэлбэлзэл) тэнцвэртэй хуваарилж, МА-аас математикийн хувьд гарвалтай (MACD, дэд МА-ийн ялгавар г.м.) эсвэл RSI/ATR-тай үндсэндээ ижил мэдээлэл өгөх давхардсан индикаторуудыг хасах байдлаар цөөрүүлсэн. Шинж чанаруудыг `_1min_4H` дагавраар ялгасан. Нэгдсэн 1 минутын суурь цувааг 6 интервалд `pandas.resample()` хийгээд интервал бүрд 8 индикатор тооцов. Дараа нь `merge_asof(backward)` аргаар нэгтгэснээр $8 \times 6 = 48$ хэмжээст шинж чанарын вектор $\mathbf{x} \in \mathbb{R}^{48}$ үүсгэдэг.

Шошго (label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) ханшийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

Домэйны нэр томьёо: Пипс (pip, percentage in point) нь Форекс зах зээлд ханшийн хамгийн бага өөрчлөлтийн нэгж; EUR/USD-д 1 пипс = 0.0001. Зах зээлийн хэлбэлзлийг хэмжихэд хэрэглэгддэг.

$$\text{label} = \begin{cases} \text{BUY (+1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (3.1)$$

Үүнд Δ_{up} нь ирээдүйн 240 минутын дээд ханш ба одоогийн хаалтын зөрүү, Δ_{down} нь доод ханшийн зөрүү (пипсээр); 30 пипсийн босго нь EUR/USD-ийн дундаж өдрийн ATR(14) (≈ 80 пипс)-ийн 37%; 1.5 давамгайлалыг [1.2, 2.0] мужид туршиж шошгын тэнцвэрийг харгалзан сонгосон.

Томьёоны бодит хэрэгжилтийг Алгоритм 1-д псевдокод хэлбэрээр тоймлов.

Algorithm 1 Шошго үүсгэх алгоритм

Оролт: OHLC цуваа $\{(t_i, o_i, h_i, l_i, c_i)\}_{i=1}^N$, ирээдүйн цонх $W = 240$ мин, босго $\theta = 30$ пипс, давамгайлал $\rho = 1.5$

Гаралт: Шошгын вектор $\mathbf{y} \in \{-1, 0, +1\}^N$

```

1: pip_size  $\leftarrow$  0.0001 // зөвхөн EUR/USD-д
2: for  $i = 1, \dots, N - W$  do
3:    $H_{\max} \leftarrow \max_{j \in [i+1, i+W]} h_j$ 
4:    $L_{\min} \leftarrow \min_{j \in [i+1, i+W]} l_j$ 
5:    $\Delta_{\text{up}} \leftarrow (H_{\max} - c_i) / \text{pip\_size}$ 
6:    $\Delta_{\text{down}} \leftarrow (c_i - L_{\min}) / \text{pip\_size}$ 
7:   if  $\Delta_{\text{up}} \geq \theta$  and  $\Delta_{\text{up}} > \rho \cdot \Delta_{\text{down}}$  then  $y_i \leftarrow +1$  // BUY
8:   else if  $\Delta_{\text{down}} \geq \theta$  and  $\Delta_{\text{down}} > \rho \cdot \Delta_{\text{up}}$  then  $y_i \leftarrow -1$  // SELL
9:   else  $y_i \leftarrow 0$  // HOLD
10: end for
11:  $y_{N-W+1}, \dots, y_N \leftarrow \text{NaN}$  // сүүлийн  $W$  candle-д шошго байхгүй
12: буцаах:  $\mathbf{y}$ 

```

2015–2024 оны M1 өгөгдөл (3,726,046 цэг) дээрх ангиллын хуваарилалт нь HOLD 75.5% (2,812,515 цэг), BUY 12.2% (454,999 цэг), SELL 12.3% (458,532 цэг) хэлбэртэй гарсан. Энэхүү тэнцвэргүй байдлыг зохицуулахын тулд LightGBM ба XGBoost загваруудад `scale_pos_weight =`

neg/pos параметрийг тохируулсан. Ангилал тус бүрийн загвар дээрх нөлөө болон BUY/SELL ангийн recall-ийн дүн шинжилгээг §4.2-т нэгтгэв.

Шошго ба шинж чанарын цагийн нийцлийн аудит (leakage audit)

Мэдээллийн нэвчилт гэдэг нь загварын сургалтад ирээдүйн мэдээлэл санамсаргүй нэвтрэх үзэгдэл бөгөөд энэ нь тестийн нарийвчлалыг хиймлээр өндөр харуулдаг. Шошго үүсгэх ба олон интервалын шинж чанар нэгтгэх үеийн гол шаардлага нь шийдвэрийн агшин (t_0)-д зөвхөн тухайн мөчөөс өмнө мэдэгдэх боломжтой мэдээлэл ашиглах явдал. Энэ нөхцөлийг хатуу хэлбэрээр томъёолбол:

$$t_{\text{feature}} \leq t_0, \quad \text{label window} = (t_0, t_0 + 240 \text{ минут}] \quad (3.2)$$

Шинж чанарын цонх $[i - K + 1, i]$ ба шошгын цонх $[i + 1, i + W]$ давхцахгүй тул мэдээллийн нэвчилт алгоритмын түвшинд хязгаарлагдсан. Шинж чанар үүсгэх ба шошго тооцох үе шатанд систем цагийн нийцлийн дүрмийг тогтмол мөрддөг (томъёо 3.2). Бүх компонентын нарийвчилсан хяналтын дүрмийг Хавсралт А-д тайлбарласан. merge_asof(backward) болон хугацааны тусгаарлалтын дүрэм нь нэвчилтийн эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй.


WFV-ийн олон огтлолын алхамт логик

Судалгаанд урагш гүйлгэн баталгаажуулалтыг цаг хугацааны дарааллыг хадгалсан **олон огтлол, өргөтгөх сургалтын цонх** (expanding window) протоколоор хэрэгжүүлсэн. Нийт **5 fold** ашигласан, train cutoff жил бүр 1 жилээр шилжсэн (Fold 1: 2018, Fold 2: 2019, ..., Fold 5: 2022); сургалтын цонх 4→8 жил болж өргөжсөн ба баталгаажуулалт (val) ба тест тус бүрд 1 жилийн дараалсан цонх ашигласан (Fold k -ийн val жил = train cutoff + 1, test жил = train cutoff + 2). Энэ нь **step size = 1 жил** бүхий expanding window протокол юм. KPI-ийн дэлгэрэнгүй үнэлгээ **Fold 5** огтлол (2015–2022 / 2023 / 2024)-д суурилсан; Хүснэгт 3.3 тухайн огтлолын хуваалтыг нэгтгэв. Fold 1–5-ийн бүх огнооны хуваарийг Хавсралт Б, Зураг Б.1-аас үзнэ үү.

Хүснэгт 3.3 Урагш гүйлгэн баталгаажуулалтын өгөгдлийн хуваалт

Бүлэг	Хугацаа	Candle-ын тоо	Зорилго
Сургалт	2015–2022	~2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	~371,000	Эрт зогсоох (early stopping), calibration туршилтын ажиглалт (10%)
Тест	2024	~371,000	Эцсийн үнэлгээ (10%)

Зураг 3.4 нь энэхүү хуваалтыг цаг хугацааны тэнхлэг дээр дүрслэн харуулав. Сургалтын өгөгдөл (80%), баталгаажуулалтын өгөгдөл (10%), тестийн өгөгдөл (10%) нь цаг хугацааны дарааллаар ялгагдана. **Чухал:** WFV нь зөвхөн *офлайн сургалтын үе шатанд* (хөгжүүлэгчийн компьютер дээр) хэрэгждэг; production-д ажиллаж буй Flask серверт WFV логик байхгүй, эцсийн сонгогдсон загвар (model.pkl) л байршуулагдсан.



Зураг 3.4 Урагш гүйлгэн баталгаажуулалтын Fold 5-ын өгөгдлийн хуваалт

Тайлбар: KPI үнэлгээнд ашигласан Fold 5-ийн бодит хуваалтыг Зураг 3.4-т харуулсан. WFV-ийн олон огтлолын ерөнхий концепцын схем болон алхамт логикийг Хавсралт Б-аас (Зураг Б.1) үзнэ үү.

3.5. AI загварын бүтэц ба сургалт

Ансамбль загварын архитектур

Системийн загвар нь гурван GBDT (gradient boosted decision trees) загвараас бүрдсэн ансамбль бөгөөд олон модны нэгдсэн архитектураар санхүүгийн хүснэгтэн өгөгдөлтэй сайн нийцдэг [2]. Загвар бүр ижил 48 шинж чанарыг хүлээн авч BUY, SELL, HOLD гурван ангиллын магадлалыг тус тус тооцоолно.

Загварын математик тодорхойлолт

Сургалтын өгөгдөл $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, $\mathbf{x}_i \in \mathbb{R}^{48}$, $y_i \in \{0, 1, 2\}$ (HOLD=0, BUY=1, SELL=2). Суурь загвар $k \in \{\text{LGB, XGB, CAT}\}$ нь давталтын *gradient boosting* аргачлалаар T шийдвэрийн модны нийлбэрийг сурдаг:

$$F_k^{(T)}(\mathbf{x}) = \sum_{t=1}^T \eta \cdot f_t(\mathbf{x}), \quad f_t \in \mathcal{F} \quad (3.3)$$

Үүнд $\mathcal{F}$ нь шийдвэрийн модны функцын орон зай, $\eta = 0.03$ нь learning rate, f_t нь t -р алхамын үед өмнөх ансамблийн *градиентыг бууруулахаар* сурсан мод юм:

$$f_t = \arg \min_{f \in \mathcal{F}} \sum_{i=1}^N \ell(y_i, F_k^{(t-1)}(\mathbf{x}_i) + f(\mathbf{x}_i)) + \Omega(f) \quad (3.4)$$

энд $\Omega(f)$ нь модны нарийн төвөгшилт хариуцсан тогтмолжуулалт. Гурван анги тул логит $\mathbf{z} \in \mathbb{R}^3$ -ыг softmax-аар магадлал болгон хувиргана:

$$P_k(y = c \mid \mathbf{x}) = \frac{\exp(z_c)}{\sum_{c'=0}^2 \exp(z_{c'})}, \quad \mathbf{z} = F_k(\mathbf{x}) \quad (3.5)$$

Алдагдлын функц (loss function)

Гурван загвар бүгд **multi-class cross-entropy** (мөн *softmax loss*, *log-loss* гэж нэрлэдэг) алдагдлын функцыг минимумжуулдаг:

$$\mathcal{L}(\mathcal{D}; \theta_k) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=0}^2 \mathbb{I}[y_i = c] \cdot \log P_k(y_i = c \mid \mathbf{x}_i; \theta_k) + \lambda_1 \|\theta_k\|_1 + \lambda_2 \|\theta_k\|_2^2 \quad (3.6)$$

Үүнд θ_k нь k -р загварын бүх параметрийн вектор, $\mathbb{I}[\cdot]$ нь индикатор функц (зөв ангилалд 1, бусдад 0), λ_1, λ_2 нь L1 ба L2 тогтмолжуулалтын хүчний коэффициент (Хүснэгт E.1-аас LightGBM ба XGBoost-д $\lambda_1 = 0.10, \lambda_2 = 1.0$; CatBoost-д L2 коэффициент (12_leaf_reg) 3.0). HOLD ангиллын давамгайллаас үүсэх тэнцвэргүй байдлыг зохицуулахын тулд LightGBM ба XGBoost загваруудад scale_pos_weight параметрийг сөрөг ба эерэг ангийн харьцаагаар (neg/pos) тохируулсан.

Ансамблийн нэгтгэх дүрэм

Гурван загварын магадлалыг **зөөлөн санал хураалтаар** тэгш жингээр дундажилж эцсийн магадлалыг гаргана:


$$P_{\text{ensemble}}(c \mid \mathbf{x}) = \sum_{k=1}^3 w_k \cdot P_k(c \mid \mathbf{x}), \quad w_k = \frac{1}{3} \quad (3.7)$$

Ангилалын шийдвэр болон итгэлцлийг доорх томъёогоор тодорхойлно:

$$\hat{c} = \arg \max_c P_{\text{ensemble}}(c \mid \mathbf{x}), \quad \text{conf} = \max_c P_{\text{ensemble}}(c \mid \mathbf{x}) \quad (3.8)$$

Үүнд $\hat{c}$ нь сонгосон ангилал, $\text{conf} \in [\frac{1}{3}, 1]$ нь ансамблийн итгэлцэл болно. Зураг 3.5 нь энэхүү бүтцийг дүрсэлнэ.

Ансамблийн жинг $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ тэгш авсан шалтгаан нь нэг огтлолд жинг оновчлох замаар үүсэх data-snooping эрсдэлээс зайлсхийх зорилготой. HOLD ангилал сонгогдсон үед систем шинэ байрлал нээхгүй (no-trade state).



Зураг 3.5 GBDT ансамбль загварын архитектур

Гурван загварыг ансамбль хэлбэрээр хослуулсан шалтгаан нь тус бүр өсөлтийн стратеги, хурд, хэт нийцлийн эрсдэлийн хувьд бие биенээ нөхдөгт оршино: LightGBM (leaf-wise, өндөр хурдтай), XGBoost (level-wise, L1/L2 тогтмолжуулалт), CatBoost (symmetric, хамгийн бага нэвчилтийн эрсдэл). Зөөлөн санал хураалтын дараа ангилал ($\arg \max_c \bar{p}_c$) болон итгэлцэл ($\max_c \bar{p}_c$) хоёр зэрэгцэн авагдана. Өөрөөр хэлбэл итгэлцлийн утга нь ансамблийн дундаж магадлалын хамгийн их утга болно.

Магадлалын калибровк (probability calibration, Platt scaling)-ийг туршилтын үе шатанд офлайн туршиж үзсэн боловч ансамбль өөрөө аль хэдийн зохистой тохируулагдсан магадлал гаргаж байв. Иймд калибровкыг production-д идэвхгүй болгож, түүхий $\max_c \bar{p}_c$ -г итгэлцлийн босготой шууд харьцуулдаг.

Гиперпараметр сонголтын протокол


Гиперпараметрийг сүлжээ хайлт (grid search)-ийн оронд жигдрэлийн протоколоор сонгосон: train-val зөрүү $< 5\%$, conf ≥ 0.90 дэд мужийн нарийвчлал $> 90\%$, шинж чанарын top-10 жагсаалтын Jaccard коэффициент > 0.7 гэсэн гурван шалгуурыг зэрэг хангах утгуудыг хайсан. Ансамбль сургалтыг random_state=42 нэг seed-ийн протоколоор явуулсан. Гол сонголтууд: $n_{\text{estimators}} = 500$, $\eta = 0.03$, $\max_depth \in \{5, 6\}$, $\text{reg_lambda} \in \{1.0, 3.0\}$, $\text{early_stopping_rounds} = 50$. Хэт нийцлээс сэргийлэх зургаан арга хэмжээ (модны гүнийг хязгаарлах, бага learning rate, эрт зогсоолт, L1/L2 тогтмолжуулалт, WFV, шинж чанарын цөөрөлт) бүгд хослуулан хэрэгжүүлсэн. Гурван загварын бүх гиперпараметрийн нарийвчилсан утгуудыг ялгаа болон үүргийн тайлбартай нь **Хавсралт Е-д** (Хүснэгт Е.1) нэгтгэв.

3.6. Дохио үүсгэх систем

Дохионы шүүлтүүр ба тоон үр дүн

Процесс P1 (Зураг 3.3) дохиог хоёр нөхцлөөр шүүгээд D1 (signals) агуулахад хадгална: (1) ансамблийн таамагласан анги BUY эсвэл SELL байх (HOLD биш) ба (2) $M1 ATR \geq 4$ пипс. Автоматаар үүсгэх мөчлөг нь итгэлцлийн босгыг энэ шатанд хэрэглэдэггүй; дээрх хоёр нөхцлийг хангасан дохио бүрийг insert үйлдлээр MongoDB-д хадгална. Итгэлцлийн босго (анхдагчаар 0.90) нь дараа нь Expo Push мэдэгдлийг хэрэглэгчид илгээх шатанд, хэрэглэгч бүрийн хувийн тохиргооны дагуу хэрэглэгдэнэ. ATR шүүлтүүр нь зах зээлийн идэвхгүй хугацаанд (шөнийн хаагдалт, долоо хоногийн эцэс) буурсан хэлбэлзлийн үед үүсэх сул дохиог хасдаг. Аль нэг нөхцөл хангагдаагүй, эсвэл өмнө нь ижил минутын дохио бүртгэгдсэн бол тухайн мөчийн боловсруулалтыг алгасна.

2025 оны бодит өгөгдөл дээрх тоон үр дүн (стратегийн гүйцэтгэлийн дэлгэрэнгүй үнэлгээг \$4-аас үзнэ үү): нийт 359,639 таамгаас итгэлцэл ≥ 0.90 ба $ATR \geq 4$ пипсийн нөхцөлд 3,567 (1.0%) дохио тэнцсэн. Хоёр шүүлтүүр өндөр корреляцтай: загвар итгэлцэл өндөр таамаглал гаргахдаа зах зээлийн хэлбэлзэл өндөр үеийг ихэвчлэн сонгодог тул ATR шүүлтүүр зөвхөн ≈ 33 нэмэлт дохиог хасдаг. Гүйцэтгэлийн талд MT5 EA-ийн MaxPositions=1 дүрэм (нэг агшинд зөвхөн нэг нээлттэй байрлалтай байх) 3,567 дохиог 230 хэлцэл хүртэл багасгадаг бөгөөд энэ нь загварын дотоод бус, гүйцэтгэлийн талын шүүлтүүрт хамаарна. Зураг 3.6 нь энэ дөрвөн алхамт юүлүүрийн процессыг харуулна.



Зураг 3.6 Дохионы шүүлтүүрийн юүлүүр (0.90 босго)

Stop Loss ба Take Profit тооцоолол

Арилжааны эрсдэлийг хязгаарлах Stop Loss (SL) болон ашгийг хамгаалах Take Profit (TP) утгуудыг ATR-д суурилан динамикаар тооцоолсон:


$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (3.9)$$

$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (3.10)$$

ATR үржвэр 5.0 нь 7 давталтын туршилтаар 3.0–7.0 мужаас тогтвортой гүйцэтгэл өгсөн утга; TP/SL=3:1 нь ердөө 33%-ийн ялалтын хувьд ч санхүүгийн хувьд ашигтай байх математик нөхцөл; 15/45 пипсийн доод хязгаар нь санамсаргүй хөдөлгөөн болон зардлаас хамгаалдаг.

Дохионы амьдралын мөчлөгийн төлөвт автомат

Дохио нь ансамбль таамаглал гарсан мөчөөс эхлэн MT5 платформ дээр позиц хаагдах хүртэлх амьдралын мөчлөгт долоон үндсэн төлвөөр дамждаг. Энэ дарааллыг Зураг 3.7-т UML 2.5-ийн төлөвт автомат (state machine) хэлбэрээр харуулсан: дээд талын хэвтээ дамжлагаар амжилттай дохионы зам, шилжилт дээр шүүлтүүрийн нөхцөл ($[conf \geq 0.90, ATR \geq 4 \text{ пипс}]$), доод хэсэгт MT5 дэх гүйцэтгэлийн нийлмэл (composite) төлөв зэрэгцэн оршино.



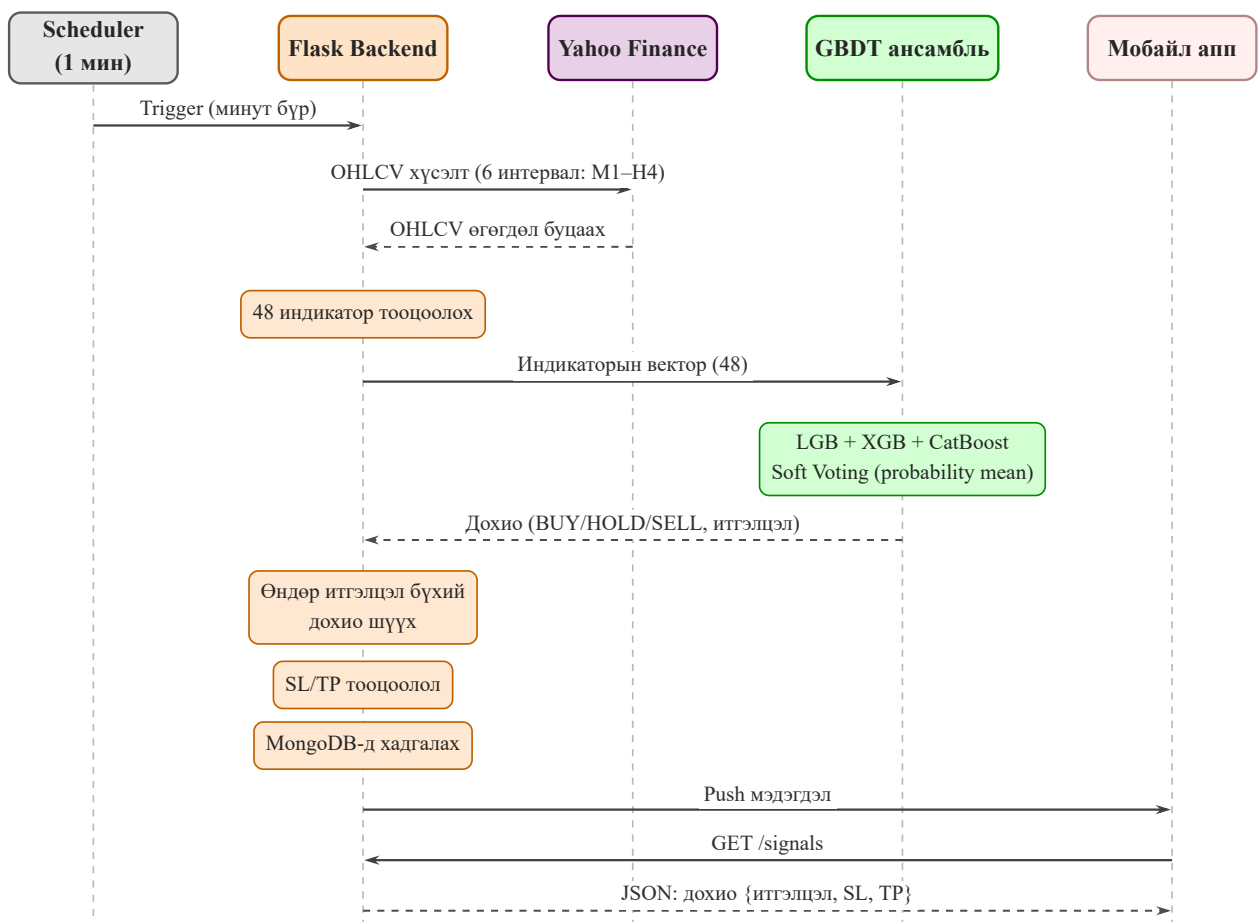
Зураг 3.7 Дохионы амьдралын мөчлөгийн төлөвт автомат

Дохио нь итгэлцэл ($\geq 0,90$) ба ATR (≥ 4 пипс) гэсэн хоёр шүүлтүүрийг дараалан давсны дараа SL/TP-г тооцоолон MongoDB-д хадгалагдана. Дараа нь Expo Push-аар хэрэглэгчийн утсанд мэдэгдэл хүрнэ.

Хэрэглэгч MT5-д позиц нээх үед нийлмэл «Гүйцэтгэж буй» төлөвт ордог. Тус нийлмэл төлөвт TP-хяналт, SL-хяналт болон 4 цагийн таймер гэсэн гурван зэрэгцээ муж нэгэн зэрэг идэвхждэг. Аль нэгийг нь нөхцөл түрүүлж биелэх үед тухайн төлвөөр эцсийн төлөв (TP-д хүрсэн / SL-д хүрсэн / хугацаа дууссан) тодорхойлогдоно. Тоон үр дүн нь Хүснэгт Г.3-ийн баганатай шууд харгалзана.

Дохио үүсгэх дарааллын диаграмм

Дохио үүсгэх процессын таамаглах, шүүх, хэрэглэгчид хүргэх гэсэн нэгдсэн дарааллыг Зураг 3.8-т sequence diagram хэлбэрээр дүрсэлсэн.



Зураг 3.8 Дохио үүсгэх дараалал

Scheduler нь 1 минут тутамд Flask backend-ийг сэрээдэг. Backend нь Yahoo Finance-ээс M1–H4 хүртэлх 6 интервалын OHLCV-г татаж, 48 техникийн индикаторын вектор бүрдүүлээд GBDT ансамбльд дамжуулна. Ансамбль (LightGBM, XGBoost, CatBoost) зөөлөн санал хураалтаар BUY/HOLD/SELL ангилал ба итгэлцлийг буцаана. Backend нь хэрэглэгчийн тогтоосон босгоос дээш итгэлцэлтэй дохиог шүүж, ATR-д суурилсан SL/TP-г тооцоолж MongoDB-д хадгалаад мобайл аппын зүгт Expo Push мэдэгдэл илгээнэ. Хэрэглэгч аппыг нээх үед GET /signals REST хүсэлтээр сүүлийн идэвхтэй дохиог JSON хэлбэрээр татаж авна.

3.7. Стратегийн backtesting (түүхэн өгөгдөл дээрх системийн туршилт)

Дохио үүсгэх системийн бодит цагийн (real-time) логикийг §3.5-д тодорхойлсон бол, тус системийн стратеги нь бодит зах зээлийн нөхцөлд статистикийн хувьд ашигтай гүйцэтгэлтэй эсэхийг шалгахын тулд түүхэн өгөгдөл дээр симуляцийн туршилт (backtesting) явуулсан. MetaTrader 5-ийн Strategy Tester нь Expert Advisor (EA) алгоритмыг түүхэн OHLCV өгөгдөл дээр симуляцаар ажиллуулж хэлцлийн лог (timestamp, SL, TP, ашиг/алдагдал) бичдэг бөгөөд энэ судалгаанд GBDT ансамблийн гаралтыг бодит нөхцөлтэй холбосон баталгаажуулалтын орчин болгон ашигласан.

Гүйцэтгэлийн логик

Симуляцийн гүйцэтгэлд эрсдэлийн удирдлагатай гүйцэтгэгч модуль ашиглаж, дохио бүр дээр байрлалын хэмжээ, итгэлцлийн босго, гулсалтын хязгаар зэрэг дүрмийг тогтмол мөрдсөн. Хүснэгт 3.4 нь энэ хэсгийн үндсэн тохиргоог нэгтгэв.

Хүснэгт 3.4 *Backtesting-ийн EA-ийн үндсэн тохиргоо*

Параметр	Утга	Тайлбар
Арилжаа бүрийн эрсдэл	1.0%	Нэг дохион дээр авах эрсдэлийн хувь
Нэг удаагийн байрлалын дээд тоо	1	Давхар байрлал нээхээс сэргийлсэн
Итгэлцлийн доод босго	0.90	Чанарын шүүлтүүрийн үндсэн босго
Зөвшөөрөгдөх гулсалтын хязгаар	10 point	Гүйцэтгэлийн бодит нөхцөлийг тусгасан

Туршилтын нөхцөл

MetaTrader 5 Strategy Tester дээр *Every tick based on real ticks* горимд, EUR/USD хэрэгслийн брокерын бүртгэсэн бодит spread-ийг автоматаар (хувьсах байдлаар) ашиглан, 2025.01.01–2026.01.01 цонхонд, \$10,000 анхны хөрөнгөөр туршилт хийсэн. 0.90 суурь шүүлтүүрийн 3,567 дохионоос гадна 0.91–0.99 мужийн урьдчилан шүүсэн багцуудыг харьцуулан ажиглав; дохио/өдөр үзүүлэлтийг 261 ажлын өдрөөр тооцсон.

Арилжааны зардлын хамралт

Туршилтын орчинд spread ба гулсалт (10 point дээд хязгаар) тусгагдсан; commission болон swap зардал тусгагдаагүй. Энэ нөхцөлийн нөлөө болон үлдэгдэл хязгаарлалтын дэлгэрэнгүй хэлэлцүүлгийг §4.6.3-т нэгтгэв.

Босго сонголтын протокол

Шалгагдсан 0.90–0.99 мужийн доод хязгаар нь баталгаажуулалтын итгэлцлийн нарийвчлалын шинжилгээнд (Хүснэгт 4.3) тулгуурласан; дээд хязгаар нь дохионы давтамж хэт цөөрөхийн урьдчилан сэргийлэлт. Босгын мужийн хүснэгт нь ажиллах үеийн динамик тааруулалт бус, **сценарийн харьцуулалт** бөгөөд 0.91 нь энэ шинжилгээний хүрээнд ажиглагдсан локал дээд цэг тул бүх нөхцөлд универсал оновчтой утга гэж дүгнэхгүй.

Нэгдсэн үнэлгээний шалгуур үзүүлэлтүүд

Загварын ангиллын чанар болон системийн стратегийн гүйцэтгэлийг хамарсан нэгдсэн шалгуурын багцыг Хүснэгт 3.5-д харуулав; үзүүлэлтүүд нь дээрх backtest-ийн нөхцөлд хэмжигдэн §4-т (Үр дүн) тоон утгаар тайлагнагдана.

Хүснэгт 3.5 Системийн үнэлгээний шалгуур үзүүлэлтүүд

Үзүүлэлт	Тодорхойлолт	Чиглэл
<i>Загварын ангиллын чанар</i>		
Тестийн нарийвчлал	2024 тест хуваалтын зөв ангиллын хувь	Өндөр = сайн
Өндөр итгэлцэлтэй нарийвчлал	Итгэлцэл өндөр мужийн зөв ангиллын хувь	Өндөр = сайн
<i>Сценарийн системийн үзүүлэлтүүд (Chapter 4)</i>		
Өгөөж (%)	$(B_{\text{final}} - 10,000) / 10,000 \times 100$	Өндөр = сайн
Дохио/өдөр	Нийт дохио / 261 арилжааны өдөр	Контекстээс хамаарна
Дохио тутмын ашиг	Нэг дохионд ногдох дундаж ашиг (\$)	Өндөр = сайн
Гүйцэтгэлийн хувь	Шүүгдсэн дохионоос хаагдсан арилжааны хувь	Контекстээс хамаарна
Ялалтын хувь; 95% CI	Хаагдсан арилжаан дахь TP хувь; Wilson CI	Өндөр = сайн
Expectancy (R)	TP/SL=3:1-д нэг арилжаанд хүлээгдэх өгөөж	0-ээс их = сайн
Balance CV	std/mean —эцсийн балансын хэлбэлзэл	Бага = тогтвортой
MaxDD	Оргил балансаас хамгийн их бууралт	Бага = сайн
Sharpe / Sortino / Calmar	Эрсдэлд нормчилсан өгөөжийн үзүүлэлт	Өндөр = сайн
Max losing streak	Хамгийн урт дараалсан алдагдал	Бага = тэсвэртэй

TP/SL=3:1 нөхцөлд $E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}})$ томъёогоор Expectancy тооцно; $E[R] > 0$ бол статистикийн давуу талтай.


Эрсдэлийн үзүүлэлтүүдийн тодорхойлолт: MaxDD (Maximum Drawdown) нь балансын оргил цэгээс хамгийн гүн уналтын зай. Sharpe нь илүүдэл өгөөжийг нийт хэлбэлзлээр хуваасан харьцаа; Sortino нь зөвхөн доошлох хэлбэлзлийг (downside volatility) тооцдог Sharpe-ын хувилбар; Calmar нь жилийн өгөөжийг MaxDD-д хуваасан харьцаа. Win rate-ийн 95% итгэлцлийн интервалыг Wilson аргаар (хоёртын хувь хэмжигдэхүүнд тохирсон, жижиг түүвэрт нарийвчлалтай тооцоолол) тооцов.

3.8. Серверийн хэсгийн хэрэгжүүлэлт

Архитектурын үндсэн бүрэлдэхүүн

Серверийн хэсэг нь Flask REST API, MongoDB, GBDT inference модуль, JWT нэвтрэлт гэсэн дөрвөн давхаргаас бүрдэнэ. API ба worker процессуудыг Docker контейнераар Microsoft Azure App Service дээр байршуулсан бөгөөд нэвтрэлт, ханш, дохио, мэдээ, мэдэгдэл гэсэн 5 функциональ урсгал тэдгээрт хуваарилагдана. Зураг 3.9 нь системийн **физик байршуулалтыг** (UML 2.5 deployment

diagram) зангилаа (node), артефакт (artifact), гадаад үйлчилгээний түвшинд харуулсан бөгөөд §3.2-ийн логик архитектурыг гүйцэтгэлийн орчинд хэрхэн буулгасныг дүрсэлдэг.



Зураг 3.9 Системийн байршуулалтын диаграмм

Зураг 3.9-т гурван байршуулалтын зангилаа болон тэдгээрийн гадаад үйлчилгээтэй холболтыг харуулсан. Зангилаа бүр нь хөгжүүлэгчийн компьютер (офлайн сургалт), Microsoft Azure App Service-д Docker контейнероор байршуулсан Flask сервер, мөн Android утас гэсэн гурван физик орчныг төлөөлдөг.

Систем нь гурван үе шатаар ажиллана:

1. Офлайн сургалтаар 3 GBDT загвар бэлдэж model.pkl артефактыг серверт байршуулна («deploy»).
2. Worker үүрэгтэй процесс нь Yahoo Finance-с ханш, AlphaVantage болон TradingView-с мэдээллийн хуанли татаж дохио үүсгэн MongoDB-д хадгална.
3. Expo Push API-гаар дамжуулан мэдэгдэл хүргэж, React Native апп REST API-аар дохио, ханш, мэдээг хэрэглэгчдэд үзүүлнэ.

Нэвтрэлт, контейнер тохиргоо, хурдны хязгаарлалт, найдвартай ажиллагаа болон гүйцэтгэлийн хэмжүүрийн (KPI) дэлгэрэнгүй протоколыг Хавсралт В-аас үзнэ үү.

3.9. Харагдах хэсгийн архитектур

Харагдах хэсгийн зорилго нь серверийн хэсгээс ирэх ханш, дохио, мэдээ, мэдэгдлийг нэгтгэн хэрэглэгчид тасралтгүй хүргэхэд оршино; харагдах хэсгийг нэвтрэлт, өгөгдөл харуулах, сервертэй синхрончлол гэсэн гурван түвшний модулиар хэрэгжүүлсэн.


Харагдах хэсгийн модулийн бүтэц ба API харилцаа

Харагдах хэсэг нь нэвтрэлт, ханш, дохио, мэдээ гэсэн дөрвөн бие даасан модулиас бүрдэнэ. Модуль тус бүрийн үүрэг, харилцааны загвар (REST GET polling эсвэл POST/PUT) болон холбогдох API endpoint-ийн бүрэн жагсаалтыг Хавсралт Ж-ээс үзнэ үү.

Нэгдсэн архитектурын зураглал

Систем нь REST polling ба Expo Push гэсэн хоёр харилцааны загварыг хослуулан ашигладаг. Polling урсгалыг Зураг 3.10-т харуулсан бөгөөд харагдах хэсгийн 4 модуль REST API-ийн дөрвөн endpoint бүлгээр серверийн харгалзах сервистэй холбогдоно. Үүний зэрэгцээ серверийн дохио ба мэдээний сервисүүд тэрс чигт (server-initiated) Expo Push сувгаар хэрэглэгчийн утсанд мэдэгдэл илгээдэг —энэ хоёр загварын нарийвчилсан дарааллыг Зураг 3.8-аас үзнэ үү.

REST polling урсгал —харагдах хэсгийн 4 модуль → REST API → серверийн 4 сервис:



Зураг 3.10 REST polling холболтын архитектур

3.10. Загварын давталтын сайжруулалт

Өмнөх хэсгүүдэд системийн эцсийн архитектурыг (өгөгдлийн урсгал, GBDT ансамбль, дохио үүсгэх логик, серверийн хэрэгжүүлэлт, харагдах хэсэг) тоймлов. Эдгээр шийдвэрүүд нь нэг удаагийн дизайны үр дүн биш, харин олон давталтын туршилтаар тогтоосон сонголтууд юм. DSR арга зүйн дагуу загварын хөгжүүлэлтийг 7 давталтын (iterative) үе шатаар явуулсан. Үе шат бүрт “бүтээх → үнэлэх → сайжруулах” мөчлөгийг давтаж, өмнөх хувилбарын түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үр дүнд тулгуурлан сул талыг зассан. Үе шат бүрийн гол өөрчлөлтийг Хүснэгт 3.6-д нэгтгэн харуулав.

Хүснэгт 3.6 Загварын давталтын 7 үе шат

Үе шат	Гол өөрчлөлт	Үндэслэл ба үр дүн
1	ATR шүүлтүүр	ATR-ийн доод босгыг 3 → 4 пипс болгож, бага хэлбэлзэлтэй 86.8% дохиог шүүн хасав
2	Шинж чанар нэмэх	Анхны багцад 15 нэмэлт техникийн шинж чанар нэмж нийт 75 болгов
3	Загварын олон янз байдал	Туршсан 9 загвараас гүйцэтгэлийн хувьд хамгийн сайн 3-ыг сонгов (LightGBM, XGBoost, CatBoost)
4	Trailing stop	Ашгийн явцад SL-ийг дагуулан шилжүүлэх стратеги нэмж, ашигтай арилжааг урт хугацаанд барьдаг болгов
5	Уналтын засвар	Байрлалын хяналт ба эрсдэлийн хязгаарыг чангатгаснаар Max Drawdown бууруулав
6	Хэт нийцлийн засвар	Шинж чанар 75 → 48 болгож, урагш гүйлгэн баталгаажуулалт (WFV) хийв
7	Чанартай дохио	Итгэлцлийн босго ≥ 0.90 , $ATR \geq 4$ пипс, $TP:SL=3:1$ параметруудийг тогтоож дохионы чанарыг тогтворжуулав

4. Судалгааны үр дүн

4.1. Үр дүнгийн өгөгдлийн эх сурвалж

Энэ бүлгийн бүх тоон үр дүнг MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилтын логуудаас гаргав. Логийн нэгтгэлийн дүрэм нь нэг ижил өгөгдөл дээр давтан тооцоход үр дүн өөрчлөгдөхгүй байх боломжийг хангадаг. Хязгаарлалтыг §4.6.3-т, эх сурвалжийн нэгтгэлийн нөхцөлийг Хавсралт Г-аас үзнэ үү.

4.2. Загварын ангиллын гүйцэтгэл

Судалгааны асуулт 1 (RQ1): “Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр найдвартай ажиллах уу?” гэсэн асуултад хариулахын тулд GBDT ансамблийн ангиллын нарийвчлалыг Walk-Forward Validation (WFOV) схемийн дагуу тусдаа өгөгдлийн хуваалт дээр хэмжив. Хэмжилтийн аргачлал (зөөлөн санал хураалт ба *argmax* ангиллын шийдвэр)-ийг §3.4-т тайлбарласан; нарийвчлал ба F1 оноог `sklearn.metrics`-ээр тооцов. Хуваалт: сургалт 2015–2022, баталгаажуулалт 2023, тест 2024 (харагдаагүй өгөгдөл).

Хүснэгт 4.1 GBDT ансамблийн нарийвчлал ба F1 оноо —хуваарь тус бүрээр

Хуваарь	Хугацааны цонх	Нарийвчлал (%)	F1-macro (%)	F1-weighted (%)
Сургалт	2015.01–2022.12	82.71	67.74	80.94
Баталгаажуулалт	2023 бүтэн жил	84.48	62.67	82.29
Тест (out-of-sample)	2024 бүтэн жил	89.25	59.45	87.23

Сургалт ба баталгаажуулалтын нарийвчлалын зөрүү +1.77% (баталгаажуулалт нь сургалтаас өндөр) байгаа нь загварт хэт нийцлийн ноцтой шинж тэмдэг ажиглагдаагүйг илтгэнэ.¹ Тест нарийвчлал 89.25% нь 2024 оны харагдаагүй өгөгдөл дээр ч жигд гүйцэтгэл хадгалагдаж буйг харуулсан. F1-macro (59–68%) нь F1-weighted (80–87%)-аас бага байгаа нь BUY/SELL ангийн recall харьцангуй доогуур байгааг илтгэх бөгөөд HOLD давамгайлсан өгөгдөлд нарийвчлал ганцаараа хангалттай хэмжүүр биш юм.²

Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт (2024)

Хүснэгт 4.2 Тестийн өгөгдөл дээрх ангилал тус бүрийн үзүүлэлт

Анги	Precision (%)	Recall (%)	F1 (%)	Дээжийн тоо
BUY	68.24	29.97	41.65	22,405
HOLD	90.24	98.33	94.11	322,186
SELL	75.80	29.60	42.58	26,791

¹ Баталгаажуулалт сургалтаас өндөр гарах нь онолын хувьд ердийн биш. Хоёр шалтгаан: *нэгдүгээрт*, 2023 оны баталгаажуулалтын өгөгдөл дотор HOLD ангийн эзлэх хувь сургалтын дундаж 75.5%-аас өндөр (76.9%) байсан тул HOLD ангийн өндөр precision (90%+) нарийвчлалыг дээш нь түрсэн; *хоёрдугаарт*, LightGBM ба XGBoost-ийн `early_stopping_rounds=50` нь баталгаажуулалтын алдагдлыг шууд минимумжуулдаг учраас баталгаажуулалтын тархалттай уялдаа сайтай байгаа нь хүлээгдэх үзэгдэл. Тестийн нарийвчлал баталгаажуулалттай ойролцоо (87–89%) хадгалагдсан нь зөрүү нь өгөгдөл-тусгай хазайлт бөгөөд хэт нийцлийн илрэл биш гэдгийг батлана.

² F1-macro гурван ангийг тэнцүү жинтэйгээр нэгтгэдэг, F1-weighted нь ангийн дээжийн тоогоор жинлэдэг. HOLD ангийн давамгайлалын шалтгаан ба ангиллын тусдаа дүнг §4.2.1-т харуулав.

BUY ба SELL ангийн дуудалтын хувь (recall) харьцангуй бага (30%) байгаа нь хоёр шалтгаантай. Нэгдүгээрт, сургалтын өгөгдлийн 75.6% нь HOLD ангид хамаарах тул загвар HOLD ангийг давтан сонгох хандлагатай болдог. Хоёрдугаарт, итгэлцлийн босго 0.90-өөс дээш шаардах нь нийт чиглэлтэй дохионы 70% гаруйг шүүж хасдаг. Практикт энэ нь аппликейшны хэрэглэгч өдөрт дунджаар 13.67 дохио хүлээн авах бөгөөд нарийвчлал (precision) өндөр (BUY: 68.24%, SELL: 75.80%) гэсэн үр дүнтэй. BUY/SELL чиглэлтэй боломжийн гуравны нэгийг л барьдаг тул өндөр давтамжийн стратегид нийцэхгүй боловч чанартай цөөн дохио хүлээдэг хэрэглэгчид илүү тохирно.

Итгэлцлийн мужийн нарийвчлал

Хүснэгт 4.3 *Итгэлцлийн мужийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)*

Итгэлцлийн муж	Нарийвчлал (%)
0.85–0.90	≈72
0.90–0.92	≈84
0.92–0.95	≈91
0.95+	≈97
≥0.90 (нийт)	96.96


Итгэлцлийн босго 0.92-оос дээш дохионд 91%, 0.95 давсан тохиолдолд 97% нарийвчлалд хүрдэг. Баталгаажуулалтын өгөгдөлд 0.90-өөс дээш дохионы нарийвчлал 96.96% байгаа нь ийм босгын шүүлтүүрийн үндэслэлийг тодорхой харуулна. Шүүлтийн босго нэмэгдэх тусам нарийвчлал хамт өсөх хандлага ажиглагдсан нь RQ1-ийн хүрээнд загварын найдвартай байдлыг дэмжиж байна.

4.3. Босгын мужийн нэгдсэн үр дүн

10 итгэлцлийн босго (0.90–0.99)-д MetaTrader 5 Strategy Tester-ээр 2025 оны бүтэн жилийн EUR/USD H1 туршилт явуулсан. Үр дүнг энэ хэсэгт диаграммын хэлбэрээр харуулна. Өгөөжийг
$$\text{Өгөөж}(\%) = (\text{Эцсийн баланс} - 10,000) / 10,000 \times 100$$
 томъёогоор тооцсон; зардлын хамралтын хязгаарлалтыг §4.6.3-т дэлгэрэнгүй авч үзсэн. Бүх тоон утгуудын дэлгэрэнгүй хүснэгтийг Хүснэгт Г.2, Хүснэгт Г.3, Хүснэгт Г.4 (Хавсралт 8)-аас үзнэ үү.

Нийт өгөөж ба худалдан аваад барих жишиг

Зураг 4.1 зурагт босго тус бүрийн эцсийн балансыг үзүүлэв.




Зураг 4.1 Босго бүрийн эцсийн баланс

Бүх 10 босго худалдан аваад барих жишгийн \$11,347 (+13.47%) дүнгээс 5.5–38 дахин их өгөөжтэй гарсан. Хамгийн их баланс 0.91 босгод \$61,770 (+517.70%), хамгийн бага 0.99 босгод \$17,429 (+74.29%) ажиглагдсан. 0.90–0.92 кластерт балансын зөрүү бага (\$5–6K хүрээнд) бөгөөд босго ≥ 0.93 -аас эхлэн өгөөж эрс буурдаг.

Дохио-арилжааны хувирлын механизм

Шүүгдсэн дохио (Ачаалагдсан) болон бодит арилжааны тооны хооронд тогтмол зөрүү ажиглагдсан. Энэ нь EA-ийн MaxPositions=1 дүрэм, давхацсан дохиог алгасах механизм болон тухайн валютын хослолд зөвхөн нэг байрлал гүйцэтгэх дүрмээс үүдэлтэй (§3.6.1). Зураг 4.2-д гүйцэтгэлийн хувийн өөрчлөлтийг харуулав.




Зураг 4.2 Босго тус бүрийн гүйцэтгэлийн хувь

0.90–0.97 мужид гүйцэтгэлийн хувь 6–9% хүрээнд жигд; 0.98–0.99-д шүүгдсэн дохио цөөрөхөд 11–24% болж огцом өснө.

Ялалтын хувь ба статистикийн ач холбогдол

Зураг 4.3 зурагт ялалтын хувийг 95% Wilson итгэлцлийн интервалтай хамт үзүүлэв. TP/SL=3:1 нөхцөлд алдагдалгүй (break-even) байх win rate нь $p_0 = 0.25$ (улаан тасархай шугам).




Зураг 4.3 Ялалтын хувь 95% Wilson итгэлцлийн интервалтай

Босго өсөхөд win rate дундаж 44.78%-аас 65.71% болж өснө; арилжааны тоо буурснаар CI өргөсч, 0.99 босгод $\pm 15\%$ хүртэл сунана. Бином тестээр бүх 10 сценарийн win rate $p_0 = 0.25$ -аас мэдэгдэхүйц өндөр: 0.91 босгод $z = 7.45$, хамгийн бага түүвэртэй 0.99 босгод $z = 5.56$ ($n = 35$), бүгд $p < 0.0001$. Иймээс систем санамсаргүй сонголтоос статистикийн хувьд ач холбогдолтойгоор давсан гэж дүгнэх боломжтой.

Хүлээгдэж буй өгөөж

Зураг 4.4 зурагт нэг арилжааны хүлээгдэж буй өгөөж $E[R] = \hat{p} \cdot 3 - (1 - \hat{p}) \cdot 1$ томъёогоор тооцсон утгыг үзүүлэв.




Зураг 4.4 Нэг арилжааны хүлээгдэж буй өгөөж $E[R]$

Бүх босгод $E[R] > 0$. 0.99 босгод $E[R] = 1.63R$ хамгийн өндөр боловч нэг жилийн нийт арилжаа ердөө 35 хэлцэл байна.

Эрсдэлийн үзүүлэлтүүд

Зураг 4.5 зурагт босгуудын эрсдэл-өгөөжийн дөрвөн үндсэн үзүүлэлтийг 2×2 жижиг панелэд нэгтгэв.




Зураг 4.5 Эрсдэлийн үзүүлэлтүүд босго тус бүрээр

Дөрвөн үзүүлэлт ялгаатай чиглэлийг харуулна. MaxDD (A) хамгийн бага нь 0.99 (1.98%), хамгийн өндөр нь 0.93 (9.53%); 0.91, 0.92, 0.97 нь 3% орчим. Sharpe (B) ба Sortino (C) 0.99 босгод хамгийн өндөр (12.83, 44.76) гарсан нь алдагдлын хэлбэлзэл бага байгаатай холбоотой. Calmar (D) нь өгөөж/MaxDD харьцаа тул 0.91 (174.20), 0.92 (155.79), 0.90 (122.96) кластер илт онцрох бол 0.93, 0.98 хамгийн доогуур утга үзүүлж байна. Энэ нь **өндөр өгөөж + бага MaxDD-ийн тэнцвэр** 0.90–0.92 мужид төвлөрсөн гэдгийг харуулна. Sharpe/Sortino/Calmar утгууд цөөн хэлцэл (35–230) ба богино цонхноос (1 жил) зохиомлоор томруулагдсан тул босгуудын харьцангуй харьцуулалт болгож үзнэ (§4.6.3).

Олон шалгуурт нэгтгэл ба босгын ранкинг


«Хамгийн их өгөөж» нь үргэлж «хамгийн оновчтой босго»-той тэнцэхгүй. Босго бүрийн чанарыг найман нормчилсон үзүүлэлтээр (өгөөж, MaxDD-урвуу, Calmar, Sharpe, win%, CI-ийн доод хил, $E[R]$, арилжааны тоо N) дүгнэсэн нэгдсэн (composite) оноог тооцов. Жинлэл: өгөөж 0.20; уналт 0.15; Calmar 0.15; Sharpe 0.10; win 0.10; $E[R]$ 0.10; CI доод 0.10; N 0.10. Үр дүнг Зураг 4.6 ба Зураг 4.7-д харуулав.



Зураг 4.6 Босгуудын нэгдсэн (composite) ранкин

Зураг 4.6 нь босгуудыг нэгдсэн ранкингаар эрэмбэлсэн дүн. **Тэргүүн 4 байр:** 0.91 (0.642), 0.92 (0.597), 0.99 (0.567), 0.90 (0.508). 0.91 нь зөвхөн өгөөжөөрөө биш, эрсдэл–өгөөж тэнцвэрээр (өндөр Calmar, бага MaxDD, дунд зэрэг win rate) эхний байрт орсон. 0.99 нь өгөөжөөр хамгийн доогуур (#10) хэдий ч хамгийн бага MaxDD, дээд $E[R]$, дээд Sharpe-аар нэгтгэгдэн 3-р байрт орсон. Энэ нь **эрсдэлгүй сонголтын** төлөөлөл боловч ердөө 35 хэлцлийн түүвэрт суурилсан.

Зураг 4.7-д нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын 8 үзүүлэлтийн профайлыг радар диаграммаар үзүүлэв. Босго утга тус бүрийн «хүчтэй талын зураглал» ялгаатай байгаа нь тодорхой ажиглагдана.




Зураг 4.7 Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын 8 үзүүлэлтийн радар профайл

Дүгнэлт: **0.91–0.92 «балансжсан кластер»** нь өгөөж, эрсдэл, гүйцэтгэлийн давтамж, статистикийн түүврийн хэмжээ —дөрвөн талаасаа нэгэн зэрэг өндөр оноо авсан **практик дүгнэлтэд илүү тохирох** босго юм. 0.99 «эрсдэлгүй сонголт» нь эрсдэл багатай боловч жилд 35 хэлцэл (сард 3 орчим) гүйцэтгэдэг. Тиймээс статистикийн тодорхойгүй байдал өндөр (win rate CI өргөн $\pm 15\%$) бөгөөд практикт хэрэглээний хүрээ хязгаарлагдмал.

Хөрөнгийн өөрчлөлтийн муруй ба сарын ашгийн жигдрэлт


Зураг 4.8 зурагт нэгдсэн үнэлгээгээр тэргүүлсэн **3 босго утгын (0.91, 0.92, 0.99)** equity curve-ийг ижил х-тэнхлэг (**2025 оны хуанлийн өдөр**) дээр давхарлан үзүүлэв. Эхлэх баланс бүгд \$10,000, эрсдэл 1% тогтмол. Цаг хугацаагаар харьцуулах нь арилжааны тоо ялгаатай босгуудыг шударгаар үнэлдэг: 0.91 нь 198 хэлцэл, 0.99 нь ердөө 35 хэлцэлтэй боловч хоёулаа ижил жилийн цонхонд ажилласан. Координатуудыг MetaTrader 5-ийн бодит хэлцлийн логоос Python скриптээр (хэлцэл бүрийн `close_dt` талбараар) сэргээж тооцсон. Үлдсэн 7 босгын (0.90, 0.93–0.98) эцсийн үр дүнг Хүснэгт Г.2-аас үзнэ үү.



Зураг 4.8 Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын equity curve (2025 он)

Цаг хугацаагаар харьцуулахад гурван чухал хэв шинж илэрнэ. **Нэг:** гурвуулаа B&N шугам (\$11K)-аас 1.5–5.6 дахин өндөр төгссөн нь стратеги бүх кластерт жишгийг давсныг харуулна. **Хоёр:** **0.91 ба 0.92** муруй 7–10 сард (210–302 дахь өдөр) шууд тасарч урагшилсан — 2025 Н2-ийн чиг хандлагатай хугацаатай давхцана. **Гурав:** **0.99** муруй **302 дахь өдөр (10-р сарын сүүл)-ээс хойш хэвтээ үргэлжилсэн** — хатуу шүүлтүүрийн улмаас оны сүүлийн 60 хоног арилжаа огт хийгээгүй. Энэ нь өндөр итгэлцлийн босго → зах зээлийн зарим үед бүрэн идэвхгүй болохыг харуулна. Үлдсэн 7 босгын (0.90, 0.93–0.98) ижил төстэй уналт ба өсөлтийн хэв шинжийг Хүснэгт Г.2 хүснэгтийн тоон үзүүлэлтээс үзэж болно.

Зураг 4.9 зурагт нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын (0.91, 0.92, 0.99) сар бүрийн цэвэр ашиг/алдагдлыг дүрсэлсэн. Бодит хэлцлийн `close_dt` талбараар Python-р сар бүрээр нэгтгэв.



Зураг 4.9 Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын цэвэр ашиг/алдагдал (2025, сараар)

Сарын динамикаас гурван онцлог: (1) 0.91 ба 0.92 кластер 2025 оны 12 сар бүрд эерэг ашиг гаргасан — зөвхөн 11 сард богино алдагдалд орсон ($-\$638$, $-\$30$); (2) 5, 8, 10 сар хамгийн өндөр ашигтай байсан нь 2025 оны H2-д EUR/USD-ийн чиг хандлагатай шилжсэнтэй давхцана; (3) 0.99 нь 11, 12 сард огт арилжаа гаргаагүй — хатуу шүүлтүүр нь тасралтгүй ажиллагааг бууруулдгийг харуулна. 0.91–0.92 кластер нь ашгийн жигдрэлт, сарын эрсдэлийн жижиг хэмжээ (хамгийн муу алдагдал -1% балансын доор) болон 12 сарын бүрэн ашиглалт зэрэг шинжээрээ практик стандартад илүү таарна.

4.4. Үр дүнгийн тайлбар

Босго $0.90 \rightarrow 0.99$ өсөхөд нийт дохио 95.88% -аар буурч нэг дохионы дундаж ашиг $\$13.53 \rightarrow \50.54 болж өсдөг (Хүснэгт Г.2). Энэ давтамж $\leftrightarrow$ нэг арилжааны үр ашгийн солилцоог дээжийн хэмжээний нөлөөтэй хамт авч үзэх шаардлагатай [26, 27].

Зураг 4.6-аар тогтсон **0.91–0.92 балансжсан кластер** нь өгөөж ($+465\% — +518\%$), бага MaxDD ($2.97\% — 2.99\%$), өндөр Calmar ($155–174$), статистикийн хангалттай түүвэр ($201–212$ хэлцэл) болон сарын жигд эерэг ашиг гэсэн таван талаасаа нэгэн зэрэг тэргүүлсэн. Иймд **цаашдын зөвлөмжийн босго** болж чадна. 0.99 нь эрсдэлийн эсрэг хамгаалалтын хувьд (MaxDD 1.98% , win rate 65.71%) онцрох сонголт хэдий ч жилд 35 хэлцэл, 11–12 сард огт арилжаа байхгүй нь практик хэрэглээний тасралтгүй байдалд хязгаарлалт үүсгэнэ.

Энэ дүгнэлт нь **EUR/USD валютын хослол, 2025.01.01–2026.01.01 цонх, нэг агшинд нэг байрлалын EA дүрэм, MT5-ийн бодит спрэд + 10 point гулсалтын нөхцөл** дотор хүчинтэй. Өөр валютын хослолд (GBP/USD, USD/JPY) шууд ерөнхийлөх, шимтгэл-своп бүрэн хамруулсан өгөөжийг гаргах, эсвэл бусад брокерын нөхцөлд дамжуулах нь батлагдаагүй ($\$4.6.3$). Иймд 0.91-ийг *бүх нөхцөлд оновчтой* босго гэж бус, *уг харьцуулалтын багцад оновчтой* босго гэж тайлбарлана.

4.5. Архитектурын KPI-ийн баталгаажуулалтын үр дүн

API давхаргын p95 latency $471–536$ ms байсан нь зорилтот 350 ms-г хэтэрсэн; нийт 90 хүсэлтийн аль нэг нь ч 5xx кодтой хариу өгөөгүй (5xx алдааны хувь 0.0%). Latency зорилт биелээгүйн гол шалтгаан нь хэмжилтийн байршил (Улаанбаатар) ба сервер (Токио) хоорондын RTT ($\approx 150–$

180 ms) болон Flask+MongoDB боловсруулалтын нийлбэр (≈ 300 ms) юм. Шийдвэрлэх чиглэлүүд болон дэлгэрэнгүй хүснэгтийг Хавсралт В-аас үзнэ үү.

4.6. Дүгнэлт

Судалгааны гол үр дүн

Энэ судалгаагаар машин сургалтын ансамбль аргыг ашиглан Форекс зах зээлийн арилжааны дохионы системийг хөгжүүлсэн. Гол үр дүнг гурван багц болгон нэгтгэн дүгнэв.

1. **Машин сургалтын ансамбль загвар:** LightGBM, XGBoost, CatBoost гурван GBDT загварыг нэгтгэж, 6 хугацааны интервалын 48 шинж чанараар EUR/USD-ийн чиг хандлагыг BUY/HOLD/SELL гурван ангилалд таамагласан. 7 давталтын хөгжүүлэлтийн мөчлөгөөр 75→48 шинж чанар, 9→3 загвар болгон хялбарчлан хэт нийцлийн эрсдэлийг бууруулсан. Нарийвчилсан үнэлгээний үзүүлэлтийг Хүснэгт 4.1 ба Хүснэгт 4.3-т тайлагнасан (RQ1).
2. **Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэл:** 2025 оны бүтэн жилийн EUR/USD H1 цонхонд (1% эрсдэл, TP/SL=3:1) бүх 10 босго утга (0.90–0.99) эерэг өгөөжтэй, B&H жишгээс (+13.47%) 5.5–38 дахин өндөр гарсан. Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын товч дүнг Хүснэгт 4.4-т харууллаа.

Хүснэгт 4.4 Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утгын товч үзүүлэлт (§4.3.6)

Босго утга	Өгөөж (%)	MaxDD (%)	Win (%)	Comp. ранк	Профайл
0.91	+517.70	2.97	47.17	#1 (0.642)	Балансжсан
0.92	+465.12	2.99	47.26	#2 (0.597)	Балансжсан
0.99	+74.29	1.98	65.71	#3 (0.567)	Эрсдэлгүй

Бүх 10 сценарийн ялалтын хувь TP/SL=3:1-ийн break-even ($p_0 = 0.25$)-тэй харьцуулахад бином тестээр статистикийн ач холбогдолтой давсан ($z > 5$, $p < 0.0001$, §4.3). Дэлгэрэнгүй үзүүлэлтийг Хүснэгт Г.2, Хүснэгт Г.3, Хүснэгт Г.4-аас (Хавсралт Г) үзнэ үү.

3. **Инженерчлэлийн хэрэгжүүлэлт:** §3.2-т тайлбарласан загвар сургалт → дохио үүсгэх → мобайл апп гэсэн ML serving дамжлагыг ажиллах прототип хэлбэрт бүтээсэн.

Судалгааны практик хувь нэмэр

- **Нэгдсэн үнэлгээний хүрээ:** Ангиллын нарийвчлал, Wilson итгэлцлийн интервал, эрсдэлийн матриц, ерөнхийлөх боломжийн хязгаарыг нэг дор тайлбарласан нь финтек судалгааны ил тод байдлын стандартад нийцдэг.
- **Олон давхаргын нэгтгэл:** Загварын математик гүйцэтгэл, серверийн хэсгийн ажиллагаа, мобайл аппликейшны харагдах хэсгийг нэг туршилтын хүрээнд үнэлсэн нь академик хүрээнээс давсан системийн инженерчлэлийн жишиг болно.
- **Монгол хэл дээрх техникийн баримтжуулалт:** Машин сургалт, санхүүгийн нэр томъёоны Монгол тайлбар бүхий судалгааны бичвэр нь энэ чиглэлийн дотоодын судалгааны суурь болж чадна.

Хязгаарлалт

1. **Хамрах хүрээ:** EUR/USD валютын хослол болон сонгосон хугацааны цонхонд л үр дүн батлагдсан тул өөр валютын хослол, брокерын нөхцөлд шууд ерөнхийлөх боломжгүй
2. **Шошгын нэвчилтийн үлдэгдэл эрсдэл:** Олон интервалыг нэгтгэхэд хугацааны дүрэм мөрдсөн ч эрсдэлийг бүрэн үгүйсгээгүй
3. **Гүйцэтгэлийн хөрвүүлэлтийн хазайлт:** Гүйцэтгэлийн хувь 100% биш үед ялалтын хувь, хүлээгдэж буй өгөөж нь хэрэгжсэн арилжааны хувьд л хүчинтэй
4. **Статистикийн харьцуулсан тест дутуу:** Win rate-ийн break-even ($p_0 = 0.25$)-тэй харьцуулсан бином тест §4.3-д хийгдсэн ($z > 5$, $p < 0.0001$). Харин загвар хоорондын McNemar's тест явуулаагүй; арилжааны тоо цөөн (35–230 хэлцэл) нь сценари хоорондын ялгааны хүчтэй дүгнэлт гаргахад хязгаарлалт үүсгэнэ
5. **Арилжааны зардлын хамралт:** MetaTrader 5-ийн бодит спрэд болон 10 point-ийн гулсалтын хязгаар тусгасан. Харин брокер тус бүрийн шимтгэл (commission) болон шөнийн байрлал хадгалалтын зардал (swap) энэ хувилбарт тусгаагүй. Шимтгэл нь брокерын нөхцөлөөс ихээхэн хамаарах тул тодорхой тоон утгаар загварчлахын оронд хязгаарлалт болгон тэмдэглэн, өгөөжийн дүнг сценарийн харьцуулалтын хүрээнд тайлбарлав. Бодит орчинд хэрэглэхийн өмнө тухайн брокерын шимтгэл болон свопыг нэмж тооцох нь зайлшгүй.
6. **Магадлалын калибровк ба сургалт-үйлчилгээний зөрүү:** Магадлалын калибровкыг туршилтын ажиглалтаар шалгасан; ажиллах үед магадлалын тооцоо өөрчлөгдөх боломжоос үлдэгдэл эрсдэл үүсч болно
7. **Бодит цагийн хүндрэл:** Гадаад системийн API хязгаарлалт, сүлжээний саатал зэрэг техникийн асуудлууд

Цаашдын чиглэл

Цаашдын ажлыг гурван үндсэн чиглэлд бүлэглэв.

1. **Хүрээний өргөтгөл (загвар ба өгөгдөл):**
 - *Олон валютын хослол:* GBP/USD, USD/JPY зэрэг хослолд сургаж багц стратеги бүтээх
 - *Гүн сургалтын загвар:* LSTM, Transformer-ийг GBDT ансамбльтай харьцуулах — цагийн цуваа дотрох хамаарлыг илрүүлэх чадамжийг үнэлэх
 - *Мэдээний шинжилгээ:* Хэлний боловсруулалтаар эдийн засгийн мэдээг автоматаар шинжилж шинж чанарт оруулах
2. **MLOps баталгаажуулалт ба түгээлт:**
 - *Загварын хувилбарын удирдлага:* Дохио бүрт model_version ба run_id хадгалж ул мөрдөх боломж бүрдсэн боловч formal Model Registry, approve/promote workflow, автомат rollback протокол бүрэн хэрэгжээгүй хэвээр — дараагийн инженерчлэлийн гол шаардлага

- *Түгээлтийн суваг*: Google Play түгээлт нэвтрүүлэх, загварын шилжилтийн мониторинг, хувилбар гаргалтын автоматжуулалт

3. Эрсдэлийн менежмент ба байрлалын удирдлага:

- *Дагах зогсоол (trailing stop)*: Ашгийг хамгаалах динамик SL-ийн аргачлалыг сайжруулах
- *Бататгах сургалт (RL)*: Багцын менежмент, байрлалын хэмжээ тохируулалтад хэрэглэх

Эцсийн дүгнэлт

Судалгааны гурван асуултад товч хариулт өгвөл:

RQ1 (загварын найдвартай байдал): **Тийм**. Загвар нь 2024 оны харагдаагүй өгөгдөл дээр 89.25% нарийвчлал, итгэлцэл ≥ 0.90 дохионд 96.96% нарийвчлалд хүрсэн (баталгаажуулалт). Сургалт-баталгаажуулалтын зөрүү +1.77% нь хэт нийцлийн шинж тэмдэггүй (Хүснэгт 4.1, Хүснэгт 4.3).

RQ2 (дохио хэрэгжих чадвар): **Тийм**. 0.90 босгод 3,567 шүүгдсэн дохио MT5-д 230 хэлцэл болж хэрэгжсэн (Exec rate 6.45–23.81%). Win rate 44.78–65.71% (Wilson 95% CI) бөгөөд бүх 10 сценарид TP/SL=3:1 break-even ($p_0 = 0.25$)-тэй харьцуулахад бином тестээр $z > 5$, $p < 0.0001$ ач холбогдолтой давсан (Хүснэгт Г.3).

RQ3 (1 жилийн тестийн цонхны ашигт ажиллагаа): **Тийм**. 1% тогтмол эрсдэлийн доор бүх 10 сценари эерэг нийт өгөөж (+74.29% — +517.70%) ба эерэг хүлээгдэж буй өгөөж ($E[R] = 0.79\text{--}1.63R$) үзүүлсэн. Бүх 10 сценари EUR/USD-ийн худалдан аваад барих жишгээс (+13.47%) 5.5–38 дахин өндөр өгөөжтэй гарсан (Хүснэгт Г.2, Хүснэгт Г.1). MaxDD 1.98–9.53% хүрээнд хадгалагдсан (Хүснэгт Г.4). Сценари хоорондын балансын хэлбэлзэл ($CV=38.01\%$) нь үр дүн босго сонголтод мэдрэмтгий болохыг харуулдаг тул босгыг тогтоохдоо MaxDD-тэй хамтад нь авч үзэх шаардлагатай.

Дүгнэлт нь EUR/USD валютын хослол, 2025 оны туршилтын цонх ба зардлыг бүрэн тусгаагүй нөхцөлд хүчинтэй. Иймд бусад зах зээлд шууд ерөнхийлөх боломжгүй; практикт эрсдэлийн менежмент, үе үе дахин сургалт, шинэ нөхцөлд дасан зохицох протокол шаардагдана.

Нэгтгэн дүгнэвэл, энэ судалгаа гурван чиглэлд хувь нэмэр оруулсан. Нэгдүгээрт, загвар сургалтаас сервер, мобайл апп хүртэлх ML serving дамжлагыг прототип хэлбэрт бүтээсэн. Хоёрдугаарт, GBDT ансамблийн ангиллын нарийвчлал, итгэлцлийн шүүлтийн нөлөө, эрсдэл-өгөөжийн үзүүлэлтийг нэгдсэн хүрээнд үнэлж, тоон дүн болон хязгаарлалтыг ил тайлагнасан нь финтек судалгааны ил тод байдлын стандартад нийцэж байна. Гуравдугаарт, ML-ийн академик үнэлгээг системийн гүйцэтгэлийн шинжилгээтэй нэгтгэсэн арга зүй нь цаашдын олон давхаргат ML системийн судалгааны загвар болж чадна.

- [1] Bank for International Settlements. Triennial central bank survey: Foreign exchange turnover in april 2022, 2022.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.
- [3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.
- [4] Joarder Kamruzzaman and Ruhul A. Sarker. Forecasting of currency exchange rates using ANN: A case study. *Journal of Financial Forecasting and Analysis*, 1(1):1–15, 2003.
- [5] M. Kumar and M. Thenmozhi. Forecasting stock index movement: A comparison of SVM and random forest. *Indian Institute of Capital Markets Working Paper*, 1(1):1–22, 2006.
- [6] Michel Ballings, Dirk Van den Poel, Niels Hespels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.
- [7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.
- [8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review. *Applied Soft Computing*, 97, 2019.
- [9] Deniz Can Yildirim, Ismail Hakki Toroslu, and Ugo Fiore. Forecasting directional movement of Forex data using LSTM with technical and macroeconomic indicators. *Financial Innovation*, 7(1), 2021.
- [10] Ahmet Murat Ozbayoglu, Mehmet Ugur Gudelek, and Omer Berat Sezer. Deep learning for financial applications: A survey. *Applied Soft Computing*, 93:106384, 2020.
- [11] Yuqi Nie, Nam Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. A time series is worth 64 words: Long-term forecasting with transformers. *International Conference on Learning Representations*, 2023.
- [12] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Timesnet: Temporal 2d-variation modeling for general time series analysis. *International Conference on Learning Representations*, 2023.
- [13] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2):689–702, 2017.
- [14] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [15] Shihao Gu, Bryan T. Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

- [17] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.
- [18] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [19] Omer Berat Sezer, Mehmet U. Gudelek, and A. Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [20] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.
- [21] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis. *The Journal of Finance*, 55(4):1705–1765, 2000.
- [22] Cheol-Ho Park and Scott H. Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.
- [23] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.
- [24] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.
- [25] Ben R. Marshall, Ros Cahan, and Jean M. Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.
- [26] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.
- [27] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.
- [28] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023.
- [29] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O’Reilly Media, 2nd edition, 2018.
- [30] Miguel Grinberg. *Flask Web Development: Developing Web Applications with Python*. O’Reilly Media, 2nd edition, 2018.
- [31] Alan R Hevner, Salvatore T March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.
- [32] Ken Peffers, Tuure Tuunanen, Marcus A Rothenberger, and Samir Chatterjee. A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77, 2007.
- [33] John J. Murphy. *Technical Analysis of the Financial Markets*. New York Institute of Finance, 1999.

Талархал

Энэхүү төгсөлтийн судалгааны ажлыг амжилттай гүйцэтгэхэд үнэтэй дэмжлэг, чиглүүлэг үзүүлсэн нийт хүмүүстээ чин сэтгэлийн талархлаа илэрхийлж байна.

Юуны өмнө удирдагч багш **Н.Соронзонболд**-д судалгааны сэдэв, чиглэлийг тодорхойлох, арга зүйн зөвлөгөө өгөх болон гүйцэтгэлийн алхам бүрт тасралтгүй хяналт тавьж зөвлөн чиглүүлсэнд гүн талархал илэрхийлье. Багшийн үнэтэй зөвлөгөө, цаг ямагт үзүүлсэн дэмжлэг ажлын чанарт шууд нөлөөлсөн билээ.

Шинэ Монгол Технологийн Коллеж-ийн Компьютерын ухааны тэнхимийн багш нартаа дөрвөн жилийн турш програмчлал, алгоритм, өгөгдлийн бүтэц, машин сургалт зэрэг чиглэлээр гүнзгий мэдлэг, мэргэжлийн чиг баримжаа олгосонд талархал илэрхийлж байна. Тэдний хичээл зүтгэлийн ачаар энэхүү судалгааны ажлыг бие даан гүйцэтгэх суурь бэлтгэлтэй болсон юм.

Эцэст нь, намайг үргэлж хурцалж, сэтгэл зүйн хувьд хамгийн том дэмжлэг болж байсан гэр бүлийнхэндээ болон алхам бүрд хамт байсан ангийн хамт олондоо баярлалаа. Та бүхний минь тусламж, халуун дулаан уур амьсгал энэхүү судалгааны ажлыг дуусгахад үнэлж баршгүй түлхэц болсон билээ.

Хүндэтгэсэн **М.Мөнхдорж**

2026 оны 6-р сар

Хавсралт

Хавсралт А: Нэвчилтийн аудитын нарийвчилсан дүрэм

Цагийн нийцлийн дүрэм

Мэдээллийн нэвчилтээс сэргийлэх цагийн нийцлийн үндсэн томьёо (томьёо 3.2) болон ерөнхий тайлбарыг Арга зүйн бүлгийн §3.3-т (“Шошго ба шинж чанарын цагийн нийцлийн аудит” дэд хэсэг) үзнэ үү. Доор компонент бүрийн нарийвчилсан аудитын дүрмийн хүснэгтийг харуулав.

Нэвчилтийн аудит дүрмүүдийн нарийвчилсан тайлан

Хүснэгт А.1 Нэвчилтийн аудитын цагийн нийцлийн дүрмүүд


Компонент	Үйлдэл	Цагийн нөхцөл	Нэвчилтийн эрсдэл
OHLCV өгөгдөл	t_0 -д хаалтын ханш ба үзүүлэлтүүдийг ашиглах	$t_{\text{candle}} < t_0$	Бага (хаалтын ханш шийдвэрийн агшинд мэдэгдсэн байдаг)
MA (хөдөлгөөнт дундаж)	t_0 -г оруулаад өмнөх 50 лааны (candle) дундаж	$t_{\text{MA window}} < t_0$	Бага (түүхэн мэдээлэл)
RSI, ATR	t_0 -г оруулаад өмнөх өгөгдлөөс тооцох	$t_{\text{period}} \leq t_0$	Бага
240 минутын label	t_0 -ээс дараах 240 минутын хамгийн дээд/доод	$t_{\text{label}} > t_0$	ӨНДӨР (future data)
Олон интервалын синхрончлол	merge_asof, direction=backward	$t_{\text{small}} \leq t_{\text{large}}$	Дунд (boundary алдаа)

Тайлбар: merge_asof(backward) болон хугацааны тусгаарлалтын дүрэм нь нэвчилтийн эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй. Иймээс үр дүнг тайлбарлахдаа энэ эрсдэлийг хязгаарлалтын хүрээнд хамтад нь авч үзсэн.

Хавсралт Б: Урагш гүйлгэн баталгаажуулалтын олон огтлолын схем

WFV олон огтлолын концепцын схем

Үндсэн бичвэрийн §3.4.5-т тайлбарласан олон огтлол, өргөтгөх сургалтын цонх (expanding window) протоколын Fold 1–Fold 5-ийн хуваарийг нэг зурагт төвлөрүүлэн харуулав.



Зураг Б.1 WFV олон огтлолын ерөнхий концепцын схем (Fold 1–Fold 5 expanding window protocol)

Тайлбар: Бүх Fold-ийн сургалт 2015-аас эхэлж, Fold өсөх тусам сургалтын цонх жил жилээр өргөжин (4 → 5 → 6 → 7 → 8 жил), баталгаажуулалт ба тестийн цонх урагш шилждэг *expanding window* протокол. Сургалтын блокын урт нь бодит хугацааны хэмжээтэй пропорциональ зурагдсан тул дээд folds бага, доод folds (Fold 5) хамгийн урт болж харагдана. Энэ судалгааны KPI үнэлгээнд Fold 5-ын хуваалт ашиглагдсан (үндсэн бичвэрийн Зураг 3.4-ийг үзнэ үү).

Хавсралт В: Архитектурын KPI-ийн хэмжилтийн нөхцөл

Архитектурын хэмжигдэх KPI ба баталгаажуулалтын протокол

Архитектурын шийдлүүдийг зөвхөн бүтэц дүрслэлээр бус хэмжигдэх шалгуураар үнэлэх зорилгоор баталгаажуулалтын протоколыг доор тодорхойлсон. Энэ протокол нь API, worker, push урсгалын ажиллах чанарыг ижил нөхцөлд давтан шалгах үндсэн хүрээг тогтооно.

Хүснэгт В.1 Архитектурын баталгаажуулалтын KPI протокол

Компонент	KPI	Зорилтот босго	Баталгаажуулах арга
API давхарга	p95 latency	≤ 350ms	Ижил endpoint дээр 15 минутын тогтмол ачааллын туршилт, median/p95-г нэгтгэн тайлагнах
API давхарга	5xx алдааны хувь	< 1.0%	Ачааллын туршилтын хугацаанд нийт хүсэлтэд харьцуулж тооцох
Worker урсгал	Job completion rate	≥ 99%	Төлөвлөгөөт ажлын log мөрөөр амжилт/алдааны харьцааг өдөр тутамд тооцох
Worker урсгал	Retry recovery rate	≥ 95%	Алдаатай job-ийн дахин оролдлогоос амжилттай сэргэсний хувийг хэмжих
Push урсгал	Notification delivery rate	≥ 98%	Push сервисийн нийлбэр илгээлт ба хүрсэн мэдэгдлийн тоог харьцуулах

Хэмжилтийн нөхцөл

API давхаргын p95 latency хэмжилтийг доорх нөхцөлд явуулсан:

- **Хэмжилтийн байршил:** Улаанбаатар (Монгол улс)
- **Серверийн байршил:** Токио (Japan East, Azure App Service)
- **Сүлжээний RTT:** дунджаар 150–180ms
- **Хүсэлтийн тоо:** endpoint тутамд n=30 хүсэлт
- **Ачааллын загвар:** Дараалсан (sequential) ачаалал, өөр өөр 3 endpoint-т
- **Хэмжилтийн хугацаа:** 15 минут (900 сек), тасралтгүй

Worker ба Push урсгалын KPI:

- **Worker job completion:** Өдөрт 50–100 ажил процесс хийгдэж, лог дээр бичигдэнэ
- **Worker scheduling:** Python threading (time.sleep мөчлөгт суурилсан) ашиглан минут бүр дохио үүсгэх мөчлөгийг гүйцэтгэдэг

- **Push delivery:** Expo Push API (`exp.host`) платформ, хүргэлтийн статистик Expo dashboard-аар тайлагнана

p95 latency зорилтот босгоос хэтрэлтийн дүн шинжилгээ

API давхаргын p95 latency 471–536ms байсан нь зорилтот 350ms-ийг хэтэрсэн. Үндсэн шалтгааны дүн шинжилгээ:

1. **Сүлжээний RTT нөлөө:** Улаанбаатараас Токиогийн сервер хүртэлх RTT дунджаар 150–180ms байдаг тул энэ сүлжээний саатлыг latency-ийн зорилтот хүлээлтэд тооцох шаардлагатай
2. **MongoDB query latency:** /signals/latest endpoint-т MongoDB дээр дохиог авах query хэрэгтэй бөгөөд үндсэн database-д индексийн оновчлол хийгдээгүй үлдсэн
3. **Сериалчлалын ачаалал:** JSON сериалчлал нь томоохон объектын цуглуулгыг боловсруулахад нэмэлт ачаалал үүсгэдэг
4. **Кэшлэлтийн хомсдол:** /rates/live-ийн үр дүнг Redis кэшэд тогтмол хадгалдаггүй тул кэшлэлтийг сайжруулбал latency буурах боломжтой

Практик сайжруулах сонголтууд:

- MongoDB дохионы хадгалалтад (`timestamp`, `symbol`, `timeframe`) compound unique index + `upsert` бодлого хэрэгжүүлэх (`idempotency`)
- Серверийн бүсчлэлийг хэрэглэгчийн байршилд ойртуулах, эсвэл CDN/edge cache ашиглах
- Redis multi-tier кэшлэл (L1 in-memory, L2 Redis)
- Олон query-г багцлан (`batch request`) илгээх

Хавсралт Г: Эх сурвалжийн нэгтгэлийн дүрэм

Үр дүнгийн өгөгдлийн эх сурвалж ба reproducibility

Энэ бүлгийн бүх тоон дүнг түүхэн өгөгдөл дээрх системийн туршилтын логуудаас гаргав. Лог файлууд нь хуримтлагдсан (`append`) бүтэцтэй тул өмнөх гүйлтийн мөрүүд дараагийн файлд давтагддаг. Иймээс босго бүрийн `run`-ыг `Loaded signals` мөрөөр таньж, тухайн `run`-т харгалзах `final balance` болон `TP/SL` мөрүүдтэй тогтмол дүрмээр хослуулан нэгтгэл хийв. Энэ дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах нөхцөлийг хангана.

Босгын мужийн нэгдсэн тоон үзүүлэлтийн дэлгэрэнгүй

§4.3-ын зургуудад харуулсан үзүүлэлтүүдийн тоон утгуудыг доорх дөрвөн хүснэгтэд нэгтгэв. Хүснэгт Г.2 нь босго бүрийн дохио, баланс, өгөөжийн нэгтгэл; Хүснэгт Г.3 нь дохио-арилжааны гүйцэтгэл, ялалтын хувь ба итгэлцлийн интервал; Хүснэгт Г.4 нь эрсдэлийн үзүүлэлтүүдийг; Хүснэгт Г.1 нь EUR/USD-ийн худалдан аваад барих жишгийн дэлгэрэнгүйг агуулна.

Хүснэгт Г.1 EUR/USD худалдан аваад барих жишигийн хураангуй (2025)

Үзүүлэлт	Утга
Эхлэл хаалт (2025)	1.03514
Төгсгөл хаалт (2025)	1.17456
Худалдан аваад барих өгөөж (%)	13.47
\$10,000 хөрөнгийн эцсийн баланс (\$)	11,346.87

Тайлбар: Энэ жишиг нь close-to-close энгийн загвар тул стратегийн өгөөжтэй шууд тэнцэхгүй; сценарийн дүнг харьцуулахад ашиглав.

Хүснэгт Г.2 0.90–0.99 мужийн босгын харьцуулалт

Босго	Нийт дохио	Дохио/өдөр	Эцсийн баланс (\$)	Цэвэр ашиг (\$)	Өгөөж (%)	Нэг дохионы ашиг (\$)
0.90	3,567	13.67	58,262.39	48,262.39	482.62	13.53
0.91	3,274	12.54	61,770.46	51,770.46	517.70	15.81
0.92	2,958	11.33	56,512.20	46,512.20	465.12	15.72
0.93	2,643	10.13	46,807.24	36,807.24	368.07	13.93
0.94	2,287	8.76	38,050.13	28,050.13	280.50	12.27
0.95	1,914	7.33	32,844.40	22,844.40	228.44	11.94
0.96	1,588	6.08	33,040.14	23,040.14	230.40	14.51
0.97	1,195	4.58	29,019.19	19,019.19	190.19	15.92
0.98	673	2.58	25,447.43	15,447.43	154.47	22.95
0.99	147	0.56	17,428.89	7,428.89	74.29	50.54

Тайлбар: Дохио/өдөр үзүүлэлтийг Нийт дохио/261 (2025 оны Даваа–Баасан ажлын өдрийн тоо) томъёогоор тооцсон.

Хүснэгт Г.3 Босго тус бүрийн дохио-арилжааны гүйцэтгэл ба ялалтын хувь (95% CI)

Босго	Ачаал.	Арилжаа	Хөрвөөгүй	Гүйц. (%)	TP/SL	Ялалт (%)	95% CI	E[R]
0.90	3,567	230	3,337	6.45	103/127	44.78	[38.49, 51.24]	0.79
0.91	3,274	212	3,062	6.48	100/112	47.17	[40.56, 53.88]	0.89
0.92	2,958	201	2,757	6.80	95/106	47.26	[40.48, 54.15]	0.89
0.93	2,643	188	2,455	7.11	87/101	46.28	[39.30, 53.41]	0.85
0.94	2,287	154	2,133	6.73	73/81	47.40	[39.68, 55.26]	0.90
0.95	1,914	137	1,777	7.16	65/72	47.45	[39.27, 55.76]	0.90
0.96	1,588	113	1,475	7.12	59/54	52.21	[43.08, 61.20]	1.09
0.97	1,195	106	1,089	8.87	54/52	50.94	[41.56, 60.26]	1.04
0.98	673	76	597	11.29	43/33	56.58	[45.39, 67.14]	1.26
0.99	147	35	112	23.81	23/12	65.71	[49.15, 79.17]	1.63

Тайлбар: Win rate-ийн 95% Wilson итгэлцлийн интервал болон Expectancy ($E[R]$, TP/SL=3:1 нөхцөлд)-ийн тооцоолол §3.6-аар тодорхойлогдсон.

Хүснэгт Г.4 Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ

Босго	MaxDD (%)	Sharpe	Sortino	Calmar	Хамгийн урт дараалсан алдагдал
0.90	3.93	9.11	24.82	122.96	7
0.91	2.97	9.75	25.99	174.20	7
0.92	2.99	9.90	29.78	155.79	7
0.93	9.53	9.21	25.92	38.63	10
0.94	6.80	8.87	24.66	41.23	8
0.95	3.94	8.57	23.97	57.97	6
0.96	4.88	9.84	30.15	47.18	5
0.97	2.96	9.02	24.90	64.19	4
0.98	7.66	10.63	28.84	20.16	8
0.99	1.98	12.83	44.76	37.53	2

Чухал анхааруулга: Sharpe (9–13), Sortino (24–45), Calmar (20–174) утгууд нь арилжаа цөөн (35–230 хэлцэл), хугацааны цонх богино (1 жил) ба зардал бүрэн тусгаагүйгээс зохиомлоор томруулагдсан тул санхүүгийн стандарт утгуудтай шууд харьцуулах боломжгүй; зөвхөн босгуудын харьцангуй харьцуулалтын суурь болгон ашиглана.

Хавсралт Д: MongoDB цуглуулгын схемийн хүснэгт

Системийн өгөгдлийн тогтвортой давхарга нь MongoDB Atlas үүлэн дээр байршуулсан 12 цуглуулгаас бүрдэх ба тэдгээрийг гүйцэтгэх үүргээр нь Хэрэглэгчийн, Дохио-Мэдэгдлийн, Мэдээний болон Системийн гэсэн 4 бүлэгт ангилав. Цуглуулга бүрийн гол талбарууд, индекс ба TTL (Time-To-Live) тохиргоог Хүснэгт Д.1-т нэгтгэв.

Хүснэгт Д.1 MongoDB Atlas-д байршсан 12 цуглуулгын схем —гол талбарууд, индекс ба TTL тохиргоо

Цуглуулга	Гол талбарууд	Индекс	TTL
<i>1. Хэрэглэгчийн бүлэг</i>			
users	_id, email, password_hash, name, created_at	unique(email)	—
push_tokens	user_id, push_token, platform, notifications_enabled, signal_threshold	unique(user_id)	—
refresh_tokens	user_id, token_hash, expires_at, created_at	—	expires_at
verification_codes	email, code (OTP), expires_at (+10мин), created_at	—	expires_at
reset_codes	email, code, expires_at, used	—	expires_at
<i>2. Дохио / Мэдэгдлийн бүлэг</i>			
signals	pair, symbol, timeframe, signal {BUY,SELL,HOLD}, confidence, entry_price, SL, TP, run_id, source, timestamp	unique(source, ts, sym, tf); (pair, created_at)	—
in_app_notifications	type {signal, news, security}, title, body, data, created_at, expires_at, read_by: [user_id]	—	expires_at
<i>3. Мэдээний бүлэг</i>			
ai_insights	pair, timestamp, analysis, type, expires_at	—	expires_at
news_analysis	event, impact, analysis, sentiment, timestamp, created_at	—	—
notified_events	event_id, notified_at	—	—
<i>4. Системийн бүлэг</i>			
job_locks	job_name, owner_id, expires_at (хуваарилагдсан түгжээ)	—	expires_at
analysis_jobs	job_id, status {pending,...,done}, result, created_at	—	—

Цуглуулга хоорондын гадаад түлхүүрийн (foreign key) харьцааг Хүснэгт Д.2-т харуулав.

Хүснэгт Д.2 Цуглуулга хоорондын гадаад түлхүүрийн харилцаа

Эх цуглуулга	Харьцаа	Зорилтот цуглуулга	Холбогдох талбар
users._id	1:1	push_tokens	user_id
users._id	1:N	refresh_tokens	user_id
signals._id	1:N	in_app_notifications	data.signal_id

Дизайны зарчмууд: (1) TTL индексүүд нь түр зуурын баримтуудыг (verification_codes, reset_codes, job_locks, refresh_tokens, in_app_notifications, ai_insights) автоматаар цэвэрлэж хадгалалтын зайг хэмнэдэг. (2) signals цуглуулгын (source, timestamp, symbol, timeframe) unique compound индекс нь олон instance-ын зэрэгцээ ажиллагаанд давхардсан дохио үүсэхээс сэргийлдэг (idempotent upsert). (3) job_locks цуглуулга нь олон Azure App Service instance-ийн зэрэгцээ ажиллах үед нэг scheduler-ийг зөвхөн нэг instance гүйцэтгэхийг хангадаг.

Хавсралт E: GBDT гиперпараметруудийн нарийвчилсан жагсаалт

§3.4-т (Гиперпараметр сонголтын протокол) дурдсан жигдрэлийн протоколын дагуу сонгогдсон LightGBM, XGBoost ба CatBoost загваруудын бүх гиперпараметрийг Хүснэгт E.1 хүснэгтэд нэгтгэв. Хүснэгт нь reproducibility-ийн зорилгод зориулагдсан бөгөөд параметр тус бүрийн утга ба үүргийг загвар бүрд харьцуулан харуулав.

Хүснэгт E.1 Гурван GBDT загварын гиперпараметрууд

Параметр	LightGBM	XGBoost	CatBoost	Үүрэг
<i>Загварын ерөнхий бүтэц</i>				
n_estimators	500	500	500	Модны дээд тоо (эрт зогсоолтоор тасалдаг)
learning_rate	0.03	0.03	0.03	Алхамын хэмжээ; бага утга сургалтыг удаашруулдаг боловч хэт нийцлийг бууруулдаг
max_depth	6	5	5	Модны хамгийн их гүн
num_leaves	31	—	—	Leaf-wise өсөлтийн (LGBM) бутархай хязгаар
<i>Тогтмолжуулалт</i>				
min_child_samples	20	—	—	Leaf-д байх хамгийн бага дээж (LightGBM)
min_child_weight	—	5	—	Leaf-д шаардлагатай хамгийн бага жин (XGBoost)
reg_alpha (L1)	0.10	0.10	—	L1 норм нэмэх жин
reg_lambda (L2)	1.0	1.0	3.0	L2 норм нэмэх жин (CatBoost-д l2_leaf_reg)
gamma	—	0.1	—	Хуваалт хийх хамгийн бага алдагдлын бууралт (XGBoost)
subsample	0.7	0.7	—	Мөр түүвэрлэх хувь (bagging)
colsample_bytree	0.7	0.7	—	Шинж чанар түүвэрлэх хувь
<i>Сургалтын протокол</i>				
early_stopping_rounds	50	50	50	Val loss сайжрахгүй 50 давталт → зогсооно
eval_metric	multi_logloss	mlogloss	MultiClass	Multi-class cross-entropy
scale_pos_weight	neg/pos	neg/pos	—	Ангийн тэнцвэргүй байдлыг зохицуулах
random_state	42	42	42	Reproducibility-н seed
<i>Алгоритмын онцлог параметр</i>				
boosting_type	gbdt	gbtree	Plain	Үндсэн boosting аргачлал
grow_policy	leaf-wise	depth-wise	symmetric	Модны өсөлтийн стратеги
bootstrap_type	—	—	Bayesian	CatBoost-ийн bagging схем (bagging_temperature=1.0)

Тэмдэглэл: “—” нь тухайн параметр уг загварт байхгүйг харуулна. Хэт нийцлээс сэргийлэх зургаан арга хэмжээ (модны гүнийг хязгаарлах, бага learning rate, эрт зогсоолт, L1/L2 тогтмолжуулалт, WFLV, шинж чанарын цөөрөлт) бүгд энэ хүснэгтэд тусгагдсан.

Хавсралт Ж: Харагдах хэсгийн модуль ба API endpoint жагсаалт

§3.9-т (Харагдах хэсгийн архитектур) дурдсан мобайл аппын дөрвөн модуль тус бүрийн үүрэг, харилцааны загвар ба холбогдох REST API endpoint-үүдийг Хүснэгт Ж.1 хүснэгтэд нэгтгэв.

Хүснэгт Ж.1 Харагдах хэсгийн модулиуд, харилцааны загвар ба API endpoint бүлэг

Модуль	Үндсэн үүрэг	Харилцааны загвар	Холбогдох API endpoint
Нэвтрэлтийн модуль	Бүртгэл, нэвтрэлт, токен шинэчлэлт, профайл	REST POST/PUT	/auth/register, /auth/login, /auth/refresh
Ханшийн модуль	Бодит цагийн ханш, 24 цагийн өөрчлөлт, хослол сонгох	REST GET (polling)	/rates/live, /rates/{pair}/history
Дохионы модуль	Дохио жагсаалт, итгэлцэл, SL/TP дэлгэрэнгүй, гүйцэтгэлийн статистик	REST GET + Push	/signals/latest, /signals/{id}, /signals/stats
Мэдээний модуль	Эдийн засгийн мэдээ, үйл явдлын хуанли, AI шинжилгээ	REST GET	/news/feed, /news/calendar

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутан: s21c033b, М.Мөнхдорж

Удирдагч багш: Н.Соронзонболд

1. Удиртгал

Гадаад валютын зах зээл нь өндөр хэлбэлзэлтэй, шуугиан ихтэй цаг хугацааны цуваа үүсгэдэг тул уламжлалт статистик аргад тулгуурласан таамаглал хязгаарлагдмал хэвээр байна. GBDT болон нейрон сүлжээний загварууд зүй тогтлыг илрүүлэх чадвартай нь нотлогдсон ч нэг загварт түшиглэсэн архитектур нь хэт нийцлийн эрсдэлээс шалтгаалан практик хэрэглээнд саад болсоор байна. Энэ судалгаа нь EUR/USD валютын хослолд BUY/HOLD/SELL ангиллын дохио үүсгэх GBDT ансамбль ML системийг бүтээж, мобайл аппликейшнаар хэрэглэгчид хүргэх зорилготой. Гурван судалгааны асуултыг дэвшүүлэв:

- **RQ1:** Загвар цагийн дарааллыг хадгалсан тест дээр найдвартай ажиллах уу?
- **RQ2:** Шүүгдсэн дохио бодит арилжаа болж хэрэгжих үү?
- **RQ3:** Тогтмол эрсдэлтэй 1 жилд эерэг өгөөж гарах уу?

2. Судалгааны сэдвийн онол, өнөөгийн түвшин

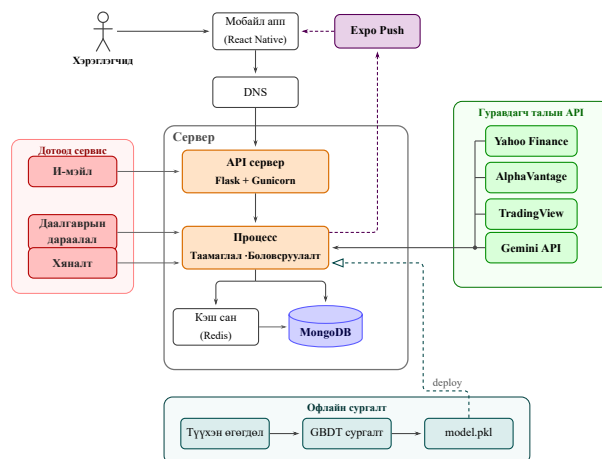
Санхүүгийн цаг хугацааны цуваа таамаглах судалгаа EMH-ийн онолын эргэлзээний дунд хөгжсөн ч сүүлийн жилүүдэд машин сургалтаар зүй тогтлыг мэдэгдэхүйц илрүүлэх боломжтой болохыг бэхжүүлсэн. Krauss нар (2017) GBDT нь гүн сургалтаас илүү найдвартай үр дүн үзүүлдэг гэж дүгнэсэн бол Ballings нар (2015) ансамбль дангаар ажиллах загвараас 3–7% ахиц гаргадгийг тогтоосон. Fischer, Krauss (2018) LSTM-ийг S&P 500, Yildirim нар (2021) EUR/USD дээр туршсан хэдий ч олон интервалын шинж чана-

рын инженерчлэлийг GBDT ансамбльтай хослуулсан эмпирик ажил цөөн хэвээр байна.

Хувь нэмэр. Энэ судалгаа Форекс зах зээлд GBDT ансамбль, олон хугацааны интервалын шинж чанар, итгэлцлийн босгот суурилсан дохио шүүлтүүр болон мобайл интерфэйсийг нэгдсэн системд хослуулан эмпирик байдлаар туршсан.

3. Судалгааны арга зүй


Загвар сургалтаас мобайл апп хүртэлх ML serving системийг бүтээсэн (Зураг 1). Гурван үндсэн давхарга: (i) офлайн сургалт (GBDT pkl); (ii) Сервер (Flask + MongoDB + Redis + Expo Push) + 4 гадаад API; (iii) Мобайл апп (React Native, 4 дэлгэц).



Зураг 1 Системийн архитектур


Өгөгдөл. EUR/USD 2015–2024 оны түүхэн өгөгдөл дээр 6 интервал (M1–H4) $\times$ 8 техникийн үзүүлэлт = 48 шинж чанарын матриц бүрдүүлсэн. Шошгыг 240 минутын ирээдүйн хөдөлгөөнөөс 30 пипсийн босгоор BUY/HOLD/SELL гурван ангилалд хуваасан.

Загвар. LightGBM, XGBoost, CatBoost загваруудыг зөөлөн санал хураалтаар тэгш жингээр нэгтгэсэн ансамбль (Зураг 2). Гурван загвар өсөлтийн стратеги (leaf-wise, level-wise, symmetric)-аараа бие биенээ нөхөж хэт нийцлийн эрсдэлийг бууруулдаг. Сургалтыг WFV-ийн тав дахь огтлолоор (train 2015–2022, val 2023, test 2024) явуулсан. Хэт нийцлээс сэргийлэхийн тулд модны гүн, бага learning rate, эрт зогсоолт, L1/L2 тогтмолжуулалт, WFV болон шинж чанарын сонголт гэсэн зургаан арга хэмжээг хослуулан хэрэгжүүлсэн.



Зураг 2 GBDT ансамбль загварын архитектур

Дохио шүүлтүүр. Итгэлцэл ($\text{conf} \geq 0.90$) ба ATR (≥ 4 пипс) хослолоор дохиог шүүж, 2025 оны 359,639 таамаглалаас 3,567 (1.0%) дохио үлдэн, MT5-ийн MaxPositions=1 дүрмээр 230 хэлцэл хэрэгжсэн (Зураг 3). SL/TP-г ATR-аас динамикаар тооцох ба TP/SL=3:1 харьцаа хадгалсан.



Зураг 3 Дохионы шүүлтүүрийн юүлүүр (0.90 босго утга)

Туришилт. MT5 Strategy Tester, 2025.01–2026.01, \$10,000 анхны хөрөнгө, нэг агшинд нэг

байрлал, бодит спрэд + 10 point гулсалт, 10 итгэлцлийн босго утга (0.90–0.99).


4. Судалгааны үр дүн

Ангиллын чанар. 2024 оны харагдаагүй тестийн ерөнхий нарийвчлал **89.25%** (бүх ангилал) бол баталгаажуулалтын (2023) дээж дээр $\text{conf} \geq 0.90$ шүүлтийн дараах нарийвчлал **96.96%** болж нэмэгдсэн. Баталгаажуулалт–сургалтын зөрүү +1.77% —хэт нийцэлгүй (Хүснэгт 1).

Хүснэгт 1 GBDT ансамблийн нарийвчлал ба F1 оноо


Хуваарь	Цонх	Асс (%)	F1-mac	F1-wgt
Сургалт	2015–2022	82.71	67.74	80.94
Баталгаажуулалт	2023	84.48	62.67	82.29
Тест (out-of-sample)	2024	89.25	59.45	87.23

Стратегийн өгөөж. Бүх 10 итгэлцлийн босго утга (0.90–0.99) эерэг өгөөжтэй гарч, Buy & Hold (+13.47%) жишгийг 5.5–38 дахин давсан. 0.91 босго утгад хамгийн өндөр +517.70% (\$61,770) илэрсэн ба 0.90–0.92 муж нь өндөр өгөөжийг бага уналттай (MaxDD < 3%) хослуулсан тэнцвэрт цэг боллоо (Зураг 4).



Зураг 4 Босго утга бүрийн эцсийн баланс

Эрсдэл ба статистик. Win rate 44.78–65.71% (Wilson 95% CI); бином тест $z > 5$, $p < 0.0001$; $E[R]=0.79–1.63R$ эерэг; MaxDD 1.98–9.53% (Зураг 5). Sharpe 8.6–12.8 утга нь түүврийн хэмжээ бага, цонх богино, зардал бүрэн тусгаагүйгээс зохиомлоор томруулагдсан тул босго утгуудын харьцангуй харьцуулалтад л хүчинтэй.



Зураг 5 Эрсдэлийн үзүүлэлтүүд босго утга тус бүрээр

5. Дүгнэлт

Энэхүү судалгаа нь EUR/USD валютын зах зээлд BUY/HOLD/SELL ангиллын дохио үүсгэх GBDT ансамбль, итгэлцлийн босгот шүүлтүүр болон мобайл интерфэйсийг сургалтаас хэрэглэгч хүртэлх цогц pipeline-ийн хүрээнд нэгтгэн эмпирик байдлаар туршив. Гурван судалгааны асуултад дараах хариултыг олж авав:

- **RQ1:** 89.25% (тест 2024, бүх ангилал) / 96.96% (val 2023, $\text{conf} \geq 0.90$)
- **RQ2:** 3,567 дохио $\rightarrow$ 230 хэлцэл (6.45–23.81%)
- **RQ3:** +74–518% өгөөж, $E[R]=0.79-1.63R$

Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утга (Хүснэгт 2):

Хүснэгт 2 Нэгдсэн үнэлгээгээр тэргүүлсэн 3 босго утга

Босго утга	Өгөөж	MaxDD	Win	Профайл
0.91	+517.70%	2.97%	47.17%	#1 Балансжсан
0.92	+465.12%	2.99%	47.26%	#2 Балансжсан
0.99	+74.29%	1.98%	65.71%	#3 Эрсдэлгүй

Дээрх үр дүн нь зөвхөн загварын статистик нарийвчлал биш, өгөгдөл цуглуулалт $\rightarrow$ шинж чанарын инженерчлэл $\rightarrow$ ансамбль сургалт $\rightarrow$ дохио шүүлтүүр $\rightarrow$ автомат хэлцэл $\rightarrow$ мобайл мэдэгдэл гэсэн нэгдсэн pipeline-ийн чанарыг хамтад нь баталгаажуулсан. Шинжлэх ухааны хувьд GBDT ансамбль, олон интервалын шинж чанар болон итгэлцлийн босгот шүүлтүүрийг

нэгтгэсэн эмпирик нотолгоог танилцуулсан бол практикийн хувьд сургалтаас мобайл түгээлт хүртэлх бүрэн хэрэгжүүлэлтийн загвар (referent system)-ийг бүтээж, бодит цаг хугацааны нөхцөлд ажиллах чадварыг нь харууллаа.

Хязгаарлалт. Үр дүн EUR/USD ба 2025 оны цонхонд л баталгаажсан тул бусад хослолд шууд ерөнхийлөх боломжгүй; шимтгэл (commission) ба swar бүрэн тусгагдаагүй; дохиогүйцэтгэлийн хөрвүүлэлт 100%-иас бага байна.

Цаашдын чиглэл. GBP/USD, USD/JPY руу өргөтгөх; LSTM/Transformer-той харьцуулах; RL-ээр байрлалын хэмжээ удирдах; Model Registry ба Google Play түгээлтийг хэрэгжүүлэх.

Ном зүй

1. Krauss, C., Do, X.A., Huck, N. (2017). Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical Arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2): 689–702.
2. Ballings, M., Van den Poel, D., Hespels, N., Gryp, R. (2015). Evaluating Multiple Classifiers for Stock Price Direction Prediction. *Expert Systems with Applications*, 42(20): 7046–7056.
3. Fischer, T., Krauss, C. (2018). Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions. *European Journal of Operational Research*, 270(2): 654–669.
4. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems (NeurIPS)*, 30: 3146–3154.
5. Yildirim, D.C., Toroslu, I.H., Fiore, U. (2021). Forecasting Directional Movement of Forex Data Using LSTM with Technical and Macroeconomic Indicators. *Financial Innovation*, 7(1).

FOREIGN EXCHANGE TRADING SIGNAL GENERATION SYSTEM

Department of Computer Science
Student: s21c033b, M. Munkhdorj
Supervisor: N. Soronzonbold

1. Introduction

The foreign exchange (Forex) market produces highly volatile, noisy time series, so forecasting based on traditional statistical methods remains limited. Although GBDT and neural-network models have been shown capable of detecting patterns, single-model architectures are still hindered in practice by the risk of overfitting. This study builds a GBDT-ensemble ML system that generates BUY/HOLD/SELL classification signals for the EUR/USD pair and delivers them to users through a mobile application. Three research questions were posed:

- **RQ1:** Does the model perform reliably on a chronologically ordered hold-out test?
- **RQ2:** Do the filtered signals actually execute as real trades?
- **RQ3:** Under a fixed-risk rule, does the system yield a positive return over one year?

2. Background and Related Work

Research on financial time-series forecasting developed amid the theoretical skepticism of the Efficient Market Hypothesis (EMH), yet recent years have reinforced that machine learning can detect patterns to a meaningful degree. Krauss et al. (2017) concluded that GBDT yields more reliable results than deep learning, while Ballings et al. (2015) found that ensembles gain 3–7% over single models. Although Fischer & Krauss (2018) tested LSTM on the S&P 500 and Yildirim et al. (2021) on EUR/USD, empirical work combining multi-timeframe feature engineering with a GBDT ensemble remains scarce.

Contribution. This study empirically tests, within a single unified system, a GBDT ensemble, multi-timeframe features, confidence-threshold signal filtering, and a mobile interface for the Forex market.

3. Methodology

An ML serving system spanning from model training to the mobile app was built (Figure 1). It has three core layers: (i) offline training (GBDT.pkl); (ii) Server (Flask + MongoDB + Redis + Expo Push) + 4 external APIs; (iii) Mobile app (React Native, 4 screens).




Figure 1 System architecture

Data. A 48-feature matrix was built from EUR/USD 2015–2024 historical data over 6 timeframes (M1–H4) $\times$ 8 technical indicators. Labels were assigned to BUY/SELL/HOLD by a 30-pip threshold on the future 240-minute move.

Model. LightGBM, XGBoost, and CatBoost were combined by equal-weight soft voting (Figure 2). The three models complement one another through different growth strategies

(leaf-wise, level-wise, symmetric), reducing the risk of overfitting. Training used the fifth WFFV fold (train 2015–2022, val 2023, test 2024). Six anti-overfitting measures were combined: limited tree depth, low learning rate, early stopping, L1/L2 regularization, WFFV, and feature selection.




Figure 2 GBDT ensemble model architecture

Signal filter. Signals are filtered by confidence ($\text{conf} \geq 0.90$) and ATR (≥ 4 pips); of 359,639 predictions in 2025, 3,567 (1.0%) remained, and MT5’s MaxPositions=1 rule executed 230 trades (Figure 3). SL/TP are computed dynamically from ATR with a 3:1 TP/SL ratio.




Figure 3 Signal filtering funnel (0.90 threshold)

Experiment. MT5 Strategy Tester, 2025.01–2026.01, \$10,000 initial capital, one position at a time, real spread + 10 point slippage, 10 confidence thresholds (0.90–0.99).

4. Results

Classification quality. On the unseen 2024 test set, overall accuracy reached **89.25%** (all classes), while on the validation (2023) sample after

$\text{conf} \geq 0.90$ filtering accuracy rose to **96.96%**. The validation–training gap of +1.77% indicates no overfitting (Table 1).

Table 1 GBDT ensemble accuracy and F1 scores

Split	Window	Acc (%)	F1-mac	F1-wgt
Train	2015–2022	82.71	67.74	80.94
Validation	2023	84.48	62.67	82.29
Test (out-of-sample)	2024	89.25	59.45	87.23

Strategy return. All 10 confidence thresholds (0.90–0.99) produced positive returns, beating the Buy & Hold (+13.47%) benchmark by 5.5–38 $\times$. The 0.91 threshold reached the highest **+517.70% (\$61,770)**, and the 0.90–0.92 band combined high return with low drawdown (MaxDD < 3%), forming a balanced operating point (Figure 4).




Figure 4 Final balance by threshold

Risk and statistics. Win rate 44.78–65.71% (Wilson 95% CI); binomial test $z > 5$, $p < 0.0001$; $E[R]=0.79$ –1.63R, all positive; MaxDD 1.98–9.53% (Figure 5). The Sharpe values of 8.6–12.8 are *inflated* by the small sample size, the short window, and the incomplete cost modeling, so they are valid only for relative comparison across thresholds.




Figure 5 Risk metrics by threshold

5. Conclusion

This study integrated a GBDT ensemble, confidence-threshold filtering, and a mobile interface for the EUR/USD market within an end-to-end pipeline from training to user, and tested it empirically. The three research questions were answered as follows:

- **RQ1:** 89.25% (test 2024, all classes) / 96.96% (val 2023, $\text{conf} \geq 0.90$)
- **RQ2:** 3,567 signals $\rightarrow$ 230 trades (6.45–23.81%)
- **RQ3:** +74–518% return, $E[R]=0.79\text{--}1.63R$

The top 3 thresholds by composite score (Table 2):

Table 2 Top 3 thresholds by composite score

Threshold	Return	MaxDD	Win	Profile
0.91	+517.70%	2.97%	47.17%	#1 Balanced
0.92	+465.12%	2.99%	47.26%	#2 Balanced
0.99	+74.29%	1.98%	65.71%	#3 Risk-averse

Beyond statistical accuracy, the results validate the quality of an integrated pipeline: data collection $\rightarrow$ feature engineering $\rightarrow$ ensemble training $\rightarrow$ signal filtering $\rightarrow$ automated trade $\rightarrow$ mobile notification. Scientifically, it presents empirical evidence combining a GBDT ensemble, multi-timeframe features, and confidence-threshold filtering; practically, it delivers a complete reference system from training to mobile distribution and demonstrates its ability to operate under real-time conditions.

Limitations. The results are validated only for EUR/USD and the 2025 window, so they cannot be directly generalized to other pairs; commission and swap are not fully modeled; the signal-to-execution conversion is below 100%.

Future work. Extend to GBP/USD and USD/JPY; compare with LSTM/Transformer; manage position sizing via reinforcement learning (RL); implement a Model Registry and Google Play distribution.

References

1. Krauss, C., Do, X.A., Huck, N. (2017). Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical Arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2): 689–702.
2. Ballings, M., Van den Poel, D., Hespeels, N., Gryp, R. (2015). Evaluating Multiple Classifiers for Stock Price Direction Prediction. *Expert Systems with Applications*, 42(20): 7046–7056.
3. Fischer, T., Krauss, C. (2018). Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions. *European Journal of Operational Research*, 270(2): 654–669.
4. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems (NeurIPS)*, 30: 3146–3154.
5. Yildirim, D.C., Toroslu, I.H., Fiore, U. (2021). Forecasting Directional Movement of Forex Data Using LSTM with Technical and Macroeconomic Indicators. *Financial Innovation*, 7(1).

外国為替取引シグナル生成システム

コンピュータサイエンス学科

学生：s21c033b, M. Munkhdorj

指導教員：N. Soronzonbold

1. 序論

外国為替（FX）市場は変動が大きくノイズの多い時系列を生成するため、従来の統計的手法に基づく予測は限定的である。GBDT やニューラルネットワークのモデルはパターンを検出できることが示されているが、単一モデルのアーキテクチャは過学習のリスクにより実用面で依然として制約を受ける。本研究は、EUR/USD 通貨ペアに対して BUY/HOLD/SELL の分類シグナルを生成し、モバイルアプリを通じてユーザーへ配信する GBDT アンサンブル機械学習システムを構築する。3 つの研究課題を設定した：

- **RQ1**：モデルは時系列順を保持したホールアウトテストで信頼性高く動作するか？
- **RQ2**：フィルタされたシグナルは実際の取引として約定するか？
- **RQ3**：固定リスクのルールの下で、1 年間に正のリターンが得られるか？

2. 背景と関連研究

金融時系列予測の研究は効率的市場仮説（EMH）の理論的懐疑のなかで発展してきたが、近年では機械学習が有意な程度にパターンを検出できることが裏付けられている。Krauss ら（2017）は GBDT が深層学習より信頼性の高い結果をもたらすと結論づけ、Ballings ら（2015）はアンサンブルが単一モデルより 3～7% 向上することを示した。Fischer・Krauss（2018）は LSTM を S&P 500 で、Yildirim ら（2021）は EUR/USD で検証したものの、マルチタイムフレームの特徴量エンジニアリングを GBDT アンサンブルと組み合わせた実証研究は依然として少ない。

貢献。 本研究は、GBDT アンサンブル、マルチタイムフレーム特徴量、信頼度しきい値によるシグナルフィルタリング、およびモバイルインターフェースを単一の統合システムとして FX 市場で実証的に検証した。

3. 研究手法

モデル学習からモバイルアプリまでを貫く ML サービングシステムを構築した（図1）。3 つの中核レイヤーから成る：(i) オフライン学習（GBDT pk1）；(ii) サーバー（Flask + MongoDB + Redis + Expo Push）+ 4 つの外部 API；(iii) モバイルアプリ（React Native、4 画面）。




図1 システムアーキテクチャ

データ。 EUR/USD の 2015～2024 年の履歴データから、6 つのタイムフレーム（M1～H4）× 8 つのテクニカル指標 = 48 特徴量の行列を構築した。ラベルは将来 240 分の値動きに対する 30 pips のしきい値で BUY/SELL/HOLD に分類した。

モデル。 LightGBM、XGBoost、CatBoost を等重みのソフト投票で統合したアンサンブル

ル (図2)。3つのモデルは成長戦略 (leaf-wise、level-wise、symmetric) の違いにより互いを補完し、過学習のリスクを低減する。学習は WFV の第5フォールド (train 2015~2022、val 2023、test 2024) で行った。過学習を防ぐため、木の深さ、低い学習率、早期終了、L1/L2 正則化、WFV、特徴量選択の6つの対策を組み合わせた。




図2 GBDT アンサンブルモデルのアーキテクチャ

シグナルフィルタ。信頼度 ($\text{conf} \geq 0.90$) と ATR (≥ 4 pips) でシグナルをフィルタし、2025 年の 359,639 件の予測から 3,567 件 (1.0%) が残り、MT5 の MaxPositions=1 ルールにより 230 取引が約定した (図3)。SL/TP は ATR から動的に算出し、TP/SL=3:1 の比率を保持する。




図3 シグナルフィルタリングのファネル (しきい値 0.90)

実験。MT5 ストラテジーテスター、2025.01~2026.01、初期資金 \$10,000、同時に 1 ポジション、実スプレッド + 10 point スリッページ、10 個の信頼度しきい値 (0.90~0.99)。

4. 研究結果

分類性能。未知の 2024 年テストでの全体正解率は **89.25%** (全クラス)、検証 (2023) サンプルでは $\text{conf} \geq 0.90$ フィルタ後に正解率が **96.96%** へ上昇した。検証-学習の差は +1.77% で、過学習はみられない (表1)。

表1 GBDT アンサンブルの正解率と F1 スコア

区分	期間	Acc (%)	F1-mac	F1-wgt
学習	2015~2022	82.71	67.74	80.94
検証	2023	84.48	62.67	82.29
テスト (out-of-sample)	2024	89.25	59.45	87.23

戦略リターン。10 個の信頼度しきい値 (0.90~0.99) すべてが正のリターンを示し、Buy & Hold (+13.47%) のベンチマークを 5.5~38 倍上回った。0.91 のしきい値で最高の **+517.70% (\$61,770)** に達し、0.90~0.92 の帯域は高いリターンと低いドローダウン (MaxDD < 3%) を両立するバランス点となった (図4)。




図4 しきい値ごとの最終残高

リスクと統計。勝率 44.78~65.71% (Wilson 95% CI)；二項検定 $z > 5$ 、 $p < 0.0001$ ； $E[R] = 0.79 \sim 1.63R$ ですべて正；MaxDD 1.98~9.53% (図5)。Sharpe の 8.6~12.8 という値は、サンプル数の少なさ、期間の短さ、コストの不完全なモデル化により **過大に算出されている**ため、しきい値間の相対比較にのみ有効である。




図5 しきい値ごとのリスク指標

5. 結論

本研究は、GBDT アンサンブル、信頼度しきい値フィルタリング、およびモバイルインターフェースを、学習からユーザーまでのエンドツーエンドのパイプラインとして EUR/USD 市場に統合し、実証的に検証した。3つの研究課題には次のように回答した：

- **RQ1**：89.25% (test 2024、全クラス) / 96.96% (val 2023、conf ≥ 0.90)
- **RQ2**：3,567 シグナル $\rightarrow$ 230 取引 (6.45 $\sim$ 23.81%)
- **RQ3**：+74 $\sim$ 518% のリターン、 $E[R]=0.79\sim 1.63R$

総合評価で上位の3つのしきい値(表2)：

表2 総合評価上位3つのしきい値

しきい値	リターン	MaxDD	勝率	プロファイル
0.91	+517.70%	2.97%	47.17%	#1 バランス型
0.92	+465.12%	2.99%	47.26%	#2 バランス型
0.99	+74.29%	1.98%	65.71%	#3 低リスク型

これらの結果は、統計的な正解率にとどまらず、データ収集 $\rightarrow$ 特徴量エンジニアリング $\rightarrow$ アンサンブル学習 $\rightarrow$ シグナルフィルタリング $\rightarrow$ 自動約定 $\rightarrow$ モバイル通知という統合パイプラインの品質を併せて裏付けるものである。学術的には、GBDT アンサンブル、マルチタイムフレーム特徴量、信頼度しきい値フィルタリングを統合した実証的証拠を示し、実務的には、学習からモバイル配信まで

の完全な参照システムを構築し、リアルタイム環境で動作する能力を示した。

制約。 結果は EUR/USD と 2025 年の期間でのみ検証されており、他の通貨ペアへ直接一般化することはできない；手数料 (commission) とスワップ (swap) は完全にはモデル化されていない；シグナルから約定への変換率は 100% 未満である。

今後の課題。 GBP/USD、USD/JPY への拡張；LSTM/Transformer との比較；強化学習 (RL) によるポジションサイズ管理；Model Registry と Google Play 配信の実装。

参考文献

1. Krauss, C., Do, X.A., Huck, N. (2017). Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical Arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2): 689–702.
2. Ballings, M., Van den Poel, D., Hespeels, N., Gryp, R. (2015). Evaluating Multiple Classifiers for Stock Price Direction Prediction. *Expert Systems with Applications*, 42(20): 7046–7056.
3. Fischer, T., Krauss, C. (2018). Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions. *European Journal of Operational Research*, 270(2): 654–669.
4. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems (NeurIPS)*, 30: 3146–3154.
5. Yildirim, D.C., Toroslu, I.H., Fiore, U. (2021). Forecasting Directional Movement of Forex Data Using LSTM with Technical and Macroeconomic Indicators. *Financial Innovation*, 7(1).