



ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутны код: s21c033b

Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

/ДЭД БАКАЛАВРЫН ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот

2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Дэд бакалаврын төгсөлтийн судалгааны ажил (061301)

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ
СИСТЕМ

Удирдагч багш

/Н.Соронзонболд, Магистр/

Гүйцэтгэсэн оюутан

/s21c033b, М.Мөнхдорж/

Улаанбаатар хот
2026 он

Хураангуй

Энэхүү судалгааны зорилго нь шуугиан ихтэй, тогтворгүй (non-stationary) санхүүгийн цаг хугацааны цуваанаас BUY / HOLD / SELL гурван ангиллын дохио гаргах машин сургалтын ансамбль систем боловсруулах явдал юм. Мөн загварын ангиллын гүйцэтгэлийг цаг хугацааны дарааллыг хадгалсан баталгаажуулалт болон бодит орчны симуляцаар цогцоор нь үнэлэв. Туршилтын домэйн нь EUR/USD гадаад валютын хослол (гадаад валютын зах зээл буюу Форекс) бөгөөд өндөр хэлбэлзэлтэй, шугаман бус хандлагатай энэ өгөгдөл нь цаг хугацааны цуваа ангилалтын сорилтот тохиолдол болдог.

LightGBM, XGBoost, CatBoost гурван GBDT загварыг зөөлөн санал хураалтаар нэгтгэсэн ансамблийг EUR/USD-ийн 2015–2024 оны өгөгдөл дээр сургасан. Урагш гүйлгэн баталгаажуулалтын Fold 5 огтлолын 2024 оны тестийн нарийвчлал 89.25%, итгэлцэл ≥ 0.90 дохионы нарийвчлал 96.96% гарсан нь загварын тогтвортой байдлыг харуулсан. MetaTrader 5-д 2025 оны бүтэн жилийн туршилтад бүх 10 итгэлцлийн сценари эерэг өгөөж үзүүлсэн; 0.91 босгон дээр +517.70% (\$61,770) хүрч, суурь жишгийн (EUR/USD-г эхнээс эцэс хүртэл барих стратеги) +13.47%-г мэдэгдэхүйц давсан. Спред болон гулсалт тусгагдсан боловч шимтгэл, своп зардал тусгагдаагүй тул өгөөжийн дүнг сценарийн харьцуулалтын хүрээнд тайлбарлах шаардлагатай.

Системийн инженерчлэлийн хувь нэмэр нь оффлайн загвар сургалт, REST API серверийн хэсэг (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Firebase FCM) гэсэн дөрвөн давхаргыг нэг нэгдмэл өгөгдөл боловсруулах урсгал (pipeline) болгон хэрэгжүүлсэнд оршино. Судалгааны үр дүн EUR/USD хослол болон тодорхой хугацааны цонхонд хязгаарлагдах тул бусад өгөгдлийн домэйнд шууд ерөнхийшүүлэхгүй; практик хэрэглээнд тогтмол дахин сургалт болон эрсдэлийн менежментийн протокол зайлшгүй шаардлагатай.

Түлхүүр үгс: машин сургалт, ансамбль загвар, GBDT, урагш гүйлгэн баталгаажуулалт, түүхэн өгөгдөл дээрх системийн туршилт, дохио-арилжааны хөрвүүлэлт, Wilson итгэлцлийн интервал, хүлээгдэж буй өгөөж (R), хамгийн их уналт (Max drawdown), сценарийн хэлбэлзэл (CV), серверийн хэсэг, харагдах хэсэг

Гарчиг	
Хураангуй	i
Гарчиг	ii
Товчилсон үгсийн жагсаалт	iii
Нэр томъёоны тайлбар толь	iv
Хүснэгтийн жагсаалт	vi
Зургийн жагсаалт	vii
Ажлын төлөвлөгөө	1
1 Удиртгал	2
1.1 Үндэслэл, ач холбогдол	2
1.2 Зорилго, зорилт	2
1.3 Судалгааны асуулт ба хэмжигдэх шалгуур	3
2 Судалгааны сэдвийн онол, өнөөгийн түвшин	4
2.1 Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд	4
2.2 Шинж чанаруудын судалгаа	6
2.3 Урагш гүйлгэн баталгаажуулалт ба санхүүгийн цаг хугацааны цуваа	6
2.4 ML serving урсгал (pipeline) ба мобайл аппын архитектур	7
2.5 Төсөөтэй системүүд ба харьцуулалт	7
2.6 Бусад судалгааны ажлуудтай үүсэх уялдаа ба энэхүү ажлын хувь нэмэр	8
3 Судалгааны арга зүй	10
3.1 Судалгааны арга барил	10
3.2 Системийн ерөнхий бүтэц	10
3.3 Өгөгдлийн урсгал	13
3.4 Өгөгдлийн бэлтгэл	15
3.5 AI загварын бүтэц ба сургалт	18
3.6 Дохио үүсгэх систем	22
3.7 MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт	26
3.8 Серверийн хэсгийн хэрэгжүүлэлт	30
3.9 Харагдах хэсгийн архитектур	33
3.10 Загварын давталтат сайжруулалт	36
4 Судалгааны үр дүн	38
4.1 Үр дүнгийн өгөгдлийн эх сурвалж	38
4.2 Загварын ангилалтын гүйцэтгэл	38
4.3 Босгын мужийн нэгтгэсэн үр дүн	39
4.4 Үр дүнгийн тайлбар	44
4.5 Архитектурын KPI-н баталгаажуулалтын үр дүн	46
4.6 Дахин хэрэгжүүлэх боломж ба орчны нөхцөл	48
4.7 Дүгнэлт	48
Ном зүй	50
Хавсралт	52
Товчлол	1

Товчилсон үгсийн жагсаалт

Нэр томъёоны тайлбар толь

Энэхүү тайлбар тольд ажлын туршид ижил утгаар хэрэглэсэн гол нэр томъёонуудыг нэг мөр болгож жагсаав. Монгол нэршлийг үндсэн хэлбэр болгон авч, шаардлагатай тохиолдолд эх нэршлийг хаалтанд хавсаргав.

Монгол нэршил	Original term
шинж чанар	feature
шинж чанарын инженерчлэл	feature engineering
шинж чанарын нөлөөлөл	feature importance
шошго	label
ансамбль загвар	ensemble model
зөөлөн санал хураалт	soft voting
гиперпараметр	hyperparameter
эрт зогсоох	early stopping
тогтмолжуулалт	regularization
хэт нийцэл	overfitting
урагш гүйлгэн баталгаажуулалт	walk-forward validation
ирээдүйн мэдээлэл ашиглах хэвийдэл	look-ahead bias
зорилтот хувьсагчийн нэвчилт	target leakage
түүхэн өгөгдөл дээрх системийн туршилт	backtesting
уналт	drawdown
ханшийн хэлбэлзэл	volatility
хугацааны интервал	timeframe
итгэлцэл	confidence
итгэлцлийн босго	confidence threshold
магадлалын тохируулга	probability calibration
системийн туршилт	system testing
серверийн хэсэг	backend
харагдах хэсэг	frontend
өгөгдөл боловсруулах урсгал	data pipeline
цогц систем	end-to-end system
түүвэр доторх	in-sample
түүврийн гадуурх	out-of-sample
байрлал	position
пипс	pip
спрэд	spread
гулсалт	slippage
эрсдэл-өгөөжийн харьцаа	risk-reward ratio
загварын шилжилт	model drift
push мэдэгдэл	push notification

ML Machine Learning – Машин сургалт

AI Artificial Intelligence – Хиймэл оюун ухаан

GBDT Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

XGBoost Extreme Gradient Boosting

LightGBM Light Gradient Boosting Machine

CatBoost Categorical Boosting

LSTM Long Short-Term Memory – Урт богино хугацааны санах ой

RSI Relative Strength Index – Харьцангуй хүчний индекс

ATR Average True Range – Дундаж жинхэнэ хүрээ

SMA Simple Moving Average – Энгийн хөдөлгөөнт дундаж

EMA Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

SL Stop Loss – Алдагдал зогсоох

TP Take Profit – Ашиг авах

API Application Programming Interface

REST Representational State Transfer

JWT JSON Web Token

OHLCV Open, High, Low, Close, Volume

MT5 MetaTrader 5

DD Drawdown – Уналт

RR Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

WSGI Web Server Gateway Interface

FCM Firebase Cloud Messaging – Firebase-н push мэдэгдэл хүргэх үйлчилгээ

APNs Apple Push Notification service – Apple-н push мэдэгдэл хүргэх үйлчилгээ

UI User Interface – Хэрэглэгчийн интерфэйс

UX User Experience – Хэрэглэгчийн туршлага

WFFV Walk-Forward Validation – Урагш гүйлгэн баталгаажуулалт

Хүснэгтийн жагсаалт

Хүснэгт 1.1.	Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)	3
Хүснэгт 3.1.	Түүхэн өгөгдлийн хэмжээний хураангуй	16
Хүснэгт 3.2.	Шинж чанарын жагсаалт (интервал бүрд)	16
Хүснэгт 3.3.	Урагш гүйлгэн баталгаажуулалтын хүрээнд ашигласан үндсэн огтлолын өгөгд- лийн хуваалт	18
Хүснэгт 3.4.	Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо	26
Хүснэгт 3.5.	Арилжааны зардлын хамралтын матриц	27
Хүснэгт 3.6.	Системийн үнэлгээний шалгуур үзүүлэлтүүд	29
Хүснэгт 3.7.	Серверийн хэсгийн програм хангамжийн архитектурын бүрэлдэхүүн	30
Хүснэгт 3.8.	Байршуулалтын (deployment) топологийн технологийн стек	31
Хүснэгт 3.9.	API endpoint-ийн хандалтын хурдны хязгаарлалт	32
Хүснэгт 3.10.	Архитектурын нэг цэгийн эмзэглэлийн шинжилгээ	32
Хүснэгт 3.11.	Харагдах хэсгийн модулиуд, харилцааны загвар ба API endpoint бүлэг	34
Хүснэгт 3.12.	Өгөгдөл дамжуулах загварын харьцуулалт	35
Хүснэгт 3.13.	Системийн гэрээ: автомат ба зөвлөмжийн үйлдэл	36
Хүснэгт 4.1.	GBDT ансамблийн нарийвчлал ба F1 оноо — хуваарь тус бүрээр	38
Хүснэгт 4.2.	Тестийн өгөгдөл дээрх ангилалт тусдаа (BUY / HOLD / SELL)	38
Хүснэгт 4.3.	Итгэлцлийн бүрийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)	39
Хүснэгт 4.4.	0.90–0.99 босгын мужийн харьцуулсан шинжилгээний баталгаажсан дүн	39
Хүснэгт 4.5.	EUR/USD худалдан аваад барих жишгийн хураангуй	40
Хүснэгт 4.6.	Босго тус бүрийн дохио-арилжааны гүйцэтгэл ба ялалтын хувь (95% CI)	41
Хүснэгт 4.7.	Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ	41
Хүснэгт 4.8.	Сценарийн дүгнэлтийг ерөнхийлөн дүгнэх боломжийн түвшин	45
Хүснэгт 4.9.	Арга зүйн эрсдэлийн нэгдсэн хүснэгт (энэ хувилбар)	46
Хүснэгт 4.10.	API давхаргын KPI: хэмжигдсэн дүн (n=30 хүсэлт/endpoint)	47
Хүснэгт 4.11.	API давхаргын 5xx алдааны хувь (n=90 нийт хүсэлт)	47
Хүснэгт 4.12.	API давхаргын KPI баталгаажуулалтын хураангуй	48
Хүснэгт 4.13.	Гурван суурь загварын сонгогдсон гиперпараметрууд	53
Хүснэгт 4.14.	Leakage audit-ын цагийн нийцлийн дүрмүүд	54
Хүснэгт 4.15.	Архитектурын баталгаажуулалтын KPI протокол	55
Хүснэгт 4.16.	Босго тус бүрийн нотолгооны индексжүүлсэн холболт (reproducibility reference) .	57

Зургийн жагсаалт

Зураг 3.1.	Давталтат хөгжүүлэлтийн үе шат: 7 давталтаар 75 шинж чанар, 9 загвараас 48 шинж чанар, 3 загварт шилжсэн нь	10
Зураг 3.2.	Системийн UML Deployment Diagram: хөгжүүлэгчийн компьютер, серверийн орчин, мобайл төхөөрөмж	11
Зураг 3.3.	Мобайл аппын UML Component Diagram: навигацийн бүтэц, дэлгэцийн давхарга, үйлчилгээний давхарга	12
Зураг 3.4.	Системийн UML Use Case Diagram: Трейдерийн ашиглах тохиолдлуудын хавтгай	13
Зураг 3.5.	Өгөгдлийн урсгалын UML Activity Diagram: swimlane-аар дата боловсруулалтын алхмууд	14
Зураг 3.6.	Урагш гүйлгэн баталгаажуулалт (WFV): энэ судалгааны үнэлгээнд ашигласан нэг огтлолын (Fold 5) өгөгдлийн хуваалт	18
Зураг 3.7.	GBDT ансамбль загварын архитектур	19
Зураг 3.8.	Гурван GBDT алгоритмын харьцуулалт: өсөлтийн стратеги, сургалтын хурд, хэт нийцлийн эрсдэл	20
Зураг 3.9.	Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио	22
Зураг 3.10.	Дохио үүсгэх UML Sequence Diagram — (A) өгөгдөл татаж таамаглах	24
Зураг 3.11.	Дохио үүсгэх UML Sequence Diagram — (B) дохио шүүж хэрэглэгчид хүргэх	25
Зураг 3.12.	Архитектурын зураглал — (A) REST polling урсгал: харагдах хэсгийн модуль бүр тохирох API endpoint-тай шууд холбогдоно	34
Зураг 3.13.	Архитектурын зураглал — (B) Push мэдэгдлийн урсгал: серверийн хэсэг FCM-ийг дамжуулан апп руу шуурхай мэдэгдэл хүргэнэ. Сумны чиглэл баруунаас зүүн тийш байна.	35
Зураг 3.14.	Загварын давталтат сайжруулалтын үе шатууд ба гол өөрчлөлтүүд	37
Зураг 4.1.	Босгын мужийн шинжилгээ: гүйцэтгэлийн хувийн өөрчлөлт	42
Зураг 4.2.	Босгын мужийн шинжилгээ: ялалтын хувь ба 95% итгэлцлийн интервал	43
Зураг 4.3.	Босгын мужийн шинжилгээ: хүлээгдэж буй өгөөжийн өөрчлөлт	43
Зураг 4.4.	Хамгийн өндөр өгөөжтэй 3 босгын equity curve — MT5 бодит хэлцлийн лог дээр суурилсан	44
Зураг B.1.	WFV олон огтлолтын ерөнхий концепцын схем (Fold 1–Fold 5 expand window protocol)	55

Ажлын төлөвлөгөө**Оюутны нэр:** М.Мөнхдорж**Удирдагч багшийн нэр:** Н.Соронзонболд**Судалгааны ажлын сэдэв:** Машин сургалтын аргаар Форекс зах зээлийн арилжааны дохионы систем хөгжүүлж үнэлэх

Сар	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 сар	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Форекс арилжаа, машин сургалт (machine learning) онолын судалгаа хийх	✓
	3	Yahoo Finance ба MetaTrader 5-аас EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 сар	1	70+ техник индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модел сургах	✓
	3	Stacking Ensemble модел хөгжүүлэх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх	✓
	4	Серверийн хэсэг болон мобайл апп хөгжүүлэх	✓
12 сар	1	ТСА Үзлэг 1	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 сар	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 сар	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	✓
	4	Хамгаалалтын бэлтгэл хийх	✓
3 сар	1	ТСА Үзлэг 2	☐
	2	Засвар хийх, санал хүсэлтийг тусгах	☐
	3	Код тайлбар, баримтжуулалт	☐
	4	Хамгаалалтын дадлага хийх	☐
4 сар	1	Эцсийн засвар хийх	☐
	2	Слайд сайжруулах	☐
	3	Хамгаалалтын бэлтгэл	☐
	4	ТСА урьдчилсан хамгаалалт	☐
5 сар	1	ТСА урьдчилсан хамгаалалт	☐
	2	ТСА урьдчилсан хамгаалалт	☐
	3	Эцсийн засвар, сайжруулалт	☐
	4	ТСА үндсэн хамгаалалт	☐

Удирдагч багш

Гүйцэтгэсэн оюутан

/Н.Соронзонболд, магистр/

/s21c033b, М.Мөнхдорж/

1. Удиртгал

1.1. Үндэслэл, ач холбогдол

Өгөгдлийн шинжлэх ухаан болон мэдээллийн технологийн салбарт олон хэмжээст, шуугиан ихтэй цаг хугацааны цувааны өгөгдөлд дүн шинжилгээ хийх нь томоохон сорилт хэвээр байна. Түүний тод жишээ нь гадаад валютын зах зээл буюу Форекс юм. Энэ зах зээл нь олон улсын эдийн засгийн төлөв байдал, төв банкуудын бодлого зэрэг макро түвшний хүчин зүйлсээс хамааран тасралтгүй, өндөр хэлбэлзэлтэйгээр өөрчлөгддөг [1]. Ийм өндөр хэлбэлзэлтэй, шугаман бус хандлагатай зах зээлийн өгөгдлөөс зүй тогтлыг илрүүлэх нь уламжлалт статистикийн шинжилгээний хувьд хэцүү даалгавар хэвээр байна.

Уламжлалт аргууд нь ихэвчлэн хүний шууд оролцоо, субъектив дүгнэлтэд тулгуурладаг тул их хэмжээний өгөгдлийг богино хугацаанд автоматаар боловсруулж таамаглахад тохиромжгүй бөгөөд нарийвчлалын алдагдал гарах эрсдэл өндөр байдаг.

Сүүлийн жилүүдэд машин сургалт болон хиймэл оюун ухааны алгоритмууд санхүүгийн салбарт эрчимтэй нэвтэрсэн. Тухайлбал, GBDT болон нейрон сүлжээ зэрэг орчин үеийн алгоритмууд их хэмжээний өгөгдлөөс нарийн зүй тогтлыг илрүүлэх чадамжтай болохыг олон судалгаа нотолсон [2, 3]. Гэсэн хэдий ч загвар сургалтын өгөгдөлдөө хэт нийцэх, нэг алгоритмд түшиглэсэн архитектураас үүдэн системийн доголдол гарах зэрэг инженерчлэлийн асуудал практик орчинд тулгарсаар байна.

Энэ чиглэлийн судалгаанд загварын нарийвчлалыг сайжруулах нь дангаараа хангалтгүй. Серверийн хэсгийн бодит цагийн өгөгдөл боловсруулах урсгал, гүйцэтгэлийн тогтвортой байдал, харагдах хэсэгт үр дүнг хүргэх уялдааг хамтад нь авч үзэх шаардлагатай. Энэхүү судалгаа нь загварын нарийвчлал, серверийн хэсгийн архитектур, мобайл интерфэйс гэсэн гурван давхаргыг нэг туршилтын хүрээнд нэгтгэж, тэдгээрийн хамтарсан гүйцэтгэлийг үнэлснээрээ ялгарна.

Энэхүү судалгааны ажилд зөөлөн санал хураалтад (soft voting) суурилсан GBDT ансамбль загвар, цаг хугацааны дарааллыг хадгалсан урагш гүйлгэн баталгаажуулалт (Walk-Forward Validation), олон хугацааны интервалын шинж чанарын инженерчлэл (multi-timeframe feature engineering) гэсэн гурвыг нэгтгэн найдвартай ML ангиллын системийг хөгжүүлсэн. Загварын гаралтыг REST API болон мобайл аппаар дамжуулан хэрэглэгчдэд хүргэх нэгдмэл өгөгдөл боловсруулах урсгалыг (pipeline) хэрэгжүүлснээр загвар–серверийн хэсэг–харагдах хэсгийн уялдааг прототипийн түвшинд баталгаажуулсан.

1.2. Зорилго, зорилт

Судалгааны зорилго

Энэхүү судалгааны ажлын үндсэн зорилго нь **шуугиан ихтэй санхүүгийн цаг хугацааны цуваанд (EUR/USD өгөгдөл дээр) GBDT ансамбль загвар ашиглан гурван ангилалтын (BUY / HOLD / SELL) систем боловсруулж, ангиллын чанарыг итгэлцлийн шүүлтүүрээр сайжруулах, мөн үүссэн дохионы гүйцэтгэлийг түүхэн өгөгдөл дээрх системийн туршилтаар үнэлэх** явдал юм.

Судалгааны зорилтууд

Энэхүү зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлэв:

1. Олон хугацааны интервалын (M1–H4, 6 интервал) санхүүгийн цаг хугацааны цуваанаас шинж чанарын матриц (48 feature) бүрдүүлж, гурван ангилалтын (BUY / HOLD / SELL) сургалтын шошго үүсгэх; мэдээллийн нэвчилтийн (label leakage) эрсдэлийг аудитаар хянах.

2. Цаг хугацааны дарааллыг алдагдуулахгүй урагш гүйлгэн баталгаажуулалт (Walk-Forward Validation) дээр суурилсан GBDT ансамбль (LightGBM + XGBoost + CatBoost, зөөлөн санал хураалт)-ийн туршилтын орчныг хөгжүүлж, хэт нийцлийн эрсдэлийг хянах.
3. Ангиллын нарийвчлал, итгэлцлийн шүүлтийн нөлөө, дохио-гүйцэтгэлийн хөрвүүлэлт (signal-to-execution conversion rate), болон эрсдэл-өгөөжийн үзүүлэлтүүдийг нэгдсэн үнэлгээний хүрээнд хэмжих.
4. Бодит цагийн ML таамаглал гаргах серверийн REST API (Flask + MongoDB), мобайл харагдах хэсэг (React Native), push мэдэгдэл (Firebase FCM)-ийг нэгтгэн, загвар сургалтаас хэрэглэгч хүртэлх нэгдмэл ML serving урсгал (pipeline) бүтээх.

1.3. Судалгааны асуулт ба хэмжигдэх шалгуур

Судалгааны ажлын зорилтуудыг хэмжихүйц шалгууруудтай холбохын тулд дараах судалгааны асуултуудыг тодорхойлов.

Хүснэгт 1.1 Судалгааны асуулт ба үнэлгээний шалгуур үзүүлэлтүүд (KPIs)

RQ	Судалгааны асуулт	Хэмжих шалгуур үзүүлэлт
RQ1	Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр тогтвортой, найдвартай ажиллах уу?	Ерөнхий ангиллын чанар (accuracy/F1), мөн өндөр итгэлцэлтэй дохионы дэд багц дахь чанар
RQ2	Шүүгдсэн дохио бодит гүйцэтгэл дээр үнэхээр арилжаа болж хэрэгжих үү?	Дохионы гүйцэтгэлийн хувь (execution rate), амжилттай арилжааны хувь (win rate), win rate-ийн Wilson 95% итгэлцлийн интервал
RQ3	Тогтмол эрсдэлийн дүрэмтэй үед систем урт хугацаанд ашигтай, тогтвортой байх уу?	Эцсийн үлдэгдэл ба нийт өгөөж, нэг арилжааны хүлээгдэж буй өгөөж (Expectancy, R), сценарийн хэлбэлзэл (балансын CV)

2. Судалгааны сэдвийн онол, өнөөгийн түвшин

2.1. Санхүүгийн зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

Уламжлалт машин сургалтын аргууд

Санхүүгийн зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн өмнөх судалгаанууд нь голчлон нейрон сүлжээ (neural networks) болон тулгуур векторын машин (SVM)-д төвлөрч байсан. Kamruzzaman, Sarker нар (2003) нь нейрон сүлжээг ашиглан валютын ханш таамаглахад 81%-ийн нарийвчлалд хүрсэн (сургалтын түүвэр дотрох дүн; санхүүгийн таамаглалын нийтлэг дундаж нарийвчлал 50–60% байдаг тул түүврийн гадуурх дүнтэй шууд харьцуулах боломжгүй) [4]. Эдгээр судалгаанууд чухал ач холбогдолтой хэдий ч дараах чиглэлүүдэд гүнзгийрүүлэн судлах орон зай үлдсэн:

- Зөвхөн нэг валютын хослолд хязгаарлагдаж байсан
- Хэт нийцлийн асуудлыг илүү системтэй авч үзэх орон зай үлдсэн
- Түүхэн өгөгдөл дээрх системийн туршилт (backtesting)-ын бодит орчны үнэлгээ дутагдалтай байсан

Kumar, Thenmozhi нар (2006) нь SVM болон Random Forest-ийг хөрөнгийн индексийн чиглэлийн таамаглалд харьцуулсан бөгөөд зах зээлийн нөхцөл өөрчлөгдөхөд загварын тогтвортой байдал буурах эрсдэлийг онцолсон [5].

Санамсаргүй ой (random forest) болон градиент нэмэгдүүлэлт (gradient boosting) аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings тэргүүтэй судлаачид (2015) нь хувьцааны ханшийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц гарсан** болохыг тогтоосон [6]. Гэхдээ Форекс зах зээлд ансамбль аргыг хэрэглэсэн эмпирик харьцуулалтын судалгаа цөөхөн хэвээр байна.

Гүн сургалтын аргууд

Сүүлийн жилүүдэд урт-богино хугацааны санах ой (long short-term memory, LSTM) болон гүн нейрон сүлжээ (deep neural network, DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer, Krauss нар (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang тэргүүтэй судлаачид (2019) нь санхүүгийн цаг хугацааны цуваанд гүн сургалтын хэрэглээг системтэй тоймлон нэгтгэсэн [8].

Гэхдээ эдгээр ажлууд ихэвчлэн ерөнхий урьдчилан таамаглалын чанарын харьцуулалтад төвлөрдөг. Форексын дохио шүүлтүүр, гүйцэтгэлийн хөрвүүлэлт, бодит орчны нөхцөлийг хамтад нь хамарсан судалгаа ховор хэвээр байна. Krauss болон бусад (2017) [9] гүн сургалтын дараах сул талуудыг дурдсан:

- **Тайлбарлах боломжгүй байдал:** Санхүүгийн шийдвэр гаргалтанд шаардлагатай тайлбарлах чадвар дутмаг
- **Маш олон параметр, удаан сургалт:** 100,000+ параметртэй, өгөгдөл их шаарддаг
- **Хэт нийцэлд эмзэг:** Түүхэн өгөгдөлд хэт тохирч, шинэ зах зээлийн нөхцөлд муу ажилладаг
- **Тогтворгүй:** Анхны параметрээс их хамаардаг

Krauss болон түүний багийнхан (2017) нь гүн нейрон сүлжээ болон градиент нэмэгдүүлсэн шийдвэрийн мод (gradient-boosted trees) загваруудыг S&P 500 дээр харьцуулж, **GBDT загварууд илүү тогтвортой үр дүн үзүүлсэн** гэж дүгнэсэн [9]. Энэ нь судалгаанд GBDT ансамбль загваруудыг ашиглах үндэслэл болж байна.

Градиент нэмэгдүүлсэн шийдвэрийн мод санхүүгийн салбарт

GBDT нь Friedman (2001)-ийн боловсруулсан аргачлал бөгөөд олон шийдвэрийн мод (decision tree)-ийг дараалан нэмж, алхам бүрд өмнөх загварын үлдэгдэл алдааг (gradient) бууруулж сургадаг [10]. Gu, Kelly, болон Xiu (2020) нь 150+ оролтын хувьсагчтай GBDT загварыг хувьцааны өгөөж таамаглахад хэрэглэж, **гүн сургалтын загваруудтай харьцуулахад илүү нарийвчлалтай** байсныг тогтоосон [11]. Тэд мөн GBDT загваруудын дараах давуу талуудыг дурдсан:

- Хүснэгтэн (tabular) өгөгдөлд тохирсон шинж чанаруудын харилцан үйлчлэл (feature interaction)-ийг олж илрүүлдэг
- Цөөн параметртэй – хурдан сургаж болно
- Шинж чанарын чухал байдал (feature importance)-ыг хялбар тооцоолох – тайлбарлах боломжтой
- Гажиг утга (outlier)-д мэдрэмтгий бус

XGBoost [2], LightGBM [3], CatBoost [12] нь GBDT-ийн орчин үеийн хувилбар бөгөөд өөр өөр онцлогтой. XGBoost нь L1/L2 тогтмолжуулалт (regularization) давуу талтай, LightGBM нь хурдтай боловч хэт нийцэлд илүү эмзэг, CatBoost нь эрэмбэлэгдсэн нэмэгдүүлэлт (ordered boosting) ашиглан зорилтот хувьсагчийн нэвчилт (target leakage)-ийн эрсдэлийг бууруулдаг. Гэсэн хэдий ч **XGBoost, LightGBM, CatBoost гурвыг нэг орчинд нэгтгэж, WFV болон leakage хяналттай Форекс зах зээлд туршсан эмпирик судалгаа** маш хязгаарлагдмал хэвээр байна.

Ансамбль аргуудын хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [13]. Breiman (2001) санамсаргүй ой аргаар олон модыг параллель сургаж, дундажлах (average) замаар хэлбэлзэл (variance)-ийг бууруулсан [14]. Sezer тэргүүтэй судлаачид (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол өндөр гүйцэтгэлтэй байдгийг** дурдсан [15].

Өмнөх судалгаануудын хүрэн дэх нээлттэй асуудлууд

Дээр дурдсан ажлуудаас энэ судалгааны хувьд хамааралтай гурван нээлттэй асуудлыг тодорхойлов:

- **Форекс зах зээлийн онцлог тусгагдаагүй:** Судалгааны ихэнх нь хувьцааны зах зээлд төвлөрсөн тул 24/5 үргэлжлэх Форекс зах зээлийн өгөгдлийн онцлог, олон хугацааны интервалын (multitimeframe) нэгдсэн нөлөөг үнэлсэн ажил хомс.
- **GBDT ансамблийн харьцуулалт дутуу:** XGBoost, LightGBM, CatBoost-ийг нэг орчинд ансамбль хэлбэрээр харьцуулан, WFV болон leakage хяналттай нэгтгэсэн эмпирик нотолгоо хязгаарлагдмал.

- **Практик хэрэгжүүлэлт хамрагдаагүй:** Загварын нарийвчлалаас эхлэн мобайл аппликейшн хүртэлх бүрэн цогц системийн үнэлгээг нэг судалгааны хүрээнд хийсэн ажил ховор.

2.2. Шинж чанаруудын судалгаа

Шинж чанаруудын үр дүнтэй байдлын харьцуулалт

Уламжлалт санхүүгийн онол буюу Fama (1970)-ийн гаргасан "Үр ашигт зах зээлийн таамаглал" (efficient market hypothesis – EMH)-аар техникийн дүн шинжилгээ нь ямар ч ашиггүй хэмээн үздэг байв [16]. Murphy (1999) техник шинжилгээний арга зүйг нэгтгэн тайлбарласан боловч танилцуулсан аргуудын статистикийн баталгаажуулалт хангалттай гүнзгийрээгүй [17]. Харин Lo болон бусад судлаачид (2000) илүү нарийвчилсан статистик тестүүд хийж үзээд, **техник аргууд нь зах зээл дээр статистикийн хувьд ач холбогдолтой үр дүн өгч чаддаг** болохыг нотолсон байдаг [18]. Энэхүү нээлт нь зах зээл хэзээд, бүрэн үр ашигтай байдаг гэсэн EMH-ийн онолыг тодорхой хэмжээнд няцаасан юм.

Olson (2004) нь RSI, MACD, Stochastic зэрэг түгээмэл шинж чанаруудыг Форекс зах зээлд судалж, **ганц шинж чанар дангаараа тогтвортой ашиг өгөх боломжгүй** гэж дүгнэсэн [19]. Хугацааны интервал өөрчлөгдөхөд индикаторын үр дүн дагаад өөрчлөгддөг тул **олон шинж чанарыг хослуулах, мөн олон хугацааны хүрээг зэрэг ашиглах** шаардлага гардаг. Энэ дүгнэлт нь энэ судалгааны олон хугацааны интервалын шинж чанарын инженерчлэлийн үндэслэл болсон (дэлгэрэнгүйг §3.4.2-т үзнэ үү).

Brock тэргүүтэй судлаачид (1992) нь хөдөлгөөний дунджийн огтлолцолд суурилсан стратегиудыг судалж, тодорхой нөхцөлд ашигтай байж болохыг харуулсан боловч **арилжааны зардлыг тооцох үед ашиг ихээхэн багасах** эрсдэлийг онцолсон [20]. Marshall нар (2008) futures зах зээлд стратегийн үр дүн нь дүрэм болон зардлын таамаглалаас хүчтэй хамаарахыг нотолсон [21]. Эдгээр дүн нь бодит орчны туршилтад спред, гулсалт зэрэг зардлуудыг тусгах шаардлагатайг харуулна.

Шинж чанарын хослуулалт ба шинж чанарын инженерчлэл

Park, Irwin нар (2007) нь 95 судалгааг тоймлон, техник аргууд 1995 он хүртэл үр дүнтэй байсан боловч сүүлийн жилүүдэд үр дүн буурч байгааг тогтоосон. Үүнийг **зах зээлийн дасан зохицох чадвар**-ын илрэл гэж тайлбарласан [22]. Энэ нь шинж чанарыг дангаар нь ашиглахаас илүү машин сургалтын загварт хослуулан хэрэглэх нь үр дүнтэй байж болохыг илтгэнэ.

Шинж чанарууд GBDT загварт оролтын хувьсагч болж ашиглагдахад үр дүнтэй боловч өмнөх судалгааны ихэнх нь зөвхөн нэг хугацааны интервалын өгөгдөл ашигласан. Энэ нь чухал мэдээллийг алдах эрсдэлтэй: 1 минутын графикт богино хугацааны эргэлт харагддаг бол 4 цагийн графикт урт хугацааны чиг хандлага тод ажиглагдана. Эдгээрийг хамтад нь ашигласнаар загвар зах зээлийн олон давтамжийн мэдээллийг нэгэн зэрэг боловсруулах боломжтой болно. Энэхүү судалгаанд M1, M5, M15, M30, H1, H4 гэсэн 6 интервалаас нийт 48 индикатор тооцоолсон нь өмнөх судалгаанаас ялгарах онцлог (дэлгэрэнгүйг §3.4.2-т үзнэ үү).

2.3. Урагш гүйлгэн баталгаажуулалт ба санхүүгийн цаг хугацааны цуваа

Уламжлалт k-нугалааст солбицсон баталгаажуулалт (k-fold cross-validation) нь санхүүгийн цуваа өгөгдөлд тохиромжгүй, учир нь цаг хугацааны дарааллыг зөрчиж, ирээдүйн мэдээлэл ашиглах

хэвийдэл (look-ahead bias) үүсгэдэг. Pardo (2008) нь урагш гүйлгэн баталгаажуулалт аргачлалыг танилцуулж, энэхүү аргачлал нь цаг хугацааны дарааллыг хадгалж, загварыг ирээдүйн өгөгдөл дээр шалгахад илүү бодит болохыг харуулсан [23].

Аргачлалын гол давуу тал нь: ирээдүйн өгөгдлийг сургалтаас тусгаарлах; зах зээлийн горим өөрчлөгдөхийг гүйцэтгэлийн хэлбэлзлээр илрүүлэх; бодит арилжааны шийдвэр гаргалттай ижил нөхцөлийг дуурайх. Аргазүйн бүлгийн огтлолын хуваалтыг Зураг 3.6-т дүрслэн харуулсан.

Bailey болон түүний багийнхан (2014) санхүүгийн загваруудын хэт нийцлийн эрсдэлийг задлан, **олон параметрийн тохируулга хийх нь түүвэр доторх үр дүнг сайжруулна гэхдээ түүврийн гадуурх (out-of-sample) дүнг муутгана** гэж анхааруулсан [24]. WFTV ашиглах энэ шалтгааны дагуу судалгаанд 2015–2022 (сургалт), 2023 (баталгаажуулалт), 2024 (тест), 2025 (түүхэн өгөгдөл дээрх системийн туршилт) гэж тусгаарлаж хэт нийцлээс сэргийлсэн.

2.4. ML serving урсгал (pipeline) ба мобайл аппын архитектур

Мобайл арилжааны технологи

React Native [25] нь JavaScript дээр суурилсан гар утасны хөгжүүлэлтийн орчин бөгөөд нэг кодын сууриар Android аппликейшн хурдан хөгжүүлэхэд тохиромжтой. Eisenman (2018) нь React Native-ийн давуу тал нь хурдан хөгжүүлэлт, код дахин ашиглалт болохыг дурдсан боловч гүйцэтгэл нь цэвэр native аппликейшнаас бага зэрэг буурч болохыг тэмдэглэсэн [26].

Серверийн хэсгийн ерөнхий архитектурын хандлага

Серверийн хэсгийн архитектурын зорилго нь бодит цагийн өгөгдлийг тогтвортой боловсруулах, машин сургалтын загварын үр дүнг API дамжуулалт хэлбэрээр хүргэх, мөн мобайл аппликейшн-тэй найдвартай холболт үүсгэх явдал юм. Судалгааны ажлуудад хөнгөн, уян хатан вэб фреймворк (framework) ашиглах нь хурдан туршилт болон тасралтгүй шинэчлэл хийх давуу талтай гэж үздэг [27].

Системийн найдвартай байдал ба аюулгүй байдлын судалгааны цоорхой

ML системийн олон судалгаа загварын нарийвчлал (accuracy), өгөөж (return) зэрэг offline метрикүүдэд төвлөрдөг боловч бодит хэрэглээний орчинд системийн найдвартай ажиллагаа, серверийн тасралтгүй бэлэн байдал (availability), API latency, мэдээлэл хүргэлтийн чанарыг хангалттай авч үздэггүй. Загварын математик гүйцэтгэл сайн байсан ч үйл ажиллагааны хүчин зүйлс сул байвал системийн нийт үр нөлөө буурдаг. Энэхүү судалгаанд машин сургалтын үнэлгээг системийн найдвартай ажиллагааны үнэлгээтэй уялдуулсан нэгдмэл хандлагыг хэрэглэсэн.

2.5. Төсөөтэй системүүд ба харьцуулалт

Энэ судалгааны “Predictrix” системтэй төстэй, зах зээлд байгаа зарим мобайл аппликейшн болон нээлттэй эхийн системүүдийг харьцуулан судлав.

Зах зээлд байгаа төсөөтэй аппликейшнууд

1. AlgoTrade 3

Kin Fung Wong-ийн хөгжүүлсэн “AlgoTrade 3” нь алгоритмын арилжааны стратегиудыг симуляци

хийх, түүхэн өгөгдөл дээрх системийн туршилт хийх зориулалттай мобайл аппликейшн юм. Энэ нь өдөр тутмын (daily) хувьцааны өгөгдөл дээр үндэслэн стратегиудыг турших боломжийг олгодог.

- *Ялгаа:* Энэхүү апп нь бодит цагийн Форекс дохио өгдөггүй, зөвхөн түүхэн өгөгдөл дээрх симуляцид төвлөрсөн. Мөн зөвхөн өдрийн хугацааны интервал (Daily timeframe) ашигладаг тул өдрийн (intraday) бодит арилжаанд тохиромжгүй. Харин “Predictrix” нь M1–H4 хүртэлх олон хугацааны интервал ашиглан бодит цагийн дохио үүсгэдэг.

2. Tradlgo: Algo Trade & Screener (Android)

ZSCALE TECH-ийн хөгжүүлсэн “Tradlgo” нь хиймэл оюун ухаан ашиглан хэрэглэгчийн бичсэн энгийн текстээс (natural language) алгоритмын арилжааны стратеги үүсгэх, код бичихгүйгээр (no-code) автоматжуулах боломжийг олгодог платформ юм.

- *Ялгаа:* Tradlgo нь хэрэглэгчийг өөрөө стратегиа бүтээхэд туслах хэрэгсэл (tool) юм. Харин “Predictrix” нь урьдчилан сургагдсан GBDT ансамблийн гаралтад суурилсан дохиог аппликейшнаар хүргэх судалгааны прототип байдлаар хэрэгжсэн.

Харьцуулсан судалгаа ба open source системүүд

1. GBDT загваруудын хэрэглээний суурь:

XGBoost, LightGBM, CatBoost загваруудын алгоритмын онцлог, давуу талуудыг эх бүтээлүүдэд дэлгэрэнгүй тайлбарласан [2, 3, 12]. Гэсэн хэдий ч эдгээр загваруудыг Форекс өгөгдөл дээр нэгтгэсэн ансамбль хэлбэрээр системийн түвшинд туршсан эмпирик нотолгоо хязгаарлагдмал хэвээр байна.

2. Open source арилжааны системүүд (QuantConnect, Freqtrade):

QuantConnect (lean engine) болон Freqtrade зэрэг open source төслүүд нь алгоритмын арилжааны дэд бүтцийн жишээ болдог. Ялангуяа Freqtrade нь “FreqAI” модулиар дамжуулан машин сургалтын загваруудыг ашиглах боломжийг олгодог. Гэвч эдгээр системүүд нь: (1) ихэвчлэн автомат арилжаанд (bot) зориулагдсан, (2) жирийн хэрэглэгчдэд ээлтэй мобайл интерфэйсгүй байдаг. “Predictrix” нь шийдвэр гаргалтыг дэмжих (decision support system) зорилготой мобайл аппликейшний судалгааны прототип хэлбэрээр хэрэгжсэн.

2.6. Бусад судалгааны ажлуудтай үүсэх уялдаа ба энэхүү ажлын хувь нэмэр

Дээрх гурван нээлттэй асуудлыг шийдвэрлэх зорилгоор энэхүү судалгааны ажил дараах шинэлэг хувь нэмрийг оруулна.

Судалгааны шинэлэг хувь нэмэр:

- **XGBoost, LightGBM, CatBoost гурван загварын ансамбль:** Өмнөх судалгаануудад голчлон тус тусад нь ашиглагдаж байсан алгоритмуудын давуу талыг нэгтгэн туршсан.
- **48 шинж чанар, 6 хугацааны интервал:** Зөвхөн нэг хугацааны интервалд хязгаарлагдахын оронд M1–H4 олон давтамжийн дүн шинжилгээг хэрэгжүүлсэн.
- **Урагш гүйлгэн баталгаажуулалт + бодит MT5 түүхэн өгөгдөл дээрх системийн туршилт:** Хэт нийцлээс сэргийлэх шилдэг туршлагаудыг ашиглаж, бодит мэдээлэл дээр шалгасан.

- **React Native аппликейшн интеграц:** Загвар сургалтаас гар утасны апп хүртэлх нэгдмэл системийг прототипийн түвшинд хэрэгжүүлсэн нь уламжлалт академик хүрээнээс давсан практик ач холбогдолтой.


3. Судалгааны арга зүй

3.1. Судалгааны арга барил

Энэхүү судалгаа нь **Зохиомжлох шинжлэх ухааны** (design science research – DSR) [28] арга зүйд суурилсан. DSR нь бодит асуудлыг шийдвэрлэхэд чиглэсэн цоо шинэ артефакт (систем, загвар, бүтээгдэхүүн) бүтээж, түүний ашиг тусыг туршилтаар баталгаажуулдаг [29]. Энэ судалгааны хувьд DSR-ийн дараах гурван үндсэн зарчмыг баримтлав:

1. **Артефакт бүтээх:** Санхүүгийн зах зээлийн таамаглалын үр дүн үүсгэж, мобайл аппликейшнаар дамжуулан хэрэглэгчид хүргэх систем хөгжүүлэх
2. **Асуудалд чиглэсэн:** Жижиг арилжаачдын мэдээлэл дутмаг, мэргэжлийн дүн шинжилгээний хүртээмж бага байдлыг шийдвэрлэх
3. **Туршилтаар баталгаажуулах:** MetaTrader 5 Strategy Tester-ийн бодит нөхцөлд (спрэд, гулсалт) түүхэн өгөгдөл дээрх системийн туршилт хийж, системийн ашигт ажиллагааг шинжлэх ухааны аргаар үнэлэх

Судалгааны процесс нь **давталтат хөгжүүлэлт** (iterative development) загвараар явагдсан; үе шат бүрд гүйцэтгэлийг хэмжиж, сул талыг тодорхойлон, дараагийн хувилбарт засварлах мөчлөгийг 7 удаа давтсан. Давталтын үндсэн үе шатуудыг Зураг 3.1-т харуулав.




Зураг 3.1 Давталтат хөгжүүлэлтийн үе шат: 7 давталтаар 75 шинж чанар, 9 загвараас 48 шинж чанар, 3 загварт шилжсэн нь

3.2. Системийн ерөнхий бүтэц

Системийн үндсэн ойлголт нь санхүүгийн өгөгдөл → AI таамаглал → мобайл апп → трейдер гэсэн урсгалд төвлөрдөг; илүү нарийвчилсан архитектурын зураглалыг Зураг 3.2 болон дараах нэгдмэл өгөгдөл боловсруулах урсгалын (pipeline) зурагт нэгтгэн харуулна.

Хөгжүүлсэн системд хэрэглэгчид хүрэх үндсэн харагдах хэсэг нь мобайл апп бөгөөд серверийн хэсэг ба мобайл апп хоёр тусдаа давхаргад зохион байгуулагдан REST API-аар харилцдаг. Машин сургалтын сургалтын үе шат нь оффлайн орчинд хийгдэж, бэлтгэсэн загварыг серверийн хэсэгт ачаалан таамаглал гүйцэтгэнэ. Зураг 3.2 нь энэ хамаарлыг харуулав.




Зураг 3.2 Системийн UML Deployment Diagram: хөгжүүлэгчийн компьютер, серверийн орчин, мобайл төхөөрөмж

Системийн ажиллах зарчим дараах байдалтай:

- Оффлайн сургалт:** MetaTrader 5-ын түүхэн өгөгдлөөр 3 GBDT загварыг сургаж, зөөлөн санал хураалтаар нэгтгэн итгэлцэл тооцно. Энд гурван загварын магадлалыг дунджилж эцсийн шийдвэр гаргана. Магадлалын тохируулгыг баталгаажуулалтын огтлол дээр шалгасны дараа загварыг серверийн хэсэгт байршуулна.
- Серверийн хэсэг:** Бодит цагийн мэдээллийг боловсруулж, ачаалсан загвараар дохио үүсгэн хадгалж, API-гаар түгээнэ.
- Харагдах хэсэг:** Серверийн API-тай холбогдож ханш, дохио, мэдээг хэрэглэгчид үзүүлнэ.

Мобайл аппын архитектур


React Native-д суурилсан мобайл аппын дотоод архитектурыг Зураг 3.3 нь харуулав. Апп нь гурван давхаргаас бүрдэнэ: навигацийн давхарга (Root Stack Navigator болон Main Bottom Tab Navigator), дэлгэцийн давхарга (Auth болон үндсэн дэлгэцүүд), үйлчилгээний давхарга (API дуудалт, токен хадгалалт, push мэдэгдэл). Үйлчилгээний давхарга нь сүлжээний логикийг дэлгэцийн логигоос тусгаарлан хангана.



Зураг 3.3 Мобайл аппын UML Component Diagram: навигацийн бүтэц, дэлгэцийн давхарга, үйлчилгээний давхарга

Системийн хэрэглэх тохиолдлуудын диаграмм


Системийн хэрэглэгчид болон ML-ийн гадаад оролцогчдын хоорондын харилцааг Зураг 3.4 UML Use Case Diagram хэлбэрт харуулав. Трейдер нэвтрэх, дохио харах, мэдэгдэл хүлээн авах, ханш болон мэдээг харах, мөн профайлаа удирдах тохиолдлуудтай харьцана. ML Систем дохиог автоматаар үүсгэх тохиолдлыг гүйцэтгэнэ. “Дохионы жагсаалт харах” нь “Push мэдэгдэл хүлээн авах”-ыг «include»-ийн харилцаагаар агуулдаг: дохионы жагсаалтыг системийн push урсгалтай уялдуулан ажиллуулдаг тул хоёр тохиолдол хамтдаа хэрэгждэг.



Зураг 3.4 Системийн UML Use Case Diagram: Трейдерийн ашиглах тохиолдлуудын хавтгай

3.3. Өгөгдлийн урсгал

Системд өгөгдөл хэрхэн урсаж, боловсруулагддагийг нэгтгэсэн нэгдмэл өгөгдөл боловсруулах урсгалаар (pipeline) харуулав. Гадаад эх сурвалжаас (MetaTrader 5, Yahoo Finance, TradingView, AlphaVantage) өгөгдөл орж ирэн, серверийн хэсэг дээр боловсруулагдаж, MongoDB-д төвлөрөөд, дараа нь харагдах хэсгээр дамжин хэрэглэгчдэд хүрнэ.



Зураг 3.5 Өгөгдлийн урсгалын UML Activity Diagram: swimlane-аар data боловсруулалтын алхмууд

Унших заавар. MT5 болон Yahoo Finance-ийн өгөгдөл нь шинж чанар болон GBDT дохио үүсгэх урсгалаар, AlphaVantage болон TradingView-ийн мэдээлэл нь LLM шинжилгээний урсгалаар тус тус орж, хоёулаа MongoDB-д төвлөрнө. MongoDB-оос хэрэглэгчид push мэдэгдэл болон мобайл апп руу түгээнэ.

LLM-д суурилсан зах зээлийн дүн шинжилгээний бүрэлдэхүүн

Системийн өгөгдлийн урсгалд GBDT-ийн тоон дохионоос гадна Gemini API-д суурилсан хэлний загварын бүрэлдэхүүнийг нэмж оруулсан. Энэ хэсгийн зорилго нь загварын тоон гаралтыг

эдийн засгийн мэдээ болон зах зээлийн тэмдэглэлийн контекстоор нэмэлтлэн хэрэглэгчид ойлгомжтой хэлбэрт хүргэх явдал юм.

Оролтын эх сурвалж:

- **AlphaVantage** — EUR/USD болон холбогдох валютын хослолын мэдээний гарчиг, сэтгэл санааны оноо (sentiment score)-ыг API-аар татаж авна.
- **TradingView** — Эдийн засгийн хуанли: ирэх долоо хоногийн CPI, NFP, FED хурал зэрэг өндөр нөлөөтэй мэдээний хуваарийг хадгална.

LLM-ийн боловсруулалтын логик:

AlphaVantage болон TradingView-ийн мэдээллийг GBDT ансамблийн тухайн мөчийн таамгийн хамт Gemini API-д дамжуулна. Gemini нь дараах гаралтыг бий болгодог:

1. **Дохионы тайлбар хураангуй** — “Яагаад BUY/SELL дохио гарсан бэ?” гэдгийг хэрэглэгчид ойлгомжтой байдлаар тайлбарлана (жишээ нь: “EUR-ийг дэмжих дохио: CPI өндөр гарсантай зэрэгцэн EUR/USD хамгийн дээд түвшнийг тогтоосон”).
2. **Зах зээлийн нийт төлвийн дүгнэлт** — Тухайн үеийн макро нөхцөл, мэдээний тэнцвэр, эрчмийн үнэлгээг нэг догол мөрт нэгтгэнэ.
3. **Эрсдэлийн анхааруулга** — Ирэх цагт өндөр нөлөөтэй мэдээ төлөвлөгдсөн бол хэрэглэгчид “Санаа тавих нөхцөл байна” гэсэн тэмдэглэл харуулна.

Архитектурын байршил:

LLM бүрэлдэхүүн GBDT ансамблийн ангиллын шийдвэрт нөлөөлөхгүй — BUY/SELL/HOLD гаралт болон итгэлцлийн утгыг өөрчлөхгүй. Gemini-ийн гаралт зөвхөн **харагдах хэсгийн тайлбарын давхарга** болж MongoDB-д тусдаа талбарт хадгалагдана. GBDT-ийн тоон үнэлгээ болон LLM-ийн тайлбар хоёр архитектурын хувьд зэрэгцэн ажиллаж, нэг нь нөгөөгөө орлохгүй.

Энэ бүрэлдэхүүн нь мэргэжлийн дүн шинжилгээнд хандах боломж хязгаарлагдмал жижиг арилжаачдад аналитикийн контекст хүргэх **шийдвэр дэмжих** (decision support) зорилготой бөгөөд арилжаа нээх/хаах шийдвэрийг хэрэглэгч өөрөө гаргадаг.

Тайлбар: LLM бүрэлдэхүүний гаралтын тоон үнэлгээ — жишээлбэл, тайлбарын нарийвчлал, хэрэглэгчийн ойлголтод үзүүлэх нөлөө — одоогийн судалгааны хүрээнд хийгдсэнгүй. Иймд энэ бүрэлдэхүүн нь GBDT ансамблийн ангиллын үр дүнд тусгаагүй бөгөөд системийн прототипийн нэг бүтцийн хэсэг хэлбэрт оршино. Нарийвчилсан үнэлгээг цаашдын ажилд үлдээсэн.

3.4. Өгөгдлийн бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5 платформуос EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 3.1 нь интервал бүрийн өгөгдлийн хэмжээг харуулав.

Хүснэгт 3.1 Түүхэн өгөгдлийн хэмжээний хураангуй

Интервал (timeframe)	Мөрийн тоо	Хугацаа
M1 (1 минут)	~3,700,000	2015–2024
M5 (5 минут)	~740,000	2015–2024
M15 (15 минут)	~247,000	2015–2024
M30 (30 минут)	~123,000	2015–2024
H1 (1 цаг)	~62,000	2015–2024
H4 (4 цаг)	~15,500	2015–2024

Олон цагийн интервал бүхий өгөгдлийг хослуулах замаар загвар нь зах зээлийн богино хугацааны хэлбэлзэл (M1, M5), дунд хугацааны чиг хандлага (M15, M30), мөн урт хугацааны бүтэц (H1, H4)-ыг нэгэн зэрэг харах боломжтой болсон. Энэ олон хугацааны интервалын арга нь [17] шинж чанарын инженерчлэл буюу “олон хугацааны хүрээ” (multiple timeframe analysis) зарчимд нийцнэ.

Шинж чанарын инженерчлэл

Интервал бүрээс 8 шинж чанар тооцоолж, нийт 48 шинж чанар бүхий матриц үүсгэсэн. Хүснэгт 3.2 нь шинж чанаруудыг жагсаав.

Домэйны нэр томьёо: Candle (мөн OHLCV бар гэнэ) нь тодорхой хугацааны интервалын нээлт (open), дээд (high), доод (low), хаалт (close) ханш болон эргэлт (volume)-ийн таван утгыг хамарсан нэгдмэл өгөгдлийн цэг. Жишээлбэл, M1 интервалын нэг candle нь 1 минутын хугацааны дүн юм. RSI нь Relative Strength Index (харьцангуй хүч индекс), ATR нь Average True Range (дундаж жинхэнэ хэлбэлзэл), SMA нь Simple Moving Average (энгийн хөдөлгөөний дундаж)-ийн товчлол.

Хүснэгт 3.2 Шинж чанарын жагсаалт (интервал бүрд)

№	Шинж чанар	Тайлбар
1	close	Тухайн candle-ийн хаалтын ханш
2	rsi	RSI (14 candle) — хэт худалдсан/хэт худалдан авсан байдлыг 0–100 хуваарьт хэмждэг импульс шинж чанар
3	atr	ATR (14 candle) — сүүлийн 14 candle-ийн дундаж жинхэнэ хэлбэлзэл; зах зээлийн эрсдэлийн хэмжүүр
4	ma_5	Сүүлийн 5 candle-ийн хаалтын ханшийн хөдөлгөөний дундаж (SMA) — богино хугацааны чиглэл
5	ma_20	Сүүлийн 20 candle-ийн SMA — дунд хугацааны чиглэл
6	ma_50	Сүүлийн 50 candle-ийн SMA — урт хугацааны чиглэл
7	volatility	Сүүлийн 20 candle-ийн хаалтын ханшийн стандарт хазайлт; зах зээлийн тайван эсвэл хэлбэлзэлтэй байдлын үзүүлэлт
8	returns	Өмнөх candle-тэй харьцуулсан ханшийн өөрчлөлтийн хувь (pct_change)

MA(5), MA(20), MA(50) гурвыг хослуулан оруулсан шалтгаан нь тэдгээр нь тус тус богино (M5), дунд (M30–H1), урт (H1–H4) хугацааны чиг хандлагын хүчийг нэгэн зэрэг дүрслэх боломжийг

олгодогт оршино. GBDT-д давхардсан шинж чанар нь feature importance-аар автоматаар шүүгддэг тул мэдээллийн хувьд асуудал үүсдэггүй.

Энэ ажлын эхний шатанд 75 орчим боломжит шинж чанарыг туршсан боловч эцсийн загварт 48 шинж чанарын матрицыг тогтмол болгосон. Тиймээс MACD, ADX, CCI зэрэг индикаторын нэр томьёо нь судалгааны тойм болон туршилтын боломжит багцад дурдагдсан ч энэ хувилбарын эцсийн оролтын матрицад ороогүй.

Шинж чанаруудыг `_1min`, `_5min`, `_15min`, `_30min`, `_1H`, `_4H` гэсэн дагавраар ялгана. Жишээлбэл, `rsi_1min` нь 1 минутын RSI, `atr_4H` нь 4 цагийн ATR-ийг илэрхийлнэ. Систем 1 минутын суурь өгөгдлөөс бусад интервалын шинж чанаруудыг `merge_asof (backward)` аргаар нэгтгэдэг.

Шошго (label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) ханшийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

Домэйны нэр томьёо: Пипс (pip, percentage in point) нь Форекс зах зээлд ханшийн хамгийн бага өөрчлөлтийн нэгж; EUR/USD-д 1 пипс = 0.0001. Зах зээлийн хэлбэлзлийг тоолоход хэрэглэгддэг.

$$\text{label} = \begin{cases} \text{BUY (+1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (3.1)$$

Үүнд:

- Δ_{up} – ирээдүйн 240 минутын хамгийн дээд ханш ба одоогийн хаалтын ханшийн зөрүү (пипсээр)
- Δ_{down} – одоогийн хаалтын ханш ба ирээдүйн хамгийн доод ханшийн зөрүү (пипсээр)
- 30 пипс – шуугианаас дохиог ялгах доод хязгаар; EUR/USD-ийн дундаж өдрийн ATR(14) (≈ 80 пипс, 2015–2024)-ийн 37%
- 1.5 дахин давамгайлал – чиг хандлагын тодорхой байдлыг шаардах; [1.2, 2.0] мужийн утгыг туршиж шошгын тэнцвэрийг харгалзан сонгосон

2015–2022 оны M1 сургалтын өгөгдөл (3,726,046 цэг) дээрх ангиллын хуваарилалт: HOLD 75.5% (2,812,515), BUY 12.2% (454,999), SELL 12.3% (458,532). HOLD давамгайлалтай тул LightGBM загварт `scale_pos_weight = neg/pos` параметрийг тохируулж, ангиллын тэнцвэргүй байдлыг зохицуулсан.

Шошго ба шинж чанарын цагийн нийцлийн аудит (leakage audit)

Leakage (мэдээллийн нэвчилт) гэдэг нь загварын сургалтад ирээдүйн мэдээлэл санамсаргүй-гээр орохыг хэлэх бөгөөд энэ нь тестийн нарийвчлалыг хиймлээр өндөр харуулдаг. Шошго үүсгэх ба олон интервалын шинж чанар нэгтгэх үеийн гол шаардлага нь шийдвэрийн агшин (t_0)-д зөвхөн тухайн мөчөөс өмнө мэдэгдэх боломжтой мэдээлэл ашиглах явдал юм. Энэ нөхцөлийг дараах байдлаар тодорхойлов:

$$t_{\text{feature}} \leq t_0, \quad \text{label window} = (t_0, t_0 + 240 \text{ минут}] \quad (3.2)$$

Шинж чанар үүсгэх ба шошго тооцох үе шатанд систем цагийн нийцлийн дүрмийг тогтвортой мөрддөг (томъёо 3.2). Бүх компонентын нарийвчилсан хяналтын дүрмийг Хавсралт В-аас үзүүлэв. `merge_asof(backward)` болон хугацааны тусгаарлалтын дүрэм нь `leakage` эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй.

WFV-ийн олон огтлолтын алхамт логик

Судалгаанд урагш гүйлгэн баталгаажуулалтыг цаг хугацааны дараалал хадгалсан **олон огтлолт, өргөтгөх сургалтын цонх** (expanding window) протоколоор хэрэгжүүлсэн. KPI-ийн дэлгэрэнгүй үнэлгээ **Fold 5** огтлол (2015–2022 / 2023 / 2024)-д суурилсан бөгөөд Хүснэгт 3.3 тухайн огтлолын хуваалтыг нэгтгэн харуулна. Олон огтлолтын ерөнхий концепцын схемийг Хавсралт В-аас үзнэ үү.

Хүснэгт 3.3 Урагш гүйлгэн баталгаажуулалтын хүрээнд ашигласан үндсэн огтлолын өгөгдлийн хуваалт

Бүлэг	Хугацаа	Candle-ын тоо	Зорилго
Сургалт	2015–2022	~2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	~371,000	Early stopping, calibration туршилтын ажиглалт (10%)
Тест	2024	~371,000	Эцсийн үнэлгээ (10%)

Зураг 3.6 нь энэхүү хуваалтыг цаг хугацааны тэнхлэг дээр дүрслэн харуулав. Сургалтын өгөгдөл (80%) баталгаажуулалтын өгөгдөл (10%) тестийн өгөгдөл (10%)-өөс цаг хугацааны дарааллаар ялгагдана.



Зураг 3.6 Урагш гүйлгэн баталгаажуулалт (WFV): энэ судалгааны үнэлгээнд ашигласан нэг огтлолын (Fold 5) өгөгдлийн хуваалт

Тайлбар: KPI үнэлгээнд ашигласан Fold 5-ийн бодит хуваалтыг Зураг 3.6 харуулав. WFV-ийн олон огтлолтын ерөнхий концепцын схем болон алхамт логикийг Хавсралт В-аас (Зураг В.1) үзнэ үү.

3.5. AI загварын бүтэц ба сургалт

Ансамбль загварын архитектур

Системийн загвар нь гурван GBDT (gradient boosted decision trees) загвараас бүрдэх ансамбль юм. GBDT нь олон модны нэгтгэсэн загвар бөгөөд санхүүгийн хүснэгтэн өгөгдөлтэй сайн нийцдэг [2]. Загвар бүр ижил 48 шинж чанарыг хүлээн авч BUY, SELL, HOLD гурван ангиллын магадлалыг тус тус тооцоолно. Эдгээр магадлалыг зөөлөн санал хураалтаар тэгш жингээр дундажилж эцсийн итгэлцлийг үүсгэнэ:


$$P_{\text{ensemble}}(c | \mathbf{x}) = \frac{1}{3} \sum_{k=1}^3 P_k(c | \mathbf{x}), \quad c \in \{\text{BUY, SELL, HOLD}\} \quad (3.3)$$

$$\hat{c} = \arg \max_c P_{\text{ensemble}}(c | \mathbf{x}), \quad \text{conf} = \max_c P_{\text{ensemble}}(c | \mathbf{x}) \quad (3.4)$$

Үүнд $P_k(c | \mathbf{x})$ нь k -р загварын c ангилалд өгсөн магадлал, $\hat{c}$ нь сонгосон ангилал, conf нь ансамблийн итгэлцэл болно. Logistic Regression-д суурилсан магадлалын тохируулгыг баталгаажуулалтын огтлол дээр шалгасан. Зарим нөхцөлд тархалт хэт төвлөрөх шинж ажиглагдсан тул энэ тайланд тохируулгагүй шууд магадлалыг ашиглав; тохируулгын дүнг туршилтын ажиглалт болгон тэмдэглэж, бодит ажиллах орчны хэрэглээ гэж авч үзсэнгүй. Зураг 3.7 нь энэхүү бүтцийг харуулав.

Ансамблийн жинг $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ гэж тэгш авсан нь хоёр шалтгаантай. Нэгдүгээрт, гурван загвар суралцах хандлагын хувьд ялгаатай тул нэг загварт жинг хэт төвлөрүүлэхгүй байх нь оновчтой. Хоёрдугаарт, нэг баталгаажуулалтын огтлолд жинг тусад нь оновчлох нь data-snooping эрсдэл нэмэгдүүлдэг тул тогтвортой бөгөөд дахин хэрэгжүүлэхэд хялбар тэгш жингийн бодлогыг баримталсан.

Энд нэг чухал ялгаа бий: **загварын ангиллын гаралт** нь BUY/SELL/HOLD (3 ангилал), харин **гүйцэтгэлийн түвшний хэрэгжих үйлдэл** нь BUY эсвэл SELL (2 үйлдэл) юм. HOLD ангилал сонгогдсон үед систем шинэ байрлал нээхгүй, өөрөөр хэлбэл “үйлдэлгүй төлөв” (no-trade state) гэж үзнэ.



Зураг 3.7 GBDT ансамбль загварын архитектур

Гурван загварыг ансамбль хэлбэрээр хослуулсан шалтгаан нь тус бүр нь өсөлтийн стратеги, хурд, хэт нийцлийн эрсдэлийн хувьд бие биенээ нөхдөгт оршино. Зураг 3.8 нь тэдгээрийн гол ялгааг харуулав.



Зураг 3.8 Гурван GBDT алгоритмын харьцуулалт: өсөлтийн стратеги, сургалтын хурд, хэт нийцлийн эрсдэл

Гиперпараметр сонголтын протокол

Гиперпараметрийг “хамгийн өндөр ганц үзүүлэлт” дагуу хайх бус, тогтвортой байдлын протоколоор сонгосон. Үндсэн алхмууд нь: (1) өндөр багтаамжтай суурь тохиргооноос эхлэх, (2) модны гүн ба навчийн тоог бууруулах, (3) subsample/colsample болон L1/L2 тогтмолжуулалт нэмэх, (4) 2023 оны баталгаажуулалтын огтлол дээр early stopping-оор хэт сургалтыг зогсоох. Сонголтын шалгуур нь train-val зөрүүг хянах, өндөр итгэлцлийн дэд мужийн чанарыг хадгалах, мөн ажиллах үеийн итгэлцлийн тархалтыг тогтвортой байлгах явдал байсан.

Энэ хувилбарт ансамбль сургалтыг нэг эхлүүлэх утга (single-seed protocol)-тай явуулсан нь туршилтын хэмжээсийг хэт томруулахгүйгээр давтан хэрэгжих чадварыг сайжруулах зорилготой. Олон seed-ийн дундажтай тайланг дараагийн шатны баталгаажуулалтын ажилд үлдээсэн.

Гурван загварын гиперпараметрийг тогтвортой байдлын протоколоор сонгосон: модны гүнийг 5–6 хооронд хязгаарлаж, learning rate 0.03, early stopping patience 50 давталт байв. Дэлгэрэнгүй параметрийг Хавсралт А-аас үзнэ үү.

Хэт нийцэл (overfitting)-аас сэргийлэх арга хэмжээ

Санхүүгийн загварт хэт нийцэл (overfitting) нь хамгийн чухал сорилт юм. Үүнээс сэргийлэхэд модны гүнийг хязгаарлах, learning rate бага тогтоох, early stopping, L1/L2 нормчлол, цаг хугацааны дараалал хадгалсан баталгаажуулалт, болон шинж чанарын тоог багасгах зэрэг зургаан арга хэмжээг авсан. Тус бүрийн дэлгэрэнгүй аргачлалыг Хавсралт А-аас үзнэ үү.

Сургалтын алгоритм

Энэ судалгаанд ансамбль загварын сургалтыг хугацааны дараалал хадгалсан тогтмол протоколоор хэрэгжүүлсэн. Протоколын зорилго дараах байдалтай:

- Өгөгдөл хуваах ба шинж чанар бэлтгэх алхмыг тогтмолжуулах

- Суурь загваруудыг ижил нөхцөлд сургах
- Магадлалуудыг тэгш жингээр нэгтгэх
- Тохируулга ба тестийн үнэлгээг нэг мөрөөр тодорхойлох

Тэмдэглэгээ: D нь цагийн дараалалтай өгөгдөл, $\mathcal{B} = \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$ нь суурь загварын багц, $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ нь ансамблийн жин, $p = 50$ нь early stopping-ийн patience параметр болно.

Ансамбль загварын сургалтын протокол

Оролт: Цагийн дараалалтай өгөгдөл D , суурь загварын багц $\mathcal{B}$, жин w , эрт зогсоолтын параметр p

Гаралт: Ансамбль $\mathcal{M} = \{M_1, M_2, M_3\}$, тохируулгын загвар C , тестийн үнэлгээ acc_{test}

$\mathcal{B} \leftarrow \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$

$w \leftarrow (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$

I. Цаг хугацааны хуваалт ба шинж чанар бэлтгэх

$(D_{\text{train}}, D_{\text{val}}, D_{\text{test}}) \leftarrow \text{TimeSplit}(D)$

$(X_{\text{train}}, X_{\text{val}}, X_{\text{test}}) \leftarrow \text{BuildFeatures}(D_{\text{train}}, D_{\text{val}}, D_{\text{test}})$

$(y_{\text{train}}, y_{\text{val}}, y_{\text{test}}) \leftarrow \text{ExtractLabels}(D_{\text{train}}, D_{\text{val}}, D_{\text{test}})$

II. Суурь загвар сургах

for суурь загвар $b_k \in \mathcal{B}$ **do**

$M_k \leftarrow \text{Train}(b_k, X_{\text{train}}, y_{\text{train}}, X_{\text{val}}, y_{\text{val}}, p)$

end for

III. Ансамбль магадлал нэгтгэх

for $k = 1, 2, 3$ **do**

$P_{\text{val}}^{(k)} \leftarrow M_k.\text{predict_proba}(X_{\text{val}})$

$P_{\text{test}}^{(k)} \leftarrow M_k.\text{predict_proba}(X_{\text{test}})$

end for

$\bar{P}_{\text{val}} \leftarrow \sum_{k=1}^3 w_k P_{\text{val}}^{(k)}$

$\bar{P}_{\text{test}} \leftarrow \sum_{k=1}^3 w_k P_{\text{test}}^{(k)}$

IV. Тохируулга ба үнэлгээ

$C \leftarrow \text{FitCalibrator}(\bar{P}_{\text{val}}, y_{\text{val}})$

$(\text{score}_{\text{raw}}, \text{score}_{\text{cal}}) \leftarrow \text{CompareCalibration}(\bar{P}_{\text{val}}, C(\bar{P}_{\text{val}}), y_{\text{val}})$

$\text{acc}_{\text{test}} \leftarrow \text{accuracy}(\bar{P}_{\text{test}}, y_{\text{test}})$

Ажиллах үеийн шийдвэрт ансамблийн шууд магадлал $\hat{P}$ -оос $c = \max(\hat{P})$ итгэлцлийг тооцно

return $\mathcal{M}, w, C, \text{score}_{\text{raw}}, \text{score}_{\text{cal}}, \text{acc}_{\text{test}}$

Тайлбар: Энэ хувилбарт тохируулгын загвар (C)-ыг сүлжээнээс гадуурх үнэлгээнд ашиглаж, ажиллах орчинд ансамблийн шууд магадлалыг хэрэглэсэн.

3.6. Дохио үүсгэх систем


Дохионы шүүлтүүр

Загварын таамгаас чанартай дохиог ялгахын тулд хоёр шүүлтүүр ашигласан. HOLD ангилал нь энэ шатанд BUY/SELL мэт “дохио” биш, харин арилжаанд орохгүй гэсэн төлөв тул хэрэгжих захиалгын урсгалд орохгүй:

- **Итгэлцлийн босго:** Системийн ажиллах урсгалд ансамблийн итгэлцэл (confidence) ≥ 0.60 босгыг анхан шатны шүүлтүүрт ашигласан. Харин энэ тайлангийн бүх тоон үнэлгээ, босгын мужийн харьцуулалт нь ≥ 0.90 суурь босго дээр хийгдсэн бөгөөд 0.90–0.99 мужийг шинжилсэн (§4.5).
- **ATR шүүлтүүр:** $ATR \geq 4.0$ пипс. Зах зээлд хангалттай хэлбэлзэл байх үед л дохио өгнө (бага хэлбэлзэлтэй үед арилжаа хийх нь ашиггүй)

2025 оны өгөгдөл дээрх анхны 359,639 таамгаас итгэлцэл (confidence) $\geq 90\%$ босгонд 3,567 нь (1.0%) эдгээр шалгуурыг хангасан. Зураг 3.9 нь энэхүү шүүлтүүрийн процессыг юүлүүр диаграммаар харуулав.

Итгэлцлийн шүүлтүүрийн дараа ердөө ≈ 33 дохио ATR шүүлтүүрт нэмэлтээр хасагдсан нь хоёр шүүлтүүрийн өндөр корреляцийг илэрхийлнэ. Загвар итгэлцэл өндөртэй ($\geq 90\%$) таамаглал гаргахдаа зах зээлийн хэлбэлзэл (ATR) өндөр үеийг ихэвчлэн сонгодог бөгөөд бага хэлбэлзэлтэй (шуугианы) үед итгэлцлийн шүүлтүүр аль хэдийн тэдгээрийг хасдаг. $ATR \geq 4.0$ пипс шүүлтүүр нь хоёр дугаар шүүлтүүр болж, итгэлцлийн шалгуурт тэнцсэн боловч хэлбэлзэл хангалтгүй хэдэн арван дохиог нэмэлтээр цэвэрлэдэг.



Зураг 3.9 Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио

Stop Loss ба Take Profit тооцоолол

Арилжааны эрсдэлийг хязгаарлах Stop Loss (SL) болон ашгийг баталгаажуулах Take Profit (TP) утгуудыг ATR-д суурилан динамикаар тооцоолсон:

$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (3.5)$$

$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (3.6)$$


Энэ аргын давуу тал нь зах зээлийн хэлбэлзлийн урсгалд тохируулан SL/TP-ийн хэмжээг автоматаар сунгаж эсвэл нарийсгаж тохируулдаг явдал юм. Гол параметрууд:

- **SL-ийн ATR үржвэр (5.0):** Загварын 7 давталтат сайжруулалтын явцад 3.0–7.0 мужийн утгыг туршиж, хэт нийцэл ба дуулианы тэнцлийн хувьд 5.0 нь хамгийн тогтвортой гүйцэтгэл өгсөн тул сонгосон (Хавсралт А-ын давталтат протоколын дэлгэрэнгүйг үзнэ үү).
- **TP/SL харьцаа (3:1):** Системийн зөв таамаглах магадлал ердөө 33% байсан ч санхүүгийн хувьд ашигтай ажиллах математик эрсдэл-өгөөжийн харьцаа юм.
- **Хамгийн бага SL (15 пипс):** Зах зээл хэт тайван үед SL хэт багасаж бага зэргийн санамсаргүй хөдөлгөөнд арилжаа хаагдахаас хамгаалах доод хязгаар.
- **Хамгийн бага TP (45 пипс):** Аливаа арилжаанаас олох ашиг нь зардлаас (spread, шимтгэл) давж, статистик ач холбогдол бүхий хэмжээнд байхыг баталгаажуулах доод хязгаар.

Дохио үүсгэх дарааллын диаграмм


Дохио үүсгэх процессыг хоёр хэсэгт хуваан тайлбарлана: **(А)** өгөгдөл татаж таамаглал хийх хэсэг, **(В)** дохио шүүж хэрэглэгчид хүргэх хэсэг. Хоёр диаграмм нь нэг тасралтгүй мөчлөгийн хоёр хагас юм.

(А) Өгөгдөл татаж таамаглал хийх:



Зураг 3.10 Дохио үүсгэх UML Sequence Diagram — (A) өгөгдөл татаж таамаглах

(B) Дохио шүүж хэрэглэгчид хүргэх:



Зураг 3.11 Дохио үүсгэх UML Sequence Diagram — (B) дохио шүүж хэрэглэгчид хүргэх

Унших заавар. (A) зурагт (Зураг 3.10) Scheduler trigger-аас эхлэн OHLCV татаж, шинж чанар тооцоолж, GBDT ансамблиар дохио+итгэлцэл гаргах дарааллыг харуулна. (B) зурагт (Зураг 3.11) сервер дохиог шүүж, SL/TP тооцоолж, MongoDB-д хадгалаад push мэдэгдэл илгээх ба апп REST-ээр дэлгэрэнгүйг авах дарааллыг харуулна.

Дохионы эх үүсвэрийн бүрэн бүтэн байдал ба leakage-ээс сэргийлэлт

Энэ судалгаанд leakage (өгөгдөл/шийдвэрийн нэвчилт) гэдгийг ирээдүйн мэдээлэл сургалт, үнэлгээ рүү санамсаргүй орох эсвэл гадаад гараар оруулсан дохио автомат урсгалтай холилдох эрсдэл гэж тодорхойлов. Үнэлгээний багцад зөвхөн автомат өгөгдөл боловсруулах урсгалаар (pipeline) үүссэн дохиог хамруулж, гараар үүсгэсэн болон хувийн туршилтын дохиог тусгаарласан.

Мөн дохио бүрт эх үүсвэрийн мөр (provenance trace) хадгалж, ямар загварын хувилбар, ямар хугацааны огноо-цагийн цонхоос үүссэнийг индексжүүлэн шалгах боломжтой болгосон. Ингэснээр үр дүнг дахин тооцоход адил гаралт авах нөхцөл хангагдаж, аудитын үед дохионы гарал үүслийг буцаан шалгах боломж бүрдсэн.

Энэ бичвэрт хэрэгжилтийг арга зүйн түвшинд абстракцлан, шалгуур логик болон нэгтгэсэн үзүүлэлтүүдийг системтэй нэгтгэн тайлбарласан.

3.7. MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт

MetaTrader 5 (MT5) нь санхүүгийн зах зээлийн арилжааны платформ бөгөөд уг судалгаанд зөвхөн Strategy Tester модулийг ашигласан. Strategy Tester нь Expert Advisor (EA) хэлбэрт бичсэн алгоритмын дүрмийг түүхэн OHLCV өгөгдөл дээр дахин тоглуулж, хэлцлийн дэлгэрэнгүй логийг (timestamp, SL, TP, ашиг/алдагдал) бичдэг симуляцийн орчин юм. Энэ судалгаанд MT5-ын Strategy Tester нь GBDT ансамблийн гаралтыг validation engine болгон ашиглаж, загварын ML метрикийн үнэлгээг (Chapter 4) бодит орчны симуляцтай холбосон.

Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэлийн логик

Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэлд эрсдэлийн удирдлагатай гүйцэтгэгч модуль ашиглаж, дохио бүр дээр байрлалын хэмжээ, итгэлцлийн босго, гулсалтын хязгаар зэрэг дүрмийг тогтмол мөрдсөн. Хүснэгт 3.4 нь энэ хэсгийн үндсэн тохиргоог харуулав.

Хүснэгт 3.4 Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо

Параметр	Утга	Тайлбар
Арилжаа бүрийн эрсдэл	1.0%	Нэг дохион дээр авах эрсдэлийн хувь
Нэг удаагийн байрлалын дээд тоо	1	Давхар байрлал нээхээс сэргийлсэн
Итгэлцлийн доод босго	0.90	Чанарын шүүлтүүрийн үндсэн босго
Зөвшөөрөгдөх гулсалтын хязгаар	10 point	Гүйцэтгэлийн бодит нөхцөлийг тусгасан

Тайлбар: “10 point” нь EUR/USD-ийн хувьд 1 pip-тэй тэнцэх ба 0.0001 ханшийн нэгжтэй тохирно (1 pip = 10 point = 0.0001). MetaTrader 5-д “point” нь хамгийн жижиг ханшийн нэгж бөгөөд EUR/USD-д 5 аравтын орны гарал болно.

Түүхэн өгөгдөл дээрх системийн туршилтын нөхцөл

- **Платформ:** MetaTrader 5 Strategy Tester
- **Горим:** Every tick (бүх тикийн өгөгдөл – бодит нөхцөлд ойролцоо гүйцэтгэлийн горим)
- **EA тестийн цонх:** 2025.01.01 – 2026.01.01

- **Анхны хөрөнгө:** \$10,000
- **Хэрэгсэл:** EUR/USD (бодит спрэд)
- **Суурь дохионы багц:** 0.90 итгэлцлийн шүүлтүүртэй суурь багц (3,567 дохио)
- **Нэмэлт босгын багцууд:** 0.91–0.99 мужийн урьдчилан шүүсэн дохионы багцууд; ЕА талын ажиллах үеийн итгэлцлийн босго 0.90 дээр тогтмол байсан бөгөөд ялгаа нь оролтын шүүлтүүрээс үүссэн
- **Дохио/өдөр үзүүлэлт:** backtest цонхны Даваа–Баасан арилжааны өдрийн тоо (261 өдөр)-д суурилан тооцсон

Арилжааны зардлын хамралтын матриц

Энэ судалгаанд зардлын загварчлалын хамрах хүрээг Хүснэгт 3.5-д нэгтгэв.

Хүснэгт 3.5 *Арилжааны зардлын хамралтын матриц*

Зардлын бүрэлдэхүүн	Статус	Энэ ажлын хэрэгжүүлэлт	Тайлбарын нөлөө
Spread	Тийм	MT5-ийн бодит spread орчинд тооцсон	Бодит нөхцөлд ойртуулна
Slippage	Тийм	10 point дээд хязгаар ашигласан	Гүйцэтгэлийн тодорхой бус байдлыг хэсэгчлэн тусгана
Commission	Үгүй	Брокер тус бүрийн шимтгэлийг sweep тайланд тусгаагүй	Өгөөжийг хэт өөдрөг харагдуулах эрсдэлтэй
Swap	Үгүй	Шөнийн санхүүжилтийн зардлыг тусгаагүй	Удаан хадгалсан байрлалын цэвэр үр дүнг зөрүүлэх эрсдэлтэй

Иймд энэ бүлэгт нэгтгэн харуулсан өгөөжийн дүнг бүх зардал бүрэн шингэсэн эцсийн ашиг гэж бус, сценарийн түвшний харьцуулалтын үр дүн гэж тайлбарлав.

Босго сонголтын протокол ба өгөгдлийн хэт сонголтын эрсдэлийн хяналт

Босгын мужийн хүснэгт нь **сценарийн харьцуулалт** бөгөөд ажиллах үеийн динамик босго тааруулалт биш юм. Өөрөөр хэлбэл энэ ажилд ЕА талын босго 0.90 дээр тогтмол байсан ба шинжилгээ нь урьдчилан шүүсэн дохионы багцуудын үр дүнг харьцуулсан тайлангийн алхам болно.

Өгөгдлийн хэт сонголтын эрсдэлийг бууруулахын тулд босго сонголтыг дараах зарчмаар тайлбарлав:

1. **Selection phase:** ижил журамтай сонголтын цонх дээр кандидат босгуудын харьцуулалт хийх
2. **Freeze:** сонгосон бодлогын мужийг (жишээ нь 0.90–0.92) тогтмолжуулах
3. **Confirmation:** дараагийн хугацааны цонхонд өөрчлөлтгүй баталгаажуулах

Иймд 0.91 босго нь энэ шинжилгээний хүрээнд ажиглагдсан локал дээд цэг гэж тайлбарлагдах бөгөөд бүх нөхцөлд универсал оновчтой утга гэж дүгнэхгүй. Мөн энэ хувилбарт confirmation шатны тусдаа хугацааны цонхны дүнг бүрэн тусгаагүй тул босгоны дүгнэлтийг нөхцөлт хүрээнд авч үзсэн.

Үнэлгээний шалгуур үзүүлэлтүүд

Загварын болон системийн гүйцэтгэлийг дараах шалгуур үзүүлэлтүүдээр үнэлсэн. Хүснэгт 3.6 нь тэдгээрийн тодорхойлолт болон чиглэлийг харуулав.

Хүснэгт 3.6 Системийн үнэлгээний шалгуур үзүүлэлтүүд

Үзүүлэлт	Тодорхойлолт	Үнэлгээний чиглэл
<i>Загварын ангиллын чанарын үзүүлэлтүүд (энэ ажлын үнэлгээний хүрээнд)</i>		
Тестийн нарийвчлал (accuracy)	2024 оны тест хуваалтын зөв ангиллын хувь	Өндөр байх тусам сайн
Өндөр итгэлцэлтэй дохионы нарийвчлал	Итгэлцэл өндөр муж дахь зөв ангиллын хувь	Өндөр байх тусам сайн
<i>Босгын мужийн сценарийн системийн үзүүлэлтүүд (Chapter 4-т нэгтгэн харуулсан)</i>		
Эцсийн баланс (\$)	Сценари бүрийн туршилтын эцсийн хөрөнгө	Өндөр байх тусам сайн
Цэвэр ашиг (\$)	Эцсийн баланс – анхны хөрөнгө (\$10,000)	Өндөр байх тусам сайн
Өгөөж (%)	$\frac{\text{Final Balance} - 10,000}{10,000} \times 100$	Өндөр байх тусам сайн
Дохио/өдөр	Нийт дохиог backtest цонхны Даваа–Баасан арилжааны өдрийн тоонд (261) харьцуулсан давтамж	Хэрэглээний ачааллаас хамаарна
Дохио тутмын ашиг (\$)	Нэг дохионд ногдох дундаж ашиг	Өндөр байх тусам сайн
Гүйцэтгэлийн хувь (execution rate)	Шүүгдсэн дохионоос бодитоор нээгдэж хаагдсан арилжааны хувь	Контекстээс хамаарна
Ялалтын хувь (win rate)	Хаагдсан арилжаан дахь TP эзлэх хувь	Өндөр байх тусам сайн
Ялалтын хувь 95% CI	Wilson аргаар тооцсон итгэлцлийн интервал	Нарийн байх тусам тодорхой
Expectancy (R)	TP/SL=3:1 нөхцөлд нэг арилжаанд хүлээгдэх нормчилсон өгөөж	0-ээс их байх тусам сайн
Сценарийн хэлбэлзэл (balance CV)	Босгуудад харгалзах эцсийн балансын тархалтын хэлбэлзэл (std/mean)	Бага байх тусам тогтвортой
Max drawdown (MaxDD)	Оргил балансаас хамгийн их уналтын хувь	Бага байх тусам сайн
Sharpe	Өдөр тутмын өгөөжийн эрсдэлд нормчилсон өгөөж	Өндөр байх тусам сайн
Sortino	Зөвхөн сөрөг хэлбэлзлээр нормчилсон өгөөж	Өндөр байх тусам сайн
Calmar	Жилийн дүнгээр тооцсон өгөөжийг MaxDD-д харьцуулсан үзүүлэлт	Өндөр байх тусам сайн
Max losing streak	Хамгийн урт дараалсан алдагдлын үзүүлэлт	Бага байх тусам тэсвэртэй

Энэ судалгаанд ангиллын чанарыг тестийн нарийвчлал болон өндөр итгэлцэлтэй дохионы нарийвчлалаар, системийн үр ашгийг босгын мужийн балансын нэгтгэсэн үзүүлэлтүүдээр үнэлсэн. Нэмэлтээр дохио-арилжааны хөрвүүлэлтийн чанарыг хэрэгжилтийн хувь, ялалтын хувь, ялалтын хувийн 95% интервал, Expectancy (R), сценарийн түвшний balance CV, мөн

MaxDD/Sharpe/Sortino/Calmar/хамгийн урт алдагдлын дарааллын эрсдэлийн шинжилгээтэй хамтатган нэгтгэн харуулав. Санхүүгийн туршилтад дохио/өдөр зэрэг давтамжийн үзүүлэлт нь backtest цонхны Даваа–Баасан арилжааны өдрийн тооноос (261) хамаарах тул түүний тооцооллын суурийг Хүснэгт 4.4-ийн доор ил тод тайлбарласан.

TP/SL=3:1 нөхцөлд Expectancy-г дараах байдлаар тодорхойлно:

$$E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}}) \quad (3.7)$$

энд p_{win} нь ялалтын хувь юм. $E[R] > 0$ бол нормчилсон эрсдэл-өгөөжийн хувьд статистикийн давуу талтай, $E[R] \leq 0$ бол тухайн босгоны бодлого хангалтгүйг илэрхийлнэ.

3.8. Серверийн хэсгийн хэрэгжүүлэлт

Архитектурын үндсэн бүрэлдэхүүн

Серверийн хэсэг нь бодит цагийн мэдээлэл боловсруулах, дохио үүсгэх, хэрэглэгчийн хүсэлтийг боловсруулах, болон мобайл аппликейшнтэй өгөгдөл солилцох үүргийг гүйцэтгэнэ. Хүснэгт 3.7 хүснэгтэд энэ давхаргын үндсэн бүрэлдэхүүнийг нэгтгэв.

Хүснэгт 3.7 Серверийн хэсгийн програм хангамжийн архитектурын бүрэлдэхүүн

Технологийн давхарга	Хэрэгжүүлэлтийн дэлгэрэнгүй ба үүрэг
API үйлчилгээний давхарга	Python Flask фреймворк ашигласан RESTful API. Мобайл харагдах хэсгээс (frontend) ирсэн HTTP хүсэлтүүдийг JSON форматаар хүлээн авч, боловсруулан хариу дамжуулна.
Өгөгдөл хадгалалтын давхарга	MongoDB (Баримт бичигт суурилсан NoSQL өгөгдлийн сан). Дохио, хэрэглэгчийн профайл, гүйцэтгэлийн статистикийг BSON хэлбэрээр уян хатан, өндөр хурдтай хадгалах, унших давхарга.
Загвар ачаалах давхарга	Сургагдсан GBDT ансамбль (LightGBM, XGBoost, CatBoost) загваруудыг Pickle / Joblib форматаар сериализаци (serialization) хийн хадгалж, серверийн санах ойд ачаалан бодит цагийн таамаглал (inference) гүйцэтгэх модуль.
Нэвтрэлт ба эрхийн удирдлага	JWT (JSON Web Tokens) ашиглан хэрэглэгчийн нэвтрэлтийн төлөвийг хадгалах, API хандалтын нууцлал үүсгэх, баталгаажуулах хэсэг.

Deployment архитектур ба ажиллуулах орчин

Судалгааны прототипийг контейнерт суурилсан орчноор ажиллуулах боломжтойгоор зохион байгуулсан. Архитектурын түвшинд API үйлчилгээ болон арын ажлыг тусад нь process болгон салгаж, нэг орчинд (PaaS) бие даан скейл хийх боломж үлдээсэн. Ингэснээр хэрэглэгчийн хүсэлтийн урсгал (API) ба хугацаат тооцооллын урсгал (worker)-ыг ачааллаар нь тусгаарлан тогтвортой байдлыг нэмэгдүүлдэг.

Хүснэгт 3.8 Байршуулалтын (deployment) топологийн технологийн стек

Давхарга	Хэрэгжүүлэлт	Инженерийн архитектурын үүрэг
Контейнер орчин	Docker image	Системийн хамаарал болон тохиргоог нэгтгэсэн Dockerfile-аар API болон Worker процессийг нэгдсэн нэг суурь (base image) дээр тусгаарлан (isolation) ажиллуулах.
API процесс	Gunicorn / Waitress (WSGI Server)	Flask API-ийг үйлдвэрлэлийн (production) орчинд олон thread/worker горимоор ажиллуулж, өндөр ачааллыг зэрэгцээгээр боловсруулах.
Worker процесс	Python threading	Зах зээлийн өгөгдөл татах (API integration), загварын таамаглал үүсгэх (inference), пуш мэдэгдэл (push notification) илгээх зэрэг хугацаат арын процессуудыг үйлчлэх хүсэлтээс ангид ажиллуулах.
Үүлэн (Cloud) орчин	Fly.io / Heroku зэрэг PaaS	Автомат скейлинг (scaling), орчны хувьсагчийн (environment variables) нууцлал, health-check мониторинг бүхий үйлдвэрлэлийн байршуулалт.

Серверийн хэсгийн функцийн үндсэн бүлгүүд нь нэвтрэлт, ханш, дохио, мэдээ, мэдэгдэл гэсэн таван урсгалаар хэрэгжиж, дээрх deployment topology дээрх API болон worker процессүүдэд хуваарилагдана.

Нэвтрэлтийн аюулгүй байдал ба тогтвортой ажиллагаа

Системийн нэвтрэлтийн хэсэгт богино наст токен ба сессийн баталгаажуулалт ашигласнаар буруу орчноос хандалт хийх, хугацаа хэтэрсэн сесс дахин ашиглагдах эрсдэлийг бууруулсан. Мөн серверийн тасралтгүй ажиллагааг хангахын тулд арын ажлуудын (background jobs) давхардлыг хянах, алдаа гарсан үед сэргээн оролдох бодлого хэрэгжүүлсэн.

Хандалтын хурдны хязгаарлалт (Rate limiting)

Олон нийтийн API endpoint-д Redis-д суурилсан хурдны хязгаарлалтыг хэрэгжүүлсэн; Redis ашиглах боломжгүй үед дотоод санах ойд (in-memory fallback) шилжинэ. Endpoint тус бүрийн хязгаарыг Хүснэгт 3.9-д харуулав.

Хүснэгт 3.9 API endpoint-ийн хандалтын хурдны хязгаарлалт

Endpoint бүлэг	Хязгаар (хүсэлт)	Цонх (секунд)
/signals/latest	30	60
/rates/live	60	60
/auth/* (нэвтрэлт)	20	60

Хязгаарын зорилго нь credential stuffing халдлагыг бууруулах (auth endpoint), мөн арын ажлын үүсгэсэн дохиог мобайл апп шаардлагаас илүү давтамжаар хүсэхээс сэргийлэх явдал юм.

Ачааллын тайлбар: /rates/live endpoint-ийн 60 хүсэлт/60 секунд хязгаар нь **нэг хэрэглэгчийн** дээд **хязгаар** юм. Хэрэв 1,000 хэрэглэгч тус бүр секундэд нэг удаа polling хийвэл онолын дээд ачаалал 60,000 хүсэлт/минут хүрнэ. Иймд REST polling сонголтыг зөвтгөхдөө зөвхөн хэрэглэгч нэг бүрийн түвшинд бус, нийт concurrency түвшинд үнэлэх шаардлагатай.

Системийн нэг цэгийн эмзэглэлийн шинжилгээ (SPOF)

Прототипийн архитектур нь гадаад сервисүүдтэй нягт холбоотой тул дараах нэг цэгийн эмзэглэл оршино. Хүснэгт 3.10 нь тус бүрийн нөлөө ба хэрэгжсэн хяналтыг нэгтгэв.

Хүснэгт 3.10 Архитектурын нэг цэгийн эмзэглэлийн шинжилгээ

Компонент	Нөлөө	Хяналт (хэрэгжсэн)	Үлдэгдэл эрсдэл
MongoDB	Дохио, хэрэглэгч хадгалагдахгүй	Job lock, retry механизм	Нөөц инстанц (replica set) дутмаг
Firebase FCM	Push мэдэгдэл тасарна	max_retries=3 retry бодлого	FCM платформын тасралт
Flask API	Бүх endpoint хүртэх боломжгүй	Gunicorn олон worker	Нэг сервер; load balancer дутмаг
MT5 өгөгдлийн эх сурвалж	Дохио үүсэхгүй	60 секундын мөчлөг дахин оролдоно	Гадаад API хязгаарлалт
Yahoo Finance API	Ханшийн дүрс шинэчлэгдэхгүй	Кэш хугацаа (TTL) хамгаалалт	Гадаад эх сурвалжийн тасралт

Дээрх эмзэглэлүүдээс MongoDB ба API давхаргын нэг цэгийн хамаарал нь **үйлдвэрлэлийн орчинд критик эрсдэл** хэвээр байна. Иймээс replica set, автомат failover, load balancer, нөөц өгөгдлийн эх сурвалжийг дараагийн үе шатны хүсэлтийн бус **зайлшгүй суурь шаардлага** гэж үзнэ.

Архитектурын хэмжигдэх KPI ба баталгаажуулалтын протокол

Архитектурын шийдлүүдийг хэмжигдэх шалгуураар үнэлэхэд API, worker, push урсгалын KPI-г дараах байдлаар тогтоосон: p95 latency $\leq 350\text{ms}$, 5xx алдааны хувь < 1.0

Серверийн арын ажлууд

Серверийн хэсэг нь хэрэглэгчийн хүсэлт боловсруулахаас гадна төлөвлөгөөт арын ажлаар дараах үндсэн ажлуудыг тогтмол гүйцэтгэнэ:

1. Эдийн засгийн мэдээ болон үйл явдлын мэдээллийг шинэчлэх
2. Өндөр нөлөөтэй үйл явдлын талаар хэрэглэгчдэд мэдэгдэл хүргэх
3. Бодит ханш дээр суурилан автомат дохио үүсгэх
4. Серверийн эхлэлд шаардлагатай өгөгдлийг урьдчилан ачаалж гүйцэтгэлийг тогтворжуулах

Дохио үүсгэх арын ажил нь давталтат гогцоогоор (60 секундын хүлээлтийн мөчлөг) ажилладаг. Дотоодын өгөгдлийн эх сурвалжаас зөвхөн бүрэн хаагдсан candle-ийн OHLCV мэдээллийг (“хаалтын” хамгийн сүүлийн бүрэн мөр) татдаг тул яг шинэ минут эхэлсэн агшинд боловсруулалт явагдсан ч одоогоор нээгдэж буй candle-ийн мэдээлэл шинж чанарт орохгүй. Энэ нь ирээдүйн мэдээллийн нэвчилтийн (leakage) үндсэн шалтгааныг өгөгдлийн эх сурвалжийн түвшинд хаах дизайны шийдэл юм. Давхцсан ажиллагааг хаахын тулд MongoDB-д суурилсан job lock механизм ашиглагдаж, нэг мөчид нэг л worker процесс ажилладаг.

Бодит цагийн ханшийн мэдээлэл

Систем нь гол валютын хослолуудын бодит ханшийг тогтмол шинэчилж, кэшийн механизмар давтамжтай хүсэлтийн ачааллыг бууруулан ажилладаг. Энэ нь мобайл талд мэдээлэл тасалдахгүй хүрэх нөхцөлийг бүрдүүлдэг.

3.9. Харагдах хэсгийн архитектур

Харагдах хэсгийн (frontend) зорилго нь серверийн хэсгээс ирэх ханш, дохио, мэдээ, мэдэгдлийг нэгтгэн хэрэглэгчид тасралтгүй хүргэхэд оршино. Энэ судалгаанд мобайл давхаргыг гурван түвшний архитектураар тайлбарлав: (i) нэвтрэлт ба сессийн удирдлага, (ii) өгөгдөл харуулах үндсэн модуль (ханш/дохио/мэдээ), (iii) сервертэй синхрончлол ба алдааны сэргээн оролт. Архитектурын үндсэн зорилго нь мэдээллийн урсгалыг функцийн зорилтоор тусгаарлагдсан модулиар удирдах явдал бөгөөд нэг модулийн өөрчлөлт бусад модулийн ажиллагаанд нөлөөлөхгүйгээр хийгдэх боломжийг бүрдүүлдэг.

Харагдах хэсгийн модулийн бүтэц ба API харилцаа

Харагдах хэсэг нь дөрвөн функциональ модулиас бүрдэнэ. Модуль бүр зөвхөн өөрт хамаарах API endpoint-тай харилцаж, бусад модулийн хамаарлаас бие даасан байдлаар ажиллана. Хүснэгт 3.11 нь тус бүрийн үүрэг ба харилцааны загварыг харуулав.


Хүснэгт 3.11 Харагдах хэсгийн модулиуд, харилцааны загвар ба API endpoint бүлэг

Модуль	Үндсэн үүрэг	Харилцааны загвар	Холбогдох API endpoint
Нэвтрэлтийн модуль	Бүртгэл, нэвтрэлт, токен шинэчлэлт, профайл	REST POST/PUT	/auth/register, /auth/login, /auth/refresh
Ханшийн модуль	Бодит цагийн ханш, 24 цагийн өөрчлөлт, хослол сонгох	REST GET (polling)	/rates/live, /rates/{pair}/history
Дохионы модуль	Дохио жагсаалт, итгэлцэл, SL/TP дэлгэрэнгүй, гүйцэтгэлийн статистик	REST GET + Push	/signals/latest, /signals/{id}, /signals/stats
Мэдээний модуль	Эдийн засгийн мэдээ, үйл явдлын хуанли, AI шинжилгээ	REST GET	/news/feed, /news/calendar

Нэгдмэл архитектурын зураглал

Систем нь хоёр тусдаа өгөгдөл дамжуулах загвар ашиглана: **(A) Polling** — харагдах хэсэг тогтмол хугацааны интервалаар серверт хүсэлт явуулж хариу авах; **(B) Push** — серверийн хэсэг дохио үүссэн үед FCM-ээр шуурхай мэдэгдэх. Хоёр загварыг тусдаа зурагт харуулснаар урсгалын чиглэл тодорхой болно.

(A) REST polling урсгал — харагдах хэсгийн 4 модуль → REST API → серверийн 4 сервис:



Зураг 3.12 Архитектурын зураглал — (A) REST polling урсгал: харагдах хэсгийн модуль бүр тохирох API endpoint-тай шууд холбогдоно

(В) Push мэдэгдлийн урсгал — серверийн хэсгээс FCM-ийг дамжуулан мобайл апп руу:



Зураг 3.13 Архитектурын зураглал — (В) Push мэдэгдлийн урсгал: серверийн хэсэг FCM-ийг дамжуулан апп руу шуурхай мэдэгдэл хүргэнэ. Сумны чиглэл баруунаас зүүн тийш байна.

Унших заавар. (А) зурагт (Зураг 3.12) харагдах хэсгийн модуль бүр зөвхөн өөрт хамаарах нэг API endpoint-тай холбогдоно; давхцал байхгүй. (В) зурагт (Зураг 3.13) мэдэгдлийн сервис FCM-д event явуулж, FCM мобайл апп руу push дамжуулна. Push урсгалын сум баруунаас зүүн тийш байгааг анхаарна уу — polling-аас эсрэг чиглэлтэй.

Өгөгдөл дамжуулах загварын харьцуулалт

Систем дэх өгөгдөл дамжуулах хоёр үндсэн загварыг Хүснэгт 3.12-д харьцуулан нэгтгэв. Энэ ялгаа нь харагдах хэсгийн модуль тус бүрийн ачааллын зан төлөв болон серверийн хэсгийн нөөцийн хуваарилалтад нөлөөлдөг.

Хүснэгт 3.12 Өгөгдөл дамжуулах загварын харьцуулалт

Загвар	Аргачлал	Давтамж	Ашигладаг модуль	Хэрэглэх шалтгаан
REST GET polling	Харагдах хэсэг давтамжаар хүсэлт явуулна	Тогтмол интервал	Ханш, Дохио, Мэдээ	Өгөгдлийн шинэчлэл тогтмол боловч яаралтай биш
REST POST/PUT	Хэрэглэгчийн үйлдлээр нэг удаагийн хүсэлт	Хэрэглэгчийн үйлдлээс хамаарна	Нэвтрэлт	Нэвтрэлт, профайл шинэчлэлт зэрэг төлөв өөрчлөлт
Push notification	Серверийн хэсэг FCM-ээр шуурхай мэдэгдэл илгээнэ	Үйл явдалд суурилсан	Дохионы модуль	Дохио үүссэн үед хэрэглэгчид хоцрогдолгүй мэдэгдэх

WebSocket-ийг сонгоогүй тухай тайлбар. Энэхүү прототипт REST polling + FCM push хослолыг энгийн ажиллагаа, одоогийн дэд бүтцийн нийцэл, хэрэгжилтийн хурдыг харгалзан сонгосон. Гэхдээ энэ нь бүх нөхцөлд WebSocket-оос давуу гэсэн дүгнэлт биш. Ялангуяа /rates/live endpoint-д хэрэглэгчийн тоо өсөх үед polling-ийн нийт ачаалал шугаман өснө (жишээ нь 1,000 хэрэглэгч секунд тутам polling хийвэл 60,000 хүсэлт/минут). Ийм масштабын нөхцөлд WebSocket эсвэл server-sent events, мөн edge cache/CDN шийдэл нь илүү оновчтой байж болох тул архитектурын дараагийн шатанд ачааллын туршилтаар харьцуулж сонгох шаардлагатай.

Системийн гэрээ: автомат шийдвэр ба зөвлөмжийн хил

Архитектурын нэг чухал зарчим бол системийн *автоматаар гүйцэтгэдэг* үйлдэл ба хэрэглэгчид *зөвхөн зөвлөдөг* үйлдлийн хил тодорхой байх явдал юм. Энэ хил нь хэрэглэгчийн хяналт болон арилжааны эрсдэлийн хариуцлагыг архитектурт тусгана.


Хүснэгт 3.13 Системийн гэрээ: автомат ба зөвлөмжийн үйлдэл

Үйлдэл	Ангилал	Тайлбар
OHLCV өгөгдөл татах	Автомат	Scheduler минут бүр серверийг дуудна; хэрэглэгчийн оролцоо шаардахгүй
48 шинж чанар тооцоолох	Автомат	Серверийн хэсэг өгөгдлөөс шинж чанарыг автоматаар тооцоолно
BUY/SELL/HOLD таамаглал	Автомат	GBDT ансамбль загвар soft voting-оор эцсийн дохио гаргана
Итгэлцэл ба ATR шүүлтүүр	Автомат	Босго хангаагүй дохионыг систем өөрөө хасч, DB-д хадгалахгүй
SL/TP тооцоолол	Автомат	ATR-д суурилсан Stop Loss ба Take Profit утгыг серверийн хэсэг тооцоолно
Дохио өгөгдлийн санд хадгалах	Автомат	Шүүлтүүр давсан дохио бүр автоматаар бичигдэнэ
Push мэдэгдэл илгээх	Автомат	FCM-ээр хэрэглэгчид шуурхай мэдэгдэнэ
Арилжаа нээх/хаах	Зөвлөмж	Систем дохио зөвлөдөг; үйлдлийг хэрэглэгч өөрөө шийдэж биелүүлнэ
Байрлалын хэмжээ, хөшүүрэг	Зөвлөмж	Рискийн хэмжээ, ашиглах хөшүүргийг хэрэглэгч тогтооно
Дохионы цаг зөвтгөл	Зөвлөмж	Дохио гарсан ч зах зээлийн нөхцөл өөрчлөгдсөн бол хэрэглэгч эцсийн шийдвэр гаргана

Хүснэгт 3.13-ийн “автомат” мөрүүд нь Зураг 3.10–Зураг 3.11-ын дарааллын диаграммын Scheduler-аас “Өгөгдлийн санд хадгалах” хүртэлх алхамуудтай тохирно. “Зөвлөмж” ангилалтай үйлдлүүд системийн гадна талд, өөрөөр хэлбэл хэрэглэгчийн шийдвэр болон MT5 платформ дээр явагдана. Систем арилжааг автоматаар нээдэггүй бөгөөд энэ нь санаатай архитектурын хязгаарлалт юм: эрсдэлийн эцсийн хариуцлага хэрэглэгчид үлдэнэ.

3.10. Загварын давталтат сайжруулалт

DSR арга зүйн дагуу загварын хөгжүүлэлтийг 7 давталтат (iterative) үе шатаар явуулсан. Үе шат бүрт “бүтээх → үнэлэх → сайжруулах” мөчлөгийг давтаж, өмнөх хувилбарын түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үр дүнд тулгуурлан сул талыг зассан. Зураг 3.14 нь энэ давталтат урсгал болон үе шат бүрийн гол өөрчлөлтийг нэгтгэн харуулав.



Зураг 3.14 Загварын давталтат сайжруулалтын үе шатууд ба гол өөрчлөлтүүд

4. Судалгааны үр дүн

4.1. Үр дүнгийн өгөгдлийн эх сурвалж

Энэ бүлгийн бүх тоон дүнг MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилтын логоудаас гаргав. Логийн нэгтгэлийн дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах боломжийг хангана. Бүрэн зардлын хамралтын хязгаарлалтыг Дүгнэлтийн «Хязгаарлалт» хэсэгт төвлөрүүлсэн бөгөөд босго тус бүрийн холболт ба дахин хэрэгжүүлэх нөхцөлийн дэлгэрэнгүйг Хавсралт Д-аас үзнэ үү.

4.2. Загварын ангилалтын гүйцэтгэл

Судалгааны асуулт 1 (RQ1): “Загвар нь цагийн дарааллыг алдагдуулахгүй тест дээр тогтвортой, найдвартай ажиллах уу?” гэсэн асуултад хариулахын тулд GBDT ансамблийн ангилалтын нарийвчлалыг Walk-Forward Validation (WFOV) схемийн дагуу тусдаа өгөгдлийн хуваарь дээр хэмжив. Хэмжилтийн аргачлал: ансамблийн гурван загварын магадлалыг дундажилж, хамгийн өндөр магадлалтай ангийг *argmax*-аар сонгон нарийвчлал ба F1 оноог sklearn.metrics-р тооцсон. Хуваарилалт: сургалт 2015–2022, баталгаажуулалт 2023, тест 2024 (харагдаагүй өгөгдөл).

Хүснэгт 4.1 GBDT ансамблийн нарийвчлал ба F1 оноо — хуваарь тус бүрээр

Хуваарь	Хугацааны цонх	Нарийвчлал (%)	F1-macro (%)	F1-weighted (%)
Сургалт	2015.01–2022.12	82.71	67.74	80.94
Баталгаажуулалт	2023 бүтэн жил	84.48	62.67	82.29
Тест (out-of-sample)	2024 бүтэн жил	89.25	59.45	87.23

Сургалт ба баталгаажуулалтын нарийвчлалын зөрүү +1.77% (баталгаажуулалт нь сургалтаас өндөр) байгаа нь загвар сургалтын өгөгдөлдөө хэт нийцэж байхгүйг харуулна. Тест нарийвчлал 89.25% нь 2024 оны харагдаагүй өгөгдөл дээр ч тогтвортой гүйцэтгэл хадгалагдаж буйг харуулсан.

F1-macro vs. F1-weighted тайлбар: Энэ нь 3 ангилалтын (BUY / HOLD / SELL) асуудал бөгөөд сургалтын өгөгдлийн 75.6% нь HOLD анги тул F1-macro харьцангуй бага (59–68%) байна. F1-weighted нь ангийн дээжийн тоогоор жинлэдэг тул HOLD-ийн давамгайлалыг тусгаж, 80–87% болж өсдөг. Арилжааны тогтолцоонд ч мөн адил чухал нь HOLD-ийг зөв шүүж, зөвхөн чанартай чиглэлтэй дохиог гаргах явдал юм.

Тестийн өгөгдөл дээрх ангилалт тусдаа (2024)

Хүснэгт 4.2 Тестийн өгөгдөл дээрх ангилалт тусдаа (BUY / HOLD / SELL)

Анги	Precision (%)	Recall (%)	F1 (%)	Дээжийн тоо
BUY	68.24	29.97	41.65	22,405
HOLD	90.24	98.33	94.11	322,186
SELL	75.80	29.60	42.58	26,791

BUY ба SELL ангийн recall харьцангуй бага (30%) нь хоёр шалтгаантай. Нэгдүгээрт, HOLD ангийн 75.6%-ийн давамгайлал загварыг “дохиогүй” гэж таамаглахад ашигтай болгодог. Хоёрдугаарт, итгэлцлийн босго 0.90+ шаардах нь нийт чиглэлтэй дохионы 70% гаруйг шүүж хасдаг. Практикт энэ нь аппликейшны хэрэглэгч өдөрт дунджаар 13.67 дохио хүлээн авах боловч precision өндөр (BUY: 68.24%, SELL: 75.80%) гэсэн утгатай. Нийт чиглэлтэй боломжийн гуравны нэгийг л барьдаг тул

давтамж өндөртэй стратегид тохиромжгүй бол, цөөн боловч чанартай дохио хүлээдэг хэрэглэгчид илүү тохиромжтой.

Итгэлцлийн бүрийн нарийвчлал

Хүснэгт 4.3 *Итгэлцлийн бүрийн нарийвчлал (баталгаажуулалтын өгөгдөл дээр)*

Итгэлцлийн бүр	Нарийвчлал (%)
0.85–0.90	≈72
0.90–0.92	≈84
0.92–0.95	≈91
0.95+	≈97
≥0.90 (нийт)	96.96

Итгэлцлийн босго 0.92 дээш дохионд 91%, 0.95 давсан тохиолдолд 97% нарийвчлалд хүрдэг. Баталгаажуулалтын өгөгдөлд 0.90-өөс дээш дохионы нарийвчлал 96.96% байгаа нь ийм босгын шүүлтүүрийн үндэслэлийг тодорхой харуулна. Шүүлтийн босго нэмэгдэх тусам нарийвчлал дагаад өсөх хандлага ажиглагдсан нь RQ1-ийн хүрээнд загварын тогтвортой байдлыг дэмжиж байна.

4.3. Босгын мужийн нэгтгэсэн үр дүн

Өгөөжийг дараах томъёогоор тооцсон:

$$\text{Return}(\%) = \frac{\text{Final Balance} - 10,000}{10,000} \times 100 \quad (4.1)$$

Хүснэгт 4.4 хүснэгтэд босго өсөхөд дохионы тоо, эцсийн баланс хэрхэн өөрчлөгдсөнийг харуулав.

Хүснэгт 4.4 *0.90–0.99 босгын мужийн харьцуулсан шинжилгээний баталгаажсан дүн*

Босго	Нийт дохио	Дохио/ өдөр	Эцсийн баланс (\$)	Цэвэр ашиг (\$)	Өгөөж (%)	Нэг дохионы ашиг (\$)
0.90	3,567	13.67	58,262.39	48,262.39	482.62	13.53
0.91	3,274	12.54	61,770.46	51,770.46	517.70	15.81
0.92	2,958	11.33	56,512.20	46,512.20	465.12	15.72
0.93	2,643	10.13	46,807.24	36,807.24	368.07	13.93
0.94	2,287	8.76	38,050.13	28,050.13	280.50	12.27
0.95	1,914	7.33	32,844.40	22,844.40	228.44	11.94
0.96	1,588	6.08	33,040.14	23,040.14	230.40	14.51
0.97	1,195	4.58	29,019.19	19,019.19	190.19	15.92
0.98	673	2.58	25,447.43	15,447.43	154.47	22.95
0.99	147	0.56	17,428.89	7,428.89	74.29	50.54

Тайлбар: Дохио/өдөр үзүүлэлтийг Нийт дохио/261 томьёогоор тооцсон (261 нь Forex 24/5 зах зээлийн нөхцөлд Даваа–Баасан 2025 оны хуанлийн ажлын өдрийн тоо). Зардлын хамралтын нарийвчлалыг §4.7.3-г үзнэ үү.

Суурь жишиг: EUR/USD худалдан аваад барих стратеги

Сценарийн дүнг зах зээлийн ерөнхий хөдөлгөөнтэй харьцуулахын тулд EUR/USD-ийн close-to-close худалдан аваад барих жишгийг тооцоов.

Хүснэгт 4.5 EUR/USD худалдан аваад барих жишгийн хураангуй

Үзүүлэлт	Утга
Эхлэл хаалт (2025)	1.03514
Төгсгөл хаалт (2025)	1.17456
Худалдан аваад барих өгөөж (%)	13.47
\$10,000 хөрөнгийн эцсийн баланс (\$)	11,346.87

Тайлбар: Энэ жишиг нь close-to-close энгийн загвар тул стратегийн өгөөжтэй шууд тэнцэхгүй; харин сценарийн дүнг харьцуулахад ашиглав.

Дохионы гүйцэтгэлийн чанар

Түүхэн өгөгдөл дээрх системийн туршилтын логийг босго тус бүрээр задлахад **шүүгдсэн дохионы тоо** болон **бодитоор нээгдэж хаагдсан арилжааны тоо** хооронд тогтвортой зөрүү ажиглагдсан. Энэ зөрүү нь дараах гүйцэтгэлийн механизмтай холбоотой:

- Нэг агшинд зөвхөн нэг байрлал нээх дүрэм (MaxPositions=1)
- Нээлттэй байрлал хаагдахаас өмнөх давхцсан дохионуудыг алгасах
- Зөвхөн тухайн хэрэгсэл дээрх дохиог гүйцэтгэх хязгаарлалт

Иймд гүйцэтгэлийн хувийг
$$E_{\text{хес}}(\%) = \frac{\text{Арилжаа}}{\text{Ачаалагдсан дохио}} \times 100$$
 томьёогоор тооцсон (хүснэгтэд “Loaded” гэж богиносгов). Гарсан 6.45–23.81%-ийн гүйцэтгэлийн хувь нь системийн алдаа бус, **зориудын чанарын шүүлтүүрийн үр дүн** юм — загвар минут бүр таамаглал гаргадаг ч зөвхөн итгэлцлийн босго болон MaxPositions=1 дүрмийг¹ давсан дохио л арилжаа болдог. Break-even ялалтын хувь 25% байна. Босго өсөх тусам арилжааны тоо буурч, итгэлцлийн интервал өргөсдөг.

¹MaxPositions=1: нэг агшинд зөвхөн нэг нээлттэй байрлал (open position) байхыг шаардах хязгаарлалт. “Байрлал” (position) гэдэг нь арилжаа нээгдэж, хаагдаагүй байгаа төлвийг хэлнэ.

Хүснэгт 4.6 Босго тус бүрийн дохио-арилжааны гүйцэтгэл ба ялалтын хувь (95% CI)

Босго	Loaded	Арилжаа	Хөрвөөгүй	Ехес. (%)	TP/SL	Win (%)	95% CI (Win)	E[R]
0.90	3,567	230	3,337	6.45	103/127	44.78	[38.49, 51.24]	0.79
0.91	3,274	212	3,062	6.48	100/112	47.17	[40.56, 53.88]	0.89
0.92	2,958	201	2,757	6.80	95/106	47.26	[40.48, 54.15]	0.89
0.93	2,643	188	2,455	7.11	87/101	46.28	[39.30, 53.41]	0.85
0.94	2,287	154	2,133	6.73	73/81	47.40	[39.68, 55.26]	0.90
0.95	1,914	137	1,777	7.16	65/72	47.45	[39.27, 55.76]	0.90
0.96	1,588	113	1,475	7.12	59/54	52.21	[43.08, 61.20]	1.09
0.97	1,195	106	1,089	8.87	54/52	50.94	[41.56, 60.26]	1.04
0.98	673	76	597	11.29	43/33	56.58	[45.39, 67.14]	1.26
0.99	147	35	112	23.81	23/12	65.71	[49.15, 79.17]	1.63

Тайлбар: Win rate-ийн 95% итгэлцлийн интервалыг Wilson аргаар (хоёртын хувь хэмжигдэхүүний итгэлцлийн интервалын стандарт тооцооллын арга; жижиг түүвэрт нарийвчлалтай) тооцсон. TP/SL=3:1 тогтмол бодлогын дор Expectancy-г $E[R] = p_{\text{win}} \cdot 3 - (1 - p_{\text{win}})$ томъёогоор тооцсон.

Статистикийн тодорхойгүй байдлын нэмэлт нэгтгэл

Босгуудын эцсийн балансын тархалтыг нэгтгэн үзвэл дундаж нь \$39,918.25, стандарт хазайлт нь \$15,171.78, харьцангуй хэлбэлзэл (CV) нь 38.01% байна. Энэ нь шинжилгээний үр дүн босго сонголтод мэдрэмтгий байгааг илэрхийлнэ.

Хүснэгт 4.7 Босгын мужийн лог дээр суурилсан эрсдэл-өгөөжийн шинжилгээ

Босго	MaxDD (%)	Sharpe	Sortino	Calmar	Хамгийн урт дараалсан алдагдал
0.90	3.93	9.11	24.82	122.96	7
0.91	2.97	9.75	25.99	174.20	7
0.92	2.99	9.90	29.78	155.79	7
0.93	9.53	9.21	25.92	38.63	10
0.94	6.80	8.87	24.66	41.23	8
0.95	3.94	8.57	23.97	57.97	6
0.96	4.88	9.84	30.15	47.18	5
0.97	2.96	9.02	24.90	64.19	4
0.98	7.66	10.63	28.84	20.16	8
0.99	1.98	12.83	44.76	37.53	2


Нэр томъёоны тайлбар: MaxDD (Maximum Drawdown) нь балансын оргил цэгээс хамгийн гүн уналтын зай; эрсдэлийн хамгийн чухал хэмжүүрүүдийн нэг. Sharpe ratio нь илүүдэл өгөөжийг нийт хэлбэлзлээр хуваасан харьцаа. Sortino нь доошлох хэлбэлзлийг (downside volatility) л тооцдог Sharpe-ын өөрчлөл. Calmar нь жилийн өгөөжийг MaxDD-д хуваасан харьцаа.

Чухал анхааруулга: Энэ хүснэгтийн Sharpe (9–13), Sortino (24–45), Calmar (20–174) утгууд нь санхүүгийн зах зээлийн нийтлэг стандарт утгуудтай *шууд харьцуулах боломжгүй*. Эдгээр нь хэлцлийн логийн өдрийн баланс дараалалд суурилсан хэмжилт бөгөөд арилжааны тоо цөөн (35–230 хэлцэл), хугацааны цонх богино (1 жил), зардлын бүрэн хамралтгүй нөхцөлд гарсан. Иймд эдгээрийг зөвхөн **босгуудын харьцангуй харьцуулалтын суурь** болгон авч үзэх бөгөөд боломжит хөрөнгө оруулалтын шийдвэрийн үндэс болгохгүй.

Энэ графикаас харахад 0.93 (9.53%) болон 0.98 (7.66%) босгон дээр уналтын эрсдэл харьцангуй өндөр байна. Харин 0.99 дээр MaxDD хамгийн бага (1.98%) боловч нийт өгөөж болон дохионы тоо мэдэгдэхүйц буурсан. Иймээс босго сонгохдоо зөвхөн өгөөж бус, уналтын эрсдэлийг хамтад нь авч үзэх шаардлагатай.

Босго ба гүйцэтгэлийн хувийн хамаарал

Зураг 4.1 зурагт Loaded дохионоос бодитоор арилжаанд орсон хувь буюу гүйцэтгэлийн хувийн өөрчлөлтийг харуулав.




Зураг 4.1 Босгын мужийн шинжилгээ: гүйцэтгэлийн хувийн өөрчлөлт

0.90–0.97 мужид гүйцэтгэлийн хувь харьцангуй ойролцоо, харин 0.98–0.99 дээр өссөн нь өндөр босгонд шүүгдсэн дохионы тоо цөөрөх үед гүйцэтгэгдэх хувийн жин нэмэгдэж байгааг илтгэнэ.

Босго ба ялалтын хувийн хамаарал

Зураг 4.2 зурагт ялалтын хувийг 95% Wilson итгэлцлийн интервалтай хамт error bar хэлбэрээр үзүүлэв.




Зураг 4.2 Босгын мужийн шинжилгээ: ялалтын хувь ба 95% итгэлцлийн интервал

Босго өсөхөд ялалтын хувь дундаж өсөх хандлагатай ч интервал мөн өргөсөж байна. Энэ нь өндөр босго дээр арилжааны тоо багассанаас статистикийн тодорхойгүй байдал нэмэгдэж байгааг илтгэнэ.

Босго ба хүлээгдэж буй өгөөжийн хамаарал

Зураг 4.3 зурагт нэг арилжааны хүлээгдэж буй дундаж үр ашиг буюу хүлээгдэж буй өгөөжийн өөрчлөлтийг харуулав.



Зураг 4.3 Босгын мужийн шинжилгээ: хүлээгдэж буй өгөөжийн өөрчлөлт


Хүлээгдэж буй өгөөж бүх босгон дээр 0-ээс дээш байгаа нь хэрэгжсэн арилжааны түвшинд эерэг хүлээлттэй байгааг харуулна. Гэвч гүйцэтгэлийн хувь, MaxDD, нийт өгөөжтэй хамтад нь авч үзсэний дараа л практик шийдвэрт ашиглах нь зүйтэй.

Хамгийн өндөр өгөөжтэй 3 босгын equity curve

Equity curve нь ML системийн дохионоос гүйцэтгэгдсэн хэлцэл бүрийн дараа аккаунтын балансын хуримтлагдсан хөдөлгөөнийг цагийн дарааллаар харуулдаг цаг хугацааны цуваа (time series) юм.

Тасралтгүй өсөх муруй нь дохионы эерэг гүйцэтгэлийг, уналтын хэсэг нь дараалсан алдагдлыг илэрхийлнэ.

Зураг 4.4 зурагт өгөөжийн хувьд хамгийн өндөр гурван босго (0.91, 0.90, 0.92)-ын equity curve-ийг нэг графикт давхарлан харуулав. Гурван муруй нь ижил эхлэх баланс (\$10,000) болон ижил 1% тогтмол эрсдэлийн бодлогын дор хуримтлагдсан балансын хөдөлгөөнийг илэрхийлнэ. Координатуудыг MetaTrader 5 Strategy Tester-ийн бодит хэлцлийн логоос тооцоолон гаргасан.



Зураг 4.4 Хамгийн өндөр өгөөжтэй 3 босгын equity curve — MT5 бодит хэлцлийн лог дээр суурилсан

Муруйн хэлбэрээс харахад гурван босго нь туршилтын эхний хагаст ижил төстэй замаар өссөн боловч 130–170 дахь арилжааны орчмоос 0.91 босго илт тасарч урагшилсан. 0.92 босго нь 0.90-тэй ойролцоо эцсийн баланстай боловч арилжааны тоо цөөн (201 vs 230) тул equity муруй жигд байна.

4.4. Үр дүнгийн тайлбар

Энэ хэсэг нь дээрх 10 түүхэн өгөгдөл дээрх системийн туршилтын логийн нэгтгэлд тулгуурласан нөхцөлт дүгнэлт юм.

Үр дүнг ерөнхийлөн дүгнэх боломжийн хүрээ (scope of validity)

Энэ бүлгийн тоон үр дүн нь дараах нөхцөлд хүчинтэй: (i) EUR/USD хэрэгсэл, (ii) 2025.01.01–2026.01.01 туршилтын цонх, (iii) EA-ийн тогтмол дүрмүүд (нэг агшинд нэг байрлал). Зардлын бүрэн хамралтын хязгаарлалтыг Дүгнэлтийн «Хязгаарлалт» хэсэгт төвлөрүүлсэн.

Хүснэгт 4.8 *Сценарийн дүгнэлтийг ерөнхийлөн дүгнэх боломжийн түвшин*

Дүгнэлтийн төрөл	Статус	Тайлбар
0.90–0.99 босгын мужийн харьцуулалт	Батлагдсан	Энэ судалгааны өгөгдөл, дүрэм, зардлын нөхцөлд сценарийн харьцуулалт хэлбэрээр батлагдсан
0.91 босгыг универсал оновчтой гэж үзэх	Батлагдаагүй	Локал дээд цэг байж болох ч өөр хугацааны цонх, өөр хэрэгсэл дээр дахин баталгаажуулах шаардлагатай
Олон хэрэгсэлд шууд өргөтгөх	Батлагдаагүй	EUR/USD-ээс гаднах хэрэгсэл дээр тусдаа out-of-sample туршилт хийгдээгүй
Бүрэн зардлын хамралт	Хэсэгчлэн батлагдсан	Дэлгэрэнгүй хязгаарлалтыг §4.7.3-т төвлөрүүлсэн

Сценарийн хүрээнд ажиглагдсан дээд цэг

Тухайн цонхны харьцуулалтад хамгийн өндөр эцсийн баланс 0.91 босгон дээр \$61,770.46 (+517.70%) гарсан. Энэ бол универсал оновчтой босго биш, харин тухайн өгөгдөл ба дүрмийн хүрээнд ажиглагдсан локал дүн юм.

Уг дүн “3,274 loaded дохио → 212 хэрэгжсэн арилжаа” нөхцөлд гарсан; бүх дохионд ижил хэрэгжилт гарна гэж үзэхгүй. MaxDD=2.97%, Sharpe=9.75, Sortino=25.99, Calmar=174.20 үзүүлэлтүүдийг (Хүснэгт 4.7) сценари хооронд харьцуулах суурь болгож ашиглав.

Чанар-тоо хэмжээний зөрчил

Хүснэгт 4.4-аас харахад босго 0.90-ээс 0.99 хүртэл өсөхөд нийт дохио 95.88%-аар буурч нийт өгөөж буурсан боловч, нэг дохионы дундаж ашиг \$13.53-аас \$50.54 болж өссөн.

Өндөр итгэлцэлтэй дохио цөөрөх тусам нэг дохионы үр ашиг өсч болох ч нийт давтамж хэт багасснаас хуримтлагдсан ашиг буурдаг. Дээжийн хэмжээний нөлөөг хамтад нь авч үзэх шаардлагатайг [23, 24] онцолдог.

Босго сонголтын зарчим

Энэ бүлгийн зорилго нь урьдчилан тогтоосон босгуудын оролт-үр ашгийн тэнцвэрийг ижил нөхцөлд харьцуулах явдал бөгөөд ажиллах үед босгыг динамикаар тааруулах биш. Локал дүн ба ерөнхийшүүлэх хязгаарын тайлбарыг Хүснэгт 4.8 хүснэгтэд нэгтгэсэн.

0.95 ба 0.96 дээр жижиг зөрүү ажиглагдсан (\$32,844.40 → \$33,040.14). Энэ нь босгоос гадна тухайн хугацаанд таарсан хэлбэлзэл, байрлал хаагдах дараалал зэрэг гүйцэтгэлийн түвшний хүчин зүйлс үр дүнд нөлөөлдгийг харуулна.

Арга зүйн эрсдэлийн нэгдсэн тайлбар

Хүснэгт 4.9 Арга зүйн эрсдэлийн нэгдсэн хүснэгт (энэ хувилбар)

Эрсдэл	Нөлөө	Энэ тайлан дахь хяналт	Үлдэгдэл эрсдэл
Label leakage	Өндөр	Цагийн дарааллын дүрэм, backward нэгтгэл, split тусгаарлалт	Бүрэн үгүйсгээгүй
WFV нэг огтлолын нэгтгэл	Дунд-өндөр	WFV хүрээ хэрэглэсэн, нэг огтлолд төвлөснийг ил тод заасан	Олон огтлолтын дундаж дутуу
Execution selection bias	Өндөр	Loaded vs Executed ялгааг хүснэгтээр нэгтгэн харуулсан	Нөхцөлт тайлбар шаардлагатай
Зардлын модел дутуу	Дунд	Spread/slippage тусгасан, хамралтын матриц нэмсэн	Дэлгэрэнгүйг Дүгнэлтийн «Хязгаарлалт» хэсэгт төвлөрүүлсэн
Тохируулгын туршилтын ажиглалт (сургалт-үйлчилгээний зөрүү)	Дунд	Тохируулгыг баталгаажуулалтын огтлол дээр туршилтын ажиглалтаар шалгасан, ажиллах үеийн дүнг түүхий магадлалаар тайлагнасан	Ажиллах орчны баталгаажуулалт дутуу
Эрсдэлийн шинжилгээний лог-суурь тооцоолол	Дунд	MaxDD/Sharpe/Sortino/Calmar/losing streak-ийг босго бүрт нэгтгэн харуулсан	MT5 statement-level official metric-тэй бүрэн кросс-валидаци дутуу
Босгын өгөгдлийн хэт сонголт	Дунд	Сонголтыг түгжиж баталгаажуулах протокол тайлбарласан	Баталгаажуулалтын шат бүрэн тусгаагүй

Практик шийдвэр гаргалтын хүрээ

Энэ судалгааны шинжилгээний хүрээнд дараах байдлаар практик тайлбар хийж болно.

- **Эрсдэл-өмнөх шалгуур:** CV харьцангуй бага, MaxDD хэт өсөөгүй, хамгийн урт дараалсан алдагдал богино, win rate-ийн 95% CI хэт өргөн биш, мөн Expectancy (R) тогтвортой эерэг мужийг давуу үзэх
- **Нийт өгөөжийг** түлхүү зоривол: энэ шинжилгээний хүрээнд 0.90–0.92 муж нөхцөлт практик сонголт болж ажиглагдсан
- **Дохионы тоог** багасгаж, зөвхөн өндөр итгэлцэлтэй оролт хүсвэл: 0.97+ мужийг нөхцөлтөөр авч үзэж болно
- **Тэнцвэрт сонголт:** 0.90–0.92 муж нь нийт өгөөж ба давтамжийн харьцаагаар хамгийн тэнцвэртэй мужаар ажиглагдсан

4.5. Архитектурын KPI-н баталгаажуулалтын үр дүн

Баталгаажуулалтын протокол (Methodology-д тодорхойлсон) нь API давхарга, worker урсгал, push урсгалын хэмжигдэх шалгуурыг тогтоосон. Энэ хэсэгт тухайн протоколын дагуу явуулсан

туршилтын бодит дүнг тайлагнана. Хэмжилтийн нөхцөл, методология, болон дэлгэрэнгүй үнэлгээний дүнг Хавсралт Г-аас үзнэ үү.

API давхаргын KPI: latency ба алдааны хувь

Хүснэгт 4.10 API давхаргын KPI: хэмжигдсэн дүн ($n=30$ хүсэлт/endpoint)

Endpoint	Зорилтот p95	Хэмжигдсэн p50	Хэмжигдсэн p95	Биелэлт	Тайлбар
/health	≤ 350 ms	448 ms	536 ms	Хэтэрсэн	Дундаж Токио→орон нутаг RTT
/rates/live	≤ 350 ms	375 ms	471 ms	Хэтэрсэн	Кэшлэгдсэн endpoint
/signals/latest	≤ 350 ms	413 ms	482 ms	Хэтэрсэн	MongoDB query + сериалчлал

Хүснэгт 4.11 API давхаргын 5xx алдааны хувь ($n=90$ нийт хүсэлт)

KPI	Зорилтот босго	Хэмжигдсэн утга	Биелэлт
5xx алдааны хувь	< 1.0%	0.0%	Хангасан ✓

Тайлбар: 90 хүсэлтийн аль нэг нь ч 5xx кодтой хариу өгөөгүй. HTTP 200 хариугийн хувь 100% байв.

API давхаргын p95 latency 471–536ms байсан нь зорилтот 350ms-ийг хэтэрсэн. Гол шалтгаан нь хэмжилтийн эх цэг (Улаанбаатар) ба сервер (Токио) хоорондын RTT юм. Нийт хоцролтын задаргааг дараах байдлаар тайлбарлана:

- **Сүлжээний RTT** (Улаанбаатар → Токио): $\approx 150\text{--}180$ ms
- **Серверийн боловсруулалт** (Flask + MongoDB query): ≈ 300 ms
- **Нийт p95** ≈ 471 ms ✓

Иймээс p95 latency зорилт биелээгүй шалтгааныг зөвхөн сүлжээний гадаад нөлөө гэж үзэхгүй; серверийн байршлыг Токио болгон сонгосон архитектурын шийдвэр өөрөө энэ зөрүүнд шууд нөлөөлсөн. Энэ нь **архитектурын гүйцэтгэлийн зөрүү** бөгөөд дараах гурван чиглэлд шийдвэрлэх боломжтой: (1) серверийг хэрэглэгчийн бүсэд (Улаанбаатар, Зүүн Ази) ойртуулах бүсчлэл (regional deploy), (2) ‘/rates/live’ зэрэг байнга хандагддаг endpoint-д CDN/edge cache нэмэх, (3) MongoDB query-г индекс оновчлол болон холболтын санг (connection pooling) сайжруулах замаар ≈ 300 ms-ийн боловсруулалтын хугацааг бууруулах. Эдгээр шийдлийг хэрэгжүүлсний дараа p95 зорилтыг хангах нь техникийн хувьд боломжтой гэж үзэж байна.

Worker болон Push үйлчилгээний архитектурын байдал

Worker урсгал нь Python threading-д суурилсан бөгөөд минут бүр өгөгдөл татаж, GBDT ансамблиар таамаглал хийж, MongoDB-д хадгалах мөчлөгийг автоматаар гүйцэтгэдэг. Firebase FCM-

ээр дамжуулан шинэ дохио үүсэх бүрт мобайл апп руу push мэдэгдэл илгээгддэг. Эдгээр бүрэлдэхүүнүүд прототипийн орчинд тогтвортой ажиллаж байгаа боловч бүтээмжийн хэмжилтийн (Prometheus, structured log counter) нэгдсэн дэд бүтэц дараагийн шатны инженерчлэлийн ажилд хамаарна.

KPI хураангуй

Хүснэгт 4.12 API давхаргын KPI баталгаажуулалтын хураангуй

Компонент	KPI	Зорилтот	Хэмжигдсэн	Биелэлт
API давхарга	p95 latency	≤ 350 ms	471–536 ms	Зорилтоос хэтэрсэн; RTT нөхцөл нь тайлбарлана
API давхарга	5xx алдааны хувь	$< 1.0\%$	0.0%	Хангасан ✓

4.6. Дахин хэрэгжүүлэх боломж ба орчны нөхцөл

Энэ бүлгийн үр дүнг дахин хэрэгжүүлэхэд дараах нөхцөлүүдийг тогтмол хадгалах шаардлагатай: MT5 логийн нэгтгэлийн дүрэм ((timestamp, symbol) гэсэн compound index), дохио бүрийн model_version ба run_id ул мөр, мөн гүйцэтгэлийн EA тохиргоо (Хүснэгт 3.4-ийн параметрууд). Дохионы давхардлаас сэргийлэхийн тулд MongoDB-д upsert=True болон compound unique index хэрэгжүүлсэн бөгөөд энэ нь ижил дохиог дахин бичих эрсдэлийг прототипийн түвшинд бууруулсан. Дэлгэрэнгүй нөхцөл ба протоколын жагсаалтыг Хавсралт Д-аас үзнэ үү.

4.7. Дүгнэлт

Судалгааны гол үр дүн

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан Форекс зах зээлийн арилжааны дохионы системийг хөгжүүлсэн. Үр дүнг дараах байдлаар нэгтгэн дүгнэв.

- Машин сургалтын ансамбль загвар:** LightGBM, XGBoost, CatBoost гурван GBDT загварыг нэгтгэж, 6 хугацааны интервалын 48 шинж чанараар EUR/USD-ийн чиг хандлагыг BUY/SELL/HOLD гурван ангилалд таамагласан. 7 давталтат хөгжүүлэлтээр 75→48 шинж чанар, 9→3 загвар болгон хялбарчилж хэт нийцлийн эрсдэлийг бууруулсан. Нарийвчилсан үнэлгээний үзүүлэлтийг Хүснэгт 4.1 ба Хүснэгт 4.3-т тайлагнасан (RQ1).
- Түүхэн өгөгдөл дээрх системийн туршилтын гүйцэтгэл:** 0.90–0.99 мужийн сценарийн харьцуулалтад бүх босго эерэг өгөөжтэй гарсан. Дохио-арилжааны гүйцэтгэл, ялалтын хувь, хүлээгдэж буй өгөөж, болон уналтын хэмжээг хэрэгжсэн арилжааны хүрээнд тайлбарласан. MaxDD, Sharpe, Sortino, Calmar зэрэг эрсдэлийн үзүүлэлтүүдийг босго бүрээр харьцуулсан.
- Инженерчлэлийн хэрэгжүүлэлт:** §3.2-т тайлбарласан загвар сургалт → дохио үүсгэх → мобайл апп гэсэн нэгдмэл өгөгдөл боловсруулах урсгал (pipeline) прототипийн түвшинд бүрэн хэрэгжсэн.

Судалгааны практик хувь нэмэр

- **Нэгдмэл үнэлгээний хүрээ:** Ангиллын нарийвчлал, Wilson итгэлцлийн интервал, эрсдэлийн матриц, ерөнхийшүүлэх боломжийн хязгаарыг нэг дор тайлбарласан нь финтек судалгааны ил тод байдлын стандартад нийцнэ.
- **Олон давхаргын нэгтгэл:** Загварын математик гүйцэтгэл, серверийн хэсгийн ажиллагаа, мобайл аппликейшны харагдах хэсгийг нэг туршилтын хүрээнд үнэлсэн нь академик хүрээнээс давсан системийн инженерчлэлийн жишиг.
- **Монгол хэл дээрх техникийн баримтжуулалт:** Машин сургалт, санхүүгийн нэр томъёоны Монгол тайлбар тольтой судалгааны бичвэр нь энэ чиглэлийн дотоодын судалгааны суурь болж чадна.

Хязгаарлалт

1. **Хамрах хүрээ:** EUR/USD хэрэгсэл, сонгосон хугацааны цонхонд батлагдсан тул өөр валютын хослол, брокерт шууд ерөнхийшүүлэхгүй
2. **Шошгын нэвчилтийн үлдэгдэл эрсдэл:** Олон интервалын нэгтгэхэд хугацааны дүрэм мөрдсөн ч бүрэн үгүйсгээгүй
3. **Гүйцэтгэлийн хөрвүүлэлтийн хэлбийлт:** Гүйцэтгэлийн хувь 100% биш үед ялалтын хувь, хүлээгдэж буй өгөөж нь хэрэгжсэн арилжаанд нөхцөлт
4. **Статистикийн чухал ач холбогдлын шинжилгээ дутуу:** Ансамблийн загваруудыг харьцуулахад McNemar's test зэрэг тодорхой статистикийн чухал ач холбогдлын шинжилгээ хийгдээгүй; арилжааны тоо цөөн (35–230 хэлцэл) нь статистикийн хүчтэй дүгнэлт гаргахад хязгаарлалт үүсгэнэ
5. **Арилжааны зардлын хамралт:** MetaTrader 5-ийн бодит спрэд болон 10 point-ийн гулсалтын хязгаар тусгасан. Гэхдээ брокер тус бүрийн шимтгэл (commission) болон шөнийн байрлал хадгалалтын зардал (swap) энэ хувилбарт тусгаагүй. Шимтгэл нь брокерын нөхцөлөөс ихээхэн хамаарах тул тодорхой тоон утгаар загварчлахын оронд хязгаарлалт болгон тэмдэглэн, өгөөжийн дүнг сценарийн харьцуулалтын хүрээнд тайлбарлав. Бодит орчинд хэрэглэхийн өмнө тухайн брокерын шимтгэл болон свопыг нэмж тооцох нь зайлшгүй.
6. **Тохируулга ба сургалт-үйлчилгээний зөрүү:** Офлайн тохируулгыг туршилтын ажиглалтаар шалгасан; ажиллах үеийн түүхий магадлалтай ялгаанаас үлдэгдэл эрсдэл үүсч болно
7. **Бодит цагийн хүндрэл:** Гадаад системийн API хязгаарлалт, сүлжээний саатал зэрэг техникийн асуудлууд

Цаашдын чиглэл

1. **Олон валютын хослолд өргөтгөх:** GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, багц стратеги бүтээх
2. **Дагах зогсоол:** Ашгийг хамгаалах динамик SL-ийн аргачлалыг сайжруулах

3. **Гүн сургалтын загвар:** Цаашдын ажилд LSTM, Transformer загваруудыг GBDT ансамбльд нэмж, цагийн цуваа дотрох хамаарлыг илрүүлэх чадамжийн хувьд GBDT-тэй харьцуулан үнэлэх боломжтой
4. **Бататгалтат сургалт:** Багцын менежмент, байрлалын хэмжээ тохируулалтад хэрэглэх
5. **Мэдээний шинжилгээ:** Хэлний боловсруулалт ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах
6. **Түгээлт ба MLOps:** Google Play түгээлтийн сувгийг нэвтрүүлж, загварын шилжилтийн мониторинг, хувилбар гаргалтын автоматжуулалтыг өргөтгөх
7. **Загварын хувилбарын удирдлага ба буцаах протокол:** Дохио бүрт `model_version` ба `run_id` талбар хадгалж ул мөрдөх боломж бүрдсэн боловч `formal Model Registry`, `approve/promote workflow`, автоматаар `rollback` хийх протокол бүрэн хэрэгжээгүй хэвээр байна. Иймд энэ хэсэг нь дараагийн инженерчлэлийн ажлын гол шаардлага хэвээр үлдэнэ.

Эцсийн дүгнэлт

Судалгааны гурван асуултад дараах байдлаар хариулав:

RQ1 (загварын тогтвортой байдал): Загвар харагдаагүй 2024 оны өгөгдөл дээр тогтвортой ажиллаж буйг харуулсан — нарийвчилсан үзүүлэлтийг Хүснэгт 4.1 ба Хүснэгт 4.3-т үзнэ үү.

RQ2 (дохио хэрэгжих чадвар): Гүйцэтгэлийн хувь нь зориудын чанарын шүүлтүүрийн үр дүн; хэрэгжсэн арилжааны хүлээгдэж буй өгөөж бүх босгон дээр эерэг гарсан (Хүснэгт 4.6).

RQ3 (урт хугацааны ашигт ажиллагаа): Бүх 10 сценарийн өгөөж, уналтын хэмжээний нарийвчилсан дүнг Хүснэгт 4.4 ба Хүснэгт 4.7-т нэгтгэсэн.

Дүгнэлт нь EUR/USD хэрэгсэл, 2025 оны туршилтын цонх, зардлын тусгагдаагүй бүрэлдэхүүнүүдийг харгалзах нөхцөлд хүчинтэй тул шууд ерөнхийшүүлэхгүй. Практикт эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох протокол зайлшгүй шаардлагатай.

Нэгтгэн дүгнэвэл, энэ судалгааны гол хувь нэмэр хоёр талтай. Нэгдүгээрт, загвар сургалтаас серверийн хэсэг, мобайл аппликейшны харагдах хэсэг хүртэлх бүрэн урсгалыг нэг инженерчлэлийн хүрээнд прототипийн түвшинд хэрэгжүүлсэн. Хоёрдугаарт, машин сургалтын академик үнэлгээг практик системийн гүйцэтгэлтэй зэрэгцүүлэн нэг шинжилгээний хүрээнд авч үзсэн нь финтек судалгааны уламжлалт арга зүйгээс давсан ач холбогдолтой.

- [1] Bank for International Settlements. Triennial central bank survey: Foreign exchange turnover in april 2022, 2022.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.
- [3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.
- [4] Joarder Kamruzzaman and Ruhul A. Sarker. Forecasting of currency exchange rates using ANN: A case study. *Journal of Financial Forecasting and Analysis*, 1(1):1–15, 2003.
- [5] M. Kumar and M. Thenmozhi. Forecasting stock index movement: A comparison of SVM and random forest. *Indian Institute of Capital Markets Working Paper*, 1(1):1–22, 2006.
- [6] Michel Ballings, Dirk Van den Poel, Niels Hespeels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.
- [7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.
- [8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review. *Applied Soft Computing*, 97, 2019.
- [9] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2):689–702, 2017.
- [10] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [11] Shihao Gu, Bryan T. Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [12] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [13] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.
- [14] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [15] Omer Berat Sezer, Mehmet U. Gudelek, and A. Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [16] Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.

- [17] John J. Murphy. *Technical Analysis of the Financial Markets*. New York Institute of Finance, 1999.
- [18] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis. *The Journal of Finance*, 55(4):1705–1765, 2000.
- [19] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.
- [20] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.
- [21] Ben R. Marshall, Ros Cahan, and Jean M. Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.
- [22] Cheol-Ho Park and Scott H. Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.
- [23] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.
- [24] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.
- [25] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023.
- [26] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O’Reilly Media, 2nd edition, 2018.
- [27] Miguel Grinberg. *Flask Web Development: Developing Web Applications with Python*. O’Reilly Media, 2nd edition, 2018.
- [28] Alan R Hevner, Salvatore T March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.
- [29] Ken Peffers, Tuure Tuunanen, Marcus A Rothenberger, and Samir Chatterjee. A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77, 2007.

Хавсралт

Хавсралт А: Гиперпараметрийн дэлгэрэнгүй

Гиперпараметрийн бодит утгуудын хүснэгт

Доор гурван загварын эцэст сонгогдсон гиперпараметрийн бодит утгуудыг нэгтгэн харуулав. Параметр сонголтын аргачлал, тогтвортой байдлын протокол, early stopping болон тогтмолжуулалтын нарийвчилсан тайлбарыг Аргазүйн бүлгийн §3.4-т үзнэ үү.

Гиперпараметрийн дэлгэрэнгүй үзүүлэлтүүд

Хүснэгт 4.13 Гурван суурь загварын сонгогдсон гиперпараметрууд

Параметр	LightGBM	XGBoost	CatBoost
max_depth	5	5	6
num_leaves	32	—	—
learning_rate	0.03	0.03	0.03
n_estimators	200	200	200
subsample	0.8	0.8	0.8
colsample_bytree	0.8	0.7	0.8
reg_alpha (L1)	0.01	0.01	0.01
reg_lambda (L2)	0.1	0.1	0.1
early_stopping_rounds	50	50	50
min_data_in_leaf	20	—	—
min_child_weight	—	1	1

Тайлбар: Бүх гурван загварт модны гүнийг 5–6-р хязгаарлаж, learning rate-ийг 0.03 байлгасан. Early stopping patience нь 50 давталт байв. L1/L2 тогтмолжуулалт нь загварын ерөнхийлөн суралцах чадварыг нэмэгдүүлэхэд ашиглагдав.

Хэт нийцлээс сэргийлэх арга хэмжээ ба шинж чанарын сонголт

Хэт нийцлээс сэргийлэх зургаан арга хэмжээ (модны гүн хязгаарлалт, learning rate=0.03, early stopping patience=50, L1/L2 тогтмолжуулалт, урагш гүйлгэн баталгаажуулалт, шинж чанарын хялбарчлал) болон 75 шинж чанараас 48-д шилжсэн шалтгааны дэлгэрэнгүй тайлбарыг Аргазүйн бүлгийн §3.4-ийн “Гиперпараметр сонголтын протокол” ба “Шинж чанарын инженерчлэл” дэд хэсгүүдэд үзнэ үү. Эцэст сонгогдсон 8 шинж чанар (close, RSI-14, ATR-14, MA-5, MA-20, MA-50, volatility-20, returns) нь хэлбэлзэл, импульс, чиг хандлагын гурван өнцгийг хамарна.

Хавсралт Б: Leakage audit-ын дэлгэрэнгүй дүрэм

Цагийн нийцлийн дүрэм

Мэдээллийн нэвчилтээс (leakage) сэргийлэх цагийн нийцлийн үндсэн томъёо (томъёо 3.2) болон ерөнхий тайлбарыг Аргазүйн бүлгийн §3.3-т (“Шошго ба шинж чанарын цагийн нийцлийн аудит” дэд хэсэг) үзнэ үү. Доор компонент бүрийн нарийвчилсан аудитын дүрмийн хүснэгтийг харуулав.

Leakage audit дүрмүүдийн дэлгэрэнгүй тайлан

Хүснэгт 4.14 *Leakage audit-ын цагийн нийцлийн дүрмүүд*

Компонент	Үйлдэл	Цагийн нөхцөл	Leakage эрсдэл
OHLCV өгөгдөл	t_0 -д хаалтын ханш ба үзүүлэлтүүдийг ашиглах	$t_{\text{candle}} < t_0$	Бага (хаалтны мэдээлэл хэмжээст мэдэгдэх)
MA (движуш. дундаж)	t_0 -г оруулаад өмнөх 50 шоосны дундаж	$t_{\text{MA window}} < t_0$	Бага (историко мэдээлэл)
RSI, ATR	t_0 -г оруулаад өмнөх өгөгдлөөс тооцох	$t_{\text{period}} \leq t_0$	Бага
240 минутын label	t_0 -ээс дараах 240 минутын хамгийн дээд/доод	$t_{\text{label}} > t_0$	ӨНДӨР (future data)
Олон интервалын синхрончлол	merge_asof(direction=backward)	$t_{\text{small}} \leq t_{\text{large}}$	Дунд (boundary алдаа)

Тайлбар: merge_asof(backward) болон хугацааны тусгаарлалтын дүрэм нь leakage эрсдэлийг бууруулдаг ч олон интервалын синхрончлолын үлдэгдэл эрсдэлийг бүрэн үгүйсгэхгүй. Иймээс үр дүнг тайлбарлахдаа энэ эрсдэлийг хязгаарлалтын хүрээнд хамтад нь авч үзсэн.

Хавсралт В: Урагш гүйлгэн баталгаажуулалтын олон огтлолын схем

WFV олон огтлолт (expanding window) протокол

Урагш гүйлгэн баталгаажуулалтыг цаг хугацааны дараалал хадгалсан **олон огтлолт, өргөтгөх сургалтын цонх** (expanding window) протоколоор хэрэгжүүлсэн. Өөрөөр хэлбэл Fold 1–Fold 5 огтлол бүрт сургалт→баталгаажуулалт→тестийн алхмыг урагшлуулан давтаж, ирээдүйн мэдээлэл сургалтад нэвтрэх эрсдэлийг хязгаарласан.

Олон огтлолтын ерөнхий алхамт логик:

1. Эхний хугацааны огтлолд өмнөх жилүүдээр загвар сургана (Fold 1: 2015–2017)
2. Дараагийн хугацааны огтлолд баталгаажуулалт/шалгалт (early stopping, calibration) хийнэ
3. Дараагийн огтлол руу шилжихдээ сургалтын цонхыг урагшлуулж дахин сургана (Fold 2: 2015–2018, ..., Fold 5: 2015–2022)
4. Эцсийн үнэлгээнд сүүлийн огтлолын (Fold 5) түүврийн гадуурх (out-of-sample) гүйцэтгэлийг ашиглана (2024 тестийн өгөгдөл)

WFV олон огтлолын концепцын схем



Зураг В.1 *WFV олон огтлолын ерөнхий концепцын схем (Fold 1–Fold 5 expand window protocol)*

Тайлбар: Энэ схем нь Fold 1–Fold 5 протоколыг **нэг зурагт** жилээр нь харуулсан: бүх Fold-ийн сургалт 2015-аас эхэлж, Fold өсөх тусам сургалтын цонх өргөжин, баталгаажуулалт ба тестийн цонх урагш шилжинэ. Энэ судалгааны KPI үнэлгээнд нэг огтлолын (Fold 5) дэлгэрэнгүй хуваалт ашиглагдсан (үндсэн бичвэрийн Figure 4.6-г үзнэ үү).

Хавсралт Г: Архитектурын KPI-ийн хэмжилтийн нөхцөл

Архитектурын хэмжигдэх KPI ба баталгаажуулалтын протокол

Архитектурын шийдлүүдийг зөвхөн бүтэц дүрслэлээр бус хэмжигдэх шалгуураар үнэлэх зорилгоор дараах баталгаажуулалтын протокол нэгтгэсэн. Энэ протокол нь API, worker, push урсгалын ажиллах чанарыг ижил нөхцөлд давтан шалгах үндсэн хүрээг тогтооно.

Хүснэгт 4.15 *Архитектурын баталгаажуулалтын KPI протокол*

Компонент	KPI	Зорилтот босго	Баталгаажуулах арга
API давхарга	p95 latency	$\leq 350\text{ms}$	Ижил endpoint дээр 15 минутын тогтмол ачааллын туршилт, median/p95-г нэгтгэн тайлагнах
API давхарга	5xx алдааны хувь	$< 1.0\%$	Ачааллын туршилтын хугацаанд нийт хүсэлтэд харьцуулж тооцох
Worker урсгал	Job completion rate	$\geq 99\%$	Төлөвлөгөөт ажлын log мөрөөр амжилт/алдааны харьцааг өдөр тутамд тооцох
Worker урсгал	Retry recovery rate	$\geq 95\%$	Алдаатай job-ийн дахин оролдлогоос амжилттай сэргэсний хувийг хэмжих
Push урсгал	Notification delivery rate	$\geq 98\%$	Push сервисийн нийлбэр илгээлт ба хүрсэн мэдэгдлийн тоог харьцуулах

Хэмжилтийн нөхцөл

API давхаргын p95 latency хэмжилтийг дараах нөхцөлд явуулсан:

- **Эх цэг:** Улаанбаатар (Mongolia)
- **Серверийн байршил:** Токио (Tokyo, Fly.io)
- **Сүлжээний RTT:** дунджаа 150–180ms
- **Хүсэлтийн тоо:** Эндпойнт тутамд n=30 хүсэлт
- **Ачааллын загвар:** Дараалсан (sequential) ачаалал, өөр өөр 3 endpoint-т
- **Хэмжилтийн хугацаа:** 15 минут (900 сек), тасралтгүй

Worker ба Push урсгалын KPI:

- **Worker job completion:** Өдөрт 50–100 ажил процесс хийгдэж, лог дээр бичигдэнэ
- **Worker scheduling:** Python threading (time.sleep мөчлөгт суурилсан) ашиглан минут бүр дохио үүсгэх мөчлөгийг гүйцэтгэдэг
- **Push delivery:** Firebase FCM платформ, хүргэлтийн статистик FCM console-ээр тайлагнана

p95 latency зорилтот босгоос хэтрэлтийн дүн шинжилгээ

API давхаргын p95 latency 471–536ms байсан нь зорилтот 350ms-ийг хэтэрсэн. Үндсэн шалтгааны дүн шинжилгээ:

1. **Сүлжээний RTT нөлөө:** Улаанбаатараас Токиогийн сервер хүртэлх RTT дунджаа 150–180ms байдаг тул сүлжээний холболтын орыг зохисон хүлээлтэнд оруулах шаардлагатай
2. **MongoDB query latency:** /signals/latest endpoint-т MongoDB дээр дохиог авах query хэрэгтэй бөгөөд үндсэн database-д индекс оновчлол хийхээр үлдсэн
3. **Сериалчлалын ачаалал:** JSON сериалчлалын үед томоохон объектын цуглуулгыг үйлдэх үйлүүлэгдсэн
4. **Кэшлэлтийн хомсдол:** /rates/live-ийн үр дүнг Redis кэш-д байнаар хадгалснаас гадна, түүвэр дүүргэлтийн үедээ кэш сайн ажиллавал бууна

Практик сайжруулах сонголтууд:

- MongoDB дохионы хадгалалтад (timestamp, symbol, timeframe) compound unique index + upsert бодлого хэрэгжүүлэх (idempotency)
- Серверийн бүсчлэлийг хэрэглэгчийн байршилд ойртуулах, эсвэл CDN/edge cache ашиглах
- Redis multi-tier кэшлэл (L1 in-memory, L2 Redis)
- Мейл query-ийн цуврал хүсэлт (batch requests) хийх

Хавсралт Д: Эх сурвалжийн нэгтгэлийн дүрэм

Үр дүнгийн өгөгдлийн эх сурвалж ба reproducibility

Энэ бүлгийн бүх тоон дүнг түүхэн өгөгдөл дээрх системийн туршилтын логоудаас гаргав. Лог файлууд нь хуримтлагдсан (append) бүтэцтэй тул өмнөх гүйлтийн мөрүүд дараагийн файлд давтагддаг. Иймээс босго бүрийн run-ыг Loaded signals мөрөөр таньж, тухайн run-т харгалзах final balance болон TP/SL мөрүүдтэй тогтмол дүрмээр хослуулан нэгтгэл хийв. Энэ дүрэм нь ижил өгөгдөл дээр дахин тооцоход ижил үр дүн гаргах нөхцөлийг хангана.

Босго тус бүрийн нотолгооны индексжүүлсэн холболт

Хүснэгт 4.16 Босго тус бүрийн нотолгооны индексжүүлсэн холболт (reproducibility reference)

Босго	Дохио индекс	Баланс индекс	Дохионы тоо	Эцсийн баланс (\$)
0.90	SIG-090	BAL-090	3,567	58,262.39
0.91	SIG-091	BAL-091	3,274	61,770.46
0.92	SIG-092	BAL-092	2,958	56,512.20
0.93	SIG-093	BAL-093	2,643	46,807.24
0.94	SIG-094	BAL-094	2,287	38,050.13
0.95	SIG-095	BAL-095	1,914	32,844.40
0.96	SIG-096	BAL-096	1,588	33,040.14
0.97	SIG-097	BAL-097	1,195	29,019.19
0.98	SIG-098	BAL-098	673	25,447.43
0.99	SIG-099	BAL-099	147	17,428.89

Тайлбар: Индексжүүлэлт нь нэгтгэлийн мөр-эх сурвалжийн холболтыг тогтвортой хадгалах зорилготой. Дахин хэрэгжүүлэлтийн үед ижил MT5 лог-д эдгээр индексүүдийг судлахаар хүрэлцээ.

Дахин хэрэгжүүлэх боломж ба орчны нөхцөл

Энэ бүлгийн үр дүнг дахин хэрэгжүүлэхэд дараах нөхцөлүүдийг тогтмол хадгалах шаардлагатай:

- **Эх сурвалжийн лог багц:** Босгын мужийн 0.90–0.99 бүх гүйлтийн MT5 логиог өөрчлөхгүй хадгалах
- **Нэгтгэлийн дүрэм:** Босго бүрт Loaded signals anchor мөрөөс хойших эхний final balance мөрийг холбох
- **Арилжааны үзүүлэлтүүд:** Trades/Trade мөрөөс TP/SL болон хаагдсан арилжааны дарааллыг нэг ижил дүрмээр тооцох
- **Гүйцэтгэлийн нөхцөл:** Ижил MT5 тестийн хугацааны цонх, ижил EA ажиллах үеийн дүрмүүд (нэг агшинд нэг байрлал, ижил дохио ачаалах журам)

Эдгээр нөхцөл зөрвөл тайланд буй тоон үр дүнтэй 1:1 давхцахгүй байж болох тул дахин хэрэгжүүлэлтийн үед параметрийн өөрчлөлт бүрийг тусдаа протоколын хүснэгтээр бүртгэх нь зүйтэй.

Практик шийдвэр гаргалтын нэмэлт тайлбар

Практик шийдвэр гаргалтын хүрээний дэлгэрэнгүй тайлбарыг Үр дүнгийн бүлгийн “Практик шийдвэр гаргалтын хүрээ” хэсгээс үзнэ үү. Тухайн хэсэгт эрсдэл-өмнөх шалгуур (CV, MaxDD, урт дараалсан алдагдал, win rate CI) болон босгын практик мужийн нөхцөлт тайлбарыг нэгтгэн харуулсан болно.

ВАЛЮТЫН ЗАХ ЗЭЭЛИЙН АРИЛЖААНЫ ДОХИО ҮҮСГЭХ СИСТЕМ

КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутан: s21c033b, М.Мөнхдорж

Удирдагч багш: Н.Соронзонболд

1. Удиртгал

Шуугиан ихтэй, тогтворгүй (non-stationary) цаг хугацааны цуваанаас ангилалтын дохио (classification signal) найдвартай гаргах нь машин сургалтын томоохон сорилтуудын нэг юм. Энэ судалгаанд гадаад валютын зах зээлийн (Форекс) EUR/USD өгөгдлийг туршилтын домэйн болгон ашиглав. Макро эдийн засгийн хүчин зүйл, зах зээлийн сэтгэл санааны нөлөөгөөр тасралтгүй өөрчлөгддөг энэ өгөгдөл нь олон хэмжээст, өндөр хэлбэлзэлтэй цаг хугацааны цувааны сорилтот тохиолдол болдог. Уламжлалт дүн шинжилгээ нь хүний субъектив шийдвэрт тулгуурладаг тул автоматжуулсан ML системийн хэрэгцээ тодорхой байна.

Гэхдээ зөвхөн загварын нарийвчлалыг өндөр байлгах нь хангалтгүй юм. Бодит цагийн дохионы урсгал, гүйцэтгэлийн чанарыг хэмжих аргачлал, хэрэглэгчид үр дүнг хүргэх мобайл интерфэйс — эдгээрийг хамтад нь шийдэх шаардлагатай. Иймд энэ судалгааны зорилго нь EUR/USD дээр машин сургалтын ансамбль загвар боловсруулж, дохионы чанарыг бодит нөхцөлд шалгаад, үр дүнг хэрэглэгчид хүргэх нэгдсэн системийг прототипийн түвшинд бүтээх явдал юм.

Гурван судалгааны асуулт тавьсан:

- **RQ1:** Загвар цагийн дарааллыг алдагдуулахгүй тест дээр тогтвортой, найдвартай ажиллах уу?
- **RQ2:** Шүүгдсэн дохио бодит гүйцэтгэл дээр арилжаа болж хэрэгжих үү, дохио-арилжааны хөрвүүлэлт хэд вэ?

- **RQ3:** Тогтмол эрсдэлийн дүрэмтэй үед систем урт хугацаанд ашигтай, тогтвортой байх уу?

2. Онолын суурь

Санхүүгийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд нейрон сүлжээ, тулгуур векторын машин (SVM)-аас эхэлж, LSTM, Transformer зэрэг гүн сургалтын архитектурт хүрсэн. Гэвч дунд хэмжээний хүснэгтэн өгөгдөлд гүн сургалт нь тайлбарлах чадвар сул, параметр олон, хэт нийцэлд эмзэг зэрэг практик бэрхшээлтэй.

Краус нар (2017) S&P 500 дээр градиент нэмэгдүүлсэн шийдвэрийн мод (GBDT) загварууд нь гүн нейрон сүлжээнээс **илүү тогтвортой гүйцэтгэл** үзүүлснийг тогтоосон. Ballings нар (2015) ансамбль аргууд дангаар ажилладаг загвараас **3–7% нарийвчлалын давуу** талтайг харуулсан.

Гэсэн хэдий ч дараах асуудлууд нээлттэй хэвээр байна:

- Форекс зах зээлийн олон интервалын онцлогийг тусгасан судалгаа цөөн
- XGBoost, LightGBM, CatBoost гурвыг ансамблаар Форекст харьцуулсан ажил дутмаг
- Дохио шүүлтүүр, гүйцэтгэлийн хөрвүүлэлт, мобайл интерфэйсийг нэгтгэсэн судалгаа хийгдээгүй

3. Судалгааны арга зүй

Арга барил: Зохиомжлох шинжлэх ухааны судалгаа (DSR) буюу “бүтээх–

үнэлэх–сайжруулах” мөчлөгийг 7 давталтаар хэрэгжүүлсэн. Давтальт бүрд өмнөх хувилбарын алдааг шинжилж загвар болон шинж чанарыг боловсронгуй болгосон. Эцэстээ шинж чанарын тоог 75-аас 48-д, загварын тоог 9-өөс 3-т хүртэл цөөлж хэт нийцэл буюу overfitting эрсдэлийг бууруулсан.

Өгөгдөл: EUR/USD-ийн 2015–2024 оны OHLCV өгөгдлийг зургаан интервалаар (M1, M5, M15, M30, H1, H4) ашигласан. Интервал бүрээс 8 шинж чанар (хаалтын ханш, RSI, ATR, MA(5), MA(20), MA(50), хэлбэлзэл, өгөөж) тооцоолж нийт **48 шинж чанарын матриц** бүрдүүлсэн. Шошгыг ирээдүйн 240 минутын дээд/доод ханшийн хөдөлгөөнд (30 пипс, 1.5 дахин давамгайлал) үндэслэн BUY/SELL/HOLD гэж тодорхойлсон. Leakage эрсдэлийг тусгай аудитаар шалгасан.

Загвар: LightGBM, XGBoost, CatBoost гурвыг зөөлөн санал хураалтаар нэгтгэсэн. Урагш гүйлгэн баталгаажуулалтын Fold 5 (2015–2022 сургалт, 2023 баталгаажуулалт, 2024 тест) дээр гол шинжилгээг хийсэн. Гиперпараметрийг тогтвортой байдлын протоколоор сонгосон: модны гүнийг хязгаарлаж (max_depth=5–6), L1/L2 тогтмолжуулалт нэмж, early stopping (patience=50)-оор хянасан.

Дохионы шүүлтүүр: Ансамблийн гаралтыг хоёр шүүлтүүрээр шүүсэн: итгэлцлийн босго (≥ 0.90) ба ATR (≥ 4.0 пипс). Нийт 359,639 таамгаас зөвхөн **3,567 дохио** (1.0%) үлдсэн. SL/TP утгыг ATR-д суурилан автоматаар тооцоолсон бөгөөд TP/SL харьцаа 3:1 тогтмол.

Туршилт: MetaTrader 5 дээр 2025.01.01–2026.01.01 хугацаанд, \$10,000 анхны хөрөнгөтэй, нэг агшинд нэг байрлал, бодит спрэд нөхцөлд туршсан. Итгэлцлийн босгыг 0.90-оос 0.99 хүртэл 10 утгаар харьцуулсан.

Архитектур: Систем гурван давхаргатай ML serving урсгал (pipeline) хэлбэрт хэрэгжсэн: (1) оффлайн сургалтын давхарга (GBDT загвар); (2) серверийн хэсэг (Python/Flask REST

API, Python threading, MongoDB, Firebase FCM push); (3) мобайл апп (React Native, 4 дэлгэц). Загвар нь REST API polling болон push notification хоёр дамжуулалтыг хослуулан хэрэгжүүлсэн. Гол архитектурын зарчим: өгөгдөл таах → таамаглах → шүүх → SL/TP тооцоолох → мэдэгдэл илгээх — **бүгд автомат**; эцсийн шийдвэр (арилжаа нээх/хаах) — **хэрэглэгчид үлдсэн**.

4. Судалгааны үр дүн

Өгөөж: Бүх 10 сценари эерэг өгөөжтэй гарсан. Buy-and-hold жишиг нь \$10,000-ийг +13.47% буюу \$11,347 болгосон. Хамгийн өндөр өгөөж 0.91 босгонд +517.70% (\$61,770) бол 0.90 дээр +482.62% гарсан. Босго өсөхөд дохио цөөрч өгөөж буурна: 0.93 дээр +368%, 0.96 дээр +230%, 0.99 дээр +74% (зөвхөн 147 дохио).

Дохионы гүйцэтгэл: Ачаалагдсан дохиотой харьцуулахад бодитоор арилжаа болсон хувь 6.45–23.81% байсан. Энэ нь системийн алдаа бус, зориудын чанарын шүүлтүүрийн үр дүн юм: загвар минут бүр таамаглал гаргадаг ч нэг агшинд нэг байрлалын дүрэм (MaxPositions=1) болон итгэлцлийн босгыг хангаагүй дохиог алгасдаг. Босго өсөхөд дохио цөөрч, гүйцэтгэлийн хувь нэмэгдэх хандлага ажиглагдсан.

Ялалтын хувь: Ялалтын хувь 44.78–65.71% мужид байсан. TP/SL=3:1 нөхцөлд алдагдалгүй байх доод хязгаар 25% тул бүх сценари түүнээс дээш гарсан. Нэг арилжааны дундаж хүлээгдэж буй өгөөж (Expectancy) 0.79–1.63R мужид эерэг. Босго өсөхөд ялалтын хувь өсөх боловч арилжааны тоо цөөрснөөс итгэлцлийн интервал (95% Wilson CI) мөн өргөсдөг.

Эрсдэл: Sharpe 8.57–12.83, Sortino 23.97–44.76, Calmar 20.16–174.20. Хамгийн их уналт (MaxDD) 1.98% (0.99)–9.53% (0.93), хамгийн урт дараалсан алдагдал 2–10 арилжаа. Балансын харьцангуй хэлбэлзэл (CV) 38.01% байгаа нь босго сонголт гүйцэтгэлд ихээхэн нөлөөтэй болохыг харуулна. 0.91 босго хамгийн өндөр өгөөж (+517.70%) ба бага уналт (MaxDD 2.97%)-ийг хослуулсан тэнцвэртэй сценари.

5. Судалгааны нэгтгэл

Судалгааны асуултуудад товчоор хариулвал:

- **RQ1:** WFV Fold 5-ийн тест өгөгдөл (2024) дээр нарийвчлал 89.25%, итгэлцэл ≥ 0.90 дохионы нарийвчлал 96.96% гарсан нь загвар харагдаагүй өгөгдөл дээр тогтвортой ажиллаж буйг харуулсан.
- **RQ2:** Execution rate 6.45–23.81% байсан тул дохио бодит арилжаа болж хэрэгжсэн, гэхдээ MaxPositions=1 дүрмээс нэлээд хэсэг алгасагдсан.
- **RQ3:** Бүх сценарид buy-and-hold жишгийг давсан эерэг Expectancy (0.79–1.63R), MaxDD 1.98–9.53% гарсан.

Инженерчлэлийн хувьд загвар сургалтаас мобайл апп хүртэлх нэгдсэн урсгалыг прототипийн түвшинд хэрэгжүүлсэн.

Хязгаарлалт: (i) EUR/USD, нэг хугацааны цонхонд батлагдсан тул бусад хэрэгсэлд шууд нэвтрүүлэх боломжгүй. (ii) Спрэд болон гулсалт тусгасан боловч шимтгэл, своп хамруулаагүй; бодит хэрэглээнд эдгээрийг нэмж тооцох шаардлагатай. (iii) Гүйцэтгэлийн хувь 100% биш тул ялалтын хувь, хүлээгдэж буй өгөөж нь зөвхөн хэрэгжсэн арилжааны багцад хүчинтэй. (iv) Leakage эрсдэлийг аудитаар хянасан ч бүрэн арилгаагүй. (v) Офлайн тохируулга ба бодит орчны гаралтын зөрүүнөөс дэд эрсдэл үүсч болзошгүй.

Цаашдын чиглэл: (1) GBP/USD, USD/JPY зэрэг хэрэгсэлд өргөтгөх, (2) LSTM/Transformer загвар ансамбльд нэмэх, (3) байрлалын хэмжээнд бататгалтат сургалт (RL) хэрэглэх, (4) NLP-ээр макро мэдээ шинжлэх, (5) MLOps мониторинг ба Google Play түгээлт хэрэгжүүлэх.