ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Оюутны код: s21c033b
Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

Дэд бакалаврын төгсөлтийн судалгааны ажил

Удирдагч багш /Н.Соронзонболд/
Гүйцэтгэсэн оюутан /М.Мөнхдорж/

Улаанбаатар хот
2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

Дэд бакалаврын төгсөлтийн судалгааны ажил (061301)

Удирдагч багш: /Н.Соронзонболд/

Гүйцэтгэсэн оюутан: /М.Мөнхдорж/

Улаанбаатар хот
2026 он

Хураангуй

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан санхүүгийн шуугиан ихтэй цаг хугацааны цувааны өгөгдөл дээр таамаглал хийж, үр дүнг хэрэглэгчид бодит хугацаанд хүргэх өгөгдөл боловсруулах урсгал болон харагдах хэсэг (frontend)-тэй мобайл аппликейшн хөгжүүлсэн.

Системийн цөм нь LightGBM, XGBoost, CatBoost гэсэн гурван градиент нэмэгдүүлсэн шийдвэрийн модны (GBDT) алгоритмуудаас бүрдэх санал өгөх механизмтай (Voting Classifier) ансамбль загвар юм. Загваруудыг 2015–2022 оны ∼2.97 сая өгөгдлийн цэг (өгөгдлийн түүвэр)-ийг ашиглан сургаж, 2023 оны 371,000 цэг дээр баталгаажуулж, 2024 оны 371,000 цэг дээр тестэлсэн. Загварын хэт нийцэл (overfitting) үүсэх эрсдэлийг бууруулах зорилгоор урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) хэрэглэсэн. 6 хугацааны интервалаас нийт 48 шинж чанар (feature) боловсруулж сургалтад ашигласан. Загварын магадлалын тохируулгыг (probability calibration) сүлжээнээс гадуурх үнэлгээнд ашигласан бөгөөд бодит ажиллах орчинд (production runtime) ансамблийн шууд магадлалд суурилсан итгэлцлийн босго (confidence threshold) хэрэглэсэн.

Программ хангамжийн туршилтын (system testing) шинэ багцад EA талын runtime итгэлцлийн босгыг 0.90 дээр тогтмол байлгаж, 0.90–0.99 мужийн урьдчилан шүүсэн дохионы 10 багцаар түүхэн өгөгдөл дээрх системийн туршилт (backtesting) ажиллуулж, бүх тохиргоонд эерэг өгөөж гарсан. Хамгийн өндөр үр дүн нь 0.91 багц дээр $61,770.46 (+517.70%), 0.90 багц дээр $58,262.39 (+482.62%) эцсийн баланс байв. Эдгээр дүн нь EUR/USD хэрэгслийн EA тестийн цонх (2025.01.01–2026.01.01) дахь sweep туршилтын хүрээнд тайлбарлагдана. React Native технологи дээр суурилсан “Predictrix” харагдах хэсэг (frontend) нь бодит цагийн мэдээлэл, таамаглалын үр дүн, хэрэглэгчийн баталгаажуулалт зэргийг харуулсан. Мөн серверийн хэсгийн аюулгүй байдал, өгөгдлийн урсгалын тогтвортой ажиллагааг хангах инженерчлэлийн шийдлүүдийг системийн хэрэгжилтэд тусгасан.

Түлхүүр үг: машин сургалт, ансамбль загвар, цаг хугацааны цувааны өгөгдөл, GBDT, XGBoost, LightGBM, CatBoost, шинж чанарын инженерчлэл, өгөгдөл боловсруулах урсгал, React Native, харагдах хэсэг, туршин шалгах

Abstract

This research develops an end-to-end machine learning system, which uses ensemble methods for classifying and predicting high-noise, financial time-series data, and integrating a data pipeline with a mobile frontend application to provide real-time results.

The core of the system is an ensemble voting classifier composed of three Gradient Boosted Decision Tree (GBDT) models: LightGBM, XGBoost, and CatBoost. The models were trained on ∼2.97 million data points from 2015–2022, validated on 371,000 points from 2023, and tested on 371,000 points from 2024. A walk-forward validation methodology was implemented to mitigate overfitting risks. Feature engineering produced 48 distinct features spanning across 6 time intervals (M1–H4). Probability calibration was retained for offline evaluation, while production runtime utilizes direct ensemble probability confidence thresholds for stability.

The updated system evaluation keeps the EA runtime confidence threshold fixed at 0.90 and runs 10 backtests using pre-filtered signal sets across the 0.90–0.99 range; all configurations remain profitable. The best outcome is observed for the 0.91 signal set with a final balance of $61,770.46 (+517.70%), while the 0.90 set yields $58,262.39 (+482.62%). These outcomes are reported for EUR/USD within the EA

test window (2025.01.01–2026.01.01). The “Predictrix” mobile frontend application, developed with React Native, integrates real-time data flows, predictive results, and secure user authentication. System engineering contributions include robust backend stability, secure access control, and reliable production-grade data delivery.

Keywords: machine learning, ensemble models, time-series data forecasting, feature engineering, data pipelines, GBDT, XGBoost, LightGBM, CatBoost, React Native, frontend application, algorithm testing

Гарчиг

Хураангуй **i**

Гарчиг **iii**

Товчилсон үгсийн жагсаалт **iv**

Нэр томьёоны тайлбар толь **v**

Хүснэгтийн жагсаалт **vii**

Зургийн жагсаалт **viii**

1 Ажлын төлөвлөгөө **1**

2 Удиртгал **2**
2.1 Үндэслэл, ач холбогдол 2
2.2 Зорилго, зорилт 2

3 Судалгааны сэдвийн онол, өнөөгийн түвшин **3**
3.1 Санхүүгийн цаг хугацааны цувааны (Time-series) зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд 3
3.2 Шинж чанар (Feature)-уудын судалгаа 4
3.3 Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) ба санхүүгийн цаг хугацааны цуваа 5
3.4 Forex санхүүгийн таамаглалын аппликейшн ба технологийн хэрэгжүүлэлт 6
3.5 Төсөөтэй системүүд ба харьцуулалт 6
3.6 Бусад судалгааны ажлуудын дутагдал ба энэхүү ажлын хувь нэмэр 7
3.7 Бүлгийн дүгнэлт 8

4 Судалгааны арга зүй **9**
4.1 Судалгааны арга барил 9
4.2 Системийн ерөнхий бүтэц 9
4.3 Өгөгдлийн урсгал 10
4.4 Өгөгдлийн бэлтгэл 11
4.5 AI загварын бүтэц ба сургалт 13
4.6 Дохио үүсгэх систем 15
4.7 MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт (backtesting) 17
4.8 Серверийн хэсгийн хэрэгжүүлэлт 19
4.9 Мобайл аппликейшний хөгжүүлэлт 20
4.10 Загварын давталтат сайжруулалт 22
4.11 Бүлгийн дүгнэлт 23

5 Судалгааны үр дүн, дүгнэлт **25**
5.1 Үр дүнгийн өгөгдлийн эх сурвалж 25
5.2 Загварын ангиллын үзүүлэлтүүд 25
5.3 Threshold sweep-ийн нэгтгэсэн үр дүн 25
5.4 Үр дүнгийн тайлбар 26
5.5 Практик шийдвэр гаргалтын хүрээ 26
5.6 Бүлгийн дүгнэлт 27
5.7 Дүгнэлт 27

Ном зүй **29**

Товчлол **32**

Товчилсон үгсийн жагсаалт

ML Machine Learning – Машин сургалт

AI Artificial Intelligence – Хиймэл оюун ухаан

GBDT Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

XGBoost Extreme Gradient Boosting

LightGBM Light Gradient Boosting Machine

CatBoost Categorical Boosting

LSTM Long Short-Term Memory – Урт богино хугацааны санах ой

RSI Relative Strength Index – Харьцангуй хүчний индекс

ATR Average True Range – Дундаж жинхэнэ хүрээ

MACD Moving Average Convergence Divergence

SMA Simple Moving Average – Энгийн хөдөлгөөнт дундаж

EMA Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

ADX Average Directional Index – Дундаж чиглэлийн индекс

CCI Commodity Channel Index

SL Stop Loss – Алдагдал зогсоох

TP Take Profit – Ашиг авах

API Application Programming Interface

REST Representational State Transfer

JWT JSON Web Token

OHLCV Open, High, Low, Close, Volume

MT5 MetaTrader 5

PF Profit Factor – Ашгийн коэффициент

DD Drawdown – Уналт

RR Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

CORS Cross-Origin Resource Sharing

WSGI Web Server Gateway Interface

CSV Comma-Separated Values

Нэр томьёоны тайлбар толь

Хатуу мөрдөх зарчим:

- Нэг ойлголтод зөвхөн хүснэгтэд өгсөн нэг л Монгол нэршлийг хэрэглэнэ.
- Өөр хувилбар, ижил утгатай өөр орчуулга, эсвэл Монгол нэршилгүй дан гадаад үг хэрэглэхгүй.
- Орчуулгыг үгчлэн махчилж буулгахгүй; компьютерын ухааны хэрэглээний утгаар нь Монгол хэлэнд буулгана.
- Бичлэгийн үндсэн хэлбэр нь **Монгол нэр (original term)** байна.

Канон Монгол нэршил	Original term
хиймэл оюун ухаан	artificial intelligence
машин сургалт	machine learning
ангилал	classification
хоёртын ангилал	binary classification
шинж чанар	feature
шинж чанарын инженерчлэл	feature engineering
шинж чанарын нөлөөлөл	feature importance
шошго	label
ансамбль загвар	ensemble model
зөөлөн санал хураалт	soft voting
гиперпараметр	hyperparameter
эрт зогсоох	early stopping
тогтмолжуулалт	regularization
хэт нийцэл	overfitting
урагш гүйлгэсэн баталгаажуулалт	walk-forward validation
ирээдүйг харах төөрөгдөл	look-ahead bias
зорилтот хувьсагчийн алдагдал	target leakage
түүхэн өгөгдөл дээрх системийн тур-шилт	backtesting
уналт	drawdown
үнийн хэлбэлзэл	volatility
хугацааны интервал	timeframe
итгэлцэл	confidence
итгэлцлийн босго	confidence threshold
магадлалын тохируулга	probability calibration
сүлжээнээс гадуурх үнэлгээ	offline evaluation
бодит ажиллах орчин	production runtime
серверийн хэсэг	backend
харагдах хэсэг	frontend
өгөгдөл боловсруулах урсгал	data pipeline
үйлчилгээний интерфейс	API
цог систем	end-to-end system
цог шийдэл	end-to-end solution
цог боловсруулах урсгал	end-to-end pipeline
түүвэр доторх	in-sample
түүврийн гадуурх	out-of-sample
байрлал	position
пипс	pip
спрэд	spread
гулсалт	slippage
эрсдэл-өгөөжийн харьцаа	risk-reward ratio
загварын хазайлт	model drift
push мэдэгдэл	push notification

Хүснэгтийн жагсаалт

Хүснэгт 4.1. Түүхэн өгөгдлийн хэмжээний хураангуй 11
Хүснэгт 4.2. Шинж чанар (Feature)ын жагсаалт (интервал бүрд) 12
Хүснэгт 4.3. Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) – өгөгдлийн хуваалт . 13
Хүснэгт 4.4. Загвар бүрийн гол гиперпараметрүүд 14
Хүснэгт 4.5. Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо 18
Хүснэгт 4.6. Системийн үнэлгээний шалгуур үзүүлэлтүүд 18
Хүснэгт 4.7. Серверийн хэсгийн үндсэн бүрэлдэхүүн 19
Хүснэгт 4.8. Серверийн хэсгийн функцийн бүлгүүд 19
Хүснэгт 4.9. Мобайл аппликейшний технологийн стек 20

Хүснэгт 5.1. Threshold тус бүрийн лог нотолгооны эх мөрүүд 25
Хүснэгт 5.2. Загварын ангиллын баталгаажсан үзүүлэлтүүд 25
Хүснэгт 5.3. 0.90–0.99 threshold sweep-ийн баталгаажсан дүн 26

Зургийн жагсаалт

Зураг 4.1. Системийн үндсэн ойлголт – өгөгдлөөс трейдер хүртэлх урсгал 9
Зураг 4.2. Системийн гурван давхаргат бүтэц 10
Зураг 4.3. Өгөгдлийн урсгалын диаграмм (Data Flow Diagram) 10
Зураг 4.4. Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) – цаг хугацааны дараалыг хадгалсан өгөгдлийн хуваалт 13
Зураг 4.5. GBDT ансамбль загварын архитектур 14
Зураг 4.6. Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио 16
Зураг 4.7. Дохио үүсгэх дараалын диаграмм (Sequence Diagram) 17
Зураг 4.8. Мобайл аппликейшний хэрэглэгчийн навигацийн урсгал 21
Зураг 4.9. Хэрэглэгчийн бүртгэл ба нэвтрэлтийн дараалын диаграмм (Sequence Diagram) . . . 22
Зураг 4.10. Загварын давталтат сайжруулалтын үе шатууд ба гол өөрчлөлтүүд 23

1. Ажлын төлөвлөгөө

Оюутны нэр: М.Мөнхдорж **Удирдагч багшийн нэр:** Н.Соронзонболд

Судалгааны ажлын сэдэв: Машин сургалтын аргаар хөрөнгийн зах зээлийн чиг хандлагыг таамаглах арилжааны бот хөгжүүлэх

Сар	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 сар	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Forex арилжаа, машин сургалт (machine learning) онолын судалгаа хийх	✓
	3	Yahoo Finance API-аас EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 сар	1	70+ техник индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модел сургах	✓
	3	Stacking Ensemble модел хөгжүүлэх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх	✓
	4	Серверийн хэсэг болон мобайл апп хөгжүүлэх	✓
12 сар	1	ТСА Үзлэг 1	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 сар	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 сар	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	✓
	4	Хамгаалалтын бэлтгэл хийх	✓
3 сар	1	ТСА Үзлэг 2	☐
	2	Засвар хийх, санал хүсэлтийг тусгах	☐
	3	Код тайлбар, баримтжуулалт	☐
	4	Хамгаалалтын дадлага хийх	☐
4 сар	1	Эцсийн засвар хийх	☐
	2	Слайд сайжруулах	☐
	3	Хамгаалалтын бэлтгэл	☐
	4	ТСА урьдчилсан хамгаалалт	☐
5 сар	1	ТСА урьдчилсан хамгаалалт	☐
	2	ТСА урьдчилсан хамгаалалт	☐
	3	Эцсийн засвар, сайжруулалт	☐
	4	ТСА үндсэн хамгаалалт	☐

Удирдагч багш /Н.Соронзонболд, магистр/

Гүйцэтгэсэн оюутан /s21c033b, М.Мөнхдорж/

2. Удиртгал

2.1. Үндэслэл, ач холбогдол

Мэдээллийн технологи, өгөгдлийн шинжлэх ухааны салбарт олон хэмжээст, шуугиан ихтэй цаг хугацааны цуваа өгөгдөл дээр таамаглал хийх нь томоохон сорилтуудын нэг юм. Үүний тод жишээ нь гадаад валютын зах зээл буюу Forex (Foreign Exchange) бөгөөд энэ зах зээл олон улсын эдийн засаг, төв банкуудын бодлого зэрэг хүчин зүйлсээс хамааран тасралтгүй өөрчлөгддөг [1]. Ийм шугаман бус өгөгдлөөс зүй тогтлыг илрүүлэх нь уламжлалт статистик анализийн хувьд хүндрэлтэй.

Уламжлалт аргачлалууд нь ихэвчлэн хүний туршлага, субьектив шийдвэрт тулгуурладаг бөгөөд их хэмжээний өгөгдлийг (Big Data) богино хугацаанд боловсруулах тооцооллын хүчин чадал болон математик статистикийн нарийвчлалын хувьд хязгаарлагдмал байдаг.

Сүүлийн жилүүдэд машин сургалт (machine learning) болон хиймэл оюун ухааны технологиуд программ хангамжийн салбарт өргөн хэрэглэгдэх болсон. Градиент нэмэгдүүлсэн шийдвэрийн мод (gradient boosted decision trees, GBDT), нейрон сүлжээ (neural network) зэрэг орчин үеийн алгоритмууд нь том хэмжээний өгөгдөл боловсруулж, нарийн төвөгтэй зүй тогтлыг илрүүлэх чадвартай болсон [2][3]. Гэвч алгоритмын хэт нийцэл (overfitting)-ийн асуудал, системийн архитектурын хүртээмжийн дутагдал, болон нэг алгоритмд хэт найдсан системийн доголдол зэрэг сорилтууд програм хангамжийн инженерчлэлийн түвшинд байсаар байна.

Ийм төрлийн судалгаанд зөвхөн алгоритмын нарийвчлалыг (model accuracy) сайжруулаад зогсох нь хангалтгүй юм. Хэрэглэгчийн нэвтрэлтийн аюулгүй байдал (authentication/security), серверийн хэсэг (backend)-ийн бодит хугацааны өгөгдөл боловсруулах урсгалын (real-time data pipeline) найдвартай ажиллагаа, үүлэн (cloud) орчны байршуулалтын (deployment) тогтвортой байдал зэрэг системийн архитектурын хүчин зүйлсийг нэгтгэн шийдвэрлэх шаардлагатай. Иймд энэхүү судалгааны ажил нь алгоритмын гүйцэтгэлийг серверийн хэсэг (backend) болон харагдах хэсэг (frontend)-ийн бодит хэрэгжилттэй уялдуулсан цог системийн (end-to-end system) хөгжүүлэлтээрээ онцлогтой.

Энэхүү судалгаанд машин сургалтын ансамбль загваруудын хослол (Voting Classifier), урагш гүйлгэсэн баталгаажуулалт (walk-forward validation), олон хугацааны интервалын шинж чанарын инженерчлэл (feature engineering) аргыг ашиглан илүү найдвартай, тогтвортой системийн архитектурыг боловсруулж туршин баталгаажуулсан. Түүнчлэн тооцооллын үр дүнг программ хангамжаар дамжуулан хялбарчилж, энгийн хэрэглэгчдэд хүртээмжтэй мобайл интерфейс хөгжүүлснээр мэдээллийн технологи, финтек (fintech) салбарт практик хувь нэмэр оруулах боломжтой юм.

2.2. Зорилго, зорилт

Судалгааны зорилго

Энэхүү судалгааны ажлын гол зорилго нь **EUR/USD арилжааны өгөгдөл дээр машин сургалтын ансамбль загвар боловсруулж, зах зээлийн шуугианыг шүүх замаар таамаглалын нарийвчлалыг дээшлүүлэн, түүний системийн гүйцэтгэлийг практик орчинд турших** явдал юм.

Судалгааны зорилтуд

1. EUR/USD хослолын түүхэн өгөгдлийг цуглуулах, цэвэрлэх болон түүнээс шинж чанарын инженерчлэл (feature engineering) хийх аргачлалуудыг судлах.
2. Ансамбль загваруудын санал өгөх хослол (voting mechanism), олон хугацааны интервалын дүн шинжилгээ, мөн хэт нийцлээс (overfitting) сэргийлэх урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)-ын туршилтын орчин (experimentation setup) хөгжүүлэх.
3. Системийн архитектурын таамаглах чадвар (accuracy), алдааны тооцоолол (drawdown), найдвартай байдлыг туршин шалгах (system testing) үнэлгээ гаргах.
4. Хэрэглэгчдэд ойлгомжтой график интерфэйс бүхий (UI/UX) харагдах хэсэг (frontend) бүхий аппликейшн бүтээж, серверийн бодит хугацааны таамаглалын мэдээллийг хэрэглэгчид дамжуулах интеграци хийх.

3. Судалгааны сэдвийн онол, өнөөгийн түвшин

3.1. Санхүүгийн цаг хугацааны цувааны (Time-series) зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

Уламжлалт машин сургалтын аргууд

Санхүүгийн цаг хугацааны цувааны (Time-series) зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн өмнөх үеийн судалгаанууд нь голчлон нейрон сүлжээ (neural networks) болон тулгуур векторын машин (support vector machines, SVM)-д төвлөрч байсан. Kamruzzaman, Sarker нар (2003) нь нейрон сүлжээг ашиглан валютын ханш таамаглахад 81%-ийн нарийвчлал хүрсэн [4]. Гэвч судалгааны дараах сул талууд байна:

- Зөвхөн нэг валютын хослолд хязгаарлагдсан
- Хэт нийцэл (overfitting)-ийн асуудлыг тодорхой авч үзээгүй
- Түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийгээгүй

Kumar, Thenmozhi нар (2006) нь SVM-ийг ашиглан USD/INR хослолыг судалж 67%-ийн нарийвчлал авсан боловч модел нь зах зээлийн горимын өөрчлөлтөд мэдрэмтгий байсан [5].

Санамсаргүй ой (Random Forest) болон градиент нэмэгдүүлэлт (Gradient Boosting) аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings тэргүүтэй судлаачид (2015) нь хувьцааны үнийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц гарсан** болохыг тогтоосон [6]. Гэсэн хэдий ч, Санхүүгийн цаг хугацааны цувааны (Time-series) зах зээлд энэ аргуудыг бүрэн туршиж үзээгүй нь судалгааны ажлуудын дутагдалтай тал хэвээр байна.

Гүн сургалтын аргууд

Сүүлийн жилүүдэд урт-богино хугацааны санах ой (Long Short-Term Memory, LSTM) болон гүн нейрон сүлжээ (deep neural network, DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer, Krauss нар (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang тэргүүтэй судлаачид (2019) нь LSTM сүлжээг алтны үнэ таамаглахад хэрэглэж 58.7% нарийвчлал хүрсэн [8].

Гэсэн хэдий ч, **гүн сургалтын аргуудын дараах сул талууд** илэрхий байна [9]:

- **Тайлбарлах боломжгүй (black-box)**: Санхүүгийн шийдвэр гаргалтанд шаардлагатай тайлбарлах чадвар дутмаг
- **Их параметр, удаан сургалт**: 100,000+ параметртэй, өгөгдөл их шаарддаг
- **Хэт нийцэл (overfitting)-д эмзэг**: Түүхэн өгөгдөлд хэт тохирч, шинэ зах зээлийн нөхцөлд муу ажилладаг
- **Тогтворгүй**: Анхны параметрээс их хамаардаг

Krauss болон түүний багийнхан (2017) нь гүн нейрон сүлжээ болон градиент нэмэгдүүлсэн шийдвэрийн мод (gradient-boosted trees) загваруудыг S&P 500 дээр харьцуулж, **GBDT загварууд илүү тогтвортой үр дүн үзүүлсэн** гэж дүгнэсэн [9]. Энэ нь бидний судалгаанд GBDT ансамбль загваруудыг ашиглах үндэслэл болж байна.

Градиент нэмэгдүүлсэн шийдвэрийн мод (Gradient Boosted Decision Trees) санхүүгийн салбарт

GBDT нь Friedman (2001)-ийн боловсруулсан аргачлал бөгөөд олон шийдвэрийн мод (decision tree)-ийг дараалан нэмж, алхам бүрд өмнөх загварын үлдэгдэл алдааг (gradient) бууруулж сургадаг [10]. Gu, Kelly, болон Xiu (2020) нь 150+ оролтын хувьсагчтай GBDT загварыг хувьцааны өгөөж таамаглахад хэрэглэж, **гүн сургалтын загваруудтай харьцуулахад илүү нарийвчлалтай** байсныг тогтоосон [11]. Тэд мөн GBDT загваруудын дараах давуу талуудыг дурдсан:

- Хүснэгтэн (tabular) өгөгдөлд тохирсон шинж чанаруудын харилцан үйлчлэл (feature interaction)-ийг олж илрүүлдэг
- Цөөн параметртэй – хурдан сургаж болно
- Шинж чанарын чухал байдал (feature importance)-ыг хялбар тооцоолох – тайлбарлах боломжтой
- Гажиг утга (outlier)-д мэдрэмтгий бус

XGBoost [2], LightGBM [3], CatBoost [12] нь GBDT-ийн орчин үеийн хувилбар бөгөөд өөр өөр онцлогтой. XGBoost нь L1/L2 тогтмолжуулалт (regularization) давуу талтай, LightGBM нь хурдтай боловч хэт нийцэл (overfitting)-д илүү эмзэг, CatBoost нь эрэмбэлэгдсэн нэмэгдүүлэлт (ordered boosting) ашиглан зорилтот хувьсагчийн алдагдал (target leakage)-аас сэргийлдэг. Гэсэн хэдий ч, **эдгээр загваруудыг Forex зах зээлд ансамбль хэлбэрээр хэрэглэж, харьцуулсан судалгаа маш хомс** байна.

Ансамбль аргуудын санхүүгийн хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [13]. Breiman (2001) санамсаргүй ой (Random Forest) аргаар олон модыг параллель сургаж, дундажлах (average) замаар хэлбэлзэл (variance)-ийг бууруулсан [14]. Sezer тэргүүтэй судлаачид (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол өндөр гүйцэтгэлтэй байдгийг** дурдсан [15].

Өмнөх судалгаануудын дутагдалтай талууд:

- Ихэнх нь хувьцааны зах зээлд төвлөрсөн – Forex зах зээлийн онцлог (24/5 арилжаа, макро эдийн засгийн үйл явдал (event)-ын нөлөөлөл, ам.долларын индекс) харгалзаагүй
- Дан загвар эсвэл нэг төрлийн ансамбль (жишээ нь зөвхөн санамсаргүй ой (Random Forest)) хэрэглэсэн – **өөр өөр алгоритмуудын (XGBoost, LightGBM, CatBoost) ансамбль судлаагүй**
- Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) аргачлал хийж, цаг хугацааны алдагдал (leak)-аас сэргийлээгүй
- Практик хэрэглээ (мобайл аппликейшн, бодит цагийн дохио үүсгэх) байхгүй
- Олон хугацааны интервалын (multi-timeframe) өгөгдөл хангалттай ашиглаагүй

3.2. Шинж чанар (Feature)-уудын судалгаа

Шинж чанар (Feature)-уудын үр дүнтэй байдлын харьцуулалт

Уламжлалт санхүүгийн онол буюу Fama (1970)-ийн гаргасан ”Үр ашигт зах зээлийн таамаглал” (Efficient Market Hypothesis – EMH)-аар техникийн дүн шинжилгээ нь ямар ч ашиггүй хэмээн үздэг байв [16]. Хожим нь Murphy (1999) техник шинжилгээний талаарх маш системтэй танилцуулгыг бичсэн ч, түүнийгээ бодит өгөгдөл дээр хангалттай сайн баталгаажуулж чадаагүй юм [17]. Харин Lo болон бусад судлаачид (2000) илүү нарийвчилсан статистик тестүүд хийж үзээд, **техник аргууд нь зах зээл дээр статистикийн хувьд ач холбогдолтой үр дүн өгч чаддаг** болохыг нотолсон байдаг [18]. Энэхүү нээлт нь зах зээл хэзээд, бүрэн үр ашигтай байдаг гэсэн EMH-ийн онолыг тодорхой хэмжээнд няцаасан юм.

Түүнчлэн, Olson (2004) нь үнийн хэлбэлзэл болон эрчмийг хэмждэг RSI, MACD, Stochastic зэрэг түгээмэл өгөгдлийн шинж чанаруудыг (features) (математик томьёололд суурилсан хэмжүүрүүдийг) Forex (гадаад валютын арилжаа)-ийн зах зээлд судалж үзээд, **тухайлсан нэг шинж чанар**

(feature) дангаараа байнга тогтвортой ашиг өгөх боломжгүй хэмээн дүгнэжээ [19]. Тэрээр хугацааны интервал (timeframe буюу үнийн мэдээлэл цуглуулах хугацааны цонх) өөрчлөгдөхөд индикаторын үр дүн дагаад өөрчлөгддөг бөгөөд зах зээлийн тухайн үеийн нөхцөл байдлаас маш их хамаардаг болохыг онцолсон байна. Иймд илүү үнэн зөв мэдээлэл авахын тулд **олон шинж чанар (feature)ыг хослуулах, мөн олон хугацааны хүрээг (multi-timeframe) нэгэн зэрэг ашиглах** нь зүйтэй. Энэхүү шаардлага нь бидний судалгааны ажилд шууд үндэслэл болсон бөгөөд M1-ээс H4 хүртэлх 6 ялгаатай хугацааны интервал дээр нийт 48 өгөгдлийн шинж чанаруудыг (features) тооцоолж, хэв шинж (feature) болгон загварт ашигласан шалтгаан юм.

Brock тэргүүтэй судлаачид (1992) нь хөдөлгөөний дунджийн огтлолцол (moving average crossover буюу үнийн дундаж утгуудын муруй огтлолцох цэг дээр суурилсан дохио) бүхий стратегиудыг судалж, тодорхой нөхцөлд ашигтай байж болохыг харуулсан боловч **санхүүгийн таамаглалын зардал (transaction cost)-ыг тооцох үед ашиг ихээхэн багассан** [20]. Энэ нь MetaTrader 5 (бодит өгөгдлийн платформ (data platform)) дээрх түүхэн өгөгдөл дээрх системийн туршилт (backtesting)-д спред (spread буюу авах, зарах үнийн зөрүү, EUR/USD дээр ойролцоогоор 1.5 pips), ханшийн зөрүү (slippage буюу захиалга биелэх үеийн үнийн зөрүү, ∼0.5 pips), болон своп (swap буюу хоног шилжих үеийн хүүгийн зардал) зэрэг бодит зах зээлийн шимтгэлүүдийг (pips буюу үнийн хамгийн бага өөрчлөлтийн нэгжээр тооцон) заавал оруулж тооцоолох шаардлагатайг баталж байна. Marshall болон түүний багийнхан (2008) нь техник аргууд нь хөгжиж буй зах зээл (emerging markets) дээр үр дүнтэй ажилладаг хэдий ч төдийлөн засвартай (developed) зах зээл дээр үр дүн мууддаг болохыг тогтоосон [21].

Шинж чанар (feature)-уудын хослуулалт ба шинж чанарын инженерчлэл (feature engineering)

Park, Irwin нар (2007) нь 95 судалгааг тоймлон, техник аргууд 1995 хүртэл үр дүнтэй байсан боловч сүүлийн жилүүдэд үр дүн буурч байгааг тогтоосон – энэ нь **зах зээлийн дасан зохицох чадвар (adaptive efficiency)-ын** илрэл [22]. Энэ нь шинж чанар (feature)ыг дангаар нь ашиглавал үр дүнгүй боловч машин сургалтын загварт шинж чанар (feature) болгон хэрэглэхэд илүү ашигтай байж болно гэсэн үг юм.

Шинж чанар (Feature)ууд нь GBDT загварт оролтын хувьсагч (feature) болж ашиглагдахад үр дүнтэй. Гэвч өмнөх судалгаануудын ихэнх нь зөвхөн нэг хугацааны интервалын (жишээ нь зөвхөн цагийн буюу өдрийн график (chart)) өгөгдлийг ашигласан. Энэ нь чухал мэдээллийг алдах эрсдэлтэй: жишээлбэл 1 минутын график (chart) дээр богино хугацааны эргэлт харагддаг ч 4 цагийн график (chart) дээр урт хугацааны чиг хандлага тодорхой гарч ирдэг. Тэдгээрийг хамтад нь ашигласнаар загвар нь зах зээлийн дүр зургийг олон өнцгөөс харж чаддаг. Энэхүү судалгаанд M1, M5, M15, M30, H1, H4 гэсэн 6 хугацааны интервал болон 48 индикатор тооцоолж загварт оруулсан нь өмнөх судалгаануудаас ялгарах гол онцлог юм.

3.3. Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) ба санхүүгийн цаг хугацааны цуваа

Уламжлалт k-нугалааст солбицсон баталгаажуулалт (k-fold cross-validation) нь санхүүгийн цуваа өгөгдөлд тохиромжгүй, учир нь цаг хугацааны дараалыг зөрчиж, ирээдүйг харах төөрөгдөл (look-ahead bias) үүсгэдэг. Pardo (2008) нь урагш гүйлгэсэн баталгаажуулалт (walk-forward validation, WFV) аргачлалыг танилцуулж, энэхүү аргачлал нь цаг хугацааны дараалыг хадгалж, загварыг ирээдүйн өгөгдөл дээр шалгахад илүү бодит болохыг харуулсан [23].

Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) аргачлалын давуу талууд:

- **Ирээдүйн өгөгдөл сургалтад нэвтрэхээс сэргийлдэг**: Загварыг сургах үед зөвхөн тухайн цэгийн өмнөх өгөгдлийг ашигладаг тул ирээдүйн мэдээлэл алдагдахгүй

- **Зах зээлийн нөхцөл өөрчлөгдөхийг илрүүлдэг**: Цаг хугацааны явцад зах зээлийн зан төлөв өөрчлөгдөж байдаг бөгөөд WFV нь загварын гүйцэтгэлийн хэлбэлзлээр энэ өөрчлөлтийг илрүүлж чаддаг
- **Бодит санхүүгийн таамаглалын нөхцөлийг дуурайдаг**: Загвар нь таамаглал хийх үед зөвхөн өнгөрсөн өгөгдлийг хардаг – яг бодит арилжаан дахь шийдвэр гаргалттай адил

Bailey болон түүний багийнхан (2014) нь санхүүгийн загваруудын хэт нийцэл (overfitting)-ийн эрсдэлийг задлан, **олон параметрийн тохируулга (parameter tuning) хийх нь түүвэр доторх (in-sample) үр дүнг сайжруулна гэхдээ түүврийн гадуурх (out-of-sample) дээр муудна** гэж анхааруулсан [24]. Энэ нь WFV ашиглах чухал шалтгаан – энэхүү судалгаанд 2015–2022 (сургалт), 2023 (баталгаажуулалт), 2024 (тест), 2025 (түүхэн өгөгдөл дээрх системийн туршилт (backtesting)) гэж тусгаарлаж, хэт нийцэл (overfitting)-аас сэргийлсэн.

3.4. Forex санхүүгийн таамаглалын аппликейшн ба технологийн хэрэгжүүлэлт

Мобайл санхүүгийн таамаглалын технологи

Гар утасны санхүүгийн таамаглалын аппликейшнууд санхүүгийн салбарт хурдацтай нэвтэрч байна. Charles Schwab-ийн 2023 оны судалгаагаар хөрөнгө оруулагчдын 60%-аас дээш нь гар утсаар арилжаа хийдэг болсон. React Native [25] нь JavaScript дээр суурилсан гар утасны (mobile) хөгжүүлэлтийн фреймворк (framework) бөгөөд нэг програмын кодоор Android аппликейшн хурдан хөгжүүлэхэд тохиромжтой. Eisenman (2018) нь React Native-ийн давуу тал нь хурдан хөгжүүлэлт, кодыг дахин ашиглах боломжтой болохыг дурдсан боловч гүйцэтгэл нь цэвэр үндсэн (native) аппликейшнаас бага зэрэг унадаг нь тогтоогдсон [26].

Серверийн хэсгийн ерөнхий архитектурын хандлага

Серверийн хэсгийн архитектурын зорилго нь бодит цагийн өгөгдлийг тогтвортой боловсруулах, машин сургалтын загварын үр дүнг үйлчилгээ болгон хүргэх, мөн мобайл аппликейшнтэй найдвартай холболт үүсгэх явдал юм. Судалгааны ажлуудад хөнгөн, уян хатан вэб хүрээ ашиглах нь хурдан туршилт болон тасралтгүй шинэчлэл хийх давуу талтай гэж үздэг [27].

Системийн найдвартай байдал ба аюулгүй байдлын судалгааны цоорхой

Санхүүгийн таамаглалын олон судалгаа загварын нарийвчлал (accuracy), өгөөж (return) зэрэг үзүүлэлтүүдэд төвлөрдөг боловч бодит хэрэглээний орчинд системийн найдвартай ажиллагаа, үйлчилгээний тогтвортой байдал, мэдээлэл хүргэлтийн чанарыг хангалттай тайлагнадаггүй.

Энэ цоорхой нь бодит хэрэглээнд шилжих үед өндөр эрсдэл үүсгэдэг. Учир нь загварын математик гүйцэтгэл сайн байсан ч үйл ажиллагааны хүчин зүйлс сул байвал системийн нийт үр нөлөө буурдаг. Иймд энэхүү судалгаа нь машин сургалт (machine learning)-ын үнэлгээг системийн найдвартай ажиллагааны үнэлгээтэй уялдуулсан нэгдмэл хандлага хэрэглэснээрээ ялгарна.

3.5. Төсөөтэй системүүд ба харьцуулалт

Бидний санал болгож буй “Predictrix” системтэй төстэй, зах зээлд байгаа зарим мобайл аппликейшн болон open source системүүдийг харьцуулан судлав.

Зах зээлд байгаа төсөөтэй аппликейшнууд

1. AlgoTrade 3

Kin Fung Wong-ийн хөгжүүлсэн “AlgoTrade 3” нь алгоритмын таамаглах стратегиудыг симуляци хийх, түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийх зориулалттай мобайл аппликейшн юм. Энэ нь өдөр тутмын (Daily) хувьцааны өгөгдөл дээр үндэслэн стратегиудыг турших боломжийг олгодог.

- *Ялгаа*: Энэхүү апп нь бодит цагийн Forex дохио өгдөггүй, зөвхөн түүхэн өгөгдөл дээрх симуляцид төвлөрсөн. Мөн зөвхөн Daily timeframe ашигладаг тул өдрийн (intraday) бодит системийн ажиллагаанд тохиромжгүй. Харин "Predictrix" нь M1–H4 олон timeframe ашиглан бодит цагийн дохио үүсгэдэг.

2. Tradlgo: Algo Trade & Screener (Android)

ZSCALE TECH-ийн хөгжүүлсэн "Tradlgo" нь хиймэл оюун ухаан ашиглан хэрэглэгчийн бичсэн энгийн текстээс (Natural Language) алгоритмын таамаглах стратеги үүсгэх, код бичихгүйгээр (no-code) автоматжуулах боломжийг олгодог платформ юм.

- *Ялгаа*: Tradlgo нь хэрэглэгчийг өөрөө стратегиа бүтээхэд туслах хэрэгсэл (tool) юм. Харин "Predictrix" нь бэлэн сургагдсан, баталгаажсан мэргэжлийн GBDT ансамбль загварыг санал болгож, хэрэглэгчээс нарийн мэдлэг шаардахгүйгээр бэлэн дохио өгдгөөрөө ялгаатай.

Харьцуулсан судалгаа ба open source системүүд

1. GBDT загваруудыг санхүүгийн салбарт хэрэглэсэн судалгаанууд:

Hancock, Khoshgoftaar нар (2020) нь санхүүгийн өгөгдөл дээр XGBoost, LightGBM, CatBoost загваруудыг харьцуулан судалсан. Тэдний үр дүнгээр XGBoost нь тохируулах параметрийн уян хатан байдал болон тогтворт гүйцэтгэлээрээ, CatBoost нь хэт нийцэл (overfitting)-ээс хамгийн сайн хамгаалагдсанаараа, LightGBM нь сургалтын хурдаараа тус тус давуу талтай болохыг тогтоосон. Гэвч ихэнх судалгаа эдгээр загваруудыг тус тусад нь ашигласан байдаг. Харин манай систем нь эдгээр гурван загварын сул талыг нөхөх зорилгоор *Soft Voting Ensemble* архитектурыг ашигласан.

2. Open source санхүүгийн таамаглалын системүүд (QuantConnect, Freqtrade):

QuantConnect (Lean engine) болон Freqtrade зэрэг open source төслүүд нь алгоритмын санхүүгийн таамаглалын дэд бүтцийг сайн шийдсэн байдаг. Ялангуяа Freqtrade нь "FreqAI" модулиар дамжуулан машин сургалтын загваруудыг ашиглах боломжийг олгодог. Гэвч эдгээр системүүд нь: (1) ихэвчлэн автомат бодит системийн ажиллагаанд (bot) зориулагдсан, (2) жирийн хэрэглэгчдэд ээлтэй мобайл интерфейсгүй байдаг. "Predictrix" нь мэргэжлийн трейдерүүдэд зориулсан шийдвэр гаргалтыг дэмжих (Decision Support System) мобайл аппликейшн хэлбэрээр хөгжүүлэгдсэнээрээ практик хэрэглээний хувьд ялгарна.

3.6. Бусад судалгааны ажлуудын дутагдал ба энэхүү ажлын хувь нэмэр

Дээр дурдсан судалгаануудыг тоймлон үзвэл, дараах **хангалтгүй хэвээр үлдсэн асуудлууд** илэрхий байна:

1. **Ансамбль GBDT загваруудыг Forex зах зээлд хэрэглэсэн судалгаа хомс**: Ихэнх нь дан загвар эсвэл хувьцааны зах зээлд төвлөрсөн
2. **Олон хугацааны интервалын (multi-timeframe) индикатор ашиглаагүй**: Зөвхөн нэг chart timeframe ашигласан
3. **Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) дутмаг**: Хэт нийцэл (overfitting) шалгалт сул
4. **Бодит санхүүгийн таамаглалын нөхцөл (spread, slippage, swap) тооцоолоогүй**: түүхэн өгөгдөл дээрх системийн туршилт (backtesting) нь түүхэн дүн шинжилгээнд л хязгаарлагдсан
5. **Практик хэрэглээ (мобайл app, бодит цагийн дохио) хийгээгүй**: Академик судалгаа л болсон

Энэхүү судалгааны шинэлэг хувь нэмэр:

- **XGBoost, LightGBM, CatBoost гурван загварын ансамбль**: Өөр өөр алгоритмуудын давуу талыг нэгтгэсэн
- **48 шинж чанар (feature) 6 хугацааны интервалаас**: M1–H4 олон давтамжийн дүн шинжилгээ
- **Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) + бодит MT5 түүхэн өгөгдөл дээрх системийн туршилт (backtesting)**: Хэт нийцэл (overfitting) сэргийлж, бодит санхүүгийн таамаглалын нөхцөлд шалгасан
- **"Predictrix" React Native аппликейшн**: Хэрэглэгчдэд хүртээмжтэй, практик хэрэглээтэй систем
- **Цог шийдэл (end-to-end solution)**: Өгөгдлөөс эхлэн машин сургалт (machine learning)-ын сургалт, түүхэн өгөгдөл дээрх системийн туршилт (backtesting), гар утасны (mobile) апп хүртэлх цогц систем

3.7. Бүлгийн дүгнэлт

Энэ бүлэгт Forex зах зээлийн таамаглалд машин сургалт (machine learning)-ыг хэрэглэсэн судалгаануудыг шүүмжлэлтэй авч үзлээ. Уламжлалт машин сургалт (machine learning)-ын аргууд болон гүн сургалтын аргууд дээр тулгуурлан судалгаанууд хийгдсэн боловч, **GBDT ансамбль аргууд** нь санхүүгийн хүснэгтэн (tabular) өгөгдөлд хамгийн тохиромжтой гэдгийг олон судалгаанууд харуулсан. Гэсэн хэдий ч, Forex зах зээлд, ялангуяа олон хугацааны интервалын мэдээлэл ашиглан, урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) хийх, бодит санхүүгийн таамаглалын нөхцөлд шалгах талаар судалгаа хомс байна.

Шинж чанар (feature)-ууд нь дангаараа үр дүнгүй боловч машин сургалт (machine learning)-ын загварын шинж чанар (feature)-аар ашиглахад илүү үр дүнтэй байдаг. Олон хугацааны интервалын дүн шинжилгээ, урагш гүйлгэсэн баталгаажуулалт (walk-forward validation), бодит түүхэн өгөгдөл дээрх системийн туршилт (backtesting) зэрэг нь энэхүү судалгааны гол багана болж байна. Дараагийн бүлэгт судалгааны арга зүйг дэлгэрэнгүй танилцуулна.

4. Судалгааны арга зүй

Энэ бүлэгт судалгааны ажлын арга зүйг дэлгэрэнгүй тайлбарлана. Эхлээд судалгааны ерөнхий арга барилыг тодорхойлж, дараа нь системийн бүтэц, өгөгдлийн бэлтгэл, AI загварын архитектур, дохио үүсгэх механизм, MetaTrader 5 дээрх түүхэн өгөгдөл дээрх системийн туршилт (backtesting), серверийн болон мобайл аппликейшний хөгжүүлэлт, мөн үнэлгээний шалгуур үзүүлэлтүүдийг хамарна.

4.1. Судалгааны арга барил

Энэхүү судалгаа нь **дизайн шинжлэх ухаан** (Design Science Research – DSR) [28] арга зүйд суурилсан. DSR нь бодит асуудлыг шийдвэрлэхэд чиглэсэн цоо шинэ артефакт (систем, загвар, бүтээгдэхүүн) бүтээж, түүний ашиг тусыг туршилтаар баталгаажуулдаг [29]. Энэ судалгааны хувьд DSR-ийн дараахь гурван үндсэн зарчмыг баримтлав:

1. **Артефакт бүтээх**: Санхүүгийн зах зээлийн зах зээлийн таамаглалын үр дүн үүсгэж, мобайл аппликейшнаар хүргэх бүрэн бүтэн систем хөгжүүлэх
2. **Асуудалд чиглэсэн**: Жижиг трейдерүүдийн мэдээлэл дутмаг, мэргэжлийн дүн шинжилгээний хүртээмж бага байдлыг шийдвэрлэх
3. **Туршилтаар баталгаажуулах**: MetaTrader 5 Strategy Tester-ийн бодит зах зээлийн нөхцөлд (спрэд буюу spread, гулсалт буюу slippage) түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийж, системийн ашигт ажиллагааг шинжлэх ухааны аргаар үнэлэх

Судалгааны процесс нь **давталтат хөгжүүлэлт** (iterative development) загвараар явагдсан. Ye шат бүрд загварын гүйцэтгэлийг хэмжиж, сул талыг тодорхойлон, дараагийн хувилбарт засварлах мөчлөгийг 7 удаа давтсан. Энэхүү давталтат арга барил нь нэг удаагийн шугаман хөгжүүлэлтээс ялгаатай нь системийн чанарыг алхам алхмаар сайжруулах боломжийг олгосон.

4.2. Системийн ерөнхий бүтэц

Зураг 4.1 нь системийн үндсэн санааг товч харуулав: санхүүгийн зах зээлийн зах зээлийн өгөгдлийг автоматаар дүн шинжилгээ хийж, AI загвараар таамаглалын үр дүн үүсгэн, хэрэглэгчийн утасны аппликейшнд хүргэнэ.

Зураг 4.1 *Системийн үндсэн ойлголт – өгөгдлөөс трейдер хүртэлх урсгал*

Хөгжүүлсэн систем нь гурван үндсэн давхаргаас бүрдэнэ: (1) Машин сургалтын загварын давхарга, (2) серверийн хэсгийн давхарга, (3) мобайл аппликейшний давхарга. Зураг 4.2 нь энэ бүтцийг харуулав.

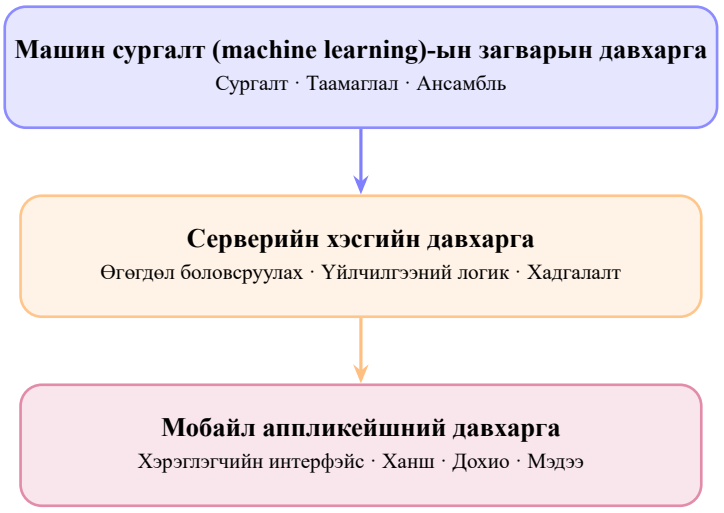

Зураг 4.2 *Системийн гурван давхаргат бүтэц*

Системийн ажиллах зарчим дараахь байдалтай:

1. **Машин сургалт (machine learning)-ын давхарга**: MetaTrader 5-аас татсан 10 жилийн түүхэн өгөгдлөөр 3 GBDT загварыг сургаж, зөөлөн санал хураалт (Soft Voting) ансамблиар нэгтгэн итгэлцлийн (confidence) утга тооцно. Тохируулга (Calibration)-ийг сүлжээнээс гадуурх (offline) үнэлгээнд ашиглаж, бодит ажиллах орчин (production runtime) дээр ансамблийн шууд магадлалыг хэрэглэнэ
2. **Серверийн хэсгийн давхарга**: Бодит цагийн мэдээллийг нэгтгэн боловсруулж, загварын дүгнэлт дээр суурилсан дохиог хадгалж, хэрэглэгчдэд түгээнэ
3. **Мобайл давхарга**: Харагдах хэсэг (frontend) нь серверийн хэсэг (backend)-тэй холбогдож ханш, дохио, мэдээг хэрэглэгчдэд ойлгомжтой байдлаар харуулна

4.3. Өгөгдлийн урсгал

Системд өгөгдөл хэрхэн урсаж, боловсруулагддагийг Зураг 4.3 харуулав. Гадаад эх сурвалжаас (MetaTrader 5, Yahoo Finance, TradingView, AlphaVantage) өгөгдөл орж ирэн, серверийн хэсэг (backend) дээр боловсруулагдаж, эцэст нь мобайл аппликейшнаар хэрэглэгчдэд хүрнэ.

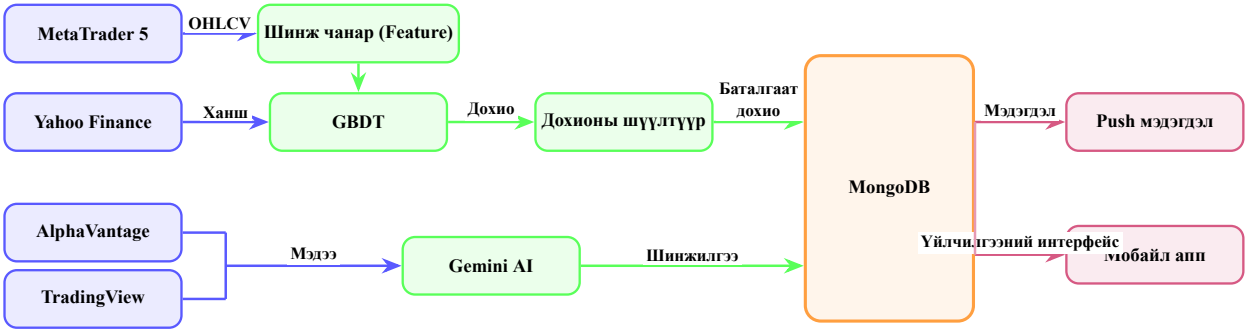

Зураг 4.3 *Өгөгдлийн урсгалын диаграмм (Data Flow Diagram)*

Өгөгдлийн урсгалын гол шатуудыг тайлбарлавал:

- **Өгөгдөл цуглуулах**: MetaTrader 5-аас 10 жилийн OHLCV (Нээлтийн үнэ, Дээд үнэ, Доод үнэ, Хаалтын үнэ, Эзлэхүүн), Yahoo Finance-аас бодит цагийн ханш, AlphaVantage (мэдээний уур амьсгал буюу сентимент (sentiment)) болон TradingView (эдийн засгийн хуанли (economic calendar))-аас эдийн засгийн мэдээ татна
- **Шинж чанар (Feature) тооцоолох**: 6 хугацааны интервалаас (M1, M5, M15, M30, H1, H4) тус бүр 8 шинж чанар (feature) тооцоолж, нийт 48 шинж чанар (feature) үүсгэнэ
- **Таамаглал хийх**: LightGBM, XGBoost, CatBoost гурван загварын ансамбль магадлалаар дохио үүсгэнэ
- **Шүүж хадгалах**: Итгэлцэл (confidence) $\geq$ 90%, бодит дундаж хэлбэлзэл (ATR буюу Average True Range) $\geq$ 4.0 пипс шалгуурыг хангасан дохиог өгөгдлийн сан (MongoDB)-д хадгалж, хэрэглэгчдэд push мэдэгдэл илгээнэ
- **Хэрэглэгчид хүргэх**: Мобайл аппликейшн нь серверийн хэсэг (backend)-тэй холбогдон бүх мэдээллийг бодит цагт хүлээн авна

4.4. Өгөгдлийн бэлтгэл

Түүхэн өгөгдөл

MetaTrader 5 платформоос EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 4.1 нь интервал бүрийн өгөгдлийн хэмжээг харуулав.

Хүснэгт 4.1 *Түүхэн өгөгдлийн хэмжээний хураангуй*

Интервал (Timeframe)	Мөрийн тоо	Хугацаа
M1 (1 минут)	∼3,700,000	2015–2024
M5 (5 минут)	∼740,000	2015–2024
M15 (15 минут)	∼247,000	2015–2024
M30 (30 минут)	∼123,000	2015–2024
H1 (1 цаг)	∼62,000	2015–2024
H4 (4 цаг)	∼15,500	2015–2024

Олон цагийн интервал бүхий өгөгдлийг хослуулах замаар загвар нь зах зээлийн богино хугацааны хэлбэлзэл (M1, M5), дунд хугацааны чиг хандлага (M15, M30), мөн урт хугацааны бүтэц (H1, H4)-ыг нэгэн зэрэг харах боломжтой болсон. Энэ олон хугацааны интервалын арга нь [17] шинж чанарын инженерчлэл (feature engineering) буюу “олон хугацааны хүрээ” (multiple timeframe analysis) зарчимд нийцнэ.

Шинж чанар (Feature)ын инженерчлэл (feature engineering)

Интервал бүрээс 8 шинж чанар (feature) тооцоолж, нийт 48 шинж чанар (feature) бүхий матриц үүсгэсэн. Хүснэгт 4.2 нь шинж чанарууд (features)ыг жагсаав.

Хүснэгт 4.2 *Шинж чанар (Feature)ын жагсаалт (интервал бүрд)*

№	Шинж чанар (Feature)	Тайлбар
1	`close`	Тухайн candle-ийн хаалтын үнэ
2	`rsi`	RSI (14 candle) — хэт худалдсан/хэт худалдан авсан байдлыг 0–100 хуваарьт хэмждэг импульс шинж чанар (feature)
3	`atr`	ATR (14 candle) — сүүлийн 14 candle-ийн дундаж жинхэнэ хэлбэлзэл; зах зээлийн эрсдэлийн хэмжүүр
4	`ma_5`	Сүүлийн 5 candle-ийн хаалтын үнийн энгийн гулсах дундаж (SMA) — богино хугацааны чиглэл
5	`ma_20`	Сүүлийн 20 candle-ийн SMA — дунд хугацааны чиглэл
6	`ma_50`	Сүүлийн 50 candle-ийн SMA — урт хугацааны чиглэл
7	`volatility`	Сүүлийн 20 candle-ийн хаалтын үнийн стандарт хазайлт; зах зээлийн тайван эсвэл тавгүй байдлын үзүүлэлт
8	`returns`	Өмнөх candle-тэй харьцуулсан үнийн өөрчлөлтийн хувь (`pct_change`)

Шинж чанар (Feature)уудыг `_1min`, `_5min`, `_15min`, `_30min`, `_1H`, `_4H` гэсэн дагаваруудаар ялгана. Жишээлбэл, `rsi_1min` нь 1 минутын RSI, `atr_4H` нь 4 цагийн ATR-ийг илэрхийлнэ. 1 минутын суурь өгөгдлөөс бусад интервалуудын шинж чанар (feature)ыг `merge_asof` (backward) аргаар нэгтгэсэн.

Шошго (Label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) үнийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

$$\text{label} = \begin{cases} \text{BUY (1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \tag{4.1}$$

Үүнд:

- Δ_{up} – ирээдүйн 240 минутын хамгийн дээд үнэ ба одоогийн хаалтын үнийн зөрүү (пипсээр)
- Δ_{down} – одоогийн хаалтын үнэ ба ирээдүйн хамгийн доод үнийн зөрүү (пипсээр)
- 30 пипс – хамгийн бага шаардлагатай хөдөлгөөн (шуугианаас ялгах)
- 1.5 дахин давамгайлал – чиг хандлагын тодорхой байдлыг шаардах

Өгөгдлийн хуваалт – урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)

Цаг хугацааны дараалыг хадгалсан урагш гүйлгэсэн баталгаажуулалт (walk-forward validation, WFV) аргачлалыг ашигласан. Энэ нь уламжлалт k-fold cross-validation-аас ялгаатай нь цаг хугацааны дараалыг зөрчихгүй тул санхүүгийн загварт зохимжтой. Хүснэгт 4.3 нь хуваалтын дэлгэрэнгүйг харуулав.

Хүснэгт 4.3 *Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) – өгөгдлийн хуваалт*

Бүлэг	Хугацаа	Candle-ын тоо	Зорилго
Сургалт	2015–2022	∼2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	∼371,000	Early stopping, calibration (10%)
Тест	2024	∼371,000	Эцсийн үнэлгээ (10%)

Зураг 4.4 нь энэхүү хуваалтыг цаг хугацааны тэнхлэг дээр дүрслэн харуулав. Сургалтын өгөгдөл (80%) баталгаажуулалтын өгөгдөл (10%) тестийн өгөгдөл (10%)-өөс цаг хугацааны дараалаар ялгагдана.

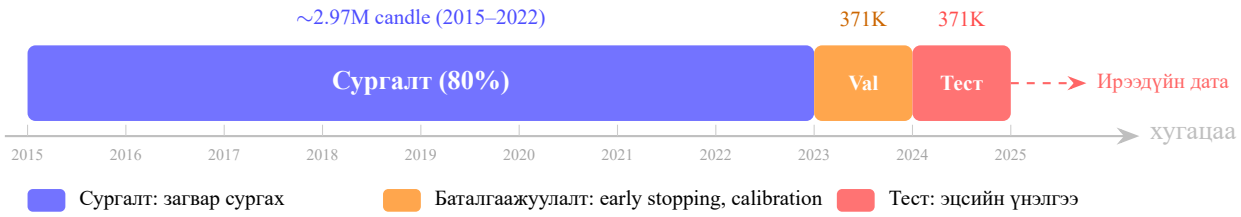

Зураг 4.4 *Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) – цаг хугацааны дараалыг хадгалсан өгөгдлийн хуваалт*

Энэ хуваалтаар загварыг сургахдаа зөвхөн тухайн цэгийн өмнөх өгөгдлийг ашигладаг тул ирээдүйн мэдээлэл алдагдах (look-ahead bias) асуудлаас бүрэн сэргийлнэ. Санхүүгийн цуваа өгөгдөлд уламжлалт k-fold cross-validation ашиглах нь цаг хугацааны бүтцийг эвдэж, зохиомол өндөр үр дүн үзүүлэх эрсдэлтэй тул WFV нь стандарт хандлага юм [23].

4.5. AI загварын бүтэц ба сургалт

Ансамбль загварын архитектур

Системийн загвар нь гурван GBDT (Gradient Boosted Decision Trees) загвараас бүрдэх Soft Voting ансамбль юм. GBDT нь олон модны нэгтгэсэн загвар бөгөөд санхүүгийн өгөгдлийн хүснэгтийн (tabular) бүтэцтэй сайн нийцдэг [2]. Загвар бүр нь ижил 48 шинж чанар (feature)-ыг хүлээн авч, BUY, SELL, HOLD гурван ангиллын магадлалыг тус тусдаа тооцоолно. Эдгээр магадлалуудыг дундажилж эцсийн итгэлцэл (confidence) үүсгэнэ. Logistic Regression магадлалын тохируулгыг (probability calibration) сургалтын үеийн баталгаажуулалтын шинжилгээнд ашигласан боловч бодит ажиллах орчинд (production runtime) тогтмол утга өгөх эрсдэл ажиглагдсан тул шууд ансамблийн магадлал ашиглах бодлого руу шилжүүлсэн. Зураг 4.5 нь энэхүү бүтцийг харуулав.

Энд нэг чухал ялгаа бий: **загварын ангиллын гаралт** нь BUY/SELL/HOLD (3 ангилал), харин **гүйцэтгэлийн түвшний хэрэгжих үйлдэл** нь BUY эсвэл SELL (2 үйлдэл) юм. HOLD ангилал сонгогдсон үед систем шинэ байрлал нээхгүй, өөрөөр хэлбэл “үйлдэлгүй төлөв” (no-trade state) гэж үзнэ.

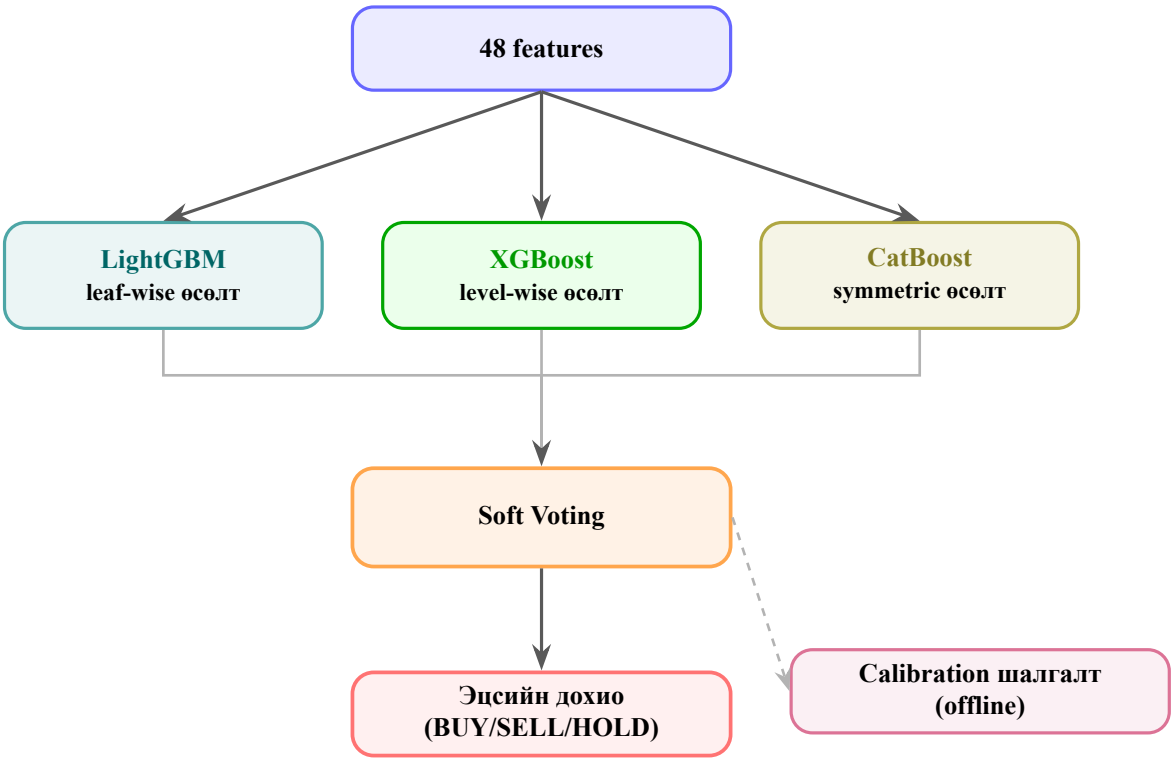

Зураг 4.5 *GBDT ансамбль загварын архитектур*

Гурван загварыг ансамбль хэлбэрээр хослуулсан шалтгаан нь тус бүр нь өөр өөр давуу талтай:

- **LightGBM**: Leaf-wise (навч чиглэлтэй) модны өсөлт ашигладаг тул сургалтын хурд маш өндөр. Их хэмжээний өгөгдөлд тохиромжтой
- **XGBoost**: Level-wise (түвшин чиглэлтэй) модны өсөлт болон L1/L2 нормчлолоор тогтвортой гүйцэтгэл үзүүлдэг. Тохируулах параметрийн уян хатан байдал өндөр
- **CatBoost**: Symmetric (тэгш хэмт) модны бүтэц, ordered boosting ашиглан хэт нийцэл (overfitting)-аас хамгийн сайн хамгаалагддаг

Хүснэгт 4.4 нь загвар бүрийн гол гиперпараметрүүдийг харуулав.

Хүснэгт 4.4 *Загвар бүрийн гол гиперпараметрүүд*

Параметр	LightGBM	XGBoost	CatBoost
Модны тоо (n_estimators)	496	∼400	499
Хамгийн их гүн (max_depth)	6	5	5
Сургалтын хурд (learning_rate)	0.03	0.03	0.03
L1 нормчлол (reg_alpha)	Тийм	Тийм	–
L2 нормчлол (reg_lambda)	Тийм	Тийм	Тийм
Early stopping (patience)	50 давталт	50 давталт	50 давталт
Модны өсөлтийн арга	Leaf-wise	Level-wise	Symmetric

Хэт нийцэл (overfitting)-аас сэргийлэх арга хэмжээ

Санхүүгийн загварт хэт нийцэл (overfitting) нь хамгийн чухал сорилт юм. Сургалтын өгөгдлийг хэт сайн цээжлэх нь шинэ өгөгдөл дээр гүйцэтгэл буурахад хүргэдэг. Үүнээс сэргийлэх дараахь арга хэмжээнүүдийг авсан:

1. **Модны гүнийг хязгаарлах** (`max_depth=5--6`): Гүн бага мод нь ерөнхийлөн суралцах чадвартай тул шинэ өгөгдөл дээр илүү тогтвортой ажилладаг
2. **Сургалтын хурдыг бага тогтоох** (`learning_rate=0.03`): Загварыг удаан боловч илүү нарийвчлалтай сургах. Алхам бүрд бага зэргийн өөрчлөлт хийдэг
3. **Early stopping**: Баталгаажуулалтын алдаа 50 давталт дотор сайжрахгүй бол сургалтыг зогсоох
4. **L1/L2 нормчлол**: Загварын жингүүдийг хэт их болгохоос сэргийлж, ерөнхийлөн суралцах чадварыг нэмэгдүүлэх
5. **Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)**: Цаг хугацааны дараалыг хадгалж, ирээдүйн өгөгдөл сургалтад нэвтрэхээс сэргийлэх
6. **Шинж чанар (feature) хялбаржуулалт**: Анхны 75 шинж чанар (feature)-аас 48 болгож бууруулсан. Хэт олон шинж чанар (feature) нь загварыг шуугианд суралцуулах эрсдэлтэй

Сургалтын алгоритм

Загварын сургалтын алгоритмыг Алгоритм 1 нь харуулав.

Algorithm 1 Ансамбль загварын сургалтын алгоритм

Require: Өгөгдлийн бүтэц $D = \{(x_i, y_i)\}_{i=1}^{N}$, хугацааны хуваалт
Ensure: Сургагдсан ансамбль загвар $\mathcal{M}$

```
D_train, D_val, D_test ← TimeSplit(D)
Шинж чанар (Feature) тооцоолох: X ← ComputeFeatures(D) {48 шинж чанар (feature)}
for загвар k ∈ {LightGBM, XGBoost, CatBoost} do
    M_k ← Train(X_train, y_train, eval_set = X_val, early_stopping = 50)
end for
Загвар бүрийн магадлал: P_k ← M_k.predict_proba(X_val), k = 1, 2, 3
Дундаж магадлал: P̄ ← (1/3)(P_1 + P_2 + P_3)
Optional offline calibration: LR ← LogisticRegression.fit(P̄, y_val)
Runtime итгэлцэл (confidence): c ← max(P̄)
Тест дээр үнэлэх: accuracy(M, X_test, y_test)
return M = {M_1, M_2, M_3}
```

4.6. Дохио үүсгэх систем

Дохионы шүүлтүүр

Загварын таамгаас чанартай дохиог ялгахын тулд хоёр шүүлтүүр ашигласан. HOLD ангилал нь энэ шатанд BUY/SELL мэт “дохио” биш, харин арилжаанд орохгүй гэсэн төлөв тул хэрэгжих захиалгын урсгалд орохгүй:

- **Итгэлцлийн босго**: Ансамблийн итгэлцэл (confidence) $\geq$ 0.90 (90%). Загвар 90%-аас дээш итгэлтэй тохиолдолд л дохио үүсгэнэ

- **ATR шүүлтүүр**: ATR $\geq$ 4.0 пипс. Зах зээлд хангалттай хэлбэлзэл байх үед л дохио өгнө (бага хэлбэлзэлтэй үед арилжаа хийх нь ашиггүй)

2025 оны өгөгдөл дээрх анхны 359,639 таамгаас итгэлцэл (confidence) $\geq$ 90% босгонд 3,567 нь (1.0%) эдгээр шалгуурыг хангасан. Зураг 4.6 нь энэхүү шүүлтүүрийн процессыг юүлүүр диаграммаар харуулав.

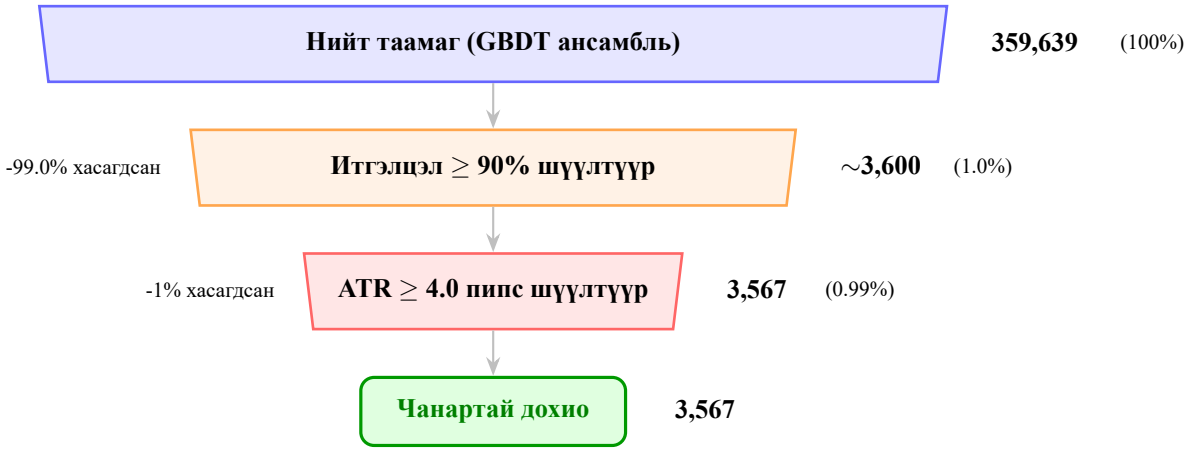

Зураг 4.6 *Дохионы шүүлтүүрийн юүлүүр диаграмм – 359,639 таамгаас 3,567 чанартай дохио*

Stop Loss ба Take Profit тооцоолол

SL/TP-г ATR (Average True Range) дээр суурилан динамикаар тооцоолсон:

$$SL = \max(\text{ATR}_{14} \times 5.0,\ 15 \text{ пипс}) \tag{4.2}$$

$$TP = \max(SL \times 3.0,\ 45 \text{ пипс}) \tag{4.3}$$

Энэ аргын давуу тал нь зах зээлийн хэлбэлзэлд тохируулан SL/TP-г динамикаар тогтоодог. Хэлбэлзэл их байхад SL/TP өргөн, бага байхад нарийн болно. Гол параметрүүд:

- SL-ийн ATR үржвэр: 5.0 – зах зээлийн шуугиан, спрэдийг тооцоолсон
- TP/SL харьцаа: 3:1 – 33% нарийвчлалтай ч ашигтай байх боломжтой эрсдэл-өгөөжийн харьцаа
- Хамгийн бага SL: 15 пипс – хэт бага SL нь шуугиан дээр зогсох эрсдэлтэй
- Хамгийн бага TP: 45 пипс – утга бүхий ашгийг баталгаажуулах

Дохио үүсгэх дараалын диаграмм

Зураг 4.7 нь серверийн хэсэг автоматаар дохио үүсгэх бүрэн дараалыг харуулав.

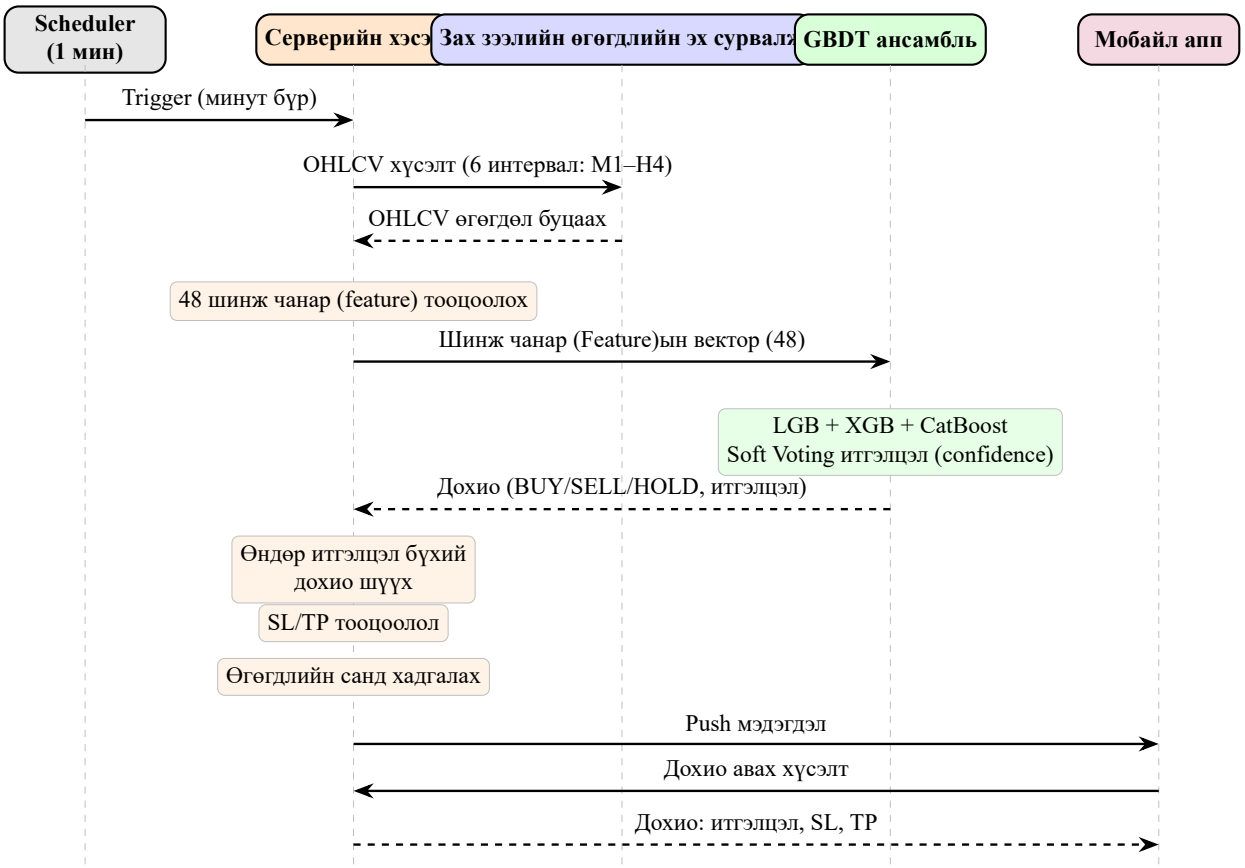

Зураг 4.7 *Дохио үүсгэх дараалын диаграмм (Sequence Diagram)*

Дараалын диаграммаас харахад, дохио үүсгэх процесс дараах дараалаар явагдана:

1. Scheduler минут бүр автоматаар серверийн тооцооллын мөчлөгийг ажиллуулна
2. Сервер нь гадаад эх сурвалжаас 6 интервалын (M1, M5, M15, M30, H1, H4) OHLCV өгөгдлийг татна
3. Татсан өгөгдлөөс 6 интервалын 48 шинж чанар (feature)ыг тооцоолно
4. GBDT ансамбль загвараар BUY/SELL/HOLD гурван ангиллын магадлалыг тооцоолно
5. HOLD ангилал гарвал шинэ байрлал нээхгүй; BUY/SELL ангилалд итгэлцэл ($\geq$90%) болон ATR ($\geq$4 пипс) шүүлтүүрийг давсан тохиолдолд л хэрэгжих дохио үүснэ
6. Динамик SL/TP-г ATR дээр суурилан тооцоолно
7. Дохиог өгөгдлийн санд хадгалж, мобайл апп руу мэдэгдэл илгээнэ
8. Мобайл апп хүсэлтээр дохионы мэдээллийг авч хэрэглэгчид харуулна

4.7. MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилт (backtesting)

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн логик

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлд эрсдэлийн удирдлагатай гүйцэтгэгч модуль ашиглаж, дохио бүр дээр байрлалын хэмжээ, итгэлцлийн босго, гулсалтын хязгаар зэрэг дүрмийг тогтмол мөрдсөн. Хүснэгт 4.5 нь энэ хэсгийн үндсэн тохиргоог харуулав.

Хүснэгт 4.5 *Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) гүйцэтгэлийн үндсэн тохиргоо*

Параметр	Утга	Тайлбар
Арилжаа бүрийн эрсдэл	1.0%	Нэг дохион дээр авах эрсдэлийн хувь
Нэг удаагийн байрлалын дээд тоо	1	Давхар байрлал нээхээс сэргийлсэн
Итгэлцлийн доод босго	0.90	Чанарын шүүлтүүрийн үндсэн босго
Зөвшөөрөгдөх гулсалтын хязгаар	10 point	Гүйцэтгэлийн бодит нөхцөлийг тусгасан

Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) нөхцөл

- **Платформ**: MetaTrader 5 Strategy Tester
- **Горим**: Every tick (бүх тикийн өгөгдөл – хамгийн бодит нөхцөл)
- **EA тестийн цонх**: 2025.01.01 – 2026.01.01
- **Анхны хөрөнгө**: $10,000
- **Хэрэгсэл**: EUR/USD (бодит спрэд)
- **Суурь дохионы багц**: 0.90 итгэлцлийн шүүлтүүртэй суурь багц (3,567 дохио)
- **Нэмэлт sweep багцууд**: 0.91–0.99 мужийн урьдчилан шүүсэн дохионы багцууд; EA талын runtime итгэлцлийн босго 0.90 дээр тогтмол байсан бөгөөд ялгаа нь оролтын шүүлтүүрээс үүссэн
- **Дохио/өдөр үзүүлэлт**: sweep нэгтгэлийн effective day count (312 өдөр)-д суурилан тооцсон

Үнэлгээний шалгуур үзүүлэлтүүд

Загварын болон системийн гүйцэтгэлийг үнэлэхэд дараах, энэ тайланд бодитоор тайлагнасан шалгуур үзүүлэлтүүдийг ашигласан. Хүснэгт 4.6 нь тэдгээрийн тодорхойлолт болон үнэлгээний чиглэлийг нэгтгэн харуулав.

Хүснэгт 4.6 *Системийн үнэлгээний шалгуур үзүүлэлтүүд*

Үзүүлэлт	Тодорхойлолт	Үнэлгээний чиглэл
Загварын ангиллын үзүүлэлтүүд (Chapter 4-т тайлагнасан)		
Тестийн нарийвчлал (Accuracy)	2024 оны тест хуваалтын зөв ангиллын хувь	Өндөр байх тусам сайн
Өндөр итгэлцэлтэй дохионы нарийвчлал	Итгэлцэл өндөр муж дахь зөв ангиллын хувь	Өндөр байх тусам сайн
Threshold sweep-ийн системийн үзүүлэлтүүд (Chapter 4-т тайлагнасан)		
Эцсийн баланс ($)	Sweep бүрийн туршилтын эцсийн хөрөнгө	Өндөр байх тусам сайн
Цэвэр ашиг ($)	Эцсийн баланс – анхны хөрөнгө ($10,000)	Өндөр байх тусам сайн
Өгөөж (%)	$\frac{\text{Final Balance} - 10{,}000}{10{,}000} \times 100$	Өндөр байх тусам сайн
Дохио/өдөр	Нийт дохиог effective day count-д харьцуулсан давтамж	Хэрэглээний ачааллаас хамаа
Дохио тутмын ашиг ($)	Нэг дохионд ногдох дундаж ашиг	Өндөр байх тусам сайн

Энэ судалгаанд ангиллын чанарыг тестийн нарийвчлал болон өндөр итгэлцэлтэй дохионы нарийвчлалаар, системийн үр ашгийг threshold sweep-ийн балансын агрегат үзүүлэлтүүдээр үнэлсэн.

Санхүүгийн туршилтад дохио/өдөр зэрэг давтамжийн үзүүлэлт нь ашигласан effective day count-ооc хамаарах тул түүний тооцооллын суурийг Хүснэгт 5.3-ийн доор ил тод тайлбарласан.

4.8. Серверийн хэсгийн хэрэгжүүлэлт

Архитектурын үндсэн бүрэлдэхүүн

Серверийн хэсэг нь бодит цагийн мэдээлэл боловсруулах, дохио үүсгэх, хэрэглэгчийн хүсэлтийг боловсруулах, болон мобайл аппликейшнтэй өгөгдөл солилцох үүргийг гүйцэтгэнэ. Хүснэгт 4.7 хүснэгтэд энэ давхаргын үндсэн бүрэлдэхүүнийг нэгтгэв.

Хүснэгт 4.7 *Серверийн хэсгийн үндсэн бүрэлдэхүүн*

Бүрэлдэхүүн	Үүрэг
Вэб үйлчилгээний давхарга	Мобайл аппликейшнээс ирсэн хүсэлтийг хүлээн авч, мэдээлэл дамжуулах
Өгөгдлийн сангийн давхарга	Дохио, хэрэглэгчийн мэдээлэл, статистикийг найдвартай хадгалах
Нэвтрэлтийн хяналт	Хэрэглэгчийн нэвтрэлтийн аюулгүй байдлыг хангах
Мэдэгдлийн үйлчилгээ	Дохио болон чухал үйл явдлын мэдээллийг хэрэглэгчид хүргэх

Үйлчилгээний функцийн бүлгүүд

Серверийн хэсгийн үйлчилгээг судалгааны зорилготой уялдуулан дараах үндсэн бүлгүүдэд зохион байгуулсан.

Хүснэгт 4.8 *Серверийн хэсгийн функцийн бүлгүүд*

Бүлэг	Тайлбар
Нэвтрэлт ба хэрэглэгч	Бүртгэл, нэвтрэлт, профайл шинэчлэлт, нууц үгийн удирдлага
Ханшийн мэдээлэл	Бодит цагийн ханш болон сонгосон хослолын мэдээлэл авах
Дохионы мэдээлэл	Одоогийн болон түүхэн дохио, гүйцэтгэлийн статистик боловсруулах
Мэдээ, шинжилгээ	Эдийн засгийн мэдээ болон тайлбар шинжилгээ хүргэх
Мэдэгдэл	Push болон апп доторх мэдэгдлийн тохиргоо, төлөвийн удирдлага

Нэвтрэлтийн аюулгүй байдал ба тогтвортой ажиллагаа

Системийн нэвтрэлтийн хэсэгт богино наст токен ба сессийн баталгаажуулалт ашигласнаар буруу орчноос хандалт хийх, хугацаа хэтэрсэн сесс дахин ашиглагдах эрсдэлийг бууруулсан. Мөн серверийн тасралтгүй ажиллагааг хангахын тулд арын процессуудын давхардлыг хянах, алдаа гарсан үед сэргээн оролдох бодлого хэрэгжүүлсэн.

Серверийн арын процессууд

Серверийн хэсэг нь хэрэглэгчийн хүсэлт боловсруулахаас гадна автомат арын процессоор дараах үндсэн ажлуудыг тогтмол гүйцэтгэнэ:

1. Эдийн засгийн мэдээ болон үйл явдлын мэдээллийг шинэчлэх
2. Өндөр нөлөөтэй үйл явдлын талаар хэрэглэгчдэд мэдэгдэл хүргэх
3. Бодит ханш дээр суурилан автомат дохио үүсгэх
4. Серверийн эхлэлд шаардлагатай өгөгдлийг урьдчилан ачаалж гүйцэтгэлийг тогтворжуулах

Бодит цагийн ханшийн мэдээлэл

Систем нь гол валютын хослолуудын бодит ханшийг тогтмол шинэчилж, кэшийн механизмаар давтамжтай хүсэлтийн ачааллыг бууруулан ажилладаг. Энэ нь мобайл талд мэдээлэл тасалдахгүй хүрэх нөхцөлийг бүрдүүлдэг.

4.9. Мобайл аппликейшний хөгжүүлэлт

Технологийн стек

Хүснэгт 4.9 *Мобайл аппликейшний технологийн стек*

Технологи	Хувилбар	Үүрэг
React Native	0.74.5	Мобайл хөгжүүлэлтийн фреймворк
TypeScript	5.3.x	Төрлийн аюулгүй байдалтай код
Expo	51.0	Хөгжүүлэлт, бэлтгэлийн хэрэгсэл
React Navigation	6.x	Дэлгэцийн навигаци (Stack + Tab)
React Query	5.x	Серверийн өгөгдлийн менежмент, кэш
Axios	1.6+	HTTP хүсэлт (auto-retry)
AsyncStorage	–	Дотоод хадгалалт (нэвтрэлтийн мэдээлэл, тохиргоо)
Expo Notifications	–	Push мэдэгдэл хүлээн авах

Аппликейшний навигацийн бүтцийн диаграмм

Аппликейшний хэрэглэгчийн урсгалыг Зураг 4.8 харуулав. Нэвтрэлтийн дараа Bottom Tab Navigator-ийн 4 таб нэвтрэх боломжтой болно.

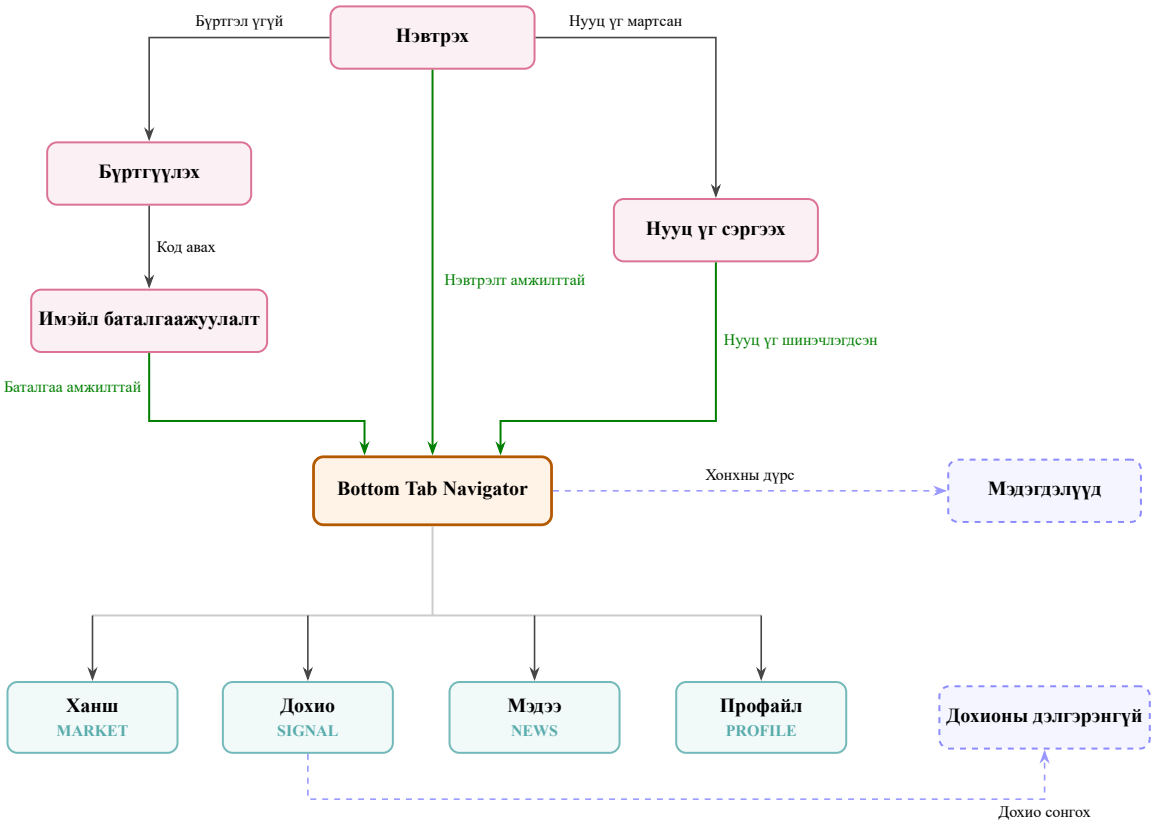

Зураг 4.8 *Мобайл аппликейшний хэрэглэгчийн навигацийн урсгал*

Хэрэглэгчийн нэвтрэлтийн дараалын диаграмм

Зураг 4.9 нь хэрэглэгч бүртгүүлэх болон нэвтрэх дараалыг харуулав.

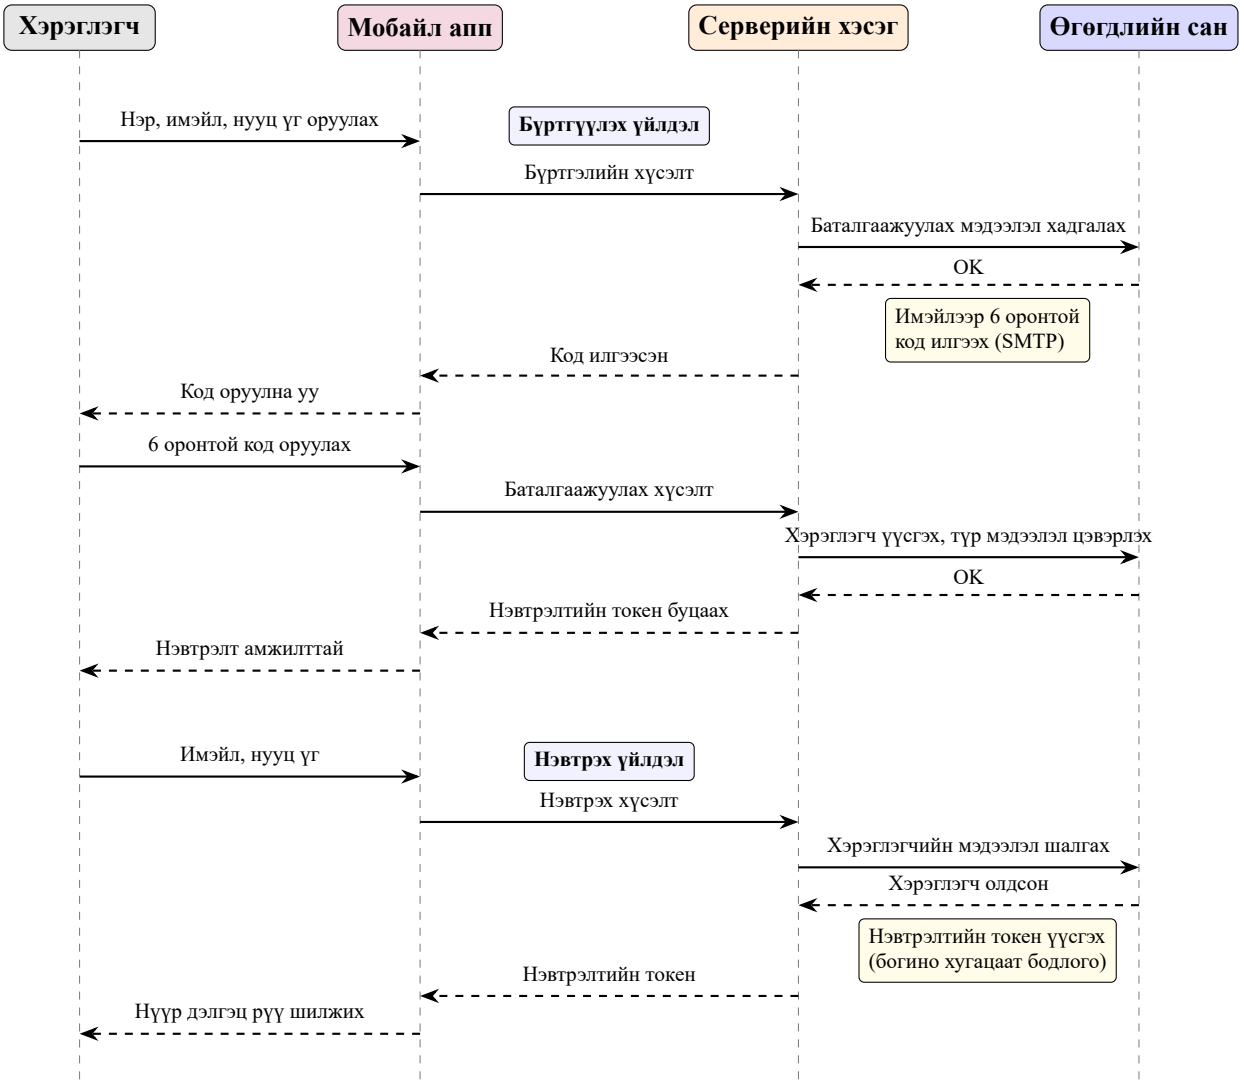

Зураг 4.9 *Хэрэглэгчийн бүртгэл ба нэвтрэлтийн дараалын диаграмм (Sequence Diagram)*

Бодит цагийн өгөгдлийн менежмент

Аппликейшн нь серверийн өгөгдлийг бодит цагийн горимоор удирдаж, тодорхой давтамжаар автоматаар шинэчилдэг. Мөн алдаа гарсан үед сэргээн оролдох бодлого болон сессийн хамгаалалтын механизмыг ашигласнаар хэрэглэгчийн урсгал тасалдах эрсдэлийг бууруулсан.

4.10. Загварын давталтат сайжруулалт

DSR арга зүйн дагуу загварын хөгжүүлэлтийг 7 давталтат (iterative) үе шатаар явуулсан. Үе шат бүрт “бүтээх → үнэлэх → сайжруулах” мөчлөгийг давтаж, өмнөх хувилбарын түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үр дүнд тулгуурлан сул талыг зассан. Зураг 4.10 нь энэ давталтат урсгал болон үе шат бүрийн гол өөрчлөлтийг нэгтгэн харуулав.

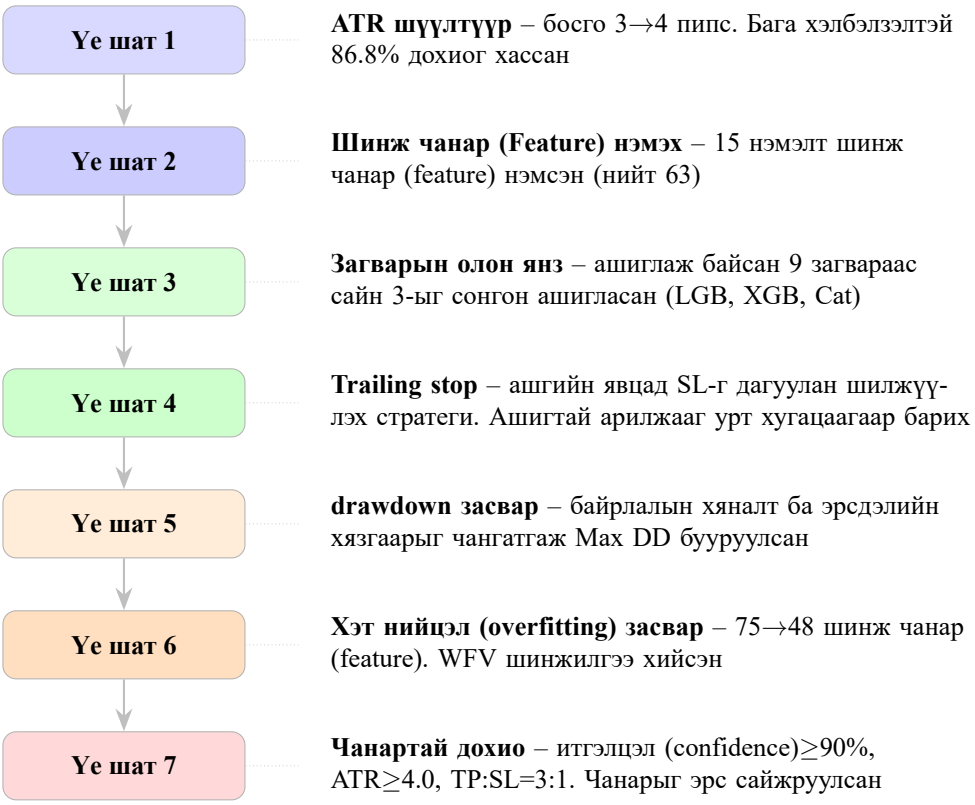

Зураг 4.10 *Загварын давталтат сайжруулалтын ye шатууд ба гол өөрчлөлтүүд*

4.11. Бүлгийн дүгнэлт

Энэ бүлэгт дизайн шинжлэх ухааны (DSR) арга зүйд суурилсан судалгааны арга зүйг дэлгэрэнгүй тайлбарлав. Арга зүйн гол хэсгүүдэд:

- **Өгөгдлийн бэлтгэл**: MetaTrader 5-аас 10 жилийн OHLCV өгөгдлийг 6 интервалаар татаж, олон хугацааны шинжилгээний зарчмаар 48 шинж чанар (feature) тооцоолсон
- **Загварын архитектур**: 3 GBDT загварын (LightGBM, XGBoost, CatBoost) Soft Voting ансамблийг урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)-аар сургаж, магадлалын тохируулга (probability calibration)-ыг сүлжээнээс гадуурх үнэлгээнд (offline evaluation) ашиглан бодит ажиллах орчинд (production runtime) шууд ансамблийн итгэлцэл (confidence)-ийг хэрэглэсэн
- **Дохионы чанарын хяналт**: Итгэлцэл $\geq$ 90%, ATR $\geq$ 4.0 пипс, TP:SL = 3:1 шүүлтүүрээр чанартай дохиог ялгасан
- **Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) баталгаажуулалт**: MT5 Strategy Tester-ийн бодит зах зээлийн нөхцөлд (спрэд, слиппэж) үнэлгээ хийсэн
- **Системийн хэрэгжүүлэлт**: Серверийн хэсэг (backend), өгөгдлийн сан, мобайл аппликейшнийг нэгтгэсэн цог архитектур (end-to-end architecture) хэрэгжүүлж, нэвтрэлт ба үйл ажиллагааны тогтвортой байдлыг баталгаажуулсан
- **Давталтат сайжруулалт**: 7 ye шаттай “бүтээх → үнэлэх → сайжруулах” мөчлөгөөр загварын чанарыг алхам дараалан сайжруулсан

Эдгээр бэлтгэсэн арга зүйн дагуу хөгжүүлсэн системийн бодит үр дүнгийн дэлгэрэнгүйг дараагийн бүлэгт танилцуулна.

5. Судалгааны үр дүн, дүгнэлт

5.1. Үр дүнгийн өгөгдлийн эх сурвалж

Энэ бүлгийн бүх тоон дүнг дараах хоёр эх сурвалжаас нэгтгэв.

- MetaTrader 5 түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) 10 гүйлтийн лог
- Threshold sweep-ийн нэгтгэсэн хүснэгтэн өгөгдөл

Лог файлууд нь хуримтлагдсан (cumulative) бүтэцтэй тул нэг threshold-ийн үр дүн дараагийн гүйлтүүдэд давтагдан орсон. Иймээс threshold бүрийн хувьд дохионы тоог заасан мөрийн **эхний илрэл** болон түүнтэй харгалзах эцсийн балансын мөрийг нотолгооны эх цэг болгон сонгов.

Эх сурвалжийн мөрийн баталгаа

Хүснэгт 5.1 *Threshold тус бүрийн лог нотолгооны эх мөрүүд*

Threshold	Дохио мөр	Баланс мөр	Дохионы тоо	Final balance ($)
0.90	38	2570	3,567	58,262.39
0.91	2617	4951	3,274	61,770.46
0.92	4981	7194	2,958	56,512.20
0.93	9501	11571	2,643	46,807.24
0.94	11618	13314	2,287	38,050.13
0.95	13361	14870	1,914	32,844.40
0.96	14917	16162	1,588	33,040.14
0.97	16209	17377	1,195	29,019.19
0.98	40	878	673	25,447.43
0.99	925	1312	147	17,428.89

Энд анхаарах нэг цэг нь бүх гүйлтэд EA талын runtime итгэлцлийн босго 0.90 дээр тогтмол байсан явдал юм. Иймээс threshold sweep-ийн ялгаа нь гүйцэтгэгчийн параметрийн өөрчлөлтөөс бус, урьдчилан шүүсэн оролтын дохионы багцуудын ялгаанаас үүссэн.

5.2. Загварын ангиллын үзүүлэлтүүд

Хүснэгт 5.2 хүснэгтэд энэ судалгаанд тайлагнасан загварын түвшний ангиллын гол үзүүлэлтүүдийг нэгтгэв.

Хүснэгт 5.2 *Загварын ангиллын баталгаажсан үзүүлэлтүүд*

Үзүүлэлт	Утга	Тайлбар
Тестийн нарийвчлал (Accuracy)	87.4%	2024 оны тест хуваалт дээрх зөв ангиллын хувь
Өндөр итгэлцэлтэй дохионы нарийвчлал	95%+	Өндөр итгэлцэлтэй муж дахь зөв ангиллын чан
Гаралтын ангиллын хэлбэр	BUY/SELL/HOLD	3 ангиллын таамаглал
Гүйцэтгэлийн үйлдлийн хэлбэр	BUY/SELL	Хэрэгжих захиалгын түвшний 2 үйлдэл

Эдгээр үзүүлэлт нь **загварын ангиллын чанар**-ыг, харин дараах threshold sweep хүснэгт нь **системийн оролт-үр ашгийн trade-off**-ийг тус тус харуулж байна.

5.3. Threshold sweep-ийн нэгтгэсэн үр дүн

Өгөөжийг дараах томьёогоор тооцсон:

$$\text{Return}(\%) = \frac{\text{Final Balance} - 10{,}000}{10{,}000} \times 100 \tag{5.1}$$

Хүснэгт 5.3 хүснэгтэд threshold өсөхөд дохионы тоо, дундаж итгэлцэл, эцсийн баланс хэрхэн өөрчлөгдсөнийг харуулав.

Хүснэгт 5.3 *0.90–0.99 threshold sweep-ийн баталгаажсан дүн*

Threshold	Нийт дохио	Дохио/өдөр	Дундаж итгэлцэл	Final balance ($)	Net profit ($)	Өгөөж (%)	Дохио тутмын ашиг ($)
0.90	3,567	11.43	0.9489	58,262.39	48,262.39	482.62	13.53
0.91	3,274	10.49	0.9533	61,770.46	51,770.46	517.70	15.81
0.92	2,958	9.48	0.9580	56,512.20	46,512.20	465.12	15.72
0.93	2,643	8.47	0.9626	46,807.24	36,807.24	368.07	13.93
0.94	2,287	7.33	0.9674	38,050.13	28,050.13	280.50	12.27
0.95	1,914	6.13	0.9723	32,844.40	22,844.40	228.44	11.94
0.96	1,588	5.09	0.9763	33,040.14	23,040.14	230.40	14.51
0.97	1,195	3.83	0.9806	29,019.19	19,019.19	190.19	15.92
0.98	673	2.16	0.9858	25,447.43	15,447.43	154.47	22.95
0.99	147	0.47	0.9918	17,428.89	7,428.89	74.29	50.54

Тайлбар: **Дохио/өдөр** үзүүлэлтийг Нийт дохио/312 томьёогоор тооцсон. Энд 312 нь sweep нэгтгэлийн effective day count юм.

5.4. Үр дүнгийн тайлбар

Хамгийн өндөр нийт өгөөжтэй цэг

Нийт өгөөжийн хувьд хамгийн сайн дүн нь threshold 0.91 дээр гарсан: $61,770.46 (+517.70%). Энэ нь threshold-ийг зөвхөн өсгөхөд үргэлж илүү сайн нийт ашиг гарна гэсэн үг биш гэдгийг харуулж байна.

Чанар-тоо хэмжээний зөрчил (trade-off)

Threshold 0.90-ээс 0.99 хүртэл өсөхөд:

- Нийт дохио 3,567-оос 147 болж 95.88%-аар буурсан
- Нийт өгөөж +482.62%-аас +74.29% хүртэл буурсан
- Харин дохио тутмын дундаж ашиг $13.53-аас $50.54 хүртэл өссөн

Энэ нь **чанартай (өндөр итгэлцэлтэй) дохио** цөөрөх тусам нэг дохионы үр ашиг өсч болох ч, нийт оролтын давтамж хэт багассанаар хуримтлагдсан ашиг буурдаг гэдгийг илэрхийлнэ. Санхүүгийн туршилтад ийм дээжийн хэмжээний (sample size) нөлөөг давхар авч үзэх шаардлагатайг [23, 24] онцолдог.

Орон нутгийн хэлбэлзэл

0.95 ба 0.96 дээр жижиг зөрүү ажиглагдсан ($32,844.40 → $33,040.14). Энэ нь threshold-оос гадна тухайн хугацаанд таарсан хэлбэлзэл, байрлал хаагдах дараалал зэрэг execution-level хүчин зүйлс үр дүнд нөлөөлдгийг харуулна.

5.5. Практик шийдвэр гаргалтын хүрээ

Энэ судалгааны sweep-ийн хүрээнд дараах байдлаар практик тайлбар хийж болно.

- **Нийт өгөөжийг** түлхүү зоривол: threshold 0.90–0.92 муж илүү тохиромжтой
- **Дохионы тоог** багасгаж, зөвхөн өндөр итгэлцэлтэй оролт хүсвэл: threshold 0.97+ муж тохиромжтой

- **Тэнцвэрт сонголт**: 0.91 орчим нь энэ датасет дээр хамгийн өндөр нийт өгөөжтэй цэг болсон

Энд “хамгийн сайн threshold” нь универсал тогтмол утга биш; өгөгдлийн хугацаа, зах зээлийн горим, зардлын нөхцөл өөрчлөгдвөл дагаад өөрчлөгдөх боломжтой.

5.6. Бүлгийн дүгнэлт

Энэ бүлэгт 0.90–0.99 threshold sweep-ийн лог болон нэгтгэсэн үр дүн дээр суурилсан баталгаажсан дүнг системтэйгээр нэгтгэлээ. Гол дүгнэлт нь: (i) бүх threshold эерэг өгөөжтэй дууссан, (ii) нийт өгөөжийн оргил цэг 0.91 дээр ажиглагдсан, (iii) threshold-ийг хэт өндөрсгөхөд дохионы чанар өсөх боловч нийт өгөөж буурдаг гэсэн trade-off тодорхой гарсан явдал юм. Иймээс системийн бодит хэрэглээнд threshold сонголтыг зөвхөн нэг KPI-ээр биш, **нийт өгөөж + дохионы давтамж + эрсдэлийн шаардлага**-ын хамтарсан шалгуураар тогтоох нь зүйтэй.

5.7. Дүгнэлт

Судалгааны гол үр дүн

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан Forex зах зээлийн таамаглалын цогц системийг амжилттай хөгжүүлсэн. Гол үр дүнгүүд:

1. **Машин сургалт (machine learning) ансамбль загвар**: LightGBM, XGBoost, CatBoost гэсэн гурван GBDT загварын ансамбль нь 6 хугацааны хүрээний 48 шинж чанар (feature)-ыг ашиглан EUR/USD-ийн чиг хандлагыг амжилттай таамаглаж чадсан. Урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)-аар баталгаажуулсан тест дээрх нарийвчлал (accuracy) 87.4%, өндөр итгэлцэлтэй дохионы нарийвчлал 95%+ байсан. Загварын ангиллын гаралт BUY/SELL/HOLD (3 ангилал) боловч хэрэгжих захиалгын түвшинд BUY/SELL (2 үйлдэл) болж ашиглагдсан.

2. **Түүхэн өгөгдөл дээрх системийн туршилт (backtesting)-ийн гүйцэтгэл**: EA талын runtime итгэлцлийн босгыг 0.90 дээр тогтмол байлгаж, 0.90–0.99 мужийн урьдчилан шүүсэн дохионы багцаар хийсэн sweep туршилтад:

   - Бүх тохиргоо эерэг өгөөжтэй дууссан (+74.29% – +517.70%)
   - Хамгийн өндөр эцсийн баланс: $61,770.46 (0.91 threshold)
   - 0.90 threshold тохиргоонд $58,262.39 эцсийн баланс, +482.62% өгөөж гарсан
   - Итгэлцлийн (confidence) босго өсөхөд дохионы тоо 3,567-оос 147 хүртэл буурч, тоо-чанарын тэнцвэр тодорхой ажиглагдсан

3. **Мобайл аппликейшн**: React Native дээр суурилсан бүрэн функциональ “Predictrix” аппликейш-нийг хөгжүүлж, бодит цагийн ханш, машин сургалт (machine learning)-ын дохио, эдийн засгийн мэдээ, AI шинжилгээг нэг дор хүргэсэн.

4. **Хэт нийцэл (overfitting) эрсдэлийн бууралт**: 7 давталтат хөгжүүлэлтийн үе шатаар загварыг хялбаршуулж (75→48 шинж чанар (feature), 9→3 загвар), урагш гүйлгэсэн баталгаажуулалт (walk-forward validation)-аар баталгаажуулснаар түүврийн гадуурх (out-of-sample) тогтвортой байдлыг сайжруулсан.

5. **Бодит хэрэглээний (Production) хэрэгжүүлэлт**: Серверийн хэсэг (backend)-ийн тогтвор-той ажиллагаа, өгөгдлийн сангийн холбоос, дохио үүсгэх модуль зэрэг үйл ажиллагааны (operational) шалгалтуудыг амжилттай баталгаажуулсан.

Судалгааны шинэлэг тал

- **Олон хугацааны хүрээний шинж чанар (feature)**: 6 хугацааны интервалаас (M1–H4) шинж чанар (feature) тооцоолсноор "том зурагийг" авч үзэх чадвартай загвар бүтээсэн
- **Итгэлцлийн удирдлага (confidence governance)**: Ансамблийн магадлалд суурилсан итгэлцэл (confidence) шүүлтүүрийг бодит ажиллах орчинд (production runtime) тогтвортой ашиглаж, магадлалын тохируулга (probability calibration)-ыг сүлжээнээс гадуурх (offline evaluation) үнэлгээний түвшинд салгаж хэрэгжүүлсэн
- **Чанар > тоо хэмжээ**: 359,639 таамгаас итгэлцэл (confidence) $\geq$ 90% босгонд 3,567 (1.0%) дохио шүүж, босгыг 99% болгоход 147 хүртэл бууруулан туршсан стратеги
- **Цог систем (end-to-end system)**: Загварын сургалтаас эхлээд гар утасны (mobile) аппликейшн хүртэл бүрэн, нэгдмэл системийг хэрэгжүүлсэн

Хязгаарлалт

Судалгааны ажлын зарим хязгаарлалтуудыг тодорхойлох нь чухал:

1. **Ганц валютын хослол**: Зөвхөн EUR/USD дээр сургагдсан – бусад хослолд шууд ашиглах боломжгүй
2. **Түүхэн өгөгдөл дээрх системийн туршилт (backtesting) ба бодит санхүүгийн таамаглалын зөрүү**: Түүхэн өгөгдөл дээрх системийн туршилт (backtesting) нь бодит санхүүгийн таамаглалын бүх нөхцлийг (жишээ нь төлбөрийн чадварын хязгаарлалт, шуугиан) бүрэн дүрсэлж чаддаггүй
3. **Зах зээлийн горимын өөрчлөлт**: Зах зээлийн бүтцэд суурь өөрчлөлт гарвал загварын гүйцэтгэл буурч болно
4. **Санхүүгийн таамаглалын зардал**: Спрэд (spread), гулсалт (slippage) зэрэг зардлыг тооцсон ч комисс, своп (swap) зэргийг бүрэн тооцоогүй
5. **Бодит цагийн хүндрэл**: Гадаад үйлчилгээний хязгаарлалт, сүлжээний саатал зэрэг техникийн асуудлууд

Цаашдын чиглэл

Судалгааг цаашид дараахь чиглэлээр хөгжүүлэх боломжтой:

1. **Олон валютын хослолд өргөтгөх**: GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, багц (portfolio) стратеги бүтээх
2. **Дагах зогсоол (Trailing Stop)**: Нээлттэй байрлалын (position) ашгийг хамгаалах динамик хязгаарлалт (SL)-ын аргачлалыг цаашид сайжруулах
3. **Гүн сургалтын загвар**: LSTM, Transformer зэрэг цуваа өгөгдлийн загваруудыг ансамбль-д нэмэх
4. **Бататгалтат сургалт (Reinforcement Learning)**: Багцын (portfolio) менежмент, байрлалын (position) хэмжээ тохируулалтад хэрэглэх
5. **Мэдээний шинжилгээ**: Байгалийн хэлний боловсруулалт (NLP) ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах

6. **Түгээлт болон хөгжүүлэлтийн ажиллагаа (Distribution ба MLOps)**: Google Play түгээлтийн сувгийг бүрэн нэвтрүүлж, загварын хазайлт (model drift) мониторинг, үйл ажиллагааны (operational) аудит лог (audit log), хувилбар гаргалтын (release) автоматжуулалтыг өргөтгөх

Эцсийн дүгнэлт

Машин сургалтын ансамбль загвар нь Forex зах зээл дээр ашигтай таамаглалын систем үүсгэх чадвартайг энэхүү судалгааны sweep үр дүн харуулсан. Түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) багцад 0.90–0.99 дохионы багцын бүх тохиргоо эерэг өгөөжтэй гарч, хамгийн өндөр дүн нь +517.70% ($61,770.46), 0.90 хувилбарт +482.62% ($58,262.39) байсан нь системийн практик чадамжийг баталгаажуулсан. Гэхдээ эдгээр дүн нь EUR/USD хэрэгслийн EA тестийн цонх (2025.01.01–2026.01.01) болон sweep нэгтгэлийн effective coverage-ийн хүрээнд гарсан тул өөр зах зээлийн горим, өөр хэрэгсэл дээр шууд ижил байна гэж үзэхгүй; эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох чадвар, хэрэглэгчийн эрсдэлийн мэдээлэлжүүлэлт нь тасралтгүй сайжруулалт шаарддаг.

Систем нь загвар сургалтаас эхлээд эцсийн хэрэглэгч хүртэлх бүрэн үйл явцыг амжилттай хэрэгжүүлсэн бөгөөд энэ нь машин сургалт, серверийн хэсэг (backend)-ийн хөгжүүлэлт, гар утасны аппликейшний хөгжүүлэлт зэрэг олон салбарыг хамарсан цогц инженерийн ажил юм.

Ном зүй

[1] Bank for International Settlements. Triennial central bank survey of foreign exchange and over-the-counter (otc) derivatives markets in 2022. Technical report, Bank for International Settlements, Basel, Switzerland, 2022.

[2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.

[3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.

[4] Joarder Kamruzzaman and Ruhul A Sarker. Forecasting of currency exchange rates using ann: A case study. *International Conference on Neural Networks and Signal Processing*, pages 793–797, 2003.

[5] Manish Kumar and M Thenmozhi. Forecasting stock index movement: A comparison of support vector machines and random forest. *Indian Institute of Capital Markets 9th Capital Markets Conference Paper*, 2006. Available at SSRN.

[6] Michel Ballings, Dirk Van den Poel, Nathalie Hespeels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.

[7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.

[8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review and future research directions. *Applied Soft Computing*, 97, 2019.

[9] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the s&p 500. *European Journal of Operational Research*, 259(2):689–702, 2017.

[10] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.

[11] Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.

[12] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[13] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.

[14] Leo Breiman. Random forests. *Machine learning*, 45:5–32, 2001.

[15] Omer Berat Sezer, Mehmet Ugur Gudelek, and Ahmet Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.

[16] Eugene F Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.

[17] John J Murphy. Technical analysis of the financial markets: A comprehensive guide to trading methods and applications. *New York Institute of Finance*, 1999.

[18] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis: Computational algorithms, statistical inference, and empirical implementation. *The Journal of Finance*, 55(4):1705–1765, 2000.

[19] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.

[20] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.

[21] Ben R Marshall, Rochester H Cahan, and Jared M Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.

[22] Cheol-Ho Park and Scott H Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.

[23] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.

[24] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.

[25] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023. Accessed: 2024-12-01.

[26] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O'Reilly Media, 2nd edition, 2018.

[27] Miguel Grinberg. *Flask Web Development: Developing Web Applications with Python*. O'Reilly Media, 2nd edition, 2018.

[28] Alan R Hevner, Salvatore T March, Jinsoo Park, and Sudha Ram. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.

[29] Ken Peffers, Tuure Tuunanen, Marcus A Rothenberger, and Samir Chatterjee. A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3):45–77, 2007.

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ АРИЛЖААНЫ БОТ

КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ
Оюутан: s21c033b, М.Мөнхдорж
Удирдагч багш: Н.Соронзонболд

1. Удиртгал

Forex (гадаад валютын зах зээл) нь 24/5 горимоор тасралтгүй хөдөлдөг, макро эдийн засгийн мэдээ, төв банкны бодлого, геополитикийн нөлөөнд өндөр мэдрэг зах зээл тул өгөгдлийн шуугиан (noise) болон горимын өөрчлөлт (regime shift) ихтэй байдаг. Ийм орчинд зөвхөн нэг алгоритмд суурилсан таамаглалын систем нь богино хугацаанд өндөр дүн үзүүлэх боловч шинэ нөхцөлд муудах эрсдэлтэй байдаг. Иймээс энэ нь дан ганц загварын асуудал биш бөгөөд өгөгдөл цуглуулалт, шинж чанар (feature) боловсруулах шат, үнэлгээний зөв протокол, серверийн тасралтгүй ажиллагаа, хэрэглэгчид хүргэх интерфэйсийн найдвартай байдал зэрэг инженерчлэлийн олон бүрэлдэхүүнтэй асуудал юм.

Энэхүү ажлын үндсэн зорилго нь санхүүгийн таамаглалын алгоритмын үнэлгээг программ хангамжийн системийн хэрэгжилттэй нэгтгэх явдал байв. Өөрөөр хэлбэл, таамаглалын чанарыг зөвхөн нэг удаагийн нарийвчлалаар биш, бодит хэрэглээний нөхцөлд дохионы тогтвортой байдал, өгөөж-эрсдэлийн харьцаа, мөн хэрэглэгчийн түвшинд хүргэж буй үйлчилгээгээр цогцоор үнэлсэн. Энэ хандлага нь академик үр дүнг практик хэрэгжүүлэлт рүү хөрвүүлэхэд чиглэсэн бөгөөд судалгааны ач холбогдлыг нэмэгдүүлсэн.

Мөн судалгааны асуултыг дараах гурван чиглэлд төвлөрүүлсэн. Нэгдүгээрт, олон төрлийн GBDT загварыг ансамбль хэлбэрээр нэгтгэхэд дан загвараас илүү тогтвортой үр дүн гарах эсэх. Хоёрдугаарт, урагш гүйлгэсэн баталгаажуулалт (walk-forward validation) болон чанарын шүүлтүүрүүд нь хэт нийцэл (overfitting)-ийн эрсдэлийг бууруулахад бодитой нөлөө үзүүлэх эсэх. Гуравдугаарт, серверийн хэсэг (backend) ба харагдах хэсэг (frontend)-ийг нэгтгэсэн инженерчлэлийн шийдэл нь судалгааны үр дүнг эцсийн хэрэглэгчид ойлгомжтой, ашиглагдахуйц хэлбэрээр хүргэж чадах эсэхийг шалгасан.

2. Судалгааны арга зүй

Судалгаанд дизайн шинжлэх ухааны (Design Science Research) арга барил хэрэглэж, асуудал тодорхойлох, артефакт боловсруулах, туршилтаар үнэлэх, сайжруулалт хийх мөчлөгийг 7 давталттайгаар хэрэгжүүлсэн. Энэ арга нь онолын таамаглал дэвшүүлэхээс гадна бодит ажиллах систем бүтээж баталгаажуулахад тохиромжтой тул энэхүү ажлын зорилготой нийцсэн. Давталт бүрд загварын алдаа, дохионы чанар, эрсдэлийн үзүүлэлт, мөн системийн ажиллагааны асуудлыг тус тус шинжилж дараагийн хувилбарт тусгасан.

Өгөгдлийн түвшинд MetaTrader 5 платформоос EUR/USD хослолын 2015–2024 оны OHLCV түүхэн өгөгдлийг татан авч, M1, M5, M15, M30, H1, H4 гэсэн 6 хугацааны интервал дээр боловсруулсан. Интервал бүрээс чиг хандлага, моментум, хэлбэлзэл, эзлэхүүн зэрэг мэдээлэл агуулсан 8 шинж чанар тооцоолж, нийт 48 шинж чанарын оролт бүрдүүлсэн. Олон хугацааны интервал ашигласнаар богино болон дунд хугацааны хөдөлгөөнийг зэрэг харгалзах боломжтой болсон.

Загварчлалын түвшинд LightGBM, XGBoost, CatBoost гэсэн гурван GBDT загварыг сургасан. Өгөгдлийг сургалт (2015–2022), баталгаажуулалт (2023), тест (2024) болгон цаг хугацааны дараалал алдагдуулахгүй хуваасан. Энэ хуваалт нь санхүүгийн цуваа өгөгдөлд түгээмэл гардаг look-ahead bias буюу ирээдүйн мэдээлэл сургалт руу алдагдах эрсдэлийг бууруулна. Ансамблийн гаралтыг нэгтгэхдээ магадлалд суурилсан санал өгөх (soft voting)

логик ашиглаж, сүлжээнээс гадуурх (offline) үнэлгээнд калибровк хийсэн.

Дохио үүсгэх шатанд чанарын хяналт оруулахын тулд итгэлцэл (confidence) $\geq$ 90% болон ATR $\geq$ 4.0 пипс гэсэн босго хэрэглэсэн. Эдгээр шалгуур нь олон таамгаас хамгийн ашигтай, эрсдэлийн хувьд харьцангуй зохистой дохиог шүүн гаргах зорилготой. Өөрөөр хэлбэл, системийн стратеги нь ”тоог нэмэх” бус ”чанарыг нэмэх” зарчимд тулгуурласан. Энэ нь түүхэн өгөгдөл дээрх системийн туршилтын (backtesting) үеийн их уналтыг бууруулахад чухал нөлөө үзүүлсэн.

Системийн хэрэгжилтийн түвшинд серверийн хэсэг (backend), өгөгдлийн сан, мөн React Native дээр суурилсан харагдах хэсэг (frontend)-ийг нэгтгэн хөгжүүлсэн. Сервер нь таамаглалын өгөгдөл, мэдээний шинжилгээ, хэрэглэгчийн хүсэлтийн урсгалыг нэгтгэн удирдаж, мобайл апп нь бодит хугацааны ханш, дохио, тайлбар мэдээллийг хэрэглэгчид хүргэдэг. Ийм архитектур нь машин сургалтын загварыг тусдаа лабораторийн туршилт биш, хэрэглээний систем болгон өргөтгөсөн.

Үр дүнгийн баталгаажуулалтад MetaTrader 5 Strategy Tester ашиглан түүхэн өгөгдөл дээрх системийн туршилт (backtesting) хийж, өгөөж, ашгийн хүчин зүйл, Шарпын харьцаа, хамгийн их уналт зэрэг үзүүлэлтээр дүгнэсэн. Ингэхдээ зөвхөн нэг хэмжүүрээр дүгнэлт хийхээс зайлсхийж, ангиллын нарийвчлал ба санхүүгийн гүйцэтгэлийн үзүүлэлтийг хамтад нь авч үзсэн.

3. Судалгааны үр дүн

Сургалт, баталгаажуулалт, тестийн хуваалтаар үнэлэхэд загварын тестийн нарийвчлал 87.4% гарч, өндөр итгэлцэлтэй дохионы нарийвчлал 95%+ хүрсэн. Энэ нь загвар зөвхөн ерөнхий ангиллын түвшинд бус, өндөр итгэлтэйгээр гаргасан дохионы чанарын хувьд илүү сайн гүйцэтгэлтэйг харуулж байна. Түүнчлэн итгэлцэлд (confidence) суурилсан шүүлтүүр нь алдаатай дохионы хувь хэмжээг бууруулах практик үр нөлөөтэй байв.

Түүхэн өгөгдөл дээрх системийн туршилтын шинэ багцад итгэлцлийн (confidence) босгыг 90–99% болгож 10 хувилбараар шалгахад бүгд эерэг өгөөжтэй гарсан. Хамгийн өндөр дүн нь итгэлцэл (confidence) $\geq$ 91% дээр $61,770.46 (+517.70%), итгэлцэл (confidence) $\geq$ 90% хувилбарт $58,262.39 (+482.62%) байв. Харин босгыг 99% хүртэл өсгөхөд дохионы тоо огцом буурснаар эцсийн баланс $17,428.89 (+74.29%) болсон.

Дохио шүүх үр нөлөөг хэмжихэд 359,639 урьдчилсан таамгаас итгэлцэл (confidence) $\geq$ 90% босгонд 3,567 (1.0%) дохио үлдсэн бөгөөд босгыг 99% болгоход 147 (0.04%) болсон. Энэ нь систем бүх боломжит хөдөлгөөнд оролцохоос илүү чанарын босго давсан нөхцөлд сонгомол оролцоо хийх стратеги баримталж байгааг харуулна. Санхүүгийн талаас тайлбарлавал, босго хэт өндөрсөх үед алдаатай дохионуудын хамт ашигтай боломжууд мөн багасаж, нийт өгөөж буурах эрсдэлтэй байдаг.

Системийн инженерчлэлийн хувьд серверийн хэсэг (backend) болон харагдах хэсгийн (frontend) интеграц тогтвортой ажилласан. Таамаглалын үр дүн, мэдээний мэдээлэл, хэрэглэгчийн хандалтын урсгалыг нэг цэгт удирдах боломжтой болсон нь судалгааны үр дүнг хэрэглэгчийн ашиглалттай холбосон бодит давуу тал юм. Өөрөөр хэлбэл, алгоритмын үзүүлэлт сайн байхтай зэрэгцээд түүнийг зөв хүргэх программ хангамжийн бүтэц хэрэгжсэн.

4. Дүгнэлт

Энэхүү судалгааны гол дүгнэлт нь санхүүгийн шуугиантай өгөгдөл дээр нэг загвараас илүүтэй олон GBDT загварын ансамбль хандлага тогтвортой үр дүн өгөх боломжтой, мөн энэ үр дүнг заавал инженерчлэлийн хэрэгжүүлэлттэй холбон үнэлэх шаардлагатай гэдгийг харуулсан явдал юм. Урагш гүйлгэсэн баталгаажуулалт, чанарын босготой дохио шүүх логик, ба системийн интеграц гэсэн гурван хүчин зүйл хамтдаа ажилласнаар хэт нийцэл (overfitting)-ийн эрсдэлийг бууруулж, бодит хэрэглээнд ойр гүйцэтгэл үзүүлсэн.

Гэсэн хэдий ч хязгаарлалт бий. Судалгаа одоогоор зөвхөн EUR/USD хослолд төвлөрсөн бөгөөд өөр зах зээл, өөр хугацааны горимд ижил түвшний үр дүн тогтвортой гарах эсэхийг цаашид баталгаажуулах шаардлагатай. Мөн зах зээ-

лийн огцом горимын өөрчлөлт, макро мэдээний гэнэтийн нөлөөлөл, бодит гүйцэтгэлийн саатал зэрэг хүчин зүйлсийг урт хугацааны мониторингтой уялдуулан судлах хэрэгтэй.

Ирээдүйн ажлаар олон валютын хослолд өргөтгөх, загварын drift мониторинг, автомат дахин сургалт, мэдээний NLP шинжилгээ, мөн MLOps түвшний хяналт нэвтрүүлэх нь системийн найдвартай байдлыг өсгөнө. Ийнхүү энэхүү судалгаа нь машин сургалтын таамаглалын ажлыг дан лабораторийн туршилтаас бодит хэрэглээний систем рүү шилжүүлэх суурь инженерчлэлийн шийдэл болгож өргөжүүлснээрээ практик ач холбогдолтой гэж дүгнэгдэж байна.

5. Ном зүй

Судалгааны үндсэн эх сурвалжуудаас:

1. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *ACM SIGKDD*.

2. Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS*.

3. Prokhorenkova, L., et al. (2018). CatBoost: Unbiased Boosting with Categorical Features. *NeurIPS*.

4. Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*.

5. Pardo, R. (2008). *The Evaluation and Optimization of Trading Strategies*. John Wiley & Sons.

6. Bailey, D., et al. (2014). The Probability of backtesting overfitting. *Journal of Computational Finance*.

7. Hevner, A., et al. (2004). Design Science in Information Systems Research. *MIS Quarterly*.

8. Peffers, K., et al. (2007). A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*.