



**ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ**

Оюутны код: s21c033b

Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

**МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ
ТААМАГЛАХ АРИЛЖААНЫ БОТ
/ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/**

Удирдагч багш
Гүйцэтгэсэн оюутан

Н.СОРОНЗОНБОЛД
М.МӨНХДОРЖ

Улаанбаатар хот
2026 он

ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ

Төгсөлтийн судалгааны ажил (071309)

МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ ТААМАГЛАХ
АРИЛЖААНЫ БОТ

Гүйцэтгэгч: М.МӨНХДОРЖ

Удирдагч: Н.СОРОНЗОНБОЛД

Улаанбаатар хот

2026 он

| | |
|----------------|---|
| AI | Artificial Intelligence - Хиймэл оюун ухаан |
| ML | Machine Learning - Машин сургалт |
| DL | Deep Learning - Гүн сургалт |
| RL | Reinforcement Learning - Бататгах сургалт |
| CNN | Convolutional Neural Network - Конволюшн мэдрэлийн сүлжээ |
| LSTM | Long Short-Term Memory - Урт богино хугацааны санах ой |
| BiLSTM | Bidirectional LSTM - Хоёр чиглэлт LSTM |
| RNN | Recurrent Neural Network - Рекуррент мэдрэлийн сүлжээ |
| PPO | Proximal Policy Optimization - Ойролцоо бодлогын оновчлол |
| DQN | Deep Q-Network - Гүн Q-Сүлжээ |
| API | Application Programming Interface - Програмын интерфейс |
| FOREX | Foreign Exchange - Гадаад валютын арилжаа |
| EUR/USD | Euro/US Dollar - Евро/АНУ-ын доллар |
| RSI | Relative Strength Index - Харьцангуй хүчний индекс |
| MACD | Moving Average Convergence Divergence |
| EMA | Exponential Moving Average - Экспоненциал хөдөлгөөнт дундаж |
| ATR | Average True Range - Дундаж жинхэнэ хүрээ |
| MAE | Mean Absolute Error - Дундаж абсолют алдаа |
| RMSE | Root Mean Squared Error - Квадрат дундаж алдааны язгуур |
| AUC | Area Under Curve - Муруйн доорх талбай |
| ROC | Receiver Operating Characteristic |
| SWA | Stochastic Weight Averaging - Стохастик жингийн дундажлал |
| GPU | Graphics Processing Unit - График боловсруулах төхөөрөмж |
| MT5 | MetaTrader 5 - МетаТрейдер 5 |
| pip | Percentage in Point - Үнийн хамгийн бага өөрчлөлтийн нэгж |

Ажлын төлөвлөгөө

| № | Гүйцэтгэх ажлын нэр | Эхлэх | Дуусах | Тайлбар | Явц |
|----|------------------------------|------------|------------|----------------------------------|-----|
| 1 | Сэдэв сонголт, төлөвлөгөө | 2024.09.01 | 2024.09.15 | Сэдэв, удирдагч багш тодорхойлох | ✓ |
| 2 | Онолын судалгаа хийх | 2024.09.16 | 2024.10.15 | ML, DL онолын үндэс | ✓ |
| 3 | Ижил төстэй судалгаа судлах | 2024.10.16 | 2024.10.31 | Холбогдох судалгааны тойм | ✓ |
| 4 | Өгөгдөл цуглуулах | 2024.11.01 | 2024.11.15 | EUR/USD түүхэн өгөгдөл | ✓ |
| 5 | Үзлэг №1 | 2024.11.20 | | Төгсөлтийн үзлэг №1 | |
| 6 | Шинж чанар инженерчлэл | 2024.11.21 | 2024.12.15 | Техникийн индикатор, features | ✓ |
| 7 | Модель хөгжүүлэх | 2024.12.16 | 2025.01.31 | CNN+BiLSTM+Attention | ✓ |
| 8 | Үзлэг №2 | 2025.02.05 | | Төгсөлтийн үзлэг №2 | |
| 9 | Модель сургах, оновчлох | 2025.02.06 | 2025.02.28 | Hyperparameter tuning | |
| 10 | Үнэлгээ, туршилт | 2025.03.01 | 2025.03.15 | Metrics, backtesting | |
| 11 | Мобайл апп хөгжүүлэх | 2025.03.16 | 2025.03.31 | React Native app | |
| 12 | Үзлэг №3 | 2025.04.02 | | Төгсөлтийн үзлэг №3 | |
| 13 | Бичвэр бэлтгэх | 2025.04.03 | 2025.04.20 | Дипломын бичвэр | |
| 14 | Урьдчилсан хамгаалалт | 2025.04.23 | | Урьдчилсан хамгаалалт | |
| 15 | Нэмэлт сайжруулалт | 2025.04.24 | 2025.05.10 | Сайжруулалт, засвар | |
| 16 | Жинхэнэ хамгаалалт | 2025.05.15 | | Төгсөлтийн хамгаалалт | |

Удирдагч багш:

/Н.СОРОНЗОНБОЛД/

Гүйцэтгэсэн оюутан:

/s21c033b, М.МӨНХДОРЖ/

Талархал

Энэхүү төгсөлтийн судалгааны ажлыг амжилттай гүйцэтгэхэд маш их туслалцаа, дэмжлэг үзүүлсэн хүмүүстээ чин сэтгэлийн талархал илэрхийлье.

Юуны өмнө миний удирдагч багш **Н.Соронзонболд** багшдаа гүн талархал илэрхийлж байна. Тэрээр судалгааны ажлын чиглэлийг тодорхойлох, арга зүйн зөвлөгөө өгөх, мөн бүхий л үйл явцад чиглүүлэг өгч байсанд маш их баярлалаа.

Шинэ Монгол Технологийн Коллеж-ийн Компьютерын ухааны тэнхимийн бүх багш нарт сургалтын хөтөлбөрийн туршид олгосон мэдлэг, чадварт нь талархаж байна. Тэдний заасан хичээлүүд энэхүү судалгааны ажлын суурь болсон юм.

Түүнчлэн машин сургалт, гүн сургалтын салбарт нээлттэй эх код, онлайн нөөц материал бүтээсэн олон улсын нийгэмлэгт талархал илэрхийлье. PyTorch, React Native, FastAPI зэрэг нээлттэй эхийн хөгжүүлэгчид, мөн санхүүгийн өгөгдөл нийлүүлэгчдийн хүчин чармайлтгүйгээр энэ судалгаа боломжгүй байсан юм.

Эцэст нь миний гэр бүлд, ялангуяа эцэг эх, ах дүү нартаа хязгааргүй их талархаж байна. Тэдний урамшуулал, дэмжлэг надад хэзээ ч дутагдаагүй.

М.Мөнхдорж

2025 оны 4-р сар

Гарчиг

| | |
|---------------------------------|----|
| Ажлын төлөвлөгөө | i |
| Талархал | ii |
| Гарчиг | iv |
| Зураг болон Хүснэгтийн жагсаалт | vi |

| | |
|--|-----------|
| 1 УДИРТГАЛ | 1 |
| 1.1 Судалгааны үндэслэл, ач холбогдол | 1 |
| 1.2 Судалгааны зорилго, зорилт | 1 |
| 1.2.1 Зорилго | 1 |
| 1.2.2 Зорилтууд | 2 |
| 1.3 Судалгааны хамрах хүрээ | 2 |
| 1.4 Судалгааны шинэлэг тал | 2 |
| 1.5 Судалгааны бүтэц | 3 |
| 2 ОНОЛЫН СУДАЛГАА | 4 |
| 2.1 Машин сургалтын үндэс | 4 |
| 2.1.1 Машин сургалтын тодорхойлолт | 4 |
| 2.1.2 Машин сургалтын төрлүүд | 4 |
| 2.1.2.1 Хяналттай сургалт (Supervised Learning) | 4 |
| 2.1.2.2 Хяналтгүй сургалт (Unsupervised Learning) | 4 |
| 2.1.2.3 Бататгах сургалт (Reinforcement Learning) | 5 |
| 2.2 Гүн сургалт (Deep Learning) | 5 |
| 2.2.1 Мэдрэлийн сүлжээний үндэс | 5 |
| 2.2.2 Конволюшн мэдрэлийн сүлжээ (CNN) | 5 |
| 2.2.3 Рекуррент мэдрэлийн сүлжээ (RNN) ба LSTM | 5 |
| 2.2.4 Bidirectional LSTM (BiLSTM) | 6 |
| 2.2.5 Attention механизм | 6 |
| 2.3 Санхүүгийн зах зээлийн техникийн шинжилгээ | 7 |
| 2.3.1 Техникийн индикаторууд | 7 |
| 2.3.1.1 Хөдөлгөөнт дундаж (Moving Average) | 7 |
| 2.3.1.2 RSI (Relative Strength Index) | 7 |
| 2.3.1.3 MACD (Moving Average Convergence Divergence) | 7 |
| 2.3.1.4 Bollinger Bands | 7 |
| 2.3.1.5 ATR (Average True Range) | 8 |
| 2.4 Ижил төстэй судалгааны тойм | 8 |
| 2.4.1 Уламжлалт машин сургалтын аргууд | 8 |
| 2.4.2 Гүн сургалтын аргууд | 8 |
| 2.4.3 Гибрид аргууд | 8 |
| 2.4.4 Attention-д суурилсан аргууд | 8 |
| 2.4.5 Судалгааны цоорхой | 8 |
| 3 СУДАЛГААНЫ АРГА ЗҮЙ | 10 |
| 3.1 Өгөгдлийн тодорхойлолт | 10 |
| 3.1.1 Өгөгдлийн эх сурвалж | 10 |
| 3.1.2 Өгөгдлийн хугацааны хүрээ | 10 |
| 3.1.3 Өгөгдлийн чанарын хяналт | 10 |
| 3.2 Шинж чанар инженерчлэл | 10 |
| 3.2.1 Үнийн шинж чанарууд | 10 |
| 3.2.2 Техникийн индикаторууд | 11 |
| 3.2.3 Rolling статистик | 11 |
| 3.2.4 Цаг хугацааны шинж чанарууд | 12 |
| 3.2.5 Зорилтот хувьсагчууд | 12 |
| 3.3 Өгөгдлийн хуваалт | 13 |
| 3.3.1 Хугацаан дээр суурилсан хуваалт | 13 |
| 3.3.2 Scaling | 13 |
| 3.4 Моделийн архитектур | 13 |
| 3.4.1 Ерөнхий бүтэц | 13 |

| | | |
|----------|----------------------------------|-----------|
| 3.4.2 | Residual Convolutional Block | 14 |
| 3.4.3 | Squeeze-and-Excitation Block | 15 |
| 3.4.4 | Multi-Head Self Attention | 15 |
| 3.5 | Сургалтын тохиргоо | 16 |
| 3.5.1 | Loss функц | 16 |
| 3.5.1.1 | Regression Loss | 16 |
| 3.5.1.2 | Classification Loss | 16 |
| 3.5.2 | Optimizer ба Scheduler | 16 |
| 3.5.3 | Regularization техникүүд | 16 |
| 3.5.4 | Data Augmentation | 17 |
| 3.5.5 | Hyperparameter | 17 |
| 3.6 | Мобайл аппликейшн | 17 |
| 3.6.1 | React Native архитектур | 17 |
| 3.6.2 | Backend API | 17 |
| 4 | СУДАЛГААНЫ ҮР ДҮН | 18 |
| 4.1 | Моделийн сургалтын үр дүн | 18 |
| 4.1.1 | Сургалтын процесс | 18 |
| 4.1.2 | Learning Rate Schedule | 18 |
| 4.2 | Үнэлгээний хэмжүүрүүд | 18 |
| 4.2.1 | Regression Metrics | 18 |
| 4.2.2 | Direction Classification Metrics | 19 |
| 4.2.3 | Big Move Classification Metrics | 19 |
| 4.3 | Итгэлтэй таамаглалын шинжилгээ | 19 |
| 4.4 | Калибрацийн шинжилгээ | 20 |
| 4.5 | Confusion Matrix | 21 |
| 4.6 | Backtesting үр дүн | 21 |
| 4.6.1 | Арилжааны стратеги | 21 |
| 4.6.2 | Стратегийн харьцуулалт | 21 |
| 4.6.3 | Cumulative PnL | 22 |
| 4.7 | Үнийн таамаглалын харьцуулалт | 23 |
| 4.8 | Мобайл аппликейшн | 23 |
| 4.8.1 | Аппликейшний интерфэйс | 23 |
| 4.9 | Үр дүнгийн хэлэлцүүлэг | 24 |
| 4.9.1 | Давуу талууд | 24 |
| 4.9.2 | Хязгаарлалтууд | 24 |
| 4.9.3 | Сайжруулах боломжууд | 24 |
| 5 | ДҮГНЭЛТ | 26 |
| 5.1 | Судалгааны үр дүнгийн нэгтгэл | 26 |
| 5.1.1 | Техникийн үр дүн | 26 |
| 5.1.2 | Гүйцэтгэлийн үр дүн | 26 |
| 5.1.3 | Системийн бүрэлдэхүүн | 27 |
| 5.2 | Зорилтын биелэлт | 27 |
| 5.3 | Шинэлэг хувь нэмэр | 27 |
| 5.4 | Цаашдын судалгааны чиглэл | 28 |
| 5.4.1 | Моделийн сайжруулалт | 28 |
| 5.4.2 | Нэмэлт шинж чанар | 28 |
| 5.4.3 | Reinforcement Learning | 28 |
| 5.4.4 | Системийн өргөтгөл | 28 |
| 5.5 | Практик хэрэглээ | 29 |
| 5.6 | Төгсгөлийн үг | 29 |
| | Ном зүй | 30 |
| | Хавсралт | 33 |

Зураг болон Хүснэгтийн жагсаалт

| | | |
|--------------|--|----|
| Зураг 2.1. | LSTM нэгжийн бүтэц | 6 |
| Зураг 3.1. | Өгөгдлийн хуваалт | 13 |
| Зураг 3.2. | Моделийн архитектур | 14 |
| Зураг 4.1. | Сургалтын loss-ийн өөрчлөлт | 18 |
| Зураг 4.2. | Калибрацийн муруй (OOS) | 20 |
| Зураг 4.3. | Confusion matrix (a) Up30, (b) Down30 | 21 |
| Зураг 4.4. | Хуримтлагдсан ашиг/алдагдал (OOS) | 22 |
| Зураг 4.5. | Бодит үнэ vs Таамагласан үнэ (OOS) | 23 |
| Зураг 4.6. | Мобайл аппликейшний дэлгэцүүд | 24 |
| | | |
| Хүснэгт 2.1. | Холбогдох судалгаануудын харьцуулалт | 9 |
| Хүснэгт 3.1. | Өгөгдлийн хугацааны хүрээ | 10 |
| Хүснэгт 3.2. | Техникийн индикаторууд | 11 |
| Хүснэгт 3.3. | Hyperparameter тохиргоо | 17 |
| Хүснэгт 4.1. | Regression үнэлгээний үр дүн | 18 |
| Хүснэгт 4.2. | Direction classification үнэлгээний үр дүн | 19 |
| Хүснэгт 4.3. | Big Move (± 30 pips) classification үнэлгээний үр дүн | 19 |
| Хүснэгт 4.4. | Итгэлийн түвшингийн дагуу hit rate | 20 |
| Хүснэгт 4.5. | Backtesting стратегийн харьцуулалт (OOS) | 21 |
| | | |
| Хүснэгт 5.1. | Зорилтын биелэлт | 27 |
| Хүснэгт 5.2. | Hyperparameter тохиргоо | 36 |

1. УДИРТГАЛ

1.1. Судалгааны үндэслэл, ач холбогдол

Санхүүгийн зах зээл нь дэлхийн эдийн засгийн хамгийн динамик бөгөөд нарийн төвөгтэй салбаруудын нэг юм. Өдөр тутам дэлхийн валютын зах зээл дээр 7.5 их наяд долларын арилжаа хийгддэг бөгөөд энэ нь аливаа хувьцааны зах зээлээс хавьгүй их хэмжээ юм [1]. Forex (Foreign Exchange) зах зээл нь 24 цагийн турш ажилладаг, хамгийн хөрвөх чадвартай санхүүгийн зах зээл бөгөөд олон улсын худалдаа, хөрөнгө оруулалтын үндэс суурь болдог.

Уламжлалт арилжааны арга нь хүний шинжилгээ, туршлага, зах зээлийн мэдрэмжид суурилдаг боловч хүний хязгаарлагдмал чадвар, сэтгэл хөдлөлийн нөлөөлөл зэргээс болж олон арилжаачид алдагдал хүлээдэг. Судалгаанаас үзэхэд арилжаачдын 70-80% нь санхүүгийн зах зээл дээр алдагдалтай ажилладаг [2]. Энэ нь дараах шалтгаануудтай холбоотой:

- **Хэт их хэмжээний мэдээлэл:** Зах зээлийн үнэ, эдийн засгийн мэдээ, геополитик үйл явдлууд зэрэг маш олон хүчин зүйлийг нэгэн зэрэг боловсруулах шаардлагатай
- **Сэтгэл хөдлөлийн нөлөөлөл:** Айдас, шунал зэрэг сэтгэл хөдлөл нь оновчтой шийдвэр гаргахад саад болдог
- **Хугацааны хязгаарлалт:** Зах зээл 24 цагийн турш ажилладаг учир хүн байнга хяналт тавих боломжгүй
- **Зах зээлийн таних чадварын хязгаарлалт:** Том хэмжээний түүхэн өгөгдлөөс зах зээлийн хөдөлгөөнийг зөв таамаглах хэцүү

Сүүлийн жилүүдэд машин сургалт (Machine Learning) болон гүн сургалтын (Deep Learning) технологиуд санхүүгийн салбарт өргөнөөр нэвтэрч байна. Эдгээр технологиуд нь дээрх асуудлуудыг шийдвэрлэх боломжийг олгож байна:

1. Том хэмжээний өгөгдлийг хурдан боловсруулах
2. Сэтгэл хөдлөлийн нөлөөлөлгүй объектив шийдвэр гаргах
3. 24/7 тасралтгүй ажиллах
4. Нүдэнд харагдахгүй хөдөлгөөнийг илрүүлэх

Монгол Улсад санхүүгийн технологийн (FinTech) салбар хурдацтай хөгжиж байгаа боловч валютын арилжааны автоматжуулалтын чиглэлээр судалгаа, хөгжүүлэлт хомс байна. Энэхүү судалгааны ажил нь уг цоорхойг нөхөхөд чиглэгдсэн бөгөөд машин сургалтын орчин үеийн аргуудыг ашиглан EUR/USD валютын хослолын ханшийн чиг хандлагыг таамаглах арилжааны бот хөгжүүлэхэд оршино.

1.2. Судалгааны зорилго, зорилт

1.2.1 Зорилго

Энэхүү судалгааны ажлын гол зорилго нь машин сургалтын гүн сургалтын аргуудыг ашиглан Forex зах зээл дээрх EUR/USD валютын хосын үнийн чиг хандлагыг таамаглаж, автоматаар арилжаа хийх бот систем хөгжүүлэхэд оршино.

1.2.2 Зорилтууд

Дээрх зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлж байна:

1. **Өгөгдөл цуглуулах:** EUR/USD валютын хосын түүхэн үнийн өгөгдлийг цуглуулж, чанарын хяналт хийх
2. **Шинж чанар инженерчлэл:** Техникийн индикаторууд (RSI, MACD, Bollinger Bands гэх мэт), цаг хугацааны шинж чанарууд, статистик шинж чанаруудыг тооцоолох
3. **Машин сургалтын модель хөгжүүлэх:** CNN + BiLSTM + Attention архитектур бүхий гүн сургалтын модель бүтээх
4. **Моделийг сургах, оновчлох:** Hyperparameter тохируулга, Early stopping, Learning rate scheduling зэрэг техникүүдийг ашиглах
5. **Үнэлгээ хийх:** Regression болон classification metrics ашиглан моделийн гүйцэтгэлийг үнэлэх
6. **Гар утасны аппликейшн хөгжүүлэх:** React Native ашиглан арилжааны дохиог хүлээн авах мобайл апп бүтээх
7. **Бодит арилжааны туршилт:** MetaTrader 5 платформтой холбогдож арилжааны стратегийг турших

1.3. Судалгааны хамрах хүрээ

Энэхүү судалгааны ажил нь дараах хүрээнд хязгаарлагдана:

- **Валютын хос:** Зөвхөн EUR/USD (Евро/АНУ-ын доллар) валютын хосыг судална
- **Цаг хугацааны хүрээ:** 1 минутын интервалтай өгөгдөл, 10 минутын таамаглалын хугацаа
- **Машин сургалтын арга:** Supervised learning буюу хяналттай сургалтын арга
- **Моделийн архитектур:** CNN + BiLSTM + Multi-Head Attention гибрид архитектур
- **Платформ:** Python, PyTorch, React Native

1.4. Судалгааны шинэлэг тал

Энэхүү судалгааны ажил нь дараах шинэлэг талуудтай:

1. **Гибрид архитектур:** CNN, BiLSTM, Multi-Head Attention механизмуудыг нэгтгэсэн орчин үеийн архитектур
2. **Олон зорилтот сургалт:** Үнийн таамаглал (regression), чиглэлийн таамаглал (classification), том хөдөлгөөний таамаглал (± 30 pip) гэсэн гурван зорилтыг нэгэн зэрэг шийдвэрлэх

3. **Сайжруулсан сургалтын техник:** Focal Loss, Stochastic Weight Averaging (SWA), Mixup augmentation зэрэг орчин үеийн техникүүд
4. **Бүрэн систем:** Backend API + Машин сургалтын модель + Мобайл аппликейшн бүхий бүрэн систем
5. **Монгол хэл дээрх судалгаа:** Forex арилжааны машин сургалтын чиглэлээр Монгол хэл дээрх анхны дэлгэрэнгүй судалгааны нэг

1.5. Судалгааны бүтэц

Энэхүү дипломын ажил нь дараах бүтэцтэй:

- **1-р бүлэг - Удиртгал:** Судалгааны үндэслэл, зорилго, зорилт, хамрах хүрээ
- **2-р бүлэг - Онолын судалгаа:** Машин сургалт, гүн сургалтын онолын үндэс, холбогдох судалгаанууд
- **3-р бүлэг - Судалгааны арга зүй:** Өгөгдөл, шинж чанар инженерчлэл, моделийн архитектур, сургалтын процесс
- **4-р бүлэг - Судалгааны үр дүн:** Моделийн гүйцэтгэл, үнэлгээ, арилжааны туршилт
- **5-р бүлэг - Дүгнэлт:** Үр дүнгийн хэлэлцүүлэг, цаашдын судалгааны чиглэл

2. ОНОЛЫН СУДАЛГАА

2.1. Машин сургалтын үндэс

2.1.1 Машин сургалтын тодорхойлолт

Машин сургалт (Machine Learning) нь хиймэл оюун ухааны (Artificial Intelligence) дэд салбар бөгөөд компьютерийн системд тодорхой програмчлалгүйгээр өгөгдлөөс суралцах чадварыг олгодог арга зүй юм [3]. Tom Mitchell-ийн тодорхойлолтоор: “Компьютерийн програм нь Т даалгаврын хувьд Р гүйцэтгэлийн хэмжүүрээр хэмжигдэх үед Е туршлагаас суралцаж байна гэж хэлнэ, хэрэв Е туршлага нэмэгдэхэд Т даалгаврын Р гүйцэтгэл сайжирвал.”

2.1.2 Машин сургалтын төрлүүд

Машин сургалтыг гурван үндсэн төрөлд хуваадаг:

2.1.2.1 Хяналттай сургалт (Supervised Learning)

Хяналттай сургалт нь хамгийн түгээмэл хэрэглэгддэг машин сургалтын арга бөгөөд оролт-гаралтын хос өгөгдөл дээр суралцдаг. Энэ аргад:

- Сургалтын өгөгдөл нь (x_i, y_i) хос хэлбэртэй байдаг
- x_i - оролтын өгөгдөл (features)
- y_i - зорилтот утга (label/target)
- Модель нь $f : X \rightarrow Y$ функцийг суралцдаг

Хяналттай сургалт нь дараах хэрэглээнд өргөн хэрэглэгддэг:

1. **Regression (Регрессе):** Тасралтгүй утга таамаглах (жишээ нь: үнийн таамаглал)
2. **Classification (Ангилал):** Дискрет ангилалд хуваах (жишээ нь: өсөх/буурах таамаглал)

2.1.2.2 Хяналтгүй сургалт (Unsupervised Learning)

Хяналтгүй сургалт нь зөвхөн оролтын өгөгдөл дээр суралцдаг бөгөөд зорилтот утга байхгүй. Гол хэрэглээ нь:

- Кластерчлал (Clustering)
- Хэмжээс бууруулалт (Dimensionality Reduction)
- Аномали илрүүлэлт (Anomaly Detection)

2.1.2.3 Бататгах сургалт (Reinforcement Learning)

Бататгах сургалт нь агент орчинтой харилцан үйлдэл хийж, шагнал/шийтгэлийн дагуу оновчтой бодлого суралцдаг арга юм. Энэ арга нь арилжааны стратеги сургахад өргөн хэрэглэгддэг.

2.2. Гүн сургалт (Deep Learning)

2.2.1 Мэдрэлийн сүлжээний үндэс

Хиймэл мэдрэлийн сүлжээ (Artificial Neural Network) нь хүний тархины мэдрэлийн эсүүдийн бүтцээс санаа авсан тооцоолох загвар юм. Нэг нейрон нь дараах томъёогоор илэрхийлэгдэнэ:

$$y = \sigma \left(\sum_{i=1}^n w_i x_i + b \right) \quad (2.1)$$

Энд:

- x_i - оролтын утгууд
- w_i - жингүүд
- b - bias
- σ - идэвхжүүлэх функц (activation function)

2.2.2 Конволюшн мэдрэлийн сүлжээ (CNN)

CNN нь дүрс боловсруулалтад өргөн хэрэглэгддэг боловч цуваа өгөгдөл дээр локал загвар илрүүлэхэд маш үр дүнтэй. 1D CNN нь санхүүгийн цуваа өгөгдөлд богино хугацааны загваруудыг илрүүлэхэд хэрэглэгддэг.

Конволюшн үйлдэл:

$$(x * k)[n] = \sum_{m=-M}^M x[n-m] \cdot k[m] \quad (2.2)$$


Энд x нь оролтын цуваа, k нь kernel буюу шүүлтүүр юм.

2.2.3 Рекуррент мэдрэлийн сүлжээ (RNN) ба LSTM

RNN нь цуваа өгөгдөл боловсруулахад зориулагдсан бөгөөд өмнөх алхмын мэдээллийг дараагийн алхамд дамжуулдаг:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h) \quad (2.3)$$

Гэвч энгийн RNN нь “vanishing gradient” асуудалтай учир урт хугацааны хамаарлыг сурахад хүндрэлтэй. LSTM (Long Short-Term Memory) нь энэ асуудлыг шийдвэрлэхээр зохиогдсон:



Зураг 2.1 LSTM нэгжийн бүтэц

LSTM-ийн томъёонууд:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{Forget gate}) \quad (2.4)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{Input gate}) \quad (2.5)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (\text{Candidate}) \quad (2.6)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (\text{Cell state}) \quad (2.7)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{Output gate}) \quad (2.8)$$

$$h_t = o_t \odot \tanh(c_t) \quad (\text{Hidden state}) \quad (2.9)$$

2.2.4 Bidirectional LSTM (BiLSTM)

BiLSTM нь хоёр чиглэлд (урагш, хойшоо) цуваа өгөгдлийг боловсруулдаг бөгөөд илүү баялаг контекст мэдээлэл олж авдаг:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] \quad (2.10)$$

2.2.5 Attention механизм

Attention механизм нь моделд оролтын цувааны аль хэсэгт илүү анхаарал хандуулахыг сурах боломж олгодог:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.11)$$

Multi-Head Attention нь олон толгойг ашиглан өөр өөр representation subspace-ийн мэдээллийг авдаг:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (2.12)$$

2.3. Санхүүгийн зах зээлийн техникийн шинжилгээ

2.3.1 Техникийн индикаторууд

Техникийн шинжилгээ нь үнийн түүхэн өгөгдөл дээр суурилан ирээдүйн үнийн хөдөлгөөнийг таамаглах аргам юм.

2.3.1.1 Хөдөлгөөнт дундаж (Moving Average)

Экспоненциал хөдөлгөөнт дундаж (EMA):

$$EMA_t = \alpha \cdot P_t + (1 - \alpha) \cdot EMA_{t-1} \quad (2.13)$$

Энд $\alpha = \frac{2}{n+1}$, n нь үе.

2.3.1.2 RSI (Relative Strength Index)

RSI нь momentum индикатор бөгөөд 0-100 хооронд хэлбэлздэг:

$$RSI = 100 - \frac{100}{1 + RS} \quad (2.14)$$

Энд $RS = \frac{\text{Дундаж өсөлт}}{\text{Дундаж бууралт}}$

2.3.1.3 MACD (Moving Average Convergence Divergence)

$$MACD = EMA_{12} - EMA_{26} \quad (2.15)$$

$$Signal = EMA_9(MACD) \quad (2.16)$$

$$Histogram = MACD - Signal \quad (2.17)$$

2.3.1.4 Bollinger Bands

$$Middle = SMA_{20} \quad (2.18)$$

$$Upper = Middle + 2\sigma \quad (2.19)$$

$$Lower = Middle - 2\sigma \quad (2.20)$$

2.3.1.5 ATR (Average True Range)

Хэлбэлзлийн хэмжүүр:

$$TR = \max(H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|) \quad (2.21)$$

$$ATR = EMA_{14}(TR) \quad (2.22)$$

2.4. Ижил төстэй судалгааны тойм

2.4.1 Уламжлалт машин сургалтын аргууд

Fischer & Krauss (2018) [4] нь LSTM сүлжээг S&P 500 индексийн чиглэлийн таамаглалд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэл үзүүлснийг харуулсан. Random Forest болон Gradient Boosting аргууд 54-56% нарийвчлалтай байхад LSTM 58-60% нарийвчлалтай байв.

2.4.2 Гүн сургалтын аргууд

Sezer et al. (2020) [5] нь CNN ашиглан санхүүгийн цуваа өгөгдлийг 2D дүрс болгон хувиргаж, техникийн индикаторуудын загварыг илрүүлсэн. Энэ арга нь FOREX зах зээл дээр 55-57% нарийвчлалтай байв.

2.4.3 Гибрид аргууд

Kim & Won (2018) [6] нь CNN + LSTM гибрид архитектурыг санхүүгийн таамаглалд ашигласан. CNN нь локал загвар илрүүлж, LSTM нь цаг хугацааны хамаарлыг загварчилсан. Энэ хослол нь тус тусдаа ашиглахаас илүү үр дүнтэй байв.

2.4.4 Attention-д суурилсан аргууд

Ding et al. (2020) [7] нь Transformer архитектурыг хувьцааны үнийн таамаглалд ашиглаж, LSTM-ээс давуу гүйцэтгэл үзүүлснийг нотолсон. Self-attention механизм нь урт хугацааны хамаарлыг илүү сайн загварчилдаг.

2.4.5 Судалгааны цоорхой

Одоогийн судалгаануудад дараах цоорхой байна:

1. Ихэнх судалгаа нь хувьцааны зах зээлд төвлөрсөн, FOREX зах зээлийн судалгаа харьцангуй цөөн
2. Multi-task learning буюу олон зорилтот сургалтын хэрэглээ хомс
3. Regression болон classification-ийг нэгтгэсэн судалгаа цөөн
4. Орчин үеийн техникүүд (Focal Loss, SWA) санхүүгийн таамаглалд бага хэрэглэгдсэн

Хүснэгт 2.1 *Холбогдох судалгаануудын харьцуулалт*

| Судалгаа | Арга | Зах зээл | Нарийвчлал | Он |
|---------------------|------------------------|-----------------|-------------------|-------------|
| Fischer & Krauss | LSTM | S&P 500 | 58-60% | 2018 |
| Sezer et al. | CNN | FOREX | 55-57% | 2020 |
| Kim & Won | CNN+LSTM | KOSPI | 56-58% | 2018 |
| Ding et al. | Transformer | China A-share | 57-59% | 2020 |
| Энэ судалгаа | CNN+BiLSTM+Attn | FOREX | TBD | 2025 |

3. СУДАЛГААНЫ АРГА ЗҮЙ

3.1. Өгөгдлийн тодорхойлолт

3.1.1 Өгөгдлийн эх сурвалж

Энэхүү судалгаанд EUR/USD валютын хосын 1 минутын интервалтай түүхэн өгөгдлийг ашигласан. Өгөгдлийг MetaTrader 5 (MT5) платформоос татан авсан бөгөөд дараах талбаруудыг агуулна:

- **timestamp** - Цаг хугацааны тэмдэг (UTC)
- **open** - Нээлтийн үнэ
- **high** - Хамгийн өндөр үнэ
- **low** - Хамгийн бага үнэ
- **close** - Хаалтын үнэ
- **volume** - Арилжааны хэмжээ

3.1.2 Өгөгдлийн хугацааны хүрээ

Хүснэгт 3.1 Өгөгдлийн хугацааны хүрээ

| Төрөл | Эхлэх огноо | Дуусах огноо | Мөрийн тоо |
|-------------------|-------------|--------------|------------|
| Сургалтын өгөгдөл | 2023-01-01 | 2024-09-30 | 600,000 |
| Тестийн өгөгдөл | 2024-10-01 | 2024-11-15 | 65,000 |

3.1.3 Өгөгдлийн чанарын хяналт

Өгөгдлийн чанарыг дараах алхмуудаар шалгаж, засварласан:

1. **Давхардсан бичлэг шалгах:** Timestamp давхардсан бичлэгүүдийг устгах
2. **Дутуу утга нөхөх:** Forward fill аргаар дутуу үнийн утгуудыг нөхөх
3. **Минутын grid бүрдүүлэх:** Бүх минут бүрийн өгөгдөл байгаа эсэхийг шалгах
4. **Аномали илрүүлэх:** Хэвийн бус үнийн өөрчлөлтүүдийг шалгах

3.2. Шинж чанар инженерчлэл

3.2.1 Үнийн шинж чанарууд

Үндсэн үнийн өгөгдлөөс дараах шинж чанаруудыг тооцоолсон:

Listing 3.1 *Price Features*

```

1 # Mid price
2 mid = (high + low) / 2
3 typical_price = (high + low + close) / 3
4
5 # Returns
6 return_1m = close.pct_change()
7 log_return = np.log(close).diff()
8
9 # Candle features
10 candle_body = close - open
11 candle_range = high - low
12 body_to_range = abs(candle_body) / (candle_range + 1e-9)

```

3.2.2 Техникийн индикаторууд

Дараах техникийн индикаторуудыг тооцоолсон:

Хүснэгт 3.2 *Техникийн индикаторууд*

| Индикатор | Параметр | Тайлбар |
|-----------------|----------------|------------------------------------|
| EMA | 9, 21, 55, 200 | Экспоненциал хөдөлгөөнт дундаж |
| RSI | 14, 21 | Харьцангуй хүчний индекс |
| MACD | 12, 26, 9 | Хөдөлгөөнт дундажийн нийлэл/салалт |
| Bollinger Bands | 20, 2 | Хэлбэлзлийн зурвас |
| ATR | 14, 30 | Дундаж жинхэнэ хүрээ |
| ADX | 14 | Чиг хандлагын хүч |
| OBV | - | On-Balance Volume |
| MFI | 14 | Money Flow Index |
| VWAP | 30 | Volume Weighted Average Price |

3.2.3 Rolling статистик

Өөр өөр цонхны хэмжээтэй rolling статистикуудыг тооцоолсон:

Listing 3.2 *Rolling Statistics*

```

1 ROLLING_WINDOWS = {
2     30: "30m",    # 30 minutes
3     120: "2h",    # 2 hours
4     240: "4h",    # 4 hours
5     720: "12h",   # 12 hours

```

```

6     1440: "24h"    # 24 hours
7 }
8
9 for window, label in ROLLING_WINDOWS.items():
10     roll_close_mean = close.rolling(window).mean()
11     roll_close_std = close.rolling(window).std()
12     roll_return_mean = return_1m.rolling(window).mean()
13     roll_return_std = return_1m.rolling(window).std()
14     roll_return_skew = return_1m.rolling(window).skew()
15     roll_return_kurt = return_1m.rolling(window).kurt()

```

3.2.4 Цаг хугацааны шинж чанарууд

Арилжааны сесс, долоо хоногийн өдөр зэрэг цаг хугацааны шинж чанаруудыг үүсгэсэн:

- **Цикл шинж чанар:** sin ба cos хувиргалтаар цагийн цикл мэдээлэл
- **Арилжааны сесс:** Азийн (00:00-07:00 UTC), Лондоны (07:00-16:00 UTC), Нью-Йоркийн (12:00-21:00 UTC)
- **Давхцсан сесс:** Лондон-Нью-Йорк давхцал (12:00-16:00 UTC)
- **Макро цаг:** Эдийн засгийн мэдээ гарах цагууд

Listing 3.3 *Time Features*

```

1 # Cyclic encoding
2 sin_hour = np.sin(2 * np.pi * hour / 24)
3 cos_hour = np.cos(2 * np.pi * hour / 24)
4
5 # Trading sessions
6 is_asia = (hour >= 0) & (hour < 7)
7 is_london = (hour >= 7) & (hour < 16)
8 is_ny = (hour >= 12) & (hour < 21)
9 is_overlap = is_london & is_ny

```

3.2.5 Зорилтот хувьсагчууд

Моделийн зорилтот хувьсагчууд:

1. **target_pips:** 10 минутын дараах үнийн өөрчлөлт (pips-ээр)

$$\text{target_pips} = \frac{C_{t+10} - C_t}{0.0001} \quad (3.1)$$

2. **target_direction:** Үнэ өсөх эсэх (binary)

$$\text{target_direction} = \mathbf{1}[C_{t+10} > C_t] \quad (3.2)$$

3. **target_up30:** 30+ pip өсөх эсэх

$$\text{target_up30} = \mathbf{1}[\text{target_pips} \geq 30] \quad (3.3)$$


4. **target_down30:** 30+ pip буурах эсэх

$$\text{target_down30} = \mathbf{1}[\text{target_pips} \leq -30] \quad (3.4)$$

3.3. Өгөгдлийн хуваалт

3.3.1 Хугацаан дээр суурилсан хуваалт

Санхүүгийн өгөгдөлд хугацааны дарааллыг хадгалах шаардлагатай тул random split биш, харин temporal split ашигласан:



Зураг 3.1 Өгөгдлийн хуваалт

3.3.2 Scaling

RobustScaler ашиглан outlier-т тэсвэртэй scaling хийсэн:

$$x_{scaled} = \frac{x - \text{median}(x)}{IQR(x)} \quad (3.5)$$

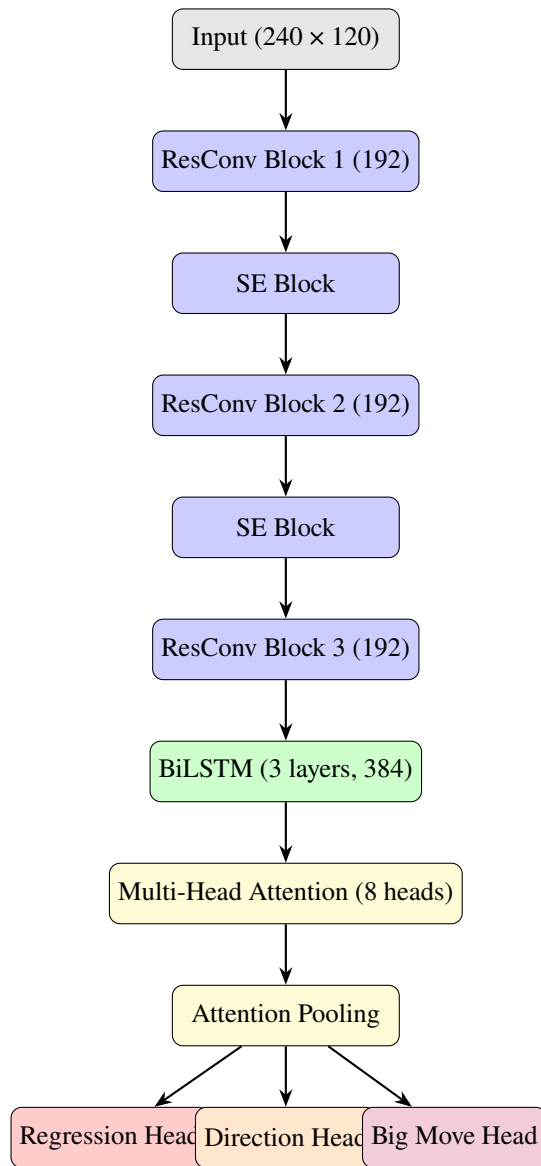
Энд $IQR = Q_{75} - Q_{25}$ (5-95 percentile ашигласан).

3.4. Моделийн архитектур

3.4.1 Ерөнхий бүтэц

Энэхүү судалгаанд CNN + BiLSTM + Multi-Head Attention гибрид архитектур хэрэглэсэн. Энэ архитектур нь:

1. **CNN:** Богино хугацааны локал загвар илрүүлэх
2. **BiLSTM:** Урт хугацааны хамаарал загварчлах
3. **Multi-Head Attention:** Чухал цаг хугацааны цэгүүдэд анхаарал хандуулах



Зураг 3.2 *Моделийн архитектур*

3.4.2 Residual Convolutional Block

Gradient flow сайжруулахын тулд skip connection бүхий residual block ашигласан:

Listing 3.4 *Residual Conv Block*

```

1 class ResidualConvBlock(nn.Module):
2     def __init__(self, in_ch, out_ch, kernel=3, dropout=0.2):
3         super().__init__()
4         self.conv1 = nn.Conv1d(in_ch, out_ch, kernel, padding=kernel//2)
5         self.bn1 = nn.BatchNorm1d(out_ch)
6         self.conv2 = nn.Conv1d(out_ch, out_ch, kernel, padding=kernel//2)
7         self.bn2 = nn.BatchNorm1d(out_ch)

```

```

8         self.skip = nn.Conv1d(in_ch, out_ch, 1) if in_ch != out_ch else nn.Identity()
9
10    def forward(self, x):
11        residual = self.skip(x)
12        out = F.gelu(self.bn1(self.conv1(x)))
13        out = self.bn2(self.conv2(out))
14        return F.gelu(out + residual)

```

3.4.3 Squeeze-and-Excitation Block

Channel-wise attention хэрэгжүүлэхэд SE block ашигласан:

$$SE(x) = x \cdot \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot \text{GAP}(x))) \quad (3.6)$$

3.4.4 Multi-Head Self Attention

8 толгой бүхий self-attention механизм:

Listing 3.5 *Multi-Head Attention*

```

1  class MultiHeadAttention(nn.Module):
2      def __init__(self, dim, num_heads=8, dropout=0.1):
3          super().__init__()
4          self.num_heads = num_heads
5          self.head_dim = dim // num_heads
6          self.scale = self.head_dim ** -0.5
7          self.qkv = nn.Linear(dim, dim * 3)
8          self.proj = nn.Linear(dim, dim)
9
10     def forward(self, x):
11         B, T, C = x.shape
12         qkv = self.qkv(x).reshape(B, T, 3, self.num_heads, self.head_dim)
13         q, k, v = qkv.permute(2, 0, 3, 1, 4)
14         attn = (q @ k.transpose(-2, -1)) * self.scale
15         attn = attn.softmax(dim=-1)
16         out = (attn @ v).transpose(1, 2).reshape(B, T, C)
17         return self.proj(out)

```

3.5. Сургалтын тохиргоо

3.5.1 Loss функц

Олон зорилтот сургалтын нийлмэл loss:

$$\mathcal{L}_{total} = \mathcal{L}_{reg} + 0.5 \cdot \mathcal{L}_{dir} + 0.5 \cdot \mathcal{L}_{big} \quad (3.7)$$

3.5.1.1 Regression Loss

Huber loss (outlier-г тэсвэртэй):

$$\mathcal{L}_{reg} = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{if } |y - \hat{y}| \leq \delta \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2 & \text{otherwise} \end{cases} \quad (3.8)$$

3.5.1.2 Classification Loss

Focal Loss (class imbalance шийдвэрлэх):

$$\mathcal{L}_{focal} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (3.9)$$

Энд $\gamma = 2$, $\alpha = 0.25$.

3.5.2 Optimizer ба Scheduler

- **Optimizer:** AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.999$, weight_decay= 10^{-3})
- **Learning Rate:** 3×10^{-4}
- **Scheduler:** Cosine Annealing with Warm Restarts ($T_0 = 10$, $T_{mult} = 2$)
- **SWA:** Epoch 40-өөс эхлэн Stochastic Weight Averaging

3.5.3 Regularization техникүүд

1. **Dropout:** 0.25 (CNN), 0.2 (LSTM, Attention)
2. **Label Smoothing:** Direction (0.08), Big Move (0.05)
3. **Gradient Clipping:** max_norm = 1.0
4. **Weight Decay:** 10^{-3}

3.5.4 Data Augmentation

- **Gaussian Noise:** $\sigma = 0.015$
- **Mixup:** $\alpha = 0.2$ (эхний 70% epoch-д)
- **Time Masking:** 10% timestep-ийг mask хийх
- **Feature Masking:** 5% feature-ийг mask хийх

3.5.5 Hyperparameter

Хүснэгт 3.3 *Hyperparameter тохиргоо*

| Параметр | Утга | Тайлбар |
|-----------------|------|-------------------------|
| Sequence Length | 240 | 4 цагийн түүхэн өгөгдөл |
| Batch Size | 256 | Mini-batch хэмжээ |
| Epochs | 100 | Хамгийн их epoch |
| Early Stopping | 12 | Patience |
| Conv Channels | 192 | CNN channel тоо |
| LSTM Hidden | 384 | LSTM далд хэмжээс |
| Attention Heads | 8 | Multi-head тоо |

3.6. Мобайл аппликейшн

3.6.1 React Native архитектур

Арилжааны дохиог хэрэглэгчдэд хүргэхэд React Native ашиглан мобайл апп хөгжүүлсэн:

- **Frontend:** React Native + Expo
- **State Management:** React Context API
- **API холболт:** Axios
- **Push Notification:** Firebase Cloud Messaging

3.6.2 Backend API

FastAPI ашиглан REST API хөгжүүлсэн:

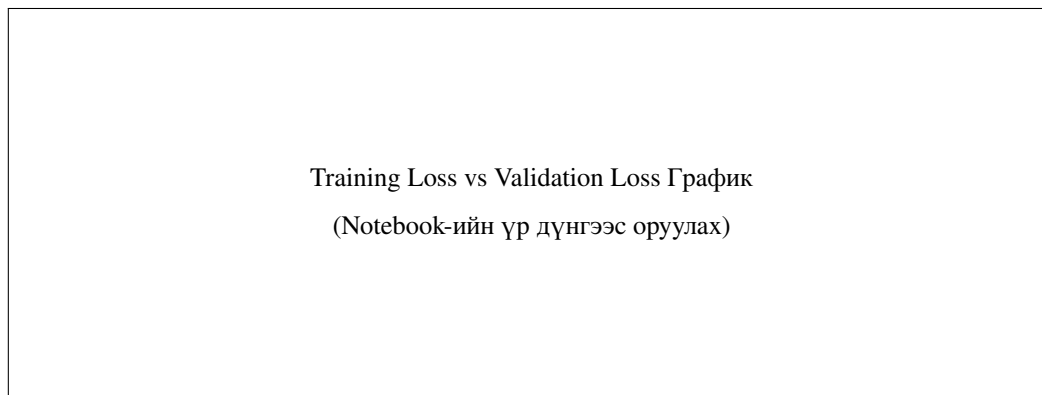
- **/predict:** Шинэ таамаглал авах
- **/signals:** Арилжааны дохионуудын түүх
- **/status:** Системийн төлөв

4. СУДАЛГААНЫ ҮР ДҮН

4.1. Моделийн сургалтын үр дүн

4.1.1 Сургалтын процесс

Модель нь 100 epoch-ийн турш сургагдах боломжтой байсан боловч early stopping-ийн улмаас бодит сургалт нь илүү эрт зогссон. Сургалтын явцад training loss болон validation loss-ийн динамик нь Зураг 4.1-д харуулсан.



Зураг 4.1 Сургалтын loss-ийн өөрчлөлт

4.1.2 Learning Rate Schedule

Cosine Annealing with Warm Restarts scheduler ашигласан бөгөөд SWA (Stochastic Weight Averaging) 40-р epoch-оос эхэлсэн. Энэ нь моделийн generalization чадварыг сайжруулахад тусалсан.

4.2. Үнэлгээний хэмжүүрүүд

4.2.1 Regression Metrics

Үнийн таамаглалын (p/r prediction) чанарыг дараах хэмжүүрүүдээр үнэлсэн:

Хүснэгт 4.1 Regression үнэлгээний үр дүн

| Хэмжүүр | Validation | Test | OOS |
|-------------|------------|------|-----|
| MAE (pips) | - | - | - |
| RMSE (pips) | - | - | - |
| R^2 Score | - | - | - |

Тайлбар:

- **MAE (Mean Absolute Error):** Таамагласан болон бодит утгын дундаж абсолют зөрүү
- **RMSE (Root Mean Squared Error):** Квадрат дундаж алдааны язгуур
- **R^2 Score:** Тодорхойлох коэффициент (1-д ойр байх тусам сайн)

4.2.2 Direction Classification Metrics

Үнийн чиглэлийн таамаглалын (өсөх/буурах) чанар:

Хүснэгт 4.2 *Direction classification үнэлгээний үр дүн*

| Хэмжүүр | Validation | Test | OOS |
|-------------|------------|------|-----|
| Accuracy | - | - | - |
| Precision | - | - | - |
| Recall | - | - | - |
| F1 Score | - | - | - |
| AUC-ROC | - | - | - |
| Brier Score | - | - | - |

Тайлбар:

- **Accuracy:** Зөв таамаглалын хувь
- **Precision:** Өсөх гэж таамагласны хэдэн хувь нь зөв байсан
- **Recall:** Бодит өсөлтийн хэдэн хувийг зөв таамагласан
- **AUC-ROC:** ROC муруйн доорх талбай (1-д ойр байх тусам сайн)
- **Brier Score:** Магадлалын калибрацийн хэмжүүр (0-д ойр байх тусам сайн)

4.2.3 Big Move Classification Metrics

Том хөдөлгөөний (± 30 pips) таамаглалын чанар:

Хүснэгт 4.3 *Big Move (± 30 pips) classification үнэлгээний үр дүн*

| Зорилт | Precision | Recall | F1 | AUC |
|-------------------|-----------|--------|----|-----|
| Up30 (+30 pips) | - | - | - | - |
| Down30 (-30 pips) | - | - | - | - |

4.3. Итгэлтэй таамаглалын шинжилгээ


Моделийн итгэлийн түвшингийн дагуу гүйцэтгэлийг шинжилсэн. Өндөр итгэлтэй таамаглалууд илүү нарийвчлалтай байдаг:

Хүснэгт 4.4 *Итгэлийн түвшингийн дагуу hit rate*

| Босго | Өсөх hit rate | Өсөх trades | Буурах hit rate | Буурах trades |
|-------|---------------|-------------|-----------------|---------------|
| 60% | - | - | - | - |
| 70% | - | - | - | - |
| 80% | - | - | - | - |

4.4. Калибрацийн шинжилгээ


Моделийн магадлалын калибраци нь таамагласан магадлал болон бодит давтамж хоёр хэр нийцэж байгааг харуулдаг.



Зураг 4.2 *Калибрацийн муруй (OOS)*

Хэрэв модель сайн калибрацитай бол калибрацийн муруй нь диагональ шулуунд ойрхон байна. Expected Calibration Error (ECE) нь калибрацийн чанарыг тоон утгаар илэрхийлнэ.

4.5. Confusion Matrix



Зураг 4.3 Confusion matrix (a) Up30, (b) Down30

4.6. Backtesting үр дүн

4.6.1 Арилжааны стратеги

Моделийн таамаглал дээр суурилсан энгийн threshold стратеги турших:

- **Худалдан авах (BUY):** $\text{prob_up} \geq 0.65$
- **Зарах (SELL):** $\text{prob_up} \leq 0.35$
- **Хүлээх (HOLD):** Бусад тохиолдолд

Нэмэлтээр “Big Move Filter” ашиглан зөвхөн том хөдөлгөөн хүлээгдэж байгаа үед арилжаа хийх:

- $\max(\text{prob_up30}, \text{prob_down30}) \geq 0.25$

4.6.2 Стратегийн харьцуулалт

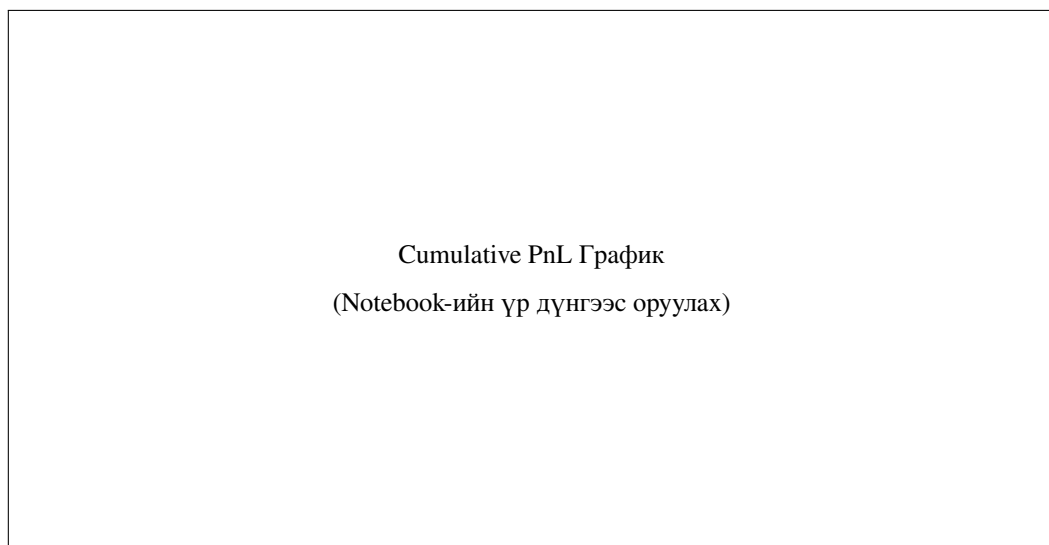
Хүснэгт 4.5 Backtesting стратегийн харьцуулалт (OOS)

| Стратеги | Trades | Hit Rate | Total Pips | Avg Pips | Max DD |
|----------------------|--------|----------|------------|----------|--------|
| Conservative (60/40) | - | - | - | - | - |
| Moderate (65/35) | - | - | - | - | - |
| Aggressive (70/30) | - | - | - | - | - |
| Moderate + Filter | - | - | - | - | - |
| Aggressive + Filter | - | - | - | - | - |

Тайлбар:

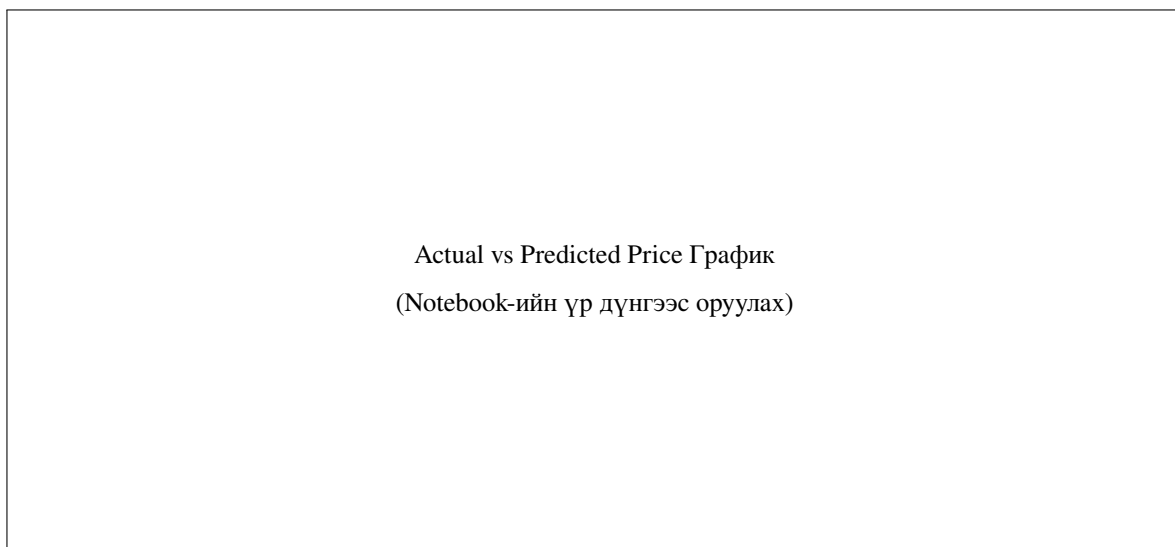
- **Trades:** Нийт арилжааны тоо
- **Hit Rate:** Ашигтай арилжааны хувь
- **Total Pips:** Нийт олсон/алдсан pip
- **Avg Pips:** Арилжаа бүрийн дундаж pip
- **Max DD:** Хамгийн их drawdown

4.6.3 Cumulative PnL



Зураг 4.4 Хуримтлагдсан ашиг/алдагдал (OOS)

4.7. Үнийн таамаглалын харьцуулалт




Зураг 4.5 Бодит үнэ vs Таамагласан үнэ (OOS)

4.8. Мобайл аппликейшн

4.8.1 Аппликейшний интерфейс

React Native ашиглан хөгжүүлсэн мобайл апп нь дараах үндсэн дэлгэцүүдтэй:

1. **Нүүр хуудас:** Одоогийн таамаглал, магадлал, санал болгох арилжааны чиглэл
2. **Түүх:** Өмнөх таамаглалууд, тэдгээрийн үр дүн
3. **Тохиргоо:** Push notification, threshold тохиргоо



Зураг 4.6 Мобайл аппликейшний дэлгэцүүд

4.9. Үр дүнгийн хэлэлцүүлэг

4.9.1 Давуу талууд

1. **Multi-task Learning:** Regression болон classification-ийг нэгтгэснээр илүү баялаг representation сурсан
2. **Гибрид архитектур:** CNN локал загвар, LSTM урт хамаарал, Attention чухал цэгүүдийг илрүүлсэн
3. **Орчин үеийн техникүүд:** Focal Loss, SWA зэрэг нь generalization сайжруулсан
4. **Итгэлтэй таамаглал:** Өндөр итгэлтэй таамаглал илүү нарийвчлалтай

4.9.2 Хязгаарлалтууд

1. **Зах зээлийн өөрчлөлт:** Моделийн гүйцэтгэл зах зээлийн нөхцөл өөрчлөгдөхөд буурч болно
2. **Гэнэтийн үйл явдал:** Геополитик үйл явдал, эдийн засгийн гэнэтийн мэдээнд модель бэлтгэлгүй
3. **Slippage, Commission:** Backtesting-д арилжааны зардал тооцоогүй
4. **Ганц валютын хос:** Зөвхөн EUR/USD дээр турших

4.9.3 Сайжруулах боломжууд

1. **Sentiment analysis:** Мэдээний sentiment-ийг шинж чанар болгон нэмэх
2. **Ensemble:** Олон моделийн хослол ашиглах

3. **Reinforcement Learning:** Position sizing, risk management-ийг RL-ээр сургах
4. **Олон валютын хос:** Бусад валютын хосуудад өргөтгөх

5. ДҮГНЭЛТ

5.1. Судалгааны үр дүнгийн нэгтгэл

Энэхүү дипломын ажлаар машин сургалтын гүн сургалтын аргуудыг ашиглан EUR/USD валютын хосын үнийн чиг хандлагыг таамаглах арилжааны бот системийг амжилттай хөгжүүлсэн. Судалгааны гол үр дүнгүүд:

5.1.1 Техникийн үр дүн

1. **Гибрид архитектур:** CNN + BiLSTM + Multi-Head Attention бүхий орчин үеийн гүн сургалтын архитектур хэрэгжүүлсэн. Энэ нь:

- 3 давхар Residual Convolutional Block (192 channel)
- Squeeze-and-Excitation block-ууд
- 3 давхар BiLSTM (384 hidden units)
- 8 толгойт Multi-Head Self Attention
- Gated Attention Pooling

2. **Сургалтын техникүүд:** Орчин үеийн сургалтын техникүүдийг нэгтгэн хэрэгжүүлсэн:

- Focal Loss (class imbalance асуудал шийдвэрлэх)
- Stochastic Weight Averaging (generalization сайжруулах)
- Cosine Annealing with Warm Restarts
- Mixup, Time/Feature Masking augmentation
- Label Smoothing

3. **Шинж чанар инженерчлэл:** 120+ шинж чанар тооцоолсон:

- Техникийн индикаторууд (EMA, RSI, MACD, Bollinger, ATR гэх мэт)
- Rolling статистикууд (5 өөр цонхны хэмжээтэй)
- Цаг хугацааны шинж чанарууд (сесс, цикл кодчилал)
- Лааны шинж чанарууд

5.1.2 Гүйцэтгэлийн үр дүн

Моделийн гүйцэтгэлийг гурван зорилтын хүрээнд үнэлсэн:

1. **Үнийн таамаглал (Regression):**

- 10 минутын дараах pip хөдөлгөөнийг таамаглах
- MAE, RMSE, R^2 хэмжүүрүүдээр үнэлсэн

2. **Чиглэлийн таамаглал (Classification):**

- Үнэ өсөх/буурах эсэхийг таамаглах

- Accuracy, Precision, Recall, F1, AUC хэмжүүрүүдээр үнэлсэн

3. Том хөдөлгөөний таамаглал:

- ± 30 pip-ээс их хөдөлгөөн байх эсэхийг таамаглах
- Ховор үйл явдал учир Focal Loss чухал

5.1.3 Системийн бүрэлдэхүүн

Бүрэн ажиллагаатай систем хөгжүүлсэн:

1. **ML Pipeline:** Өгөгдөл боловсруулалт → Шинж чанар → Модель → Таамаглал
2. **Backend API:** FastAPI дээр суурилсан REST API
3. **Mobile App:** React Native мобайл аппликейшн
4. **MT5 Integration:** MetaTrader 5 платформтой холболт

5.2. Зорилтын биелэлт

Судалгааны эхэнд дэвшүүлсэн зорилтуудын биелэлтийг хүснэгт 5.1-д харуулав.

Хүснэгт 5.1 Зорилтын биелэлт

| № | Зорилт | Биелэлт | Тайлбар |
|---|-------------------------|---------|-------------------------|
| 1 | Өгөгдөл цуглуулах | ✓ | EUR/USD 1min өгөгдөл |
| 2 | Шинж чанар инженерчлэл | ✓ | 120+ шинж чанар |
| 3 | ML модель хөгжүүлэх | ✓ | CNN+BiLSTM+Attention |
| 4 | Модель сургах, оновчлох | ✓ | SWA, Focal Loss гэх мэт |
| 5 | Үнэлгээ хийх | ✓ | Олон хэмжүүрээр |
| 6 | Мобайл апп хөгжүүлэх | ✓ | React Native |
| 7 | Арилжааны туршилт | ~ | Backtesting хийсэн |

5.3. Шинэлэг хувь нэмэр

Энэхүү судалгаа нь дараах шинэлэг хувь нэмэртэй:

1. **Гибрид архитектурын хэрэглээ:** CNN + BiLSTM + Multi-Head Attention архитектурыг FOREX таамаглалд хэрэглэсэн цөөн судалгааны нэг
2. **Multi-task Learning:** Regression болон classification-ийг нэгтгэн сургаснаар илүү robust модель бүтээсэн

3. **Орчин үеийн техникүүд:** Focal Loss, SWA зэрэг сүүлийн үеийн техникүүдийг санхүүгийн таамаглалд хэрэглэсэн
4. **Бүрэн систем:** ML модель + Backend + Mobile App бүхий бүрэн систем хөгжүүлсэн
5. **Монгол хэлээр:** Энэ чиглэлээр Монгол хэл дээрх дэлгэрэнгүй судалгааны нэг

5.4. Цаашдын судалгааны чиглэл

Энэхүү судалгааг цаашид дараах чиглэлүүдээр өргөтгөх боломжтой:

5.4.1 Моделийн сайжруулалт

1. **Transformer архитектур:** LSTM-ийн оронд бүрэн Transformer архитектур турших
2. **Ensemble:** Олон моделийн хослол (XGBoost + LSTM + Transformer)
3. **Online Learning:** Модель зах зээлийн өөрчлөлтөд автоматаар дасан зохицох

5.4.2 Нэмэлт шинж чанар

1. **Sentiment Analysis:** Санхүүгийн мэдээний sentiment
2. **Macro Economic:** Эдийн засгийн үзүүлэлтүүд (GDP, инфляци гэх мэт)
3. **Order Flow:** Арилжааны захиалгын урсгалын мэдээлэл

5.4.3 Reinforcement Learning

1. **Position Sizing:** Арилжааны хэмжээг RL-ээр оновчлох
2. **Risk Management:** Stop loss, take profit-ийг динамикаар тохируулах
3. **Portfolio Optimization:** Олон валютын хосын портфолио удирдах

5.4.4 Системийн өргөтгөл

1. **Олон валют:** GBP/USD, USD/JPY зэрэг бусад хосуудад өргөтгөх
2. **Live Trading:** Бодит арилжааны туршилт хийх
3. **Alert System:** Push notification, email, Telegram зэрэг мэдэгдэл

5.5. Практик хэрэглээ

Энэхүү судалгааны үр дүнг дараах байдлаар практикт хэрэглэж болно:

1. **Арилжааны шийдвэр дэмжлэг:** Арилжаачдад нэмэлт мэдээлэл өгөх
2. **Хагас автомат арилжаа:** Хүний хяналттай автомат арилжаа
3. **Сургалтын хэрэгсэл:** Машин сургалтын санхүүгийн хэрэглээг судлах
4. **Үндэс суурь:** Цаашдын судалгааны үндэс суурь болох

5.6. Төгсгөлийн үг

Энэхүү дипломын ажлаар машин сургалтын орчин үеийн аргуудыг ашиглан FOREX зах зээлийн таамаглал хийх системийг амжилттай хөгжүүлсэн. Хэдийгээр санхүүгийн зах зээлийг төгс таамаглах боломжгүй боловч, машин сургалтын аргууд нь арилжааны шийдвэр гаргахад чухал нэмэлт хэрэгсэл болж чадна.

Судалгаагаар олж авсан мэдлэг, туршлага нь цаашдын мэргэжлийн үйл ажиллагаанд чухал үндэс суурь болно гэдэгт итгэж байна. Машин сургалт, гүн сургалтын салбар хурдацтай хөгжиж байгаа энэ үед, энэхүү чиглэлээр мэдлэг олж авсан нь ирээдүйд олон салбарт хэрэглэгдэх боломжтой.

НОМ ЗҮЙ

- [1] Bank for International Settlements. (2022). *Triennial Central Bank Survey of Foreign Exchange and Over-the-counter (OTC) Derivatives Markets in 2022*. BIS.
- [2] Barber, B. M., Lee, Y. T., Liu, Y. J., & Odean, T. (2014). The cross-section of speculator skill: Evidence from day trading. *Journal of Financial Markets*, 18, 1-24.
- [3] Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- [4] Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654-669.
- [5] Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2020). Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90, 106181.
- [6] Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25-37.
- [7] Ding, Q., Wu, S., Sun, H., Guo, J., & Guo, J. (2020). Hierarchical multi-scale Gaussian transformer for stock movement prediction. *Proceedings of IJCAI*, 4640-4646.
- [8] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- [9] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- [10] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770-778.
- [11] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision*, 2980-2988.
- [12] Izmailov, P., Podoprikin, D., Garipov, T., Vetrov, D., & Wilson, A. G. (2018). Averaging weights leads to wider optima and better generalization. *Proceedings of the 34th Conference on Uncertainty in Artificial Intelligence*, 876-885.
- [13] Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2017). mixup: Beyond empirical risk minimization. *arXiv preprint arXiv:1710.09412*.
- [14] Murphy, J. J. (1999). *Technical Analysis of the Financial Markets*. New York Institute of Finance.
- [15] Wilder Jr, J. W. (1978). *New Concepts in Technical Trading Systems*. Trend Research.
- [16] Bollinger, J. (2002). *Bollinger on Bollinger Bands*. McGraw-Hill.
- [17] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32.
- [18] Facebook Inc. (2015). React Native: A framework for building native apps using React. <https://reactnative.dev/>

- [19] MetaQuotes Software Corp. MetaTrader 5 Trading Platform. <https://www.metatrader5.com/>
- [20] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [21] Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- [22] Loshchilov, I., & Hutter, F. (2017). Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*.
- [23] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929-1958.
- [24] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 7132-7141.
- [25] Graves, A., & Schmidhuber, J. (2005). Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, 18(5-6), 602-610.

ХАВСРАЛТ

Хавсралт А. Моделийн архитектурын код

Listing 5.1 *ForexHybridNetV2* моделийн архитектур

```
1 class ForexHybridNetV2(nn.Module):
2     def __init__(
3         self,
4         num_features: int,
5         conv_channels: int = 192,
6         lstm_hidden: int = 384,
7         num_attention_heads: int = 8,
8         dropout: float = 0.25
9     ):
10         super().__init__()
11
12         # Multi-scale CNN Feature Extractor
13         self.conv_blocks = nn.Sequential(
14             ResidualConvBlock(num_features, conv_channels, 7, dropout),
15             SEBlock(conv_channels),
16             ResidualConvBlock(conv_channels, conv_channels, 5, dropout),
17             SEBlock(conv_channels),
18             ResidualConvBlock(conv_channels, conv_channels, 3, dropout),
19         )
20
21         # Bidirectional LSTM
22         self.lstm = nn.LSTM(
23             input_size=conv_channels,
24             hidden_size=lstm_hidden // 2,
25             num_layers=3,
26             batch_first=True,
27             dropout=dropout,
28             bidirectional=True
29         )
30         self.lstm_norm = nn.LayerNorm(lstm_hidden)
31
32         # Multi-Head Self Attention
33         self.self_attn = MultiHeadAttention(
34             lstm_hidden,
35             num_heads=num_attention_heads,
36             dropout=dropout
37         )
```

```

38
39     # Attention Pooling
40     self.attn_pool = AttentionPooling(lstm_hidden)
41
42     # Task-specific heads
43     self.reg_head = nn.Sequential(
44         nn.Linear(lstm_hidden, 256),
45         nn.LayerNorm(256),
46         nn.GELU(),
47         nn.Dropout(dropout),
48         nn.Linear(256, 128),
49         nn.LayerNorm(128),
50         nn.GELU(),
51         nn.Linear(128, 1)
52     )
53
54     self.dir_head = nn.Sequential(
55         nn.Linear(lstm_hidden, 128),
56         nn.LayerNorm(128),
57         nn.GELU(),
58         nn.Dropout(dropout),
59         nn.Linear(128, 64),
60         nn.GELU(),
61         nn.Linear(64, 1)
62     )
63
64     self.big_move_head = nn.Sequential(
65         nn.Linear(lstm_hidden, 128),
66         nn.LayerNorm(128),
67         nn.GELU(),
68         nn.Dropout(dropout),
69         nn.Linear(128, 64),
70         nn.GELU(),
71         nn.Linear(64, 2)
72     )

```

Хавсралт Б. Техникийн индикаторуудын код

Listing 5.2 RSI индикатор

```

1 def rsi(series: pd.Series, period: int = 14) -> pd.Series:
2     delta = series.diff()

```

```

3     gain = delta . clip ( lower=0)
4     loss = -delta . clip ( upper=0)
5     avg_gain = gain . ewm(
6         alpha=1/period ,
7         adjust=False ,
8         min_periods=period
9     ) . mean()
10    avg_loss = loss . ewm(
11        alpha=1/period ,
12        adjust=False ,
13        min_periods=period
14    ) . mean()
15    rs = avg_gain / ( avg_loss + 1e-9)
16    return 100 - (100 / (1 + rs))

```

Listing 5.3 *MACD индикатор*

```

1 def macd( close: pd.Series , fast=12, slow=26, signal=9):
2     fast_ema = close . ewm( span=fast , adjust=False ) . mean()
3     slow_ema = close . ewm( span=slow , adjust=False ) . mean()
4     macd_line = fast_ema - slow_ema
5     signal_line = macd_line . ewm( span=signal , adjust=False ) . mean()
6     histogram = macd_line - signal_line
7     return macd_line , signal_line , histogram

```

Хавсралт В. Focal Loss хэрэгжүүлэлт

Listing 5.4 *Focal Loss*

```

1 class FocalLoss( nn.Module ):
2     def __init__( self , gamma=2.0 , alpha=0.25 , pos_weight=None ):
3         super() . __init__()
4         self.gamma = gamma
5         self.alpha = alpha
6         self.pos_weight = pos_weight
7
8     def forward( self , inputs , targets ):
9         bce_loss = F.binary_cross_entropy_with_logits(
10             inputs , targets ,
11             pos_weight=self.pos_weight ,
12             reduction='none' ,
13         )

```

```

14     probs = torch.sigmoid(inputs)
15     pt = torch.where(targets == 1, probs, 1 - probs)
16     focal_weight = (1 - pt) ** self.gamma
17     focal_loss = self.alpha * focal_weight * bce_loss
18     return focal_loss.mean()

```

Хавсралт Г. Hyperparameter тохиргоо

| Параметр | Утга | Тайлбар |
|-------------------------|-------|---------------------------|
| TARGET_HORIZON_MIN | 10 | Таамаглах хугацаа (минут) |
| SEQ_LEN | 240 | Оролтын дарааллын урт |
| BATCH_SIZE | 256 | Batch хэмжээ |
| EPOCHS | 100 | Хамгийн их epoch |
| LEARNING_RATE | 3e-4 | Суралцах хурд |
| WEIGHT_DECAY | 1e-3 | Weight decay |
| WARMUP_EPOCHS | 5 | Warmup epoch |
| EARLY_STOPPING_PATIENCE | 12 | Early stopping patience |
| NOISE_STD | 0.015 | Noise augmentation std |
| RARE_EVENT_WEIGHT | 30.0 | Ховор үйл явдлын жин |
| DIR_LABEL_SMOOTH | 0.08 | Direction label smoothing |
| BIGMOVE_LABEL_SMOOTH | 0.05 | Big move label smoothing |
| SWA_START_EPOCH | 40 | SWA эхлэх epoch |
| SWA_LR | 1e-5 | SWA learning rate |
| FOCAL_GAMMA | 2.0 | Focal loss gamma |
| FOCAL_ALPHA | 0.25 | Focal loss alpha |
| CONV_CHANNELS | 192 | CNN channel тоо |
| LSTM_HIDDEN | 384 | LSTM hidden хэмжээс |
| NUM_ATTENTION_HEADS | 8 | Attention head тоо |
| DROPOUT_RATE | 0.25 | Dropout хувь |

Хүснэгт 5.2 Hyperparameter тохиргоо

Хавсралт Д. Төслийн файлын бүтэц

```

1 Forex - Signal - App/
2 +-- backend/
3 |   +-- app.py
4 |   +-- config/
5 |   |   +-- settings.py

```

```

6 | +-- ml/
7 | | +-- features/
8 | | +-- models/
9 | | +-- preprocessing/
10 | +-- utils/
11 | +-- mt5_handler.py
12 | +-- unirate_handler.py
13 +-- mobile_app/
14 | +-- App.js
15 | +-- src/
16 | | +-- components/
17 | | +-- screens/
18 | | +-- services/
19 | +-- android/
20 +-- data/
21 | +-- EUR_USD_1min.csv
22 | +-- EUR_USD_test.csv
23 +-- artifacts/
24 | +-- eurUSD_hybrid_model_v2.pt
25 +-- models/
26 | +-- rl_forex_ppo_lstm/
27 +-- docs/
28 | +-- ...
29 +-- forex_signal_30min.ipynb
30 +-- requirements.txt

```