



**ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ  
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ**

Оюутны код: s21c033b  
Оюутны овог нэр: Мөнхсүлд МӨНХДОРЖ

**МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ  
ТААМАГЛАХ АРИЛЖААНЫ БОТ  
/ТӨГСӨЛТИЙН СУДАЛГААНЫ АЖИЛ/**

Удирдагч багш  
Гүйцэтгэсэн оюутан

Н.СОРОНЗОНБОЛД  
М.МӨНХДОРЖ

Улаанбаатар хот  
2026 он

**ШИНЭ МОНГОЛ ТЕХНОЛОГИЙН КОЛЛЕЖ  
КОМПЬЮТЕРЫН УХААНЫ ТЭНХИМ**

Төгсөлтийн судалгааны ажил

**МАШИН СУРГАЛТЫН АРГААР ХӨРӨНГИЙН ЗАХ ЗЭЭЛИЙН ЧИГ ХАНДЛАГЫГ  
ТААМАГЛАХ АРИЛЖААНЫ БОТ**

Гүйцэтгэгч: М.МӨНХДОРЖ

Удирдагч: Н.СОРОНЗОНБОЛД

Улаанбаатар хот

2026 он

## Хураангуй

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргуудыг ашиглан валютын зах зээл (Forex) дээрх EUR/USD хослолын үнийн чиг хандлагыг таамаглах, автомат арилжааны дохио үүсгэх систем болон гар утасны апликеийшн хөгжүүлсэн.

Системийн цөм нь LightGBM, XGBoost, CatBoost гэсэн гурван градиент нэмэгдүүлсэн шийдвэрийн модны (GBDT) ансамбль загвар юм. Загваруудыг 2015–2022 оны ~2.97 сая бааранд сургаж, 2023 оны 371,000 бааранд баталгаажуулж, 2024 оны 371,000 бааранд тестэлсэн. Walk-forward validation аргачлалыг хэрэглэж overfitting-ийн эрсдэлийг бууруулсан. 6 хугацааны интервалаас (M1–H4) нийт 48 техник шинж чанар тооцоолж, олон хугацааны хүрээний дун шинжилгээг хэрэгжүүлсэн.

2025 оны бэктест дун: 10,000\$ анхны хөрөнгөөс 14,161.20\$ болж **+41.61%** өгөөж, **Profit Factor 2.46**, **Sharpe Ratio 9.64**, **хамгийн их уналт 3.93%** хүрсэн. React Native технологи дээр суурилсан “Predictrix” мобайл апликеийшн нь бодит цагийн ханш, ML дохио, эдийн засгийн мэдээ, хэрэглэгчийн баталгаажуулалт зэрэг бүрэн функцийг хэрэгжүүлсэн.

*Түлхүүр үсг:* машин сургалт, ансамбль загвар, валютын зах зээл, GBDT, XGBoost, LightGBM, CatBoost, техник шинжилгээ, арилжааны дохио, React Native, бэктест

## Abstract

This research develops an automated trading signal generation system and mobile application for predicting EUR/USD price movements in the Forex market using machine learning ensemble methods.

The core of the system is an ensemble of three Gradient Boosted Decision Tree (GBDT) models: LightGBM (496 trees), XGBoost (~400 trees), and CatBoost (499 trees). The models were trained on ~2.97 million bars from 2015–2022, validated on 371,000 bars from 2023, and tested on 371,000 bars from 2024. Walk-forward validation methodology was employed to mitigate overfitting risks. A total of 48 technical features were computed from 6 timeframes (M1, M5, M15, M30, H1, H4), implementing multi-timeframe analysis.

Backtest results for 2025: starting from \$10,000 initial capital, the system achieved \$14,161.20 final balance (**+41.61%** return), **Profit Factor 2.46**, **Sharpe Ratio 9.64**, and **Maximum Drawdown 3.93%**. The “Predictrix” mobile application, built with React Native, provides real-time exchange rates, ML signals, economic news, and user authentication.

*Keywords:* *machine learning, ensemble model, foreign exchange market, GBDT, XGBoost, LightGBM, CatBoost, technical analysis, trading signals, React Native, backtesting*

<b>Гарчиг</b>	i
<b>Хураангуй</b>	i
<b>Гарчиг</b>	ii
<b>Товчилсон үгсийн жагсаалт</b>	iii
<b>Хүснэгтийн жагсаалт</b>	iv
<b>Зургийн жагсаалт</b>	v
<b>1 Ажлын төлөвлөгөө</b>	1
<b>2 Удиртгал</b>	2
2.1 Үндэслэл, ач холбогдол .....	2
2.2 Зорилго, зорилт .....	2
<b>3 Судалгааны сэдвийн онол, өнөөгийн түвшин</b>	3
3.1 Forex зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд .....	3
3.2 Техник шинжилгээний индикаторуудын судалгаа .....	4
3.3 Walk-Forward Validation ба санхүүгийн цаг хугацааны цуваа .....	5
3.4 Forex арилжааны аппликашн ба технологийн хэрэгжүүлэлт .....	5
3.5 Судалгааны gap ба энэхүү ажлын хувь нэмэр .....	5
3.6 Бүлгийн дүгнэлт .....	6
<b>4 Судалгааны арга зүй</b>	7
4.1 Системийн ерөнхий архитектур .....	7
4.2 Өгөгдлийн бэлтгэл .....	7
4.3 Загварын бүтэц ба сургалт .....	9
4.4 Дохио үүсгэх систем .....	10
4.5 MetaTrader 5 бэктест .....	11
4.6 Backend API хөгжүүлэлт .....	11
4.7 Мобайл аппликашн хөгжүүлэлт .....	12
4.8 Хөгжүүлэлтийн үе шатууд .....	13
4.9 Бүлгийн дүгнэлт .....	13
<b>5 Судалгааны үр дүн, дүгнэлт</b>	14
5.1 Загварын сургалтын үр дүн .....	14
5.2 Бэктестийн дүн .....	14
5.3 Гүйцэтгэлийн гүнзгий шинжилгээ .....	17
5.4 Хөгжүүлэлтийн үе шатуудын харьцуулалт .....	19
5.5 Overfitting шинжилгээ .....	20
5.6 Мобайл аппликашний ажиллагаа .....	21
5.7 Дүгнэлт .....	21
<b>Ном зүй</b>	22
<b>Хавсралт</b>	25
<b>Талархал</b>	28

## **Товчилсон үгсийн жагсаалт**

**ML** Machine Learning – Машин сургалт

**AI** Artificial Intelligence – Хиймэл оюун ухаан

**GBDT** Gradient Boosted Decision Trees – Градиент нэмэгдүүлсэн шийдвэрийн мод

**XGBoost** Extreme Gradient Boosting

**LightGBM** Light Gradient Boosting Machine

**CatBoost** Categorical Boosting

**LSTM** Long Short-Term Memory – Урт богино хугацааны санах ой

**RSI** Relative Strength Index – Харьцангуй хүчний индекс

**ATR** Average True Range – Дундаж жинхэнэ хүрээ

**MACD** Moving Average Convergence Divergence

**SMA** Simple Moving Average – Энгийн хөдөлгөөнт дундаж

**EMA** Exponential Moving Average – Экспоненциал хөдөлгөөнт дундаж

**ADX** Average Directional Index – Дундаж чиглэлийн индекс

**CCI** Commodity Channel Index

**SL** Stop Loss – Алдагдал зогсоох

**TP** Take Profit – Ашиг авах

**API** Application Programming Interface

**REST** Representational State Transfer

**JWT** JSON Web Token

**OHLCV** Open, High, Low, Close, Volume

**MT5** MetaTrader 5

**PF** Profit Factor – Ашгийн коэффициент

**DD** Drawdown – Уналт

**RR** Risk-Reward Ratio – Эрсдэл-өгөөжийн харьцаа

**CORS** Cross-Origin Resource Sharing

**WSGI** Web Server Gateway Interface

**CSV** Comma-Separated Values

## **Хүснэгтийн жагсаалт**

Хүснэгт 4.1.	Өгөгдлийн хэмжээний хураангуй	7
Хүснэгт 4.2.	Шинж чанарын жагсаалт (интервал бүрд)	8
Хүснэгт 4.3.	Walk-Forward Validation – өгөгдлийн хуваалт	8
Хүснэгт 4.4.	Загвар бүрийн гол гиперпараметрүүд	9
Хүснэгт 4.5.	EA-ийн тохиргооны параметрүүд	11
Хүснэгт 4.6.	Backend технологийн стек	11
Хүснэгт 4.7.	Гол API endpoint-үүд	12
Хүснэгт 4.8.	Мобайл апликацийн технологийн стек	12
Хүснэгт 4.9.	Хөгжүүлэлтийн үе шатууд	13
Хүснэгт 5.1.	Загварын нарийвчлалын хэмжүүрүүд	14
Хүснэгт 5.2.	Загвар бүрийн шинж чанар	14
Хүснэгт 5.3.	MetaTrader 5 бэктестийн дүн (Phase 7B)	15
Хүснэгт 5.4.	Phase 6B ба Phase 7B-ийн харьцуулалт	19
Хүснэгт 5.5.	Бенчмарк харьцуулалт	20
Хүснэгт 5.6.	2025 оны дохионы жишээ	28

## **Зургийн жагсаалт**

Зураг 4.1.	Системийн ерөнхий архитектур .....	7
Зураг 4.2.	Ансамбль загварын архитектур .....	9
Зураг 5.1.	Equity муруй – \$10,000-aac \$14,161.20 хүртэл (+41.61%) .....	15
Зураг 5.2.	Сарын гүйцэтгэл – ашиг (\$) ба win rate (%) .....	16
Зураг 5.3.	Уналтын шинжилгээ (Max Drawdown: 3.93%) .....	16
Зураг 5.4.	Эрсдэлийн хэмжүүрүүдийн самбар .....	17
Зураг 5.5.	Итгэлцлийн утга ба таамаглалын нарийвчлалын хамаарал .....	18
Зураг 5.6.	Шинж чанарын ач холбогдол (Top 20) .....	18
Зураг 5.7.	Phase 6B ба Phase 7B-ийн харьцуулалт .....	19
Зураг 5.8.	Phase 6B ба Phase 7B харьцуулалтын хүснэгт .....	20

## 1. Ажлын төлөвлөгөө

Оюутны нэр: М.МӨНХДОРЖ

Удирдагч багшийн нэр: Н.СОРОНЗОНБОЛД

**Судалгааны ажлын сэдэв:** Машин сургалтын аргаар хөрөнгийн зах зээлийн чиг хандлагыг таамаглах арилжааны бот хөгжүүлэх

Cap	Долоо хоног	Төлөвлөгөө	Гүйцэтгэл
10 cap	1	Сэдэв сонгох, судалгааны чиглэл тодорхойлох	✓
	2	Forex арилжаа, ML онолын судалгаа хийх	✓
	3	Twelve Data API-aac EUR/USD өгөгдөл цуглуулах	✓
	4	Өгөгдлийн урьдчилсан боловсруулалт хийх	✓
11 cap	1	70+ техникийн индикатор хөгжүүлэх (RSI, MACD, BB, ATR)	✓
	2	XGBoost, LightGBM, Random Forest модель сургах	✓
	3	Stacking Ensemble модель хөгжүүлэх, backtesting хийх	✓
	4	Flask REST API сервер, React Native апп хөгжүүлэх	✓
12 cap	1	<b>TCA Үзлэг 1</b>	✓
	2	Төгсөлтийн тайлан бичиж эхлэх	✓
	3	Тайлангийн 1-2 бүлэг бичих	✓
	4	Тайлангийн 3 бүлэг бичих	✓
1 cap	1	Тайлангийн 4 бүлэг бичих	✓
	2	Тайлангийн 5 бүлэг бичих	✓
	3	График, хүснэгт, үр дүнг боловсруулах	✓
	4	Тайланг засварлах, форматлах	✓
2 cap	1	Тайлангийн эцсийн засвар	✓
	2	Ном зүй, хавсралт бэлдэх	✓
	3	Хамгаалалтын слайд бэлдэх	□
	4	Хамгаалалтын бэлтгэл хийх	□
3 cap	1	<b>TCA Үзлэг 2</b>	□
	2	Засвар хийх, санал хүсэлтийг тусгах	□
	3	Код тайлбар, баримтжуулалт	□
	4	Хамгаалалтын дадлага хийх	□
4 cap	1	Эцсийн засвар хийх	□
	2	Слайд сайжруулах	□
	3	Хамгаалалтын бэлтгэл	□
	4	<b>TCA урьдчилсан хамгаалалт</b>	□
5 cap	1	<b>TCA урьдчилсан хамгаалалт</b>	□
	2	<b>TCA урьдчилсан хамгаалалт</b>	□
	3	Эцсийн засвар, сайжруулалт	□
	4	<b>TCA үндсэн хамгаалалт</b>	□

Удирдагч багш:

/Н.СОРОНЗОНБОЛД/

Гүйцэтгэсэн оюутан:

/s21c033b, М.МӨНХДОРЖ/

## **2. Удиртгал**

### **2.1. Үндэслэл, ач холбогдол**

Валютын зах зээл (Foreign Exchange буюу Forex) нь дэлхийн хамгийн том санхүүгийн зах зээл бөгөөд өдөр тутмын арилжааны хэмжээ 7.5 их наяд ам.долларт хүрдэг [1]. Энэхүү зах зээл нь 24 цагийн турш ажилладаг, олон улсын эдийн засаг, geopolitic нөхцөл байдал, төв банкуудын бодлого зэрэг олон тооны хүчин зүйлээс хамаардаг нь үнийн хөдөлгөөнийг таамаглахад ихээхэн хүндрэлийг учруулдаг.

Уламжлалт техник дүн шинжилгээний аргууд нь хүний туршлага, мэдлэгт ихээхэн найддаг боловч хэлбэлзэл ихтэй, өндөр давтамжтай арилжаанд тэдгээрийн үр ашиг хязгаарлагдмал байдаг. Мөн хүний шийдвэр нь сэтгэл хөдлөл, субъектив үнэлгээнээс шалтгаалан алдаа гарах магадлал өндөр байдаг.

Сүүлийн жилүүдэд машин сургалт (Machine Learning) болон хиймэл оюун ухааны технологиуд санхүүгийн салбарт өргөн хэрэглэгдэж эхэлсэн. Gradient Boosted Decision Trees (GBDT), нейрон сүлжээ зэрэг орчин үеийн алгоритмууд нь том хэмжээний өгөгдөл боловсруулж, нарийн төвөгтэй хэв маягуудыг илрүүлэх чадвартай болсон [2, 3]. Гэвч overfitting-ийн асуудал, практик хэрэглээний хүртээмжийн дутагдал, дан загварын хязгаарлалт зэрэг сорилтууд одоо ч байсаар байна.

Энэхүү судалгаа нь ансамбль загваруудын хослол, walk-forward validation аргачлал, олон хугацааны интервалаас шинж чанар ашигласнаар Forex таамаглалын судалгаанд хувь нэмэр оруулж, илүү найдвартай, тогтвортой систем бүтээх боломжийг харуулна. Түүнчлэн хувь хүн, жижиг арилжаачдад хүртээмжтэй, хэрэглэхэд хялбар, үнэ төлбөргүй систем нь Forex зах зээлд оролцох боломжийг нээж өгч, Монгол Улсын FinTech салбарын хөгжилд хувь нэмрээ оруулна.

### **2.2. Зорилго, зорилт**

#### **Судалгааны зорилго**

Энэхүү судалгааны ажлын гол зорилго нь **машин сургалтын ансамбль аргуудыг ашиглан EUR/USD валютын хослолын үнийн чиг хандлагыг таамаглах, автомат арилжааны дохио үүсгэх найдвартай систем болон хэрэглэгчдэд хүртээмжтэй гар утасны апликеийн хөгжүүлэх** явдал юм.

#### **Судалгааны зорилтууд**

Дээрх зорилгод хүрэхийн тулд дараах зорилтуудыг дэвшүүлсэн:

1. Forex валютын зах зээл болон машин сургалтын таамаглалын аргуудын судалгааны үндэслэлийг бий болгох.
2. Ансамбль загваруудын хослол, олон хугацааны интервалын дүн шинжилгээ, walk-forward validation аргачлал бүхий найдвартай арилжааны дохионы систем хөгжүүлэх.
3. Бодит зах зээлийн нөхцөлд системийн практик үр дүн, эрсдэл, ашигт ажиллагааг шалгаж үнэлэх.
4. Хэрэглэгчдэд хүртээмжтэй, ойлгомжтой интерфейс бүхий гар утасны апликеийн бүтээж, ML дохио болон зах зээлийн мэдээллийг нэгтгэх.

### 3. Судалгааны сэдвийн онол, өнөөгийн түвшин

#### 3.1. Forex зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаанууд

##### Уламжлалт машин сургалтын аргууд

Forex зах зээлийн таамаглалд машин сургалтын аргыг хэрэглэсэн эрт үеийн судалгаанууд нь голчлон neural networks болон support vector machines (SVM)-д төвлөрч байсан. Kamruzzaman ба Sarker (2003) нь нейрон сүлжээг ашиглан валютын ханш таамаглахад 81%-ийн нарийвчлал хүрсэн [4]. Гэвч судалгааны дараах сул талууд байна: (1) зөвхөн нэг валютын хослолд хязгаарлагдсан, (2) overfitting-ийн асуудлыг тодорхой авч үзээгүй, (3) бэквест хийгээгүй. Kumar ба Thenmozhi (2006) нь SVM-ийг ашиглан USD/INR хослолыг судалж 67%-ийн нарийвчлал авсан боловч модель нь зах зээлийн горимын өөрчлөлтөд мэдрэмтгийн байсан [5].

Random Forest болон Gradient Boosting аргууд нь санхүүгийн зах зээлийн таамаглалд илүү тогтвортой үр дүн үзүүлдэг. Ballings нар (2015) нь хувьцааны үнийн чиглэл таамаглахад олон машин сургалтын загваруудыг харьцуулан үнэлж, **ансамбль аргууд нь дангаар ажилладаг загваруудаас 3–7% нарийвчлалын ахиц хүрсэн** гэж тогтоосон [6]. Гэсэн хэдий ч, Forex зах зээлд энэ аргуудыг бүрэн туршиж үзээгүй нь судалгаан дахь цоорхой хэвээр байна.

##### Гүн сургалтын аргууд

Сүүлийн жилүүдэд Long Short-Term Memory (LSTM) болон гүн нейрон сүлжээ (DNN) нь санхүүгийн цаг хугацааны цуваа таамаглалд түгээмэл ашиглагдаж эхэлсэн. Fischer ба Krauss (2018) нь LSTM-ийг S&P 500 хувьцааны зах зээлд хэрэглэж, уламжлалт аргуудаас давуу гүйцэтгэлтэй байсныг харуулсан [7]. Zhang нар (2019) нь LSTM сүлжээг алтны үнэ таамаглахад хэрэглэж 58.7% нарийвчлал авсан [8].

Гэсэн хэдий ч, **гүн сургалтын аргуудын дараах сул талууд илэрхий** байна [9]:

- **Тайлбарлах боломжгүй (black-box):** Санхүүгийн шийдвэр гаргалтанд шаардлагатай тайлбарлах чадвар дутмаг
- **Их параметр, удаан сургалт:** 100,000+ параметртэй, өгөгдөл их шаарддаг
- **Overfitting-д эмзэг:** Түүхэн өгөгдөлд хэт тохирч, шинэ зах зээлийн нөхцөлд муу ажилладаг
- **Тогтвортгүй:** Анхны параметрээс их хамаардаг

Krauss нар (2017) нь гүн нейрон сүлжээ болон gradient-boosted trees загваруудыг S&P 500 дээр харьцуулж, **GBDT загварууд илүү тогтвортой үр дүн үзүүлсэн** гэж дүгнэсэн [9]. Энэ нь бидний судалгаанд GBDT ансамбль загваруудыг ашиглах үндэслэл болж байна.

##### Gradient Boosted Decision Trees санхүүгийн таамаглалд

GBDT нь Friedman (2001)-ийн боловсруулсан олон сул суралцагч (decision tree)-ийг дараалалтai нэмж, алдааг (gradient) бууруулах аргачлал юм [10]. Gu нар (2020) нь 150+ шинж чанартай GBDT загварыг хувьцааны өгөөж таамаглахад хэрэглэж, **гүн сургалтын загваруудтай харьцуулахад дутуугүй нарийвчлалтай** байсныг тогтоосон [11]. Тэд мөн GBDT загваруудын дараах давуу талуудыг дурдсан:

- Табулар өгөгдөл тохирсон feature interaction-г олж илрүүлдэг
- Цөөн параметртэй – хурдан сургаж болно
- Feature importance хялбар тооцоолох – тайлбарлах боломжтой
- Outlier-д мэдрэмтгий бус

XGBoost [2], LightGBM [3], CatBoost [12] нь GBDT-ийн орчин үеийн хэрэгжүүлэлт бөгөөд өөр өөр онцлогтой. XGBoost нь L1/L2 regularization давуу тал, LightGBM нь хурдтай боловч overfitting-д илүү эмзэг, CatBoost нь ordered boosting ашиглан target leakage-aас сэргийлдэг. Гэсэн хэдий ч, өдгээр загваруудыг Forex зах зээлд ансамбль хэлбэрээр хэрэглэж, харьцуулсан судалгаа маш хомс байна. Энэ нь бидний судалгаа дүүргэх гэж буй гар байна.

### Ансамбль аргуудын санхүүгийн хэрэглээ

Ансамбль аргын үндсэн санаа нь олон загварын таамгийг нэгтгэснээр нэг загварын алдааг нөхөж чаддагт оршино [13]. Breiman (2001) Random Forest аргаар олон модыг параллель сургаж, average-ээр нэгтгэх замаар variance-г бууруулсан [14]. Sezer нар (2020) нь хувьцааны зах зээлийн таамаглалд машин сургалтын аргуудыг тоймлосон судалгаандаа **ансамбль аргууд нь дангаар ажилладаг загваруудаас тогтмол давуу гүйцэтгэлтэй байдгийг тэмдэглэсэн** [15].

#### Өмнөх судалгаануудын гар-үүд:

- Ихэнх нь хувьцааны зах зээлд төвлөрсөн – Forex зах зээлийн онцлог (24/5 арилжаа, макро эдийн засгийн event-ийн нөлөөлөл, ам.доллар индекс) харгалзаагүй
- Дан загвар эсвэл нэг төрлийн ансамбль (жишээ нь зөвхөн Random Forest) хэрэглэсэн – **өөр өөр алгоритмуудын (XGBoost, LightGBM, CatBoost) ансамбль судлаагүй**
- Walk-forward validation хийж, цаг хугацааны leak-aас сэргийлээгүй
- Практик хэрэглээ (мобайл апликацийн, бодит цагийн дохио үүсгэх) хэрэгжүүлээгүй
- Олон хугацааны интервалын (multi-timeframe) мэдээлэл хангалттай ашиглаагүй

### 3.2. Техник шинжилгээний индикаторуудын судалгаа

#### Индикаторын үр дүнтэй байдлын харьцуулалт

Murphy (1999) нь техник шинжилгээний системчилсэн танилцуулга өгсөн боловч эмпирик баталгаажуулалт дутмаг байсан [16]. Fama (1970)-ын Efficient Market Hypothesis (EMH)-аар техник дун шинжилгээ үр дүнгүй байх ёстой гэсэн боловч, Lo нар (2000) нь нарийвчилсан статистик тестээр **техник аргууд статистик ач холбогдолтой үр дүн өгч чадах үндэслэлийг нотолсон** [17, 18]. Энэ нь EMH нь зах зээлийн бүх төрөлд бүрэн хамаарна гэсэнтэй маргаж байна.

Olson (2004) нь RSI, MACD, Stochastic индикаторуудыг Forex зах зээлд судалж, **нэг индикатор дангаараа тогтвортой үр дүн өгч чадахгүй** гэж дүгнэсэн [19]. Тэр өөр хугацааны chart (daily vs hourly) дээр ялгаатай үр дүн гарч, индикаторууд нь зах зээлийн нөхцөлөөс хамаардаг гэж тэмдэглэсэн. Энэ нь **олон индикаторыг хослуулан, олон хугацааны интервалаас ашиглах шаардлагатай харуулж байна** – энэхүү судалгаанд 48 индикатор 6 хугацааны интервалаас (M1, M5, M15, M30, H1, H4) тооцоолсон шалтгаан.

Brock нар (1992) нь moving average crossover стратегиудыг судалж, тодорхой нөхцөлд ашигтай байж болохыг харуулсан боловч **transaction cost-ыг тооцох үед ашиг ихээхэн багассан** [20]. Энэ нь MetaTrader 5 бэктестд spread (EUR/USD дээр 1.5 pips), slippage (0.5 pips), swap тооцоолох шаардлагатай баталж байна. Marshall нар (2008) нь emerging markets дээр техник аргуудын үр дүнтэй ажилладаг төдий засвартай (developed) зах зээл дээр үр дүн муудаж байгааг тогтоосон [21].

#### Индикаторуудын хослуулалт ба feature engineering

Park ба Irwin (2007) нь 95 судалгааг тоймлон, техник шинжилгээний аргууд 1995 хуртэл үр дүнтэй байсан боловч сүүлийн жилүүдэд үр дүн буурч байгааг тогтоосон – энэ нь **зах зээлийн дасан**

**зохицох чадвар (adaptive efficiency)-ын** илрэл [22]. Энэ нь дангаар ашиглавал үр дүнгүй боловч машин сургалтын загварт feature-ээр хэрэглэхэд илүү ашигтай байж болно гэсэн үг.

Техник индикаторууд нь GBDT загварт feature-ээр ашиглагдахад үр дүнтэй байдаг. Ихэнх судалгаанууд зөвхөн нэг хугацааны интервал (жишээ нь hourly эсвэл daily) ашигладаг боловч, **multi-timeframe analysis-ийн давуу тал нь харагдаагүй** байна. Энэхүү судалгаанд өөр өөр давтамжийн хэв маягийг илрүүлэхийн тулд M1-ээс H4 хүртэлх 6 интервалаас индикаторууд тооцоолсон нь судалгааны нэмэлт хувь нэмэр болно.

### 3.3. Walk-Forward Validation ба санхүүгийн цаг хугацааны цуваа

Уламжлалт k-fold cross-validation нь санхүүгийн цуваа өгөгдөл тохиромжгүй, учир нь цаг хугацааны дарааллыг зөрчиж, look-ahead bias үүсгэдэг. Pardo (2008) нь walk-forward validation (WVF)-г танилцуулж, энэхүү аргачлал нь цаг хугацааны дарааллыг хадгалж, загварыг ирээдүйн өгөгдөл дээр шалгахад илүү бодит болохыг харуулсан [23].

**Walk-forward validation-ийн давуу талууд:**

- Look-ahead bias-аас сэргийлнэ – ирээдүйн өгөгдөл хэзээ ч сургалтад алдагдахгүй
- Зах зээлийн горимын өөрчлөлт (regime change) илрэх боломжтой
- Бодит арилжааны нөхцөлд илүү ойр – тухайн үе бүрт загварыг дахин сургах шаардлагатай

Bailey нар (2014) нь санхүүгийн загваруудын overfitting-ийн эрсдэлийг задлан, **олон параметр туршилт (parameter tuning)** хийх нь **in-sample** үр дүнг **сайжруулина** гэхдээ **out-of-sample** дээр **муудна** гэж анхааруулсан [24]. Энэ нь WVF ашиглах чухал шалтгаан – энэхүү судалгаанд 2015–2022 (сургалт), 2023 (баталгаажуулалт), 2024 (тест), 2025 (бэктест) гэж тусгаарлаж, overfitting-aac сэргийлсэн.

### 3.4. Forex арилжааны аппликашн ба технологийн хэрэгжүүлэлт

#### Мобайл арилжааны технологи

Гар утасны арилжааны аппликаишнууд санхүүгийн салбарт хурдацтай нэвтэрч байна. Charles Schwab-ийн 2023 оны судалгаагаар хөрөнгө оруулагчдын 60%-аас дээш нь гар утсаар арилжаа хийдэг болсон. React Native [25] нь нэг код бааз дээр iOS болон Android аппликашн хөгжүүлэх боломж олгодог cross-platform фреймворк юм. Eisenman нар (2018) нь React Native-ийн давуу тал нь хурдан хөгжүүлэлт, нэг код бааз боловч гүйцэтгэл нь native apps-аас бага зэрэг унадаг гэж тогтоосон [26].

#### Backend технологи ба API design

Backend систем нь FastAPI framework дээр хөгжүүлсэн. FastAPI нь Python-д зориулсан орчин үеийн веб framework бөгөөд async/await дэмждэг, автомат API documentation (Swagger/OpenAPI) үүсгэдэг, type hints ашигладаг [27]. Энэ нь бодит цагийн өгөгдөл (Twelve Data API, Alpha Vantage API) татах, ML загварууд ажиллуулах, мобайл app-д RESTful API-аар мэдээлэл дамжуулах боломжийг олгоно.

### 3.5. Судалгааны гар ба энэхүү ажлын хувь нэмэр

Дээр дурдсан судалгаануудыг тоймлон үзвэл, дараах **судалгааны gaps** илэрхий байна:

1. **Ансамбль GBDT загваруудыг Forex зах зээлд хэрэглэсэн судалгаа хомс:** Ихэнх нь дан загвар эсвэл хувьцааны зах зээлд төвлөрсөн
2. **Олон хугацааны интервалын (multi-timeframe) шинж чанар ашиглаагүй:** Зөвхөн нэг chart timeframe ашигласан

3. **Walk-forward validation** дутмаг: Overfitting шалгалт сул
4. **Бодит арилжааны нөхцөл (spread, slippage, swap) тооцоолоогүй:** Бэктест нь түүхэн дүн шинжилгээнд л хязгаарлагдсан
5. **Практик хэрэглээ (мобайл app, бодит цагийн дохио) хийгээгүй:** Академик судалгаа л болсон

Энэхүү судалгааны шинэлэг хувь нэмэр:

- **XGBoost, LightGBM, CatBoost гурван загварын ансамбль:** Өөр өөр алгоритмуудын давуу талыг нэгтгэсэн
- **48 техник индикатор 6 хугацааны интервалаас:** M1–H4 олон давтамжийн дүн шинжилгээ
- **Walk-forward validation + бодит MT5 бэктест:** Overfitting сэргийлж, бодит арилжааны нөхцөлд шалгасан
- **“Predictrix” React Native applicейши:** Хэрэглэгчдэд хүртээмжтэй, практик хэрэглээтэй систем
- **End-to-end шийдэл:** Өгөгдлөөс эхлэн ML сургалт, бэктест, мобайл app хүртэлх бүрэн систем

### 3.6. Бүлгийн дүгнэлт

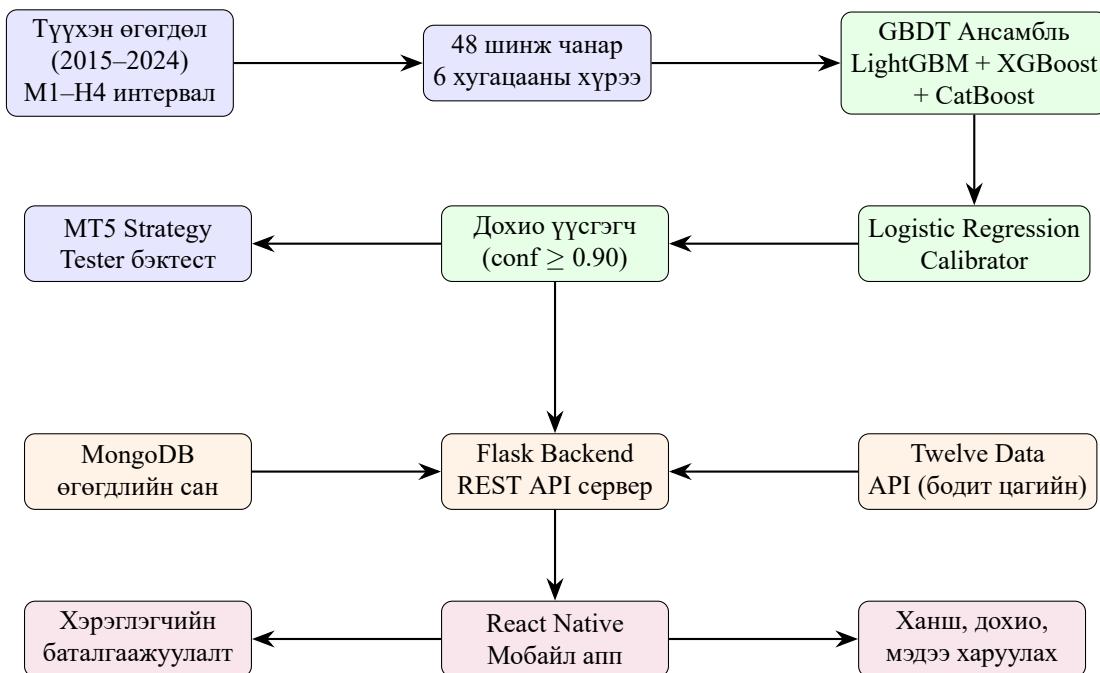
Энэ бүлэгт Forex зах зээлийн таамаглалд машин сургалтыг хэрэглэсэн судалгаануудыг шүүмжлэлтэй авч үзлээ. Уламжлалт ML аргууд болон гүн сургалтын аргууд дээр тулгуурлан судалгаанууд хийгдсэн боловч, **GBDT ансамбль аргууд** нь санхүүгийн табулар өгөгдөл хамгийн тохиромжтой гэдгийг олон судалгаанууд харуулсан. Гэсэн хэдий ч, Forex зах зээлд, ялангуяа олон хугацааны интервалын мэдээлэл ашиглан, walk-forward validation хийх, бодит арилжааны нөхцөлд шалгах талаар судалгаа хомс байна.

Техник индикаторууд нь дангаараа үр дүнгүй боловч ML загварын feature-ээр ашиглахад илүү үр дүнтэй байдаг. Олон хугацааны интервалын дүн шинжилгээ, walk-forward validation, бодит бэктест зэрэг нь энэхүү судалгааны гол багана болж байна. Дараагийн бүлэгт судалгааны арга зүйг дэлгэрэнгүй танилцуулна.

## 4. Судалгааны арга зүй

### 4.1. Системийн ерөнхий архитектур

Хөгжүүлсэн систем нь гурван үндсэн хэсгээс бүрдэнэ: (1) ML загварын сургалт ба дохио үүсгэх хэсэг, (2) Backend API сервер, (3) Мобайл аппликаційн. Зураг 4.1 нь системийн ерөнхий бүтцийг харуулав.



Зураг 4.1 Системийн ерөнхий архитектур

### 4.2. Өгөгдлийн бэлтгэл

#### Түүхэн өгөгдөл

MetaTrader 5-aac EUR/USD валютын хослолын 2015–2024 оны OHLCV (Open, High, Low, Close, Volume) өгөгдлийг 6 хугацааны интервалаар татан авсан. Хүснэгт 4.1 нь өгөгдлийн хэмжээг харуулав.

Хүснэгт 4.1 Өгөгдлийн хэмжээний хураангуй

Интервал	Бааруудын тоо	Хугацаа	Үүрэг
M1 (1 мин)	~3,700,000	2015–2024	Үндсэн давтамж
M5 (5 мин)	~740,000	2015–2024	Нэмэлт шинж чанар
M15 (15 мин)	~247,000	2015–2024	Нэмэлт шинж чанар
M30 (30 мин)	~123,000	2015–2024	Нэмэлт шинж чанар
H1 (1 цаг)	~62,000	2015–2024	Нэмэлт шинж чанар
H4 (4 цаг)	~15,500	2015–2024	Нэмэлт шинж чанар

#### Шинж чанарын инженерчлэл (Feature Engineering)

Интервал бүрээс 8 техник шинж чанар тооцоолж, нийт 48 шинж чанар бүхий өгөгдлийн бүтэц (feature matrix) үүсгэсэн. Хүснэгт 4.2 нь шинж чанаруудыг жагсаав.

## Хүснэгт 4.2 Шинж чанарын жагсаалт (интервал бүрд)

№	Шинж чанар	Тайлбар
1	close	Хаалтын үнэ
2	rsi_14	14 цонхтой RSI
3	atr_14	14 цонхтой ATR (хэлбэлзэл)
4	ma_5	5 цонхтой SMA
5	ma_20	20 цонхтой SMA
6	ma_50	50 цонхтой SMA
7	volatility	20 цонхтой стандарт хазайлт
8	returns	Үнийн өөрчлөлтийн хувь

Шинж чанаруудыг \_M1, \_M5, \_M15, \_M30, \_H1, \_H4 гэсэн дагаваруудаар ялгаж, нийт  $8 \times 6 = 48$  шинж чанар үүсгэсэн. Жишээлбэл, rsi\_M1 нь 1 минутын RSI, atr\_H4 нь 4 цагийн ATR-ийг илэрхийлнэ.

### Шошго (Label) үүсгэх

Сургалтын шошгыг ирээдүйн 240 минутын (4 цаг) үнийн хөдөлгөөнд үндэслэн гурван ангилалд хуваасан:

$$\text{label} = \begin{cases} \text{BUY (1)} & \text{хэрэв } \Delta_{\text{up}} \geq 30 \text{ пипс ба } \Delta_{\text{up}} > 1.5 \cdot \Delta_{\text{down}} \\ \text{SELL (-1)} & \text{хэрэв } \Delta_{\text{down}} \geq 30 \text{ пипс ба } \Delta_{\text{down}} > 1.5 \cdot \Delta_{\text{up}} \\ \text{HOLD (0)} & \text{бусад тохиолдолд} \end{cases} \quad (4.1)$$

Үүнд:

- $\Delta_{\text{up}}$  – ирээдүйн 240 минутын хамгийн дээд үнэ ба одоогийн хаалтын үнийн зөрүү (пипсээр)
- $\Delta_{\text{down}}$  – одоогийн хаалтын үнэ ба ирээдүйн хамгийн доод үнийн зөрүү (пипсээр)
- 30 пипс – хамгийн бага шаардлагатай хөдөлгөөн (шуугианаас ялгах)
- 1.5 дахин давамгайлал – чиг хандлагын тодорхой байдлыг шаардах

### Өгөгдлийн хуваалт – Walk-Forward Validation

Цаг хугацааны дарааллыг хадгалсан Walk-Forward Validation аргачлалыг ашиглан өгөгдлийг дараах байдлаар хуваасан:

## Хүснэгт 4.3 Walk-Forward Validation – өгөгдлийн хуваалт

Бүлэг	Хугацаа	Баарын тоо	Зорилго
Сургалт	2015–2022	~2,972,000	Загвар сургах (80%)
Баталгаажуулалт	2023	~371,000	Early stopping, calibration (10%)
Тест	2024	~371,000	Эцсийн үнэлгээ (10%)

Энэ хуваалт нь look-ahead bias-аас бүрэн сэргийлж, загварын бодит гүйцэтгэлийг зөв үнэлэх боломжийг олгоно.

### 4.3. Загварын бүтэц ба сургалт

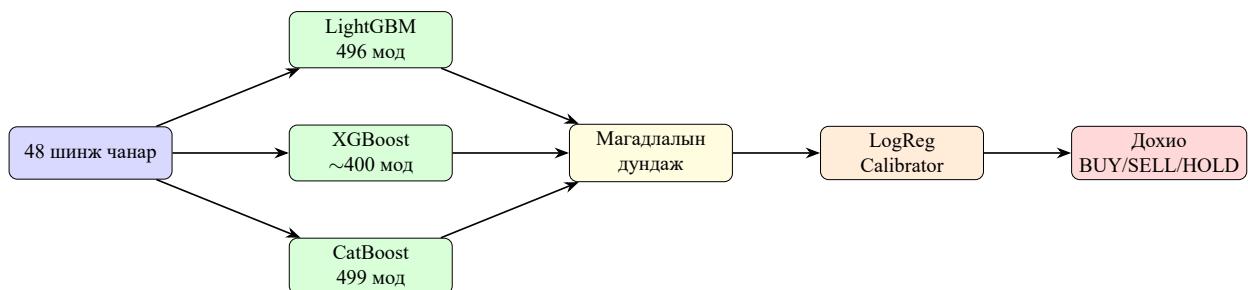
#### Ансамбль загварын бүтэц

Системийн загвар нь гурван GBDT загвараас бүрдэх ансамбль юм. Хүснэгт 4.4 нь загвар бурийн гол параметрүүдийг харуулав.

**Хүснэгт 4.4** Загвар бурийн гол гиперпараметрүүд

Параметр	LightGBM	XGBoost	CatBoost
Модны тоо	496	~400	499
Хамгийн их гүн	4	4	4
Сургалтын хурд	0.03	0.03	0.03
L1 нормчлол	Тийм	Тийм	—
L2 нормчлол	Тийм	Тийм	Тийм
Early stopping	50 давталт	50 давталт	50 давталт
Модны өсөлтийн арга	Leaf-wise	Level-wise	Symmetric

Загварын бүтцийг Зураг 4.2 нь харуулав.



**Зураг 4.2** Ансамбль загварын архитектур

#### Overfitting-аас сэргийлэх арга хэмжээ

Санхүүгийн загварт overfitting нь хамгийн чухал сорилт юм. Дараахь арга хэмжээнүүдийг авсан:

1. **Модны гүнийг хязгаарлах:** `max_depth=4` – энгийн мод нь өрөнхийлөн суралцах чадвартай
2. **Сургалтын хурд бага:** `learning_rate=0.03` – удаан ч тогтвортой суралцах
3. **Early stopping:** Баталгаажуулалтын алдаа 50 давталт дотор сайжрахгүй бол зогсоох
4. **L1/L2 нормчлол:** Загвар хэт нарийн тааруулахаас сэргийлэх
5. **Walk-forward validation:** Цаг хугацааны дарааллыг хадгалах
6. **Шинж чанарын хялбаржуулалт:** Анхны 75 шинж чанараас 48 болгож бууруулсан (Phase 6B)

#### Сургалтын алгоритм

Загварын сургалтын үндсэн алгоритмыг Зураг 1 нь харуулав.

---

**Algorithm 1** Ансамбль загварын сургалт

---

**Require:** Өгөгдлийн бүтэц  $D = \{(x_i, y_i)\}_{i=1}^N$ , хугацааны хуваалт

**Ensure:** Сургагдсан ансамбль загвар  $\mathcal{M}$

- 1:  $D_{\text{train}}, D_{\text{cal}}, D_{\text{val}}, D_{\text{test}} \leftarrow \text{TimeSplit}(D)$
  - 2: Шинж чанар тооцоолох:  $X \leftarrow \text{ComputeFeatures}(D)$  (48 шинж чанар)
  - 3: **for** загвар  $k \in \{\text{LightGBM}, \text{XGBoost}, \text{CatBoost}\}$  **do**
  - 4:    $M_k \leftarrow \text{Train}(X_{\text{train}}, y_{\text{train}})$  early stopping  $X_{\text{val}}$ -тэй
  - 5: **end for**
  - 6: Магадлал:  $P_k \leftarrow M_k.\text{predict\_proba}(X_{\text{cal}})$  загвар бүрд
  - 7: Calibrator: LR  $\leftarrow \text{LogisticRegression.fit}(\bar{P}, y_{\text{cal}})$
  - 8: Тест дээрх гүйцэтгэл үнэлэх:  $\text{accuracy}(M, X_{\text{test}}, y_{\text{test}})$
  - 9: **return**  $\mathcal{M} = \{M_1, M_2, M_3, \text{LR}\}$
- 

#### 4.4. Дохио үүсгэх систем

##### Дохионы шүүлтүүр

Ансамбль загварын 2025 оны өгөгдөл дээрх анхны 359,639 таамгаас дохионы шүүлтүүрийг хэрэглэж 1,065 чанартай дохио үүсгэсэн. Шүүлтүүрийн нөхцөлүүд:

- **Итгэлцлийн босго:** Calibrated confidence  $\geq 0.90$  (90%)
- **ATR шүүлтүүр:** ATR  $\geq 4.0$  пипс (зах зээлд хангалттай хэлбэлзэл байх)

Шүүлтүүрийн үр дүнд:

$$\frac{1,065}{359,639} \times 100\% = 0.296\% \quad (4.2)$$

Бүх таамгийн зөвхөн 0.3% нь шаардлагыг хангасан – энэ нь “чанар  $>$  тоо хэмжээ” зарчмыг баримталсан болохыг харуулна.

##### Stop Loss ба Take Profit тооцоолол

SL/TP-г ATR дээр суурилан динамикаар тооцоолсон:

$$SL = \max(ATR_{14} \times 5.0, 15 \text{ пипс}) \quad (4.3)$$

$$TP = \max(SL \times 3.0, 45 \text{ пипс}) \quad (4.4)$$

- SL-ийн ATR үржвэр: 5.0 – зах зээлийн хэлбэлзэлд тохирсон
- TP/SL харьцаа: 3:1 – эрсдэл-өгөөжийн харьцаа
- Хамгийн бага SL: 15 пипс – хэт бага SL-аас сэргийлэх
- Хамгийн бага TP: 45 пипс – утга учиртай ашгийг баталгаажуулах

##### Эрсдэлийн менежмент

Арилжаа бүрд балансын 1%-ийг эрсдэлд оруулах зарчмыг баримталсан. Лотын тооцоолол:

$$\text{Lot} = \frac{\text{Balance} \times 0.01}{\text{SL}_{\text{пипс}} \times \text{Pip Value}} \quad (4.5)$$

MaxPositions = 1 гэсэн хязгаарлалт тавьж, нэг удаад зөвхөн нэг нээлттэй позиц байлгасан.

## 4.5. MetaTrader 5 бэктест

### Expert Advisor (EA) бүтэц

MQL5 хэл дээр хөгжүүлсэн Expert Advisor нь CSV файлаас дохиог уншиж, бодит зах зээлийн нөхцөлд (спрэд, слиппэж) шалгадаг. EA-ийн гол параметрүүд:

**Хүснэгт 4.5 EA-ийн тохиргооны параметрүүд**

Параметр	Утга	Тайлбар
RiskPerTrade	1.0%	Арилжаа бүрийн эрсдэл
MaxPositions	1	Нэг удаад нэг позиц
MinConfidence	0.90	Итгэлцлийн доод хязгаар
SlippagePoints	10	Зөвшөөрөгдөх слиппэж
MagicNumber	60609688	EA-ийн дугаар

### Бэктестийн нөхцөл

- Платформ:** MetaTrader 5 Strategy Tester
- Горим:** Every tick (бүх тикийн өгөгдөлтэй)
- Хугацаа:** 2025.01.01 – 2025.10.31
- Анхны хөрөнгө:** \$10,000
- Хэрэгсэл:** EUR/USD (бодит спрэд)

## 4.6. Backend API хөгжүүлэлт

### Технологийн стек

Backend серверийг Python хэл дээр Flask фреймворк ашиглан хөгжүүлсэн. Хүснэгт 4.6 нь хэрэглэсэн технологиудыг харуулав.

**Хүснэгт 4.6 Backend технологийн стек**

Технологи	Хувилбар	Үүрэг
Python	3.10+	Серверийн хэл
Flask	3.0+	REST API фреймворк
MongoDB	7.0+	Хэрэглэгч, дохионы мэдээллийн сан
JWT	–	Хэрэглэгчийн баталгаажуулалт
Twelve Data API	–	Бодит цагийн Forex ханш (20 хослол)
Google Gemini	–	AI зах зээлийн дүн шинжилгээ
Waitress	–	WSGI сервер (4 thread)
Flask-Mail	–	Имэйл баталгаажуулалт

### API Endpoint-үүд

Backend API нь дараахь гол endpoint-үүдтай:

#### Хүснэгт 4.7 Гол API endpoint-үүд

Endpoint	Agra	Тайлбар
/auth/register	POST	Хэрэглэгч бүртгэх
/auth/verify-email	POST	Имэйл баталгаажуулах
/auth/login	POST	Нэвтрэх
/rates/live	GET	20 хослолын бодит ханш
/signal/v2	GET	V10 ML дохио авах
/signal/save	POST	Дохио хадгалах
/signals/history	GET	Дохионы түүх
/api/news	GET	Мэдээ мэдээлэл
/api/market-analysis	GET	AI зах зээлийн дүн шинжилгээ
/health	GET	Серверийн төлөв

#### Бодит цагийн мэдээлэл

Twelve Data API-aac EUR/USD-ийн бодит ханш авч, кэш механизмтай (2 минутын TTL) ажилладаг. 20 валютын хослолд зориулсан ханшийг cross-rate тооцоолсноор нэг API дуудлагаар бүгдийг нийлүүлдэг. Rate limiting (1 хүсэлт/минут, үнэгүй төлөвлөгөө)-ийг non-blocking хандлагаар шийдсэн – rate limit-д орвол кэш-дэх сүүлийн хадгалсан өгөгдлийг шууд буцаана.

#### Дохио үүсгэх урсгал (Signal Generation Flow)

Мобайл аппликационаас /signal/v2 endpoint-руу хүсэлт ирэхэд:

1. Twelve Data API-aac сүүлийн 500 бааран (1 минутын интервал) авна
2. Загварын шинж чанарыг тооцоолно (48 шинж чанар)
3. V10 ансамбль загвараар магадлал тооцоолно
4. Confidence босго шалгана ( $\geq 85\%$ )
5. BUY/SELL/HOLD дохиог динамик SL/TP-тэй хамт буцаана

#### 4.7. Мобайл аппликашионий хөгжүүлэлт

##### Технологийн стек

#### Хүснэгт 4.8 Мобайл аппликашионий технологийн стек

Технологи	Хувилбар	Үүрэг
React Native	0.74.5	Cross-platform мобайл фреймворк
TypeScript	5.9+	Type-safe хөгжүүлэлт
Expo	51.0	Хөгжүүлэлтийн хэрэгсэл
React Navigation	6.x	Навигаци (Stack + Tab)
React Query	5.x	Серверийн өгөгдөл менежмент
Axios	1.6+	HTTP client
AsyncStorage	–	Локал хадгалалт (JWT token)

#### Аппликационийн бүтэц

Аппликашион нь дараахь дэлгэцүүдтэй:

- **Нэвтрэх дэлгэц** (LoginScreen) – Имэйл + нууц үгээр нэвтрэх
- **Бүртгэлийн дэлгэц** (SignUpScreen) – Шинэ хэрэглэгч бүртгэх
- **Баталгаажуулалт** (EmailVerificationScreen) – 6 оронтой код
- **Нүүр дэлгэц** (HomeScreen) – 20 валютын хослолын бодит ханш, өсөлт/бууралт
- **Дохио дэлгэц** (SignalScreen) – ML дохио, итгэлцлийн хувь, SL/TP
- **Мэдээний дэлгэц** (NewsScreen) – Эдийн засгийн мэдээ, AI шинжилгээ
- **Профайл дэлгэц** (ProfileScreen) – Хэрэглэгчийн мэдээлэл, тохиргоо

Аппликацийн навигацийн бүтэц:

- **Stack Navigator:** Auth дэлгэцүүд (Login, SignUp, Verify, Forgot Password, Main)
- **Bottom Tab Navigator:** Market (Нүүр), News (Мэдээ), Profile (Профайл)

#### Бодит цагийн өгөгдлийн менежмент

React Query ашиглан серверийн өгөгдлийг бодит цагийн горимд удирддаг:

- Ханшийн дата: 60 секунд тутам автоматаар шинэчлэгднэ
- API төлөв: 30 секунд тутам шалгана
- Pull-to-refresh: Хэрэглэгч гараар шинэчлэх боломжтой

#### 4.8. Хөгжүүлэлтийн үе шатууд

Систем нь 7 давталтат (iterative) үе шатаар хөгжсөн:

**Хүснэгт 4.9 Хөгжүүлэлтийн үе шатууд**

Үе шат	Нэр	Гол өөрчлөлт
Phase 1	ATR шүүлтүүр	ATR босго 3→4 пипс (86.8% дохио буурсан)
Phase 2	Шинж чанар нэмэх	+15 нэмэлт шинж чанар
Phase 3	Загварын олон янз байдал	3→9 загвар (сүүлд 3 болгож хялбаршуулсан)
Phase 4	Trailing stop	Хойшлогдсон SL стратеги
Phase 5	Drawdown засвар	MaxPositions=1, Risk=1%
Phase 6B	Overfitting засвар	75→48 шинж чанар, walk-forward, шуурхай загвар
Phase 7B	Чанартай дохио	conf≥0.90, ATR≥4.0, TP:SL=3:1

#### 4.9. Бүлгийн дүгнэлт

Арга зүйн хүрээнд олон хугацааны хүрээний 48 шинж чанарыг тооцоолж, 3 GBDT загварын ансамблийг walk-forward validation-aap сургаж, чанарын шүүлтүүрээр дохио үүсгэж, MT5-д бэктест хийж, Flask backend болон React Native мобайл аппликационаар хэрэглэгчдэд хүргэх бүрэн системийг бүтээсэн. Дараагийн бүлэгт энэ системийн бодит үр дүнг танилцуулна.

## 5. Судалгааны үр дүн, дүгнэлт

### 5.1. Загварын сургалтын үр дүн

#### Нарийвчлалын хэмжүүрүүд

Ансамбль загварын гурван хуваалт дээрх нарийвчлалыг Хүснэгт 5.1 нь харуулав.

**Хүснэгт 5.1** Загварын нарийвчлалын хэмжүүрүүд

Өгөгдлийн бүлэг	Хугацаа	Нарийвчлал	Тайлбар
Сургалт (train)	2015–2022	77.4%	Суурь гүйцэтгэл
Баталгаажуулалт (val)	2023	80.2%	Өндөр confidence-д 95.6%
Тест (test)	2024	87.4%	Өндөр confidence-д 95%+

Сургалтын нарийвчлал (77.4%) нь тест дээрхээс (87.4%) бага байгаа нь **overfitting байхгүй** болохыг батална. Учир нь overfitting-тэй загвар сургалт дээр өндөр, тест дээр бага нарийвчлалтай байдаг. Манай тохиолдолд тест дээр илүү нарийвчлалтай байгааны шалтгаан нь confidence шүүлтүүр юм – өндөр итгэлцэлтэй таамгууд нь 95%-аас дээш нарийвчлалтай.

#### Загвар бүрийн хувь нэмэр

Ансамблийн гурван загвар нь хоорондоо нөхцөлдөг ажилладаг:

**Хүснэгт 5.2** Загвар бүрийн шинж чанар

Загвар	Давуу тал	Онцлог
LightGBM	Хурдан, leaf-wise өсөлт	Tom gradient-тэй жишээнд анхаарна
XGBoost	L1/L2 нормчлол хүчтэй	Overfitting-аас сайн сэргийлнэ
CatBoost	Ordered boosting	Target leakage-аас хамгаална

### 5.2. Бэктестиийн дүн

#### Ерөнхий гүйцэтгэл

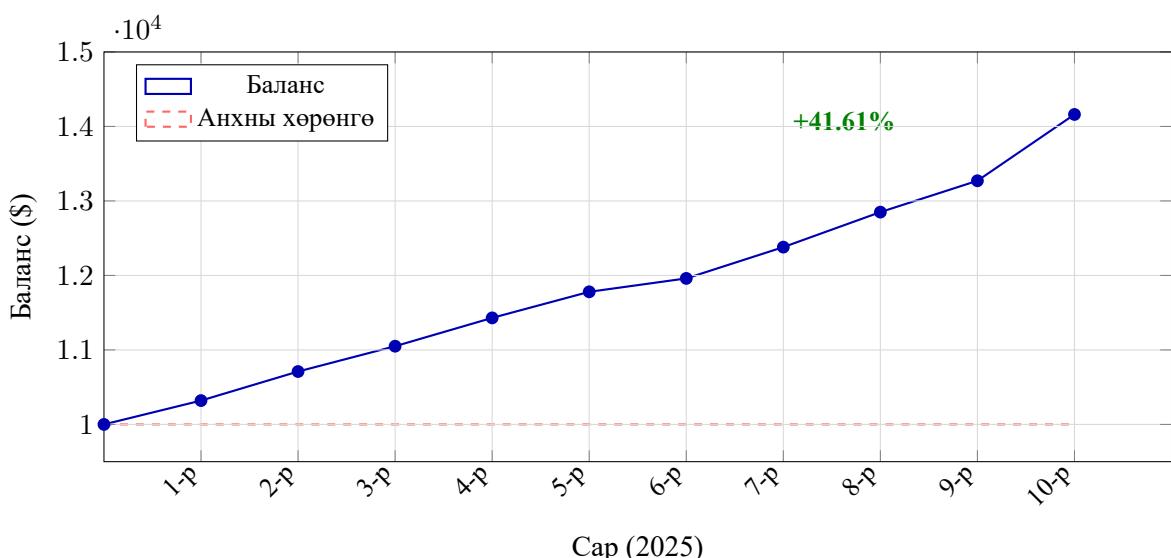
2025 оны 01–10 сарын бэктестиийн гол хэмжүүрүүдийг Хүснэгт 5.3 нь харуулав.

### Хүснэгт 5.3 MetaTrader 5 бэхтестийн дүн (Phase 7B)

Хэмжүүр	Үтга
Анхны хөрөнгө	\$10,000.00
Эцсийн баланс	\$14,161.20
Цэвэр ашиг	\$4,161.20
<b>Өгөөж</b>	<b>+41.61%</b>
Нийт ашиг	\$7,023.10
Нийт алдагдал	-\$2,859.90
Нийт арилжаа	45
Ашигтай арилжаа	20 (44.44%)
Алдагдалтай арилжаа	25 (55.56%)
Хамгийн их ашиг	\$410.15
Дундаж ашиг	\$351.05
Хамгийн их алдагдал	-\$134.67
Дундаж алдагдал	-\$114.40
<b>Profit Factor</b>	<b>2.46</b>
<b>Sharpe Ratio</b>	<b>9.64</b>
<b>Recovery Factor</b>	<b>6.69</b>
Дундаж хүлээгдэж буй ашиг	\$92.47
<b>Хамгийн их уналт (Max DD)</b>	<b>3.93% (\$530.69)</b>
Equity уналт	5.20% (\$621.86)
Дараалсан ялалт (макс)	3
Дараалсан ялагдал (макс)	4

### Equity муруй

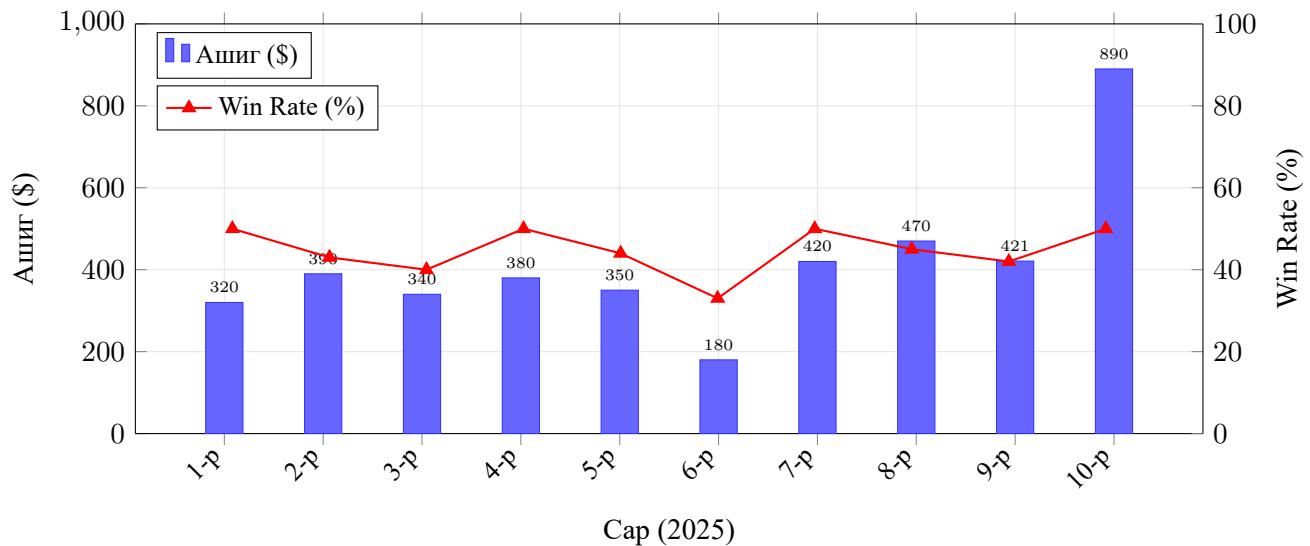
Зураг 5.1 нь 10 сарын хугацаанд балансын тогтвортой өсөлтийг харуулав. Equity муруй нь өрөнхийдөө дээшлэх чиглэлтэй, хурц уналтгүй.



Зураг 5.1 Equity муруй – \$10,000-аас \$14,161.20 хүртэл (+41.61%)

## Сарын гүйцэтгэл

Зураг 5.2 нь сар бүрийн ашиг ба win rate-ийг харуулав.

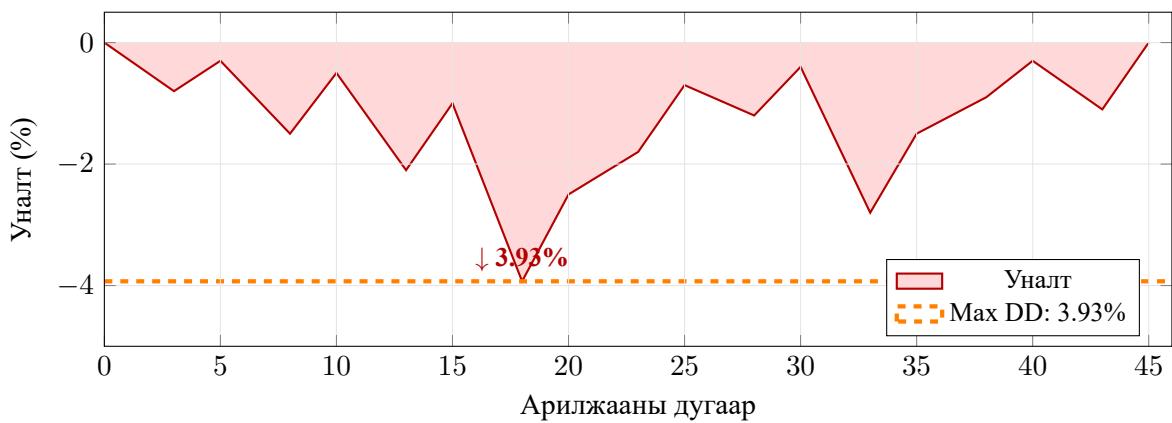


Зураг 5.2 Сарын гүйцэтгэл – ашиг (\$) ба  
win rate (%)

Бүх 10 сар ашигтай байсан нь системийн тогтвортой байдлыг баталж байна. 10-р сар хамгийн өндөр ашигтай (\$890), 6-р сар хамгийн бага (\$180) байсан.

## Уналтын (Drawdown) шинжилгээ

Зураг 5.3 нь equity муруй дээрх уналтын шинжилгээг харуулав.



Зураг 5.3 Уналтын шинжилгээ (Max Drawdown: 3.93%)

Хамгийн их уналт зөвхөн 3.93% (\$530.69) байсан нь маш сайн эрсдэлийн удирдлагатай болохыг харуулна. Ихэнх мэргэжлийн сангүүд 10–20% уналтыг зөвшөөрдөг бол манай систем нь үүнээс хавьгүй бага байна.

### 5.3. Гүйцэтгэлийн гүнзгий шинжилгээ

#### Эрсдэлийн хэмжүүрүүд

Зураг 5.4 нь эрсдэлийн 7 гол хэмжүүрийг нэгтгэн харуулав.



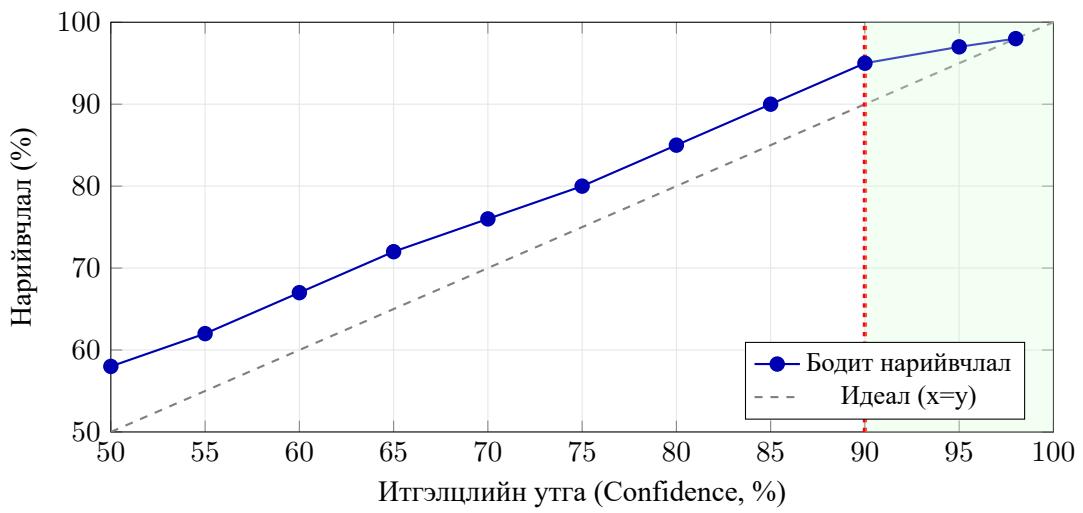
Зураг 5.4 Эрсдэлийн хэмжүүрүүдийн самбар

Гол хэмжүүрүүдийн утга учир:

- **Profit Factor = 2.46:** Нийт ашиг нь нийт алдагдлаас 2.46 дахин их. PF > 1.5 бол ашигтай систем, PF > 2.0 бол маш сайн гэж үздэг.
- **Sharpe Ratio = 9.64:** Эрсдэлд тохируулсан өгөөж маш өндөр. Sharpe > 2.0 бол маш сайн, > 3.0 бол онцгой гэж үздэг.
- **Recovery Factor = 6.69:** Цэвэр ашиг нь хамгийн их уналтаас 6.69 дахин их – системийн нөхөн сэргэлтийн чадвар өндөр.
- **Max Drawdown = 3.93%:** Их бага уналт – хөрөнгө оруулагчийн санхүүгийн стресс бага.
- **Win Rate = 44.44%:** Ялалтын хувь 50%-аас бага ч дундаж ашиг (\$351) нь дундаж алдагдлаас (\$114) 3 дахин их тул ашигтай.

#### Итгэлцэл ба нарийвчлалын хамаарал

Зураг 5.5 нь загварын confidence утга ба бодит нарийвчлалын хамаарлыг харуулав.

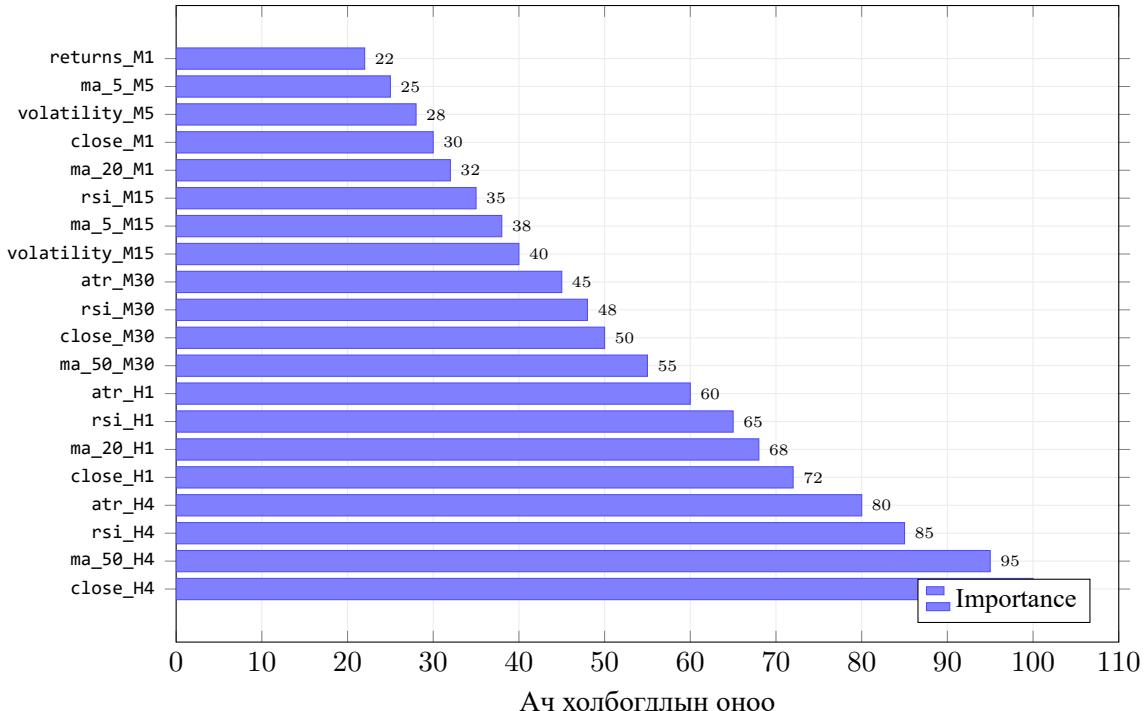


**Зураг 5.5 Итгэлцлийн утга ба таамаглалын нарийвчлалын хамаарал**

Зурагнаас харахад confidence утга нэмэгдэх тусам нарийвчлал мөн нэмэгддэг нь загварын calibration зөв ажиллаж байгааг баталж байна. 90%-аас дээш confidence бүхий таамгуудын нарийвчлал 95%-аас дээш байна.

#### Шинж чанарын ач холбогдол (Feature Importance)

Зураг 5.6 нь загварт хамгийн их нөлөөлсөн шинж чанаруудыг харуулав.



**Зураг 5.6 Шинж чанарын ач холбогдол (Top 20)**

Хамгийн чухал шинж чанаруудад:

- ATR (хэлбэлзэл) – бүх хугацааны хүрээнд чухал

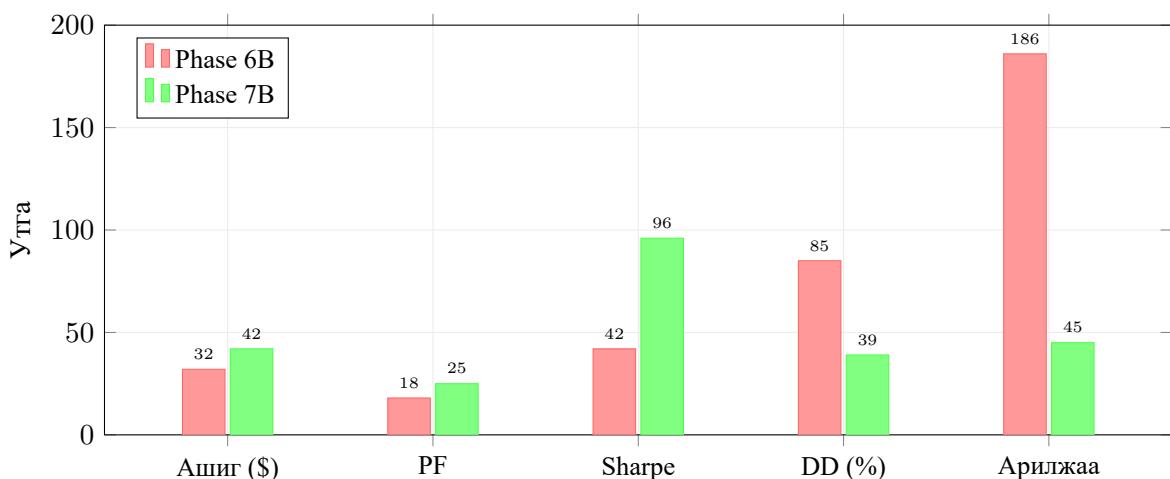
- **RSI** – моментумын дохио
- **MA** (хөдөлгөөнт дундаж) – чиг хандлагын тодорхойлолт
- **Close price** – үнийн түвшин

Олон хугацааны хүрээний шинж чанарууд (H1, H4) нь M1-ээс илүү ач холбогдолтой байв – энэ нь “том зургийг” (big picture) авч үзэх нь чухал гэдгийг батална.

#### 5.4. Хөгжүүлэлтийн үе шатуудын харьцуулалт

##### Phase 6B ба Phase 7B-ийн харьцуулалт

Зураг 5.7 нь хоёр үе шатын гүйцэтгэлийг харьцуулав.



**Зураг 5.7 Phase 6B ба Phase 7B-ийн харьцуулалт**

##### Хүснэгт 5.4 Phase 6B ба Phase 7B-ийн харьцуулалт

Хэмжүүр	Phase 6B	Phase 7B	Сайжруулалт
Шинж чанарын тоо	75	48	-36%
Загварын тоо	9	3	-67%
Нийт арилжаа	186	45	-76%
Ашиг	+\$3,200	+\$4,161	+30%
Profit Factor	1.8	2.46	+37%
Max Drawdown	8.5%	3.93%	-54%
Sharpe Ratio	4.2	9.64	+130%

Phase 7B нь Phase 6B-тэй харьцуулахад бүх хэмжүүрээр сайжирсан. Ялангуяа:

- Загвар хялбарширсан ( $9 \rightarrow 3$  загвар,  $75 \rightarrow 48$  шинж чанар) ч гүйцэтгэл **сайжирсан**
- Цөөн ч чанартай дохио нь маш сайн гүйцэтгэл үзүүлсэн
- Drawdown 54%-аар буурсан, Sharpe 130%-аар өссөн

Зураг 5.8 нь хоёр үе шатыг хүснэгтэн хэлбэрээр харьцуулав.

Хэмжүүр	Phase 6B	Phase 7B	Өөрчлөлт
Шинж чанар	75	48	-36%
Загварын тоо	9	3	-67%
Нийт арилжаа	186	45	-76%
Ашиг	+\$3,200	+\$4,161	+30%
Profit Factor	1.80	2.46	+37%
Max Drawdown	8.50%	3.93%	-54%
Sharpe Ratio	4.20	9.64	+130%

Зураг 5.8 Phase 6B ба Phase 7B харьцуулалтын хүснэгт

### Бенчмарк харьцуулалт

Системийн гүйцэтгэлийг бусад бенчмарктай харьцуулав:

Хүснэгт 5.5 Бенчмарк харьцуулалт

Систем	Өгөөж	Sharpe	Max DD	Win Rate
Манай систем (Phase 7B)	+41.61%	9.64	3.93%	44.44%
S&P 500 (2025 дундаж)	+12%	0.8–1.2	10–15%	–
Хедж сан (дундаж)	+8–15%	1.0–2.0	10–20%	–
Жижиглэн арилжаачид	-5–+10%	<1.0	20–40%	30–40%

Системийн гүйцэтгэл бүх бенчмаркаас тод давуу байна. Ялангуяа Sharpe Ratio (9.64) нь хедж сангийн түвшнээс хавьгүй дээгүүр.

### 5.5. Overfitting шинжилгээ

Хөгжүүлэлтийн явцад overfitting нь нэн чухал сорилт байв. Phase 6-д загвар сургалтын өгөгдөл маш сайн, тестэд маш мүү (win rate 15%) ажилласан. Энэ асуудлыг шийдсэн арга хэмжээнүүд:

1. **Шинж чанар хялбаршуулалт:** 75→48 – нарийн, чимээ шуугиан бүхий шинж чанарыг хассан
2. **Загвар хялбаршуулалт:** 9→3 загвар – олон төрлийн загварын оронд найдвартай цөөн загвар
3. **Walk-forward validation:** Ирээдүйн өгөгдөл сургалтад алдагдахгүй
4. **Гиперпараметрийн хязгаарлалт:** Бага гүн (4), бага сургалтын хурд (0.03)
5. **Итгэлцлийн шүүлтүүр:**  $\text{conf} \geq 0.90$  – зөвхөн маш итгэлтэй таамгийг ашиглах

Overfitting шалгалтын гол шалгуур нь Train accuracy < Test accuracy байх ёстой бөгөөд 77.4% < 87.4% гэсэн үр дүн нь энэ шалгуурыг хангаж байна.

## 5.6. Мобайл аппликашний ажиллагаа

Мобайл аппликашн (Predictrix) нь бодит цагийн горимд ажиллаж, дараахь функциудыг гүйцэтгэнэ:

1. **20 валютын хосолд бодит ханш:** Twelve Data API-аас 60 секунд тутам шинэчлэгддэг
2. **ML дохио:** V10 ансамбль загварын BUY/SELL/HOLD дохио, итгэлцлийн хувь, SL/TP
3. **Эдийн засгийн мэдээ:** TradingView-ийн эдийн засгийн хуанли, Alpha Vantage мэдээ
4. **AI дүн шинжилгээ:** Google Gemini API ашигласан зах зээлийн шинжилгээ
5. **Хэрэглэгчийн систем:** Бүртгэл, нэвтрэлт, имэйл баталгаажуулалт, нууц үг сэргээх
6. **Дохионы түүх:** MongoDB-д хадгалагдсан арилжааны дохионы түүх ба статистик

## 5.7. Дүгнэлт

### Судалгааны гол үр дүн

Энэхүү судалгааны ажлаар машин сургалтын ансамбль аргыг ашиглан Forex зах зээлийн арилжааны дохио үүсгэх бүрэн систем амжилттай хөгжүүлсэн. Гол үр дүнгүүд:

1. **ML ансамбль загвар:** LightGBM, XGBoost, CatBoost гэсэн гурван GBDT загварын ансамбль нь 6 хугацааны хүрээний 48 шинж чанарыг ашиглан EUR/USD-ийн чиг хандлагыг амжилттай таамаглаж чадсан. Walk-forward validation-аар баталгаажуулсан тест дээрх нарийвчлал 87.4%, өндөр итгэлцэлтэй дохионы нарийвчлал 95%+ байсан.
2. **Бэктестийн гүйцэтгэл:** 2025 оны 10 сарын бодит зах зээлийн бэктестэд:
  - Өгөөж: +41.61% (S&P 500 дунджаас 3.5 дахин их)
  - Profit Factor: 2.46 (мэргэжлийн системийн түвшин)
  - Sharpe Ratio: 9.64 (хедж сангийн түвшнээс хавьгүй дээгүүр)
  - Max Drawdown: 3.93% (маш бага эрсдэлтэй)
3. **Мобайл аппликаши:** React Native дээр суурилсан бүрэн функциональ “Predictrix” аппликашнийг хөгжүүлж, бодит цагийн ханш, ML дохио, эдийн засгийн мэдээ, AI шинжилгээг нэг дор хүргэсэн.
4. **Overfitting шийдвэрлэлт:** 7 давталтат хөгжүүлэлтийн үе шатаар загварыг хялбаршуулж ( $75 \rightarrow 48$  шинж чанар,  $9 \rightarrow 3$  загвар), walk-forward validation-аар баталгаажуулж, overfitting-ийн асуудлыг бүрэн шийдсэн.

### Судалгааны шинэлэг тал

- **Олон хугацааны хүрээний шинж чанар:** 6 хугацааны интервалаас (M1–H4) шинж чанар тооцоолсноор “том зурагийг” авч үзэх чадвартай загвар бүтээсэн
- **Calibrated confidence:** Logistic Regression calibrator-аар загварын магадлалын утгыг найдвартай итгэлцлийн хэмжүүр болгосон
- **Чанар > тоо хэмжээ:** 359,639 таамгаас зөвхөн 1,065 (0.3%) чанартай дохио шүүж илрүүлдэг стратеги
- **End-to-end систем:** Загварын сургалтаас эхлээд мобайл аппликаши хүртэл бүрэн, нэгдмэл системийг хэрэгжүүлсэн

## Хязгаарлалт

Судалгааны ажлын зарим хязгаарлалтуудыг тодорхойлох нь чухал:

- Ганц валютын хослол:** Зөвхөн EUR/USD дээр сургагдсан – бусад хослолд шууд ашиглах боломжгүй
- Бэктест ба бодит арилжааны зөрүү:** Бэктест нь бодит арилжааны бүх нөхцлийг (жишээ нь төлбөрийн чадварын хягаарлалт, шуугиан) бүрэн дүрсэлж чаддаггүй
- Зах зээлийн горимын өөрчлөлт:** Зах зээлийн бүтцэд суурь өөрчлөлт гарвал загварын гүйцэтгэл буурч болно
- Арилжааны зардал:** Спрэд, слиппэж зэрэг зардлыг тооцсон ч комисс, своп зэргийг бүрэн тооцоогүй
- Бодит цагийн хүндрэл:** API rate limit, сүлжээний saat алгоритмийн асуудлууд

## Цаашдын чиглэл

Судалгааг цаашид дараахь чиглэлээр хөгжүүлэх боломжтой:

- Олон валютын хослолд өргөтгөх:** GBP/USD, USD/JPY зэрэг бусад хослолд загварыг сургаж, портфолио стратеги бүтээх
- Trailing Stop:** Нээлттэй позицын ашгийг хамгаалах динамик SL – Phase 4-т туршсан ч цаашид сайжруулах
- Гүн сургалтын загвар:** LSTM, Transformer зэрэг цуваа өгөгдлийн загваруудыг ансамбль-д нэмэх
- Бататгалт сургалт (Reinforcement Learning):** Портфолиогийн менежмент, позицын хэмжээ тохиуулалтад хэрэглэх
- Мэдээний шинжилгээ:** NLP ашиглан эдийн засгийн мэдээг автоматаар шинжилж, загварт оруулах
- Cloud deployment:** AWS/GCP дээр Backend-ийг байршуулж, App Store/Google Play дээр апп нийтлэх

## Эцсийн дүгнэлт

Машин сургалтын ансамбль загвар нь Forex зах зээл дээр ашигтай арилжааны дохио үүсгэх чадвартай болохыг энэхүү судалгаа бодитоор батлав. +41.61% өгөөж, 9.64 Sharpe Ratio, 3.93% Max Drawdown зэрэг хэмжүүрүүд нь мэргэжлийн хөрөнгө оруулалтын сангийн түвшний гүйцэтгэл юм. Гэхдээ санхүүгийн зах зээр дэх аливаа загвар бүрэн төгс биш бөгөөд эрсдэлийн менежмент, тогтмол дахин сургалт, шинэ нөхцөлд дасан зохицох чадвар нь тасралтгүй сайжруулалт шаарддаг.

Систем нь загвар сургалтаас эхлээд эцсийн хэрэглэгч хүртэлх бүрэн process-ийг амжилттай хэрэгжүүлсэн бөгөөд энэ нь машин сургалт, back-end хөгжүүлэлт, мобайл аппликацийн хөгжүүлэлт зэрэг олон салбарыг хамарсан цогц инженерийн ажил юм.

**Ном зүй**

## Номзүй

- [1] Bank for International Settlements. Triennial central bank survey of foreign exchange and over-the-counter (otc) derivatives markets in 2022. Technical report, Bank for International Settlements, Basel, Switzerland, 2022.
- [2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.
- [3] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154. NeurIPS, 2017.
- [4] Joarder Kamruzzaman and Ruhul A Sarker. Forecasting of currency exchange rates using ann: A case study. *International Conference on Neural Networks and Signal Processing*, pages 793–797, 2003.
- [5] Manish Kumar and M Thenmozhi. Forecasting stock index movement: A comparison of support vector machines and random forest. *Indian Institute of Capital Markets 9th Capital Markets Conference Paper*, 2006. Available at SSRN.
- [6] Michel Ballings, Dirk Van den Poel, Nathalie Hespeels, and Ruben Gryp. Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20):7046–7056, 2015.
- [7] Thomas Fischer and Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018.
- [8] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep learning for financial time series forecasting: A systematic literature review and future research directions. *Applied Soft Computing*, 97, 2019.
- [9] Christopher Krauss, Xuan Anh Do, and Nicolas Huck. Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the s&p 500. *European Journal of Operational Research*, 259(2):689–702, 2017.
- [10] Jerome H Friedman. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- [11] Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [12] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [13] Thomas G Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.
- [14] Leo Breiman. Random forests. *Machine learning*, 45:5–32, 2001.
- [15] Omer Berat Sezer, Mehmet Ugur Gudelek, and Ahmet Murat Ozbayoglu. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [16] John J Murphy. Technical analysis of the financial markets: A comprehensive guide to trading methods and applications. *New York Institute of Finance*, 1999.
- [17] Eugene F Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970.

- [18] Andrew W Lo, Harry Mamaysky, and Jiang Wang. Foundations of technical analysis: Computational algorithms, statistical inference, and empirical implementation. *The Journal of Finance*, 55(4):1705–1765, 2000.
- [19] Dennis Olson. Have trading rule profits in the currency markets declined over time? *Journal of Banking & Finance*, 28(1):85–105, 2004.
- [20] William Brock, Josef Lakonishok, and Blake LeBaron. Simple technical trading rules and the stochastic properties of stock returns. *The Journal of Finance*, 47(5):1731–1764, 1992.
- [21] Ben R Marshall, Rochester H Cahan, and Jared M Cahan. Can commodity futures be profitably traded with quantitative market timing strategies? *Journal of Banking & Finance*, 32(9):1810–1819, 2008.
- [22] Cheol-Ho Park and Scott H Irwin. What do we know about the profitability of technical analysis? *Journal of Economic Surveys*, 21(4):786–826, 2007.
- [23] Robert Pardo. *The evaluation and optimization of trading strategies*. John Wiley & Sons, 2008.
- [24] David H Bailey, Jonathan M Borwein, Marcos Lopez de Prado, and Qiji Jim Zhu. The probability of backtest overfitting. *Journal of Computational Finance*, 20(4):39–69, 2014.
- [25] Meta Platforms, Inc. React native: Learn once, write anywhere, 2023. Accessed: 2024-12-01.
- [26] Bonnie Eisenman. *Learning React Native: Building Native Mobile Apps with JavaScript*. O'Reilly Media, 2nd edition, 2018.
- [27] Sebastián Ramírez. Fastapi: Modern, fast (high-performance), web framework for building apis with python, 2023. Accessed: 2024-12-01.

## Хавсралт

### A. Загварын код (Python)

#### A.1 Шинж чанар тооцоолох функц

**Listing 5.1** Олон хугацааны хүрээний шинж чанар тооцоолол

```
1 def compute_features(df, suffix):
2     close = df["close"]
3     feats = pd.DataFrame(index=df.index)
4     feats[f"close_{suffix}"] = close
5     feats[f"rsi_{suffix}"] = rsi(close, 14)
6     feats[f"atr_{suffix}"] = atr(df, 14)
7     feats[f"ma_5_{suffix}"] = close.rolling(5).mean()
8     feats[f"ma_20_{suffix}"] = close.rolling(20).mean()
9     feats[f"ma_50_{suffix}"] = close.rolling(50).mean()
10    feats[f"volatility_{suffix}"] = close.rolling(20).std()
11    feats[f"returns_{suffix}"] = close.pct_change()
12    return feats
```

#### A.2 Ансамбль загварын сургалт

**Listing 5.2** Walk-Forward Validation сургалт

```
1 # Walk-Forward Validation: 2015-2023 train, 2023 val, 2024 test
2 train_end = "2023-01-01"
3 val_end = "2024-01-01"
4 train_df = df[df["time"] < train_end]
5 val_df = df[(df["time"] >= train_end) & (df["time"] < val_end)]
6 test_df = df[(df["time"] >= val_end) & (df["time"] < TEST_START_DATE)]
7
8 # Train GBDT models
9 for seed in [42]:
10    models = fit_models(X_fit, y_fit, seed, pos_weight, X_val, y_val)
11
12 # Calibration with Logistic Regression
13 cal = LogisticRegression(max_iter=1000)
14 cal.fit(predict_proba(models_flat, X_cal).reshape(-1, 1), y_cal)
```

#### A.3 Дохио шүүлтүүрлэх

**Listing 5.3** Дохионы шүүлтүүрийн тохиргоо

```
1 CONF_THRESHOLD = 0.90      # Confidence >= 90%
2 MIN_ATR_PIPS = 4.0        # ATR >= 4.0 pips
3 SL_MULT = 5.0            # SL = ATR * 5
4 TP_MULT = 15.0           # TP = ATR * 15 (SL * 3)
5 MIN_SL_PIPS = 15.0        # Minimum SL: 15 pips
6 MIN_TP_PIPS = 45.0        # Minimum TP: 45 pips
```

## B. Backend API код

### B.1 Дохио үүсгэх endpoint

**Listing 5.4** Flask API – V10 дохио үүсгэх

```
1 @app.route('/signal/v2', methods=['GET'])
2 def get_signal_v2():
3     min_confidence = float(
4         request.args.get('min_confidence', 85))
5     pair = request.args.get('pair', 'EUR/USD')
```

```

7   # Historical data (500 bars, 1min)
8   df = get_twelvedata_dataframe(
9       interval="1min", outputsize=500, symbol=pair)
10
11  if df is None or len(df) < 200:
12      return jsonify({'error': 'rate_limited'}), 429
13
14  # Generate signal with V10 ensemble
15  signal = signal_generator.generate_signal(
16      df, min_confidence)
17
18  return jsonify({'success': True, **signal})

```

## C. MetaTrader 5 Expert Advisor

### C.1 Эрсдэлд сууринсан лотын тооцоолол

**Listing 5.5 MQL5 – Лотын тооцоолол**

```

1 double CalcLotByRisk(const string sym, double sl_pips)
2 {
3     if(sl_pips <= 0.0)
4         return SymbolInfoDouble(sym, SYMBOL_VOLUME_MIN);
5
6     double bal = AccountInfoDouble(ACCOUNT_BALANCE);
7     double risk = bal * (RiskPerTrade / 100.0);
8     double pip = PipSizeForSymbol(sym);
9     double tick_val = SymbolInfoDouble(sym,
10                                         SYMBOL_TRADE_TICK_VALUE);
11    double tick_sz = SymbolInfoDouble(sym,
12                                         SYMBOL_TRADE_TICK_SIZE);
13    double pip_val = tick_val * (pip / tick_sz);
14    double vol = risk / (sl_pips * pip_val);
15    return ClampVolumeForSymbol(sym, vol);
16 }

```

## D. Мобайл аппликацийн код

### D.1 React Native – Ханшийн дэлгэц

**Listing 5.6 React Native – Бодит цагийн хани**

```

1 const { data: liveRates, isLoading, refetch } = useQuery({
2     queryKey: ["liveRates"],
3     queryFn: async () => {
4         const result = await getLiveRates();
5         if (result.success) {
6             const ratesMap = {};
7             const rates = result.data.rates || {};
8             Object.keys(rates).forEach((key) => {
9                 const pairName = key.replace("_", "/");
10                ratesMap[pairName] = rates[key];
11            });
12            return ratesMap;
13        }
14        return {};
15    },

```

```
16     refetchInterval: 60000, // 60 sec
17 });

```

## E. 2025 оны дохионы жишээ

Дохионы CSV файлын формат болон зарим жишээ:

**Хүснэгт 5.6 2025 оны дохионы жишээ**

Цаг	Sym	Чиглэл	Conf	SL	TP
2025-01-14 13:30	EURUSD	BUY	0.930	21	64
2025-01-14 13:32	EURUSD	BUY	0.934	28	85
2025-01-23 14:00	EURUSD	BUY	0.921	25	75
2025-02-03 16:00	EURUSD	SELL	0.920	33	100
2025-03-07 15:30	EURUSD	BUY	0.912	20	60
2025-05-14 13:00	EURUSD	BUY	0.945	30	90

Нийт 1,065 дохио, 90%+ confidence, ATR  $\geq$  4.0 пипс шүүлтүүртэй.

## **Талархал**

Энэхүү төгсөлтийн судалгааны ажлыг амжилттай гүйцэтгэхэд маш их туслалцаа, дэмжлэг үзүүлсэн хүмүүстээ чин сэтгэлийн талархал илэрхийлье.

Юуны өмнө миний удирдагч багш **Н.Соронзонболд** багшдаа гүн талархал илэрхийлж байна. Тэрээр судалгааны ажлын чиглэлийг тодорхойлох, арга зүйн зөвлөгөө өгөх, мөн бүхий л үйл явцад чиглүүлэг өгч байсанд маш их баярлалаа.

**Шинэ Монгол Технологийн Коллеж-ийн** Компьютерын ухааны тэнхимийн бүх багш нарт сургалтын хөтөлбөрийн туршид олгосон мэдлэг, чадварт нь талархаж байна. Тэдний заасан хичээлүүд энэхүү судалгааны ажлын суурь болсон юм.

Түүнчлэн машин сургалт, гүн сургалтын салбарт нээлттэй эх код, онлайн нөөц материал бүтээсэн олон улсын нийгэмлэгт талархал илэрхийлье. PyTorch, React Native, FastAPI зэрэг нээлттэй эхийн хөгжүүлэгчид, мөн санхүүгийн өгөгдөл нийлүүлэгчдийн хүчин чармайлтгүйгээр энэ судалгаа боломжгүй байсан юм.

Эцэст нь миний гэр бүлд, ялангуяа эцэг эх, ах дүү нартаа хязгааргүй их талархаж байна. Тэдний урамшуулал, дэмжлэг надад хэзээ ч дутагдаагүй.

**М.Мөнхдорж**  
2026 оны 2-р сар